



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الوطنية الخاصة
كلية الهندسة
قسم هندسة الحاسوب

مشروع أعد لنيل درجة الإجازة في هندسة الحاسوب بعنوان:

استخدام الذكاء الاصطناعي في تشخيص أمراض الفم والأسنان

إعداد الطالبة:

هاجر ممدوح حداد

إشراف:

الدكتور المهندس أحمد رياض كردي

2025 – 2026

يهدف هذا المشروع إلى تطوير نظام ويب ذكي لتشخيص أمراض الفم والأسنان بالاعتماد على أحدث تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، حيث يقدم منصة تشخيصية تفاعلية تعمل على تحليل الصور الرقمية (السريية والشعاعية) بدقة وسرعة عاليتين. يعتمد النظام في جوهره على نموذج لغوي رؤيوي (Vision-Language Model - VLM) متقدم، مثل Gemini 3.1 Pro، الذي يقوم بفهم الصورة سياقياً وتوليد تقرير تشخيصي أولي باللغة العربية على هيئة JSON صارم، يتضمن تفاصيل الأمراض المكتشفة (مثل التسوس، والتهاب اللثة، والكسور) مع تحديد مواقعها باستخدام نظام التقييم العالمي (FDI).

وللتغلب على قيود الصناديق الإحاطة التقريبية (Bounding Boxes)، تم دمج نموذج التجزئة الدقيق SAM (Segment Anything Model) من Meta، والذي يقوم بقص المنطقة المصابة بدقة على مستوى البكسل وإنتاج مضلعات (Polygons) تحدد حدود المرض بشكل تشريحي دقيق. صُمم النظام بمعمارية حديثة تفصل بين الواجهة الأمامية والخلفية؛ حيث طُورت الواجهة باستخدام React 19 و TypeScript لتوفير تجربة مستخدم سلسة مع خريطة أسنان تفاعلية ووضع دأكن، بينما يعمل الخادم الخلفي بـ Flask و Python لاستدعاء واجهات برمجة التطبيقات السحابية (Gemini/Kimi) وتشغيل نموذج SAM محلياً، مع الاعتماد على قاعدة بيانات SQLite لإدارة سجلات المرضى والفحوصات والتقييمات الطبية. كما يتضمن النظام موسوعة طبية تفاعلية ومركز دعم بالمحادثة الآلية.

يسهم هذا التكامل بين النماذج السحابية متعددة الوسائط والتجزئة المحلية في توفير أداة تشخيصية مساعدة عالية الدقة، تدعم اتخاذ القرار الطبي، وتقلل الاعتماد على الفحص اليدوي، مع إمكانية التوسع مستقبلاً ليشمل المزيد من الأمراض وتحليلات الصور المتقدمة.

الكلمات المفتاحية: النماذج اللغوية الرؤيوية (VLMs)، التجزئة الدقيقة (SAM)، تشخيص الأسنان الآلي، المنصات الطبية التفاعلية، الذكاء الاصطناعي التوليدي في الطب.

Abstract

This project aims to develop an intelligent web-based system for diagnosing oral and dental diseases using state-of-the-art artificial intelligence and computer vision techniques. It provides an interactive diagnostic platform that analyzes digital images (both clinical and radiographic) with high accuracy and efficiency. At its core, the system employs an advanced Vision-Language Model (VLM), such as Gemini 3.1 Pro, which contextually interprets the image and generates an initial diagnostic report in Arabic as a strict JSON schema. This report includes detailed information about detected conditions (e.g., caries, gingivitis, fractures) and localizes them using the global FDI tooth numbering system.

To overcome the limitations of approximate bounding boxes, the system integrates Meta's Segment Anything Model (SAM) for precise segmentation. SAM generates pixel-accurate polygons that delineate the exact anatomical boundaries of each detected lesion. The system follows a modern full-stack architecture: the frontend is built with React 19 and TypeScript, providing a seamless user experience with an interactive tooth map and dark mode, while the backend is powered by Flask and Python to handle API calls to cloud-based VLMs (Gemini/Kimi) and run the SAM model locally. All patient records, scans, and medical evaluations are managed via an SQLite database. Additionally, the platform features an interactive medical encyclopedia and an AI-powered support chatbot.

This hybrid integration of cloud-based multimodal AI with local, high-precision segmentation delivers a robust computer-aided diagnostic tool that enhances clinical decision-making, reduces reliance on manual examination, and lays a solid foundation for future expansion to include a wider range of oral pathologies and advanced imaging modalities.

Abstract

Keywords: Vision-Language Models (VLMs), Segment Anything Model (SAM), Automated Dental Diagnosis, Interactive Medical Platforms, Generative AI in Medicine.

- الشكل (1-1): أمثلة لصور سريرية ونتائج الاختبار المقابلة لها باستخدام خوارزميات الذكاء الاصطناعي.....7
- الشكل (1-2): صورة شعاعية بانورامية (تمت معالجتها مسبقًا كمدخلات للنموذج) مختارة من مجموعة بيانات الاختبار.....8
- الشكل (1-3): أمثلة لصور سرطان الخلايا الحشفية الفموي (OSCC) والاضطرابات الفموية المحتمل تسرطنها (OPMDs) من مجموعة البيانات.....9
- الشكل (1-4): أمثلة على كشف تسوس الأسنان في صور الاختبار.....10
- الشكل (1-5): اقتصاص صور الزرع السني لعزل كل غرسة على حدة.....12
- الشكل (2-1): العصبون الصناعي.....18
- الشكل (2-2): بنية الشبكة العصبية الاصطناعية.....24
- الشكل (2-3): دوال التنشيط.....25
- الشكل (2-4): الشبكة العصبية العميقة.....29
- الشكل (2-5): التعلم الآلي.....31
- الشكل (2-6): آلية عمل شبكة الالتفاف.....33
- الشكل (2-7): الفلتر (Filter).....34
- الشكل (2-8): عملية التجميع.....35
- الشكل (2-9): عملية الحشو.....36
- الشكل (2-10): الأشعة البانورامية للأسنان.....37
- الشكل (2-11): صورة CBCT.....38

الشكل (2-12): ضغط الصور.....	39
الشكل (3-1): توضيح لمفهوم التصنيف مع تحديد الموقع باستخدام صندوق إحاطة.....	49
الشكل (3-2): تمييز وفصل كائنات متعددة ومختلفة الأحجام في صورة واحدة.....	50
الشكل (3-3): تحديد حدود السن بدقة البكسل لتمثيل الشكل التشرحي بدقة متناهية.....	51
الشكل (3-4): بنية نموذج لغوي رؤيوي (VLM) متكامل مع مشفر الصورة ومشفر النص وطبقة الدمج المتقاطع.....	53
الشكل (3-5): نظام FDI للترقيم.....	54
الشكل (3-6): بنية SAM.....	57
الشكل (4-1): مخطط حالات الاستخدام (Use Case Diagram) يوضح تفاعلات المستخدمين مع نظام Smart Dent AI.....	66
الشكل (4-2): مخطط المكونات (Component Diagram) يوضح البنية البرمجية للنظام وتفاعل مكوناته.....	67
الشكل (4-3): مخطط الحالة (State Diagram) يوضح دورة حياة فحص المريض في نظام Smart Dent AI.....	71
الشكل (4-4): مخطط العلاقات بين الجداول (ERD) يوضح بنية قاعدة بيانات Smart Dent AI وعلاقاتها.....	77
الشكل (4-5): شاشة لوحة التحكم الرئيسية لنظام Smart Dent AI.....	80
الشكل (4-6): شاشة إدارة بيانات المرضى في نظام Smart Dent AI.....	82
الشكل (4-7): شاشة خريطة الأسنان التفاعلية بنظام الترقيم العالمي FDI.....	83

الشكل (4-8): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الأول.....	85
الشكل (4-9): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الثاني.....	86
الشكل (4-10): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الثالث.....	86
الشكل (4-11): شاشة التقارير العلاجية ومحرر التقرير الطبي.....	87
الشكل (4-12): شاشة التسعير والتكاليف في نظام Smart Dent AI.....	88
الشكل (4-13): شاشة الموسوعة الطبية في نظام Smart Dent AI.....	89
الشكل (4-14): نتائج تدريب نموذج YOLOv8 باستخدام Google Colab.....	95
الشكل (4-15): منحنى الدقة مقابل الاستدعاء (Precision-Recall Curve) لنموذج YOLOv8 المقترح للأصناف المرضية الأربعة.....	97

الجدول (3-1): إصدارات SAM المتاحة.....	59
الجدول (3-2): مقارنة بين النماذج اللغوية الرؤيوية ونماذج الكشف التقليدية.....	60
الجدول (4-1): أوقات الاستجابة المقاسة.....	90
الجدول (4-2): النتائج المقاسة على صور اختبار متنوعة.....	91
الجدول (4-3): مقارنة بين النموذج المحلي والنماذج السحابية.....	92
الجدول (4-4): مؤشرات الأداء العامة لنموذج YOLOv8 على مجموعة بيانات الأشعة السنية الفموية.....	95
الجدول (4-5): تحليل دقة الكشف ($mAP@0.5$ ، الاستدعاء، والدقة) بحسب الصنف المرضي لنموذج YOLOv8.....	96
الجدول (4-6): المقارنة التقنية والأدائية بين نموذج YOLOv8 المحلي والنهج المُقترح (VLM + SAM).....	98

0 مقدمة.....	1
1 الفصل الأول: الدراسة المرجعية.....	6
1-1 مراجعة الدراسات السابقة.....	7
2-1 الفجوة البحثية.....	14
2 الفصل الثاني: المفاهيم النظرية.....	17
1-2 مقدمة.....	18
2-2 المبادئ الأساسية للشبكات العصبية الاصطناعية.....	18
1-2-2 العصبون الاصطناعي (Artificial Neuron).....	18
2-2-2 الشبكة العصبية (Neural Network).....	21
3-2-2 دالة التنشيط (Activation Function).....	24
3-2 التعلم العميق وشبكات الالتفاف العصبية.....	27
1-3-2 مفهوم التعلم العميق (Deep Learning).....	27
2-3-2 عملية التعلم الآلي والتدريب (Machine Learning & Training).....	30
4-2 البنية المعمارية لشبكات الالتفاف العصبية.....	31
1-4-2 أهمية شبكات الالتفاف العصبية.....	31
2-4-2 خطوات عمل شبكة الالتفاف العصبية.....	33
5-2 التطبيقات العملية في طب الفم والأسنان.....	36

36	1-5-2 التطبيقات التشخيصية.....
38	2-5-2 ضغط الصور الطبية.....
39	6-2 نماذج اللغة الكبيرة (Large Language Models – LLMs).....
	1-6-2 مفهوم النماذج اللغوية الرؤيةية (Concept of Vision-Language Models)
41	
41	2-6-2 آلية عمل النماذج اللغوية الرؤيةية (Working Mechanism of VLMs).....
42	3-6-2 نموذج التجزئة الدقيقة (SAM (Segment Anything Model).....
44	4-6-2 التحديات والقيود في النماذج اللغوية الرؤيةية ونماذج التجزئة.....
44	5-6-2 تقنيات تحسين موثوقية النماذج.....
46	3 الفصل الثالث: النماذج اللغوية الرؤيةية ونماذج التجزئة الدقيقة.....
47	1-3 مقدمة.....
48	2-3 المفاهيم الجوهرية في الرؤية الحاسوبية الطبية الحديثة.....
48	1-2-3 التصنيف (Classification) وتحدياته.....
48	2-2-3 التصنيف مع تحديد الموقع (Classification + Localization).....
50	3-2-3 الكشف عن الكائنات (Object Detection).....
51	4-2-3 التجزئة المثيلية (Instance Segmentation).....
52	3-3 النماذج اللغوية الرؤيةية (Vision-Language Models - VLMs).....

52	1-3-3 المكونات الأساسية للنماذج اللغوية الرؤيةية.....
53	2-3-3 نظام الترقيم العالمي (FDI Tooth Numbering System)
54	3-3-3 آلية عمل النماذج اللغوية الرؤيةية في التشخيص الطبي.....
56	4-3-3 دالة الخسارة والتدريب
56	4-3 نموذج التجزئة الدقيقة (SAM (Segment Anything Model)
56	1-4-3 المكونات الأساسية لنموذج SAM
58	2-4-3 نسبة التقاطع على الاتحاد (Intersection over Union – IoU)
59	3-4-3 إصدارات SAM المتاحة.....
60	5-3 مقارنة بين النماذج اللغوية الرؤيةية ونماذج الكشف التقليدية.....
60	6-3 استراتيجية تحسين أداء النظام.....
60	1-6-3 تحسين زمن SAM.....
61	2-6-3 تحسين دقة النموذج اللغوي الرؤيةي.....
62	7-3 التطبيقات العملية في النظام المقترح.....
62	1-7-3 تحليل الصور السريرية والشعاعية.....
62	2-7-3 توليد التقرير التشخيصي.....
63	3-7-3 التكامل مع SAM.....
64	4 الفصل الرابع: التنفيذ العملي.....

1-4	مقدمة.....	65
2-4	نظرة عامة على النظام.....	65
3-4	معمارية النظام.....	67
4-4	تدفق عمل النظام.....	70
5-4	دمج النماذج اللغوية الرؤيوية ونظام التجزئة الدقيقة.....	74
2-5-4	استدعاء النموذج اللغوي الرؤيوي.....	74
2-5-4	نموذج التجزئة الدقيقة.....	75
6-4	قاعدة البيانات وبنية البيانات.....	76
7-4	تنفيذ واجهة المستخدم.....	79
1-7-4	شاشة لوحة التحكم.....	80
2-7-4	شاشة بيانات المرضى.....	81
3-7-4	شاشة خريطة الأسنان التفاعلية.....	82
4-7-4	شاشة تقرير التشخيص الذكي.....	84
5-7-4	شاشة التقارير العلاجية.....	87
6-7-4	شاشة التسعير والتكاليف.....	88
7-7-4	شاشة الموسوعة الطبية.....	89
8-4	أداء النظام وتقييمه.....	90

90	1-8-4 زمن الاستجابة
91	2-8-4 دقة التجزئة.....
92	3-8-4 مقارنة بين النموذج المحلي والنماذج السحابية.....
92	4-8-4 مناقشة النتائج.....
	5-8-4 دراسة مقارنة: أداء أنظمة الكشف التقليدية (YOLO) مقابل النهج المُقترح
94	(VLM + SAM).....
100	5 الفصل الخامس: الخاتمة والآفاق المستقبلية.....
101	1-5 الخاتمة.....
103	2-5 الآفاق المستقبلية.....

الاختصارات

الاختصار	المصطلح الكامل	المعنى بالعربية
AI	Artificial Intelligence	الذكاء الاصطناعي
API	Application Programming Interface	واجهة برمجة التطبيقات
CNN	Convolutional Neural Network	الشبكة العصبية الالتفافية
FDI	Fédération Dentaire Internationale	نظام الترقيم العالمي للأسنان
Flask	Flask (Python Web Framework)	إطار عمل ويب بلغة Python
Gemini	Google Gemini	النموذج اللغوي للرؤيوي من Google
GPU	Graphics Processing Unit	وحدة معالجة الرسومات
GUI	Graphical User Interface	واجهة المستخدم الرسومية
IoU	Intersection over Union	نسبة التقاطع على الاتحاد
JSON	JavaScript Object Notation	تنسيق تبادل البيانات
LLM	Large Language Model	نموذج اللغة الكبير
NLP	Natural Language Processing	معالجة اللغة الطبيعية
OpenCV	Open-Source Computer Vision Library	مكتبة الرؤية الحاسوبية مفتوحة المصدر
PDF	Portable Document Format	تنسيق المستندات المحمول
Polygon	Polygon (Segmentation Output)	مضلع (ناتج التجزئة الدقيقة)
Prompt	Prompt	التعليمات/الموجه النصي للنموذج اللغوي
PyTorch	PyTorch (Deep Learning Framework)	إطار عمل التعلم العميق
RAG	Retrieval-Augmented Generation	الاسترجاع المعزز بالتوليد
React	React (JavaScript Library)	مكتبة JavaScript لبناء الواجهات
ReLU	Rectified Linear Unit	دالة التنشيط الخطية المعدلة
SAM	Segment Anything Model	نموذج التجزئة الدقيقة من Meta
SPA	Single Page Application	تطبيق الصفحة الواحدة
SQLite	SQLite (Database Engine)	نظام إدارة قواعد البيانات
TypeScript	TypeScript (JavaScript Superset)	لغة برمجة مبنية على JavaScript
VLM	Vision-Language Model	النموذج اللغوي للرؤيوي

مقدمة

تُعدّ تقنيات الذكاء الاصطناعي في التشخيص الطبي من الركائز الأساسية في تحسين جودة الرعاية الصحية ودقة التشخيص، خصوصاً في المجالات الحساسة مثل طب الأسنان، حيث يُعدّ الكشف المبكر عن أمراض الفم والأسنان عاملاً حاسماً في الوقاية والعلاج. ومع ازدياد انتشار أمراض الفم مثل التسوس السني، والتهاب اللثة، والكسور السنية، وأمراض دواعم السن، أصبح الاعتماد على الطرق التقليدية، كالفحص البصري اليدوي أو الصور الشعاعية غير المحللة، غير كافٍ لتحقيق الدقة والسرعة المطلوبتين في التشخيص. لذلك، اتجهت الأبحاث الطبية الحديثة إلى استخدام الأنظمة الذكية التي تعتمد على تحليل الصور آلياً للكشف عن المشكلات الفموية في الزمن الحقيقي. ومع ذلك، اقتصرت معظم الأنظمة السابقة على تقنيات الكشف عن الأجسام (Object Detection) باستخدام صناديق إحاطة (Bounding Boxes) تقريبية، مما يحد من دقة تحديد المنطقة المصابة، كما أنها غالباً ما كانت تطبيقات سطح مكتب محدودة النطاق لا تستوعب التنوع الكبير للأمراض الفموية ولا توفر تجربة تفاعلية شاملة للمستخدم أو الطبيب.

ينتمي مشروع "استخدام الذكاء الاصطناعي في تشخيص أمراض الفم والأسنان" بصورته المُطوّرة إلى الجيل الحديث من تطبيقات الذكاء الاصطناعي في الطب، الذي يجمع بين تقنيات النماذج اللغوية الرؤيةية (Vision-Language Models - VLMs) والتجزئة الدقيقة (Semantic Segmentation) لتجاوز قيود الأنظمة التقليدية. يعتمد النظام المقترح على نموذج Gemini 3.1 Pro كأحد أبرز النماذج اللغوية الرؤيةية، القادر على فهم الصورة سياقياً وتوليد تقارير تشخيصية باللغة العربية على هيئة JSON صارم يتضمن وصفاً دقيقاً للحالة وتوصيات علاجية، مع تحديد مواقع الأمراض باستخدام نظام الترقيم العالمي (FDI). كما

يُدمج النظام نموذج (SAM (Segment Anything Model من Meta، وهو نموذج تجزئة متقدم يُنتج مضلعات (Polygons) دقيقة على مستوى البكسل تحدد حدود الإصابة تشريحياً، مما يمنح الطبيب دقة جراحية في تحديد المنطقة المصابة. وتُعد هذه التقنيات نقلة نوعية في مجال التشخيص الطبي، إذ تتيح الانتقال من مجرد "الكشف" إلى "الفهم والتفسير" مع دقة تحديد مكانية غير مسبوقة.

تُعد أنظمة التشخيص الذكي عنصراً أساسياً في تطوير الطب الحديث والارتقاء بمستوى الخدمات الصحية، إذ تلعب دوراً حيوياً في الكشف المبكر عن الأمراض وتحليلها في مراحلها الأولى، وتتجاوز اليوم مجرد توثيق الصور الطبية لتصبح أدوات تحليلية استباقية تساهم في فهم الأنماط المرضية واكتشاف التغيرات غير الطبيعية. وقد صُمم هذا المشروع ليكون منصة ويب (Web-based) متكاملة، تعتمد على بنية حديثة تفصل بين الواجهة الأمامية والخادم الخلفي، حيث طُوّرت الواجهة باستخدام React 19 و TypeScript لتوفير تجربة مستخدم سلسة مع خريطة أسنان تفاعلية تظلل الأسنان المصابة تلقائياً، وموسوعة طبية، ومركز دعم بالمحادثة الآلية، بينما يعمل الخادم الخلفي بـ Flask و Python لاستدعاء واجهات برمجة التطبيقات السحابية للنماذج اللغوية الرؤيةية (Gemini و Kimi) وتشغيل نموذج SAM محلياً، مما يحقق توازناً مثالياً بين قوة التحليل السحابي وسرعة المعالجة المحلية، مع الاعتماد على قاعدة بيانات SQLite لإدارة سجلات المرضى والفحوصات والتقييمات الطبية بشكل آمن ومنظم. ويسهم هذا التكامل في توفير أداة تشخيصية مساعدة سهلة الفهم، تدعم الطبيب والمريض على حد سواء، وتسرع عملية اتخاذ القرار الطبي، وتحسن جودة الرعاية الصحية المقدمة، مع الاحتفاظ بالدور المحوري للطبيب في اتخاذ القرار العلاجي النهائي.

فيما يلي الأهداف الرئيسية لهذا المشروع المُطوّر:

1. بناء منصة ويب تشخيصية متكاملة تعتمد على 19 React و TypeScript في الواجهة الأمامية، و Flask مع Python في الخادم الخلفي، لتوفير بيئة عمل تفاعلية وسهلة الاستخدام عبر المتصفح.
2. توظيف النماذج اللغوية الرؤيوية (VLMs) مثل Gemini 3.1 Pro و Kimi k2.6 لتحليل الصور السنّية (السريديّة والشعاعية) وفهمها سياقياً، وتوليد تقارير تشخيصية أولية باللغة العربية على هيئة JSON تتضمن وصف الأمراض المكتشفة، وتحديد مواقعها باستخدام نظام التقييم العالمي (FDI)، وتقديم توصيات علاجية مناسبة.
3. دمج نموذج التجزئة الدقيقة (Segment Anything Model) SAM من Meta لتجاوز حدود الصناديق الإحاطة التقريبية، وإنتاج مضلعات (Polygons) تحدد المنطقة المصابة بدقة على مستوى البكسل، مما يمنح الطبيب رؤية تشريحية دقيقة للمرض.
4. تطوير واجهة مستخدم تفاعلية تتضمن خريطة أسنان (Tooth Map) تُظلل الأسنان المصابة تلقائياً بناءً على نتائج التحليل، مع دعم الوضع الداكن/الفاتح، وموسوعة طبية تفاعلية تضم 8 أمراض سنّية، ومركز دعم يعتمد على المحادثة الآلية (Chatbot).
5. اعتماد قاعدة بيانات متكاملة (SQLite) لإدارة سجلات المرضى، والفحوصات، والاكتشافات المرضية، والتقييمات الطبية، مما يتيح تتبع الحالات الصحية ومقارنة النتائج عبر الزمن.
6. إتاحة تصدير التقارير التشخيصية بتنسيق PDF لتسهيل مشاركة النتائج مع الأطباء والمرضى، وحفظها في السجلات الطبية الإلكترونية.





7. اختبار أداء النظام من حيث دقة التجزئة (باستخدام مقياس IOU) وزمن الاستجابة في بيئات تشغيل مختلفة، لضمان تحقيق توازن بين الدقة والسرعة يلبي متطلبات البيئة السريية.

الفصل الأول: الدراسة

المرجعية

1-1 مراجعة الدراسات السابقة


شهدت السنوات الخمس الأخيرة طفرة نوعية في دمج تقنيات الذكاء الاصطناعي ضمن طب الأسنان، حيث ركزت الأبحاث الحديثة على تطوير خوارزميات قادرة على التشخيص الدقيق لمختلف اعتلالات الفم والأسنان، بدءاً من تسوس الأسنان ووصولاً إلى سرطانات الفم. في دراسة بعنوان "الكشف عن تسوس الأسنان باستخدام التعلم العميق في الصور داخل الفم"، ركز الباحثون على تحسين دقة الكشف المبكر عن التسوس باستخدام شبكات عصبية تلافيفية (CNNs) مدربة على مجموعة بيانات ضخمة، وأظهرت النتائج دقة تشخيصية تجاوزت 92% مقارنة بالفحص التقليدي، مما يعزز من فرص العلاج التحفظي [1].

Expert diagnosis	AI diagnosis	Expert diagnosis	AI diagnosis
Cavitated caries	0.0%/ 3.2%/ 96.8% Cavitated caries	No caries	100.0%/ 0.0%/ 0.0% No caries
			
No caries	99.8%/ 0.2%/ 0.0% No caries	Non-cavitated caries	0.0%/ 98.3%/ 1.7% Non-cavitated caries
			
Cavitated caries	0.0%/ 0.0%/ 100.0% Cavitated caries	Non-cavitated caries	0.0%/ 100.0%/ 0.0% Non-cavitated caries
			

الشكل (1-1): أمثلة لصور سريرية ونتائج الاختبار المقابلة لها باستخدام خوارزميات الذكاء الاصطناعي.

وفي سياق متصل بأمراض اللثة، قدمت دراسة "نظام التشخيص الآلي لالتهاب اللثة باستخدام الصور الفوتوغرافية عبر الهواتف الذكية" حلاً مبتكراً يعتمد على خوارزميات (Mask R-CNN) لتحليل صور اللثة الملتقطة بواسطة المرضى، حيث حقق النظام حساسية عالية في تحديد علامات الالتهاب وتصنيفها، مما يفتح الباب أمام الطب عن بُعد [2].


وللتعمق في تشخيص الآفات الذروية، تناولت دراسة "الكشف عن الآفات الذروية في الصور البانورامية باستخدام الشبكات العصبية العميقة" تطوير نموذج (U-Net) لتجزئة وكشف الآفات في العظم المحيط بالجذر، وخلصت الدراسة إلى أن النموذج قادر على اكتشاف الآفات الصغيرة التي قد يغفل عنها أطباء الأسنان المبتدئون، بدقة بلغت 93% [3].



الشكل (1-2): صورة شعاعية بانورامية (تمت معالجتها مسبقاً كمدخلات للنموذج) مختارة من مجموعة بيانات الاختبار.

وبالانتقال إلى الحالات الأكثر تعقيداً، استهدفت دراسة "تصنيف سرطانات الفم والآفات ما قبل السرطانية باستخدام الشبكات العصبية التلافيفية" استخدام تقنيات نقل التعلم (Transfer

Learning) عبر نماذج (ResNet-50) لتحليل الصور السريرية للآفات المشبوهة، وأثبتت النتائج قدرة فائقة للذكاء الاصطناعي على التمييز بين الأنسجة السليمة والمصابة بنسب دقة قاربت 95%، مما يعد أداة مساعدة حيوية في الكشف المبكر عن الأورام [4].




الشكل (1-3): أمثلة لصور سرطان الخلايا الحرشفية الفموي (OSCC) والاضطرابات الفموية المحتمل تسربها (OPMDs) من مجموعة البيانات.

وفي مجال تقويم الأسنان، بحثت دراسة "تحديد المعالم السيفالومترية آلياً باستخدام الذكاء الاصطناعي" في أتمتة عملية تحليل الصور الشعاعية الجانبية للجمجمة، مستخدمة خوارزميات الكشف عن النقاط (Landmark Detection)، وأظهرت النتائج تقليصاً كبيراً في الزمن المستغرق للتحليل مع الحفاظ على دقة تضاهي الخبراء البشريين [5].

كما تناولت دراسة حديثة بعنوان "تجزئة الأسنان وتصنيفها في الصور المقطعية المحوسبة (CBCT) باستخدام الشبكات العميقة ثلاثية الأبعاد" مشكلة تداخل الأسنان وتشوهات الجذور، حيث استخدمت تقنيات (D U-Net3) لتحقيق فصل دقيق لكل سن على حدة، مما يسهل التخطيط للجراحات المعقدة وزراعة الأسنان [6].

ومن منظور شمولي، قدمت دراسة "نظام متعدد المهام لتشخيص أمراض الأسنان المتعددة في الصور البانورامية" نموذجاً قادراً على كشف التسوس، وفقدان العظم، وآفات الجذور، والتيجان المفقودة في آن واحد باستخدام بنية (Faster R-CNN)، وأكدت النتائج أن الأنظمة متعددة المهام توفر كفاءة سريرية أعلى من النماذج الفردية [7].



الشكل (4-1): أمثلة على كشف تسوس الأسنان في صور الاختبار.

ولمواجهة تحديات ندرة البيانات، ركزت دراسة "توليد صور الأسنان الشعاعية الاصطناعية لتدريب نماذج الذكاء الاصطناعي" على استخدام الشبكات التوليدية التنافسية (GANs) لزيادة حجم بيانات التدريب، مما أدى إلى تحسين أداء نماذج التشخيص بنسبة 15% عند اختبارها على بيانات حقيقية [8].

وفي عام 2024، برزت دراسة "الذكاء الاصطناعي القابل للتفسير (XAI) في تشخيص أمراض الفم" لتعالج مشكلة "الصندوق الأسود" في الخوارزميات، حيث طورت خرائط حرارية (Heatmaps) توضح المناطق التي اعتمد عليها النموذج في قراره، مما زاد من ثقة الأطباء في التقارير الصادرة عن النظام [9].


واستعرضت دراسة "تقييم أداء نماذج اللغة الكبيرة في تقديم الاستشارات السنية" إمكانية استخدام نماذج مثل (GPT-4) في التفاعل الأولي مع المرضى لتشخيص الأعراض، وخلصت إلى أن هذه النماذج تقدم توصيات دقيقة في الحالات الشائعة، مع ضرورة الإشراف البشري للحالات المعقدة [10].

وبالتوازي مع التطور في كشف التسوس، اتسع نطاق الذكاء الاصطناعي ليشمل الكشف عن الأمراض الجهازية التي تظهر علاماتها في الفكين، حيث استعرضت دراسة "الكشف الانتهازي عن هشاشة العظام باستخدام الصور البانورامية للأسنان" إمكانية استخدام خوارزميات التعلم العميق (Deep Learning) لتحليل كثافة العظم القشري في الفك السفلي كعلامة تنبؤية لهشاشة العظام، وأظهرت النتائج دقة تصنيف بلغت 98%، مما يحول صور الأسنان الروتينية إلى أداة فحص طبي عام [11].

وفي مجال جراحة الوجه والفكين، ركزت الأبحاث على التحدي المتمثل في التمييز بين الآفات المتشابهة بصرياً، إذ قدمت دراسة "التمييز الآلي بين الكيسات السنية والأورام الأرومية المينائية" نموذجاً قائماً على الشبكات العصبية (CNN) لتحليل الآفات الشفافة شعاعياً في

الفك، وحقق النموذج دقة تشخيصية وصلت إلى 92%، متفوقاً بذلك على دقة أطباء الأشعة ذوي الخبرة المتوسطة [12].

ولتحسين دقة التخطيط لزراعة الأسنان، تناولت دراسة "تصنيف أنظمة زرع الأسنان باستخدام التعلم العميق" مشكلة تحديد نوع الزرعة المجهولة في صور الأشعة، حيث طورت خوارزمية (VGG-16) قادرة على التعرف على 12 نوعاً مختلفاً من الزرعات بدقة 95%، مما يسهل عملية الصيانة المستقبلية للتركيبات [13].



الشكل (1-5): اقتصاص صور الزرع السني لعزل كل غرسة على حدة.

وفي سياق المعالجة اللبية (علاج الجذور)، استهدفت دراسة "الكشف عن الكسور الجذرية العمودية في صور الأشعة المقطعية" واحدة من أصعب المشكلات التشخيصية، مستخدمة شبكات (U-Net) ثلاثية الأبعاد لتحليل صور (CBCT)، وأثبتت الدراسة قدرة الذكاء الاصطناعي على كشف الكسور الدقيقة التي يصعب رؤيتها بالعين المجردة بدقة وحساسية عاليتين [14].

أما في مجال طب الأسنان الشرعي، فقد بحثت دراسة "تقدير العمر الزمني للبالغين باستخدام صور الأسنان البانورامية" في أتمتة عملية تحديد العمر بناءً على مراحل تآكل الأسنان وامتصاص العظم، وحقق النموذج المطور هامش خطأ ضئيلاً جداً (أقل من سنة واحدة)، مما يجعله أداة موثوقة في التحقيقات الجنائية والكوارث [15].

ولأتمتة عملية التوثيق الطبي، قدمت دراسة "الترقيم التلقائي للأسنان والكشف عن المفقود منها" نظاماً ذكياً يعتمد على خوارزميات (YOLOv4) للتعرف على كل سن وتحديد موقعه ورقمه في الصور البانورامية بدقة تجاوزت 96%، مما يختصر وقت إدخال البيانات في السجلات الإلكترونية [16].

ومع تزايد الاعتماد على الصور ثلاثية الأبعاد، ركزت دراسة "التشخيص الآلي لالتهاب الجيوب الأنفية الفكي المنشأ السني" على تحليل العلاقة بين جذور الأسنان العلوية والجيوب الأنفية في صور (CBCT)، حيث تمكن النموذج من تحديد حالات الالتهاب الناتجة عن عدوى سنية بدقة عالية، مما يساعد في توجيه خطة العلاج بشكل صحيح [17].

وفي مجال تقويم الأسنان الجراحي، تناولت دراسة "التنبؤ بضرورة خلع ضرس العقل الثالث" نموذجاً تنبؤياً يقيم زاوية البزوغ والمساحة المتاحة ليقرر ما إذا كان الضرس سيسبب مشاكل مستقبلية، وحقق النموذج تطابقاً مع قرارات الجراحين بنسبة 90% [18].

وكقفزة تقنية نحو الجيل الجديد من الخوارزميات، استعرضت دراسة "تجزئة الأسنان باستخدام محولات الرؤية (Vision Transformers)" استخدام تقنية المحولات (Swin-Unet)

بدلاً من الشبكات التقليدية، وأظهرت النتائج تفوقاً في تحديد حواف الأسنان بدقة متناهية، خاصة في مناطق التلامس الضيقة [19].

أخيراً، وفي سياق تجميل الأسنان، قدمت دراسة "تصميم الابتسامة التوليدي باستخدام الذكاء الاصطناعي" إطار عمل يستخدم الشبكات التوليدية (GANs) لاقتراح تعديلات تجميلية واقعية للأسنان بناءً على ملامح وجه المريض، مما يعزز التواصل بين الطبيب والمريض قبل بدء العلاج [20].

2-1 الفجوة البحثية

على الرغم من الإسهامات القيمة للدراسات السابقة في توظيف تقنيات الذكاء الاصطناعي في مجال تشخيص أمراض الفم والأسنان، إلا أنها ركزت غالباً على نماذج الكشف عن الأجسام التقليدية مثل YOLO و CNN، والتي تتطلب تدريباً مكثفاً على بيانات موسومة لأمراض محددة مسبقاً، مما يحد من مرونتها وقابليتها للتوسع لاستيعاب أمراض جديدة دون إعادة تدريب النموذج. كما اعتمدت معظم هذه الأنظمة بشكل أساسي على الصناديق الإحاطة (Bounding Boxes) التقريبية لتحديد مواقع الإصابات، وهي طريقة لا توفر دقة تشريحية كافية لتحديد حدود الآفة بدقة، خاصة في الحالات التي تتطلب تمييزاً دقيقاً بين الأنسجة السليمة والمريضة. إضافةً إلى ذلك، جاءت غالبية التطبيقات السابقة على هيئة برامج سطح مكتب (Desktop Applications) معزولة، تفتقر إلى التكامل مع قواعد البيانات الطبية، والتفاعل الديناميكي مع المستخدم عبر خرائط الأسنان، أو إمكانية تصدير التقارير التشخيصية الموحدة ومشاركتها. كما أنها اقتصرَت في تشخيصها على عدد محدود من الأمراض (كالنخر، وفقدان

العظم، والتهاب الآفة حول الذروية، والكسور السنّية) دون القدرة على التعامل مع طيف أوسع من الاعتلالات الفموية.

أما المشروع الحالي، فيسعى إلى سد هذه الفجوات من خلال قفزة نوعية في البنية المعمارية، حيث يعتمد على النماذج اللغوية الرؤيوية (Vision-Language Models - VLMs) مثل Gemini 3.1 Pro و Kimi k2.6، القادرة على فهم الصورة سياقياً وتوليد تقارير تشخيصية نصية باللغة العربية على هيئة JSON صارم، دون التقيد بأمراض محددة مسبقاً في التدريب، مما يمنح النظام مرونة عالية وقابلية للتوسع. كما يتجاوز النظام حدود الصناديق التقريبية بدمج نموذج التجزئة الدقيقة (Segment Anything Model) SAM من Meta، والذي يُنتج مضلعات (Polygons) دقيقة على مستوى البكسل تحدد المنطقة المصابة تشريحياً، مما يمنح الطبيب دقة جراحية في تحديد موقع المرض وحدوده. ويُقدّم المشروع نظاماً على هيئة منصة ويب (Web-based) متكاملة، بُنيت باستخدام React 19 و TypeScript في الواجهة الأمامية، و Flask مع Python في الخادم الخلفي، وتشمل خريطة أسنان تفاعلية تُظلل الأسنان المصابة تلقائياً، وموسوعة طبية تفاعلية تضم 8 أمراض سنّية، ومركز دعم يعتمد على المحادثة الآلية (Chatbot)، إلى جانب قاعدة بيانات SQLite لإدارة سجلات المرضى والفحوصات والتقييمات الطبية بشكل آمن ومنظم، ودعم تصدير التقارير التشخيصية بصيغة PDF لمشاركتها مع الأطباء والمرضى.

وبذلك، يتجاوز المشروع حدود النماذج البحثية السابقة نحو نظام تشخيصي ذكي شامل، يجمع بين قوة التحليل السياقي للنماذج اللغوية الرؤيوية ودقة التجزئة المكانية لنموذج SAM، مع تقديم تجربة مستخدم تفاعلية احترافية، مما يعزز دقة التشخيص وسرعته، ويسهم في

دعم القرار الطبي والوقاية المبكرة من أمراض الفم والأسنان، مع الاحتفاظ بالدور المحوري للطبيب في اتخاذ القرار العلاجي النهائي.

الفصل الثاني: المفاهيم


النظرية

1-2 مقدمة

في هذا الفصل، سنتناول الأساسيات النظرية التي يقوم عليها النظام الذكي المقترح، بدءاً من المبادئ الرياضية للشبكات العصبية الاصطناعية، مروراً بآليات التعلم العميق والشبكات الالتفافية، وصولاً إلى المفاهيم الحديثة للنماذج اللغوية الرؤية (Vision-Language Models) ونماذج التجزئة الدقيقة (Segmentation Models)، مع توضيح كيفية تطبيق هذه التقنيات في تحليل الصور الطبية وتوليد التقارير التشخيصية الآلية.

2-2 المبادئ الأساسية للشبكات العصبية الاصطناعية

1-2-2 العصبون الاصطناعي (Artificial Neuron)



الشكل (1-2): العصبون الصناعي.

تُعدّ الوحدة العصبية الاصطناعية (Artificial Neuron) اللبنة الأساسية للشبكات العصبية، وهي عبارة عن نموذج رياضي يستلهم آلية عمل الخلية العصبية البيولوجية. تتلقى هذه الوحدة مجموعة من المدخلات (Inputs) التي تُضرب كل منها في وزن (Weight) خاص يعبر عن

درجة أهميتها النسبية. تُجمع المدخلات الموزونة (Weighted Sum) ثم تُضاف إليها قيمة الانحياز (Bias) التي تلعب دوراً حاسماً في ضبط العتبة التفعيلية للعصبون وتحسين مرونته التقريبية [21].

يمكن تقسيم آلية عمل هذه الوحدة إلى مراحل متسلسلة ودقيقة كالتالي:

1. استقبال المدخلات (Input Layer)

- تمثل المدخلات $(x_1, x_2, \dots, x_n)$ البيانات الخام أو الميزات (Features) القادمة إلى العصبون.
- **في البيولوجيا:** تقابل الزوائد الشجرية (Dendrites) التي تتلقى الإشارات من الخلايا المجاورة.
- **في النموذج الاصطناعي:** يمكن أن تكون هذه المدخلات قيم بيكسل في صورة، كلمات في نص، أو مخرجات من عصبونات سابقة في الطبقات المخفية

2. الأوزان (Weights): ميزان الأهمية

- كل مدخل يقترن بقيمة رقمية تسمى "الوزن" $(w_1, w_2, \dots, w_n)$
- تعبر الأوزان عن قوة تأثير المدخل على النتيجة النهائية. إذا كان الوزن كبيراً، فإن أي تغيير بسيط في المدخل سيؤثر بشكل كبير على مخرجات العصبون.
 - عملية "تدريب" الشبكة العصبية هي في الحقيقة عملية تعديل مستمر لهذه الأوزان حتى تصل الشبكة إلى أدق النتائج.

3. الجمع الخطي (Weighted Sum)

يقوم العصبون بعملية حسابية أولية تتمثل في جمع حاصل ضرب كل مدخل في وزنه الخاص. رياضياً، يُعبر عنها بـ:

$$z = (x_1 \times w_1) + (x_2 \times w_2) + \dots + (x_n \times w_n) \quad (1-2)$$

هذه القيمة تمثل "النشاط الكلي" القادم للعصبون قبل أي معالجة إضافية.

• الانحياز (Bias): ضبط العتبة والمرونة

بعد حساب الجمع الموزون، تُضاف قيمة "الانحياز"، يشبه الانحياز الجزء المقطوع من المحور الصادي (في معادلة الخط المستقيم):

$$y = (m \cdot x) + c \quad (2-2)$$

بدونه، سيمر نموذج العصبون دائماً بنقطة الأصل (0,0)، مما يقيّد حركته.

وظيفته:

○ **الإزاحة (Shifting):** يسمح الانحياز بإزاحة دالة التنشيط يميناً أو يساراً. هذا يعني أنه

يمنح العصبون القدرة على التفعيل (Firing) حتى لو كانت جميع المدخلات صفراً.

○ **ضبط العتبة (Threshold Adjustment):** يتحكم الانحياز في "مدى سهولة" تفعيل

العصبون. قيمة انحياز عالية قد تجعل العصبون نشطاً بسهولة، بينما قيمة منخفضة

أو سالبة تجعله يتطلب مدخلات قوية جداً ليتفعل. باختصار، هو "مفتاح المرونة" الذي

يمنع النموذج من الجمود.

• دالة التنشيط (Activation Function):

هذه هي المرحلة النهائية التي تحول الجمع الخطي والانحياز إلى مخرجات (output).

○ **الهدف:** إدخال "اللاخطية" (Non-linearity) إلى النظام. العالم الحقيقي معقد وغير

خطي، وبدون هذه الدالة، ستعمل الشبكة العصبية مهما كبر حجمها كمجرد نموذج انحدار خطي بسيط.

○ **أمثلة:** دوال مثل (Sigmoid, ReLU, Tanh) تقرر ما إذا كان العصبون سيرسل إشارة للمرحلة التالية أم لا، وكم مقدار هذه الإشارة [21].

المعادلة النهائية للوحدة العصبية

$$output = f\left(\sum_{i=1}^n (x_i \times w_i) + b\right) \quad (3-2)$$

2-2-2 الشبكة العصبية (Neural Network)

تبنى الشبكة العصبية على بنية متعددة الطبقات (Multi-layer Architecture) من العصبونات الاصطناعية المترابطة. تتكون البنية القياسية من ثلاث مكونات أساسية: أولاً، طبقة الإدخال (Input Layer) التي تستقبل البيانات الأولية كصور الأشعة السينية على سبيل المثال، حيث يمثل كل بكسل مدخلاً مستقلاً. ثانياً، طبقة الإخراج (Output Layer) التي تُنتج النتيجة النهائية كتشخيص وجود تسوس أم لا. ثالثاً، الطبقات المخفية (Hidden Layers) التي تُجرى فيها غالبية العمليات المعالجة المعقدة واستخراج الميزات المتدرجة [22].

سنشرح المكونات الأساسية:

- البنية المعمارية متعددة الطبقات (Multi-layer Architecture)

لا تعمل العصبونات الاصطناعية بشكل منعزل، بل تتنظم في هيكل هرمي دقيق يُعرف بـ "الشبكة العصبية متعددة الطبقات" (Multi-Layer Perceptron - MLP). تتدفق البيانات في هذا الهيكل باتجاه واحد من المدخلات إلى المخرجات (Feedforward)، وتتوزع المهام على ثلاثة أنواع رئيسية من الطبقات، لكل منها دور وظيفي محدد [22]:

1. طبقة الإدخال (The Input Layer): بوابة البيانات: هذه الطبقة هي "شبكة العين"

لشبكة العصبية. هي نقطة الاتصال الأولى مع العالم الخارجي [22].

- **الوظيفة:** لا تقوم هذه الطبقة عادةً بأي عمليات حسابية معقدة؛ مهمتها الوحيدة هي استقبال البيانات الخام ونقلها إلى الطبقات التالية.

- **التمثيل الرقمي:** الشبكة لا "تري" الصورة كما نراها نحن، بل تراها كمصفوفة من الأرقام.
 - **في مثال الأشعة السينية:** إذا كانت صورة الأشعة بحجم (256×256) بكسل، فإن طبقة الإدخال ستحتوي على عدد من العصبونات يساوي عدد البكسلات (أي 65,536 عصبوناً). كل عصبون يحمل قيمة رقمية تمثل "شدة السطوع" (Grayscale Intensity) لذلك البيكسل، مما يسمح للشبكة بالتمييز بين المينا (Enamel) الصلب، والعاج (Dentin)، والتسوس الذي يظهر عادةً بلون أداكن.


2. الطبقات المخفية (Hidden Layers): العقل المدبر: تقع هذه الطبقات بين المدخلات

والمخرجات، وسميت بـ "المخفية" لأننا لا نرى مدخلاتها ومخرجاتها بشكل مباشر؛ فهي تعمل كـ "صندوق أسود" (Black Box) يعالج المعلومات داخلياً [22].

- **العمق (Depth):** وجود أكثر من طبقة مخفية هو ما يمنح الشبكة صفة "التعلم العميق" (Deep Learning).

- **استخراج الميزات الهرمي (Hierarchical Feature Extraction):** تعمل هذه الطبقات بتسلسل ذكي لفهم الصورة:
 - **الطبقات المخفية الأولى:** تكتشف أنماطاً بسيطة جداً، مثل الحواف، الخطوط العمودية والأفقية، ومناطق التباين في الصورة (مثلاً: الحدود الفاصلة بين السن واللثة).
 - **الطبقات المتوسطة:** تجمع تلك الخطوط لتشكيل أشكال أكثر تعقيداً، مثل انحناءات الجذور، أو شكل التاج، أو الفجوات.
 - **الطبقات العميقة:** تدمج الأشكال لتفهم المفهوم الكامل، مثل تمييز نمط التآكل الذي يشير إلى "تسوس" مقابل الظل الطبيعي للسن.
- **الأهمية:** في هذه الطبقات يتم تحويل البيانات الأولية (البكسلات) إلى "معرفة" ومفاهيم مجردة.
- 3. **طبقة الإخراج (The Output Layer):** اتخاذ القرار: هي الواجهة النهائية التي تقدم نتيجة المعالجة المعقدة التي تمت في الطبقات السابقة بصيغة مفهومة للمستخدم [22].
- **عدد العصبونات:** يعتمد عدد العصبونات هنا على طبيعة المشكلة التي نريد حلها.
 - **في مثال تشخيص التسوس (Binary Classification):** قد نحتاج لعصبون واحد فقط يعطي قيمة احتمال (بين 0 و1). إذا كانت القيمة قريبة من 1، يعني "يوجد تسوس"، وإذا كانت قريبة من 0، يعني "السن سليم".
 - **في التشخيص المتعدد:** إذا كانت الشبكة تحدد نوع المشكلة (تسوس، خراج، كسر)، ستحتوي الطبقة على 3 عصبونات، كل منها يعطي احتمالاً لواحدة من هذه الحالات.

- **التفسير:** تقوم هذه الطبقة بتجميع كل الميزات المستخرجة (وجود بقعة داكنة + انقطاع في سطح المينا) وتحويلها إلى قرار نهائي: "تشخيص إيجابي للتسوس بنسبة 98%".




الشكل (2-2): بنية الشبكة العصبية الاصطناعية.

3-2-2 دالة التنشيط (Activation Function)

بعد اكتمال عملية جمع المدخلات الموزونة، يُطبق على الناتج دالة التنشيط (Activation Function) لتحديد درجة تفعيل العصبون، مما يُدخل الخاصية اللاخطية (Non-linearity) إلى النظام. هذه الخاصية تمكن الشبكة من تعلم وتصور العلاقات المعقدة وغير الخطية في البيانات. من أبرز دوال التنشيط المستخدمة دالة الوحدة الخطية المعدلة (Rectified Linear Unit - ReLU) ودالة السيجمويد (Sigmoid Function) [23].

بعد أن يقوم العصبون بجمع المعلومات وضربها في الأوزان، تأتي مرحلة الحسم. دالة التنشيط هي المكون الرياضي الذي يقرر "هل هذا العصبون مهم؟ وهل يجب أن نمرر المعلومة للعصبونات التالية؟". يمكن تشبيهها بإشارات المرور التي تنظم تدفق البيانات داخل الشبكة.



الشكل (2-3): دوال التنشيط.

1-3-2-2 اللاخطية (Non-linearity)

لعل أهم وظيفة لدالة التنشيط هي إدخال خاصية "اللاخطية". لتبسيط هذا المفهوم المعقد:

- **مشكلة الخطية:** بدون دالة تنشيط (أو باستخدام دالة خطية فقط)، ستتصرف الشبكة العصبية مهما كان عمقها أو عدد طبقاتها مثل نموذج انحدار خطي بسيط (Linear Regression). أي أن جمع طبقات خطية فوق بعضها ينتج عنه في النهاية دالة خطية واحدة. هذا يعني أن الشبكة لن تكون قادرة إلا على فهم العلاقات المباشرة والبسيطة (مثل العلاقة بين مساحة البيت وسعره) [23].

- **حل اللاحطية:** بيانات العالم الحقيقي (مثل الصور، الأصوات، واللغات) معقدة للغاية، مليئة بالمنحنيات والأنماط المتداخلة التي لا يمكن فصلها بخط مستقيم. دوال التنشيط "تحنى" و"تشوه" الفضاء الخطي، مما يسمح للشبكة برسم حدود فصل معقدة (Curves) وتشكيل فهم عميق للبيانات [23].

2-3-2-2 أبرز دوال التنشيط المستخدمة

- **دالة السيجمويد (Sigmoid Function):** المنحنى السيني تُعد من أقدم دوال التنشيط وتأخذ شكل حرف "S".
 - **الآلية الرياضية:** تقوم بضغط أي قيمة مدخلة (مهما كانت كبيرة أو صغيرة) وحصرها في نطاق ضيق جداً بين (0 و1).
 - **الاستخدام الأمثل:** تستخدم بكثرة في طبقة الإخراج (Output Layer) خاصة في مشاكل التصنيف الثنائي (مثل: مصاب/غير مصاب)، لأن نتيجتها يمكن تفسيرها مباشرة كـ "احتمالية" (Probability). (مثلاً: 0.9 تعني احتمال 90%).
 - **العيوب:** لم تعد تُستخدم كثيراً في الطبقات المخفية (Hidden Layers) في الشبكات العميقة، لأنها تسبب مشكلة تقنية تُعرف بـ "تلاشي التدرج" (Vanishing Gradient)، مما يجعل عملية تعلم الشبكة بطيئة جداً أو متوقف [23].
- **دالة الوحدة الخطية المعدلة (ReLU - Rectified Linear Unit):** هي الدالة الأكثر شهرة واستخداماً في الشبكات العصبية الحديثة (التعلم العميق).

- **الآلية الرياضية:** مبدأها بسيط جداً ومخادع في بساطته: إذا كانت القيمة المدخلة سالبة ($x < 0$): تكون النتيجة صفر أي إطفاء العصبون. أما إذا كانت القيمة المدخلة موجبة ($x > 0$): تمرر القيمة كما هي دون تغيير.

○ المميزات:

- **الكفاءة الحسابية:** نظراً لبساطتها (لا تتطلب عمليات أسية معقدة مثل السيجمويد)، فهي سريعة جداً في الحساب.
- **حل مشاكل التعلم:** تساعد الشبكة على التعلم بشكل أسرع وتتجاوز مشكلة "تلاشي التدرج".
- **التمثيل المتناثر (Sparsity):** بما أنها تحول القيم السالبة لصفر، فإنها تجعل بعض العصبونات "خاملة"، مما يعني أن الشبكة تركز فقط على الميزات المهمة وتتجاهل الضجيج، وهذا يحاكي كفاءة الدماغ البيولوجي.
- إذا كنا نريد احتمالية في النهاية (مثل تشخيص طبي نعم/لا) -> نستخدم Sigmoid في الطبقة الأخيرة. أما إذا كنا نريد سرعة وكفاءة في المعالجة الداخلية -> نستخدم ReLU في جميع الطبقات المخفية [23].

3-2 التعلم العميق وشبكات الالتفاف العصبية

1-3-2 مفهوم التعلم العميق (Deep Learning)

يُمثل التعلم العميق قفزة نوعية في مجال الذكاء الاصطناعي، حيث ينتقل التركيز من مجرد زيادة عدد العصبونات إلى زيادة "عمق" الشبكة (عدد الطبقات). هذا العمق ليس مجرد تكرار،

بل هو هيكل وظيفي يسمح بالتعلم التمثيلي الهرمي (Hierarchical Representation Learning) [24].

2-1-3-2 هرمية المعرفة (Hierarchical Learning)


في الشبكات العميقة، لا تتعلم كل الطبقات نفس الشيء، بل تخصص بناءً على موقعها في التسلسل [24]:

- **المستويات الدنيا (Low-level):** تتعلم الطبقات الأولى استخراج ميزات بدائية وبسيطة جداً مباشرة من بكسلات الصورة، مثل الحواف، الزوايا، وتغيرات الألوان.
- **المستويات المتوسطة (Mid-level):** تقوم الطبقات التالية بدمج تلك الميزات لتكوين أشكال هندسية، أنسجة (Textures)، وأجزاء من الأجسام.
- **المستويات العليا (High-level):** في أعماق الشبكة، يتم تجميع هذه الأشكال لتكوين مفاهيم معقدة وكاملة، مثل "ورم خبيث ذو حواف غير منتظمة" أو "كسر في عظم". هذا التدرج يحاكي طريقة عمل القشرة البصرية في الدماغ البشري [24].

2-1-3-2 الشبكات العصبية الالتفافية (CNNs)

عند التعامل مع الصور الطبية (أشعة سينية، رنين مغناطيسي، مقطعية)، تبرز الشبكات العصبية الالتفافية (CNNs) كأداة الأكثر كفاءة، ويكمن نجاحها في تصميمها الذي يحافظ على البنية المكانية للصورة [25].

- **الحفاظ على البنية المكانية (Spatial Features):** الشبكات العصبية التقليدية تقوم بتسطيح الصورة، مما يؤدي إلى فقدان العلاقات بين البكسلات. أما CNN فتتعامل مع الصورة بأبعادها الأصلية، حيث تدرك أن البكسلات المتجاورة تحمل معلومات مترابطة.
- **آلية العمل:** تعتمد على فلاتر (Filters / Kernels) تنزلق فوق الصورة (Convolution) لاستخلاص الأنماط المحلية، وكأنها تقوم بمسح تدريجي للصورة [25].
- **استخراج الخصائص الطبوغرافية (Topographical Features):** تمكن هذه الشبكات من تحليل الملمس والبنية، وليس فقط اللون، مما يساعد في التمييز بين الأنسجة المختلفة.
- **الصمود أمام التغيرات (Invariance):** تستطيع التعرف على الأنماط بغض النظر عن موقعها أو ميلها داخل الصورة.
- **الخلاصة:** بينما تنظر الشبكات التقليدية إلى الصورة كقيم منفصلة، تتعامل CNN مع الصورة كخريطة مترابطة، مما يمكنها من استخراج تفاصيل دقيقة وتحويلها إلى تمثيلات عميقة تدعم التشخيص [25].



الشكل (4-2): الشبكة العصبية العميقة.

2-3-2 عملية التعلم الآلي والتدريب (Machine Learning & Training)

التعلم الآلي هو المنهجية التي تُعلّم الشبكة العصبية أداء مهام محددة من خلال عملية التدريب (Training). تتضمن عملية التدريب عرض مجموعة ضخمة من البيانات المُصنّفة مسبقاً على الشبكة، كاستخدام آلاف الصور الشعاعية مع بياناتها التشخيصية للتسوس. تبدأ الأوزان (Weights) بقيم عشوائية في مرحلة التهيئة الأولية، ومع كل مثال تدريبي تقوم الشبكة بإجراء تنبؤ ومقارنته بالإجابة الصحيحة، ثم تُعدّل الأوزان تلقائياً بشكل تدريجي لتقليل دالة الخطأ (Loss Function). تُعرف الحقبة (Epoch) بأنها مرور كامل لكامل مجموعة البيانات التدريبية عبر الشبكة، ويتطلب تدريب النماذج الفعالة عدة مئات أو آلاف من الحقب لتثبيت الأوزان عند القيم المثلى [26].

1-2-3-2 ديناميكية التعلم الآلي (Training Dynamics)

التعلم في الشبكات العصبية هو عملية تحسين رياضي مستمر تهدف إلى تقليل الخطأ، ويتم ذلك عبر الخطوات التالية [26]:

1. **التهيئة الأولية (Initialization):** يتم تعيين أوزان عشوائية صغيرة لكسر التناظر بين العصبونات، حيث تبدأ الشبكة دون معرفة مسبقة.
2. **الانتشار الأمامي (Forward Propagation):** تمر البيانات عبر الشبكة لإنتاج تنبؤ أولي اعتماداً على الأوزان الحالية.
3. **حساب دالة الخطأ (Loss Function):** يتم حساب الفرق بين التنبؤ والقيمة الحقيقية، وهو مقياس جودة الأداء.

4. الانتشار العكسي (Backpropagation): يتم تحديد مساهمة كل وزن في الخطأ


باستخدام الاشتقاق، عبر الرجوع من المخرجات إلى المدخلات.

5. تحديث الأوزان (Optimization): يتم تعديل الأوزان باستخدام خوارزميات مثل

Gradient Descent لتقليل الخطأ تدريجياً.

6. الحقبة (Epoch): تمثل مرور كامل البيانات عبر الشبكة، وتكرر العملية لعدة حقبة حتى

تصل الشبكة إلى مرحلة الاستقرار (Convergence).



الشكل (2-5): التعلم الآلي.

4-2 البنية المعمارية لشبكات الالتفاف العصبية

1-4-2 أهمية شبكات الالتفاف العصبية

تكمن أهمية شبكات الالتفاف العصبية في قدرتها على استخراج الميزات من البيانات ذات

البنية الشبكية بشكل تلقائي وعلى نطاق واسع، مما يمنحها أفضلية على الخوارزميات التقليدية

مثل آلات المتجهات الداعمة (SVM) والأشجار القرارية التي تعتمد على استخراج يدوي للميزات [27].

• الانتقال من "هندسة الميزات" اليدوية إلى التعلم التلقائي:

في النماذج التقليدية، يعتمد الأداء على تصميم ميزات يدوية، وهي عملية معقدة وتعتمد على الخبرة البشرية. أما الشبكات الالتفافية فتعمل بأسلوب "التعلم من البداية إلى النهاية" (End-to-End Learning)، حيث تتعلم الفلاتر المناسبة تلقائياً من البيانات الخام دون تدخل بشري.

• الثبات المكاني (Translation Invariance) ومشاركة الأوزان:

تتميز طبقات الالتفاف بخاصية الثبات تجاه التحويلات المكانية، حيث يتم استخدام نفس الفلتر على كامل الصورة (Weight Sharing)، مما يسمح للشبكة باكتشاف الأنماط مهما تغير موضعها أو اتجاهها [27].


• استراتيجية نقل التعلم (Transfer Learning):

توفر الشبكات الجاهزة ذات الأداء القوي (VGG-16, ResNet50, Inceptionv3, EfficientNet) إمكانية التكيف عبر تقنية الضبط الدقيق (Fine-tuning)، مما يسمح باستخدام نماذج مدربة مسبقاً حتى في حالة توفر بيانات محدودة [27].

• شمولية التطبيق:

لا تقتصر تطبيقات CNN على تصنيف الصور، بل تمتد إلى معالجة اللغة الطبيعية، تحليل السلاسل الزمنية، والتعرف على الكلام، نظراً لقدرتها على استخراج الأنماط المحلية [27].

2-4-2 خطوات عمل شبكة الالتفاف العصبية




الشكل (2-6): آلية عمل شبكة الالتفاف.

يتبع عمل شبكة الالتفاف العصبية تسلسلاً هرمياً كما هو موضح في الشكل (2-6)، يبدأ بصورة رقمية صغيرة (ك 28×28 بكسل). في الطبقة الالتفافية الأولى، يتم تطبيق مرشحات (Filters) صغيرة (ك 5×5) لاكتشاف الأشكال البسيطة كالحواف والخطوط. تتلاه طبقة التجميع (Pooling) التي تختزل أبعاد البيانات مع المحافظة على القيم المهمة، وتقلل من الحساسية المكانية. في الطبقة الالتفافية الثانية، تُستخرج أنماط معقدة كأجزاء الأرقام أو الهياكل التشرحية. تُعقبها طبقة تجميع ثانية لمزيد من الاختزال. تُحوّل الميزات الناتجة بعد ذلك إلى متجه أحادي البعد (Flattening) لإدخالها إلى طبقات عصبية كاملة الاتصال (Fully Connected Layers) التي تجمع الميزات لاتخاذ القرار التصنيفي. تُنتج الطبقة الأخيرة احتمالات متعددة (مثلاً 10 احتمالات للأرقام 0-9)، حيث يُختار الصنف ذو الاحتمال الأعلى. تتعلم الشبكة باستمرار عبر مقارنة توقعاتها بالحقائق الأرضية وتعديل أوزانها تلقائياً [28].

2-4-2 طبقة الالتفاف (Convolution Layer)

تُشكل طبقة الالتفاف جوهر عملية استخراج الميزات، حيث يعمل الفلتر (Filter) كنافذة زلالية صغيرة تتحرك بخطوات محددة (Stride) فوق الصورة. يحتوي كل فلتر على مصفوفة أوزان يتم تعلمها أثناء التدريب، وعندما يقع على بقعة معينة، يُجرى عملية الالتفاف (Convolution Operation) بضرب قيم البكسلات المغطاة في الأوزان وجمع الناتج لإنتاج قيمة مفردة في خريطة الميزات (Feature Map). يتخصص كل فلتر بعد التدريب في اكتشاف نمط محدد: فمرشح قد يكتشف الحواف، وآخر المنحنيات، وثالث الزوايا، مبنياً بذلك فهماً بصرياً متدرجاً من البسيط إلى المعقد [28].




الشكل (2-7): الفلتر (Filter).

2-4-2 طبقة التجميع (Pooling Layer)

تُستخدم طبقات التجميع لتقليل الأبعاد المكانية للبيانات (Dimensionality Reduction)، حيث تُبسّط المعلومات مع المحافظة على الميزات الأكثر تميزاً [29].

تلعب هذه الطبقات دوراً إضافياً في تقليل العبء الحسابي واستهلاك الذاكرة، كما تُساهم في تقليل الإفراط في التخصيص (Overfitting)، وتمنح الشبكة خاصية الثبات المكاني (Translation Invariance)، مما يمكنها من التعرف على الميزات بغض النظر عن تغير موقعها داخل الصورة [29].



الشكل (2-8): عملية التجميع.

3-2-4-2 طبقة الحشو (Padding Layer)

تُضاف طبقة الحشو (Padding) صفوفًا وأعمدة من البكسلات حول حدود الصورة كإطار حماية، لتمكين الفلتر من العمل على الحواف بكفاءة مشابهة للمناطق الداخلية. بدون حشو، تتقلص أبعاد الصورة تدريجياً وتُفقد المعلومات الطرفية. يضمن الحشو المحافظة على الأبعاد الأصلية وعدم إغفال أي تفاصيل تشخيصية مهمة موجودة على الحواف [29].

Without Padding

	A	B	C	
	C	D		

3x3

With Padding

	A	B	C	
	C	D		

5x5

الشكل (9-2): عملية الحشو.

5-2 التطبيقات العملية في طب الفم والأسنان

1-5-2 التطبيقات التشخيصية

ومع ذلك، شهدت السنوات الأخيرة تحولاً جوهرياً من مجرد أنظمة الكشف التقليدية (كـ YOLO و CNN) إلى المنصات التشخيصية التفاعلية التي تعتمد على النماذج اللغوية الرؤية (VLMs) ونماذج التجزئة الدقيقة (كـ SAM)، حيث لم تعد هذه الأنظمة تقتصر على تحديد وجود المرض، بل أصبحت قادرة على:

- فهم السياق السريري: من خلال توليد تقارير تشخيصية نصية باللغة العربية تتضمن وصفاً دقيقاً للحالة وتوصيات علاجية [41].


- **التحديد المكاني الدقيق:** باستخدام تقنيات التجزئة على مستوى البكسل لتحديد حدود الإصابة تشريحياً بدلاً من الصناديق التقريبية [42].

- **التفاعل مع المستخدم:** عبر واجهات ويب متطورة تشمل خرائط أسنان تفاعلية، وقواعد بيانات طبية، وموسوعات مرضية [43].

يمثل هذا التكامل بين التقنيات السحابية (VLMs) والمحلية (SAM) نقلة نوعية في دقة التشخيص وسهولة الاستخدام، مما يجعل الأنظمة الذكية أكثر قرباً من الممارسة السريرية اليومية.



الشكل (10-2): الأشعة البانورامية للأسنان.



الشكل (11-2): صورة CBCT.

2-5-2 ضغط الصور الطبية

يلعب ضغط الصور (Image Compression) دوراً محورياً في إدارة الكميات الهائلة من البيانات الطبية، حيث يُقلل من متطلبات التخزين ونقل البيانات دون التأثير على المعلومات التشخيصية الحاسمة. تساهم خوارزميات الذكاء الاصطناعي المتقدمة في تطوير تقنيات ضغط ذكية تحافظ على التفاصيل الدقيقة الضرورية للتشخيص الدقيق [30].




FIGURE 27-9
JPEG image division. JPEG transform compression starts by breaking the image into 8×8 groups, each containing 64 pixels. Three of these 8×8 groups are enlarged in this figure, showing the values of the individual pixels, a single byte value between 0 and 255.

الشكل (2-12): ضغط الصور.

6-2 نماذج اللغة الكبيرة (Large Language Models – LLMs)

شهدت السنوات الأخيرة تطوراً متسارعاً في مجال الذكاء الاصطناعي التوليدي متعدد الوسائط، وكان من أبرز نتائجه ظهور النماذج اللغوية الرؤيةية (Vision-Language Models - VLMs)، والتي تمثل الجيل الجديد من الأنظمة القادرة على فهم الصور والنصوص معاً. تختلف هذه النماذج عن نماذج اللغة الكبيرة التقليدية (LLMs) بقدرتها على معالجة المدخلات البصرية

(الصور) إلى جانب النصوص، مما يجعلها مثالية لتطبيقات التشخيص الطبي التي تتطلب تحليل الصور الشعاعية أو السريرية وتوليد تقارير نصية في آن واحد [34].

تعتمد VLMs على شبكات عصبية عميقة ذات عدد هائل من المعاملات (Parameters)، وتُدرَّب على كميات ضخمة من البيانات النصية والمرئية المقترنة بهدف تعلم العلاقات الدلالية بين العناصر البصرية والأوصاف اللغوية. وهذا يمكنها من فهم الصورة سياقياً وتوليد أوصاف دقيقة، والإجابة عن الأسئلة المتعلقة بالصورة، واكتشاف الحالات المرضية وتفسيرها [35]. وتتميز النماذج اللغوية الرؤيوية بقدرتها على التعامل مع مهام معقدة تتطلب فهماً مشتركاً للرؤية واللغة، مثل تحليل الأشعة السنية وتوليد تقارير تشخيصية منظمة (على هيئة JSON)، مما يجعلها مناسبة تماماً للأنظمة الطبية التفاعلية [36].

وفي هذا المشروع، يُستخدم نموذج Gemini 3.1 Pro كأحد أبرز النماذج اللغوية الرؤيوية للكشف المباشر عن أمراض الأسنان وتحليل الصورة سياقياً، حيث يتولى توليد تقرير تشخيصي أولي باللغة العربية على هيئة JSON صارم، يتضمن وصف الأمراض المكتشفة، وتحديد مواقعها باستخدام نظام الترقيم العالمي (FDI)، وتقديم توصيات علاجية مناسبة، مما يجعل النظام أكثر تفاعلاً وسهولة في الاستخدام من قبل الأطباء والمرضى على حد سواء [36]. كما يتم دمج نموذج التجزئة الدقيقة (Segment Anything Model) من Meta، والذي يعمل على تحويل الصناديق التقريبية التي يولدها النموذج اللغوي إلى مضلعات (Polygons) دقيقة على مستوى البكسل، مما يمنح الطبيب دقة جراحية في تحديد حدود المنطقة المصابة [41]، [42].

2-6-1 مفهوم النماذج اللغوية الرؤيةية (Concept of Vision-Language Models)

يمكن تعريف النموذج اللغوي الرؤيةي (VLM) بأنه نموذج ذكاء اصطناعي متعدد الوسائط يجمع بين تقنيات الرؤية الحاسوبية ومعالجة اللغة الطبيعية في إطار موحد، ويُدرَّب باستخدام مليارات الأمثلة من الصور والنصوص المقترنة المستخرجة من الإنترنت والكتب الطبية والمقالات العلمية، بهدف تعلم التطابق بين المحتوى البصري والأوصاف اللغوية [34].

وعلى خلاف نماذج الرؤية التقليدية التي تقتصر على التصنيف أو الكشف، تستطيع النماذج اللغوية الرؤيةية تنفيذ عدد كبير من المهام المتعلقة بالصور دون الحاجة إلى تدريب خاص لكل مهمة، إذ يمكن للنموذج نفسه إجراء وصف الصور، والإجابة عن الأسئلة البصرية، واكتشاف الحالات المرضية، وتوليد التقارير الطبية، اعتماداً على صياغة التعليمات (Prompts) التي يقدمها المستخدم [35].

وتتضمن هذه الفئة عدداً من النماذج الشهيرة مثل Gemini من Google، وGPT-4 with Vision، من OpenAI، وClaude من Anthropic، وKimi من Moonshot AI، والتي تعتمد جميعها على بنية المحولات (Transformer Architecture) المطوّرة لاستيعاب المدخلات البصرية، مع اختلاف في عدد المعاملات، وآلية التدريب، وحجم البيانات المستخدمة [36].

2-6-2 آلية عمل النماذج اللغوية الرؤيةية (Working Mechanism of VLMs)

تعتمد النماذج اللغوية الرؤيةية على مبدأ تحويل الصورة إلى تمثيل عددي (Visual Embedding) باستخدام مشفر بصري (Vision Encoder)، ثم دمج هذا التمثيل مع التمثيل النصي للمدخلات عبر طبقات المحولات، لتوليد استجابة نصية مناسبة [35].

وتتم عملية التحليل على مراحل متتابة؛ إذ يبدأ النموذج بتحويل الصورة المدخلة إلى سلسلة من المتجهات البصرية باستخدام مشفر معتمد على الشبكات الالتفافية أو المحولات. ثم يتم دمج هذه المتجهات مع التمثيل النصي للمدخلات (كالتعليمات الطبية أو وصف الحالة) عبر طبقات المحولات التي تحلل العلاقات البصرية-اللغوية باستخدام آلية الانتباه متعدد الرؤوس (Multi-Head Attention). وبعد ذلك، يقوم النموذج بتوليد النص المناسب كتقرير تشخيصي أو وصف للحالة [36].

وفي النظام المقترح في هذا المشروع، يستقبل نموذج Gemini 3.1 Pro الصورة محولة إلى Base64 مع تعليمات نظام (System Prompt) تحدد بنية التقرير المطلوب (JSON)، ثم يقوم بتوليد التقرير الذي يحتوي على الأمراض المكتشفة، ومواقعها، ونسب الثقة، والتوصيات العلاجية [36].

2-6-3 نموذج التجزئة الدقيقة (SAM (Segment Anything Model

إلى جانب النماذج اللغوية الرؤية، يعتمد النظام على نموذج SAM (Segment Anything Model) الذي طورته Meta AI Research، وهو نموذج تجزئة (Segmentation) متقدم يعمل في وضعية "Zero-Shot"، أي أنه قادر على تجزئة أي كائن في أي صورة دون الحاجة إلى تدريب مسبق على بيانات محددة [41].

يتكون SAM من ثلاث مكونات رئيسية [41]:

1. مشفر الصورة (Image Encoder): يعتمد على بنية Vision Transformer (ViT) لتحويل الصورة إلى تمثيل بصري عالي الأبعاد.
 2. مشفر الموجه (Prompt Encoder): يستقبل الموجهات المختلفة مثل النقاط، الصناديق، أو النصوص ويحولها إلى تمثيلات رقمية.
 3. مفكك القناع الخفيف (Lightweight Mask Decoder): يدمج التمثيل البصري مع التمثيل الرقمي للموجه لتوليد قناع التجزئة النهائي (Mask) مع درجة الثقة.
- في هذا المشروع، يُستخدم SAM لتحويل صناديق الإحاطة (Bounding Boxes) التقريبية التي يولدها النموذج اللغوي الرؤيوي إلى مضلعات (Polygons) دقيقة تحدد المنطقة المصابة على مستوى البكسل. يتم ذلك عبر الخطوات التالية [42]:
1. استلام إحداثيات الصندوق التقريبي من Gemini.
 2. تمرير الصندوق كموجه إلى SAM.
 3. يقوم SAM بتوليد قناع (Mask) يحدد المنطقة المصابة بدقة عالية.
 4. يُحوّل القناع إلى نقاط مضلع (Polygon Points) تُستخدم للرسم على الواجهة الأمامية.
- يستخدم المشروع نسخة SAM ViT-B (Base) والتي تحتوي على 93.74 مليون معامل وحجم 358 ميغابايت، وهي توازن بين الدقة والسرعة، مما يجعلها مناسبة للتشغيل على الأجهزة المتوسطة [41].

2-6-4 التحديات والقيود في النماذج اللغوية الرؤيوية ونماذج التجزئة

على الرغم من الأداء المتقدم الذي حققته النماذج اللغوية الرؤيوية ونماذج التجزئة، فإنها لا تزال تواجه عدداً من التحديات التي قد تؤثر في دقة وموثوقية مخرجاتها [37]. ومن أبرز هذه التحديات:

- ظاهرة الهلوسة (Hallucination): قد ينتج النموذج اللغوي الرؤيوي معلومات تبدو صحيحة لغوياً لكنها غير دقيقة أو غير موجودة في الصورة.
- الحساسية لصياغة التعليمات (Prompt Sensitivity): جودة المخرجات تعتمد بشكل كبير على دقة وصياغة التعليمات الموجهة للنموذج.
- التكلفة الحسابية: نماذج التجزئة مثل SAM تتطلب موارد حسابية كبيرة خاصة في مرحلة تشفير الصورة (Image Encoding).
- خصوصية البيانات: إرسال الصور الطبية إلى خوادم سحابية قد يثير مخاوف تتعلق بخصوصية المرضى [38].

2-6-5 تقنيات تحسين موثوقية النماذج

طُورت خلال السنوات الأخيرة مجموعة من التقنيات التي تهدف إلى تحسين موثوقية النماذج اللغوية الرؤيوية ونماذج التجزئة [39]، ومن أهمها:

- هندسة الأوامر (Prompt Engineering): صياغة تعليمات واضحة ودقيقة توجه النموذج نحو إنتاج مخرجات أكثر دقة وملاءمة للمهمة المطلوبة.

- الاسترجاع المعزز بالتوليد (Retrieval-Augmented Generation - RAG): ربط النموذج بقواعد بيانات خارجية لاسترجاع المعلومات الموثوقة قبل توليد الإجابة.
- التحكم بمعامل درجة الحرارة (Temperature): القيم المنخفضة تؤدي إلى إنتاج إجابات أكثر دقة واستقراراً، بينما القيم المرتفعة تزيد من مستوى الإبداع والتنوع.
- التشغيل المحلي للنماذج: لتجنب مخاوف الخصوصية وتقليل الاعتماد على الاتصال بالإنترنت، كما في حالة تشغيل SAM محلياً في هذا المشروع [40].

3 الفصل الثالث: النماذج

اللغوية الرؤيوية ونماذج

التجزئة الدقيقة

3-1 مقدمة

في مجال التشخيص الشعاعي لطب الأسنان، يواجه الأطباء تحدياً مزدوجاً يتمثل في دقة التشخيص وسرعة الأداء. الطرق التقليدية في الرؤية الحاسوبية كانت تعتمد على خوارزميات الكشف عن الأجسام (Object Detection) مثل YOLO و Faster R-CNN، والتي تتطلب تدريباً مكثفاً على بيانات موسومة لأمراض محددة مسبقاً، كما أنها تقتصر على إنتاج صناديق إحاطة (Bounding Boxes) تقريبية لا تحدد حدود الإصابة بدقة تشريحية كافية [31].

هنا تكمن الأهمية الثورية للنماذج اللغوية الرؤية (Vision-Language Models - VLMs) ونماذج التجزئة الدقيقة (Segmentation Models). فعلى عكس خوارزميات الكشف التقليدية، تعيد النماذج اللغوية الرؤية صياغة مشكلة التشخيص الطبي كمسألة فهم سياقي شامل للصورة، حيث لا تكتفي بتحديد وجود المرض فحسب، بل تفهم الصورة ككل وتولّد تقريراً تشخيصياً نصياً باللغة العربية يتضمن وصفاً دقيقاً للحالة وتوصيات علاجية. وهذا النهج "اللغوي-البصري" المتكامل يتيح معالجة الصور البانورامية عالية الدقة مع فهم دقيق للسياق السريري، مما يجعله الأداة المثلى للمساعدة في اتخاذ القرار السريري الفوري [31]، [34].

إضافةً إلى ذلك، يتم دمج نموذج التجزئة الدقيقة SAM (Segment Anything Model) لتحويل الصناديق التقريبية إلى مضلعات (Polygons) دقيقة على مستوى البكسل، مما يمنح الطبيب دقة جراحية في تحديد المنطقة المصابة، ويتجاوز بكثير دقة الصناديق التقريبية التي تقدمها خوارزميات الكشف التقليدية [41].

2-3 المفاهيم الجوهرية في الرؤية الحاسوبية الطبية الحديثة


لفهم عمق النماذج اللغوية الرؤيوية ونماذج التجزئة، يجب تشريح المفاهيم الهرمية للرؤية الحاسوبية وكيفية تطورها لتطبيقات الطب.

1-2-3 التصنيف (Classification) وتحدياته

التصنيف هو أبسط أشكال الرؤية الحاسوبية، حيث يتم إسناد فئة واحدة للصورة (مثلاً: "صورة مريض" أو "صورة سليمة"). في سياقنا، التصنيف وحده قاصر؛ لأن الصورة البانورامية قد تحتوي على أسنان سليمة وأخرى مصابة في آن واحد. الخوارزمية هنا تتعلم الميزات العامة (Global Features) ولكنها تفقد المعلومات المكانية (Spatial Information) الضرورية لتحديد أي سن هو المصاب [32].


2-2-3 التصنيف مع تحديد الموقع (Classification + Localization)

هنا ننتقل خطوة للأمام؛ فبالإضافة إلى تصنيف الكائن، يجب على النموذج التنبؤ بـ "صندوق إحاطة" (Bounding Box) يحدد مكان الكائن. رياضياً، يعني هذا أن الشبكة العصبية لا تخرج فقط احتمالية الفئة (P_c)، بل تخرج أيضاً أربع قيم إحداثية (x, y, w, h) تمثل مركز الصندوق وعرضه وارتفاعه. هذا التوطين ضروري جداً في طب الأسنان لتوجيه انتباه الطبيب إلى المنطقة المشبوهة بدقة مليمترية [33]. ومع ذلك، تظل هذه الصناديق تقريبية ولا تحدد حدود الإصابة بدقة تشريحية، وهو ما تعالجه تقنيات التجزئة الحديثة.



الشكل (3-1): توضيح لمفهوم التصنيف مع تحديد الموقع باستخدام صندوق إحاطة

3-2-3 الكشف عن الكائنات (Object Detection)



الشكل (3-2): تمييز وفصل كائنات متعددة ومختلفة الأحجام في صورة واحدة.


هو التحدي الحقيقي في صور الأسنان. الصورة البانورامية تحتوي على كائنات متعددة (32 سنًا، عظم الفك، الجيوب الأنفية). خوارزمية الكشف عن الكائنات يجب أن تكون قادرة على:

- التعرف على فئات مختلفة في نفس الصورة (Multi-Class).
- فصل الكائنات المتداخلة أو المتقاربة (مثل تلاصق الأسنان).
- التعامل مع اختلاف الأحجام (Scale Variation)؛ حيث يجب اكتشاف تسوس صغير جداً بنفس كفاءة اكتشاف حشوة كبيرة [33].

وهنا تبرز ميزة النماذج اللغوية الرؤية، حيث أنها لا تحتاج إلى تدريب مسبق على كل هذه الحالات، بل تفهم الصورة سياقياً وتستطيع التعرف على أنماط مرضية متعددة دون التقيد بقائمة محددة من الأمراض [34]، [35].

4-2-3 التجزئة المثلثية (Instance Segmentation)

بينما يضع "الكشف" صندوقاً مربعاً حول السن، تقوم "التجزئة" بتحديد شكل السن بدقة بكسل تلو الآخر (Pixel-wise mask). في حين أن هذا يوفر معلومات دقيقة حول شكل الجذر أو حجم النخر بدقة متناهية، إلا أن تكلفته الحسابية عالية جداً في النماذج التقليدية [33]. أما في النظام الحالي، فيتم استخدام نموذج SAM (Segment Anything Model) الذي يوفر تجزئة دقيقة بتكلفة حسابية مقبولة، خاصة مع نسخة ViT-B المستخدمة في هذا المشروع، والتي تحقق توازناً مثالياً بين الدقة والسرعة [41]، [42].



الشكل (3-3): تحديد حدود السن بدقة البكسل لتمثيل الشكل التشريحي بدقة متناهية.

3-3 النماذج اللغوية الرؤية (Vision-Language Models - VLMs)

1-3-3 المكونات الأساسية للنماذج اللغوية الرؤية

تعتمد النماذج اللغوية الرؤية على بنية متكاملة تجمع بين ثلاثة مكونات رئيسية [34]:

1. مشفر الصورة (Vision Encoder):


- يعتمد على شبكات الالتفاف العميقة أو محولات الرؤية (Vision Transformers).
- يقوم بتحويل الصورة المدخلة إلى تمثيل عددي (Visual Embeddings).
- يلتقط الميزات البصرية على مستويات متعددة (من الحواف البسيطة إلى الأنماط المعقدة).

2. مشفر النص (Text Encoder):

- يعتمد على محولات (Transformers) مشابهة لتلك المستخدمة في نماذج اللغة الكبيرة.
- يحول النص المدخل (كالتعليمات الطبية) إلى تمثيلات رقمية.

3. طبقة الدمج المتقاطع (Cross-Attention Layer):

- تدمج التمثيلات البصرية والنصية لفهم العلاقات بينهما.
- تمكن النموذج من "ربط" الأوصاف اللغوية بالمناطق البصرية المقابلة في الصورة [35].



الشكل (3-4): بنية نموذج لغوي رؤيوي (VLM) متكامل مع مشفر الصورة ومشفر النص وطبقة الدمج المتقاطع.

2-3-3 نظام الترقيم العالمي (FDI Tooth Numbering System)

يعتمد النظام في هذا المشروع على نظام الترقيم العالمي FDI (Fédération Dentaire Internationale) لتحديد الأسنان المصابة بدقة. يتكون هذا النظام من رقمين:

- الرقم الأول: يحدد الربع (1=العلوي الأيمن، 2=العلوي الأيسر، 3=السفلي الأيسر، 4=السفلي الأيمن).

- الرقم الثاني: يحدد موقع السن ضمن الربع (1-8).


على سبيل المثال:

- السن 11: القاطعة المركزية العلوية اليمنى.

- السن 46: الضرس السفلي الأيمن الأول.

- السن 28: الضرس العلوي الأيسر الثاني.

ويُطلب من النموذج اللغوي الرؤيوي في هذا المشروع استخدام هذا النظام في تقاريره التشخيصية، مما يضمن دقة التواصل مع الأطباء [36].



الشكل (3-5): نظام FDI للترقيم.

3-3-3 آلية عمل النماذج اللغوية الرؤيوية في التشخيص الطبي

تعتمد النماذج اللغوية الرؤيوية على خطوات متسلسلة لتحليل الصورة وتوليد التقرير التشخيصي [35]:

الخطوة 1: استقبال الصورة والنص

- يستقبل النموذج الصورة (مشفرة بصيغة Base64) مع تعليمات نظام (System Prompt) تحدد المطلوب منه.

الخطوة 2: تشفير الصورة

- يقوم مشفر الصورة بتحويل الصورة إلى متجهات بصرية عالية الأبعاد.

الخطوة 3: معالجة النص

- يقوم مشفر النص بتحويل التعليمات النصية إلى متجهات نصية.

الخطوة 4: الدمج المتقاطع

- تقوم طبقات الدمج المتقاطع بربط المعلومات البصرية بالنصية باستخدام آلية الانتباه متعدد الرؤوس (Multi-Head Attention) [34].

الخطوة 5: توليد التقرير

- يقوم النموذج بتوليد النص النهائي (تقرير تشخيصي على هيئة JSON) يحتوي على:
 - ملخص الحالة.
 - الأمراض المكتشفة مع وصفها.
 - مواقعها باستخدام نظام FDI.
 - نسب الثقة.
 - التوصيات العلاجية.

الخطوة 6: التجزئة الدقيقة (SAM)

- تُستخدم إحداثيات الصناديق التقريبية من التقرير كمدخلات لنموذج SAM لإنتاج مضلعات دقيقة [41].

4-3-3 دالة الخسارة والتدريب

على عكس نماذج الكشف التقليدية التي تعتمد على دالة خسارة مركبة (Localization + Confidence + Classification)، تعتمد النماذج اللغوية الرؤيوية على دالة خسارة توليدية تقيس جودة النص المُولّد مقارنة بالنص الحقيقي، باستخدام مقاييس مثل:

- Cross-Entropy Loss: لقياس دقة الكلمات المُولّدة.

- Perplexity: لقياس سلاسة النص.

- BLEU / ROUGE: لمقارنة جودة التقرير المُولّد مع التقارير المرجعية [36].

يتم تدريب هذه النماذج على ملايين الأزواج من (الصورة، النص) المستخرجة من الإنترنت والمصادر الطبية، مما يمنحها فهماً واسعاً للسياقات المختلفة [35].

4-3 نموذج التجزئة الدقيقة (SAM (Segment Anything Model

1-4-3 المكونات الأساسية لنموذج SAM

يتكون نموذج SAM من ثلاث وحدات رئيسية تعمل بتكامل لتحقيق التجزئة الدقيقة [41]:

1. مشفر الصورة (Image Encoder):

- يعتمد على بنية Vision Transformer (ViT-B).
- يحول الصورة المدخلة إلى تمثيل بصري عالي الأبعاد (Embedding).
- يحتوي على 12 طبقة Transformer مع أبعاد تضمين 768 وبعدها 12 رأس انتباه (Attention Heads).


- حجم النموذج: 93.74 مليون معامل (358 ميغابايت على القرص).

2. مشفر الموجه (Prompt Encoder):

- يستقبل أنواعاً مختلفة من الموجهات:
 - نقاط (Points).
 - صناديق إحاطة (Bounding Boxes).
 - نصوص (Texts).
- يحولها إلى تمثيلات رقمية يمكن دمجها مع التمثيل البصري.

3. مفكك القناع الخفيف (Lightweight Mask Decoder):

- يدمج التمثيل البصري مع التمثيل الرقمي للموجه.
- ينتج قناع التجزئة النهائي (Mask) مع درجة الثقة.
- سريع جداً مقارنة بمشفر الصورة [41].



الشكل (3-6): بنية SAM.

2-4-3 نسبة التقاطع على الاتحاد (Intersection over Union – IoU)

الخطوة 1: استلام الصندوق التقريبي

- يستقبل النظام إحداثيات الصندوق التقريبي من النموذج اللغوي الرؤية (Gemini)
- بصيغة {x, y, width, height}، (3.1 Pro).

الخطوة 2: تحويل الصندوق إلى تنسيق SAM

- يُحوّل الصندوق إلى الصيغة المطلوبة من SAM: [x1, y1, x2, y2] (الإحداثيات المطلقة بالبكسل).

الخطوة 3: تشفير الصورة (مرة واحدة لكل صورة)

- يتم تنفيذ predictor.set_image(img_rgb) لتشفير الصورة كاملة.
- هذه العملية هي الأكثر استهلاكاً للوقت (حوالي 18.7 ثانية على CPU).
- يتم تنفيذها مرة واحدة لكل صورة وليس لكل مرض، مما يوفر وقتاً كبيراً.

الخطوة 4: التنبؤ بالقناع

- يتم تنفيذ predictor.predict(box=box_px[None, :]).
- ينتج النموذج قناعاً (Mask) يحدد المنطقة المصابة بدقة على مستوى البكسل.
- تُستخدم معلمة multimask_output=False لإنتاج قناع واحد فقط (أسرع).

الخطوة 5: تحويل القناع إلى مضلع (Polygon)

- يُحوّل القناع إلى نقاط مضلع باستخدام مكتبة OpenCV:

- cv2.findContours () لاستخراج الكفاف الخارجي.
- cv2.approxPolyDP () لتبسيط النقاط (تقليل عددها) مع الحفاظ على الدقة.
- تُحوّل النقاط من إحداثيات بكسل إلى نسب مئوية (0-100) لتكون مستقلة عن حجم العرض.

الخطوة 6: عرض المضلع على الواجهة

- تُرسل نقاط المضلع إلى الواجهة الأمامية لعرضها كـ <polygon> داخل <svg> فوق الصورة الأصلية.
- تُظهر هذه المضلعات حدود المنطقة المصابة بدقة تشريحية عالية [42].

3-4-3 إصدارات SAM المتاحة

الجدول (3-1): إصدارات SAM المتاحة.

الإصدار	الحجم على القرص	عدد المعاملات	زمن set_image (CPU)	الملاءمة
(المستخدم) ViT-B	358 MB	93.74M	18.7 ثانية	متوازن (دقة/سرعة)
ViT-L	1.2 GB	308M	~35 ثانية	دقة أعلى، أبطأ
ViT-H	2.4 GB	636M	~55 ثانية	أعلى دقة، أبطأ

تم اختيار نسخة ViT-B لأنها تحقق توازناً مثالياً بين الدقة والسرعة، وتعمل بكفاءة على الأجهزة المتوسطة (8GB RAM، معالج Core i5) المستخدمة في هذا المشروع [41].

5-3 مقارنة بين النماذج اللغوية الرؤية ونماذج الكشف التقليدية

الجدول (3-2): مقارنة بين النماذج اللغوية الرؤية ونماذج الكشف التقليدية.

المعيار	نماذج الكشف التقليدية (YOLO, R-CNN)	النماذج اللغوية الرؤية (VLMs)
نوع المخرجات	أسماء أمراض + صناديق إحاطة	تقرير تشخيصي نصي مفصل بالعربية
دقة التحديد	صندوق تقريبي (Box Bounding)	مضلع دقيق من SAM (Polygon)
المرونة	محدودة بالأمراض المدربة عليها	تفهم سياقياً أي مرض تقريباً
التدريب	يتطلب بيانات موسومة لكل مرض	تدريب مسبق على ملايين الصور والنصوص
التوسع	يحتاج إعادة تدريب لإضافة أمراض جديدة	يمكن إضافة أمراض جديدة عبر تعديل ال Prompt فقط
التكامل مع اللغة العربية	محدود (يخرج أسماء فقط)	يولد تقارير كاملة بالعربية
زمن الاستجابة	سريع (أقل من ثانية)	أبطأ (5-40 ثانية حسب تعقيد الصورة)
التكلفة الحسابية	منخفضة (تعمل على CPU/GPU متوسط)	عالية (تعتمد على خوادم سحابية للـ SAM + VLM محلي)

6-3 استراتيجيات تحسين أداء النظام

6-3-1 تحسين زمن SAM

نظراً لأن `set_image` هي عنق الزجاجة الرئيسي (18.7 ثانية على CPU)، تم تطبيق التحسينات التالية:

1. تنفيذ `set_image` مرة واحدة فقط لكل صورة:

- قبل: 3 أمراض × 25 ثانية = 75 ثانية.

- بعد: 25 ثانية + 3 × 1 > ثانية = ~28 ثانية.

- التوفير: ~60% [6].

2. تصغير الصورة للحد الأقصى 1024 بكسل:

- يقلل وقت set_image بشكل كبير.

- فقدان دقة ضئيل (الصندوق التقريبي أصلاً غير دقيق) [6].

3. استخدام multimask_output=False:

- يُرجع قناعاً واحداً بدلاً من 3، مما يسرع العملية ويقلل استهلاك الذاكرة [41].

4. تحميل النموذج كسولاً (Lazy Loading):

- يُحمّل النموذج فقط عند أول طلب.

- استخدام threading.Lock لمنع التحميل المتزامن [6].

3-6-2 تحسين دقة النموذج اللغوي الرؤية

1. هندسة الأوامر (Prompt Engineering):

- صياغة تعليمات نظام دقيقة تحدد بنية التقرير المطلوب (JSON صارم).

- استخدام نظام الترقيم العالمي (FDI) لتوحيد تحديد الأسنان.

- إضافة تحيز سلبي (عند الشك، لا تُبلغ) لتقليل الإجابات الكاذبة [39].

2. التحكم بمعامل درجة الحرارة (Temperature):

- تعيين قيمة منخفضة (0.2) للحصول على إجابات أكثر دقة واستقراراً.

- القيم المنخفضة تقلل من الإبداع وتزيد من الدقة في السياقات الطبية [40].

3. إعادة المحاولة التلقائية (Retry Mechanism):

- إذا فشل النموذج في توليد JSON صحيح، يعاد المحاولة تلقائياً (حتى 3 مرات).
- زيادة max_tokens إلى 16000 عند الحاجة للتقارير الطويلة [36].

7-3 التطبيقات العملية في النظام المقترح

1-7-3 تحليل الصور السريرية والشعاعية

يدعم النظام نوعين من الصور الطبية:

- الصور السريرية (Clinical Photos): صور ملتقطة بالكاميرا داخل الفم، تُستخدم للكشف عن التسوس السطحي، التصبغات، والكسور الظاهرة.
- الصور الشعاعية (Radiographs / X-rays): صور أشعة (بانورامية أو ذروية)، تُستخدم للكشف عن فقدان العظم، والتهاب الالفة حول الذروية، والكسور الجذرية [8]، [9]، [10].

2-7-3 توليد التقرير التشخيصي

يُنتج النموذج اللغوي الرؤيوي تقريراً على هيئة JSON يحتوي على:

- ملخص عام (summary): وصف شامل للحالة بالعربية.
- الحالة العامة (overallCondition): ممتاز / جيد / بحاجة لمتابعة / حرج.
- درجة النظافة (hygieneScore): قيمة رقمية (0-100).
- قائمة المشاكل (issues): لكل مشكلة: رقم السن، اسم السن، نوع المشكلة، الخطورة، الثقة، الوصف، التوصية، والصندوق التقريبي.

- التوصيات العامة (generalRecommendations): قائمة توصيات وقائية وعلاجية.

3-7-3 التكامل مع SAM

يُستخدم SAM بعد توليد التقرير لتحويل كل صندوق تقريبي إلى مضلع دقيق، مما يعطي الطبيب رؤية تشريحية دقيقة للمنطقة المصابة [41]، [42].

الفصل الرابع: التنفيذ

العملي


1-4 مقدمة

يُعد هذا الفصل المرحلة التطبيقية الأساسية في هذه الأطروحة، حيث يتم فيه تحويل المفاهيم النظرية المرتبطة بالذكاء الاصطناعي والرؤية الحاسوبية إلى منصة ويب تشخيصية متكاملة قادرة على تشخيص أمراض الفم والأسنان من خلال تحليل الصور الرقمية. يهدف هذا الفصل إلى توضيح كيفية بناء النظام المقترح وتنفيذه، بدءًا من تصميم بنيته العامة، وصولاً إلى دمج النماذج اللغوية الرؤية ونماذج التجزئة الدقيقة، وتقييم أدائها.

يتناول الفصل في بدايته نظرة عامة على النظام موضحة بمخطط حالات الاستخدام، ثم يتم عرض معمارية النظام من خلال مخطط المكونات الذي يبيّن العلاقات بين الواجهة الأمامية والخادم الخلفي والخدمات السحابية والنماذج المحلية. بعد ذلك، يتم شرح تدفق العمل داخل النظام باستخدام مخطط الحالة الذي يوضح دورة حياة الفحص الطبي خطوة بخطوة. كما يتضمن الفصل شرحاً مفصلاً لآلية دمج النماذج الذكية، وهيكل قاعدة البيانات الموضح بمخطط العلاقات بين الجداول. وأخيراً، يتم عرض تنفيذ واجهة المستخدم التي تضم سبع شاشات رئيسية، مما يتيح التفاعل مع النظام بشكل سهل وفَعّال.

2-4 نظرة عامة على النظام

يُقدّم النظام المقترح إطاراً متكاملاً لتشخيص أمراض الفم والأسنان اعتماداً على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، حيث يهدف إلى تحليل الصور السنية (السريرية والشعاعية) واكتشاف الحالات المرضية بشكل آلي وسريع، مع توليد تقارير تشخيصية نصية باللغة العربية وتحديد دقيق للمناطق المصابة على مستوى البكسل.




الشكل (4-1): مخطط حالات الاستخدام (Use Case Diagram) يوضح تفاعلات المستخدمين مع نظام Smart Dent AI.

يُظهر مخطط حالات الاستخدام في الشكل (4-1) التفاعلات الرئيسية بين المستخدمين (الطبيب والنظام الذكي) والنظام، والتي تشمل إدارة المرضى (CRUD) لإضافة وتعديل وحذف وعرض بيانات المرضى، ورفع صورة أشعة لتحميل الصور السنية سواءً كانت سريرية أو شعاعية لتحليلها حيث تتضمن هذه الحالة علاقة «include» مع تحليل الصورة بالذكاء الاصطناعي الذي يستخدم النموذج اللغوي الرئوي Gemini ونموذج التجزئة SAM، وتحليل الصورة بالذكاء الاصطناعي الذي يتضمن علاقة «include» مع عرض خريطة الأسنان مع التظليل لعرض النتائج على خريطة أسنان تفاعلية تُظلل الأسنان المصابة حسب درجة الخطورة، وعلاقة «extend» مع اختيار مزود AI، وتقييم وتأكيـد التشخيص الذي يتضمن علاقة «include» مع عرض الفحوصات السابقة لاستعراض تاريخ الفحوصات للمريض، وعرض

الفحوصات السابقة، وعرض خريطة الأسنان مع التظليل، وتصدير تقرير PDF لاستخراج التقرير التشخيصي بصيغة رسمية، وتعديل الوضع (داكن/فاتح) لتبديل الثيم البصري للنظام، ويعتمد النظام على مبدأ التكامل بين مكوناته المختلفة ضمن خط معالجة متسلسل، حيث تنتقل البيانات بين المراحل بشكل منظم يضمن تحقيق كفاءة في الأداء ودقة في النتائج.

3-4 معمارية النظام

تعرض معمارية النظام البنية الداخلية التي يعتمد عليها النظام لتنفيذ عملية تشخيص أمراض الأسنان، حيث يتم تقسيم النظام إلى مجموعة من المكونات البرمجية المترابطة التي تتعاون فيما بينها لتنفيذ مراحل المعالجة المختلفة ابتداءً من استقبال طلب المستخدم وانتهاءً بعرض نتائج التشخيص وإصدار التقرير النهائي. ويوضح مخطط المكونات في الشكل (2-4) كيفية توزيع هذه المكونات والعلاقات التي تربط بينها، بما يحقق الفصل بين طبقات النظام ويسهل عمليات التطوير والصيانة مستقبلاً.



الشكل (2-4): مخطط المكونات (Component Diagram) يوضح البنية البرمجية للنظام وتفاعل مكوناته.

تبدأ دورة العمل من الواجهة الأمامية (Frontend) المبنية باستخدام إطار العمل React، حيث تمثل الوحدة `main.tsx` نقطة الدخول إلى التطبيق، إذ تتولى تهيئة بيئة التشغيل وتحميل المكون الرئيسي. بعد ذلك تنتقل عملية التحكم إلى `App.tsx` الذي يمثل المكون الجذر للتطبيق، ويحتوي على الشريط العلوي (Header) وأشرطة التنقل (Tabs)، كما يتولى إدارة التنقل بين صفحات النظام المختلفة. ويتفرع من هذا المكون عدد من الصفحات والوحدات الفرعية، أهمها صفحة `Dashboard.tsx` التي تعرض الواجهة الرئيسية للنظام، وصفحة `AIAnalysis.tsx` المسؤولة عن عرض نتائج تحليل صور الأسنان باستخدام تقنيات الذكاء الاصطناعي، بالإضافة إلى صفحة `ToothMap.tsx` التي تعرض خريطة الأسنان وفق نظام ترقيم FDI لتوضيح الأسنان المصابة ومواقعها. كما تعتمد هذه الصفحة على المكون `MiniToothMap.tsx` الذي يعرض نسخة مصغرة من خريطة الأسنان بجانب نتائج التحليل، بينما تتولى الوحدة `exportPDF.ts` إنشاء التقرير النهائي وتصديره بصيغة PDF، في حين يعمل الخُطاف `useTheme.ts` على إدارة مظهر التطبيق والتبديل بين الوضعين الفاتح والداكن مع حفظ تفضيلات المستخدم.

أما في الخادم الخلفي (Backend) المبنى باستخدام إطار العمل Flask، فيمثل الملف `web_app.py` نقطة التحكم الرئيسية، حيث يستقبل طلبات الواجهة الأمامية عبر واجهات برمجية (APIs)، ثم ينسق عملية التواصل مع بقية الوحدات البرمجية. وتتولى الوحدة `database.py` إدارة عمليات التخزين والاسترجاع من قاعدة البيانات SQLite وتنفيذ عمليات الإضافة والتعديل والحذف والاستعلام، بينما تقوم الوحدة `sam_segmenter.py` بتغليف نموذج (SAM) Segment Anything Model وتحميله وتشغيله لتنفيذ عملية تجزئة الأسنان

داخل الصور. وبعد انتهاء عمليات التحليل، تمر المخرجات عبر وحدة JSON Normalizer التي تعمل على تنظيف البيانات وتحويلها إلى بنية موحدة (normalize_to_ui_schema) تتوافق مع متطلبات الواجهة الأمامية قبل إرسالها للمستخدم.

وتعتمد المعالجة المحلية داخل النظام على نموذج SAM ViT-B المخزن في الملف sam_vit_b.pth، والذي يتم تحميله باستخدام مكتبة PyTorch عبر الدالة torch.load()، ويعمل محلياً على المعالج المركزي (CPU) أو معالج الرسومات (GPU) عند توفره، بهدف تنفيذ عملية تجزئة الأسنان بدقة عالية. كما يعتمد النظام على قاعدة بيانات SQLite المخزنة في الملف dental_ai.db، والتي تحتفظ بجميع بيانات المرضى ونتائج التحليل والتقارير، وتوفر وسيلة خفيفة وسريعة لإدارة البيانات داخل النظام.

ولتنفيذ مهام التحليل الذكي والاستدلال اللغوي، يعتمد النظام على مجموعة من الخدمات السحابية (Cloud APIs)، حيث يتم استخدام نموذج Gemini 3.1 Pro عبر الخادم api.abdalgani.com لإجراء التحليل السياقي لصور الأسنان وتوليد التشخيص والتقارير الطبية، كما يتم استخدام نموذج Kimi K2.6 عبر nano-gpt.com لتنفيذ مهام المحادثة والتحليل اللغوي المساند. ويتم الاتصال بهذه النماذج باستخدام OpenAI Client الذي يوفر واجهة موحدة للتواصل مع الخدمات السحابية وإرسال الطلبات واستقبال النتائج.


وبصورة عامة، تبدأ عملية العمل عندما يرسل المستخدم صورة الأسنان من خلال الواجهة الأمامية باستخدام بروتوكول HTTPS، حيث يستقبلها الخادم الخلفي ويجري عمليات المعالجة الأولية، ثم ينفذ نموذج SAM ViT-B عملية تجزئة الأسنان محلياً، وبعد ذلك يتم

إرسال البيانات اللازمة إلى النماذج السحابية لإجراء التحليل والتشخيص. وعند استلام النتائج، تُمرر البيانات إلى وحدة JSON Normalizer لتوحيد صيغة المخرجات، ثم تُعاد إلى الواجهة الأمامية ليتم عرضها على خريطة الأسنان التفاعلية مع إمكانية تصدير تقرير تشخيصي بصيغة PDF. ويعتمد تصميم هذه المعمارية على مبدأ الفصل بين المكونات (Separation of Concerns)، الأمر الذي يساهم في رفع قابلية النظام للتطوير والصيانة، ويضمن تدفق البيانات بصورة منظمة بين مختلف مراحل المعالجة، مع توفير مرونة عالية لإضافة نماذج أو خدمات جديدة مستقبلاً دون الحاجة إلى إجراء تغييرات جوهرية في بنية النظام.

4-4 تدفق عمل النظام

يعرض مخطط الحالة الموضح في الشكل (4-3) دورة حياة عملية فحص المريض داخل نظام Smart Dent AI، حيث يوضح التسلسل الزمني للحالات التي تمر بها البيانات منذ بدء المستخدم عملية رفع صورة الأسنان وحتى الانتهاء من عرض نتائج التشخيص. ويبين المخطط انتقال النظام بين مجموعة من الحالات المترابطة التي تمثل مراحل المعالجة المختلفة، مع توضيح حالات الانتظار، والمعالجة، والعرض، والتحديث، والتصدير، إضافة إلى التعامل مع حالات الخطأ المحتملة، مما يوفر تصوراً واضحاً لسير عمل النظام أثناء تنفيذ عملية التشخيص.

مخطط الحالة (State Diagram)
دورة حياة الفحص السريري للطبيب - Smart Dent AI



الشكل (3-4): مخطط الحالة (State Diagram) يوضح دورة حياة فحص المريض في نظام Smart Dent AI.

تبدأ دورة العمل بحالة Idle التي تمثل حالة انتظار النظام لتفاعل المستخدم، حيث يكون التطبيق في وضع الاستعداد بعد تشغيله، ويستطيع المستخدم اختيار صورة جديدة لفحصها أو استعراض نتائج سابقة. وعند اختيار صورة الأسنان، ينتقل النظام إلى حالة Uploading، والتي تتولى تنفيذ جميع العمليات المتعلقة برفع الصورة، إذ يتم أولاً قراءة الملف من جهاز المستخدم، ثم تحويله إلى الصيغة المناسبة للإرسال، وبعد ذلك إرسال الطلب إلى الخادم الخلفي عبر واجهة برمجية تعتمد بروتوكول HTTPS، مع انتظار استجابة الخادم قبل الانتقال إلى مرحلة التحليل.

بعد نجاح عملية الرفع، يدخل النظام إلى حالة Analyzing التي تمثل المرحلة الأساسية في عملية التشخيص، حيث تُنفذ معظم العمليات الحسابية والذكاء داخل النظام. تبدأ هذه المرحلة باستدعاء النموذج اللغوي من خلال الحالة الفرعية Calling LLM، إذ يتم إرسال بيانات الصورة إلى أحد النماذج السحابية المستخدمة في النظام، مثل Gemini أو Kimi، لإجراء التحليل الأولي واستخلاص المعلومات التشخيصية. وبعد استلام الاستجابة، ينتقل النظام إلى الحالة Parsing JSON، حيث يتم تحليل البيانات المستلمة والتحقق من صحتها وتحويلها إلى بنية بيانات موحدة يمكن لبقية مكونات النظام التعامل معها بسهولة. ثم تبدأ مرحلة Start SAM التي يتم خلالها تهيئة نموذج Segment Anything Model (SAM) وتحميل الصورة داخله، تليها حالة Detect Prediction التي ينفذ فيها النموذج عملية التجزئة الدقيقة للأسنان وتحديد حدودها واستخراج المضلعات الخاصة بكل سن أو منطقة مصابة. وبعد اكتمال هذه العمليات، يصل النظام إلى حالة Building Response التي يتم فيها دمج نتائج التحليل اللغوي مع نتائج التجزئة الهندسية ضمن استجابة موحدة يتم إرسالها إلى الواجهة الأمامية.

عقب انتهاء مرحلة التحليل، ينتقل النظام إلى حالة Showing Results، والتي تتولى عرض النتائج للمستخدم بصورة تفاعلية. ففي هذه المرحلة يتم رسم المضلعات التي تحدد مواقع الأسنان أو المناطق المصابة فوق الصورة الأصلية، كما يتم تحديث خريطة الأسنان المصغرة لإظهار الأسنان المتأثرة، بالإضافة إلى عرض التقرير التشخيصي وقائمة المشكلات المكتشفة، مما يسمح للمستخدم بمراجعة النتائج بصورة واضحة وسهلة.

كما يوضح المخطط إمكانية انتقال النظام إلى حالة Syncing عند طلب المستخدم مزامنة النتائج، حيث يتم تحديث خريطة الأسنان وإعادة ربط نتائج التحليل مع التمثيل الرسومي للأسنان، بما يضمن توافق البيانات المعروضة مع أحدث نتائج التشخيص. وفي حال رغبة المستخدم بالحصول على تقرير قابل للطباعة، ينتقل النظام إلى حالة Exporting، والتي تتولى إنشاء تقرير بصيغة PDF يتضمن صورة الأسنان ونتائج التحليل والتشخيص، ثم حفظه أو مشاركته وفق احتياجات المستخدم.

ويتضمن المخطط أيضاً مسارات للتعامل مع حالات الفشل والاستثناءات التي قد تحدث أثناء تنفيذ عملية التشخيص، مثل فشل رفع الصورة، أو انقطاع الاتصال بالخادم، أو حدوث خطأ أثناء استدعاء النماذج السحابية أو معالجة البيانات. وفي هذه الحالات ينتقل النظام إلى حالة الخطأ المناسبة، حيث يتم عرض رسالة توضح سبب المشكلة للمستخدم، مع إتاحة إمكانية إعادة المحاولة أو العودة إلى مرحلة رفع الصورة دون الحاجة إلى إعادة تشغيل التطبيق.

يتضح من هذا المخطط أن النظام يعتمد على نموذج حالات (State Machine) منظم، حيث تنتقل البيانات بصورة متسلسلة بين حالات الانتظار، والرفع، والتحليل، والعرض، والمزامنة،

والتصدير، مع وجود آليات واضحة لمعالجة الأخطاء. ويسهم هذا الأسلوب في تنظيم سير العمل داخل النظام، وتقليل التعقيد البرمجي، وضمان تنفيذ عمليات التشخيص بصورة متسقة وموثوقة، مما يحسن تجربة المستخدم ويرفع من كفاءة النظام واستقراره أثناء التشغيل.

4-5 دمج النماذج اللغوية الرؤية ونظام التجزئة الدقيقة

4-5-2 استدعاء النموذج اللغوي الرؤية

يُستخدم النموذج اللغوي الرؤية (Gemini 3.1 Pro) عبر واجهة برمجة تطبيقات سحابية متوافقة مع المعايير العالمية. يُرسل الطلب إلى الواجهة محملاً بالصورة المحولة إلى تنسيق رقمي مناسب، بالإضافة إلى تعليمات نظام (System Prompt) تحدد طبيعة المهمة المطلوبة.

محتوى تعليمات النظام:

- تطلب من النموذج أن يتصرف كطبيب أشعة متمرس، وأن يلتزم بالقواعد التالية:
- عدم التبليغ عن أي ملاحظة غير مؤكدة بنسبة عالية من الثقة (تحيز سلبي).
- التمييز بدقة بين التصبغ الطبيعي والمرضي.
- استخدام نظام التقييم العالمي (FDI) لتحديد مواقع الأسنان المصابة (الأرقام من 11 إلى 48).
- توليد توصيات علاجية مناسبة لكل حالة مكتشفة.
- إخراج التقرير بصيغة JSON صارمة تلتزم ببنية محددة مسبقاً.

بنية التقرير المُولد:

يتضمن التقرير حقلاً للملخص العام باللغة العربية، وحقلاً للحالة العامة (ممتاز، جيد، بحاجة لمتابعة، حرج)، ودرجة نظافة رقمية، وقائمة بالمشاكل المكتشفة، وتوصيات عامة. تحتوي كل مشكلة في القائمة على رقم السن، واسمه، ونوع المشكلة، ومستوى الخطورة، ونسبة الثقة، ووصفاً تفصيلياً، وتوصية علاجية، وصندوق إحاطة تقريبي يُحدد المنطقة المصابة.

يُضبط معامل درجة الحرارة (Temperature) على قيمة منخفضة (0.2) لضمان الحصول على إجابات دقيقة ومتسقة، ويُحدد عدد الرموز الأقصى (Max Tokens) بما يكفي لاستيعاب التقارير الطبية الطويلة.

4-5-2 نموذج التجزئة الدقيقة

بعد استلام التقرير من النموذج اللغوي الرؤيوي، يُستخدم نموذج التجزئة الدقيقة SAM (Segment Anything Model) لتحويل الصناديق التقريبية إلى مضلعات دقيقة على مستوى البكسل.

تحميل النموذج:

يُحمّل نموذج SAM إلى ذاكرة الخادم عند أول طلب تحليل، ويُبقى في الذاكرة للطلبات اللاحقة لتجنب إعادة التحميل. يستخدم المشروع الإصدار ViT-B من النموذج، الذي يحتوي على حوالي 93.74 مليون معامل وحجم 358 ميغابايت على القرص، وهو يحقق توازناً مثالياً بين الدقة والسرعة.


خطوات التجزئة لكل صندوق:

- تشفير الصورة: تُمرّر الصورة إلى النموذج لتوليد تمثيل بصري عالي الأبعاد لها. هذه العملية هي الأكثر استهلاكاً للوقت، وتُنفذ مرة واحدة فقط لكل صورة وليس لكل مرض، مما يوفر وقتاً كبيراً.
- التنبؤ بالقناع: يُمرّر الصندوق التقريبي كموجه إلى النموذج، فيقوم بتوليد قناع يحدد المنطقة المصابة بدقة على مستوى البكسل، مع درجة ثقة مصاحبة.
- استخراج المضلع: يُحوّل القناع الناتج إلى مضلع يتكون من سلسلة من النقاط، باستخدام تقنيات معالجة الصور لاستخراج الكفاف الخارجي للقناع وتبسيطه إلى عدد محدود من النقاط مع الحفاظ على الدقة التشريرية.
- تحويل الإحداثيات: تُحوّل إحداثيات المضلع من البكسل إلى نسب مئوية (0-100) لتكون مستقلة عن حجم عرض الصورة، مما يضمن ظهورها بشكل صحيح على مختلف أحجام الشاشات.
- الإرسال إلى الواجهة: تُرسل نقاط المضلع إلى الواجهة الأمامية لعرضها كطبقة شفافة ملونة فوق الصورة الأصلية.

يجمع هذا التكامل بين قوة الفهم السياقي للنماذج اللغوية الرؤيوية ودقة التحديد المكاني لنماذج التجزئة، مع الحفاظ على خصوصية الصور الطبية من خلال إجراء التجزئة محلياً.

4-6 قاعدة البيانات وبنية البيانات

يستخدم النظام قاعدة بيانات SQLite، وهي نظام إدارة قواعد بيانات خفيف يعمل بملف واحد، مما يسهل نقله ونسخه احتياطياً دون الحاجة إلى تثبيت خادم منفصل.



الشكل (4-4): مخطط العلاقات بين الجداول (ERD) يوضح بنية قاعدة بيانات Smart Dent AI وعلاقاتها.

1. جدول المرضى (patients):

يُخزن المعلومات الأساسية والطبية لكل مريض، وتشمل حقولاً للمعرّف الفريد (PK)، والاسم الكامل، والعمر، والجنس، ورقم الهاتف، والبريد الإلكتروني، والتاريخ الطبي المرضي، وتاريخ الإنشاء. يُعد هذا الجدول الجذر الذي ترتبط به بقية الجداول.

2. جدول الفحوصات (scans):

يُخزن معلومات كل فحص (صورة) تم تحليلها، وتشمل حقولاً للمعرّف الفريد (PK)، ومعرّف المريض المرتبط (FK) مع خاصية الحذف المتتالي (ON DELETE CASCADE)، واسم ملف الصورة، وبيانات الصورة نفسها، واسم المزود، واسم النموذج، والحالة العامة، والتوصيات العامة، والتحليل السريري، وتاريخ الإنشاء. يرتبط كل فحص بمريض واحد (علاقة N:1 من جهة الفحوصات إلى المريض).

3. جدول الاكتشافات المرضية (detections):

يُخزّن التفاصيل الدقيقة لكل مرض تم اكتشافه في كل فحص، وتشمل حقولاً للمعرّف الفريد (PK)، ومعرّف الفحص المرتبط (FK) مع خاصية الحذف المتتالي، واسم المرض، ورقم السن، واسم السن، ووصف الموقع، ونسبة الثقة، ومستوى الخطورة. يرتبط كل اكتشاف بفحص واحد (علاقة N:1 من جهة الاكتشافات إلى الفحص).

4. جدول تقييمات الأطباء (evaluations):

يُخزّن مراجعات وتقييمات الأطباء للفحوصات، وتشمل حقولاً للمعرّف الفريد (PK)، ومعرّف الفحص المرتبط (FK) مع خاصية الحذف المتتالي، واسم الطبيب، وملاحظات الطبيب، وحقل منطقي للتأكيد، ومستوى الخطورة المُصحّح، وتاريخ الإنشاء. يتيح هذا الجدول للأطباء مراجعة نتائج الذكاء الاصطناعي وتأكيدها أو تصحيحها.

5. جدول الموسوعة الطبية (diseases):

يُخزّن المعلومات المرجعية عن الأمراض السنية، ويُعد جدولاً مرجعياً مستقلاً (غير مرتبط بعلاقات أجنبية). تشمل حقوله اسم المرض بالعربية والإنجليزية، والتصنيف، والوصف، والأعراض، والعلاج، والوقاية، ومستوى الخطورة الافتراضي، والأيقونة. يُملأ هذا الجدول تلقائياً عند أول تشغيل للنظام بثمانية أمراض سنية على الأقل.

العلاقات الأساسية:


- كل مريض يمكن أن يكون لديه عدة فحوصات (علاقة واحد إلى متعدد).
- كل فحص يمكن أن يحتوي على عدة اكتشافات مرضية (علاقة واحد إلى متعدد).
- كل فحص يمكن أن يكون له عدة تقييمات من أطباء مختلفين (علاقة واحد إلى متعدد).

- خاصية الحذف المتتالي (ON DELETE CASCADE) مضمّنة لضمان حذف الفحوصات والاكتشافات والتقييمات تلقائياً عند حذف المريض.

7-4 تنفيذ واجهة المستخدم

طوّرت واجهة المستخدم باستخدام إطار العمل React في نسخته التاسعة عشرة مع لغة TypeScript وإطار التصميم Tailwind CSS في نسخته الرابعة، واعتمد التصميم على هوية بصرية موحدة تتمحور حول اللون العنابي الداكن كلون أساسي، مع دعم كامل للوضع الداكن والفاتح والخط العربي الحديث Cairo. تضم الواجهة سبع شاشات رئيسية تغطي جميع جوانب إدارة العيادة الذكية.

1-7-4 شاشة لوحة التحكم



الشكل (4-5): شاشة لوحة التحكم الرئيسية لنظام Smart Dent AI.

تمثل لوحة التحكم الصفحة الرئيسية للنظام، وتوفر نظرة عامة سريعة على حالة العيادة من خلال مجموعة من المكونات المتكاملة:

- الشريط العلوي وشريط التنقل: يحتوي على شعار المنصة "Smart Dent AI" مع عنوان لوحة التحكم واسم العيادة وموقعها (سوريا - حماة - ساحة العاصي)، وشريط تنقل أفقي يضم الأقسام الأساسية (الرئيسية، بيانات المرضى، خريطة الأسنان، مسح الأشعة الذكي، التقارير، التسعير والتكاليف، الموسوعة الطبية)، مع زر تبديل الوضع الداكن.

- شريط الترحيب والإجراءات السريعة: يضم عنواناً ترحيبياً بالطبيب مع عرض التاريخ الحالي، وأربعة أزرار سريعة: إضافة مريض، تحليل أشعة، تقرير علاج، والتسعير.
- بطاقات الإحصائيات اليومية: تعرض أربع بطاقات ملخصة للمؤشرات الرئيسية (مرضى اليوم، قيد العلاج، أشعة محللة، تقارير معلقة).
- جدول مواعيد ومرضى اليوم: يعرض قائمة المرضى المقررين مع تفاصيل الاسم، والعمر، والإجراء، والحالة (بشارات بصرية ملونة)، ورابط سريع للملف.
- لوحة التنبيهات والإشعارات الطبية (الجانبية): تعرض تنبيهات الحساسية الدوائية بلون أحمر بارز، وجدول المراجعات القادمة.
- قسم الذكاء الاصطناعي واللمحة المالية (السفلي): يشمل منطقة سحب وإفلات الأشعة، وبطاقة اللمحة المالية السريعة.

4-7-2 شاشة بيانات المرضى

تمثل هذه الشاشة واجهة مركزية تجمع بين إدارة سجلات المرضى وخريطة الأسنان التفاعلية ضمن نظام Smart Dent AI. تُقسم الواجهة إلى ثلاثة أقسام متكاملة: قائمة جانبية تعرض بطاقات المرضى مع إمكانية البحث والإضافة، وبطاقة تعريفية تفصيلية تعرض البيانات الأساسية والتاريخ الطبي والتنبيهات السريرية (كالحساسية الدوائية)، وخريطة أسنان تفاعلية وفق نظام التقييم العالمي FDI، حيث تُلوّن الأسنان وفق حالتها (سليم، متسوس، معالج) مع إحصاءات فورية، وتتيح النقر على أي سن لعرض تفاصيله وتعديل حالته، مما يمنح الطبيب رؤية شاملة وسريعة للحالة الصحية الفموية للمريض.

Smart Dent AI لوحة تحكم العيادة الذكية

الرئيسية بيانات المرضى خريطة الأسنان مسح الأشعة الذكي التقارير التسعير والتكاليف الموسوعة الطبية

محمد أحمد العلي

مسجل منذ 21-07-2026

الاسم الكامل: محمد أحمد العلي

العمر: 35 سنة

الجنس: ذكر

معلومات التواصل

الهاتف: 0991234567

البريد الإلكتروني: mohammed.ali@email.com

موقع: حماة - شارع الحافظ

التاريخ الطبي

سكري، نوع ثاني، ضغط دم مرتفع

تحذير: حساسية

خريطة أسنان: محمد أحمد العلي

سليم: 29 | تمسوخ: 1 | معالج: 1

اللون: المسمي

انقر على أي سن لمرض تفاصيله وتعديل حالته

قائمة المرضى (5)

محمد أحمد العلي 0991234567 35 سنة

فاطمة حسن السيد 0945678901 28 سنة

خالد محمود إبراهيم 0988345612 52 سنة

نور سامر الخطيب 0933221145 19 سنة

عبد الرحمن خير بك 0998765543 41 سنة


الشكل (4-6): شاشة إدارة بيانات المرضى في نظام Smart Dent AI.

3-7-4 شاشة خريطة الأسنان التفاعلية

تعتمد هذه الشاشة على نظام التقييم العالمي FDI، وتوفر واجهة متكاملة لإدارة حالة الأسنان وبيانات المريض، وتتضمن العناصر التالية:

- الشعار والعنوان: يظهر شعار Smart Dent AI مع اسم المنظومة، وأسفله عنوان العيادة (سوريا - حماة - ساحة العاصي).

- قائمة التنقل الرئيسية: تضم تبويبات النظام المختلفة، وتشمل: الرئيسية، بيانات المرضى، خريطة الأسنان (التبويب النشط)، مسح الأشعة الذكي، التقارير، التسعير والتكاليف، الموسوعة الطبية، بالإضافة إلى زر تبديل المظهر الليلي والنهاري.
- شريط بيانات المريض: يعرض معلومات المريض الحالية، متضمنة الاسم، العمر، الجنس، والتنبيهات الطبية المهمة، مع زر لتبديل المريض.
- خريطة الأسنان التفاعلية: تعرض الفكين العلوي والسفلي وفق نظام FDI، مع تلوين الأسنان حسب حالتها (سليم، متابعة، تسوس، حشو، مفقود)، وإبراز السن المحدد للتشخيص مع إمكانية اختيار أي سن.
- بطاقة تفاصيل السن المحدد: تعرض رقم وتسمية السن المختار، وتوفر أزرارًا لتحديث حالته السريرية، إلى جانب سجل العلاجات السابقة، وقسم لإضافة سجل علاجي جديد يتضمن بيانات التشخيص والعلاج.



الشكل (4-7): شاشة خريطة الأسنان التفاعلية بنظام الترقيم العالمي FDI.

4-7-4 شاشة تقرير التشخيص الذكي

هذه هي الشاشة الأكثر أهمية، حيث تعرض نتائج تحليل الصورة بواسطة الذكاء الاصطناعي:

- شريط الأدوات العلوي: عنوان "تقرير التشخيص الذكي" مع تاريخ التوليد، وأزرار "إخفاء التحديد"، و"تصدير PDF"، و"تحليل صورة أخرى".
- بطاقات التقييم السريع: ثلاثة مؤشرات (حالة الفم العامة، مؤشر نظافة الأسنان، مستوى التحليل) مع صندوق ملخص التشخيص الإكلينيكي المولد بالذكاء الاصطناعي.
- قسم المعاينة البصرية: يعرض الصورة الشعاعية مع تظليل المضلعات الملونة، وأدوات تحكم بالصورة (تكبير، تصغير، تدوير)، وخريطة أسنان مصغرة (MiniToothMap) تُظلل الأسنان المصابة بألوان الخطورة.
- قائمة المشاكل المرصودة: تعرض كل سن مصاب مع المشكلة والوصف، ونسبة دقة الذكاء الاصطناعي مع شريط تقدم، والتوصية العلاجية.
- إرشادات وقائية عامة: قائمة من التوصيات الموجهة للمريض.

الرئيسية

بيانات المرضى

خريطة الأسنان

مسح الأشعة الذكي

التقارير

التسعير والتكاليف

الموسوعة الطبية

Smart Dent AI

لوحدة تحكم العمادة الذكية

مورزا - جدة - ساحة العاصي - جانب الساعة

تحليل صورة أخرى

تصدير PDF

إلغاء التحديد

تقرير التشخيص الذكي

تاريخ: ٢٠٢١/٧/٢٢

مستوى التحليل

تشخيص أولي معتمد

مؤشر نظافة الأسنان

45

تراكم البلاك ومستوى الحماية

حالة الفم العامة

حرج

ملخص التشخيص الإكلينيكي:

تظهر الصورة البانورامية للأشعة السينية تدهوراً ملحوظاً في صحة اللثة والأسنان، حيث يلاحظ وجود العديد من بقايا الجذور المتراكمة في الفكين العلوي والسفلي للثة تسوس أسنان متقدم غير معالج، كما يظهر سن معالج عصبياً سابقاً (السن 36) مع وجود علامات التهاب حول ذروة الجذر (مضلل) علاج (مضلل)، بالإضافة إلى فقدان بعض الأسنان وتراجع في مستوى العظم الداعم.

خريطة الأسنان المصفاة

3 سن ضباب — اشعة على السن ليرافق على الصورة

28	27	26	25	24	23	22	21	11	12	13	14	15	16	17	18
38	37	36	35	34	33	32	31	48	47	46	45	44	43	42	41

دج

متوسطة

بسيط

سليم

اضغط على أي سن ضباب ليرافق منطقة بدقة على صورة الأشعة

تمت المزامنة تلقائياً

المشاكل المرصودة (3)

المصورة التحليلية

إعادة تعيين

100%

الشكل (4-8): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الأول.

☺
تمت المزامنة تلقائياً

المشاكل المرصودة (3)

درج

رقم 36

الرجى الأولى السفلية اليسرى

المشكلة: فشل علاج عصب والتهاب حول الذروة

يظهر السن معالجاً عصبياً سابقاً ومغطى بتاج، ولكن يوجد تراجع عظمي وظلالية شعاعية واضحة حول ذروة الجذور تشير إلى وجود التهاب مزمن أو فشل في العلاج السابق.

نسبة الدقة:
90% (ثقة عالية)

التوصية: مراجعة أخصائي علاج عصب لإعادة تقييم السن وإمكانية إعادة علاج القنوات السنية أو الجراحة المجهرية، وفي حال تعذر ذلك قد يتطلب الأمر الخلع والزراعة.

درج

رقم 17

الرجى الثانية العلوية اليمنى

المشكلة: بقايا جذور متأكلة

تسوس عميق جداً أدى إلى تدمير كامل للتاج السني وتحوله إلى بقايا جذور غير قابلة للإصلاح.

نسبة الدقة:
95% (ثقة عالية)

التوصية: ينصح بخلع بقايا الجذور لتفادي حدوث خراجات أو التهابات عظمية، ومن ثم منافشة خيارات التعويض مثل زراعة الأسنان.

درج

رقم 24

الضاحك الأول العلوي الأيسر

المشكلة: بقايا جذور متأكلة

فقدان كامل للتاج السني مع بقاء الجذور فقط داخل العظم نتيجة نخر متقدم.

نسبة الدقة:
90% (ثقة عالية)

الشكل (4-9): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الثاني.

إرشادات وتوجيهات وقائية عامة

- 1 زيارة طبيب الأسنان بشكل عاجل لوضع خطة علاجية شاملة تبدأ بخلع بقايا الجذور المتلتهبة.
- 2 إعادة تقييم الأسنان المعالجة عصبياً والتي تظهر علامات التهاب حول الذروة.
- 3 عمل تنظيف عميق للثة وعلاج التراجع العظمي للحفاظ على الأسنان المتبقية.
- 4 الاهتمام بالعناية الفموية اليومية باستخدام الفرشاة والمعجون المحتوي على الفلورايد وخط الأسنان الطبي.

الشكل (4-10): شاشة تقرير التشخيص الذكي لمسح الأشعة في نظام Smart Dent AI الجزء الثالث.

4-7-5 شاشة التقارير العلاجية

الشكل (4-11): شاشة التقارير العلاجية ومحرر التقرير الطبي.

تجمع هذه الشاشة بين سجل الجلسات العلاجية ومحرر التقرير الطبي:

- شريط التنقل العلوي: زرّي تحويل بين "سجل الجلسات" و"محرر التقرير".
- القسم الأيمن (سجل الجلسات): زر "+" جلسة جديدة"، وقوائم فلترة، وبطاقات الجلسات مع اسم المريض، والتشخيص، والسن المستهدف، والملاحظات، والطبيب، والتاريخ، والحالة، مع إبراز التنبيهات الدوائية.
- القسم الأيسر (محرر التقرير): نموذج معلومات المريض، وحقل الشكوى الرئيسية، ونموذج إضافة بنود التشخيص والعلاج لكل سن، وقسم معاينة التقرير الحي.

6-7-4 شاشة التسعير والتكاليف

Smart Dent AI

نوجة تحكم العيادة الذكية

سوريا - حماة - ساحة المعادي - جانب الساعة

الرئيسية

بيانات المرضى

خريطة الأسنان

مسح الأشعة الذكي

التقارير

التسعير والتكاليف

الموسوعة الطبية

إجمالي الإيرادات

٣٢٥,٠٠٠ ل.س

المحفوظ

٢١٠,٠٠٠ ل.س

المتأخر (غير مدفوع)

١١٥,٠٠٠ ل.س

أسعار وتكاليف التشخيصات (5)

كل المريض

كل الحالات


المريض	الوصف	الكمية	سعر الوحدة	الإجمالي	المدفوع	الحالة	إجراءات
محمد أحمد العلي	علاج عصب + حشوة تاجية (س 36) 2026-07-22	1	١٥٠,٠٠٠ ل.س	١٥٠,٠٠٠ ل.س	٨٠,٠٠٠ ل.س	مدفوع جزئياً	
فاطمة حسن السيد	تنظيف احترافي (أسنان 21, 11) 2026-07-22	2	٣٥,٠٠٠ ل.س	٧٠,٠٠٠ ل.س	٧٠,٠٠٠ ل.س	مدفوع	
خالد محمود إبراهيم	تنظيف عميق + مضاد حيوي (س 46) 2026-07-22	1	٤٥,٠٠٠ ل.س	٤٥,٠٠٠ ل.س	٠ ل.س	غير مدفوع	
نور سامر الخطيب	كشف وجلسة تقييم (س 18) 2026-07-22	1	١٠,٠٠٠ ل.س	١٠,٠٠٠ ل.س	١٠,٠٠٠ ل.س	مدفوع	
عبد الرحمن خير بك	تنظيف وتلميع (س 17, 16) 2026-07-21	2	٢٥,٠٠٠ ل.س	٥٠,٠٠٠ ل.س	٥٠,٠٠٠ ل.س	مدفوع	

الشكل (4-12): شاشة التسعير والتكاليف في نظام Smart Dent AI.

تُستخدم هذه الشاشة لإدارة الفواتير والإيرادات المالية:

- بطاقات المؤشرات المالية: ثلاث بطاقات (إجمالي الإيرادات، المحصل، المتأخر) مع تلوين مناسب (أخضر للإيرادات، أحمر للمتأخر).
- شريط الفلترة والإجراءات: زر "+" بند جديد" وقوائم فلترة حسب المريض وحالة الدفع.
- جدول أسعار وتكاليف التشخيصات: يعرض الفواتير مع أعمدة (المريض، الوصف والتاريخ، الكمية، سعر الوحدة، الإجمالي، المدفوع، الحالة، إجراءات)، مع تلوين الحالة (أخضر مدفوع، أصفر مدفوع جزئياً، أحمر غير مدفوع).

7-7-4 شاشة الموسوعة الطبية



الشكل (13-4): شاشة الموسوعة الطبية في نظام Smart Dent AI.

تُعد الموسوعة الطبية مرجعاً طبياً سريعاً:

- شريط البحث والتصفية: حقل بحث تفاعلي وأزرار فلترة سريعة (الكل، أمراض شائعة، أعراض، وقاية، علاجات).
- القائمة الجانبية (قائمة المقالات): بطاقات مصغرة لأمراض مثل تسوس الأسنان، والتهاب اللثة، والتهاب دواعم السن، وحساسية الأسنان، وخراج الأسنان، والعلاج بالفلورايد.
- القسم الأيسر (عرض المقال المختار): يعرض تفاصيل المرض بشكل منظم يشمل الاسم بالعربية والإنجليزية، ووصفاً تعريفياً، والأعراض، والأسباب، وخيارات العلاج والوقاية.

8-4 أداء النظام وتقييمه

1-8-4 زمن الاستجابة

تم قياس أداء النظام على جهاز مطّور نموذجي بمعالج Intel Core i5-1135G7 (الجيل الحادي عشر، 4 أنوية فيزيائية، 8 منطقية، تردد 2.40 GHz)، وذاكرة وصول عشوائي سعة 8 جيجابايت، مع تشغيل نموذج SAM على المعالج المركزي (CPU) دون استخدام معالج الرسومات (PyTorch CPU-only).

الجدول (4-1): أوقات الاستجابة المقاسة

العملية	الزمن المقاس	ملاحظات
تحميل نموذج SAM إلى الذاكرة	ثانية 1.6	مرة واحدة عند الإقلاع (Lazy Loading)
استدعاء Gemini 3.1 Pro API	ثانية 10-40	حسب تعقيد الصورة وطول التقرير
SAM: تشفير الصورة (set_image)	ثانية 18.7	أبطأ عملية، تُنفذ مرة لكل صورة
SAM: التنبؤ بالقناع (predict) لكل صندوق	> 1 ثانية	سريع جداً بعد set_image
استخراج المضلع (Polygon) من القناع	~10 ملي ثانية	باستخدام OpenCV
الزمن الكامل للتحليل (صورة بمرض واحد)	~58 ثانية	Gemini ~40s + SAM ~18s
الزمن الكامل (3 أمراض)	~60 ثانية	نفس تقريباً (set_image مرة واحدة)

التحسينات المطبقة لتقليل زمن الاستجابة:

- تنفيذ تشفير الصورة (set_image) مرة واحدة لكل صورة بدلاً من مرة لكل مرض، مما

حقق توفيراً في الوقت بنسبة 60%.

- تصغير الصورة إلى حد أقصى 1024 بكسل قبل التشفير، مما يقلل وقت المعالجة بشكل ملحوظ مع فقدان ضئيل في الدقة.
- استخدام إعداد `multimask_output=False` لتوليد قناع واحد فقط لكل صندوق بدلاً من ثلاثة، مما يسرع العملية ويقلل استهلاك الذاكرة.
- تحميل النموذج كسولاً (Lazy Loading) بحيث يُحمّل فقط عند أول طلب، مع استخدام آليات (`threading.Lock`) لمنع التحميل المتزامن.

2-8-4 دقة التجزئة

تم قياس دقة التجزئة باستخدام مقياس IoU (Intersection over Union)، وهو مقياس هندسي يحدد مدى تطابق القناع المُنتج مع المنطقة المصابة الفعلية. كلما اقتربت القيمة من 1، كانت الدقة أعلى.

الجدول (4-2): النتائج المقاسة على صور اختبار متنوعة

الصورة	عدد نقاط المضلع	درجة IoU
صورة تسوس (سن 11)	12 نقطة	0.815
صورة متعددة الأمراض	10 نقاط	0.909
صورة متعددة الأمراض	7 نقاط	0.939
صورة متعددة الأمراض	10 نقاط	0.925
صورة متعددة الأمراض	8 نقاط	0.843

متوسط الدقة الإجمالي: ~0.89 (89%)، وهو مستوى ممتاز يشير إلى أن المضلع الناتج يطابق المنطقة المصابة بدقة عالية. يُظهر هذا أن نموذج SAM يحدد حدود المنطقة المصابة بدقة تشريحية عالية، مما يمنح الطبيب ثقة أكبر في نتائج التقرير التشخيصي.

3-8-4 مقارنة بين النموذج المحلي والنماذج السحابية

الجدول (4-3): مقارنة بين النموذج المحلي والنماذج السحابية

المعيار	النموذج المحلي (SAM)	النماذج السحابية متعددة الوسائط
نوع المخرجات	قناع دقيق على مستوى البكسل	وصف نصي أو صندوق تقريبي
دقة التحديد	مضلع يلتصق بحدود المرض (IoU) ~0.89	تقريبي (صندوق إحاطة)
خصوصية البيانات	صور المرضى تبقى على الجهاز	تُرسل الصور إلى خوادم خارجية
زمن الاستجابة	18.7 ثانية (تشفير) < 1 + ثانية (تنبؤ)	يعتمد على جودة الاتصال وسرعة الخادم
التكلفة	مجاني (مفتوح المصدر)	يعتمد على استخدام API (مدفوع عادة)
الاعتماد على الإنترنت	لا حاجة للإنترنت بعد تحميل النموذج	يتطلب اتصالاً مستقرًا بالإنترنت

4-8-4 مناقشة النتائج

تُظهر النتائج أن النظام يحقق توازناً جيداً بين الدقة والسرعة في بيئة التشغيل الحالية. على الرغم من أن زمن التحليل الكامل (حوالي 58 ثانية) قد يبدو طويلاً مقارنةً بأنظمة الكشف التقليدية (التي تعمل بأقل من ثانية)، إلا أنه يُعَوَّض بالمزايا التالية:

- دقة تشخيصية أعلى: النموذج اللغوي الرئوي (Gemini 3.1 Pro) يفهم السياق السريري ويولد تقارير نصية مفصلة باللغة العربية، بدلاً من مجرد أسماء أمراض ونسب ثقة.

- دقة مكانية فائقة: نموذج SAM ينتج مزلعات دقيقة على مستوى البكسل (متوسط IoU 89%) بدلاً من الصناديق التقريبية، مما يمنح الطبيب رؤية تشريحية دقيقة للمنطقة المصابة.
- مرونة لا مثيل لها: يمكن إضافة أمراض جديدة دون إعادة تدريب النموذج، وذلك ببساطة عبر تعديل التعليمات الموجهة (Prompts) المقدمة للنموذج اللغوي.
- خصوصية البيانات: يتم إجراء التجزئة محلياً على جهاز الخادم، مما يعني أن صور المرضى لا تُرسل إلى خوادم خارجية، وهو أمر بالغ الأهمية في التطبيقات الطبية التي تتطلب حماية البيانات الصحية.
- عنق الزجاجة الرئيسي هو عملية تشفير الصورة في SAM (set_image) والتي تستغرق 18.7 ثانية على المعالج المركزي. يمكن تحسينها بشكل كبير (إلى حوالي 1-2 ثانية) عن طريق:
- تفعيل دعم معالج الرسومات (GPU) على جهاز الخادم باستخدام PyTorch مع CUDA.
- استخدام تقنيات تسريع مثل ONNX Runtime التي قد تحسن الأداء على المعالج المركزي بمقدار 2-3 مرات.
- الاستفادة من التخزين المؤقت (Caching) للصور المتكررة لتخطي مرحلة التشفير.

5-8-4 دراسة مقارنة: أداء أنظمة الكشف التقليدية (YOLO) مقابل النهج المُقترح

(VLM + SAM)


لتوضيح الفجوة بين الأنظمة التقليدية والنهج المُقترح في هذا المشروع، تم تنفيذ تجربة مقارنة باستخدام نموذج YOLOv8 المدرب على مجموعة بيانات مخصصة للأمراض السنية الأربعة المستهدفة (نخر الأسنان، فقدان العظم السنخي، التهاب الآفة حول الذروية، والكسور السنية). تهدف هذه المقارنة إلى إبراز مزايا النهج الجديد القائم على النماذج اللغوية الرؤية والتجزئة الدقيقة من حيث المرونة، والدقة المكانية، وقابلية التوسع.

4-5-8-1 تدريب نموذج YOLO

تمثل مرحلة تدريب النموذج الخطوة الأساسية في تمكين النظام من التعرف على الأنماط المرضية في صور الأسنان. في هذه التجربة، تم استخدام نموذج YOLOv8 المدرب مسبقاً (Pretrained Model) على مجموعة بيانات COCO، ومن ثم إعادة تدريبه (Fine-Tuning) باستخدام مجموعة بيانات خاصة بالمشروع تحتوي على 1800 صورة موزعة على أربع فئات (500 صورة لنخر الأسنان، 450 لفقدان العظم السنخي، 430 لالتهاب الآفة حول الذروية، و420 للكسور السنية)، مع تقسيمها بنسبة 70% تدريب، 20% تحقق، و10% اختبار.

تم تنفيذ عملية التدريب باستخدام بيئة Google Colab مع دعم معالجة الرسومات (GPU)، وتم تمرير البيانات عبر النموذج على 100 دورة تدريبية (Epoch) مع حجم دفعة (Batch Size) مقداره 16. اعتمدت عملية التدريب على مقاييس تقييم الأداء القياسية لنماذج الكشف

عن الكائنات، وهي: الدقة (Precision)، والاستدعاء (Recall)، ومتوسط الدقة المتوسطة (mAP) عند عتبات تداخل (IoU) مختلفة.



الشكل (4-14): نتائج تدريب نموذج YOLOv8 باستخدام Google Colab.

4-5-8-2 نتائج أداء نموذج YOLO

يُظهر الجدول (4-4) مؤشرات الأداء العامة لنموذج YOLOv8 على مجموعة الاختبار:

الجدول (4-4): مؤشرات الأداء العامة لنموذج YOLOv8 على مجموعة بيانات الأشعة السينية الفموية.

المقياس العلمي (Metric)	القيمة المحققة (Value)	التفسير الأكاديمي
الدقة (Precision)	92.40%	نسبة الحالات التي صنفها النموذج كإصابة وكانت صحيحة فعلياً، مما يعكس انخفاض معدل الإيجابيات الكاذبة
الاستدعاء (Recall)	89.70%	قدرة النموذج على اكتشاف جميع الإصابات الموجودة في الصور وتقليل الحالات التي لم يتم التعرف عليها
mAP@0.5	93.10%	متوسط الدقة عند عتبة تداخل (IoU = 0.5)، ويُعد المؤشر الرئيسي لتقييم كفاءة نموذج الكشف عن الإصابات
mAP@0.5:0.95	74.80%	متوسط الدقة عبر مجموعة من عتبات التداخل (IoU = 0.5–0.95)، ويقيس دقة تحديد مواقع الإصابات وصناديق الإحاطة في ظروف تقييم أكثر صرامة


تُظهر النتائج تفوقاً ملحوظاً لنموذج YOLOv8 في التحديد الموضعي السريع لآفات السنية، حيث سجل دقة عامة بلغت 92.4% ومتوسط دقة mAP@0.5 بلغ 93.1%. ويُعزى هذا الأداء المرتفع إلى قدرة الشبكة التلافيفية العميقة على استخلاص الميزات الدقيقة من صور الأشعة، مما يثبت جاهزية النماذج التقليدية لدعم القرار الطبي في البيئات التي تتطلب سرعة فائقة واستجابة فورية [31]، [32]، [33].

4-5-8-3 تحليل دقة الكشف بحسب الصنف المرضي

يوضح الجدول (4-5) قدرة نموذج YOLOv8 على التمييز بين الحالات المرضية المختلفة:

الجدول (4-5): تحليل دقة الكشف (mAP@0.5، الاستدعاء، والدقة) بحسب الصنف المرضي لنموذج YOLOv8.

الصنف المرضي (Class) (Name)	الدقة (Precision)	الاستدعاء (Recall)	قيمة mAP@0.5
نخر الأسنان (Dental Caries)	94.20%	91.50%	94.80%
فقدان العظم السنخي (Bone Loss)	91.00%	88.40%	91.20%
التهاب الافة حول الذروية (Periapical Lesion)	89.50%	86.20%	88.90%
الكسور السنية (Tooth) (Fractures)	95.10%	92.70%	95.60%



الشكل (4-15): منحنى الدقة مقابل الاستدعاء (Precision-Recall Curve) لنموذج YOLOv8 المقترح للأصناف المرضية الأربعة.

يُظهر الشكل (4-15) بقاء قيم الدقة (Precision) قريبة من الواحد الصحيح (1.0) حتى مع وصول معدلات الاستدعاء (Recall) إلى عتبات متقدمة تتجاوز 0.8 لجميع الأصناف المرضية. ويتصدر صنف الكسور السنية المنحنى بأكبر مساحة تحت المنحنى (AUC)، يليه صنف نخر الأسنان، وهو ما يؤكد فيزيائياً سهولة كشف التباينات الحادة للحواف الخطية في الكسور والفراغات الإشعاعية الشفافة للنخر مقارنة بالتغيرات العظمية الضبابية [33].

4-5-8-4 مقارنة بين نموذج YOLO والنهج المُقترح (VLM + SAM)

يوضح الجدول (4-6) المقارنة التقنية والأدائية بين النهجين:

الجدول (4-6): المقارنة التقنية والأدائية بين نموذج YOLOv8 المحلي والنهج المُقترح (VLM + SAM).

المعيار	نموذج YOLOv8 المحلي	النهج المُقترح (VLM + SAM)
نوع المخرجات	أسماء أمراض + صناديق إحاطة تقريبية	تقرير تشخيصي نصي مفصل بالعربية + مضلعات دقيقة
دقة التحديد	صندوق إحاطة (Bounding Box) تقريبي	مضلع (Polygon) على مستوى البكسل (IoU ~89%)
المرونة	محدودة بالأمراض المدربة عليها (4 أمراض)	تفهم سياقياً أي مرض تقريباً
التوسع	يحتاج إعادة تدريب كامل لإضافة أمراض جديدة	يمكن إضافة أمراض جديدة عبر تعديل ال Prompt فقط
التدريب	يتطلب بيانات موسومة لكل مرض	تدريب مسبق على ملايين الصور والنصوص (Zero-shot)
التكامل مع اللغة العربية	محدود (يخرج أسماء فقط)	يولد تقارير كاملة بالعربية
زمن الاستجابة	سريع جداً (>1 ثانية)	أبطأ (5-40 ثانية لل SAM + 18.7 ثانية ل VLM)
خصوصية البيانات	الصور تبقى على الجهاز	التجزئة محلياً، التحليل السحابي ل VLM
التكلفة الحسابية	منخفضة (تعمل على CPU/GPU متوسط)	متوسطة (تعتمد على خوادم سحابية لل VLM + SAM محلي)

4-5-8-5 مناقشة النتائج المقارنة

يشير الأداء العام لنموذج YOLOv8 إلى تحقيق توازن فعال بين الدقة والاستدعاء، حيث تبلغ الدقة 92.4% والاستدعاء 89.7%. ومع ذلك، فإن الانخفاض النسبي في قيمة $mAP@0.5:0.95$ (74.8%) مقارنةً بـ $mAP@0.5$ (93.1%) يعكس التحدي الكامن في التحديد الدقيق لحدود صناديق الإحاطة على مستوى البكسل في صور الأشعة السنية

البانورامية [33]. يعود ذلك إلى تداخل الكثافات العظمية والنسيجية، وتداخل الأسنان المجاورة، وعدم وضوح الحواف بسبب الإسقاط ثنائي الأبعاد للتراكيب ثلاثية الأبعاد.

من ناحية أخرى، يُظهر التحليل بحسب الصنف المرضي أن النموذج حقق أعلى أداء في الكشف عن الكسور السنّية ($mAP = 95.6\%$) ونخر الأسنان ($mAP = 94.8\%$)، بينما سجل أداءً أقل في الكشف عن التهاب دواعم السن ($mAP = 88.9\%$) وفقدان العظم السنخي ($mAP = 91.2\%$). ويعود هذا التراجع إلى صعوبة التمييز بين التغيرات العظمية الدقيقة الناتجة عن الالتهاب والتراكيب العظمية الطبيعية [5]، [8]، [9]، [10].

تُظهر هذه المقارنة بوضوح الفجوة بين النهجين: فبينما يتفوق YOLO في سرعة المعالجة الفائقة (زمن استجابة شبه منعدم)، فإن النهج المُقترح (VLM + SAM) يقدم مزايا نوعية لا يمكن تجاهلها: فهم سياقي للصور عبر النماذج اللغوية الرؤية التي تولد تقارير تشخيصية مفصلة بالعربية، ودقة مكانية فائقة عبر نموذج SAM الذي ينتج مضلعات دقيقة على مستوى البكسل [41]، [42]، ومرونة لا مثيل لها في إضافة أمراض جديدة دون إعادة تدريب النماذج، بالإضافة إلى التكامل مع اللغة العربية والتقارير الشاملة التي تشمل وصفاً تفصيلياً وتوصيات علاجية [36]. هذا يبرر اختيار النهج المُقترح في هذا المشروع، رغم أن زمن الاستجابة أطول، حيث أن المزايا النوعية تفوق بكثير سرعة الكشف التقليدية.

الفصل الخامس: الخاتمة

والآفاق المستقبلية

1-5 الخاتمة

تناول هذا المشروع تصميم وتنفيذ منصة ويب تشخيصية ذكية تعتمد على أحدث تقنيات الذكاء الاصطناعي والرؤية الحاسوبية للمساعدة في تشخيص أمراض الفم والأسنان من خلال تحليل الصور الرقمية (السريية والشعاعية). وقد تجاوز المشروع حدود الأنظمة التقليدية القائمة على الكشف عن الأجسام (Object Detection) باستخدام الصناديق التقريبية، ليقدم منصة تشخيصية متكاملة تجمع بين الفهم السياقي للصور عبر النماذج اللغوية الرؤية والدقة المكانية الفائقة عبر نماذج التجزئة الدقيقة.

اعتمد النظام على النموذج اللغوي الرؤية Gemini 3.1 Pro كقلب ذكي للتحليل، حيث يقوم بفهم الصورة سياقياً وتوليد تقرير تشخيصي أولي باللغة العربية على هيئة JSON منظم، يتضمن وصفاً دقيقاً للحالات المرضية المكتشفة، وتحديد مواقعها باستخدام نظام الترقيم العالمي (FDI)، وتقديم توصيات علاجية مناسبة لكل حالة، مع درجة ثقة تعكس مدى موثوقية التشخيص. وقد تم تصميم التعليمات الموجهة (Prompts) بدقة لضمان الحصول على مخرجات موثوقة، مع تطبيق تحيز سلبي يمنع النموذج من التبليغ عن حالات غير مؤكدة، مما يقلل من الإيجابيات الكاذبة.

ولتجاوز قيود الصناديق الإحاطة التقريبية، تم دمج نموذج التجزئة الدقيقة SAM (Segment Anything Model) من Meta، والذي يعمل محلياً على جهاز الخادم لتحويل الصناديق التقريبية إلى مضلعات (Polygons) دقيقة على مستوى البكسل، تحدد حدود المنطقة المصابة بدقة تشريحية عالية. وقد حقق النموذج متوسط دقة تجزئة (IoU) بلغ 89% على

صور الاختبار، مما يمنح الطبيب رؤية دقيقة للمنطقة المصابة ويساعد في التخطيط العلاجي الدقيق. وتم اختيار الإصدار ViT-B من النموذج (93.74 مليون معامل، 358 ميغابايت) لتحقيق توازن مثالي بين الدقة والسرعة على الأجهزة المتوسطة.

ولتعزيز الجانب التفاعلي وإدارة البيانات بشكل شامل، تم تطوير منصة ويب متكاملة تعتمد على بنية تطبيق صفحة واحدة (SPA) تفصل بين الواجهة الأمامية والخادم الخلفي، طوّرت الواجهة الأمامية باستخدام React 19 و TypeScript مع Tailwind CSS v4، وتضم سبع شاشات رئيسية تغطي جميع جوانب إدارة العيادة الذكية: لوحة التحكم، وإدارة المرضى، وخريطة الأسنان التفاعلية (بنظام FDI)، وتقرير التشخيص الذكي، والتقارير العلاجية، والتسعير والتكاليف، والموسوعة الطبية. كما تم تطوير الخادم الخلفي باستخدام Flask (Python 3.11) لإدارة مسارات API، ومعالجة الصور، واستدعاء النماذج السحابية (Gemini و Kimi)، وتشغيل SAM محلياً، والتفاعل مع قاعدة البيانات.

كما تم اعتماد قاعدة بيانات SQLite لإدارة سجلات المرضى، والفحوصات، والاكتشافات المرضية، وتقييمات الأطباء، والموسوعة الطبية، في خمسة جداول مترابطة بعلاقات تضمن سلامة البيانات وسهولة استرجاعها. ويتيح هذا التصميم تتبع الحالات الصحية للمرضى، ومقارنة النتائج عبر الزمن، وتوثيق التدخلات العلاجية بشكل منظم.

أثبتت النتائج العملية أن الدمج بين النماذج اللغوية الرؤية السحابية (لفهم السياق وتوليد التقارير) و نماذج التجزئة المحلية (للدقة المكانية) في منصة ويب تفاعلية يوفر نظاماً متكاملًا يتفوق على الأنظمة التقليدية في عدة جوانب: دقة تشخيصية أعلى بفضل الفهم السياقي للصور،

ودقة مكانية فائقة بفضل التجزئة على مستوى البكسل، ومرونة لا مثيل لها في إضافة أمراض جديدة دون إعادة تدريب النماذج (عبر تعديل التعليمات فقط)، وخصوصية محسنة للبيانات الطبية من خلال إجراء التجزئة محلياً، وتجربة مستخدم شاملة عبر سبع شاشات متكاملة مع خريطة أسنان تفاعلية ووضع داكن.

وبناءً على ما سبق، يمكن القول إن المشروع نجح في تحقيق أهدافه الأساسية من خلال بناء منصة تشخيصية ذكية متكاملة قادرة على تحليل صور الفم والأسنان، واكتشاف الأمراض بصورة آلية مع تحديد دقيق للمناطق المصابة، وتوليد تقارير تشخيصية مفصلة باللغة العربية، وتقديم توصيات علاجية مناسبة، مع توفير واجهة استخدام تفاعلية وسهلة، وإدارة شاملة لبيانات المرضى والفحوصات، مما يؤكد إمكانية الاستفادة من تقنيات الذكاء الاصطناعي المتقدمة في دعم التشخيص الطبي وتحسين جودة الخدمات الصحية الرقمية، مع التأكيد أن التشخيص النهائي يبقى من اختصاص طبيب الأسنان المختص.

5-2 الآفاق المستقبلية

يمثل المشروع خطوة أولى نحو تطوير أنظمة أكثر ذكاءً في مجال تشخيص أمراض الفم والأسنان، ويمكن توسيعه مستقبلاً من خلال عدد من المقترحات التي تزيد من كفاءته وإمكاناته، ومن أهمها:

أولاً: توسيع قاعدة البيانات وتحسين دقة النماذج

- توسيع قاعدة البيانات لتشمل عدداً أكبر من الأمراض الفموية (مثل الآفات السرطانية المبكرة، واضطرابات المفصل الفكي الصدغي، وأمراض الغشاء المخاطي للفم)، وصوراً ملتقطة في ظروف وإضاءات وزوايا مختلفة، مما يزيد من قدرة النموذج اللغوي الرؤيوي على التعميم وفهم التنوع السريري.
- إثراء مجموعة التدريب بعينات إضافية متنوعة من الحالات التي قد يواجهها النموذج صعوبة في تشخيصها، مثل حالات فقدان العظم السنخي والتهاب الآفة حول الذروية، وتطبيق تقنيات تعزيز البيانات (Data Augmentation) المتخصصة في التركيبات العظمية، مثل الإزاحات والدورانات الدقيقة وتغييرات التباين الموضعية.
- تحسين دقة التجزئة من خلال استكشاف إصدارات أكبر من SAM (مثل ViT-L و ViT-H) مع تحسين البنية التحتية للأجهزة (GPU) لاستيعاب حجمها الأكبر، أو استخدام نماذج تجزئة مدربة خصيصاً على الصور السنية.

ثانياً: التوسع في أنواع الصور المدعومة

- دعم الصور الشعاعية المتقدمة مثل صور Panoramic X-ray و CBCT (الصور المقطعية المحوسبة المخروطية) إلى جانب الصور الفوتوغرافية، بما يسمح بالكشف عن أمراض يصعب ملاحظتها بالعين المجردة، مثل الكسور الجذرية الدقيقة، والأكياس السنية العميقة، والأورام الفكية المبكرة.
- دعم الصور ثلاثية الأبعاد لتمكين التحليل الحجمي للأمراض وتقييم مدى انتشارها في الأبعاد الثلاثة، مما يساعد في التخطيط الجراحي الدقيق.

ثالثاً: تحسين الأداء والموثوقية

- تسريع زمن الاستجابة من خلال تفعيل دعم معالج الرسومات (GPU) مع PyTorch
- CUDA لتسريع عملية تشفير الصورة في SAM من ~18.7 ثانية إلى ~1-2 ثانية، أو استخدام ONNX Runtime لتسريع التشغيل على المعالج المركزي بمقدار 2-3 مرات.
- تطبيق آليات التخزين المؤقت (Caching) للصور المتكررة لتخطي مرحلة تشفير الصورة في SAM عند إعادة تحليل نفس الصورة.
- تحسين موثوقية النموذج اللغوي من خلال تطبيق تقنية الاسترجاع المعزز بالتوليد (RAG) التي تربط النموذج بقواعد بيانات طبية موثوقة لاسترجاع المعلومات قبل توليد الإجابة، مما يقلل من ظاهرة الهلوسة (Hallucination) ويزيد من دقة التوصيات.

رابعاً: التوسع في الميزات والوظائف

- تطوير تطبيق للهواتف الذكية يعمل على نظامي Android و iOS لتمكين المستخدمين من إجراء الفحص الأولي بسهولة باستخدام كاميرا الهاتف، مع إمكانية مشاركة النتائج مع الطبيب عن بُعد.
- إضافة نظام متابعة للحالات المرضية يسمح بحفظ نتائج الفحوص السابقة ومقارنتها مع الفحوص اللاحقة لمراقبة تطور الحالة الصحية، مع رسوم بيانية توضيحية لتتبع التحسن أو التدهور.

- ربط النظام بالسجلات الطبية الإلكترونية (EMR/EHR) لتسهيل مشاركة نتائج الفحص مع أطباء الأسنان وتوثيق البيانات بصورة آمنة، مع الالتزام بمعايير حماية البيانات الصحية مثل HIPAA.
- دعم اللغات المختلفة وإتاحة واجهة استخدام متعددة اللغات (الإنجليزية، الفرنسية، وغيرها) لتوسيع إمكانية استخدام النظام في بيئات صحية متنوعة حول العالم.
- تطوير مساعد طبي ذكي يعتمد على النماذج اللغوية الكبيرة للإجابة عن استفسارات المرضى، وشرح طرق الوقاية، وتقديم معلومات صحية موثوقة بناءً على نتائج الفحص، مع إمكانية جدولة المواعيد وتذكير المرضى.

خامساً: التوسع في البنية التحتية والنشر

- دمج النظام مع الحوسبة السحابية بما يسمح بإجراء عمليات التحليل على خوادم عالية الأداء مع إمكانية التوسع الأفقي (Horizontal Scaling) لاستيعاب عدد أكبر من المستخدمين، وتقليل متطلبات الأجهزة المحلية، وتسريع عملية التشخيص.
- نشر النظام كنموذج خدمة (SaaS) لتوفير المنصة للعيادات والمراكز الطبية كخدمة اشتراكية، مع إمكانية تخصيصها حسب احتياجات كل عيادة.
- الاستفادة من تقنيات التعلم المستمر (Continual Learning) لتحديث النموذج اللغوي دورياً عند توفر بيانات جديدة، بما يحافظ على دقة النظام مع مرور الوقت دون الحاجة إلى إعادة تدريب كاملة.

- إضافة نظام توثيق متقدم للمستخدمين (Authentication & Authorization) مع أدوار مختلفة (طبيب، موظف استقبال، مريض) للتحكم في صلاحيات الوصول إلى البيانات الطبية الحساسة.

سادساً: التكامل مع تقنيات متقدمة

- دمج تقنيات الواقع المعزز (AR) لعرض نتائج التجزئة مباشرة على صورة المريض الحقيقية عبر كاميرا الهاتف أو النظارات الذكية، مما يساعد في التخطيط العلاجي.
- استخدام النماذج متعددة الوسائط (Multimodal Models) التي تجمع بين الصور، والتاريخ الطبي للمريض، والبيانات الجينية لتقديم تشخيص أكثر شمولية ودقة.
- تطبيق تقنيات الذكاء الاصطناعي القابل للتفسير (XAI) لتوليد خرائط حرارية (Heatmaps) توضح المناطق التي اعتمد عليها النموذج في قراره، مما يزيد من ثقة الأطباء في نتائج النظام ويساعد في تدريب الأطباء المبتدئين.

تشير هذه الآفاق المستقبلية إلى أن المشروع يمتلك قابلية كبيرة للتطوير والتوسع في عدة اتجاهات متكاملة، ويمكن أن يشكل أساساً لبناء منصات ذكية متكاملة تدعم أطباء الأسنان والمرضى على حد سواء، وتساهم في تعزيز التشخيص المبكر، وتحسين جودة الرعاية الصحية الرقمية، وتقليل الأعباء على الأنظمة الصحية، مع الحفاظ على الدور المحوري للطبيب في اتخاذ القرار العلاجي النهائي. كما يفتح المشروع الباب أمام تطبيقات أوسع في مجالات الطب عن بُعد (Telemedicine)، والتعليم الطبي، والبحث العلمي في مجال الذكاء الاصطناعي الطبي.

References:

- [1] Goswami, M., Maheshwari, M., Baruah, P. D., Singh, A., & Gupta, R. (2021). Automated detection of oral cancer and dental caries using convolutional neural network. In 2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM) (pp. 2450–2457). IEEE. <https://ieeexplore.ieee.org/document/9596537>
- [2] Anil, S., Sudeep, K., Saratchandran, S., & Sweetey, V. K. (2023). Revolutionizing Dental Caries Diagnosis through Artificial Intelligence. In A. C. R. Chibinski (Ed.), *Dental Caries Perspectives – A Collection of Thoughtful Essays*. IntechOpen. <https://doi.org/10.5772/intechopen.112979>
- [3] Lee, J. H., Kim, D. H., Jeong, S. N., & Choi, S. H. (2021). Detection and diagnosis of dental caries and periapical lesions using deep learning: A systematic review. *Journal of Dental Research*, *100*(4), 396–403. <https://doi.org/10.1177/0022034520975176>
- [4] Waris, A., Khan, A. U., & Khan, S. (2022). Oral cancer detection using deep learning with ResNet 50. *Oral Oncology*, *128*, 105850. <https://doi.org/10.1016/j.oraloncology.2022.105850>
- [5] Le, V. N. T., Oh, I.-S., Kang, J., Kim, J.-G., Lee, D.-W., & Lee, D.-W. (2022). Effectiveness of human–artificial intelligence collaboration in cephalometric landmark detection. *Journal of Personalized Medicine*, *12*(3), 387. <https://doi.org/10.3390/jpm12030387>
- [6] Thurzo, A., Urbanová, W., Novák, B., Czako, L., Siebert, T., Stano, P., et al. (2022). Where is the artificial intelligence applied in dentistry? A systematic review and literature analysis. *Healthcare*, *10*(7), 1269. <https://doi.org/10.3390/healthcare10071269>
- [7] Junaid, N., Khan, N., Ahmed, N., Abbasi, M. S., Das, G., Maqsood, A., et al. (2022). Development, application, and performance of artificial intelligence in cephalometric landmark identification and diagnosis: A systematic review. *Healthcare*, *10*(12), 2454. <https://doi.org/10.3390/healthcare10122454>
- [8] Sarwar, S., & Jabin, S. (2023). AI techniques for cone beam computed tomography in dentistry: Trends and practices. *arXiv*. <https://doi.org/10.48550/arXiv.2306.03025>

- [9] Zaheer, R., Shafique, H. Z., Khalid, Z., Shahid, R., Jan, A., Zahoor, T., et al. (2024). Comparison of semi and fully automated artificial intelligence-driven software and manual system for cephalometric analysis. *BMC Medical Informatics and Decision Making*, *24*, 271.
- [10] Ma, L., Han, J., Wang, Z., & Zhang, D. (2023). CephGPT-4: An interactive multimodal cephalometric measurement and diagnostic system with visual large language model. *arXiv*. <https://arxiv.org/abs/2307.07518>
- [11] Lee, J. S., Adhikari, S., & Lee, S. (2025). Opportunistic osteoporosis screening using deep learning on panoramic radiographs: A systematic review and meta-analysis. *Journal of Bone and Mineral Research*, *40*(3), 345–355. <https://doi.org/10.1093/jbmr/zjae001>
- [12] Demir, Ö., Ağa ayak, K. S., & Alaca, M. A. (2025). Artificial intelligence-based dental implant identification: A narrative review of panoramic and CBCT imaging studies (2020–2025). *Dicle Dental Journal*, *26*(4), 77–87.
- [13] Sukegawa, S., Nakano, K., Kanno, T., & Furuki, Y. (2023). Deep learning for dental implant classification in panoramic radiographs. *Scientific Reports*, *13*(1), 12345. <https://doi.org/10.1038/s41598-023-39456-7>
- [14] Alshahrani, A. S., Alqahtani, A. S., & Alshammari, F. A. (2026). Use of artificial intelligence in diagnosing vertical root fractures: A systematic review. *Diagnostics*, *16*(3), 406.
- [15] Wang, Y.-C. C., Chen, T.-L., Vinayahalingam, S., Wu, T.-H., Chang, C. W., Chang, H. H., et al. (2025). Artificial intelligence to assess dental findings from panoramic radiographs: A multinational study. *Radiology: Artificial Intelligence*, *7*(2), e240123. <https://doi.org/10.1148/ryai.240123>
- [16] Turosz, N., Chęcińska, K., Chęciński, M., & Sikora, M. (2025). Evaluation of dental panoramic radiographs by artificial intelligence compared to human reference: A diagnostic accuracy study. *Diagnostics*, *15*(1), 45. <https://doi.org/10.3390/diagnostics15010045>
- [17] Wu, P. Y., Chen, Y. H., & Lin, C. H. (2025). Automated implant placement pathway from dental panoramic radiographs using artificial intelligence. *Diagnostics*, *15*(20), 2598. <https://doi.org/10.3390/diagnostics15202598>
- [18] Dua, B., Gupta, R., & Sharma, P. (2025). Explainable AI for panoramic dental radiographs using contrastive learning and U-Net segmentation. *Journal of Soft Computing Paradigm*, *7*(2), 114–123.

- [19] Hao, J., Fan, Y., Sun, Y., Guo, K., Lin, L., Yang, J., et al. (2025). Towards Better Dental AI: A multimodal benchmark and instruction dataset for panoramic X-ray analysis. arXiv.
- [20] Al Ali, A., Al Sarraf, A., & Al Shammari, F. (2024). Generative adversarial networks for smile design in esthetic dentistry: A proof of concept study. *Journal of Esthetic and Restorative Dentistry*, *36*(2), 215–224. <https://doi.org/10.1111/jerd.13145>
- [21] Goodfellow, I., Bengio, Y., & Courville, A. (2023). *Deep Learning for Neural Networks: Modern Concepts and Applications*. MIT Press.
- [22] Aggarwal, C. C. (2023). *Neural Networks and Deep Learning: A Textbook (2nd ed.)*. Springer.
- [23] Khan, S., Rahmani, H., Shah, S. A. A., & Bennamoun, M. (2023). *A Guide to Convolutional Neural Networks for Computer Vision*. Springer.
- [24] Zhou, Z.-H. (2023). *Machine Learning*. Springer. <https://doi.org/10.1007/978-981-99-6644-6>
- [25] Yamashita, R., Nishio, M., Do, R. K. G., & Togashi, K. (2023). Convolutional neural networks: An overview and application in medical image analysis. *Insights into Imaging*, *14*, 152.
- [26] Chartrand, G., Cheng, P. M., Vorontsov, E., Drozdal, M., Turcotte, S., Pal, C. J., Kadoury, S., & Tang, A. (2023). Deep learning: A primer for radiologists. *RadioGraphics*, *43*(2), e220122.
- [27] Ismail Fawaz, H., Forestier, G., Weber, J., Idoumghar, L., & Muller, P. A. (2024). Deep learning for time series and image classification: State of the art and recent advances. *Information Fusion*, *102*, 102067.
- [28] Sarker, I. H. (2024). *Deep Learning: A Comprehensive Overview on Techniques, Taxonomy, Applications and Research Directions*. SN Computer Science, *5*, 218.
- [29] Alzubaidi, L., Zhang, J., Humaidi, A. J., et al. (2024). Review of deep learning: Concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*, *11*, 32.
- [30] Liu, H., Li, X., Zhang, Y., & Wang, S. (2025). Artificial intelligence for medical image compression and intelligent healthcare imaging: A review. *IEEE Access*, *13*, 28741–28763.

- [31] Jocher, G., Chaurasia, A., & Qiu, J. (2024). YOLOv11: Real-time object detection. Ultralytics. <https://docs.ultralytics.com>
- [32] Zhao, Z.-Q., Zheng, P., Xu, S.-T., & Wu, X. (2023). Object detection with deep learning: A review. *IEEE Transactions on Neural Networks and Learning Systems*, *34*(2), 1–24.
- [33] Terven, J., & Cordova-Esparza, D. (2023). A comprehensive review of YOLO object detection algorithms. *Applied Sciences*, *13*(6), 3767. <https://doi.org/10.3390/app13063767>
- [34] Raiaan, M. A. K., Mukta, M. S. H., Fatema, K., Fahad, M. A. A., et al. (2024). A review on large language models: Architectures, applications, taxonomies, open issues and challenges. *IEEE Access*, *12*, 26839–26874. <https://doi.org/10.1109/ACCESS.2024.3365742>
- [35] Mienye, I. D., & Swart, T. G. (2025). Large language models: An overview of foundational models, architecture, training methodologies, applications, and challenges. *SN Applied Sciences*, *7*, Article 76.
- [36] Cascella, M., Semeraro, F., Montomoli, J., Bellini, V., Piazza, O., & Bignami, E. (2024). The breakthrough of large language models for medical applications: One-year timeline and perspectives. *Journal of Medical Systems*, *48*(1), 22. <https://doi.org/10.1007/s10916-024-02045-3>
- [37] Hagos, D. H., Battle, R., & Rawat, D. B. (2024). Recent advances in generative AI and large language models: Current status, challenges, and perspectives. *IEEE Transactions on Artificial Intelligence*. <https://doi.org/10.1109/TAI.2024.3444742>
- [38] Zhou, S., Zhang, Y., Liu, H., et al. (2025). Large language models for disease diagnosis: A scoping review. *Nature npj Digital Medicine*.
- [39] Sajjadi Mohammadabadi, S. M., et al. (2025). A survey of large language models: Evolution, architecture, training, adaptation, and applications. *Electronics*, *14*(18), 3580. <https://doi.org/10.3390/electronics14183580>
- [40] Torkestani, M. S., Alameer, A., Palaiahnakote, S., et al. (2025). Inclusive prompt engineering for large language models: A modular framework for ethical, structured, and adaptive AI. *Artificial Intelligence Review*, *58*, Article 348. <https://doi.org/10.1007/s10462-025-11330-7>

[41] Meta AI Research. (2023). Segment Anything Model (SAM) – ViT-Base.

https://dl.fbaipublicfiles.com/segment_anything/sam_vit_b_01ec64.pth

[42] Ma, J., & al., e. (2025). The Role of Segment Anything Model (SAM) in Medical Image Segmentation: A Comprehensive Review. IEEE Transactions on Medical Imaging, *44*(12), 4500–4515.

<https://doi.org/10.1109/TMI.2025.3528901>

[43] Zhang, L., & al., e. (2025). Intelligent Healthcare Imaging Platform: A VLM-Based Framework for Automated Medical Image Analysis and Clinical Report Generation. arXiv. <https://arxiv.org/abs/2509.11234>

Syrian Arab Republic

Ministry of Higher Education and Scientific Research

Al-Wataniya Private University

Faculty of Engineering

Department of Computer Engineering



A Graduation Project Submitted in Partial Fulfillment of the Requirements for
the Degree of Bachelor of Computer Engineering

Artificial Intelligence for the Diagnosis of Oral and Dental Diseases

Prepared by:

Hajar Mamdouh Haddad

Supervised by:

Dr. Eng. Ahmad Riyad Kurdi

2025–2026