



الجمهورية العربية السورية

وزارة التعليم العالي والبحث العلمي

جامعة حماة

الكلية التطبيقية

قسم تقنيات الحاسوب

مشروع أعد لنيل درجة الإجازة في تقانة الحاسوب بعنوان:

تشخيص مرض سرطان الثدي باستخدام الذكاء الاصطناعي

إعداد الطالبات:

يمنى الخطيب - آلاء الحميدي - نسرين كلاس الحلبي

إشراف:

الدكتور المهندس أحمد رياض كردي

الدكتور عبد الحميد ملقي

2025-2024

الاهداء

بسم الله الرحمن الرحيم

[وَآخِرُ دَعْوَاهُمْ أَنِ الْحَمْدُ لِلَّهِ رَبِّ الْعَالَمِينَ]

إلى خالق الخلق، مالك الملك، بكرمه أعطاني فشكرت، وبفضله وفقت، وبفضله نجحت، إلى مَنْ أعطاني فأكرم، وألهمني فأنجزت، إلى مَنْ مِنْ نوره استنرت، وبه اهتديت، لولاه ما كنت ولولاه ما وجدت، الحمد لله على كل صعب تذلل، الحمد لله على كل عسير تيسر، الحمد لله على تمام نعمته.

(الله جلّ في علاه)

إلى المعلّم الأول، والروح الأطهر، والنور الأزهر، لنورك الذي ملأ القلب باليقين، إلى من بلغ الرسالة، وأدى الأمانة، إلى من شرف الانتماء لأمته.

(حبيبي رسول الله صلّى الله عليه وسلّم)

إلى سيادة العميد والمشرف

نتقدم بخالص الشكر والتقدير على دعمه وجهوده القيّمة

ومساندتك المستمرة لنا من خلال خبرتك العظيمة وإشرافك المتميز

وتوجيهاته السديدة التي كان لها بالغ الأثر في إنجاز هذا العمل وإخراجه بأفضل صورة ممكنة له منا كل

الامتنان والتقدير

(الدكتور المهندس أحمد رياض كردي)

كل الشكر إلى من اكتسبنا معلومات قيمه من خلاله , إلى من ساعدنا في إتمام هذا البحث إلى من زودنا بسطور معرفته وخبراته الواسعة لقد كان لتوجيهه ودعمه أثر في إخراج هذا العمل بأفضل صورة

(الدكتور عبد الحميد ملقي)

إلى من كانوا لنا عوناً ودعماً في مسيرتنا العلمية وكانوا لنا قدوة في الإخلاص والعمل نهدي هذا الجهد المتواضع تعبيراً عن امتناناً لما قدتموه من توجيه وإرشاد فلكم منا كل الشكر والتقدير .

(لينا القدور , راما الحلاق , عماد حمد , حنان حاج محمد)

الملخص

يهدف هذا المشروع إلى تطوير نظام ذكي لتشخيص سرطان الثدي بالاعتماد على تقنيات الذكاء الاصطناعي، وذلك من خلال الجمع بين تحليل صور الأشعة الطبية باستخدام خوارزمية YOLO وتحليل بيانات الفحوصات المخبرية عبر خوارزميات مثل Random Forest. يركز النظام على تقديم مقارنة شاملة تجمع بين البيانات البصرية والرقمية للوصول إلى نتائج أكثر دقة وموثوقية. أظهرت نتائج الاختبارات أن النظام قادر على تحقيق دقة عالية في التنبؤ مع تقليل الأخطاء البشرية وزمن المعالجة، مما يجعله أداة فعالة لدعم الأطباء في عملية التشخيص. كما أن تصميم الواجهات سهل الاستخدام يتيح مرونة في إدخال البيانات سواء عبر الصور أو ملفات Excel. ويسهم هذا النظام في تحسين جودة التشخيص وتسهيل دمجها في المؤسسات الطبية المختلفة.

كلمات مفتاحية

الذكاء الاصطناعي، سرطان الثدي، YOLO، الغابة العشوائية، صور الأشعة، بيانات مخبرية

ABSTRACT

This project aims to develop an intelligent system for breast cancer diagnosis based on artificial intelligence techniques, combining medical image analysis using the YOLO algorithm with laboratory data analysis through methods such as Random Forest. The proposed system integrates both visual and numerical data to achieve more accurate and reliable outcomes. Experimental results demonstrated that the system provides high prediction accuracy while minimizing human error and processing time, making it a valuable tool for supporting physicians in the diagnostic process. The user-friendly interface offers flexibility in data input, whether through images or Excel files. Overall, the system enhances diagnostic quality and facilitates integration into diverse medical institutions.

Keywords

Artificial Intelligence, Breast Cancer, YOLO, Random Forest, Medical Imaging, Laboratory Data

المحتويات

1	الفصل الأول: مقدمة	1
1-1	مقدمة المشروع وأهدافه	2
2-1	سرطان الثدي	5
1-2-1	أسباب سرطان الثدي	6
2-2-1	أعراض سرطان الثدي	7
3-2-1	تشخيص سرطان الثدي	7
4-2-1	علاج سرطان الثدي	8
5-2-1	كيف يمكن الوقاية من سرطان الثدي؟	8
6-2-1	مضاعفات سرطان الثدي	9
2	الفصل الثاني: مراجعة الدراسات السابقة	11
1-2	مراجعة لبعض الدراسات السابقة	12
1-1-2	استخدام الذكاء الاصطناعي في تشخيص سرطان الثدي	12
2-1-2	تطبيق شبكات التلافيف العصبونية (CNN) في تصنيف الأورام	14
3-1-2	معالجة التباين العرقي والإثني في التشخيص باستخدام الذكاء الصناعي	16

2-2	التحديات والقيود في الدراسات السابقة	17
3-2	العلاقة بين الدراسات السابقة وأهداف المشروع	20
3	الفصل الثالث: أساسيات الذكاء الاصطناعي	21
1-3	الذكاء الاصطناعي	22
1-1-3	تعريف الذكاء الاصطناعي	22
2-1-3	كيف يعمل الذكاء الاصطناعي؟	23
3-1-3	دور البيانات والخوارزميات في بناء النماذج الذكية	25
2-3	تعلم الآلة	26
1-2-3	كيفية بناء النماذج في التعلم الآلي	27
2-2-3	تطبيقات التعلم الآلي	29
3-3	التعلم العميق	30
1-3-3	لماذا التعلم العميق لمعالجة الصور؟	32
4	الفصل الرابع: الشبكات العصبونية	34
1-4	مفهوم الشبكات العصبونية	35
2-4	الشبكة العصبونية (DNN (Deep Neural Network	37
3-4	دوال التنغيع (Activation Functions)	39

40	4-4 متى نتوقف عن تدريب النموذج؟
43	5 الفصل الخامس: الشبكة العصبية التلافيفية (CNN)
44	1-5 مفهوم الشبكة العصبونية CNN
45	2-5 خطوات عمل الشبكة العصبية CNN
48	3-5 الفلاتر في شبكة CNN
50	6 الفصل السادس: النماذج والخوارزميات المستخدمة
51	1-6 نماذج التعلم العميق لتصنيف الصور والرؤية الحاسوبية
51	1-1-6 نموذج ResNet50v2
52	2-1-6 نموذج ResNet152v2
54	3-1-6 نموذج InceptionV3
56	4-1-6 نموذج Xception
58	5-1-6 نموذج MobileNet
60	2-6 خوارزمية YOLO
61	1-2-6 كيف تعمل خوارزمية YOLO؟
63	3-6 خوارزمية شجرة القرار (Decision Tree)
64	1-3-6 أنواع أشجار القرار

65.....	4-6 خوارزمية الغابة العشوائية (random Forest)
66.....	1-4-6 كيف تعمل خوارزمية الغابة العشوائية؟
67.....	5-6 خوارزمية SVC
68.....	1-5-6 المعاملات الأساسية
69.....	7 الفصل السابع: بناء النظام النهائي
70.....	1-7 تجهيز المكتبات والبيئات البرمجية
70.....	1-1-7 المكتبات البرمجية
71.....	2-1-7 البيئات
71.....	2-7 واجهات النظام
73.....	3-7 مخطط خوارزمية العمل
75.....	4-7 التنفيذ النهائي
79.....	8 الفصل الثامن: النتائج والتوصيات
82.....	9 المراجع

فهرس الأشكال

- الشكل (1-1): التوقعات لعدد الحالات المتوقعة من سرطان الثدي كأبرز سبب للوفاة بين النساء الشابات في عام 2024.....3
- الشكل (2-1): مفهوم النماذج ذات الصندوق الأسود.....13
- الشكل (2-2): التصور المقارن لتقنيات XAI الخاصة بكشف سرطان الثدي. (a) صورة الإدخال، (b) SHAP، (c) Grad-CAM، (d) LIME.....14
- الشكل (2-3): عدد الأوراق البحثية المسترجعة باستخدام مصطلحات البحث 'CNN' وتصنيف صور السرطان' سنويًا.....15
- الشكل (2-4): أداء الشبكات العصبونية التلافيفية (CNN) عبر كل من المجموعات العرقية/الإثنية الفرعية الستة للكشف عن الكسور الفذفية $(EF) \leq 35\%$ و $\geq 40\%$16
- الشكل (2-5): مصفوفة الارتباك التي توضح دقة المصنف متعدد الفئات (المدرّب على مجموعة البيانات الأولية) لتحديد العرق بناءً على تخطيط القلب الكهربائي.....19
- الشكل (3-1): كيفية عمل الذكاء الاصطناعي.....24
- الشكل (3-2): خطوات عمل التعلم الآلي.....28
- الشكل (3-3): الفرق بين التعلم الآلي والتعلم العميق.....31
- الشكل (4-1): الشبكات العصبية الاصطناعية.....36
- الشكل (4-2): العصبون.....37

- الشكل (3-4): الفرق بين الشبكة العصبية الاصطناعية التقليدية والشبكة العصبية العميقة.....38
- الشكل (4-4): دوال التفعيل.....39
- الشكل (4-5): مفهوم الـ Overfitting.....41
- الشكل (5-1): خطوات عمل الشبكة العصبية التلافيفية.....45
- الشكل (5-2): آلية عمل الفلتر.....49
- الشكل (6-1): معمارية ResNet50v2.....52
- الشكل (6-2): معمارية ResNet152V2.....54
- الشكل (6-3): معمارية InceptionV3.....55
- الشكل (6-4): معمارية Xception.....57
- الشكل (6-5): معمارية MobileNet.....59
- الشكل (6-6): هيكل خوارزمية YOLO.....62
- الشكل (6-7): المكونات الأساسية لشجرة القرار: العقدة الجذرية، العقد الداخلية، والعقد الورقية.....64
- الشكل (6-8): تمثيل مرئي لآلية عمل الغابة العشوائية.....67
- الشكل (7-1): مخطط واجهات النظام.....72
- الشكل (7-2): مخطط خوارزمية نظام معالجة الصور باستخدام YOLO.....73
- الشكل (7-3): مخطط خوارزمية عمل مسار تحليل البيانات.....74
- الشكل (7-4): الواجهة الرئيسية للنظام.....75
- الشكل (7-5): واجهة رفع الصور (YOLO).....76

- الشكل (6-7): نتيجة الكشف عن الورم.....76
- الشكل (7-7): واجهة إدخال البيانات يدويا أو عبر ملف إكسل.....77
- الشكل (8-7): واجهة التنبؤ بالاعتماد على البيانات مع إظهار النتيجة.....77
- الشكل (9-7): ملف إكسل يحوي بيانات المريض والنتيجة المتوقعة.....78

فهرس الجداول

- الجدول (1-5): الفرق بين شبكة CNN وDNN.....45

جدول المصطلحات

العربية	الإنجليزية	الاختصار
الذكاء الاصطناعي	Artificial Intelligence	AI
التعلم الآلي	Machine Learning	ML
التعلم العميق	Deep Learning	DL
الشبكة العصبية التلافيفية	Convolutional Neural Network	CNN
متجه آلة الدعم	Support Vector Machine	SVM
الغابة العشوائية	Random Forest	RF
أنت تنظر مرة واحدة	You Only Look Once	YOLO
التشخيص بمساعدة الحاسوب	Computer-Aided Diagnosis	CAD
الشبكة العصبية العميقة	Deep Neural Network	DNN
واحد ضد الباقي	One-vs-Rest	OVR
واحد ضد واحد	One-vs-One	OVO
العينة خارج الحقيبة	Out-of-Bag	OOB

الفصل الأول: مقدمة


1-1 مقدمة المشروع وأهدافه

يعد سرطان الثدي أحد أكثر الأمراض شيوعًا وأخطرها تهديدًا لصحة النساء حول العالم. يلعب التشخيص المبكر دورًا محوريًا في تحسين فرص العلاج وزيادة معدلات البقاء على قيد الحياة، حيث تشير الإحصائيات إلى أن الكشف المبكر يمكن أن يرفع نسبة الشفاء إلى أكثر من 90% [1]. ومع ذلك، فإن عمليات التشخيص التقليدية تعتمد بشكل كبير على التصوير الإشعاعي للثدي (الماموغرام) وتتطلب خبرة متخصصة من الأطباء الإشعاعيين لتحليل النتائج بدقة. هذه العملية ليست فقط معقدة ومكلفة، بل إنها عرضة أيضًا للأخطاء البشرية التي قد تؤدي إلى تشخيص غير دقيق، سواء بالإيجاب الزائف أو السلبي الزائف، مما يعرض حياة المرضى للخطر.

بالإضافة إلى ذلك، تشير التوقعات إلى أن سرطان الثدي سيظل السبب الرئيسي للوفاة بين النساء الشابات في السنوات القادمة، كما هو موضح في الشكل (1-1)، الذي يظهر التوقعات لعدد الحالات المتوقعة من مختلف أنواع السرطان بين النساء الشابات في عام 2024. يُلاحظ أن سرطان الثدي يأتي في المرتبة الأولى بفارق كبير عن باقي أنواع السرطانات الأخرى، مما يعكس أهمية تطوير تقنيات تشخيصية دقيقة وفعالة لتقليل العبء الصحي والاجتماعي المرتبط بهذا المرض.

في ظل هذه التحديات، برزت الحاجة الملحة لتطوير تقنيات مبتكرة تعزز دقة وكفاءة التشخيص. هنا يأتي دور الذكاء الصناعي كأداة ثورية يمكنها تقديم حلول فعالة لهذه المشكلة. يهدف المشروع المقترح إلى تصميم نظام ذكي يعتمد على تقنيات الذكاء الاصطناعي لتشخيص سرطان الثدي من خلال مسارين متكاملين للتعامل مع البيانات. المسار الأول يختص بتحليل صور الأشعة الطبية باستخدام خوارزميات

الرؤية الحاسوبية مثل YOLO، حيث يقوم النظام باكتشاف المؤشرات البصرية الدالة على وجود الأورام وعرض النتائج بشكل مباشر. أما المسار الثاني فيركز على تحليل بيانات الفحوصات المخبرية المخزنة في ملفات Excel، إذ يتم استخراج القيم المدخلة، تنظيفها، ثم تمريرها إلى النماذج الإحصائية أو خوارزميات التعلم الآلي لإنتاج التوقعات اللازمة. وبذلك يجمع النظام بين قدرات التعلم العميق في معالجة الصور ودقة النماذج الحسابية في تحليل البيانات الرقمية، مما يقلل من احتمالات الخطأ البشري ويوفر وسيلة أكثر شمولية وموثوقة لدعم عملية التشخيص الطبي.



الشكل (1-1): التوقعات لعدد الحالات المتوقعة من سرطان الثدي كأبرز سبب للوفاة بين النساء الشابات في عام 2024.

يهدف المشروع إلى تحقيق مجموعة من الأهداف الرئيسية التي من شأنها تحسين عملية تشخيص سرطان الثدي ودعم الكوادر الطبية، وذلك من خلال:

- رفع دقة التشخيص عبر دمج تحليل صور الأشعة باستخدام تقنيات الرؤية الحاسوبية مع معالجة بيانات الفحوصات المخبرية، مما يقلل من الأخطاء البشرية ويزيد من موثوقية النتائج.
- تسريع الحصول على النتائج من خلال أتمتة خطوات التحليل سواء للصور أو لملفات الإكسل، وبالتالي تقليص الوقت مقارنة بالأساليب التقليدية.
- تقليل التكلفة التشغيلية عبر توفير أداة تقنية تساعد على تقليل الاعتماد الكامل على الخبراء المتخصصين وتقلل من حجم الموارد البشرية المطلوبة.
- تعزيز شمولية التشخيص من خلال توفير نظام يجمع بين البيانات البصرية (الأشعة) والبيانات الرقمية (الفحوصات المخبرية) لإعطاء صورة أوضح عن حالة المريض.
- تقديم واجهة استخدام مرنة تمكّن المستخدم من اختيار طريقة الإدخال المناسبة سواء عبر الصور أو الملفات أو الإدخال اليدوي للبيانات.
- إتاحة التوسع والتطبيق في مختلف المؤسسات الطبية نظرًا للتصميم المرن للنظام وإمكانية دمجها بسهولة مع الأنظمة الطبية الإلكترونية.
- دعم اتخاذ القرار الطبي عبر توفير تقارير واضحة وقابلة للتخزين أو المشاركة، مما يساعد الأطباء في متابعة الحالات بدقة على المدى الطويل.
- النظام المقترح يعتمد على صور الأشعة الخاصة بالثدي وبيانات الفحوصات المخبرية كمدخلات أساسية، مما يجعله متوافقًا مع البنية التحتية الطبية القائمة ويعزز من سهولة دمجها في بيئات التشخيص المختلفة.

سيتم في الفصول القادمة تناول موضوعات مترابطة تغطي الأسس النظرية والجوانب التطبيقية للمشروع. يبدأ الفصل الثاني باستعراض الخلفية النظرية والدراسات السابقة المتعلقة باستخدام تقنيات الذكاء الاصطناعي في تشخيص سرطان الثدي، مع التركيز على أبرز التحديات والفجوات البحثية. أما الفصل الثالث فيعرض بصورة مبسطة المفاهيم الأساسية للذكاء الاصطناعي والتعلم الآلي والتعلم العميق مع إبراز دورها في تحليل الصور الطبية. ويُخصص الفصل الرابع لشرح الشبكات العصبية ومكوناتها ووظائفها المختلفة، بما في ذلك دوال التنشيط والانحياز ومشكلة فرط التعلم. بينما يركز الفصل الخامس على الشبكات العصبية الالتفافية (CNN) باعتبارها الأداة الرئيسية في معالجة الصور الطبية، مع توضيح آلية عملها ومراحلها. ويأتي الفصل السادس لعرض الخوارزميات والنماذج المستخدمة مثل ResNet، Inception، Xception، MobileNet، بالإضافة إلى خوارزمية YOLO وأشجار القرار والغابة العشوائية. وفي الفصل السابع يتم تقديم التصميم العام للنظام، متضمناً تجهيز المكتبات والبيئات البرمجية والواجهات ومخططات الخوارزميات وآلية التنفيذ. وأخيراً، يتناول الفصل الثامن النتائج التي تم التوصل إليها ويعرض مجموعة من التوصيات المستقبلية لتطوير المشروع.

1-2 سرطان الثدي

يُعَدّ سرطان الثدي أحد أكثر الأورام الخبيثة انتشاراً بين النساء، إذ ينشأ غالباً في أنسجة الغدة الثديية، سواء على مستوى القنوات اللبنية أو الفصوص المنتجة للحليب. ويُسجّل هذا النوع من السرطان بمعدلات مرتفعة لدى الإناث مقارنةً بالذكور، غير أنّ إصابة الرجال به تظل ممكنة رغم ندرتها.

1-2-1 أسباب سرطان الثدي

1. **العوامل الوراثية:** وجود حالات إصابة بسرطان الثدي في العائلة، خصوصًا لدى الأقارب من الدرجة الأولى مثل الأم أو الأخت، يُعتبر من أبرز العوامل التي تزيد احتمالية المرض. كما أنّ الطفرات الجينية في بعض الجينات، مثل BRCA1 وBRCA2، ترفع بدرجة كبيرة من خطر الإصابة ليس فقط بسرطان الثدي وإنما بأنواع سرطانية أخرى أيضًا.
2. **العمر:** تزداد احتمالية الإصابة مع التقدم في السن، إذ تُشخص معظم الحالات بعد سن الأربعين، ما يجعل العمر عاملاً رئيسيًا في تقييم مخاطر المرض.
3. **العوامل الهرمونية:** يلعب التعرض الطويل لهرمون الأستروجين دورًا مهمًا في زيادة احتمالية الإصابة. ويظهر ذلك لدى النساء اللاتي بدأت لديهن الدورة الشهرية في سن مبكرة أو اللواتي تأخر لديهن انقطاع الطمث. كما يسهم استخدام العلاج الهرموني بعد سن اليأس في رفع مستوى الخطر، إضافةً إلى تأخر الحمل أو عدم الإنجاب، وهي عوامل قد تؤثر على توازن الهرمونات في الجسم.
4. **نمط الحياة:** السمنة، خاصة بعد انقطاع الطمث، تُعد من أبرز المؤثرات السلبية، حيث تزيد تراكمات الدهون من نشاط الأستروجين. كما أن قلة ممارسة النشاط البدني بانتظام ترتبط بارتفاع احتمالية الإصابة، في حين يُعتبر التدخين من العوامل المعروفة التي تسهم في تطور عدة أنواع من الأورام، ومن بينها سرطان الثدي.

5. العوامل البيئية: يُسجل ارتباط بين التعرض للإشعاع في منطقة الصدر لأغراض علاجية وبين زيادة

مخاطر المرض. كذلك فإن التماس المتكرر مع بعض المواد الكيميائية سواء في بيئة العمل أو من

خلال منتجات صناعية مختلفة، يمكن أن يسهم في رفع معدلات الإصابة.

6. العادات الغذائية: النظم الغذائية الفقيرة بالفواكه والخضروات والغنية بالدهون والنشويات تُعدّ من

الأنماط التي تزيد من احتمالية الإصابة. إذ يُسهم سوء التغذية على المدى الطويل في إضعاف

مقاومة الجسم وتوفير بيئة أكثر ملاءمة لنمو الخلايا السرطانية.

1-2-2 أعراض سرطان الثدي

- كتلة أو تورم في الثدي أو تحت الإبط، قد يكون ملمسها صلبًا أو غير مؤلم.
- تغيير في شكل أو حجم الثدي
- تغيير في مظهر الجلد، مثل تجاعيد أو انكماش الجلد.
- إفرازات غير طبيعية في الحلمة، قد تكون دموية أو مائية.
- احمرار أو حرارة في جلد الثدي.

1-2-3 تشخيص سرطان الثدي

- الفحص الذاتي للثدي للكشف عن أي تغييرات.
- فحوصات التصوير مثل الماموغرام (تصوير الثدي بالأشعة السينية).
- أخذ خزعة لإزالة عينة من الأنسجة لفحصها تحت المجهر.

1-2-4 علاج سرطان الثدي

يعتمد العلاج على مرحلة السرطان ونوعه وقد يتضمن:

- **الجراحة:** لإزالة الورم أو الثدي بالكامل.
- **العلاج الكيميائي:** لقتل الخلايا السرطانية.
- **العلاج الإشعاعي:** لتدمير الخلايا السرطانية المتبقية.
- **العلاج الهرموني:** لتقليل مستويات الهرمونات التي قد تساهم في نمو السرطان.

1-2-5 كيف يمكن الوقاية من سرطان الثدي؟

تُعَدّ الوقاية من سرطان الثدي عنصرًا أساسيًا في الحد من انتشاره وتقليل معدلات الوفيات المرتبطة به، حيث يوصى بالالتزام بالفحوصات الدورية باستخدام الماموغرام، لاسيما لدى النساء اللواتي ينتمين إلى الفئات العمرية الأكثر عرضة للإصابة، إذ يساهم الكشف المبكر في تحسين فرص العلاج والشفاء. كما يلعب تبني أسلوب حياة متوازن دورًا محوريًا في الوقاية، من خلال اتباع نظام غذائي غني بالخضروات والفواكه، وممارسة النشاط البدني بانتظام للحفاظ على وزن صحي، إلى جانب تجنب التدخين الذي يُعَدّ من أبرز العوامل المسببة للعديد من الأورام السرطانية. إن دمج هذه الممارسات في الحياة اليومية يشكّل وسيلة فعّالة للحد من مخاطر المرض وتعزيز الصحة العامة.

1-2-6 مضاعفات سرطان الثدي

1. **المضاعفات الجسدية:** قد يؤدي سرطان الثدي إلى انتشار الخلايا السرطانية نحو أعضاء أخرى في الجسم مثل العظام، الكبد، الدماغ أو الرئة، مما يتسبب في مشكلات صحية معقدة قد تهدد حياة المريض. كما أن العلاجات المختلفة، سواء الجراحية أو الكيميائية، تُضعف الجهاز المناعي وتزيد من خطر العدوى. ويُضاف إلى ذلك أنّ التغيرات التي تصيب الثدي من حيث الشكل أو الحجم قد تترك آثارًا واضحة على المظهر الخارجي للجلد، في حين أن بعض الوسائل العلاجية مثل العلاج الإشعاعي أو الكيميائي قد تؤدي إلى تساقط الشعر والشعور المستمر بالإرهاق والتعب الشديد.
2. **المضاعفات النفسية:** يمثل التشخيص بسرطان الثدي تجربة مؤثرة على الجانب النفسي للمريض، إذ ينعكس المرض بشكل مباشر على الاستقرار العاطفي، مسببًا حالات من القلق والاكتئاب. هذه الاضطرابات النفسية قد تؤثر بدورها على طبيعة العلاقات الاجتماعية، فتحدث تغييرات في تواصل المريض مع أسرته ومحيطه.
3. **المضاعفات الاجتماعية والاقتصادية:** تُعتبر التكلفة المرتفعة للعلاج من أبرز الأعباء التي تثقل كاهل المرضى وعائلاتهم، حيث قد ينعكس ذلك سلبًا على أوضاعهم المالية. كما أنّ فترات العلاج الطويلة وما تتطلبه من التوقف عن العمل تؤدي إلى فقدان الدخل، الأمر الذي يزيد من حدة الضغوط الاقتصادية ويؤثر في الاستقرار الاجتماعي للفرد وأسرته.
4. **المضاعفات طويلة الأمد:** حتى بعد انتهاء مرحلة العلاج، قد يواجه بعض المرضى صعوبات مرتبطة بالقدرة الحركية، خصوصًا إذا خضعوا لعمليات جراحية في منطقة الثدي أو الإبط، وهو ما قد يحد

من مرونة الذراع ويؤثر على أداء الأنشطة اليومية. كما يمكن أن تظهر مشكلات صحية مزمنة نتيجة الآثار الجانبية للعلاج مثل أمراض القلب أو فقدان الوزن، مما يجعل المتابعة الطبية المستمرة ضرورية لضمان جودة الحياة على المدى البعيد.

الفصل الثاني: مراجعة

الدراسات السابقة


تلعب الدراسات السابقة دورًا محوريًا في تطوير مشروع يهدف إلى تشخيص سرطان الثدي باستخدام تقنيات الذكاء الصناعي، حيث توفر أساسًا علميًا وعمليًا لفهم الإمكانيات والتحديات المرتبطة بهذا المجال. من خلال استعراض الجهود البحثية التي تم إنجازها، يمكن تحديد الأساليب الناجحة التي مهدت الطريق أمام تطبيقات الذكاء الصناعي في التشخيص الطبي، بالإضافة إلى الوقوف على نقاط القوة التي ميزت هذه الجهود، مثل تحقيق دقة عالية في تحليل البيانات الطبية. ومع ذلك، فإن استعراض هذه الدراسات يكشف أيضًا عن نقاط ضعف تحتاج إلى معالجة، مثل التحديات المرتبطة بحجم البيانات المطلوبة أو قابلية تفسير النتائج النهائية. يركز هذا الفصل على استكشاف هذه الجهود البحثية بشكل نقدي، بهدف استخلاص الدروس المستفادة والاستفادة منها لتحسين تصميم المشروع الحالي وضمان تحقيق أهدافه بالشكل الأمثل.

2-1 مراجعة لبعض الدراسات السابقة

2-1-1 استخدام الذكاء الاصطناعي في تشخيص سرطان الثدي

في دراسة شاملة قدمتها جامعة سالم حبيب في كراتشي بالتعاون مع معهد البحوث الفرنسي LIRIS وCNRS، تم استكشاف دور تقنيات الذكاء الصناعي القابلة للتفسير (Explainable Artificial Intelligence - XAI) في تشخيص سرطان الثدي [3]. ركزت الدراسة على تحليل كيفية استخدام نماذج التعلم الآلي والتعلم العميق لتحسين دقة الكشف عن سرطان الثدي وتوفير تفسيرات واضحة للنتائج. استخدم الباحثون مجموعة متنوعة من تقنيات XAI، مثل SHAP و LIME و Grad-CAM، لتسهيل فهم القرارات التي تتخذها النموذج الذكية.

لشرح مفهوم "الصندوق الأسود" (Black Box Models) الذي يركز على أهمية الشفافية في نماذج التعلم الآلي، تم تقديم الشكل (2-1)، الذي يوضح كيف يمكن أن تكون هذه النماذج معقدة وغير شفافة، مما يبرز الحاجة إلى تقنيات XAI لتوضيح كيفية اتخاذ القرارات.




الشكل (2-1): مفهوم النماذج ذات الصندوق الأسود.

أظهرت الدراسة أن تقنيات مثل SHAP و LIME و Grad-CAM لا تساهم فقط في تعزيز دقة التشخيص، بل تساعد أيضًا في تحديد المناطق المحددة في صور الأشعة التي تؤثر على التنبؤات. على سبيل المثال، استخدم الشكل (2-2) لتقديم مقارنة بصرية بين ثلاث تقنيات شائعة: SHAP، Grad-CAM، و LIME. يُظهر هذا الشكل كيف يمكن لكل تقنية تقديم تفسيرات مرئية مختلفة لنفس صورة الإدخال. الجزء (b) من الشكل يوضح كيفية استخدام SHAP لتحديد المناطق الأكثر أهمية في الصورة، بينما يُظهر الجزء (c) كيف يستخدم Grad-CAM خرائط الحرارة لتحديد مواقع الشذوذ المحتملة داخل الأنسجة. أما الجزء (d)، فيوضح كيف يعمل LIME من خلال إنشاء اضطرابات في الصورة لتحديد الخصائص الرئيسية.

كما تم تسليط الضوء على أهمية تنوع البيانات المستخدمة في تدريب النموذج، حيث أشارت النتائج إلى أن استخدام بيانات متعددة المصادر يمكن أن يحسن الأداء العام للنظام. استُخدمت تقنيات مثل t-SNE

وUMAP لتحليل تجميع الميزات المتعددة، مما ساهم في تحسين فهم كيفية استجابة النموذج للبيانات المعقدة.



الشكل (2-2): التصور المقارن لتقنيات XAI الخاصة بكشف سرطان الثدي. (a) صورة الإدخال، (b) SHAP، (c) Grad-CAM، (d) LIME.


تأتي هذه الدراسة كجزء من الجهود المتزايدة لتطوير أنظمة ذكاء صناعي قابلة للتفسير تهدف إلى تحسين الرعاية الصحية وتوفير أدوات تشخيص دقيقة وفعالة. الجهة المقدمة لهذه الدراسة هي كلية تقنية المعلومات في جامعة سالم حبيب، بالتعاون مع معاهد بحثية مرموقة مثل LIRIS وCNRS، مما يعكس الطابع الدولي والمتعدد التخصصات لهذا البحث.

2-1-2 تطبيق شبكات التلافيف العصبونية (CNN) في تصنيف الأورام

في دراسة شاملة أجراها فريق بحثي دولي من جامعة تشجيانغ الصينية والمعهد الأوروبي للبحوث الطبية الحيوية، تم استعراض تطبيقات شبكات التلافيف العصبونية (CNN) في تحليل صور الأورام السرطانية باستخدام تقنيات التعلم العميق [4]. ركزت الدراسة على نماذج مثل DenseNet-201 وNASNet-Mobile وResNet-101 لتحسين دقة الكشف عن الأورام في صور الثدي (الماموغرام) والرنين المغناطيسي والصور المقطعية. أظهرت النتائج تحقيق معدلات دقة عالية، حيث بلغت المنطقة تحت المنحنى (AUC) أكثر من 95% في حالات مثل أورام العظام والدماغ.

أحد الجوانب المهمة التي أبرزتها الدراسة هو دور تعلّم النقل (Transfer Learning) في التغلب على ندرة البيانات الطبية. على سبيل المثال، استُخدم نموذج NASNet-Mobile المُدرَّب مسبقًا على قاعدة بيانات ImageNet وُعُدل لتحليل صور الأشعة السينية للصدر للكشف عن الالتهابات الرئوية، مما زاد الدقة مقارنة بالطرائق التقليدية. كما ناقش الباحثون تقنيات توليد البيانات الصناعية (Data Augmentation) مثل التدوير والقص لتعزيز تنوع البيانات.


في الشكل (2-3) المرفق، وُصِّح الاتجاه التصاعدي في عدد الدراسات حول CNN وتصنيف صور الأورام بين عامي 2010 و2023، حيث بلغ عدد الدراسات ذروته في عام 2023 مع 36,100 ورقة بحثية.



الشكل (2-3): عدد الأوراق البحثية المسترجعة باستخدام مصطلحات البحث 'CNN' و'تصنيف صور السرطان' سنويًا.

3-1-2 معالجة التباين العرقي والإثني في التشخيص باستخدام الذكاء الصناعي

في دراسة رائدة أجراها فريق بحثي من كلية الطب بجامعة مايو كلينك بالتعاون مع خبراء في الذكاء الصناعي، تم تقييم تأثير العوامل العرقية والإثنية على أداء نماذج الذكاء الصناعي في التشخيص الطبي، باستخدام بيانات تخطيط القلب الكهربائي (ECG) لاكتشاف ضعف عضلة القلب ($EF \leq 35\%$) و $\geq 40\%$ [5]. أظهرت النتائج أن النموذج القائم على الشبكات العصبونية (CNN) حقق أداءً مُتقاربًا عبر ست مجموعات عرقية/إثنية مختلفة، كما يوضح الشكل (2-4) من الدراسة، الذي يُظهر قيم المنطقة تحت المنحنى (AUC) لكل مجموعة، مما يؤكد إمكانية تطبيق هذه التقنيات بشكل عادل إذا تم تصميمها بعناية.



الشكل (2-4): أداء الشبكات العصبونية التلافيفية (CNN) عبر كل من المجموعات العرقية/الإثنية الفرعية الستة للكشف عن الكسور القذفية $EF \leq 35\%$ و $\geq 40\%$.

سلطت الدراسة الضوء على ضرورة استخدام بيانات متنوعة في تدريب النماذج لتقليل الانحياز، مشيرة إلى أن النقص في تنوع البيانات قد يؤدي إلى تفاوت في التشخيص بين المجموعات العرقية. على سبيل المثال، وُجد أن النموذج المُدرَّب على بيانات محدودة التنوع قد يفشل في تعميم النتائج لفئات سكانية جديدة، مما يُعيد تأكيد أهمية تضمين عينات ممثلة لجميع الفئات في مرحلة التطوير. كما ناقش الباحثون تحديات مثل الاختلافات الفسيولوجية بين المجموعات العرقية، والتي قد تؤثر على دقة النموذج إذا لم تُؤخذ في الحسبان.

أكدت الدراسة أن الذكاء الصناعي قادر على تقليل الفروق في التشخيص بين المجموعات العرقية، لكنها أشارت إلى ضرورة اختبار النماذج على بيانات خارجية (External Validation) لضمان العدالة. على سبيل المثال، في الشكل (2-4)، لوحظ أن أداء النموذج كان متسقاً بين الأمريكيين الأفارقة والبيض واللاتينيين، لكنه تراجع قليلاً في المجموعات التي لم تُمثل بشكل كافٍ في البيانات الأصلية. هذا يُظهر أن التنوع في البيانات ليس خياراً، بل ضرورة لتجنب الانحياز.

2-2 التحديات والقيود في الدراسات السابقة


أظهرت الدراسات السابقة المرجعية، والتي تمثل جهوداً بحثية من جامعات ومؤسسات عالمية رائدة، مجموعة من التحديات والقيود التي تواجه تطبيق تقنيات الذكاء الصناعي في تشخيص الأمراض، خاصة سرطان الثدي. في دراسة أجراها فريق بحثي من كلية تقنية المعلومات في جامعة سالم حبيب بالتعاون مع معهد LIRIS وجامعة كلود برنار ليون 1 [3]، تم تسليط الضوء على مشكلة نقص التنوع في البيانات المستخدمة لتدريب النماذج، مما يؤدي إلى انحياز في النتائج عند تطبيقها على مجموعات

عرقية أو إثنية غير ممثلة بشكل كافٍ. كما أكدت الدراسة أن نماذج الذكاء الصناعي المعقدة تعاني من مشكلة "الصندوق الأسود"، حيث تفتقر إلى الشفافية اللازمة لتفسير قراراتها، مما يحد من قبولها في الممارسة الطبية. بالإضافة إلى ذلك، أشار الباحثون إلى صعوبة التفسير المحلي للنماذج، حيث قد لا تكون التفسيرات دقيقة بما يكفي لدعم القرارات الطبية، كما هو موضح في الشكل (2-2).

من جهة أخرى، ركزت دراسة أخرى من كلية الهندسة في جامعة تشجيانغ الصينية بالتعاون مع مؤتمر التعلم الآلي والأتمتة الدولي [4] على تحديات تدريب نماذج الشبكات العصبونية التلافيفية (CNN). أشارت الدراسة إلى أن هذه النماذج تتطلب كميات ضخمة من البيانات، وهو ما قد يكون غير متاح في بعض الحالات، خاصةً في المؤسسات ذات الموارد المحدودة. كما ذكر الباحثون أن الاعتماد على تقنيات مثل Data Augmentation قد يزيد من تعقيد النظام ويقلل من قابليته للتوسع. بالإضافة إلى ذلك، أكدت الدراسة أن البيانات المستخدمة غالبًا ما تكون محدودة جغرافيًا، مما يؤثر على قدرة النموذج على تعميم النتائج، فضلًا عن التكلفة الحسابية العالية التي تجعل تطبيق هذه التقنيات غير عملي في بعض البيئات الطبية.

أخيرًا، في دراسة أجراها فريق بحثي من كلية الطب في مايو كلينك بالولايات المتحدة [5]، تم تقييم تأثير العوامل العرقية والإثنية على أداء نموذج الذكاء الصناعي في تحليل تخطيط القلب الكهربائي (ECG). أظهرت الدراسة أن النموذج كان أقل دقة في تصنيف المجموعات العرقية غير الممثلة بشكل كافٍ، كما يظهر في الشكل (2-5). كما أشار الباحثون إلى أن عدد المشاركين من الأقليات كان صغيرًا نسبيًا، مما قد يؤثر على موثوقية النتائج. إلى جانب ذلك، كانت البيانات مقتصرة على منطقة جغرافية واحدة،

مما يحد من قدرة النموذج على التعميم. كما أثار الباحثون مخاوف أخلاقية حول استخدام بيانات المرضى، مشيرين إلى أهمية التعامل معها بحذر لضمان الخصوصية.



الشكل (5-2): مصفوفة الارتباك التي توضح دقة المصنف متعدد الفئات (المدرّب على مجموعة البيانات الأولية) لتحديد العرق بناءً على تخطيط القلب الكهربائي.

تُبرز هذه التحديات الحاجة إلى تحسين تصميم النماذج الذكية من خلال زيادة تنوع البيانات، تعزيز الشفافية، وتقليل التكلفة الحسابية لضمان تطبيقها الفعال في المجال الطبي.

2-3 العلاقة بين الدراسات السابقة وأهداف المشروع

تتجلى العلاقة بين الدراسات السابقة وأهداف المشروع في كيفية استلهاهم الجهود البحثية لتطوير نظام ذكي يعتمد على تقنيات التعلم العميق والشبكات العصبونية التلافيفية (CNN) والشبكات العصبونية العميقة (DNN) لتحليل الصور الإشعاعية للثدي وتصنيف الأورام إلى حميدة أو خبيثة. يستفيد المشروع من المبادئ التي أبرزتها دراسة جامعة سالم حبيب وكلية LIRIS [2] حول أهمية استخدام تقنيات الذكاء الصناعي القابل للتفسير (XAI) لضمان شفافية القرارات التشخيصية، مما يعزز ثقة الأطباء في النتائج ويقلل من غموض "الصندوق الأسود" الذي يحيط بنماذج التعلم العميق. كما يستمد المشروع قوته من نماذج CNN المتقدمة التي تم تناولها في دراسة جامعة تشجيانغ [3]، والتي أظهرت قدرة ملحوظة على استخراج الخصائص الدقيقة من الصور الطبية، مما يمكنه من تحقيق دقة عالية في تصنيف الأورام بناءً على الصور الإشعاعية للثدي. من جهة أخرى، بينما لم يتم اتخاذ قرار نهائي بشأن التركيز على البيانات العرقية والإثنية في المشروع، فإن الأبحاث مثل دراسة مايو كلينك [4] تسلط الضوء على أهمية تضمين بيانات متنوعة تمثل مختلف الفئات السكانية لتجنب أي انحياز محتمل في التشخيص. يمكن للمشروع أن يستفيد من هذه الأبحاث لاحقاً إذا قرر توسيع نطاقه ليشمل جوانب أكثر تعقيداً مثل التحيز العرقي أو الإثني، حيث يمكن استخدام تقنيات مثل Data Augmentation و Ensemble Learning لتقليل تأثير هذه التحيزات. بهذه الطريقة، يتم دمج الجهود البحثية السابقة في إطار شامل يهدف إلى تقديم حلول مبتكرة وفعالة لتحسين جودة التشخيص الطبي، مع ترك المجال مفتوحاً لتطوير النظام في المستقبل ليشمل اعتبارات إضافية مثل التنوع العرقي والجغرافي.

الفصل الثالث:

أساسيات الذكاء

الاصطناعي

يُعتبر الذكاء الاصطناعي أحد أبرز المجالات التقنية التي شهدت تطوراً مذهلاً في العقود الأخيرة، وأصبح يشكل جزءاً أساسياً من حياتنا اليومية وقطاعات العمل المختلفة. في هذا الفصل، سنستعرض الأساسيات التي يقوم عليها الذكاء الصناعي ونتعرف على مفهومه بشكل عام وكيف يعمل لحل المشكلات المعقدة باستخدام البيانات والخوارزميات المتطورة. سنتناول أيضاً فرعاً مهماً من فروع الذكاء الصناعي وهو التعلم الآلي (Machine Learning)، حيث نوضح دوره المحوري وكيف يتم بناء النماذج الذكية التي تعتمد على البيانات لفهم الأنماط واتخاذ القرارات. بالإضافة إلى ذلك، سيتم تسليط الضوء على تقنية أكثر تقدماً وهي التعلم العميق (Deep Learning) الذي يتيح معالجة البيانات المعقدة مثل الصور بفضل شبكاته العصبونية العميقة وقدرته على استخراج الخصائص تلقائياً. من خلال هذا الفصل، سيتضح لنا كيف تمثل هذه التقنيات أساساً قوياً للعديد من التطبيقات الحديثة التي نستخدمها يومياً، مثل تصنيف الصور والتنبؤ بالأسعار وغيرها.

3-1 الذكاء الاصطناعي

3-1-1 تعريف الذكاء الاصطناعي

يُعرف الذكاء الاصطناعي بأنه أحد فروع علم الحاسوب الذي يعنى بتطوير الأنظمة والبرمجيات القادرة على محاكاة العمليات العقلية البشرية مثل التعلم، التحليل، واتخاذ القرارات. يهدف هذا المجال إلى تمكين الآلات من أداء المهام التي تتطلب عادةً ذكاءً بشرياً، مثل التعرف على الأنماط، معالجة اللغة الطبيعية، حل المشكلات المعقدة، والتفاعل مع البيئة المحيطة بطريقة مرنة ومبتكرة. يعتمد الذكاء الاصطناعي على مجموعة من التقنيات المتقدمة التي تمكنه من استيعاب كميات هائلة من البيانات وتحليلها

لاستخلاص النتائج واستخدامها في تنفيذ المهام بكفاءة عالية. يتجلى دور هذه التقنية في تعزيز قدرة الأنظمة الرقمية على العمل بشكل مستقل أو شبه مستقل، مما يجعلها أكثر تكيفاً مع التحديات المختلفة التي قد تواجهها دون الحاجة إلى تدخل بشري مباشر. بهذا الشكل، يمثل الذكاء الاصطناعي جسراً بين القدرات البشرية المحدودة والإمكانيات اللامحدودة للآلات الحديثة التي يمكنها تقديم حلول مبتكرة ومتطورة لمجموعة واسعة من القضايا في مختلف المجالات [6].


3-1-2 كيف يعمل الذكاء الاصطناعي؟

يُعتبر فهم كيفية عمل الذكاء الاصطناعي وما يتيح من قدرات لحل المشكلات المعقدة أمراً أساسياً لفهم دوره في العالم الحديث. الذكاء الاصطناعي لا يعمل ككيان مستقل بحد ذاته، بل يعتمد على مجموعة من التقنيات والأساليب التي تمكنه من محاكاة العمليات العقلية البشرية بطريقة آلية وممنهجة. في جوهره، يستند الذكاء الاصطناعي إلى فكرة تمكين الآلات من تلقي البيانات ومعالجتها باستخدام خوارزميات متقدمة لاستخلاص الأنماط والعلاقات المخفية داخل هذه البيانات. يتم ذلك من خلال عمليات حسابية دقيقة تُجرى على المعلومات المدخلة، حيث يتم تحويلها إلى أشكال يمكن للنظام فهمها وتحليلها [6].

عند التعامل مع مشكلة معقدة، يعمل الذكاء الاصطناعي على تقسيمها إلى مجموعة من الخطوات أو المهام الأصغر التي يمكن معالجتها بشكل منفصل ثم دمج نتائجها لتحقيق الحل النهائي. على سبيل المثال، إذا كان الهدف هو بناء نظام يستطيع التعرف على الصور، فإن النظام سيبدأ بتحليل الصورة بكسل بكسل، ثم يقوم بتحديد الخصائص الأساسية مثل الحواف، الألوان، أو الأشكال الهندسية. بعد

ذلك، يستخدم هذه الخصائص لتكوين فهم أعمق للصورة، مثل تمييز الأجسام أو الأشخاص الموجودين فيها. يتم ذلك باستخدام نماذج رياضية وبرمجية مصممة خصيصًا لتحليل البيانات بكفاءة عالية [6].

بالإضافة إلى ذلك، يعتمد الذكاء الاصطناعي على عملية تعلم مستمرة تعتمد على البيانات والملاحظات السابقة. كما هو موضح في الشكل (3-1) المرفق، يتبع الذكاء الاصطناعي خطوات رئيسية تتضمن تعلم الأنماط (Learn patterns) من البيانات، ثم إجراء التنبؤات (Make predictions) بناءً على هذه الأنماط، وأخيرًا تنفيذ المهام (Perform tasks) بناءً على النتائج المستخلصة. هذه العملية تعتمد على تقنيات مختلفة مثل التعلم الآلي (Machine learning)، الشبكات العصبونية (Neural networks)، وأنظمة الخبراء (Expert systems).



الشكل (3-1): كيفية عمل الذكاء الاصطناعي.

القدرة على حل المشكلات المعقدة تعتمد بشكل كبير على نوع البيانات المتوفرة وجودتها، وكذلك على الخوارزميات المستخدمة. الذكاء الاصطناعي يعتمد على التعلم من التجربة، حيث يتم تدريب النموذج

باستخدام بيانات سابقة ليصبح أكثر دقة في المستقبل. على سبيل المثال، إذا كان النظام يخطئ في تصنيف صورة معينة، فإنه يتعلم من هذا الخطأ ويعدل من خوارزمياته لتجنب الوقوع فيه مرة أخرى. هذا النوع من التعلم يجعل الذكاء الاصطناعي قادرًا على التكيف مع السيناريوهات الجديدة وحتى التعامل مع بيانات لم يسبق له مواجهتها من قبل [6].

علاوة على ذلك، يعتمد الذكاء الاصطناعي على مفاهيم مثل المنطق الرياضي، الاحتمالات، والإحصاء لاتخاذ قرارات مستنيرة. يتم استخدام هذه الأدوات لتحليل جميع الاحتمالات المتاحة واختيار الخيار الأمثل بناءً على المعلومات المتاحة. هذا يعني أن الذكاء الاصطناعي ليس مجرد أداة تقوم بتنفيذ أوامر مبرمجة مسبقًا، بل هو نظام ديناميكي يمكنه التفاعل مع بيئته وتعديل سلوكه بناءً على النتائج التي يحققها. بفضل هذه القدرات، أصبح الذكاء الاصطناعي أداة فعالة لحل المشكلات التي كانت تعد في الماضي شديدة التعقيد أو مستحيلة الحل باستخدام الأساليب التقليدية [6].

3-1-3 دور البيانات والخوارزميات في بناء النماذج الذكية

يعد الاعتماد على البيانات والخوارزميات أحد الركائز الأساسية التي يقوم عليها الذكاء الاصطناعي، حيث يتم من خلالها تطوير نماذج ذكية قادرة على أداء مهام معقدة بمستوى عالٍ من الكفاءة. في صميم عمل هذه النماذج، يتم استخدام كميات ضخمة من البيانات التي تمثل المدخلات الرئيسية لأنظمة الذكاء الاصطناعي. هذه البيانات قد تكون نصوصًا، صورًا، مقاطع صوتية، أو أي نوع آخر من المعلومات الرقمية التي يمكن جمعها وتحليلها. ومع ذلك، فإن مجرد توفر البيانات ليس كافيًا؛ إذ يجب أن تكون هذه البيانات دقيقة ومتنوعة لضمان تمثيل شامل للسيناريوهات المختلفة التي قد تواجه النظام [6].

بعد جمع البيانات، تأتي مرحلة المعالجة باستخدام خوارزميات متقدمة تعمل على استخلاص الأنماط والعلاقات المخفية داخلها. الخوارزميات هي مجموعة من القواعد الرياضية والمنطقية التي توجه النظام لكيفية التعامل مع البيانات وتحويلها إلى معلومات قابلة للاستخدام. يتم تصميم هذه الخوارزميات بحيث تتعلم من البيانات السابقة وتستفيد من التجربة لتحسين أدائها بشكل مستمر. على سبيل المثال، إذا كان النظام مصممًا لفهم اللغة الطبيعية، فإنه يستخدم خوارزميات متخصصة لتحليل الجمل واستنباط المعاني بناءً على السياق والقواعد اللغوية [6].

تتمثل الخطوة التالية في توليد نماذج ذكية تعتمد على ما تم تعلمه من البيانات والخوارزميات. هذه النماذج ليست مجرد برامج ثابتة، بل هي أنظمة ديناميكية قادرة على التكيف مع المعلومات الجديدة وتعديل سلوكها بناءً على ما تتعلمه. على سبيل المثال، يمكن لنظام يعتمد على الذكاء الاصطناعي أن يبدأ بتصنيف الصور بشكل أولي، ثم يتحسن تدريجيًا كلما تم تزويده بمزيد من البيانات. هذا التحسين المستمر هو ما يجعل النماذج الذكية فعالة في حل المشكلات المعقدة التي تتطلب مستوى عالٍ من الدقة والمرونة [6].

3-2 تعلم الآلة

يُعتبر التعلم الآلي (Machine Learning) أحد الفروع الرئيسية للذكاء الاصطناعي، ويتميز بقدرته على تمكين الأنظمة الحاسوبية من تحسين أدائها تدريجيًا دون الحاجة إلى برمجة صريحة لكل مهمة جديدة. في جوهره، يعتمد التعلم الآلي على فكرة أن الآلات يمكنها تعلم الأنماط والسلوكيات من البيانات المتوفرة واستخدام هذه المعرفة لاتخاذ قرارات أو تقديم تنبؤات دقيقة. بدلاً من الاعتماد على التعليمات

البشرية المسبقة، يتم تصميم نماذج التعلم الآلي بحيث تستخلص القواعد والقوانين بأنفسها من خلال معالجة كميات كبيرة من المعلومات [6].


يلعب التعلم الآلي دورًا محوريًا في توسيع نطاق الذكاء الاصطناعي وتعزيز قدراته العملية. فهو يتيح لأنظمة الذكاء الاصطناعي التعامل مع المشكلات التي تتطلب مرونة وتكيفًا مستمرًا مع البيانات الجديدة. على سبيل المثال، يمكن لنظام يعتمد على التعلم الآلي أن يتعلم كيفية التعرف على الكلام أو تصنيف الصور بناءً على التجربة المتراكمة من البيانات السابقة. هذا الدور يجعل التعلم الآلي أداة أساسية في العديد من التطبيقات الحديثة، مثل السيارات ذاتية القيادة، أنظمة التوصية في المنصات الرقمية، والتشخيص الطبي باستخدام الذكاء الاصطناعي [6].

من خلال الجمع بين تقنيات الرياضيات والإحصاء وخوارزميات الحوسبة المتقدمة، يوفر التعلم الآلي الأساس الذي يسمح للذكاء الاصطناعي بالانتقال من مجرد تنفيذ أوامر برمجية ثابتة إلى التفاعل الديناميكي مع العالم الحقيقي. هذا الانتقال يعزز قدرة الأنظمة الذكية على فهم البيئة المحيطة بها واتخاذ قرارات أكثر دقة وفعالية، مما يجعل التعلم الآلي حجر الزاوية في تطور الذكاء الاصطناعي وتوسعه في مختلف المجالات [6].

3-2-1 كيفية بناء النماذج في التعلم الآلي

تقوم الفكرة الأساسية لتعلم الآلة على تمكين الأنظمة الحاسوبية من استخلاص المعرفة من البيانات وتطبيق هذه المعرفة لحل المشكلات أو تقديم تنبؤات دقيقة دون الحاجة إلى توجيه صريح أو برمجة مسبقة لكل سيناريو جديد. في جوهرها، تعتمد هذه التقنية على خوارزميات تقوم بتحليل البيانات المتاحة

واستخلاص الأنماط والقوانين التي تحكمها. يتم ذلك من خلال عملية تُعرف باسم "التدريب"، حيث يتم إدخال كميات كبيرة من البيانات إلى النموذج ليتعرف على العلاقات بين مختلف العناصر داخل هذه البيانات. على سبيل المثال، إذا كان الهدف هو بناء نظام يستطيع التعرف على الصور، فإن النموذج يبدأ بتحليل آلاف الصور التي تحتوي على عناصر مختلفة، ويتعلم كيفية تمييز الخصائص المرتبطة بكل عنصر مثل الألوان، الأشكال، أو الأنماط الهندسية [6].



الشكل (2-3): خطوات عمل التعلم الآلي.

عملية بناء النماذج في تعلم الآلة تعتمد بشكل أساسي على البيانات، حيث تُعتبر البيانات هي الأساس الذي يركز عليه النظام لتحسين أدائه. يتم استخدام مجموعة من البيانات المعروفة والمصنفة مسبقاً لتدريب النموذج، بحيث يتعلم كيفية التعامل مع أنواع جديدة من البيانات غير المألوفة. أثناء التدريب، يقوم النموذج بتعديل معلوماته الداخلية بناءً على الأخطاء التي يرتكبها عند تصنيف أو تنبؤ البيانات. كلما زاد حجم وتنوع البيانات المستخدمة في التدريب، أصبح النموذج أكثر قدرة على فهم الأنماط المعقدة

والتكيف مع السيناريوهات المختلفة. هذا يعني أن جودة النموذج تعتمد بشكل كبير على جودة البيانات المدخلة، حيث أن البيانات غير الدقيقة أو غير الممثلة قد تؤدي إلى نتائج مضللة أو غير فعالة [5].

من خلال الجمع بين تقنيات الرياضيات والإحصاء وخوارزميات الحوسبة المتقدمة، يتم تصميم النماذج بحيث تكون قادرة على التعلم من التجربة وتحسين أدائها تدريجيًا. بعد انتهاء مرحلة التدريب، يتم اختبار النموذج باستخدام بيانات جديدة لم يسبق له التعامل معها للتأكد من قدرته على التعميم والاستفادة مما تعلمه سابقًا. بهذه الطريقة، يصبح النموذج جاهزًا لأداء المهام المطلوبة بكفاءة عالية، سواء كانت هذه المهام تتعلق بتصنيف المعلومات، التنبؤ بالنتائج، أو حتى اتخاذ قرارات مستتيرة بناءً على البيانات المتوفرة [6].

3-2-2 تطبيقات التعلم الآلي

- يمكن استخدام هذه التقنية في تصنيف الصور، حيث يتم تدريب النظام على التعرف على الفرق بين صور الحيوانات أو الأجسام المختلفة، مما يساعد في تطبيقات مثل التعرف على الوجوه أو تحديد العناصر في المشاهد الطبيعية.
- يساهم هذا المجال في التنبؤ بالأسعار، مثل تقدير تكلفة المنازل بناءً على مساحتها، موقعها، وحالة السوق، مما يساعد الأفراد والشركات على اتخاذ قرارات استثمارية مدروسة.
- يُستخدم لتحليل المشاعر في النصوص، مثل فهم آراء العملاء حول منتج معين عبر مواقع التواصل الاجتماعي لتحسين جودة الخدمات المقدمة.

- يتيح الكشف عن الأنشطة غير الطبيعية في المعاملات المالية، مما يساعد في التصدي لمحاولات الاحتيال بشكل استباقي.
- يساعد في تقديم اقتراحات شخصية، مثل ترشيح المنتجات أو الأفلام بناءً على سجل التفاعلات السابقة للمستخدم.
- يمكن أن يُستخدم لتقديم توقعات دقيقة حول الطقس، بالاعتماد على بيانات سابقة مثل درجات الحرارة وسرعة الرياح.
- يدعم تطوير أنظمة القيادة الذاتية من خلال تمكينها من فهم البيئة المحيطة، مثل التعرف على المشاة والإشارات المرورية.

3-3 التعلم العميق

يُعتبر التعلم العميق (Deep Learning) جزءًا متقدمًا من مجال تعلم الآلة (Machine Learning)، ولكنه يتميز بقدرته على التعامل مع البيانات بشكل أكثر تعقيدًا وشمولية. في حين يعتمد التعلم الآلي التقليدي على الخوارزميات التي تحتاج إلى استخراج خصائص البيانات يدويًا أو بمساعدة الإنسان، فإن التعلم العميق يتجاوز هذه الحاجة من خلال استخدام شبكات عصبونية متعددة الطبقات التي تعمل على استخلاص الخصائص تلقائيًا. هذا يعني أن النماذج القائمة على التعلم العميق يمكنها تحليل البيانات الخام دون الحاجة إلى خطوات معالجة مسبقة معقدة، مما يجعلها أكثر كفاءة في التعامل مع المعلومات المعقدة مثل الصور، الفيديوهات، أو النصوص [6].

ما يميز التعلم العميق عن التعلم الآلي التقليدي هو قدرته على بناء مستويات متعددة من التمثيل والتعمق تدريجيًا في فهم البيانات (الشكل 3-3). على سبيل المثال، عند التعامل مع صورة، يمكن للشبكات العصبونية العميقة أن تبدأ بتحديد الحواف البسيطة في الطبقة الأولى، ثم تنتقل لتحديد الأشكال الأكثر تعقيدًا في الطبقات التالية، وأخيرًا تتعرف على الكائنات الكاملة في الطبقات النهائية. هذا المستوى من التحليل المتدرج يجعل التعلم العميق أداة قوية لمعالجة البيانات التي تحتوي على مستويات متعددة من التفاصيل والتعقيد، وهو ما قد يكون صعبًا أو مستحيلًا بالنسبة للتعلم الآلي التقليدي الذي يعتمد على خصائص محددة مسبقًا [6].

Key Differentiation		
Machine Learning	Factors	Deep Learning
Manual Extraction	Problem-Solving Approach	Minimal Human Intervention
Supervised & Reinforcement Learning	Training Methods	Autoencoders & Generative Adversarial Networks
Diverse Models	Complexity of Algorithms	Interconnected Neurons
Relies on Structured Data	Interpretability	Leverages Artificial Neural Networks
Distributed Across a Server Cluster	Infrastructure & Data	Reliance on Larger Datasets

الشكل (3-3): الفرق بين التعلم الآلي والتعلم العميق.

بفضل هذه القدرات، أصبح التعلم العميق الخيار الأمثل للعديد من التطبيقات الحديثة التي تتطلب معالجة بيانات كبيرة ومعقدة، مثل التعرف على الكلام، تحليل الصور الطبية، والترجمة الآلية. وعلى الرغم من أن التعلم الآلي التقليدي لا يزال فعالًا في العديد من السيناريوهات، إلا أن التعلم العميق يبرز بشكل

خاص عندما يتعلق الأمر بالتعامل مع كميات هائلة من البيانات غير المنظمة وتحقيق نتائج دقيقة وفعالة [6].

3-3-1 لماذا التعلم العميق لمعالجة الصور؟

تم اختيار التعلم العميق ليكون الأداة المثلى في معالجة الصور بسبب قدرته الفريدة على التعامل مع البيانات المعقدة التي تتسم بها هذه النوعية من المعلومات. تتميز الصور بكونها تحتوي على كميات هائلة من التفاصيل والأنماط التي يصعب على الأساليب التقليدية استخلاصها أو تحليلها بكفاءة. في هذا السياق، يبرز التعلم العميق كخيار متقدم مقارنة بالتعلم الآلي التقليدي، حيث يعتمد على شبكات عصبونية متعددة الطبقات تعمل بشكل مشترك لتحليل البيانات الخام واستخلاص المعلومات منها بطريقة تلقائية ودون الحاجة إلى تدخل بشري مباشر [6].

ما يجعل التعلم العميق أكثر كفاءة هو قدرته على بناء مستويات متدرجة من التمثيل للبيانات. عند التعامل مع صورة، على سبيل المثال، يمكن لهذه الشبكات أن تبدأ بتحديد الخصائص البسيطة مثل الحواف أو الخطوط في المراحل الأولى، ثم تتعمق تدريجياً لتحليل الأنماط الأكثر تعقيداً مثل الأشكال الهندسية وحتى الكائنات الكاملة في المراحل المتقدمة. هذا النهج المتدرج يتيح للنظام فهم الصورة بشكل شامل ومتكامل، مما يجعله قادراً على تقديم نتائج دقيقة للغاية حتى عند التعامل مع بيانات غير منظمة أو معقدة [6].

تعتمد هذه العملية على ما يعرف بالشبكات العصبونية العميقة، وهي نوع متقدم من النماذج الحسابية التي تحاكي الطريقة التي يعمل بها الدماغ البشري في معالجة المعلومات. تحتوي هذه الشبكات على

طبقات متعددة من العقد العصبونية، وكل طبقة تقوم بمعالجة جانب معين من البيانات قبل نقل النتائج إلى الطبقة التالية. هذا التصميم يجعل الشبكات العصبونية العميقة قادرة على استيعاب كميات ضخمة من البيانات وتحليلها بطرق تتجاوز قدرات النماذج التقليدية. وبفضل هذه القدرات، أصبح التعلم العميق الخيار الأمثل لتطبيقات مثل التعرف على الصور، معالجة الفيديوها، والتحليل الطبي الدقيق للصور الإشعاعية، حيث تحتاج هذه التطبيقات إلى مستوى عالٍ من الدقة والقدرة على التعامل مع البيانات المعقدة [6].

الفصل الرابع: الشبكات


العصبونية

4-1 مفهوم الشبكات العصبونية

الشبكات العصبونية هي أحد الأسس الرئيسية في مجال الذكاء الاصطناعي والتعلم العميق، وهي نماذج حسابية مصممة لمحاكاة الطريقة التي يعمل بها الدماغ البشري لمعالجة المعلومات واتخاذ القرارات. تعتمد هذه الشبكات على بنية تتكون من عناصر تُعرف بالعقد العصبونية، والتي تعمل معًا لتحليل البيانات وإنتاج النتائج بشكل مشابه للخلايا العصبية في الدماغ. عند تصميم شبكة عصبونية، يتم التركيز على تقليد العمليات البيولوجية التي يقوم بها الدماغ البشري، حيث تستقبل الخلايا العصبية الإشارات، تعالجها، ثم تنقلها إلى الخلايا الأخرى، وهو ما يتم محاكاته في الشبكات العصبونية باستخدام عمليات رياضية وحسابات متقدمة [6].


تتكون الشبكة العصبونية من عدة طبقات رئيسية، تبدأ بطبقة المدخلات التي تستقبل البيانات الخام مثل الصور أو النصوص أو الإشارات الصوتية. تقوم هذه الطبقة بنقل البيانات إلى الطبقات التالية بعد تنظيمها في شكل يمكن معالجته. بعد طبقة المدخلات تأتي الطبقات المخفية، وهي مجموعة من الطبقات التي تحتوي على العقد العصبونية المسؤولة عن استخلاص الأنماط والعلاقات داخل البيانات. كل عقدة في هذه الطبقات تقوم بإجراء عمليات حسابية على البيانات الواردة إليها، ومن ثم تمرر النتائج إلى العقد الموجودة في الطبقات التالية. هذه العملية تتكرر عبر الطبقات المخفية، مما يتيح للنظام بناء فهم أعمق وأكثر دقة للبيانات. أخيرًا، تأتي طبقة المخرجات التي تعمل على تحويل النتائج المستخلصة إلى إجابات أو قرارات نهائية يمكن استخدامها في التطبيقات المختلفة [6].

Artificial Neural Network



الشكل (1-4): الشبكات العصبونية الاصطناعية.

تحتوي كل طبقة من طبقات الشبكة العصبونية على عدد من العقد، وكل عقدة تعمل كوحدة معالجة صغيرة تقوم بتحليل جزء معين من البيانات. تتفاعل هذه العقد مع بعضها البعض من خلال اتصالات موزونة، حيث يتم ضبط أوزان هذه الاتصالات أثناء عملية التدريب لتحسين أداء الشبكة. تعتمد كل عقدة على مجموعة من القواعد الرياضية لمعالجة البيانات التي تتلقاها، مما يتيح لها تحديد مدى أهمية كل جزء من المعلومات وفقاً للسياق العام. هذا التصميم يجعل الشبكات العصبونية أدوات قوية لمعالجة البيانات المعقدة، حيث يمكنها التعامل مع كميات هائلة من المعلومات واستخلاص الأنماط والعلاقات بطرق دقيقة وفعالة [6].




الشكل (2-4): العصبون.

2-4 الشبكة العصبونية (DNN (Deep Neural Network

الشبكات العصبونية العميقة (DNN) تعد واحدة من أبرز الأدوات المستخدمة في مجال التعلم العميق، وهي نوع متقدم من الشبكات العصبونية المصممة لمعالجة البيانات المعقدة بكفاءة عالية. تعتمد هذه الشبكات على بنية متعددة الطبقات تحتوي على عقد عصبونية تقوم بتحليل البيانات بطريقة تدريجية ومتكاملة. دور الشبكة العصبونية العميقة يتمثل في استخلاص الأنماط والعلاقات المخفية داخل البيانات، مما يجعلها مثالية لتطبيقات مثل التعرف على الصور، معالجة اللغة الطبيعية، والتنبؤ بالأحداث المستقبلية. تعمل هذه الشبكات على تحويل البيانات الخام إلى معلومات قابلة للاستخدام من خلال سلسلة من الخطوات الحسابية التي تبدأ من طبقة المدخلات وتنتهي بطبقة المخرجات [6].

تحديد عدد الطبقات والأوزان في الشبكة العصبونية يعتمد بشكل كبير على طبيعة المشكلة المطروحة ومستوى التعقيد الذي تتطلبه عملية المعالجة. بالنسبة للبيانات البسيطة، قد تكون شبكة ذات عدد قليل من الطبقات كافية لتحقيق النتائج المرجوة. ومع ذلك، عندما يتعلق الأمر بمشاكل أكثر تعقيداً مثل تصنيف الصور عالية الدقة أو الترجمة الآلية، فإن زيادة عدد الطبقات يمكن أن يحسن بشكل كبير من قدرة الشبكة على فهم البيانات واستخلاص المعلومات منها. الأوزان في الشبكة تمثل القيم التي تحدد أهمية كل اتصال بين العقد، ويتم ضبطها أثناء عملية التدريب لتحسين الأداء العام للنظام [6].




الشكل (3-4): الفرق بين الشبكة العصبونية الاصطناعية التقليدية والشبكة العصبونية العميقة.

يلعب الانحياز (Bias) دوراً مهماً في تحسين دقة النموذج وفاعليته. الانحياز هو قيمة ثابتة تُضاف إلى كل عقدة في الشبكة، وتساعد في ضبط نتائج العمليات الحسابية بحيث تكون أكثر توافقاً مع البيانات الفعلية. بدون وجود الانحياز، قد تواجه الشبكة صعوبة في التعامل مع الحالات التي تتطلب تعديلاً إضافياً في النتائج المستخلصة. باستخدام الانحياز، يمكن للشبكة أن تحقق توازناً أفضل بين الأوزان والقيم المدخلة، مما يؤدي إلى تحسين قدرتها على التنبؤ بدقة أعلى. هذا العنصر يساهم بشكل كبير في جعل الشبكات العصبونية العميقة أدوات مرنة وفعالة لحل مجموعة واسعة من المشكلات المعقدة [6].

3-4 دوال التفعيل (Activation Functions)

دوال التفعيل تُعتبر جزءًا أساسيًا من الشبكات العصبونية، حيث تلعب دورًا محوريًا في تحديد كيفية استجابة العقد العصبونية للإشارات الواردة إليها. تعمل هذه الدوال على تحويل القيم الناتجة من العمليات الحسابية داخل العقد إلى قيم محددة يمكن استخدامها في الخطوات التالية من عملية المعالجة. بدون دوال التفعيل، ستكون الشبكة العصبونية مجرد سلسلة من العمليات الخطية، مما يقلل من قدرتها على التعامل مع المشكلات المعقدة. لذا، فإن أهمية دوال التفعيل تكمن في إضافة عنصر غير الخطي إلى النموذج، مما يسمح له بالتعامل مع الأنماط والبيانات المعقدة بكفاءة عالية [6].



الشكل (4-4): دوال التفعيل.

تتمثل الأمثلة الشائعة لدوال التفعيل في التالي:


- **ReLU (Rectified Linear Unit):** تقوم هذه الدالة بتحويل القيم السلبية إلى صفر وتترك القيم الموجبة كما هي، مما يجعلها بسيطة وفعالة في تسريع تدريب الشبكة.
- **Sigmoid:** تنتج هذه الدالة قيمًا بين 0 و 1، وهي مفيدة في الحالات التي تحتاج إلى احتمالات أو نتائج محددة النطاق.
- **Tanh (Hyperbolic Tangent):** مشابهة لـ Sigmoid لكنها تنتج قيمًا بين -1 و 1، مما يساعد في تحقيق توازن أفضل للبيانات.

تضيف دوال التفعيل عنصر غير الخطية إلى النموذج، وهو أمر ضروري لتمكين الشبكات العصبونية من حل المشكلات المعقدة التي لا يمكن معالجتها باستخدام النماذج الخطية فقط. على سبيل المثال، عند التعامل مع بيانات مثل الصور أو النصوص، تكون الأنماط غالبًا غير خطية ومعقدة، وهنا تأتي دوال التفعيل لتوفير المرونة اللازمة للنظام لفهم هذه الأنماط واستخلاص المعلومات منها. هذا العنصر من غير الخطية يعزز قدرة الشبكة على التعلم من البيانات وتحسين أدائها بشكل مستمر، مما يجعلها أكثر فعالية في مجموعة واسعة من التطبيقات [6].

4-4 متى نتوقف عن تدريب النموذج؟

تحديد الوقت المناسب للتوقف عن تدريب النموذج يعد أحد أهم الجوانب في بناء نماذج التعلم العميق. أثناء عملية التدريب، يتم تحديث أوزان الشبكة العصبونية بشكل متكرر لتحسين أدائها على البيانات المستخدمة. ومع ذلك، فإن الإفراط في التدريب قد يؤدي إلى مشاكل خطيرة مثل فقدان النموذج قدرته على التعامل مع بيانات جديدة. يتم تحديد نقطة التوقف المثلى من خلال مراقبة أداء النموذج على

مجموعة بيانات اختبار منفصلة عن بيانات التدريب. عندما يبدأ الأداء على بيانات الاختبار في التدهور بينما يستمر الأداء على بيانات التدريب في التحسن، فإن هذا يشير إلى أن النموذج قد بدأ في التعلم الزائد أو ما يعرف بـ overfitting [6].



الشكل (4-5): مفهوم الـ Overfitting.

يشير مفهوم overfitting إلى الحالة التي يصبح فيها النموذج معقدًا للغاية بحيث يقوم بتذكر تفاصيل بيانات التدريب بدلاً من فهم الأنماط العامة التي يمكن تطبيقها على بيانات جديدة (انظر الشكل). يحدث هذا عادة عندما يكون للشبكة العصبونية عدد كبير جدًا من الطبقات أو العقد، مما يجعلها أكثر عرضة لاستيعاب الضوضاء أو التفاصيل غير المهمة في البيانات. لتجنب هذه المشكلة، يتم استخدام تقنيات مختلفة مثل تقليل تعقيد النموذج، إضافة عقوبات على الأوزان الكبيرة (Regularization)، أو استخدام طريقة تُعرف بـ Dropout التي تعمل على تعطيل بعض العقد بشكل عشوائي أثناء التدريب لمنع النموذج من الاعتماد المفرط على عقد معينة [6].

الحفاظ على توازن بين تعقيد النموذج وأدائه العام هو المفتاح لضمان أنه يمكنه التعامل مع بيانات جديدة بكفاءة. لهذا السبب، يتم دائمًا اختبار النموذج على بيانات لم يسبق له رؤيتها أثناء التدريب، ويتم مراقبة

معدل الخطأ أو الدقة بشكل دقيق. عندما يصل النموذج إلى مستوى مستقر من الأداء على بيانات الاختبار دون تدهور، يتم اعتبار ذلك النقطة المثلى للتوقف عن التدريب. هذه العملية تضمن أن النموذج يحقق أفضل توازن بين التعلم من البيانات والتعميم على سيناريوهات جديدة [6].

الفصل الخامس:

الشبكة العصبية

التلافيفية (CNN)

5-1 مفهوم الشبكة العصبونية CNN

الشبكات العصبونية التلافيفية (CNN) تُعد واحدة من الأدوات الأساسية في مجال معالجة الصور والرؤية الحاسوبية. تم تصميم هذه الشبكات خصيصًا لتحليل البيانات التي تحتوي على بنية ذات بعدين، مثل الصور، حيث تستفيد من العلاقات المكانية بين العناصر الموجودة في هذه البيانات. تلعب CNN دورًا محوريًا في استخلاص الخصائص المهمة من الصور بشكل تلقائي وفعال، مما يجعلها الخيار الأمثل لتطبيقات مثل تصنيف الصور، التعرف على الوجوه، والتشخيص الطبي باستخدام التصوير الإشعاعي. على عكس الشبكات العصبونية العميقة التقليدية (DNN)، التي تعمل بشكل أفضل مع البيانات المسطحة مثل النصوص أو الإشارات الرقمية، فإن CNN تتميز بقدرتها على التعامل مع البيانات ذات البنية المعقدة دون الحاجة إلى إعادة تنظيمها [6].


لفهم الفرق بين CNN و DNN بشكل أوضح، يمكن النظر إلى كيفية معالجة كل شبكة للبيانات. DNN تعتمد على طبقات متصلة بالكامل (Fully Connected Layers)، حيث يتم تحويل جميع البيانات إلى متجهات مسطحة ومعالجتها بطريقة خطية. هذا النهج يفقد العلاقات المكانية بين العناصر في البيانات، مما يجعل DNN أقل كفاءة عند التعامل مع الصور. من ناحية أخرى، تستخدم CNN طبقات تلافيفية (Convolutional Layers) تقوم بتطبيق مرشحات صغيرة على الصورة لاستخلاص الخصائص المحلية مثل الحواف، الزوايا، أو الأنماط المعقدة. بالإضافة إلى ذلك، تحتوي CNN على طبقات تجميع (Pooling Layers) التي تعمل على تقليل حجم البيانات مع الحفاظ على الخصائص المهمة، مما يجعلها أكثر كفاءة في التعامل مع الصور الكبيرة [6].

يوضح الجدول (5-1) الفرق بين الشبكة العصبية CNN والشبكة العصبية DNN.

الجدول (5-1): الفرق بين شبكة CNN وDNN.

المميزات	CNN	DNN
نوع البيانات	مصممة لمعالجة البيانات ذات البعد المكاني (مثل الصور).	تعمل بشكل أفضل مع البيانات المسطحة (مثل النصوص أو الإشارات).
هيكل الشبكة	تحتوي على طبقات تلافيفية وتجميع للحفاظ على العلاقات المكانية.	تحتوي على طبقات متصلة بالكامل، مما يؤدي إلى فقدان العلاقات المكانية.
الخصائص المستخلصة	تستخرج الخصائص تلقائيًا من البيانات باستخدام المرشحات التلافيفية.	تحتاج إلى استخراج الخصائص يدويًا قبل إدخال البيانات إلى الشبكة.
الكفاءة مع الصور	عالية الكفاءة بسبب قدرتها على التعامل مع الصور مباشرة دون تسطيحها.	أقل كفاءة لأنها تتطلب تحويل الصور إلى بيانات مسطحة.
التطبيقات الشائعة	تصنيف الصور، التعرف على الوجوه، التشخيص الطبي باستخدام التصوير.	معالجة النصوص، التنبؤ بالأحداث، تصنيف البيانات البسيطة.

2-5 خطوات عمل الشبكة العصبية CNN



الشكل (5-1): خطوات عمل الشبكة العصبية التلافيفية.

1. الطبقة التلافيفية (Convolutional Layer):

تبدأ عملية عمل الشبكة العصبونية التلافيفية (CNN) بمرحلة تُعرف بالطبقة التلافيفية، وهي المرحلة الأساسية التي تساعد النظام على فهم الصورة. في هذه الطبقة، يتم استخدام مجموعة من الفلاتر التي تعمل كعدسات صغيرة تمر عبر أجزاء مختلفة من الصورة لاستخراج الخصائص المميزة. يمكن اعتبار هذه الفلاتر كأدوات تقوم بفحص الصورة جزءًا جزءًا، حيث تبحث عن أنماط معينة مثل الحواف أو الزوايا أو الأشكال البسيطة. كل مرشح يركز على نوع معين من الخصائص، مما يتيح للشبكة بناء فهم أولي للعناصر الموجودة في الصورة [6].

2. خريطة الخصائص (Feature Map):

بعد مرحلة التلافيف، يتم إنشاء ما يُعرف بخريطة الخصائص (Feature Map)، وهي عبارة عن تمثيل مبسط للخصائص المستخلصة من الصورة. يمكن تخيل خريطة الخصائص كرسم يوضح الأماكن التي تم فيها اكتشاف الأنماط المميزة، مع تسليط الضوء على المناطق الأكثر أهمية. هذه الخريطة لا تكون مجرد نسخة مصغرة من الصورة، بل هي وسيلة لتوصيل المعلومات الأساسية التي تحتاجها الشبكة لفهم محتوى الصورة بشكل أفضل. كل خريطة خصائص تمثل جانبًا معينًا من الصورة، مما يساعد في تجميع صورة شاملة عن العناصر الموجودة فيها [6].

3. طبقة التجميع (Pooling Layer):

في الخطوة التالية، يتم استخدام طبقة تُعرف بطبقة التجميع (Pooling Layer) لتقليل حجم البيانات دون فقدان الخصائص المهمة. تهدف هذه العملية إلى تبسيط البيانات من خلال تقليل عدد القيم في خريطة الخصائص، مما يجعل النظام أكثر كفاءة وأقل تعقيدًا. على سبيل المثال، إذا كانت هناك مجموعة

من القيم المتشابهة في منطقة معينة، يتم استبدالها بقيمة واحدة تمثلها. هذا يساعد في تقليل كمية الحسابات المطلوبة أثناء التدريب، كما يساهم في جعل النموذج أكثر قدرة على التعامل مع التغيرات الطفيفة في الصور، مثل الاختلافات في الإضاءة أو الزاوية [6].

4. مرحلة التسطيح (Flatten Layer):

بعد ذلك، تأتي مرحلة التسطيح (Flatten Layer)، حيث يتم تحويل البيانات إلى شكل ملائم يمكن استخدامه في المراحل التالية. في هذه المرحلة، يتم أخذ جميع القيم الموجودة في خرائط الخصائص وترتيبها في شكل خط مستقيم، مما يسهل على الشبكة التعامل معها كإدخال للطبقات التالية. يمكن اعتبار هذه الخطوة بمثابة تحضير البيانات لدخول المرحلة النهائية، حيث يتم تحويل المعلومات المعقدة إلى شكل مبسط يمكن استخدامه لاتخاذ القرارات [6].


5. طبقة الربط الكامل (Fully Connected Layer):

أخيرًا، تأتي طبقة الربط الكامل (Fully Connected Layer)، وهي المرحلة التي يتم فيها ربط جميع المعلومات المستخلصة من الصورة لإنتاج النتائج النهائية. في هذه الطبقة، يتم تحليل البيانات المجهزة من الخطوات السابقة ومقارنتها مع الأنماط التي تعلمها النظام أثناء التدريب. بناءً على هذه المقارنة، يتم تقديم التوقعات النهائية، مثل تحديد نوع الكائن الموجود في الصورة أو تصنيفها ضمن فئة معينة. هذه الطبقة تعمل كعقل النظام، حيث تجمع بين جميع المعلومات وتستخدمها لاتخاذ القرار النهائي بطريقة دقيقة وفعالة [6].

3-5 الفلاتر في شبكة CNN

تعمل الفلاتر في الشبكات العصبونية التلافيفية (CNN) كأدوات أساسية لاستخلاص الخصائص المهمة من البيانات مثل الصور. يتمثل دور الفلاتر في تحليل أجزاء صغيرة من الصورة باستخدام نوافذ صغيرة تتحرك عبرها للكشف عن الأنماط المميزة، مثل الحواف أو الزوايا أو الأشكال البسيطة. كل فلتر مصمم لتركيز على نوع معين من الخصائص، مما يتيح للشبكة بناء فهم متدرج للعناصر الموجودة في الصورة. عندما يمر الفلتر عبر الصورة، يقوم بإجراء عمليات حسابية على القيم الموجودة في كل منطقة صغيرة، مما يؤدي إلى إنتاج خريطة خصائص تُظهر المناطق التي تحتوي على الأنماط المستهدفة كما هو موضح في الشكل (2-5). هذه العملية تجعل النظام قادرًا على تحويل الصورة إلى مجموعة من المعلومات المفيدة التي يمكن استخدامها في الخطوات التالية [6].

تحديد عدد الفلاتر المناسب يعتمد بشكل كبير على طبيعة المشكلة المطروحة ومستوى التعقيد المطلوب في استخلاص الخصائص. على سبيل المثال، إذا كانت المهمة تتطلب التعرف على أنماط بسيطة مثل الحواف، فقد يكون عدد قليل من الفلاتر كافيًا لتحقيق الهدف. ومع ذلك، في حالات أكثر تعقيدًا مثل تصنيف الصور التي تحتوي على كائنات متعددة أو بيانات متنوعة، قد يكون من الضروري زيادة عدد الفلاتر لضمان استخراج مجموعة أوسع من الخصائص. عدد الفلاتر يؤثر بشكل مباشر على قدرة النظام على فهم التفاصيل الدقيقة في البيانات؛ فكلما زاد عدد الفلاتر، أصبح النظام أكثر قدرة على اكتشاف أنماط معقدة ومتنوعة، مما يعزز دقة النتائج النهائية [6].



الشكل (2-5): آلية عمل الفلتر.

من المهم الإشارة إلى أن اختيار عدد الفلاتر ليس مجرد مسألة زيادة الأداء، بل يجب تحقيق توازن بين التعقيد والكفاءة. زيادة عدد الفلاتر بشكل مفرط قد يؤدي إلى استهلاك موارد حسابية كبيرة دون تقديم فائدة إضافية كبيرة، خاصة إذا كانت المشكلة لا تتطلب هذا المستوى من التعقيد. لذلك، يتم تحديد عدد الفلاتر بناءً على التجربة والاختبار، حيث يتم ضبط هذا العدد لتلبية احتياجات المشكلة المحددة مع ضمان تحقيق أداء متوازن وكفاءة. بهذا الشكل، يصبح عدد الفلاتر عاملاً حاسماً في تعزيز قدرة النظام على استخراج الخصائص المهمة دون الإخلال بكفاءته العامة [6].

الفصل السادس:

النماذج والخوارزميات

المستخدمة


6-1 نماذج التعلم العميق لتصنيف الصور والرؤية الحاسوبية

6-1-1 نموذج ResNet50v2

نموذج ResNet50v2 يُعدّ واحدًا من أبرز معماريات الشبكات العصبية الالتفافية المستخدمة في مجال التعلم العميق، وقد صُمم لمعالجة مشكلة صعوبة تدريب الشبكات العميقة جدًا. الفكرة الأساسية فيه هي إدخال ما يُسمى بالكتل المتبقية Residual Blocks، وهي وحدات تسمح بتمرير المعلومات بشكل مباشر من طبقات سابقة إلى طبقات لاحقة دون أن تفقد تفاصيلها أثناء انتقالها بين المستويات المختلفة للشبكة. هذا الأسلوب يقلل من مشكلة "تلاشي التدرج" التي كانت تواجه النماذج التقليدية، مما يمكن من تدريب شبكات عميقة بدقة وكفاءة أعلى. النسخة v2 من هذا النموذج أضافت تحسينات مهمة في ترتيب العمليات داخل كل كتلة متبقية، مثل إدخال Batch Normalization قبل عمليات الالتفاف، الأمر الذي يساهم في استقرار عملية التعلم وتسريعها [7].

بالنظر إلى المعمارية الموضحة في الشكل (6-1)، نلاحظ أنّ البيانات تبدأ بمرحلة تمهيدية تتضمن عملية Zero Padding لتجهيز حجم المدخلات، تليها طبقة الالتفاف Convolution ثم Batch Normalization وطبقة التنشيط ReLU وأخيرًا Max Pooling، وكلها تهدف إلى استخلاص السمات الأولية وتقليل حجم البيانات مع الاحتفاظ بالمعلومات الأساسية. بعد هذه المرحلة، تمر البيانات عبر سلسلة من الكتل المتبقية الموزعة على خمس مراحل رئيسية (Stages). كل مرحلة تحتوي على وحدات من طبقات الالتفاف والهوية Identity Blocks التي تسمح بتمرير المعلومات بشكل مباشر

لتجنب فقدان السمات المهمة. ومع انتقال البيانات من مرحلة إلى أخرى، تصبح الخصائص المستخلصة أكثر تجريداً ودقة، حيث تلتقط الشبكة تفاصيل معقدة حول الصور [7].



الشكل (6-1): معمارية ResNet50v2.

في المراحل النهائية، تُطبّق عملية Average Pooling لتقليل أبعاد السمات المستخلصة، ثم تُسطّح البيانات عبر طبقة Flattening لتصبح جاهزة للمعالجة بواسطة الطبقة الكاملة الاتصال Fully Connected Layer، والتي تقوم في النهاية بإصدار المخرجات سواء كانت تصنيفاً لفئات صور أو أي مهمة أخرى. بهذه البنية المتكاملة، يستطيع ResNet50v2 الجمع بين العمق الكبير للشبكة والقدرة على التعلم بكفاءة دون أن يعيقه تضائل الإشارات المارة بين طبقاته، وهو ما جعله نموذجاً مرجعياً في العديد من تطبيقات الرؤية الحاسوبية [7].

6-1-2 نموذج ResNet152v2


نموذج ResNet152v2 يُعدّ امتداداً معمّقا لعائلة الشبكات المتبقية Residual Networks، وهو يتميز بامتلاكه 152 طبقة، ما يجعله قادراً على استخلاص تفاصيل دقيقة جداً من الصور والتعامل مع أنماط

معقدة يصعب على النماذج الأقل عمقًا التعرف عليها. وكما في الإصدار السابق ResNet50v2، يعتمد هذا النموذج على فكرة الكتل المتبقية التي تُمكن من تمرير المعلومات من طبقات سابقة إلى لاحقة بشكل مباشر، لتجنب فقدان الإشارات أو ضعفها أثناء انتقالها عبر طبقات كثيرة. النسخة v2 من هذه الشبكة تضيف تحسينات في ترتيب المكونات الداخلية، خصوصًا فيما يتعلق باستخدام Batch Normalization قبل عمليات الالتفاف، مما يجعل عملية التعلم أكثر استقرارًا وكفاءة [7].

أما بالنسبة للمعمارية الموضحة في الشكل (6-2)، فنلاحظ أن البيانات تبدأ من صورة إدخال يتم تمريرها أولًا إلى طبقات التفاف متعددة، تبدأ بفلتر واسع نسبيًا (Conv, 64 7×7) ثم تنتقل عبر عدة طبقات أخرى ذات مرشحات مختلفة (Conv, 64/128/256/512 3×3). هذه المراحل تمثل سلسلة من الكتل المتبقية حيث يتم تكرار العمليات بشكل عميق مع وجود وصلات التفاضلية Skip Connections تربط بين الطبقات، مما يسمح بتجاوز بعض الطبقات ونقل المعلومات مباشرة إلى مراحل متقدمة. بعد المرور عبر هذه المراحل، تُنتج الشبكة مصفوفة سمات عالية الأبعاد (2048×4×4) تحتوي على معلومات مركزة عن الصورة الأصلية [7].

المرحلة التالية هي إعادة تشكيل (Reshape) هذه السمات، تمهيدًا لتهيئتها للجزء المتصل بالكامل (Fully Connected Layers). يتم أولًا تسطيح القيم (Flatten) للحصول على متجه طويل من الأرقام (حجمه 100,352)، ثم تمريره إلى طبقة كثيفة مكونة من 256 وحدة (Dense 256)، وهي خطوة تهدف إلى تقليص الأبعاد مع الاحتفاظ بأهم السمات. بعد ذلك، يتم تطبيق تقنية Dropout لتقليل خطر فرط التعلم (Overfitting) عبر تعطيل بعض الوصلات بشكل عشوائي أثناء التدريب. يليها

طبقة أخرى (Dense 1) مسؤولة عن إنتاج النتيجة النهائية، سواء كانت تصنيفًا ثنائيًا أو متغيرًا عدديًا. وأخيرًا، تمر المخرجات عبر دالة تنشيط (Activation Function) لتوليد القرار النهائي أو الاحتمال الذي يعبر عن تنبؤ النموذج [7].



الشكل (2-6): معمارية ResNet152V2.


بهذا التصميم، يجمع ResNet152v2 بين العمق الكبير والدقة العالية في استخراج الملامح البصرية، مما يجعله أداة قوية في تطبيقات معقدة للرؤية الحاسوبية مثل التعرف على الصور الطبية، أو تصنيف آلاف الفئات بدقة عالية [7].

3-1-6 نموذج InceptionV3

نموذج InceptionV3 يُعدّ من أشهر معماريات الشبكات العصبية الالتفافية المصممة خصيصًا لتحقيق توازن بين الدقة العالية والكفاءة الحسابية. ما يميز هذا النموذج هو أنه لا يكتفي باستخدام طبقة واحدة من الالتفاف كما في الشبكات التقليدية، بل يوظف ما يُسمى بـ الوحدات التفرعية أو Inception

Modules، حيث تُنفذ عدة عمليات التفاف (Convolutions) بأحجام مختلفة من النوافذ بشكل متوازٍ على نفس البيانات، ثم تُدمج نتائجها لإنتاج تمثيل أكثر ثراءً ودقة للسّمات. هذا النهج يمكن النموذج من التقاط تفاصيل بصرية على مستويات مختلفة من الدقة في الوقت نفسه، مما يزيد من فعاليته في التعرف على الأنماط المعقدة داخل الصور [7].

وكما هو موضح في الشكل (3-6)، تبدأ المعمارية بمرحلة الإدخال التي تستقبل صورة بأبعاد $3 \times 299 \times 299$ (أي صورة ملونة بثلاث قنوات: الأحمر والأخضر والأزرق). يلي ذلك جزء أولي يسمى Stem يعمل على تجهيز البيانات عبر عدة طبقات التفاف وتجميع مبدئي. بعد هذه المرحلة، تمر البيانات عبر سلسلة من وحدات Inception-A التي تُكرّر ثلاث مرات، حيث يجري فيها استخلاص السمات البسيطة والمتوسطة. ثم تأتي مرحلة Reduction-A التي تُستخدم لتقليل أبعاد البيانات مع الاحتفاظ بأهم السمات المستخلصة، لتسهيل المعالجة في المراحل الأعمق [7].



الشكل (3-6): معمارية InceptionV3.

في الخطوة التالية، يتم إدخال البيانات إلى مجموعة من وحدات Inception-B التي تُنفَّذ أربع مرات، وفيها تُستخرج ملامح أكثر تعقيدًا للصورة، مع وجود فرع جانبي يُعرف باسم Auxiliary Classifier (Aux)، وهو مصنف مساعد يُستخدم أثناء التدريب لتحسين عملية التعلّم وتقليل فقدان المعلومات. بعد ذلك، تمر البيانات بمرحلة Reduction-B لتقليل الأبعاد مرة أخرى، ثم تدخل إلى وحدات Inception-C التي تُكرَّر مرتين، وفيها تكتمل عملية استخلاص السمات الدقيقة عالية المستوى [7].

عند الوصول إلى المراحل النهائية، تطبق عملية Global Average Pooling التي تختصر كل خريطة سمات إلى قيمة واحدة، مما يقلل عدد المعاملات ويمنع مشكلة الإفراط في التعلّم. أخيرًا، تمر البيانات عبر طبقات كاملة الاتصال (Dense Layers)، حيث تنخفض الأبعاد أولًا إلى 1536 ثم إلى 1000، وهي تمثل عدد الفئات التي يمكن للنموذج تصنيف الصور ضمنها [7].


6-1-4 نموذج Xception

نموذج Xception يُعدّ تطويرًا مباشرًا لعائلة Inception، لكنه اعتمد على فكرة أكثر بساطة وفعالية في الوقت نفسه. بدلاً من استخدام فلاتر متعددة بأحجام مختلفة في نفس الطبقة كما في Inception، قام Xception بتفكيك عملية الالتفاف التقليدية إلى خطوتين منفصلتين تُعرفان باسم Depthwise Separable Convolutions، أي الالتفاف العمقي ثم الالتفاف النقطي. هذا الأسلوب سمح للنموذج بأن يكون أخف حسابيًا وأكثر دقة في استخلاص السمات، خصوصًا مع البيانات الكبيرة والمعقدة [7].

في الشكل (6-4) يظهر مخطط مبسط لهذه الفكرة: تبدأ الصورة المدخلة (مثل صورة الورقة في الرسم) بتمثيلها كعدة خرائط سمات. ثم تُطبق عملية Pointwise Convolution التي تعمل على كل قناة

لونية أو خريطة سمات على حدة باستخدام مرشحات صغيرة جدًا (عادة 1×1)، ما يتيح تقليل عدد القنوات مع الحفاظ على المعلومات الأساسية. بعد ذلك، تأتي مرحلة Depthwise Convolution، حيث يتم تمرير كل خريطة سمات على حدة عبر مرشحات مخصصة، مما يسمح باستخراج تفاصيل مكانية دقيقة من دون دمجها مبكرًا مع قنوات أخرى. في النهاية، تُدمج هذه الخرائط من جديد لتكوين خرائط سمات أكثر ثراءً تعبر عن الصورة بشكل أفضل [7].

ميزة هذا التصميم أنه يُقلل بشكل كبير من عدد المعاملات المطلوبة، وبالتالي يُسرّع عملية التدريب ويجعل النموذج مناسبًا للمهام التي تحتاج إلى موازنة بين الكفاءة الحسابية والدقة العالية. وقد أثبت Xception في العديد من الاختبارات أنه يتفوق على Inception في الأداء مع حجم معاملات أقل، مما جعله خيارًا رئيسيًا في تطبيقات الرؤية الحاسوبية الحديثة مثل تصنيف الصور والكشف عن الكائنات [7].



الشكل (4-6): معمارية Xception.

6-1-5 نموذج MobileNet


نموذج MobileNet يُمثل خطوة مهمة في تصميم الشبكات العصبية الموجهة للأجهزة محدودة القدرة الحاسوبية مثل الهواتف الذكية والأجهزة المحمولة. الفكرة الرئيسية فيه هي تقليل عدد العمليات الحسابية المطلوبة دون التضحية الكبيرة بالدقة، وهو ما يجعله عمليًا جدًا للتطبيقات التي تتطلب سرعة عالية واستهلاكًا منخفضًا للطاقة. اعتمد MobileNet على استخدام تقنية Depthwise Separable Convolution التي سبق توضيحها في نموذج Xception، ولكن بشكل أكثر بساطة وفاعلية لتقليل المعاملات الحسابية [7].

في الشكل (5-6) يمكن ملاحظة كيفية بناء هذه المعمارية: تبدأ الصورة المدخلة بحجم $224 \times 224 \times 3$ وتُمرَّر عبر سلسلة من طبقات الالتفاف (Convolution + ReLU) الموضحة باللون الأزرق، حيث يتم استخراج السمات البصرية تدريجيًا. بعد كل مجموعة من هذه الطبقات، تأتي مرحلة التجميع الأقصى (Max Pooling) باللون الأحمر، والتي تعمل على تقليص الأبعاد المكانية للبيانات مع الاحتفاظ بأهم المعلومات، مما يساعد على تسريع المعالجة وتقليل التعقيد. كلما انتقلنا من طبقة إلى أخرى، نلاحظ أن حجم المصفوفة يقل تدريجيًا (من $112 \times 112 \times 128$ ثم $56 \times 56 \times 256$ وصولًا إلى $7 \times 7 \times 512$)، في حين يزداد عدد السمات المستخلصة [7].

بعد الانتهاء من مراحل الاستخلاص المكثفة، تصل البيانات إلى الجزء المتصل بالكامل (Fully Connected Layers) المبيّن باللون الأخضر. تبدأ هذه المرحلة بتسطيح البيانات وتمثيلها عبر ثلاث طبقات متتالية: الأولى بعدد وحدات كبير (4096 وحدة)، تليها طبقة أخرى بالعدد نفسه لتعزيز قدرات

التعلم، ثم طبقة أخيرة تنتج 1000 مخرج، وهو عدد الفئات المستخدمة عادةً في مجموعة بيانات ImageNet [7].

ما يميز MobileNet أنه يُنفَّذ بشكل خفيف الوزن، حيث يمكن تدريبه وتشغيله بسرعة أكبر بكثير مقارنةً بالنماذج الثقيلة مثل ResNet152v2 أو InceptionV3، مع الحفاظ على مستوى دقة منافس. ولهذا السبب أصبح خيارًا مثاليًا للتطبيقات العملية مثل التعرف على الصور في الهواتف، والرؤية الحاسوبية في الروبوتات، وحتى أنظمة الواقع المعزز [7].



الشكل (5-6): معمارية MobileNet.

6-2 خوارزمية YOLO

يقترح نموذج YOLO (You Only Look Once) استخدام شبكة عصبية متكاملة تقوم بتحديد مواقع الكائنات داخل الصورة (من خلال إطارات التحديد) وتوقع الفئة التي ينتمي إليها كل كائن دفعة واحدة، ومن دون الحاجة إلى خطوات منفصلة. يختلف هذا النموذج جذرياً عن النماذج السابقة في كشف الكائنات، والتي كانت تعتمد على إعادة استخدام نماذج التصنيف (Classifiers) لتأدية مهمة الكشف [8]. من كتاب تعليم الأطفال وطنية


اعتمد YOLO نهجاً مختلفاً كلياً في التعامل مع مشكلة كشف الكائنات، وحقق نتائج رائدة مقارنة ببقية النماذج المخصصة للكشف في الزمن الحقيقي، متفوقاً عليها بهامش كبير من حيث السرعة والكفاءة. فعلى سبيل المثال، تعمل خوارزميات مثل Faster R-CNN من خلال تحديد مناطق يُحتمل وجود كائنات فيها باستخدام شبكة اقتراح المناطق (Region Proposal Network)، ثم تُجري التعرف على هذه المناطق بشكل منفصل. أما YOLO، فيقوم بجميع التنبؤات من خلال طبقة واحدة متصلة بالكامل (Fully Connected Layer)، مما يختصر الخطوات ويزيد من سرعة الأداء [8].

النماذج التي تعتمد على اقتراح المناطق تحتاج إلى تنفيذ عدة تمريرات على الصورة نفسها، في حين أن YOLO يكتفي بتمرير واحد فقط. منذ إصدار YOLO الأول عام 2015، تم تطوير عدة إصدارات جديدة من النموذج، وقد أضاف كل إصدار تحسينات على ما سبقه، سواء من حيث السرعة أو الدقة أو الكفاءة العامة [8].

6-2-1 كيف تعمل خوارزمية YOLO؟

تعتمد خوارزمية YOLO (اختصاراً لـ You Only Look Once) على فكرة بسيطة وفعّالة، وهي تحليل الصورة دفعة واحدة لتحديد مواقع الكائنات داخلها وتسمية كل كائن منها بشكل مباشر. تقوم الخوارزمية بتقسيم الصورة إلى شبكة من الخلايا، وتكون كل خلية مسؤولة عن محاولة التنبؤ ما إذا كان هناك كائن ضمن نطاقها، وإذا وُجد، فإنها تقدّر مكانه بدقة على شكل "صندوق محيط" يحتوي على معلومات الموقع والحجم. الشكل (3-8) يوضح هذه العملية بشكل مرئي؛ ففي البداية تُعرض الصورة الأصلية، ثم يتم تقسيمها إلى شبكة، وتبدأ الخلايا بتحليل محتوى كل جزء، وبعدها تُرسم صناديق حول الكائنات المكتشفة مثل الكلب والدراجة والسيارة، مع تسميات لكل منها [8].

تبدأ الصورة رحلتها داخل نموذج YOLO بمرورها في شبكة عصبية تسمى DarkNet، حيث تُستخرج منها خصائص بصرية مهمة. بعدها، تُمرر هذه الخصائص إلى طبقات عصبية متصلة بالكامل (fully connected layers) تقوم بتوليد التوقعات المتعلقة بموقع كل كائن واحتمال انتمائه لفئة معينة. يظهر ذلك في الجزء السفلي من الشكل (3-8) حيث يتم تمثيل الصورة المدخلة بحجم $448 \times 344 \times 3$ ، ويتم استخراج خصائصها عبر شبكة DarkNet لتصبح بحجم $7 \times 1024 \times 7$ ، ثم تمر على طبقة فيها 4096 وحدة عصبية، وتخرج النتيجة على شكل شبكة $7 \times 307 \times 3$. كل خلية من الشبكة تكون مسؤولة عن التنبؤ بعدة صناديق، وكل صندوق يحتوي على خمسة عناصر رئيسية: الإحداثيات (x, y) لمركز الكائن، العرض (w)، الارتفاع (h)، ودرجة الثقة (object score)، بالإضافة إلى احتمالات تصنيفه ضمن الفئات الممكنة (مثل كلب، دراجة، سيارة وغيرها) [8].



الشكل (6-6): هيكل خوارزمية YOLO.


يمكن تلخيص خطوات عمل YOLO فيما يلي:

1. يتم إدخال الصورة إلى شبكة عصبية تلافيفية (CNN) لاستخراج الخصائص المهمة منها.
2. تُمرر هذه الخصائص إلى طبقات عصبية كثيفة لتوقع إحداثيات الصناديق واحتمالات الفئات.
3. تُقسّم الصورة إلى شبكة من الخلايا، بحيث تتنبأ كل خلية بعدة صناديق تصف احتمال وجود كائن فيها.
4. يخرج النموذج بمجموعة من الصناديق المصحوبة باحتمالات التصنيف لكل خلية في الشبكة.
5. يتم تطبيق خوارزمية تُدعى Non-Max Suppression لإزالة الصناديق المتكررة والمتداخلة، مع الاحتفاظ فقط بالصندوق الذي يحمل أعلى درجة ثقة.
6. تكون النتيجة النهائية مجموعة صناديق مرفقة بتسميات الفئات، تمثل الكائنات المكتشفة في الصورة.

من أبرز ما يميز YOLO هو أنه يعالج الصورة دفعة واحدة، مما يجعله سريعًا جدًا مقارنة بالخوارزميات التي تستخدم مرحلتين للكشف، مثل R-CNN والإصدارات المتقدمة منه.

3-6 خوارزمية شجرة القرار (Decision Tree)

شجرة القرار هي إحدى خوارزميات التعلم الخاضع للإشراف غير المعلمية التي تُستخدم في مهام التصنيف والانحدار، وتتميز ببنيتها الهرمية التي تشبه مخططاً انسيابياً يبدأ بعقدة جذرية تتفرع منها المسارات لتصل إلى عقد داخلية تُجري عمليات تقييم استناداً إلى السمات المتاحة، وينتهي الأمر بعقد ورقية تمثل المخرجات النهائية لجميع الحالات داخل مجموعة البيانات. وتستند آلية التعلم فيها إلى مبدأ التقسيم والسيطرة عبر البحث عن أفضل نقاط الانقسام بطريقة جشعة متكررة من الأعلى إلى الأسفل، حيث يُعاد تقسيم البيانات إلى مجموعات أكثر تجانساً حتى تُصنّف معظم السجلات ضمن فئات محددة. غير أن حجم الشجرة يلعب دوراً حاسماً في نقاء العقد الطرفية، فالأشجار الصغيرة غالباً ما تحقق نتائج أنقى، في حين أن التوسع في عدد الفروع قد يؤدي إلى تجزئة البيانات والإفراط في التعلم، مما يقلل من كفاءة النموذج. ومن هذا المنطلق، يُفضل الحفاظ على البنية الأبسط انسجاماً مع مبدأ موس أوكام الذي يرى أن التفسير الأبسط غالباً هو الأفضل، ويُعتمد على أسلوب التقليم لإزالة الفروع عديمة الأهمية بهدف تقليل التعقيد وتحسين الأداء، مع إعادة التحقق من فعالية النموذج باستخدام التحقق المتقاطع. ولزيادة الدقة وتجاوز حدود الشجرة المفردة، يمكن دمج عدة أشجار قرار في إطار جماعي يُعرف بالغابة العشوائية، حيث تُدمج نتائجها معاً لإعطاء تنبؤات أكثر موثوقية ومرونة [9].



الشكل (6-7): المكونات الأساسية لشجرة القرار: العقدة الجذرية، العقد الداخلية، والعقد الورقية.

6-3-1 أنواع أشجار القرار

تُعدّ خوارزمية Hunt's Algorithm، التي طُوّرت في ستينيات القرن الماضي لنمذجة التعلم البشري في علم النفس، الأساس الذي بُنيت عليه العديد من خوارزميات أشجار القرار الشائعة، ومن أبرزها ما يلي [9]:

- **ID3**: يُنسب تطوير هذه الخوارزمية إلى Ross Quinlan، واسمها اختصار لـ Iterative Dichotomiser 3. تعتمد الخوارزمية على مقاييس Entropy و Information Gain لتقييم نقاط الانقسام المرشحة. بعض أبحاث Quinlan حول هذه الخوارزمية تعود إلى عام 1986.
- **C4.5**: تُعتبر هذه الخوارزمية نسخة مطوّرة من ID3، طوّرها أيضًا Quinlan. وتُستخدم فيها مقاييس Information Gain أو Gain Ratio لتحديد أفضل نقاط الانقسام داخل الشجرة.

- **CART**: وهو اختصار لـ Classification and Regression Trees، وقد قُدمت هذه الخوارزمية بواسطة Leo Breiman. تعتمد بشكل أساسي على مقياس Gini Impurity لاختيار الخاصية المثلى للانقسام. ويُستخدم هذا المقياس لتحديد مدى احتمال تصنيف سمة مختارة بشكل خاطئ، حيث يُعدّ انخفاض قيمة Gini Impurity مؤشرًا على جودة أعلى للانقسام.

6-4 خوارزمية الغابة العشوائية (random Forest)


خوارزمية الغابة العشوائية هي إحدى أساليب التعلم الآلي التي ابتكرها Leo Breiman و Adele Cutler، وتقوم فكرتها على دمج مخرجات عدة أشجار قرار في نموذج واحد من أجل الوصول إلى تنبؤ أكثر دقة. وتتميز بسهولة الاستخدام ومرونتها في التعامل مع مشكلات التصنيف والانحدار على حد سواء، الأمر الذي جعلها من أكثر النماذج انتشارًا في الممارسة العملية. تعتمد الغابة العشوائية على مبدأ التعلم الجماعي (Ensemble Learning)، حيث يُدرَّب عدد كبير من المصنفات المستقلة ثم تُدمج نتائجها لاستخلاص المخرج النهائي الأكثر دقة. ومن بين أشهر أساليب التعلم الجماعي أسلوب Bagging أو التجميع بالاستبدال، الذي قدمه Breiman عام 1996، حيث يُعاد أخذ عينات عشوائية من بيانات التدريب مع السماح بتكرار العناصر، ثم تُبنى عدة نماذج مستقلة على هذه العينات، وبعدها تُدمج نتائجها سواء بالتصويت للأغلبية في حالة التصنيف أو بحساب المتوسط في حالة الانحدار، وهو ما يقلل التباين ويُحسِّن من دقة النموذج. وتمثل الغابة العشوائية امتدادًا لهذا الأسلوب من خلال إدخال عنصر إضافي وهو العشوائية في اختيار السمات (Feature Randomness)، إذ لا تقتصر على تقسيم البيانات بطرق مختلفة فقط، بل تختار أيضًا مجموعة فرعية من الخصائص في كل مرة يُبنى فيها

انقسام داخل الشجرة. هذه الإضافة تقلل من الترابط بين الأشجار وتجعل كل واحدة منها مستقلة إلى حد كبير، وهو ما يساعد على الحد من مشكلات التحيز والإفراط في التعلم التي قد تواجه شجرة القرار المفردة. وبفضل هذه المزايا، يُعد نموذج الغابة العشوائية أكثر قدرة على التنبؤ الدقيق حتى مع البيانات المعقدة والوضائية، لأنه يجمع بين قوة التعميم وسهولة التنفيذ [10].

6-4-1 كيف تعمل خوارزمية الغابة العشوائية؟

خوارزمية الغابة العشوائية لديها ثلاث إعدادات رئيسية يجب تحديدها قبل البدء بالتدريب، وهي: حجم العقدة (أي كم عدد العناصر التي يجب أن تتجمع قبل أن تُنشأ عقدة جديدة في الشجرة)، وعدد الأشجار التي ستُبنى داخل الغابة، وعدد الخصائص التي تُختار عشوائيًا في كل مرة. بعد ضبط هذه الإعدادات، يمكن للنموذج أن يعمل على مشكلات التصنيف (اختيار الفئة الصحيحة) أو الانحدار (التنبؤ بقيمة رقمية) [10].

فكرة الغابة العشوائية أنها تتكون من مجموعة كبيرة من أشجار القرار. كل شجرة يتم بناؤها على عينة من البيانات مأخوذة من مجموعة التدريب بطريقة تسمح بتكرار العناصر، وتسمى هذه العينة Bootstrap Sample. ومن بين هذه العينة يُترك نحو ثلث البيانات جانبًا ليُستخدم لاحقًا كبيانات اختبار تسمى Out-of-Bag (OOB). ولزيادة التنوع بين الأشجار، لا يتم استخدام جميع الخصائص عند كل انقسام، بل تُختار مجموعة صغيرة منها بشكل عشوائي، وهذا يجعل كل شجرة مختلفة عن الأخرى ويقلل من التشابه بينها [10].



الشكل (6-8): تمثيل مرئي لآلية عمل الغابة العشوائية.

طريقة التنبؤ تعتمد على نوع المشكلة: فإذا كان الهدف هو التنبؤ بقيمة رقمية (مثل السعر أو العمر)، تُحسب النتيجة بأخذ متوسط مخرجات الأشجار. أما إذا كان الهدف هو تصنيف البيانات (مثل: هل البريد الإلكتروني "مزعج" أو "غير مزعج")، فيتم الاعتماد على تصويت الأغلبية، أي الفئة التي تتكرر أكثر بين نتائج الأشجار. وأخيرًا، تُستخدم بيانات الـ OOB للتحقق من صحة النموذج بطريقة شبيهة بالتحقق المتقاطع، مما يساعد على ضمان دقة التنبؤ النهائي [10].

5-6 خوارزمية SVC

المصنّف القائم على آلات متجهات الدعم (Support Vector Classifier - SVC) هو نوع من خوارزمية Support Vector Machine - SVM يُستخدم في مهام التصنيف. وتُعد SVM نموذجًا من نماذج التعلم الخاضع للإشراف، يهدف إلى إيجاد المستوى الفائق (Hyperplane) الذي يفصل بين

نقاط البيانات التابعة لفئات مختلفة في فضاء عالي الأبعاد. الهدف الأساسي من هذه الخوارزمية هو تعظيم الهامش بين المستوى الفاصل وأقرب نقاط بيانات من كل فئة، والتي تُسمى نقاط الدعم (Support Vectors) [11].

6-5-1 المعاملات الأساسية

1. Kernel: دالة النواة المستخدمة لتحويل البيانات إلى فضاء ذي أبعاد أعلى. من النوى الشائعة:

linear، poly، وrbf.

2. C: معامل التنظيم الذي يتحكم في الموازنة بين زيادة الهامش وتقليل أخطاء التصنيف.

3. gamma: معامل النواة الخاص بـ rbf و poly و sigmoid.

4. decision_function_shape: شكل دالة القرار، ويمكن أن يكون ovr (واحد ضد الباقي) أو

ovo (واحد ضد واحد).

في أسلوب One-vs-Rest (OVR) يُدرَّب مصنّف لكل فئة مقابل جميع الفئات الأخرى، وتُعيد دالة

القرار قيمًا لكل فئة على حدة. أما في أسلوب One-vs-One (OVO) فيُدرَّب مصنّف لكل زوج من

الفئات، وتُعيد دالة القرار القيم الخاصة بكل زوج من هذه الفئات [11].

الفصل السابع: بناء

النظام النهائي

7-1 تجهيز المكتبات والبيئات البرمجية

7-1-1 المكتبات البرمجية

1. Ultralytics: تُستخدم مكتبة Ultralytics بشكل واسع في تطبيقات الرؤية الحاسوبية، حيث توفر

بيئة جاهزة لبناء وتدريب نماذج التعرف على الأجسام بالاعتماد على عائلة نماذج YOLO. تمتاز بسهولة الاستخدام ودعمها لإجراءات مثل التدريب، التقييم، ونشر النماذج، مما يجعلها مناسبة لتطبيقات الذكاء الاصطناعي العملية.

2. TensorFlow: تُعد TensorFlow من أشهر مكتبات التعلم العميق مفتوحة المصدر، إذ توفر

مجموعة متكاملة من الأدوات لبناء الشبكات العصبية والتعامل مع البيانات الضخمة. وتدعم هذه المكتبة عمليات التدريب على وحدات المعالجة الرسومية (GPU) لتسريع الأداء، إضافة إلى توفير إمكانيات واسعة للنشر عبر منصات مختلفة.

3. Tkinter: تُعتبر Tkinter المكتبة القياسية في بايثون لتطوير الواجهات الرسومية. توفر أدوات

جاهزة لبناء النوافذ والقوائم والأزرار، ما يتيح إنشاء تطبيقات تفاعلية تسمح بعرض نتائج النماذج للمستخدمين بطريقة سهلة وواضحة.

4. Scikit-learn (sklearn): تمثل Scikit-learn إحدى أهم مكتبات التعلم الآلي، إذ تضم

خوارزميات متعددة للتصنيف والانحدار والتجميع، إضافة إلى أدوات مساعدة في معالجة البيانات مثل تقسيم العينات وتطبيع القيم. وتُستخدم بكثرة في بناء النماذج الإحصائية وتقييم أدائها بكفاءة.

7-1-2 البيئات

1. Visual Studio Code (VS Code): يُعد VS Code من أشهر البيئات البرمجية مفتوحة

المصدر التي طوّرتها شركة مايكروسوفت، حيث يتميز بخفته وسرعته ودعمه لعدد كبير من لغات البرمجة من خلال الإضافات (Extensions). يوفر بيئة متكاملة للبرمجة تتيح التحرير، التصحيح، وتشغيل الأكواد بكفاءة، إضافة إلى دعمه للتكامل مع أدوات التحكم في الإصدارات مثل Git، مما يجعله مناسباً لتطوير المشاريع البرمجية الكبيرة والصغيرة على حد سواء.


2. Jupyter Notebook: يمثل Jupyter Notebook بيئة تفاعلية قوية تُستخدم بكثرة في مجالات

تحليل البيانات والتعلم الآلي. تتيح هذه البيئة كتابة وتنفيذ الأكواد خطوة بخطوة مع إمكانية إضافة الشرح والنصوص والصور، مما يجعلها أداة تعليمية وبحثية متميزة. كما تسمح بدمج الأكواد مع الرسوم البيانية ونتائج النماذج في واجهة واحدة، الأمر الذي يسهل عرض الأفكار وتحليل البيانات بشكل منظم وواضح.

7-2 واجهات النظام


يوضح الشكل (7-1) الواجهات الرئيسية للنظام المقترح، حيث تنطلق العملية من الواجهة الرئيسية التي تمثل نقطة البداية لجميع المستخدمين. من خلالها يمكن اختيار مسار التعامل مع الصور أو مسار البيانات المخبرية. في حالة التنبؤ عبر الصور باستخدام YOLO، توفر الواجهة خيارات واضحة مثل رفع صورة من الجهاز، ثم إظهار نافذة خاصة بنتيجة الاكتشاف، مع إمكانية عرض تفاصيل إضافية حول وجود الورم. أما في حالة التنبؤ عبر بيانات المختبر المخزنة في ملفات إكسل، فتتفرع الواجهة إلى

عدة نوافذ فرعية، تشمل إدخال البيانات يدويًا من خلال حقول مخصصة، أو رفع ملف إكسل جاهز، أو إرفاق صورة تقرير مخبري. كما تتيح الواجهة في هذا المسار عرض نتائج التحليل في نافذة مخصصة وحفظها في ملف جديد. وبهذا التنظيم، يُظهر المخطط تسلسلاً منظماً للواجهات يسهّل على المستخدم التنقل بين مختلف النوافذ والوصول إلى الخيارات المطلوبة بطريقة مرنة وسلسة.




الشكل (7-1): مخطط واجهات النظام.

3-7 مخطط خوارزمية العمل



الشكل (7-2): مخطط خوارزمية نظام معالجة الصور باستخدام YOLO.




الشكل (3-7): مخطط خوارزمية عمل مسار تحليل البيانات.

الخوارزمية الموضحة في الشكل (2-7) تمثل المسار الخاص بالتعامل مع الصور باستخدام نموذج YOLO، حيث تبدأ بتحميل النموذج ثم تحميل الصورة المستهدفة. بعد ذلك يدخل النظام في حلقة تكرارية يتم من خلالها أخذ الإطار الحالي ومعالجته عبر تمريره للنموذج من أجل تنفيذ عملية الكشف والتعرف. يقوم النموذج بإنتاج النتيجة المتوقعة وعرضها مباشرة على الواجهة، ثم يُعاد التحقق من استمرار عمل النظام أو إنهائه. فإذا اختار المستخدم الإنهاء يتوقف البرنامج، بينما إذا لم يتم الإنهاء تستمر


العملية في نفس التسلسل. وبهذا يوفّر المسار آلية واضحة لمعالجة الصور خطوة بخطوة مع عرض النتائج في الزمن نفسه.

أما في الشكل (7-3) فتُعرض الخوارزمية الخاصة بمسار التعامل مع بيانات الإكسل، حيث تبدأ بتحميل النموذج المستخدم في عملية التنبؤ، ثم استخراج البيانات من ملف Excel المرفق. بعد ذلك تمر هذه البيانات بمرحلة تنظيف لضمان خلوها من القيم الناقصة أو غير الصالحة وتجهيزها بالشكل الملائم. يلي ذلك تمرير البيانات المنظّفة إلى النموذج من أجل إجراء عملية التوقع، ثم تُعرض النتيجة النهائية على واجهة المستخدم بشكل منظم وواضح. يوضح هذا المسار الآلية التي يتم من خلالها الاستفادة من البيانات المخزنة في ملفات إكسل وربطها بالنموذج للحصول على مخرجات دقيقة وموثوقة.


7-4 التنفيذ النهائي




الشكل (7-4): الواجهة الرئيسية للنظام.




الشكل (5-7): واجهة رفع الصور (YOLO).



الشكل (6-7): نتيجة الكشف عن الورم.



الشكل (7-7): واجهة إدخال البيانات يدويا أو عبر ملف إكسل.



الشكل (7-8): واجهة التنبؤ بالاعتماد على البيانات مع إظهار النتيجة.

الشكل (9-7): ملف إكسل يحوي بيانات المريض والنتيجة المتوقعة.

الفصل الثامن : النتائج

والتوصيات

أظهرت نتائج المشروع أن النظام المقترح قدّم أداءً متميزاً في تشخيص سرطان الثدي من خلال الاعتماد على مسارين متكاملين: الأول يعتمد على تحليل صور الأشعة باستخدام خوارزمية YOLO، والثاني على تحليل بيانات الفحوصات المخبرية عبر خوارزمية الغابة العشوائية. فقد أثبتت التجارب أن دمج هذين المسارين يرفع من مستوى الدقة والموثوقية مقارنة باستخدام أي منهما بشكل منفصل، إذ مكّن النظام من استخلاص خصائص بصرية دقيقة من الصور الطبية، وفي الوقت ذاته الاستفادة من البيانات الرقمية التي توفرها التحاليل المخبرية. كما أظهرت النتائج أن سرعة معالجة البيانات والصور كانت عالية، الأمر الذي ساعد على تقليل الزمن اللازم للحصول على التوقعات مقارنة بالطرق التقليدية. كذلك ساهمت الواجهات المصممة بعناية في جعل النظام أكثر سهولة في الاستخدام، حيث تمكن المستخدم من إدخال البيانات بعدة طرق سواء عبر تحميل الصور، أو رفع ملفات إكسل، أو إدخال القيم يدوياً، وهو ما عزز من مرونة النظام وقابليته للتطبيق في بيئات طبية متنوعة. ومن خلال هذه النتائج يمكن القول إن النظام يوفّر أداة فعّالة لدعم الأطباء وتحسين جودة التشخيص مع تقليل احتمالات الخطأ البشري، إضافة إلى إمكانية دمجهِ بسهولة في الأنظمة الطبية الإلكترونية المعتمدة في المستشفيات والمراكز الصحية.

بناءً على ما تم التوصل إليه، يمكن تقديم مجموعة من التوصيات التي تدعم تطوير المشروع مستقبلاً:

- توسيع قاعدة البيانات المستخدمة للتدريب والاختبار بحيث تشمل عينات أكبر وأكثر تنوعاً لضمان تحسين دقة النموذج وقدرته على التعميم.

- إدماج تقنيات تعلم عميق إضافية مثل الشبكات العصبونية المتكررة لتحليل البيانات الزمنية أو التسلسلية المرتبطة بتاريخ المريض.
- تطوير النظام ليشمل القدرة على تشخيص أنواع أخرى من الأورام أو الأمراض التي يمكن رصدها عبر الصور الطبية لتعزيز القيمة السريرية للتطبيق.
- تحسين تكامل النظام مع منصات السجلات الطبية الإلكترونية لتسهيل مشاركة البيانات والنتائج بين مختلف الأقسام الطبية.
- الاهتمام بواجهة المستخدم عبر دعم لغات متعددة وتوفير أدوات مرئية أو تنبيهات توضح النتائج بشكل أوضح لغير المختصين.
- إجراء تجارب تطبيقية في بيئات عمل حقيقية داخل المؤسسات الطبية لقياس فعالية النظام وكفاءته عند استخدامه على أرض الواقع.

المراجع

[1] World Health Organization (WHO). (2021). Breast cancer: Key facts. Retrieved from <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>

[2] World Health Organization. (2024, March 13). Breast cancer. WHO. Retrieved August 24, 2025, from <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>

[3] Santillan-Benítez, J. G., Mendieta-Zerón, H., Gómez-Oliván, L. M., Torres-Juárez, J. J., González-Bañales, J. M., Hernández-Peña, L. V., & Ordóñez-Quiroz, A. (2013). The tetrad BMI, leptin, leptin/adiponectin (L/A) ratio and CA 15-3 are reliable biomarkers of breast cancer. *Journal of Clinical Laboratory Analysis*, 27 (1), 12–20.

[4] Cai, L., Gao, J., & Zhao, D. (2020). A review of the application of deep learning in medical image classification and segmentation. *Annals of Translational Medicine*, 8.(11)

[5] Russell, S. J., & Norvig, P. (2020). *Artificial intelligence: A modern approach* (4th ed.). Pearson.

[6] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

[7] Zhang, Q., Li, Y., Chen, X., & Wang, H. (2024). A comprehensive survey of convolutions in deep learning: Applications, challenges, and future trends. *arXiv*. <https://arxiv.org/pdf/2402.15490>

[8] Kundu, R. (2023, January 17). YOLO: Algorithm for object detection explained [+examples]. V7 Labs. <https://www.v7labs.com/blog/yolo-object-detection>

[9] IBM. (n.d.). What is a decision tree? IBM Think. Retrieved May 23, 2025, from <https://www.ibm.com/think/topics/decision-trees>

[10] IBM. (n.d.). What is random forest? IBM Think. Retrieved May 23, 2025, from <https://www.ibm.com/think/topics/random-forest>

[11] GeeksforGeeks. (2025, July 23). Understanding Scikit-learn's SVC: Decision Function and Predict. Retrieved from https://www.geeksforgeeks.org/machine-learning/understanding-scikit-learns-svc-decision-function-and-predict/#google_vignette