



الجمهورية العربية السورية
وزارة التعليم والبحث العلمي
الجامعة الوطنية الخاصة
قسم هندسة الحاسوب

مشروع أعد لنيل درجة الإجازة في بكالوريوس هندسة الحاسوب بعنوان:

نظام ذكي لحساب عدد السعرات الحرارية باستخدام الرؤية الحاسوبية

إعداد الطالبة:

رؤى باسم الأحمد

إشراف:

د. لينا مراد

2025-2024

إهداء

إلى من أحمل اسمه بكلّ فخر، إلى من حصّد الأشواك عن دربي ليمهّد لي طريق العلم، إلى الرجل الأول، ومثلي

الأعلى في الحياة... بابا الغالي

رؤيتك تبسم هي أجمل لحظاتي، كتّ لي نعم الأب، رعيت مشاعري، وثقت بي، شجّعني...

إنّني يا أبي أرى الدنيا من خلال عينيك الحنونتين.

"أنت عالمي"... أحبك.

إلى حبيبتي ورقة عيني، إلى القلب النابض، معلمتي الأولى، أعظم وأحنّ إنسانة في الوجود... ماما الغالية

لا أحد يا أمي يشبه طيبتك وبقاءك، أنت كلّ شيء جميل في هذه الدنيا،

وكلّ اللحظات السعيدة أساسها أنت، أينما تكونين يا أمي يكون منزلي.

"أنت كزّي"... أحبك.

إلى إخوتي الأحبة: وائل، عبد الرحمن، صلاح الدين، عمر

أتم الأروع، والأفضل، حياتي تزداد حلاوة بوجودكم.

لطالما احتيت بكم، ووجدتكم دائماً سنداً لي، تفرحون لفرحي، وتفخرون بنجاحي كأنه نجاحكم.

"أتم أحبائي"... أحبكم.

إلى صديقتي وخلي، ملاذي وظلي،

بعضي وكلي، **أختي** وشريكتي في النجاح، مساندتي في الحياة، رفيقتي منذ الصغر...

إنني يا أختي أتباهي بك، كما يتباهى المرء بإنجازهِ الوحيد، كل شيء يا أختي يصبح بوجودك أجمل.

"أنتِ وحيدتي" ... أحبك.

إلى دكتورتي المشرفة **الدكتورة لنا مراد**، شكراً لثقتك، دعمك، وتوجيهك الكريم.

لقد كنتِ خير مُعينة وملهمة في هذا الطريق.

كل التقدير والامتنان لك... أحبك في الله.

إلى جميع **أساتذتي** الذين رافقوني طوال مشواري الدراسي،

وإلى كل من قدّم لي العون، وبالخير أوصاني...

لكم جميعاً أسمى عبارات الامتنان والتقدير.

ملخص المشروع:

يهدف هذا المشروع إلى تطوير نظام ذكي ودقيق وسريع لحساب السعرات الحرارية في المنتجات الغذائية اعتمادًا على الصور، من خلال تحليل مكونات الأطعمة تلقائيًا وتقدير قيمها الغذائية بدقة. يُقدّم النظام حلاً مبتكرًا يتجاوز التحديات التقليدية مثل عدم دقة الحساب اليدوي وصعوبة تقدير الكميات، مما يمكّن المستخدمين من متابعة استهلاكهم الغذائي بسهولة ووعي أكبر. يعتمد المشروع على خوارزمية YOLO للكشف عن مكونات الطعام، واستخدام مكتبة Ultralytics لتحميل النموذج وتحليل الصور بشكل سريع وفعال. كما يتم بناء الواجهة الرئيسية باستخدام Tkinter لتوفير تجربة مستخدم تفاعلية، وتستفيد بيئة التطوير من Visual Studio Code كأداة تحرير وتنظيم الأكواد.

يُستخدم OpenCV لمعالجة الصور بدقة، ويتيح النظام تحسين البيانات باستخدام منصة Roboflow. يدمج المشروع تقنيات الرؤية الحاسوبية والتعلم العميق لتقديم أداة فعالة تساهم في تعزيز الوعي الغذائي، ودعم القرارات الصحية، وتقديم فائدة عملية لمرضى السكري والرياضيين وأخصائيي التغذية، بما ينسجم مع مفهوم "الصحة الذكية" في العصر الرقمي.

الكلمات المفتاحية:

حساب السعرات الحرارية، رؤية حاسوبية، تعلم عميق، YOLO، صحة ذكية.

PROJECT SUUMARY:

This project aims to develop a smart, accurate, and fast system for calculating the caloric content of food products based on images, by automatically analyzing the components of foods and estimating their nutritional values accurately. The system provides an innovative solution that overcomes traditional challenges such as the inaccuracy of manual calculations and the difficulty of estimating quantities, enabling users to monitor their food intake with greater ease and awareness. The project relies on the YOLO algorithm for detecting food components, using the Ultralytics library to load the model and analyze images quickly and effectively. The main interface is built using Tkinter to provide an interactive user experience, with Visual Studio Code used as the development environment for code editing and organization. OpenCV is utilized for precise image processing, and the system benefits from data enhancement via the Roboflow platform. The project integrates computer vision and deep learning techniques to provide an effective tool that contributes to enhancing nutritional awareness, supporting health-related decisions, and offering practical benefits for diabetics, athletes, and nutritionists, aligning with the concept of "smart health" in the digital age.

Keywords:

Calorie calculation, Computer Vision, Deep Learning, YOLO, Smart Health

المحتويات

1	الفصل الأول: مقدمة	1
2	1-1 أهمية حساب السرعات الحرارية ودور التقنية الحديثة	
8	2-1 التعريف بالمشروع	
9	3-1 أهمية المشروع الصحية والتقنية	
11	4-1 أهداف المشروع	
13	الفصل الثاني: الإطار النظري ومراجعة الدراسات السابقة	13
14	1-2 تطور الذكاء الاصطناعي	
15	2-2 تعلم الآلة (Machine Learning)	
16	1-2-2 آلية عمل تعلم الآلة	
19	2-2-2 لماذا لا يكفي تعلم الآلة لمعالجة الصور المعقدة؟	
22	3-2 التعلم العميق (Deep Learning)	
23	1-3-2 الشبكات العصبية الاصطناعية (Neural Networks)	
37	4-2 الدراسات والمشاريع السابقة	
37	1-4-2 تطبيق SnapCalorie	
39	2-4-2 تطبيق Calorie Mama	

40	 Cal AI تطبيق 3-4-2
43	 Roboflow ومنصة YOLO خوارزمية الثالث: الفصل 3
44	 YOLO خوارزمية 1-3
44	 تمهيد 1-1-3
44	 تصنيف الكائنات 2-1-3
45	 تحديد الكائنات 3-1-3
46	 (Region-based CNN) الشبكات العصبية الترشيحية القائمة على المناطق 4-1-3
48	 كشف الكائنات بلمحة واحدة (Single Shot Object Detection) 5-1-3
50	 مقاييس تقييم كشف الكائنات 6-1-3
51	 تعريف خوارزمية YOLO 7-1-3
57	 منصة ROBOFLOW 2-3
58	 توسيع البيانات (Data Augmentation) 1-2-3
60	 Google Colab 3-3
61	 الربط مع Roboflow 1-3-3
63	 التنفيذ العملي: الفصل الرابع: 4
64	 بيئة العمل 1-4

64 2-4 المخطط التدفقي

66 3-4 مخطط سير الواجهات

67 4-4 التنفيذ النهائي للنظام

72 5 الفصل الخامس: الخاتمة والآفاق المستقبلية

76 6 المراجع

الأشكال

الشكل 2-1: مؤتمر Dartmouth	14
الشكل 2-2: خطوات عمل تعلم الآلة	17
الشكل 2-3: بكسلات الصورة	20
الشكل 2-4: طبقات الشبكة العصبية الاصطناعية	24
الشكل 2-5: العصبونات (العقد)	24
الشكل 2-6: هيكل الشبكات العصبية العميقة	27
الشكل 2-7: مراحل الشبكة العصبية الترشيحية (CNNs)	30
الشكل 2-8: الفرق بين أنواع ال Padding الثلاث	32
الشكل 2-9: عملية الترشيح	33
الشكل 2-10: الهيكلية الهرمية لعمل المرشحات الإضافية	34
الشكل 2-11: الفرق بين ال Max Pooling وال Average Pooling	35
الشكل 2-12: تطبيق snapCalorie	38
الشكل 2-13: تطبيق Calorie Mama	40
الشكل 2-14: تطبيق Cal AI	41
الشكل 3-1: تصنيف الكائنات	45
الشكل 3-2: تحديد الكائنات	45
الشكل 3-3: هيكل R-CNN	46

49	الشكل 3-4: هيكل SSD
51	الشكل 3-5: طريقة حساب IoU
52	الشكل 3-6: تطور إصدارات YOLO حتى عام 2025
54	الشكل 3-7: هيكل خوارزمية YOLO
57	الشكل 3-8: منصة Roboflow
59	الشكل 3-9: خيارات توسيع وتعزيز البيانات
61	الشكل 3-10: Google Colab
62	الشكل 3-11: إعداد وتدريب نموذج AI باستخدام Roboflow لتنفيذه في Google Colab
65	الشكل 4-1: مخطط خوارزمية العمل
66	الشكل 4-2: مخطط سير الواجهات
67	الشكل 4-3: الواجهة الرئيسية للنظام
67	الشكل 4-4: فتح الكاميرا المباشرة
68	الشكل 4-5: التعرف على المنتج وإظهار المعلومات الرئيسية من خلال الكاميرا المباشرة
68	الشكل 4-6: التعرف على عدة منتجات من خلال الكاميرا المباشرة
69	الشكل 4-7: فتح واجهة تحميل الصورة من الجهاز
69	الشكل 4-8: اختيار الصورة
70	الشكل 4-9: إظهار معلومات المنتج
70	الشكل 4-10: التعرف على عدة منتجات في الصورة

الشكل 4-11: فتح واجهة الحميات.....71

الشكل 4-12: وجبات حمية مرضى السكري.....71

الجدول

الجدول 1-1: معامل النشاط البدني.....5

الجدول 2-1: السعرات الحرارية للمغذيات الرئيسية الثلاث.....6

جدول المصطلحات

الاختصار	التعريف باللغة الإنجليزية	التعريف باللغة العربية
AI	Artificial Intelligence	التعلم العميق
ML	Machine Learning	التعلم الآلي
DNNs	Deep Neural Networks	الشبكات العصبية العميقة
CNNs	Convolutional Neural Networks	الشبكات العصبية الترشيحية
YOLO	You Only Look Once	أنت تنظر مرة واحدة
SSD	Single Shot MultiBox Detector	كاشف الصناديق بلقطة واحدة
mAP	Mean Average Precision	متوسط الدقة
AP	Average Precision	الدقة المتوسطة
IoU	Intersection over Union	التقاطع على الاتحاد
FPS	Frames Per Second	الإطارات في الثانية
MR	Miss Rate	معدل الخطأ
FPR	False Positive Rate	معدل الإيجابيات الخاطئة
TPR	True Positive Rate	معدل الإيجابيات الحقيقية

واجهة برمجة التطبيقات	Application Programming Interface	API
طبقة متصلة بالكامل	Fully Connected	FC
قمع غير الأعظميات	Non-Max Suppression	NMS

الفصل الأول: مقدمة

1-1 أهمية حساب السعرات الحرارية ودور التقنية الحديثة

السعرات الحرارية تُعرّف على أنها وحدة قياس الطاقة التي يحصل عليها الجسم من الطعام والشراب. من الناحية العلمية، تُعرف السعرة الحرارية (Calorie) بأنه كمية الطاقة اللازمة لرفع درجة حرارة غرام واحد من الماء درجة مئوية واحدة. في مجال التغذية، يُستخدم مصطلح "السعرة الحرارية" للإشارة إلى الكيلو سعرة (Kilocalorie أو kcal)، وهي تساوي ألف سعرة صغيرة، وتعبّر عن كمية الطاقة التي يوفرها الطعام للجسم عند استهلاكه.



وتُعد السعرات الحرارية حجر الأساس في فهم كيفية تحويل الجسم للمواد الغذائية إلى طاقة، حيث تختلف كمية الطاقة التي يوفرها كل نوع من المغذيات؛ إذ يحتوي كل غرام من الكربوهيدرات أو البروتينات على نحو 4 كيلو سعرات حرارية، بينما يحتوي كل غرام من الدهون على حوالي 9 كيلو سعرات. وتُحسب الطاقة الكلية للطعام من مجموع السعرات الحرارية لجميع مكوناته. تُستخدم

هذه الوحدة لقياس وتحديد احتياجات الجسم اليومية من الطاقة، مما يتيح مقارنة الأطعمة وتصنيفها وفقًا لقيمها الحرارية [1].

فهم السعرات الحرارية لا يقتصر على الجوانب العلمية فقط، بل يتجاوز ذلك ليؤدي دورًا عمليًا ومحوريًا في الحياة اليومية لكل فرد. فمعرفة كمية الطاقة التي يستهلكها الإنسان من خلال الطعام، مقابل ما ينفقه خلال أنشطته اليومية، تتيح له اتخاذ قرارات غذائية أكثر وعيًا. ومن خلال إدراك القيم الحرارية للأطعمة والمشروبات، يمكن تحسين نمط الحياة بشكل مستدام. وتبرز أهمية معرفة السعرات الحرارية اليومية في عدة جوانب، منها [1]:

 **التحكم في الوزن:** يساعد تتبع السعرات الحرارية على موازنة الطاقة الداخلة إلى الجسم مع الطاقة المستهلكة، وهو أمر ضروري للحفاظ على وزن صحي أو فقدان الوزن أو حتى زيادته بشكل مدروس.

 **التخطيط الغذائي:** تمكّن معرفة السعرات الأفراد من بناء خطط غذائية مناسبة لأهدافهم الصحية، سواء كانوا رياضيين، أو يعانون من حالات صحية تتطلب تنظيم الطاقة مثل السكري.

 **الوعي الغذائي:** من خلال قراءة الملصقات الغذائية ومقارنة المنتجات، يتعلم الأفراد اختيار الأطعمة ذات القيم الغذائية الأفضل والمحتوى الحراري المناسب.

 **تحسين الأداء البدني والعقلي:** التغذية السليمة المبنية على تقدير دقيق للسعرات تعزز من الطاقة العامة والتركيز والقدرة على أداء المهام اليومية.

🍌 **الوقاية من العادات الغذائية الضارة:** يساعد إدراك عدد السعرات في تجنب الإفراط في تناول الأطعمة ذات المحتوى العالي من الطاقة وقليل من القيمة الغذائية، مثل الأطعمة المصنعة والمشروبات السكرية.

تُعد السعرات الحرارية عاملاً أساسياً في فهم وتفسير العلاقة بين تناول الطعام وصحة الإنسان، لا سيما في سياق الأمراض المزمنة مثل السمنة، وأمراض القلب، والسكري. عند استهلاك سعرات حرارية أكثر مما يحتاجه الجسم، يتم تخزين الفائض على شكل دهون، مما يؤدي إلى زيادة الوزن تدريجياً حتى يصل إلى السمنة. هذه الحالة ليست مجرد زيادة في الوزن فحسب، بل هي عامل خطر رئيسي مرتبط بارتفاع احتمالية الإصابة بأمراض القلب والأوعية الدموية بسبب تراكم الدهون في الشرايين وارتفاع ضغط الدم. بالإضافة إلى ذلك، تؤثر السمنة سلباً على حساسية الجسم للأنسولين، مما قد يؤدي إلى تطور مرض السكري من النوع الثاني. من ناحية أخرى، يمكن أن يؤدي التحكم الدقيق في السعرات الحرارية المستهلكة إلى تقليل هذه المخاطر الصحية، عبر الحفاظ على توازن طاقي مناسب يدعم وزناً صحياً ووظائف جسدية مثالية [1].

لحساب السعرات الحرارية التي يحتاجها الجسم يومياً بشكل يدوي، يُستخدم مفهوم معدل الأيض الأساسي (Basal Metabolic Rate - BMR)، وهو كمية الطاقة التي يحتاجها الجسم للحفاظ على وظائفه الحيوية في حالة الراحة التامة. بعد ذلك يتم تعديل هذا المعدل بناءً على مستوى النشاط البدني للوصول إلى إجمالي السعرات الحرارية اليومية المطلوبة.

1. حساب معدل الأيض الأساسي (BMR):

هناك عدة معادلات شائعة لحساب BMR ، أشهرها معادلات هاريس-بينديكت (Harris-Benedict Equation)، والتي تختلف باختلاف الجنس:

للرجال: 🇸🇦

$$BMR = 88.362 + (13.397 \times \text{Weight [kg]}) + (4.799 \times \text{Height [cm]}) - (5.677 \times \text{Age [years]})$$

للنساء: 🇸🇦

$$BMR = 447.539 + (9.247 \times \text{Weight [kg]}) + (3.098 \times \text{Height [cm]}) + (4.330 \times \text{Age [years]})$$

2. حساب إجمالي السعرات الحرارية اليومية (TDEE):

لحساب السعرات الكلية التي يحتاجها الجسم يومياً، يتم ضرب BMR في معامل النشاط البدني (Physical Activity Level - PAL):

الجدول 1-1: معامل النشاط البدني.

معامل النشاط (PAL)	مستوى النشاط
1.2	قليل أو لا نشاط
1.375	نشاط خفيف (تمرين 1-3 أيام في الأسبوع)
1.55	نشاط معتدل (تمرين 3-5 أيام في الأسبوع)
1.725	نشاط عالي (تمرين 6-7 أيام في الأسبوع)
1.9	نشاط مكثف جداً (عمل بدني شاق أو تمرين مرتين يومياً)

بالتالي المعادلة النهائية:

$$TDEE = BMR \times PAL$$

3. حساب السعرات من الطعام:

يمكن حساب السعرات الحرارية التي يحتويها الطعام عبر معرفة كمية المغذيات الكبرى (الكربوهيدرات، البروتينات، الدهون) مضروبة في قيمتها الحرارية لكل جرام:

الجدول 1-2: السعرات الحرارية للمغذيات الرئيسية الثلاث.

مستوى النشاط	معامل النشاط (PAL)
قليل أو لا نشاط	1.2
نشاط خفيف (تمرين 1-3 أيام في الأسبوع)	1.375
نشاط معتدل (تمرين 3-5 أيام في الأسبوع)	1.55
نشاط عالي (تمرين 6-7 أيام في الأسبوع)	1.725
نشاط مكثف جدًا (عمل بدني شاق أو تمرين مرتين يوميًا)	1.9

بالتالي:

$$\text{Calories in food} = (\text{grams of carbohydrates} \times 4) + (\text{grams of protein} \times 4) + (\text{grams of fat} \times 9)$$

رغم أن الحساب اليدوي للسعرات الحرارية يوفر طريقة منهجية لفهم الاحتياجات الغذائية وتقدير الطاقة المستهلكة، إلا أنه يواجه العديد من التحديات التي تؤثر على دقته وفعاليتها في الحياة اليومية. هذه التحديات تنبع من تعقيد عملية تقدير كميات الطعام، التنوع الكبير في تركيبات الأطعمة، بالإضافة إلى عوامل إنسانية وبيئية تؤثر على نتائج التقدير. أدناه أهم هذه التحديات [1]:

🍏 **تقدير غير دقيق لكميات الطعام:** صعوبة قياس الوزن أو الحجم الحقيقي للطعام قبل تناوله تؤدي إلى أخطاء في الحساب.

🍏 **تنوع وتركيب الأطعمة المعقد:** الأطعمة المصنعة أو الوصفات المتنوعة تحتوي على مكونات متعددة بصيغ مختلفة، مما يصعب تحديد محتوى السعرات بدقة.

🍏 **الاختلاف في طرق الطهي:** تختلف السعرات باختلاف طريقة الطهي (قلي، سلق، شواء)، مما يضيف تعقيداً عند التقدير اليدوي.

🍏 **عدم توفر معلومات غذائية دقيقة:** ليست كل الأطعمة تحمل معلومات تغذوية واضحة أو متاحة، خاصة في البيئات المنزلية أو المطاعم.

🍏 **الاعتماد على جداول أو قواعد بيانات عامة:** قد لا تعكس بدقة الخصائص الفعلية للأطعمة المستخدمة، مما يسبب تفاوتاً في الحسابات.

🍏 **الخطأ البشري والتعب:** إدخال البيانات بشكل يدوي يفتح المجال للأخطاء، إضافة إلى التعب أو فقدان التركيز عند الحساب المستمر.

🍏 **تغيرات الاحتياجات الفردية:** السعرات التي يحتاجها الفرد تختلف حسب العمر، الجنس، النشاط البدني، والحالة الصحية، مما يصعب ضبط التقدير بشكل دقيق يدوياً.

نظراً للتحديات المتعددة التي تواجه التقدير اليدوي للسعرات الحرارية، برزت الحاجة إلى تطوير أنظمة ذكية تعتمد على التكنولوجيا الحديثة لتسهيل هذه العملية وتحسين دقتها. توفر الحلول الذكية إمكانيات متقدمة مثل استخدام تقنيات الرؤية الحاسوبية والتعلم العميق لتحليل الصور

والتعرف على الأطعمة بشكل سريع وفعال. هذه الأنظمة تقلل الاعتماد على الإدخال اليدوي وتحد من الأخطاء البشرية، مما يتيح للمستخدمين الحصول على تقديرات دقيقة للسعرات الحرارية بسهولة ويسر. بالإضافة إلى ذلك، تساعد الحلول الذكية في تقديم معلومات مفصلة عن مكونات الطعام والقيم الغذائية، مما يدعم اتخاذ قرارات صحية مبنية على بيانات موثوقة. وبفضل التكامل مع قواعد بيانات ضخمة وتحديثاتها المستمرة، يمكن لهذه الأنظمة تلبية احتياجات مختلف الفئات، مثل الرياضيين، مرضى السكري، وأصحاب الحميات الغذائية الخاصة، مما يعزز من دور التكنولوجيا في تحسين الصحة العامة وجودة الحياة [1].

2-1 التعريف بالمشروع

يهدف المشروع إلى تطوير نظام ذكي يستخدم تقنيات الذكاء الاصطناعي ومعالجة الصور لتنفيذ عدة وظائف متقدمة تساعد المستخدمين في تتبع مكونات الطعام وقيمه الغذائية. يعتمد النظام على تحليل صور الأطعمة التي يتم التقاطها مباشرة باستخدام تقنية YOLO، حيث يقوم النظام بالكشف عن العناصر الغذائية الأساسية مثل الدهون، البروتينات، السكريات، الألياف، الكربوهيدرات، والسعرات الحرارية لكل 100 غرام من الطعام المكتشف. يتم تحليل الأطعمة التي تكون مفردة وغير مخلوطة مثل الفواكه أو الخضروات أو أي منتج غذائي لا يحتوي على مكونات مختلطة مع بعضها (مثل التفاحة أو حبة البطاطس أو طماطم).

أما الوظيفة الثانية، فتتيح للمستخدم تحميل صورة من جهازه الشخصي ليقوم النظام بتحليلها باستخدام نفس التقنية (YOLO)، حيث يقوم النظام بالكشف عن مكونات الطعام في الصورة ومن ثم عرض نفس المعلومات الغذائية الدقيقة لكل 100 غرام من المنتج.

الوظيفة الثالثة تتعلق بالحميات الغذائية حيث يُمكن للمستخدم اختيار نوع الحمية التي يرغب في اتباعها، مثل حمية مرضى السكري. في هذه الحالة، يقوم النظام بفتح واجهة تحتوي على قائمة من الوجبات المخطط لها على مدار أسبوع كامل، تتضمن الوجبات الثلاث اليومية وفقًا للنظام الغذائي المحدد، مما يتيح للمستخدم مراقبة استهلاكه الغذائي بشكل أكثر دقة وتنظيمًا.

تستند الفكرة الأساسية للمشروع إلى استخدام خوارزميات الذكاء الاصطناعي، وبالأخص نموذج الكشف عن الأشياء (YOLO)، الذي يتيح للنظام القدرة على تحديد وتصنيف مكونات الطعام بدقة وسرعة، مما يجعل هذا النظام أداة فعالة وسهلة الاستخدام في المنازل، المطاعم، وحتى للمهتمين بالحمية الصحية في الصالات الرياضية.

3-1 أهمية المشروع الصحية والتقنية

يُشكّل هذا المشروع نقطة تحول مهمة في مجال الصحة العامة، إذ يساهم بشكل فعال في تعزيز الوعي الغذائي لدى الأفراد وتحفيزهم على اتخاذ قرارات صحية مبنية على بيانات دقيقة وموثوقة. من خلال توفير وسيلة ذكية لتحليل مكونات الطعام وحساب العناصر الغذائية مثل الدهون، البروتينات، السكريات، الألياف، الكربوهيدرات، والسعرات الحرارية لكل 100 غرام من الطعام،

يتيح النظام للمستخدمين مراقبة تناولهم الغذائي بدقة متناهية، مما يعزز التحكم في الوزن ويقلل من مخاطر الإصابة بالأمراض المزمنة المرتبطة بالتغذية غير المتوازنة، مثل السمنة، ومرض السكري، وأمراض القلب.

علاوة على ذلك، يتماشى المشروع مع التوجه العالمي نحو مفهوم "الصحة الذكية"، الذي يعتمد على دمج التكنولوجيا الحديثة مع الرعاية الصحية لتحسين جودة الحياة وتعزيز الوقاية من الأمراض. عبر استثمار تقنيات الذكاء الاصطناعي والتعلم العميق في مجال التغذية، يفتح المشروع آفاقاً جديدة لتقديم حلول صحية متطورة تواكب التطور الرقمي وتسهل تبني نمط حياة صحي، ليس فقط على المستوى الفردي، بل وعلى نطاق أوسع يشمل المجتمعات.

من الناحية التطبيقية، يقدم النظام قيمة مضافة كبيرة لمجموعة واسعة من المستخدمين. فمرضى السكري يمكنهم الاعتماد على هذا النظام لمراقبة مدخولهم الغذائي بدقة عالية، مما يساهم في ضبط مستويات السكر في الدم وتقليل المضاعفات الصحية. الرياضيون أيضاً يستفيدون من القدرة على تتبع العناصر الغذائية والسعرات الحرارية بدقة لتصميم برامج غذائية تناسب مع أهدافهم التدريبية، سواء كانت بناء العضلات أو فقدان الوزن. أما أخصائيو التغذية وخبراء الصحة، فيمكنهم استخدام النظام كأداة داعمة لتقديم استشارات مبنية على بيانات دقيقة، مما يعزز من كفاءة خدماتهم ويقوي ثقة العملاء في التوصيات المقدمة.

4-1 أهداف المشروع

- 🍏 تطوير نظام ذكي دقيق وسريع لتحليل مكونات الطعام وحساب العناصر الغذائية مثل الدهون، البروتينات، السكريات، الألياف، الكربوهيدرات، والسعرات الحرارية باستخدام الصور.
- 🍏 استخدام خوارزميات متقدمة مثل YOLO للكشف والتعرف على مكونات الطعام داخل الصورة بدقة عالية، مما يتيح تصنيف وتحليل الأطعمة بشكل فوري.
- 🍏 الاعتماد على قاعدة بيانات غذائية شاملة ودقيقة لربط العناصر المكتشفة بمعلومات غذائية موثوقة، مما يسهل تقدير قيم العناصر الغذائية بناءً على نوع وكمية الطعام.
- 🍏 تمكين المستخدمين من مراقبة وتحليل مدخلهم الغذائي بسهولة وفعالية في مختلف البيئات مثل المنزل، المطاعم، والصالات الرياضية، مما يساهم في تحسين نمط حياتهم الغذائي.
- 🍏 توفير واجهة عرض بديهية وسهلة الاستخدام لعرض النتائج الغذائية بشكل عملي، مما يعزز فهم المعلومات ويجعلها متاحة للمستخدمين بمستوياتهم.
- 🍏 دعم الفئات المختلفة مثل الرياضيين، مرضى السكري، وأخصائيي التغذية من خلال تزويدهم بأداة ذكية تساعدهم في مراقبة وتحليل التغذية بشكل دقيق ومتقدم.
- 🍏 المساهمة في التوجه العام نحو "الصحة الذكية" من خلال دمج تقنيات التعلم العميق والرؤية الحاسوبية في التطبيقات الصحية، مما يعزز الوقاية من الأمراض ويشجع على تبني نمط حياة صحي.

الفصل الثاني: الإطار

النظري ومراجعة

الدراسات السابقة

1-2 تطور الذكاء الاصطناعي

الذكاء الاصطناعي (Artificial Intelligence) هو مجال علمي يهدف إلى تصميم أنظمة قادرة على أداء مهام تتطلب عادةً ذكاءً بشريًا، مثل التعلم، التفكير، الفهم، واتخاذ القرارات. يتضمن هذا المجال تطوير خوارزميات ونماذج تمكن الحواسيب من معالجة المعلومات بطرق تشبه التفكير البشري، مما يسمح لها بالتكيف مع البيئات المتغيرة وحل المشكلات المعقدة [2].

بدأت رحلة الذكاء الاصطناعي في منتصف القرن العشرين، حيث شهدت تطورات ملحوظة عبر العقود. في الأربعينيات والخمسينيات، ظهرت مفاهيم أولية مثل "Cybernetics" التي ركزت على التحكم والتواصل في الأنظمة الحية والآلية. ثم في عام 1956، تم تنظيم مؤتمر "Dartmouth" الذي يُعتبر نقطة الانطلاق الرسمية لمجال الذكاء الاصطناعي، حيث اجتمع باحثون لمناقشة إمكانية بناء آلات قادرة على محاكاة الذكاء البشري.



الشكل 1-2: مؤتمر Dartmouth.

خلال العقود التالية، شهد الذكاء الاصطناعي فترات من التقدم والتراجع، تُعرف بـ "صيف الذكاء الاصطناعي" و"شتاء الذكاء الاصطناعي". في الستينيات والسبعينيات، تم تطوير برامج قادرة على حل مشكلات رياضية ولعب الشطرنج، مما أثار اهتمامًا واسعًا. ومع ذلك، واجه المجال تحديات كبيرة بسبب محدودية القدرة الحاسوبية ونقص البيانات، مما أدى إلى تراجع الاهتمام في بعض الفترات.

في الثمانينيات، عاد الاهتمام بالذكاء الاصطناعي مع ظهور "Connectionism"، التي ركزت على بناء نماذج تحاكي الشبكات العصبية في الدماغ البشري. ومع تقدم التكنولوجيا وزيادة القدرة الحاسوبية، شهد المجال نهضة جديدة في العقد الأول من القرن الحادي والعشرين، خاصةً مع تطوير خوارزميات التعلم العميق التي مكنت الحواسيب من معالجة كميات هائلة من البيانات وتحسين أدائها في مهام معقدة مثل التعرف على الصور والكلام.

اليوم، يُعتبر الذكاء الاصطناعي جزءًا لا يتجزأ من العديد من التطبيقات اليومية، بدءًا من المساعدات الصوتية إلى أنظمة التوصية وتحليل البيانات الضخمة. ومع استمرار البحث والتطوير، يُتوقع أن يلعب الذكاء الاصطناعي دورًا متزايد الأهمية في تشكيل مستقبل التكنولوجيا والمجتمع.


2-2 تعلم الآلة (Machine Learning)

يشكل تعلم الآلة نقطة تحول جوهرية في تطور مجال الذكاء الاصطناعي. على عكس الأساليب السابقة التي كانت تعتمد على برمجة صريحة لكل حالة محتملة، أدخل تعلم الآلة القدرة على

تحسين أداء الأنظمة بشكل ذاتي من خلال التعلم من البيانات. هذا التحول المفاهيمي مكّن الآلات من التعرف على الأنماط واتخاذ القرارات مع الحد الأدنى من التدخل البشري. من خلال اعتماد خوارزميات قادرة على التعميم بناءً على الأمثلة، تجاوزت تعلم الآلة قيود البرمجة المعتمدة على القواعد وفتحت آفاقاً جديدة للمرونة وقابلية التوسع في بيئات معقدة. يركز هذا المفهوم على فرضية أن النظام يمكنه تحسين فهمه ودقته بشكل تدريجي عن طريق التعلم من التجارب، مشابهاً للعمليات الإدراكية التي تُلاحظ في الذكاء الطبيعي. وقد مهد هذا الإنجاز الطريق أمام تطورات تقنية قادرة على معالجة مشكلات كانت في السابق تعتبر معقدة للغاية بالنسبة للحلول الحاسوبية، مما أعاد تشكيل مسار أبحاث الأنظمة الذكية [2].

2-2-1 آلية عمل تعلم الآلة

يُعد فهم آلية عمل تعلم الآلة من الركائز الجوهرية التي توضح كيف استطاع هذا المجال إحداث نقلة نوعية في الذكاء الاصطناعي. فعلى عكس البرمجة التقليدية التي تتطلب من المبرمج كتابة قواعد محددة لمعالجة المدخلات، فإن تعلم الآلة يمكّن النظام من استخلاص الأنماط والعلاقات بنفسه من خلال تحليل كميات هائلة من البيانات. تبدأ العملية بجمع بيانات تمثل المشكلة المراد حلها، وتكون هذه البيانات بمثابة المصدر الأساسي الذي يتعلم منه النموذج. على سبيل المثال، إذا كان الهدف هو التعرف على أنواع الفواكه في الصور، فإن النموذج يحتاج إلى آلاف الصور التي تحتوي على هذه الفواكه مصنفة مسبقاً [2].



الشكل 2-2: خطوات عمل تعلم الآلة.

بعد تجهيز البيانات، تأتي مرحلة المعالجة الأولية التي يتم فيها تنظيف البيانات وتنظيمها، ما يضمن خلوها من الأخطاء أو القيم الشاذة التي قد تؤثر سلبيًا على عملية التعلم. ثم تُستخدم هذه البيانات لتدريب النموذج. في هذه المرحلة، تُمرّر البيانات عبر نموذج يحتوي على مجموعة من المعاملات القابلة للتعديل تُعرف باسم "الأوزان"، وهي التي تشكل جوهر عملية التعلم. يقوم النموذج في البداية بتوقعات غير دقيقة، ولكنه يُقارن هذه التوقعات بالقيم الحقيقية (المخرجات الصحيحة) ويحسب مقدار الخطأ.

بعد حساب الخطأ، يُعدل النموذج الأوزان داخله بطريقة تدريجية بهدف تقليل هذا الخطأ في التكرارات التالية، وهي عملية تُعرف بـ "التدريب". يتم تكرار هذه العملية آلاف المرات على دفعات من البيانات تُسمى "دفعات التدريب" حتى يتمكن النموذج من تقليل الخطأ بشكل كبير.

يستخدم في هذا السياق خوارزميات تحسين خاصة مثل "الانحدار التدريجي" لتحديث الأوزان بطريقة تضمن تحسين الأداء دون الوقوع في فخ التعميم المفرط.

ما إن يكتمل التدريب، يصبح النموذج قادرًا على التعميم واتخاذ قرارات دقيقة عند تقديم بيانات جديدة لم يسبق له رؤيتها، وهي المرحلة التي يُطلق عليها "التوقع". في هذه المرحلة، يمكن للنموذج تطبيق ما تعلمه مسبقًا على بيانات حقيقية في العالم الخارجي، مثل التنبؤ بكمية السعرات الحرارية في صورة طعام أو توقع مستوى سكر الدم بناءً على مؤشرات فسيولوجية. إن هذه القدرة على التنبؤ انطلاقًا من أمثلة سابقة تجعل تعلم الآلة أداة قوية ذات تطبيقات واسعة في مختلف المجالات العلمية والتجارية والطبية.

اللافت في آلية عمل تعلم الآلة هو أنه لا يتبع منطقًا ثابتًا كالتعليمات البرمجية التقليدية، بل يعمل من خلال تحسين مستمر قائم على التجربة والخطأ، مما يجعل منه أداة تتطور بمرور الوقت كلما زادت كمية ونوعية البيانات التي يتعلم منها. كما أن تعلم الآلة لا يعتمد فقط على توفير البيانات، بل يتطلب أيضًا هندسة دقيقة لهذه البيانات وضبطًا دقيقًا للمعاملات والمعايير المرتبطة بالنموذج لتحقيق أفضل أداء ممكن.


إن تعلم الآلة يُشبه من بعض الزوايا آلية التعلم البشري، حيث يتعلم الإنسان من تكرار التجارب واكتساب الخبرات، ويُحسن قراراته مع مرور الوقت. كذلك تفعل النماذج الذكية، فهي تنطلق من مرحلة غير دقيقة، وتطور قدراتها شيئًا فشيئًا، حتى تتمكن من تقديم نتائج تتسم بالدقة

والموثوقية. بهذه الطريقة، يغدو تعلم الآلة آلية ذكية تتفاعل مع الواقع وتتكيف معه بدلاً من أن تُلقن كيفية التعامل معه.

2-2-2 لماذا لا يكفي تعلم الآلة لمعالجة الصور المعقدة؟

على الرغم من الإمكانيات الكبيرة التي أتاحتها تعلم الآلة التقليدي في التعامل مع كم هائل من البيانات وتحقيق تقدم ملموس في العديد من التطبيقات، إلا أن هذا النوع من التعلم يواجه صعوبات جوهرية عندما يتعلق الأمر بمعالجة الصور المعقدة. يعود ذلك إلى عدة أسباب تقنية ومنهجية تجعل من تعلم الآلة بأساليبه التقليدية أداة غير كافية للتعامل مع الخصائص الفريدة والمتعددة الأبعاد للصور الرقمية [2].

الصور بطبيعتها تحتوي على قدر هائل من المعلومات المرئية المرتبطة بمستويات مختلفة من التفاصيل، حيث تتضمن كل صورة بيانات بصرية موزعة عبر مصفوفة من البكسلات (الشكل 2-3)، لكل منها قيم محددة تمثل درجات اللون أو شدة الإضاءة. وعندما تُستخدم الطرق التقليدية في تعلم الآلة، مثل خوارزميات الانحدار أو الأشجار العشوائية أو حتى أساليب التصنيف الكلاسيكية، فإن هذه النماذج تفترض غالباً أن السمات المدخلة إلى النموذج هي سمات ذات معنى محدد ومحدد سلفاً، أي أنها تتطلب "هندسة سمات" يدوية يقوم فيها البشر بتحديد الخصائص الأهم في الصور وتحويلها إلى بيانات قابلة للفهم من قبل الخوارزمية.



الشكل 2-3: بكسلات الصورة.

لكن هذه العملية اليدوية لهندسة السمات تشكل عائقاً كبيراً في معالجة الصور، لأن الصور عادة لا تحتوي على سمات واضحة المعالم يمكن استخلاصها بسهولة دون خسارة كمية هائلة من المعلومات الدقيقة. فعلى سبيل المثال، يكاد يكون من المستحيل برمجياً تحديد الفرق بين صورة قطة وصورة كلب باستخدام عدد قليل من الخصائص المحددة يدوياً، مثل الطول أو العرض أو عدد الألوان. إن التوزيع البصري في الصور أكثر تعقيداً من أن يُختزل في معايير بسيطة، ما يجعل النماذج التقليدية غير قادرة على تمثيل هذا التعقيد الداخلي بكفاءة.

أضف إلى ذلك أن تعلم الآلة التقليدي يعاني من محدودية في فهم السياق المكاني بين عناصر الصورة، أي أنه يتعامل مع كل بكسل أو مجموعة بكسلات بمعزل عن موقعها النسبي أو علاقتها ببقية العناصر البصرية. وهذا يمثل مشكلة كبيرة لأن إدراك شكل معين في صورة يعتمد على كيفية تنظيم البكسلات في نمط معين، وليس فقط على وجودها. فمثلاً، وجه الإنسان ليس مجرد

مجموعة من الخطوط، بل هو نمط معين من العلاقات المكانية بين العينين والأنف والفم. تعلم الآلة التقليدي لا يستطيع بسهولة تمثيل هذه العلاقات أو تفسيرها دون تدخل يدوي معقد ومكلف.

من جهة أخرى، فإن حجم البيانات المطلوب لتدريب النماذج التقليدية على الصور يكون هائلاً، لأنه كلما زادت التفاصيل البصرية في الصور، زادت الحاجة إلى إدخال هذه التفاصيل كنقاط بيانات بشكل صريح. هذا يؤدي إلى ما يُعرف بـ "لعنة الأبعاد"، حيث يصبح من الصعب جداً على النموذج أن يتعلم تمثيلاً دقيقاً دون أن يتعرض للإفراط في التخصيص (Overfitting) أو الانخفاض الحاد في الأداء. ويزيد هذا التحدي عندما يكون الهدف هو التعميم على صور لم تُشاهد من قبل النموذج أثناء التدريب، إذ يفشل تعلم الآلة التقليدي في التقاط الأنماط البصرية التي تتطلب مستوى عالٍ من التجريد.

وبالإضافة إلى ما سبق، فإن عمليات التدريب في تعلم الآلة التقليدي تصبح أكثر عرضة للأخطاء عندما تكون الصور متغيرة في الإضاءة أو الزاوية أو الأبعاد أو الخلفية. فأي تغيير بسيط في هذه العوامل قد يؤدي إلى تغيير جذري في كيفية تمثيل الصورة ضمن النموذج، مما يؤدي إلى نتائج خاطئة أو غير مستقرة. هذه الحساسية العالية للتغيرات الطفيفة تمثل أحد أبرز العوائق أمام تبني النماذج التقليدية في تطبيقات الرؤية الحاسوبية المعقدة.

بناءً على ذلك، يمكن القول إن الفجوة بين قدرة تعلم الآلة التقليدي ومتطلبات فهم الصور المعقدة دفعت الباحثين إلى السعي نحو نماذج أكثر تطوراً، قادرة على استخراج السمات تلقائياً، وتمثيل

العلاقات المكانية والبصرية بشكل أعمق، والتعامل بكفاءة مع التغيرات في البيئة البصرية. هذه الحاجة المنهجية أدت لاحقاً إلى نشوء أنماط جديدة من النماذج التي تمثل نقلة نوعية في الذكاء الاصطناعي.

3-2 التعلم العميق (Deep Learning)

يُعدّ التعلم العميق (Deep Learning) تطوراً نوعياً في مسار الذكاء الاصطناعي، حيث يمثل نقلة نوعية من الأساليب التقليدية إلى نماذج أكثر قدرة على فهم الأنماط المعقدة في البيانات. ففي حين كانت النماذج التقليدية تعتمد على تمثيلات يحددها الإنسان، جاء التعلم العميق ليتيح للأنظمة القدرة على استخراج التمثيلات المفيدة تلقائياً من البيانات الخام [2].

يتميز التعلم العميق بقدرته على بناء تمثيلات هرمية للبيانات، حيث تتعلم النماذج تمثيلات بسيطة في الطبقات الأولى، وتبني عليها تمثيلات أكثر تعقيداً في الطبقات اللاحقة. هذا التدرج في التمثيل يمكّن النماذج من فهم البيانات بعمق، مما يتيح لها أداء مهام معقدة مثل التعرف على الصور، ومعالجة اللغة الطبيعية، وغيرها من التطبيقات التي كانت تتطلب تدخلاً بشرياً كبيراً في السابق.

الفرق الجوهرى بين التعلم العميق والتعلم الآلى التقليدي يكمن في طريقة تمثيل البيانات والتعلم منها. ففي التعلم الآلى التقليدي، يعتمد الأداء بشكل كبير على جودة التمثيلات التي يصممها الخبراء، مما يتطلب معرفة عميقة بالمجال وتفاصيل البيانات. أما في التعلم العميق، فإن النماذج


تتعلم هذه التمثيلات تلقائيًا من البيانات، مما يقلل الحاجة إلى التخصيص اليدوي ويزيد من قدرة النماذج على التعميم والتكيف مع مهام جديدة.

هذا التحول في طريقة التعلم والتمثيل يجعل التعلم العميق أداة قوية في معالجة البيانات المعقدة والمهام التي تتطلب فهمًا عميقًا للأنماط والعلاقات داخل البيانات. ومع التقدم المستمر في هذا المجال، يتوقع أن يستمر التعلم العميق في دفع حدود ما يمكن تحقيقه في الذكاء الاصطناعي وتطبيقاته المتنوعة.

1-3-2 الشبكات العصبية الاصطناعية (Neural Networks)


تمثل الشبكات العصبية الاصطناعية نموذجًا رياضيًا مستوحى من بنية الدماغ البشري وآلية معالجته للمعلومات. تقوم هذه الشبكات على فكرة أن المعالجة المعقدة للمعلومات يمكن تحقيقها عبر سلسلة من الوحدات البسيطة التي تتصل فيما بينها على شكل طبقات متعاقبة. تتكون هذه الشبكات من مجموعة من المكونات الأساسية التي تعمل بانسجام لتعلم الأنماط من البيانات وتوليد مخرجات دقيقة تمثل التوقع أو التصنيف المطلوب. هذه المكونات تمثل الركائز التي تقوم عليها البنية الحسابية لهذه النماذج، والتي مكّنت الذكاء الاصطناعي من أداء مهام كان يُعتقد سابقًا أنها تتطلب قدرات بشرية بحتة [2].

🍏 **الطبقات (Layers):** تُقسم الشبكة العصبية عادةً إلى ثلاث أنواع رئيسية من الطبقات: طبقة الإدخال التي تستقبل البيانات الخام، وطبقات خفية تتوسط عملية المعالجة، وطبقة إخراج تعطي النتيجة النهائية. كل طبقة تحتوي على عدد من الوحدات المعالجة تُعرف بالعُقد.



الشكل 2-4: طبقات الشبكة العصبية الاصطناعية.

🍏 **العُقد (Neurons):** كل عُقدة في الشبكة تمثل وحدة حسابية بسيطة تستقبل مجموعة من المدخلات، وتقوم بتطبيق عملية رياضية عليها، غالبًا ما تشمل جمعًا مرجحًا لتلك المدخلات، يتبعها تطبيق دالة تفعيل غير خطية، لإنتاج خرج يُرسل إلى العقد التالية في الشبكة.



الشكل 2-5: العصبونات (العقد).

🍎 **الأوزان (Weights):** تُعد الأوزان القيم الرقمية المرتبطة بالروابط بين العقد المختلفة في الشبكة، وتمثل مدى أهمية كل مدخل بالنسبة إلى العقدة المستقبلية. تتغير هذه الأوزان أثناء عملية التدريب لتعكس فهم النموذج للأنماط في البيانات.

🍎 **الانحيازات (Biases):** تُضاف الانحيازات إلى الناتج الخطي للعقدة قبل تطبيق دالة التنشيط، وهي عناصر تُستخدم لضبط مخرجات العقد وتمنح النموذج مرونة أكبر في التعلم، بحيث لا تكون المخرجات محكمة فقط بوزن المدخلات.

الطبقات الخفية، وهي المكونات التي تتوسط بين الإدخال والإخراج، تُعد المكان الذي تحدث فيه معظم المعالجة الفعلية. في كل طبقة خفية، يتم تحويل البيانات القادمة من الطبقة السابقة عبر العمليات المذكورة سابقًا، بحيث يصبح المولد بمثابة مدخل للطبقة التالية. كل طبقة من هذه الطبقات تتعلم تمثيلًا مجردًا أكثر تعقيدًا للبيانات الأصلية، مما يتيح للنموذج القدرة على تمثيل العلاقات غير الخطية والتفاعلات المعقدة بين المتغيرات.

تمر البيانات خلال الشبكة في البداية بمرحلة تُعرف بالانتشار الأمامي (Forward Propagation)، حيث تُنقل المدخلات من الطبقة الأولى حتى تصل إلى الطبقة الأخيرة، مرورًا بكل الطبقات الخفية. في كل مرحلة، يتم حساب ناتج العقد وفقًا للأوزان والانحيازات المطبقة، وتُطبق دوال التنشيط لتحويل القيم إلى شكل يسمح بفهم أكثر عمقًا للبيانات. النتيجة النهائية التي تنتج عن طبقة الإخراج يمكن أن تكون قيمة رقمية تمثل تقديرًا كميًا (في حالة التوقع) أو مجموعة احتمالات تمثل التصنيف إلى فئات معينة (في حالة التصنيف).


لكن دقة النموذج لا تتوقف على الانتشار الأمامي فحسب، بل تعتمد أيضاً على آلية تصحيح الأخطاء، والتي تتم من خلال عملية تُعرف بالانتشار العكسي (Backpropagation). في هذه المرحلة، يتم احتساب الخطأ بين ناتج النموذج والناتج الفعلي المرغوب فيه، ثم يُعاد هذا الخطأ إلى الخلف عبر الطبقات باستخدام قواعد اشتقاق رياضية، لتحديث الأوزان والانحيازات بطريقة تقلل من هذا الخطأ في المرات القادمة. يُستخدم في ذلك خوارزمية تُعرف باسم خوارزمية التدرج العكسي، وهي تقوم بضبط الأوزان تدريجياً باستخدام الانحدار التدرجي (Gradient Descent) بهدف تحسين أداء النموذج مع مرور الوقت.

من خلال هذه البنية المتكاملة من الطبقات والعقد والأوزان والانحيازات، وبلاستفادة من آليتي الانتشار الأمامي والعكسي، تصبح الشبكات العصبية الاصطناعية قادرة على بناء فهم متدرج للبيانات، وتمييز الأنماط الدقيقة التي قد لا تكون مرئية بوضوح للعين البشرية أو قابلة للاكتشاف بالطرق التقليدية. وتُعد النتيجة النهائية التي تُستخلص من طبقة الإخراج تجسيداً لتعلم الشبكة من البيانات، سواء كان ذلك في صورة تصنيف لفئة معينة، أو توقع لقيمة مستهدفة، مما يعكس مدى قوة هذه النماذج في دعم القرارات الآلية ضمن نطاقات متعددة من التطبيقات الواقعية.

2-1-3-1 الشبكات العصبية العميقة (Deep Neural Networks)

تمثل الشبكات العصبية العميقة (DNNs) نقلة نوعية في مجال تعلم الآلة، إذ تُبنى على فكرة توسيع عمق النموذج من خلال مضاعفة عدد الطبقات الداخلية، بحيث لا تقتصر الشبكة على طبقة واحدة أو طبقتين كما في الشبكات البسيطة، بل تتكون من تسلسل طويل من الطبقات

التي تُعالج التمثيلات بالتدرج من مفاهيم سطحية إلى مفاهيم عالية التجريد. هذه الطبقات العديدة تسمح للنموذج بإجراء عمليات تركيبية متسلسلة على البيانات، ما يجعله قادرًا على إدراك العلاقات المعقدة والأنماط المتداخلة في المجالات التطبيقية التي يصعب فيها تحديد السمات يدويًا [2].



الشكل 2-6: هيكل الشبكات العصبية العميقة.

في التطبيقات المعقدة التي تتطلب قدرة كبيرة على تمثيل التفاصيل الدقيقة في البيانات، تُستخدم الشبكات العصبية العميقة بسبب قدرتها على بناء بنى تمثيلية متعددة المستويات دون تدخل بشري مباشر في اختيار السمات. ومن أبرز المجالات التي تستفيد من هذا النوع من الشبكات: أنظمة الفهم اللغوي العميق، الترجمة الآلية دون اعتماد على قواعد لغوية صريحة، تحليل تسلسل الجينوم في التطبيقات الحيوية، والكشف التلقائي عن أنماط سلوك المستخدم في النظم الرقمية. وتبرز أهميتها أيضًا في تحليل بيانات الحساسات متعددة الأبعاد، مثل تلك المستخدمة في

المركبات ذاتية القيادة أو الروبوتات المتقدمة، حيث يكون من الضروري التعامل مع تدفقات زمنية ومكانية كثيفة ومعقدة.

مع ذلك، لا يمكن الاعتماد على الشبكات العصبية العميقة التقليدية بمفردها لمعالجة الصور بكفاءة. فرغم أنها قادرة على تعلم الأنماط غير الخطية وتمثيل التفاعلات بين السمات المختلفة، إلا أن الصور تمتاز بطبيعة مكانية وبُنية مترابطة لا تتناسب مع الأسلوب العام لتغذية البيانات في DNNs، حيث يتم غالبًا تسطيح الصور وتحويلها إلى متجهات أحادية البعد. هذا الإجراء يفصل البكسلات عن مواقعها النسبية ويؤدي إلى فقدان البنية الهندسية للصورة، وهو أمر بالغ الأهمية في إدراك الكائنات والتراكيب داخل الصور.

بالإضافة إلى ذلك، تتطلب معالجة الصور بواسطة الشبكات العميقة التقليدية حجمًا هائلًا من المعاملات، خاصة عندما تكون الصور عالية الدقة. إذ إن كل عقدة في طبقة ما ترتبط بجميع العقد في الطبقة السابقة، مما يؤدي إلى زيادة عدد الأوزان بشكل أُسي مع اتساع حجم الإدخال، وهذا يجعل النماذج أكثر عرضة لمشكلة الإفراط في التعلّم، ويزيد من العبء الحسابي بشكل كبير.

علاوة على ذلك، تفتقر هذه الشبكات إلى القدرة على التعميم المكاني، أي أنها غير قادرة على اكتشاف أنماط متكررة في مواضيع مختلفة من الصورة بنفس الكفاءة، ما يجعلها حساسة لمكان ظهور الكائن أو النمط داخل الصورة. كما أنها لا تستغل التكرار المحلي الموجود في الصور، أي أنها تعيد تعلم نفس الأنماط في مواضيع مختلفة بدلًا من مشاركتها عبر المواقع، وهو ما يؤدي إلى هدر في كفاءة التمثيل والتدريب.

لذلك، وعلى الرغم من أن DNNs توفر قدرة عالية على التمثيل التعليمي المجرد، إلا أن هذه القدرة وحدها لا تكفي لمعالجة الصور بفعالية دون الاستعانة بهياكل أخرى متخصصة تتعامل مع البيانات الصورية بطريقة تتلاءم مع خصائصها المكانية. إن الاكتفاء بالشبكات العميقة العامة يعوق تحقيق الأداء الأمثل في المهام التي تعتمد على إدراك البنية الهندسية والمكانية، كما في حالات التعرف على الأنماط البصرية أو فهم المشاهد.

2-1-3-2 الشبكات العصبية الترشيحية (Convolutional Neural Networks)

تعريف الشبكات العصبية الترشيحية


الشبكات العصبية الترشيحية، أو ما تُعرف اختصارًا بـ CNNs، هي نوع متخصص من الشبكات العصبية الاصطناعية صُممت لمعالجة البيانات ذات البنية الشبكية، مثل الصور أو الإشارات الثنائية الأبعاد. تعتمد فكرتها الأساسية على محاكاة آلية عمل النظام البصري في الكائنات الحية، حيث تستخدم طبقاتٍ متتالية من المرشحات (أو النواقل) لتحليل المدخلات عبر اكتشاف أنماط محددة، كحواف الأشكال أو التفاصيل النسيجية. تتميز هذه الشبكات بقدرتها على تعلم واستخراج السمات المهمة من البيانات تلقائيًا، دون الحاجة إلى برمجة صريحة لتحديد هذه السمات مسبقًا. تُنظّم طبقاتها في هيكل هرمي، حيث تُعالج الطبقات الأولى تفاصيل بسيطة (مثل الخطوط)، بينما تتولى الطبقات الأعمق دمج هذه التفاصيل لتكوين تمثيلات معقدة للعناصر داخل البيانات. يعتمد أداؤها على عملية الترشيح التي تُطبّق عبر نوافذ صغيرة تتحرك على كامل المدخلات، مما يسمح بالتعرف على الأنماط بغض النظر عن موقعها أو اتجاهها. هذه الخصائص جعلت منها أداة فعالة

في التعامل مع البيانات عالية الأبعاد، مع الحفاظ على كفاءة الحساب وخفض العبء التخزيني مقارنةً بالشبكات العصبية التقليدية [3].

🍎 كيف تعمل الشبكات العصبية الترشيحية؟

تتميز الشبكات العصبية الترشيحية عن الشبكات العصبية الأخرى بأدائها الفائق في معالجة المدخلات من الصور أو الكلام أو الإشارات الصوتية. تحتوي على ثلاثة أنواع رئيسية من الطبقات، هي [3]:

- الطبقة الترشيحية
- طبقة التجميع
- الطبقة المتصلة بالكامل (FC)



الشكل 7-2: مراحل الشبكة العصبية الترشيحية (CNNs).

الطبقة الترشيحية هي الطبقة الأولى في الشبكة الترشيحية. بينما يمكن أن تتبعها طبقات ترشيحية إضافية أو طبقات تجميع، تكون الطبقة المتصلة بالكامل هي الطبقة النهائية. مع كل طبقة، تزداد تعقيدًا في الشبكة العصبية الترشيحية، حيث تحدد أجزاء أكبر من الصورة. تركز الطبقات المبكرة على ميزات بسيطة، مثل الألوان والحواف. ومع تقدم بيانات الصورة عبر طبقات الشبكة العصبية الترشيحية، تبدأ في التعرف على عناصر أو أشكال أكبر للعنصر حتى تتعرف أخيرًا على الكائن المقصود [3].

○ الطبقة الترشيحية:

الطبقة الترشيحية هي الوحدة الأساسية في الشبكات العصبية الترشيحية (CNN)، حيث تحدث معظم العمليات الحسابية فيها. تتكون من ثلاثة عناصر رئيسية: المدخلات (مثل صورة ملونة ممثلة بمصفوفة ثلاثية الأبعاد للطول والعرض والعُمق، والذي يتوافق مع قيم الألوان RGB)، والمرشح (أو كاشف الميزات)، وخريطة الميزات الناتجة [3].

المرشح عبارة عن مصفوفة ثنائية الأبعاد من الأوزان، تمثل جزءًا من الصورة. يتحرك هذا المرشح فوق مناطق متداخلة من الصورة (تُسمى حقول الاستقبال)، ويُجري عملية ترشيح (التفاف) عن طريق حساب حاصل ضرب النقطي بين وحدات البكسل في المنطقة المحددة وقيم المرشح. بعد كل عملية، ينتقل المرشح بمقدار خطوة (stride) محددة، ويكرر العملية حتى يغطي كامل الصورة. الناتج النهائي لهذه العمليات المتكررة هو خريطة الميزات، التي تُظهر مدى تطابق أجزاء الصورة مع النمط الذي يبحث عنه المرشح.

تبقى أوزان المرشح ثابتة أثناء حركته، لكنها قد تُعدّل لاحقًا أثناء تدريب الشبكة عبر خوارزميات مثل الانتشار العكسي. هناك ثلاث معلمات اختيارية تُحدد قبل التدريب وتؤثر على حجم الخرج:

1. **Number of Filters**: كل مرشح يُنتج خريطة ميزات منفصلة، مما يزيد عمق الخرج.


2. **Strid**: المسافة التي يتحركها المرشح في كل مرة. كلما زادت الخطوة، قل حجم الخرج.

3. **Zero-Padding**: يُستخدم عندما لا يتناسب حجم المرشح مع الصورة. أنواعه:

a. **Valid Padding**: لا يُضيف أصفارًا، وقد يُقلص حجم الخرج.


b. **Same Padding**: يُحافظ على حجم الخرج مساويًا لحجم المدخلات.

c. **Full Padding**: يُزيد حجم الخرج بإضافة أصفار حول حواف الصورة.



الشكل 2-8: الفرق بين أنواع ال Padding الثلاث.


بعد كل عملية ترشيح، تُطبّق دالة ReLU (وحدة الخطية المستقيمة) على خريطة الميزات لإضافة عدم الخطية إلى النموذج، مما يساعده على تعلم أنماط معقدة.



الشكل 9-2: عملية الترشيح.

○ طبقة ترشيحية إضافية:

كما ذكرنا سابقًا، يمكن أن تتبع طبقة ترشيحية أخرى الطبقة الترشيحية الأولى. عند حدوث ذلك، تصبح هيكلية الشبكة العصبية الترشيحية (CNN) هرمية، حيث تتمكن الطبقات اللاحقة من "رؤية" البكسلات ضمن حقول الاستقبال في الطبقات السابقة. على سبيل المثال، لنفترض أننا نحاول تحديد ما إذا كانت صورة تحتوي على دراجة هوائية. يمكن اعتبار الدراجة مجموع أجزاء: هيكلها، المقود، العجلات، الدواسات، وهكذا. كل جزء من هذه الأجزاء يُشكّل نمطًا بسيطًا (منخفض المستوى) في الشبكة العصبية، بينما يُمثّل جميع هذه الأجزاء معًا نمطًا معقدًا (عالي المستوى)، مما يُنشئ تسلسلاً هرميًا للميزات داخل الشبكة. في النهاية، تُحوّل الطبقة الترشيحية الصورة إلى قيم رقمية، مما يسمح للشبكة العصبية بفهم واستخراج الأنماط ذات الصلة [3].



الشكل 2-10: الهيكلية الهرمية لعمل المرشحات الإضافية.

○ التجميع:

تُعرف طبقات التجميع (أو التصغير) بتقليل الأبعاد وعدد المسمات في المدخلات. مشابهة للطبقة الترشيحية، حيث تمرر عملية التجميع مرشحًا (فلتر) على كامل الصورة المدخلة، لكن الاختلاف هو أن هذا المرشح لا يحتوي على أوزان. بدلاً من ذلك، يطبق المرشح دالة تجميع على القيم داخل المنطقة المحددة من الصورة، ويملأ المصفوفة الناتجة. هناك نوعان رئيسيان من التجميع [5]:

1. التجميع الأقصى (Max pooling): عند تحرك المرشح فوق الصورة، يختار القيمة


العظمى (الأكبر) ضمن المنطقة المحددة لإرسالها إلى المصفوفة الناتجة. تُستخدم هذه

الطريقة بشكل أكثر شيوعًا.

2. التجميع المتوسط (Average pooling): يحسب المرشح القيمة المتوسطة للبكسلات

داخل المنطقة المحددة لإرسالها إلى المصفوفة الناتجة.

على الرغم من فقدان بعض المعلومات في طبقة التجميع، إلا أنها تساعد في تقليل التعقيد، وتحسين الكفاءة، وتقليل خطر ال (overfitting).



الشكل 2-11: الفرق بين ال Max Pooling وال Average Pooling.

○ الطبقة المتصلة بالكامل:

اسم هذه الطبقة يصف وظيفتها بدقة. كما ذكر سابقاً، في الطبقات المتصلة جزئياً (مثل الترشيحية أو التجميع)، لا تتصل قيم البكسلات في الصورة المدخلة مباشرة بطبقة الإخراج. أما في الطبقة المتصلة بالكامل، فإن كل عُقدة في طبقة الإخراج تتصل بشكل مباشر بكل العُقد في الطبقة السابقة [3].

تُنفَّذ هذه الطبقة مهمة تصنيف البيانات بناءً على الميزات التي تم استخراجها عبر الطبقات السابقة ومرشحاتها المختلفة. بينما تستخدم الطبقات الترشيحية والتجميع عادةً دالة التنشيط ReLU، فإن الطبقات المتصلة بالكامل تعتمد غالباً دالة التنشيط SoftMax لتصنيف المدخلات بشكل دقيق، مما يُنتج احتمالية (قيمة بين 0 و1) لانتماء البيانات إلى فئة محددة.

🍌 أنواع الشبكات العصبية الترشيحية:

وضع الباحثان كُونيهيكو فوكوشما ويان لِكُن الأسس البحثية للشبكات العصبية الترشيحية من خلال أعمالهما في عام 1980، وورقة بحثية مشهورة بعنوان "الانتشار العكسي مُطبق على تمييز الرموز البريدية المكتوبة بخط اليد" عام 1989. بشكل أكثر شهرةً، نجح يان لِكُن في تطبيق الانتشار العكسي لتدريب الشبكات العصبية على التعرف على الأنماط في سلسلة من الرموز البريدية المكتوبة بخط اليد. استمر في أبحاثه مع فريقه خلال تسعينيات القرن الماضي، لتتوج جهودهم بتطوير "LeNet-5"، الذي طبق المبادئ ذاتها على تمييز المستندات [3].

منذ ذلك الحين، ظهرت العديد من هياكل الشبكات العصبية الترشيحية المتنوعة مع ظهور مجموعات بيانات جديدة (مثل MNIST و CIFAR-10) ومسابقات مثل تحدي التعرف البصري واسع النطاق لـ ImageNet (ILSVRC). ومن أبرز هذه الهياكل:

1. AlexNet

2. VGGNet

3. GoogLeNet


4. ResNet

5. ZFNet

4-2 الدراسات والمشاريع السابقة

1-4-2 تطبيق SnapCalorie

يُعد تطبيق SnapCalorie من الابتكارات الرائدة في مجال تتبع التغذية، حيث يُسخر تقنيات الذكاء الاصطناعي والرؤية الحاسوبية لتبسيط عملية حساب السعرات الحرارية والمغذيات. يتيح التطبيق للمستخدمين التقاط صورة واحدة لوجبتهم، ليقوم بتحليلها فورًا وتقديم تقديرات دقيقة للسعرات الحرارية والمغذيات الكبرى، مثل البروتينات والكربوهيدرات والدهون، دون الحاجة إلى إدخال البيانات يدويًا أو البحث في قواعد بيانات معقدة. تُظهر الدراسات أن دقة SnapCalorie تتفوق على تقديرات أخصائيي التغذية البشريين، مما يجعله أداة موثوقة لمراقبة النظام الغذائي.



الشكل 2-12: تطبيق snapCalorie.


بالإضافة إلى ذلك، يوفر التطبيق تقارير أسبوعية شاملة تُفصل استهلاك المستخدم من السعرات الحرارية والمغذيات، مما يساعدهم على تتبع تقدمهم الغذائي واتخاذ قرارات مستنيرة بشأن نظامهم الغذائي. يُعتبر SnapCalorie مجانيًا للاستخدام، مما يجعله متاحًا لشريحة واسعة من المستخدمين دون الحاجة إلى اشتراكات مدفوعة. كما يتميز بواجهة مستخدم بسيطة وسهلة الاستخدام، مما يُمكن المستخدمين من تسجيل وجباتهم بسرعة وبدون تعقيد. تُظهر هذه الميزات أن SnapCalorie يُمثل خطوة متقدمة في مجال تتبع التغذية، حيث يُوفر حلاً دقيقًا وفعالًا لمراقبة النظام الغذائي دون الحاجة إلى الجهد اليدوي التقليدي [4].

2-4-2 تطبيق Calorie Mama

يُعد تطبيق Calorie Mama من الأدوات الحديثة التي تجمع بين الذكاء الاصطناعي والرؤية الحاسوبية لمساعدة المستخدمين في مراقبة نظامهم الغذائي بأسلوب ذكي وسهل. يعتمد التطبيق على تصوير الطعام باستخدام كاميرا الهاتف، حيث يقوم بتحليل الصورة فور التقاطها والتعرف تلقائيًا على نوع الوجبة ومكوناتها، ومن ثم يقدم تقديرًا دقيقًا لكمية السعرات الحرارية والعناصر الغذائية الأساسية الموجودة في الطبق. ما يميز هذا التطبيق هو أنه لا يقتصر على تحليل الأطعمة الفردية فحسب، بل يستطيع التمييز بين مكونات الوجبة الواحدة، حتى في الحالات التي تتضمن أطباقًا متعددة أو وصفات معقدة، مما يُعزز من دقته وفعاليته في تقديم المعلومات الغذائية.

يُوفر التطبيق دعمًا للعديد من الأنظمة الغذائية، بما في ذلك النباتية والكيو وأنظمة تخفيض الوزن، مما يجعله مناسبًا لمجموعة واسعة من المستخدمين باختلاف أهدافهم الصحية والغذائية. كما أن Calorie Mama يدعم ميزة التتبع اليومي والتقارير الدورية التي تُتيح للمستخدمين متابعة تقدمهم ومراجعة تفاصيل استهلاكهم الغذائي على مدار الأيام والأسابيع. بالإضافة إلى ذلك، يتمتع التطبيق بواجهة رسومية جذابة وسهلة التصفح، ما يجعله مناسبًا حتى للمستخدمين غير المتمرسين في استخدام التطبيقات الصحية. هذه الخصائص تجعل من Calorie Mama أداة موثوقة تجمع بين الدقة وسهولة الاستخدام في مجال تتبع السعرات والمغذيات، وتُظهر كيف

يمكن للتقنيات الحديثة أن تُبسّط عملية الالتزام بالعوادات الغذائية السليمة دون الحاجة إلى حسابات يدوية مرهقة أو جداول غذائية معقدة [5].




الشكل 2-13: تطبيق Calorie Mama.

3-4-2 تطبيق Cal AI

يُعد تطبيق Cal AI مثلاً متقدماً على استخدام الذكاء الاصطناعي لتحسين تجربة تتبع النظام الغذائي وإدارة الصحة الشخصية. يتميز هذا التطبيق بقدرته على تحليل الوجبات الغذائية بدقة من خلال الصور التي يلتقطها المستخدم باستخدام هاتفه المحمول، حيث يقوم نظام الذكاء الاصطناعي المدمج فيه بالتعرف تلقائياً على محتويات الطبق، وتحديد أنواع الأطعمة وكمياتها، ثم

حساب السعرات الحرارية والمغذيات المختلفة مثل البروتينات والكربوهيدرات والدهون. يتم كل ذلك في غضون ثوانٍ، دون الحاجة لإدخال يدوي للبيانات، مما يُقلل من الجهد ويزيد من الدقة والموثوقية في المتابعة اليومية.



الشكل 2-14: تطبيق Cal AI.

ما يميز Cal AI أيضاً هو دمج خصائص ذكية تُتيح تخصيص التوصيات الغذائية وفقاً للأهداف الصحية لكل مستخدم، مثل خسارة الوزن، بناء العضلات، أو المحافظة على الصحة العامة. يقوم التطبيق بتحليل العادات الغذائية السابقة والتقدم المُحقق، ثم يُقدم خطة غذائية مخصصة تتكيف مع الاحتياجات المتغيرة بمرور الوقت. إضافةً إلى ذلك، يوفر Cal AI رسوماً بيانية وتقارير مفصلة تساعد المستخدم في فهم العلاقة بين اختياراته الغذائية وحالته الصحية، ما يعزز من وعيه وسلوكه

الغذائي. واجهة الاستخدام المُبسطة تجعل من التطبيق أداة مناسبة لمختلف الفئات العمرية والمستويات التقنية، ويُظهر بذلك كيف يمكن للتكامل بين الذكاء الاصطناعي وتصميم التجربة الرقمية أن يُحدث تحولاً جذرياً في طريقة إدارة الصحة والتغذية على المستوى الشخصي [6].

الفصل الثالث:

خوارزمية YOLO

ومنصة Roboflow

1-3 خوارزمية YOLO


1-1-3 تمهيد

رؤية الحاسوب هي مجال سريع التطور يهدف إلى تمكين أجهزة الحاسوب من فهم وتحليل المعلومات المرئية بالطريقة نفسها التي يفهمها بها الإنسان. ويتضمن هذا المجال تطوير خوارزميات ونماذج وأنظمة قادرة على تحليل الصور ومقاطع الفيديو واستخراج معلومات مفيدة منها [7].

يُعتبر اكتشاف الأجسام (Object Detection) من أهم الفروع الفرعية في مجال رؤية الحاسوب، وهو يعني التعرف على وجود أشياء معينة داخل الصور أو الفيديوها، مثل الأشخاص أو السيارات أو الحيوانات، والتي تكون مسبقاً ضمن قائمة فئات محددة.

2-1-3 تصنيف الكائنات

هو مهمة تهدف إلى التعرف على العناصر الموجودة داخل صورة معينة وتصنيفها ضمن فئات محددة مسبقاً. يتم تنفيذ هذه المهمة غالباً باستخدام تقنيات تعلم الآلة، حيث يتم تدريب نموذج على مجموعة من الصور التي تم تصنيفها مسبقاً مع تسميات الفئات الخاصة بها. بعد إتمام التدريب، يصبح بإمكان النموذج استخدام ما تعلمه من خصائص وأنماط لتمييز الصور الجديدة وإسنادها إلى الفئة المناسبة [7].




الشكل 3-1: تصنيف الكائنات.

3-1-3 تحديد الكائنات

تُعد هذه المهمة من مهام رؤية الحاسوب، وتهدف إلى التعرف على الكائنات الموجودة داخل الصور وتحديد مواقعها بدقة، وذلك ضمن فئات محددة مسبقاً [7].


بفضل التقدم الكبير في تقنيات التعلم العميق، تمكن مجال كشف الكائنات من تحقيق نتائج مبشرة للغاية. فقد تم تطوير العديد من الخوارزميات والنماذج لأداء هذه المهمة، مثل R-CNN، وFaster R-CNN، وYOLO، وSSD. تُستخدم هذه النماذج على نطاق واسع في تطبيقات متنوعة، منها السيارات ذاتية القيادة، وأنظمة المراقبة، وتتبع الكائنات المتحركة في مقاطع الفيديو.



الشكل 3-2: تحديد الكائنات.

4-1-3 الشبكات العصبية الترشيحية القائمة على المناطق (Region-based CNN)

تُعد الشبكات العصبية الترشيحية القائمة على المناطق، والمعروفة اختصارًا بـ Region-Based CNN، من أبرز أساليب كشف الكائنات في مجال رؤية الحاسوب. تقوم هذه الطريقة على مبدأ رئيسي يتمثل في توليد مجموعة من المناطق الترشيحية داخل الصورة يُحتمل أن تحتوي على كائنات، ثم استخدام شبكة عصبية ترشيحية لتحليل كل منطقة على حدة وتحديد ما إذا كانت تحتوي فعليًا على كائن أم لا. وإذا تبيّن وجود كائن في إحدى هذه المناطق، تُجرى لاحقًا عملية تحسين لتحديد موقع الكائن بدقة أكبر وتصنيفه ضمن الفئة المناسبة له (كما هو موضح في الشكل 3-3). وغالبًا ما يُطلق على هذا المفهوم اسم "كشف الكائنات ذو المرحلتين" (Two-shot Object Detection)، لأن آليته تعتمد على خطوتين منفصلتين: ترشيح المناطق ثم تحليلها [7].



الشكل 3-3: هيكل R-CNN.

ومن أشهر النماذج التي اعتمدت هذا النهج نموذج R-CNN (Regional Convolutional Neural Network)، والذي شكّل الأساس لتطوير نسخ أخرى أكثر كفاءة، مثل Fast R-CNN وFaster R-CNN. وتهدف هذه النماذج اللاحقة إلى تحسين سرعة الأداء دون التضحية بالدقة.

وتعتمد مجتمعة على وسائل اقتراح مناطق مرشحة مثل البحث الانتقائي (Selective Search) لتحديد أجزاء من الصورة يُحتمل احتواؤها على كائنات، ثم تستخدم الشبكات العصبية الترشيحية لتصنيف هذه المناطق وتحسين تحديد مواضع الكائنات داخل الصورة. وقد أدى هذا الأسلوب إلى تحقيق تقدم كبير في مجالات متعددة، خاصة في التطبيقات التي تتطلب دقة عالية في تمييز الكائنات وتحديد مواقعها ضمن المشهد.

3-1-4-1 سلبيات R-CNN

على الرغم من أن الشبكات العصبية الترشيحية القائمة على المناطق أظهرت قدرة جيدة على أداء مهام كشف الكائنات بدقة مقبولة، فإنها ليست خالية من أوجه القصور التي تحدّ من فعاليتها في بعض السيناريوهات العملية. من أبرز هذه التحديات هو ارتفاع الكلفة الحسابية المطلوبة لتشغيل هذا النوع من النماذج، حيث تتطلب عمليات معالجة معقدة ووقتًا طويلًا نسبيًا، مما يجعل استخدامها في التطبيقات التي تتطلب استجابة فورية – مثل الأجهزة ذات القدرات المحدودة أو الأنظمة العاملة في الزمن الحقيقي – أمرًا غير عملي [7].


كما أن هذه الشبكات تحتاج إلى مجموعات بيانات ضخمة ومعلّمة بدقة، أي أن كل صورة يجب أن تكون مصنفة مسبقًا مع تحديد موقع الكائن فيها، وهو أمر يتطلب جهدًا بشريًا كبيرًا وزمنًا طويلًا، ما يزيد من صعوبة استخدامها على نطاق واسع أو في مجالات تفتقر إلى بيانات كافية. بالإضافة إلى ذلك، تعاني هذه الشبكات من محدودية في القدرة على التعميم، أي أنها لا تؤدي بنفس الكفاءة عند التعامل مع صور جديدة تختلف في طبيعتها عن الصور التي تم تدريبها عليها. كما أنها

تميل إلى معالجة الكائنات داخل الصور بشكل معزول، دون مراعاة السياق المحيط بها، مما قد يؤدي أحيانًا إلى نتائج غير دقيقة، خاصة في البيئات المعقدة التي تعتمد على فهم العلاقات بين العناصر المختلفة داخل الصورة. لهذه الأسباب، فإن الشبكات العصبية الترشيحية القائمة على المناطق لا تكون الخيار الأمثل في جميع الحالات، مما دفع الباحثين إلى تطوير بدائل أكثر كفاءة وسرعة.

3-1-5 كشف الكائنات بلقطة واحدة (Single Shot Object Detection)

يُعد الكشف عن الكائنات بلقطة واحدة من الأساليب الحديثة والفعالة في مجال الرؤية الحاسوبية، حيث يتم التعرف على الكائنات داخل الصور أو مقاطع الفيديو دفعة واحدة دون الحاجة إلى مراحل متعددة أو إلى توليد مناطق ترشيحية مسبقة. هذا الأسلوب، كما هو الحال في نموذج SSD (Single Shot MultiBox Detector) وكذلك نموذج YOLO (You Only Look Once)، يعتمد على استخدام شبكة عصبية واحدة تعالج الصورة بشكل شامل لتحديد مواضع الكائنات داخلها، وفي الوقت نفسه تصنيف كل كائن إلى الفئة المناسبة له. ومن أبرز مميزات هذا النهج أنه يتمتع بسرعة عالية وكفاءة كبيرة، ما يجعله مناسبًا للتطبيقات التي تتطلب استجابة آنية مثل أنظمة القيادة الذاتية أو الأجهزة المحمولة ذات القدرات الحسابية المحدودة. غير أن هذه النماذج قد تواجه أحيانًا بعض التحديات من حيث مستوى الدقة، خصوصًا في الحالات المعقدة التي تحتوي على كائنات صغيرة أو متقاربة جدًا داخل الصورة [7].

يوضح الشكل (3-4) الهيكلية العامة لعمل نموذج SSD بطريقة مبسطة، بدءًا من إدخال صورة بقياس 300×300 بكسل إلى الشبكة، مرورًا باستخدام شبكة VGG-16 المسبقة التدريب لاستخلاص الميزات البصرية الهامة من الصورة حتى الطبقة المسماة Conv5_3. بعد ذلك، يتم إلحاق طبقات إضافية، مثل Conv4_3 و Conv6 و Conv11_2، والتي تساعد على توليد ميزات متعددة المستويات تُستخدم لاحقًا للكشف عن الكائنات بأحجام مختلفة. في كل واحدة من هذه الطبقات، تُستخدم مصنفات خاصة تعمل على تحليل الميزات الموجودة وتحديد ما إذا كانت هناك كائنات ضمن تلك المنطقة، وما نوعها، وأين تقع بالضبط داخل الصورة. يعتمد النموذج على مصفوفات تنبؤ خاصة تُخرج معلومات متعلقة بالفئة التي ينتمي إليها الكائن، إلى جانب إحداثيات الإطار المحيط به.



الشكل 3-4: هيكل SSD.

بعد أن يحدد النموذج آلاف المواقع المحتملة التي قد تحتوي على كائنات - وفي هذا المثال تصل إلى 8732 موقعًا - يتم تطبيق تقنية تُعرف بإلغاء التكرار غير الضروري (Non-Maximum Suppression) لحذف النتائج المتكررة أو المتداخلة، مما يساهم في تقليل الضوضاء وزيادة دقة

الكشف. في نهاية العملية، يتم الحصول على النتيجة النهائية التي تتضمن الكائنات المكتشفة مع إطاراتها وتوصيفاتها، حيث أظهر نموذج SSD في هذا المثال معدل دقة متوسط يصل إلى 74.3% وسرعة معالجة تُقدَّر بـ 59 إطارًا في الثانية، مما يجعله خيارًا قويًا لأنظمة الرؤية الحاسوبية التي تحتاج إلى أداء سريع دون التضحية الكبيرة بالدقة.

3-1-6 مقاييس تقييم كشف الكائنات

هناك عدة مقاييس تُستخدم عادة لتقييم أداء نماذج كشف الكائنات:

1. الدقة المتوسطة (Mean Average Precision - mAP):


الدقة تعني نسبة الحالات التي تم اكتشافها بشكل صحيح (الحالات الإيجابية الحقيقية) من بين جميع الحالات التي توقعها النموذج على أنها صحيحة (بما في ذلك الأخطاء). مقياس mAP يأخذ في الاعتبار كل من الدقة والاسترجاع (عدد الحالات التي تم اكتشافها فعليًا من كل الحالات الحقيقية) ويحسب متوسط الدقة لكل فئة. كلما كانت قيمة mAP أعلى، كان أداء النموذج أفضل.

2. الدقة المتوسطة لكل فئة (Average Precision - AP):

هي مقياس يوضح دقة النموذج عند مستويات مختلفة من الاسترجاع. الدقة تعني عدد الحالات المكتشفة بشكل صحيح من بين جميع الحالات التي توقعها النموذج. أما الاسترجاع فهو عدد الحالات التي اكتشفها النموذج فعليًا من إجمالي الحالات الحقيقية. تُحسب AP كمساحة تحت منحنى الدقة مقابل الاسترجاع. كلما زادت قيمة AP، دل ذلك على أداء أفضل للنموذج.

3. التقاطع على الاتحاد (Intersection over Union - IoU):

يقيس مقدار التداخل بين المربع الذي يتنبأ به النموذج (الصندوق المحيط بالكائن) والمربع الحقيقي الموجود في البيانات (الصندوق الصحيح). يتم حسابه بقسمة مساحة التداخل بين الصندوقين على مساحة الاتحاد بينهما. كلما زادت قيمة IoU، كان التنبؤ أقرب للواقع.

$$IOU = \frac{\text{مساحة التداخل}}{\text{مساحة الاتحاد}} = \frac{\text{Diagram showing intersection of two rectangles}}{\text{Diagram showing union of two rectangles}}$$


الشكل 3-5: طريقة حساب IoU.

هناك أيضًا مقاييس أخرى لتقييم الدقة مثل معدل الإيجابيات الحقيقية (TPR)، ومعدل الإيجابيات الخاطئة (FPR)، ومقياس F1، ومعدل الفشل المتوسط اللوغاريتمي (Log Average Miss Rate - MR). بالإضافة إلى هذه المقاييس، يمكن تقييم نماذج كشف الكائنات من حيث كفاءتها الحسابية وسرعة أدائها.


3-1-7 تعريف خوارزمية YOLO

تُعتبر خوارزمية YOLO (اختصاراً لـ "You Only Look Once") واحدة من أشهر الخوارزميات المستخدمة في مجال كشف الكائنات باستخدام الذكاء الاصطناعي. تعتمد هذه الخوارزمية على

مبدأ معالجة الصورة كاملةً دفعة واحدة، بدلاً من تحليلها بشكل تدريجي، مما يجعلها سريعة وفعالة جداً في تحديد مواقع الكائنات داخل الصور [7].

بدأت YOLO بإصدارها الأول (YOLOv1) ومُرتّ بعدة تحسينات وإصدارات لاحقة، مثل YOLOv3 وYOLOv5 وYOLOv8، وصولاً إلى الإصدارات الحديثة التي طوّرتها شركة Ultralytics. وقد تم مؤخراً في عام 2025 إطلاق الإصدار الثاني عشر YOLOv12، والذي يُعد من أقوى الإصدارات حتى الآن. يتميز هذا الإصدار بتقنيات جديدة مثل آلية الانتباه المناطقي (Area Attention) وشبكات R-ELAN، مما يتيح له تحقيق توازن ممتاز بين الدقة وسرعة المعالجة.

كما يدعم YOLOv12 تنفيذ مهام متعددة مثل كشف الكائنات، تصنيف الصور، تقدير الوضعيات، والتعرف على الكائنات المائلة. وبفضل هذه التحسينات، أصبح YOLOv12 مناسباً أكثر من أي وقت مضى للاستخدام في التطبيقات العملية مثل أنظمة المراقبة الذكية والسيارات ذاتية القيادة.



الشكل 3-6: تطور إصدارات YOLO حتى عام 2025.


تُستخدم نماذج YOLO على نطاق واسع لأنها توفر توازناً جيداً بين سرعة المعالجة ودقة النتائج، كما يمكن تشغيلها بكفاءة حتى على أجهزة محدودة القدرات، مما يجعلها مناسبة للعديد من المشاريع العملية والتطبيقات الميدانية.

3-1-8-1 كيف تعمل خوارزمية YOLO

تعتمد خوارزمية YOLO (اختصاراً لـ You Only Look Once) على فكرة بسيطة وفعّالة، وهي تحليل الصورة دفعة واحدة لتحديد مواقع الكائنات داخلها وتسمية كل كائن منها بشكل مباشر. تقوم الخوارزمية بتقسيم الصورة إلى شبكة من الخلايا، وتكون كل خلية مسؤولة عن محاولة التنبؤ ما إذا كان هناك كائن ضمن نطاقها، وإذا وُجد، فإنها تقدّر مكانه بدقة على شكل "صندوق محيط" يحتوي على معلومات الموقع والحجم. الشكل (3-7) يوضح هذه العملية بشكل مرئي؛ ففي البداية تُعرض الصورة الأصلية، ثم يتم تقسيمها إلى شبكة، وتبدأ الخلايا بتحليل محتوى كل جزء، وبعدها تُرسم صناديق حول الكائنات المكتشفة مثل الكلب والدراجة والسيارة، مع تسميات لكل منها.

تبدأ الصورة رحلتها داخل نموذج YOLO بمرورها في شبكة عصبية تسمى DarkNet، حيث تُستخرج منها خصائص بصرية مهمة. بعدها، تُمرر هذه الخصائص إلى طبقات عصبية متصلة بالكامل (fully connected layers) تقوم بتوليد التوقعات المتعلقة بموقع كل كائن واحتمال انتمائه لفئة معينة. يظهر ذلك في الجزء السفلي من الشكل (3-7) حيث يتم تمثيل الصورة المدخلة بحجم $448 \times 448 \times 3$ ، ويتم استخراج خصائصها عبر شبكة DarkNet لتصبح بحجم

$7 \times 1024 \times 7$ ، ثم تمر على طبقة فيها 4096 وحدة عصبية، وتخرج النتيجة على شكل شبكة $7 \times 30 \times 7$. كل خلية من الشبكة تكون مسؤولة عن التنبؤ بعدة صناديق، وكل صندوق يحتوي على خمسة عناصر رئيسية: الإحداثيات (x, y) لمركز الكائن، العرض (w) ، الارتفاع (h) ، ودرجة الثقة (object score)، بالإضافة إلى احتمالات تصنيفه ضمن الفئات الممكنة (مثل كلب، دراجة، سيارة وغيرها) [7].



الشكل 3-7: هيكل خوارزمية YOLO.

يمكن تلخيص خطوات عمل YOLO فيما يلي:

1. يتم إدخال الصورة إلى شبكة عصبية تلافيفية (CNN) لاستخراج الخصائص المهمة منها.
2. تُمرر هذه الخصائص إلى طبقات عصبية كثيفة لتوقع إحداثيات الصناديق واحتمالات الفئات.

3. تُقسّم الصورة إلى شبكة من الخلايا، بحيث تتنبأ كل خلية بعدة صناديق تصف احتمال وجود كائن فيها.

4. يخرج النموذج بمجموعة من الصناديق المصحوبة باحتمالات التصنيف لكل خلية في الشبكة.

5. يتم تطبيق خوارزمية تُدعى Non-Max Suppression لإزالة الصناديق المتكررة والمتداخلة، مع الاحتفاظ فقط بالصندوق الذي يحمل أعلى درجة ثقة.

6. تكون النتيجة النهائية مجموعة صناديق مرفقة بتسميات الفئات، تمثل الكائنات المكتشفة في الصورة.

من أبرز ما يميز YOLO هو أنه يعالج الصورة دفعة واحدة، مما يجعله سريعًا جدًا مقارنة بالخوارزميات التي تستخدم مرحلتين للكشف، مثل R-CNN والإصدارات المتقدمة منه.

3-1-8-2 نقاط القوة

🍏 **الكشف عن الأجسام في الوقت الحقيقي:** يتميز YOLO بقدرته على اكتشاف الأجسام لحظة بلحظة، مما يجعله مناسبًا لتطبيقات مثل أنظمة المراقبة بالفيديو والسيارات ذاتية القيادة.

🍏 **دقة عالية:** يحقق YOLO دقة عالية من خلال استخدام الشبكات العصبية الالتفافية (CNN) التي تتنبأ بنوع الجسم وموقعه في الصورة في آنٍ واحد.

🍏 **الكشف من خلال تمريرة واحدة فقط:** يمكن ل YOLO اكتشاف الأجسام في الصورة من خلال تمريرة واحدة فقط عبر الشبكة، مما يجعله أكثر كفاءة مقارنةً بأساليب الكشف الأخرى التي تحتاج لعدة تمريرات.

🍏 **أداء جيد مع الأجسام الصغيرة:** يستطيع YOLO التعرف على الأجسام الصغيرة داخل الصورة

بفضل طريقة تقسيم الصورة إلى شبكة من الخلايا.

🍏 **كفاءة في استخدام وحدات معالجة الرسومات (GPU):** يعتمد YOLO على بنية شبكية

تعتمد بالكامل على الطبقات الالتفافية، مما يتيح الاستفادة القصوى من قدرات الـ GPU أثناء

التدريب أو التنبؤ.

🍏 **القدرة على التعامل مع الأجسام بأحجام مختلفة:** يستخدم YOLO ما يُعرف بصناديق

التثبيت (anchor boxes) مما يساعد النموذج في التعرف على الأجسام ذات الأحجام المختلفة

داخل نفس الصورة.

3-8-1-3 التحديات

🍏 **مقتصر على كشف الأشياء فقط:** برنامج YOLO مصمم بشكل رئيسي لاكتشاف الأشياء في

الصور، لكنه قد لا يكون جيدًا في مهام أخرى مثل تقسيم الصور إلى أجزاء دقيقة أو تمييز كل

جزء على حدة.

🍏 **دقته أقل من بعض الطرق الأخرى:** رغم أن YOLO دقيق إلى حد ما، إلا أن هناك طرق أخرى

مثل RetinaNet أو Mask R-CNN قد تعطي نتائج أدق في كشف الأشياء.

🍏 **يواجه صعوبة مع الأشياء الصغيرة جدًا:** طريقة YOLO تعتمد على تقسيم الصورة إلى شبكة،

وهذا قد يجعل من الصعب عليه اكتشاف الأشياء الصغيرة جدًا، خاصة إذا كانت قريبة من

أشياء أخرى.

🍏 لا يدعم تتبع الأشياء: YOLO لا يحتوي على ميزة تتبع الأشياء عبر الفيديوها، لذلك قد لا يكون مناسبًا للتطبيقات التي تحتاج لمتابعة حركة الأشياء على مدى فترة زمنية، مثل المراقبة بالفيديو.

2-3 منصة ROBOFLOW



الشكل 3-8: منصة Roboflow.

تُعد منصة متقدمة تُستخدم في إعداد مجموعات البيانات التي تُوظف في تطبيقات رؤية الحاسوب، لاسيما في مهام تصنيف وتمييز الكائنات داخل الصور. تقوم هذه الأداة بدور محوري في تجهيز الصور لتكون صالحة لاستخدامها في تدريب نماذج الذكاء الاصطناعي، من خلال تمكين المستخدم من رفع الصور، فرزها حسب الفئات المستهدفة، ثم وسم العناصر الظاهرة فيها عبر تحديد موقع كل كائن داخل الصورة وتعيين الفئة المناسبة له، مثل مركبة أو إنسان أو نبات [8].

توفر Roboflow بيئة سهلة الاستخدام تُساعد في إعداد بيانات متجانسة، حيث تقوم تلقائيًا بتقسيم الصور إلى مجموعات مخصصة للتدريب والاختبار والتقييم، مما يتيح إمكانية قياس أداء النموذج بدقة من خلال بيانات لم يتعرض لها أثناء التعلم. كما تتيح المنصة تصدير البيانات بعد تجهيزها

بصيغ متوافقة مع معظم أطر التعلم العميق، مما يُبسّط دمجها في مشاريع الذكاء الاصطناعي دون الحاجة إلى إجراء تحويلات معقدة أو يدوية.

يسهم استخدام Roboflow في تقليل الأخطاء الناتجة عن الوسم غير الدقيق أو التنظيم العشوائي للبيانات، ويضمن بذلك مستوى أعلى من الكفاءة والموثوقية في بناء النماذج. وتُعد هذه المرحلة أساسية لأي مشروع يعتمد على الرؤية الحاسوبية، إذ إن جودة البيانات المُعدّة مسبقًا تُشكل أحد العوامل الحاسمة في مدى دقة النموذج النهائي وفعاليته في التعامل مع الصور الجديدة.

1-2-3 توسيع البيانات (Data Augmentation)

إحدى الخطوات الحيوية التي تُكمل عملية تجهيز البيانات في رؤية الحاسوب هي تنظيم البيانات وتوسيعها، وهي عملية تُعرف باسم Data Augmentation. تهدف هذه المرحلة إلى تحسين جودة مجموعة البيانات وجعل النموذج أكثر قدرة على التعميم عند التعامل مع صور جديدة أو غير مألوفة. يُقصد بتنظيم البيانات ترتيب الصور ضمن فئات واضحة وتحديد نسب مخصصة للتدريب والاختبار والتقييم بشكل متوازن، مما يساعد على الحصول على نموذج يمكنه التعلم بكفاءة دون انحياز لفئة على حساب أخرى [8].


أما توسيع البيانات، فيُعنى بتوليد صور جديدة اعتمادًا على الصور الأصلية من خلال إدخال تعديلات بسيطة تحاكي تنوع الحالات الواقعية، مثل تدوير الصورة بزاوية معينة، أو قلبها أفقيًا، أو تغيير الإضاءة، أو اقتصاص جزء منها، أو حتى إضافة بعض التشويش كما هو واضح في الشكل

(9-3). تُستخدم هذه التقنيات من أجل زيادة حجم البيانات المتوفرة دون الحاجة إلى جمع صور إضافية، وهو ما يساعد في تجنب مشكلة الإفراط في التعلم ويُعزز من قدرة النموذج على التعرف على الكائنات في ظروف تصوير مختلفة.


Augmentation Options

Augmentations create new training examples for your model to learn from.

IMAGE LEVEL AUGMENTATIONS



BOUNDING BOX LEVEL AUGMENTATIONS ?



الشكل 9-3: خيارات توسيع وتعزيز البيانات.

يُعتبر التوسيع من العوامل التي تسهم في تحسين دقة النموذج واستقراره، خاصة عند توفر عدد محدود من الصور الأصلية. كما أنه يُقلل من فرص التحيز لنمط معين في البيانات، ويمنح النموذج مرونة أعلى في التعرّف على الكائنات في بيئات غير مثالية. باستخدام أدوات مثل Roboflow، يمكن تنفيذ عمليات التوسيع بشكل تلقائي ومنظم، مما يُسهّل هذه المهمة على المستخدم ويوفر عليه الكثير من الوقت والجهد مقارنةً بالطرق اليدوية.

Google Colab 3-3

يُعدّ Google Colab منصة متميزة توفر بيئة عمل سحابية تمكن المستخدمين من تنفيذ العمليات الحسابية والمعالجة بشكل سريع وفعال، دون الحاجة إلى أجهزة حاسوب ذات مواصفات عالية. يتميز هذا النظام بإتاحة موارد معالجة قوية، مثل وحدات المعالجة المركزية (CPU) ووحدات معالجة الرسومات (GPU)، مما يساعد في تسريع تنفيذ البرامج والتطبيقات، خاصة في مجالات التعلم الآلي وتحليل البيانات. بالإضافة إلى ذلك، فإن Google Colab متاح مجانًا، مما يجعله خيارًا مثاليًا للطلاب والباحثين الذين يرغبون في تطوير مشاريعهم دون تكبد تكاليف مادية كبيرة. هذا الجمع بين القوة، والسهولة، والتكلفة المنخفضة يجعل من Google Colab أداة مناسبة لجميع المستويات العلمية [9].




الشكل 3-10: Google Colab.

3-3-1 الربط مع Roboflow

في سياق هذا المشروع، تم استخدام واجهة API المقدمة من منصة Roboflow لسحب البيانات بكفاءة عالية مباشرة إلى بيئة Google Colab. هذه الواجهة تتيح ربطًا مباشرًا بين النموذج المدرب ومكان التنفيذ، مما يُمكن المستخدم من تحميل الصور، النماذج، ونتائج التدريب دون الحاجة إلى تحميل يدوي أو خطوات إضافية. توفر هذه الآلية سرعة في الوصول للبيانات، وتقلل من الأخطاء المحتملة الناتجة عن النقل اليدوي، كما تسهّل تحديث النماذج بشكل مباشر عند إدخال تحسينات أو تغييرات.

وتُعد واجهة API (واجهة برمجة التطبيقات) من الأدوات البرمجية الفعالة التي تُستخدم لتمكين التواصل بين مختلف الأنظمة البرمجية بطريقة موثوقة وآلية. في هذا السياق، مكّنت API الخاصة بـ Roboflow من تنفيذ أوامر التدريب والاستدعاء والتحليل داخل Google Colab دون انقطاع في سير العمل. وكما يظهر في الشكل (3-11)، توفر المنصة خيارات متنوعة لتدريب النماذج، سواء باستخدام AutoML أو عبر تخصيص نموذج معين مثل YOLOv5. بعد اختيار النموذج، يمكن

الحصول على كود جاهز يتضمن رابط ال API والتعليمات البرمجية الضرورية عبر زر " Get Snippet"، مما يسمح بدمج النموذج وتشغيله بسهولة ضمن بيئة Colab. هذا التكامل يُعد مثلاً عملياً على أهمية استخدام واجهات API في تبسيط تطبيقات الذكاء الاصطناعي وتسريع تنفيذها في البيئات البرمجية السحابية.



الشكل 3-11: إعداد وتدريب نموذج AI باستخدام Roboflow لتنفيذه في Google Colab.

الفصل الرابع: التنفيذ

العملي

1-4 تهيئة بيئة العمل


تم إعداد بيئة العمل الخاصة بهذا المشروع باستخدام نظام التشغيل Windows، حيث يتم تطوير النظام باستخدام لغة البرمجة Python. ولتوفير بيئة تفاعلية تسهل كتابة الأكواد وتنفيذها، تم اختيار بيئة التطوير المتكاملة Visual Studio Code، التي تتيح إمكانية تحرير الكود وتنظيمه بشكل فعال، مع دعمها المتقدم للعديد من المكتبات البرمجية.

فيما يتعلق بتحليل الصور، تم اختيار مكتبة OpenCV الخاصة بمعالجة الصور والفيديوهات، وهي أساسية لتنفيذ تقنيات الرؤية الحاسوبية التي يعتمد عليها النظام في تحليل مكونات الطعام. كما تم استخدام مكتبة Ultralytics لتحميل نموذج YOLO (You Only Look Once)، الذي يتيح الكشف عن مكونات الطعام في الصور وتحليلها بسرعة ودقة عالية.

بالنسبة للواجهة الرئيسية للنظام، تم الاستعانة بمكتبة Tkinter لبناء واجهة مستخدم تفاعلية وسهلة الاستخدام، حيث تتيح للمستخدمين تحميل الصور وعرض النتائج الغذائية بصورة منظمة وسهلة الفهم.


2-4 المخطط التدفقي

الشكل (1-4) يمثل سير العمل في نظام يستخدم نموذج YOLO للكشف عن الأشياء في الصور. يبدأ البرنامج بتهيئة نموذج YOLO ثم يلتقط صورة، ويتحقق من محتويات الإطار باستخدام النموذج. بعد التحقق من النتائج، يتم عرضها، ويستمر البرنامج في هذه الدورة حتى يتم إيقافه.



الشكل 4-1: مخطط خوارزمية العمل.

3-4 مخطط سير الواجهات




الشكل 2-4: مخطط سير الواجهات.


4-4 التنفيذ النهائي للنظام




الشكل 4-3: الواجهة الرئيسية للنظام.




الشكل 4-4: فتح الكاميرا المباشرة.




الشكل 4-5: التعرف على المنتج وإظهار المعلومات الرئيسية من خلال الكاميرا المباشرة.




الشكل 4-6: التعرف على عدة منتجات من خلال الكاميرا المباشرة.




الشكل 4-7: فتح واجهة تحميل الصورة من الجهاز.




الشكل 4-8: اختيار الصورة.



الشكل 4-9: إظهار معلومات المنتج.



الشكل 4-10: التعرف على عدة منتجات في الصورة.



الشكل 4-11: فتح واجهة الحميات.



الشكل 4-12: وجبات حمية مرضى السكري.

الفصل الخامس:

الخاتمة والآفاق

المستقبلية

في ختام هذا المشروع، يمكن التأكيد على أن استخدام تقنيات الذكاء الاصطناعي، وتحديدًا الرؤية الحاسوبية المدعومة بخوارزميات تعلم الآلة والتعلم العميق، قد أتاح تحقيق قفزة نوعية في مجال تقدير السعرات الحرارية وتحليل المكونات الغذائية من خلال الصور الملتقطة للطعام. لقد أظهر النظام الذكي المطور كفاءة عالية في تحديد أنواع الأطعمة وتقدير محتواها الغذائي والسعري بدقة ملحوظة، وهو ما يفتح المجال أمام تعزيز الوعي الصحي لدى الأفراد وتمكينهم من اتخاذ قرارات غذائية مبنية على بيانات موضوعية وموثوقة دون الحاجة إلى الاعتماد على الطرق التقليدية المعتمدة على الإدخال اليدوي أو الحسابات غير الدقيقة. كما أثبت المشروع فعاليته في معالجة إحدى أبرز المشكلات المرتبطة بتقدير السعرات، والمتمثلة في تعقيد تنوع الأطعمة، واختلاف طرق الطهي، وصعوبة التقدير الكمي للمكونات الغذائية ضمن الوجبات المركبة.

شكل هذا العمل البحثي خطوة متقدمة في تطوير أداة ذكية قادرة على خدمة مختلف الشرائح المجتمعية، من الرياضيين الراغبين في تحسين أدائهم البدني، إلى مرضى السكري الذين يحتاجون إلى متابعة دقيقة لمستوى استهلاكهم من الكربوهيدرات، وصولاً إلى الأفراد الساعين إلى التحكم بأوزانهم أو تبني أنماط غذائية صحية ومتوازنة. كما وفر المشروع بنية تقنية قابلة للتطوير والتحديث من خلال توظيف قاعدة بيانات غذائية مرنة، وقابلية دمجها مع تطبيقات الهواتف الذكية، ومنصات الرعاية الصحية الرقمية، مما يعزز من سهولة الاستخدام ويدعم الانتشار الواسع لهذا النظام في الحياة اليومية للمستخدمين. وتبرز أهمية هذا الابتكار في ظل التوجهات العالمية الرامية إلى تحسين الصحة العامة والحد من انتشار الأمراض المرتبطة بسوء التغذية والسمنة،

حيث يمكن لمثل هذه الأنظمة الذكية أن تكون جزءاً محورياً من أدوات الرعاية الصحية الوقائية والشخصية.

مع ذلك، يظل المشروع مفتوحاً أمام العديد من مجالات التحسين والتطوير المستقبلي التي من شأنها الارتقاء بأداء النظام وتوسيع نطاق استخداماته العملية. وفي هذا السياق، يمكن استشراف الآفاق المستقبلية التالية:

🍏 تطوير قاعدة بيانات غذائية أكثر شمولاً تشمل الأطعمة من مختلف الثقافات والمطابخ العالمية لضمان دقة أكبر في التعرف على الأغذية المتنوعة.

🍏 تحسين نماذج الذكاء الاصطناعي المستخدمة عبر تدريبها على مجموعات بيانات أوسع وأعلى جودة لتقليل هامش الخطأ في تقدير السعرات والمكونات الغذائية.

🍏 دمج خواص تحليل طريقة الطهي وتأثيرها على القيمة الغذائية للوجبة، مثل القلي أو الشواء أو السلق، بهدف تقديم تقديرات سعرات حرارية أكثر واقعية.

🍏 تصميم واجهات استخدام تفاعلية تدعم اللغات المختلفة وتوفر للمستخدمين توصيات غذائية مخصصة بناءً على أهدافهم الصحية والشخصية.

🍏 تطوير نسخة من النظام قادرة على العمل في الزمن الحقيقي بفعالية على أجهزة الهواتف المحمولة ذات الموارد المحدودة، دون الحاجة للاتصال الدائم بالإنترنت.

🍏 استحداث آلية تكامل مع التطبيقات الصحية القابلة للارتداء مثل الساعات الذكية وأجهزة تتبع النشاط البدني لتحسين توصيات النظام بناءً على معدل النشاط اليومي للمستخدم.

توسيع نطاق الأبحاث لتشمل تحليل المشروبات، والمكونات المخفية ضمن الوصفات المعقدة، وتقدير الأوزان والكميات تلقائياً عبر تقنيات القياس البصري.

إنشاء آلية لتحديث البيانات تلقائياً من مصادر غذائية معتمدة لضمان استمرارية دقة المعلومات وتحديثها مع ظهور منتجات غذائية جديدة في الأسواق.

استكشاف إمكانيات دمج النظام مع الأنظمة الطبية لتقديم دعم غذائي مخصص للمرضى ضمن خطط العلاج الغذائي التي يوصي بها الأطباء أو خبراء التغذية.

توسيع وظائف النظام ليشمل قياس مؤشرات غذائية أخرى مثل نسب الفيتامينات والمعادن للمساهمة في تحقيق نظام غذائي متكامل يدعم الصحة العامة.

تمثل هذه الآفاق المستقبلية مساراً واعداً نحو تعزيز فعالية النظام الذكي في حساب السعرات الحرارية وتحليل المكونات الغذائية، بما يتلاءم مع الاحتياجات المتغيرة للمجتمعات في العصر الرقمي، وبما يواكب التطور المستمر في مجالات الذكاء الاصطناعي والتكنولوجيا الصحية.

المراجع

[1]: Whitney, E., & Rolfes, S. R. (2018). Understanding Nutrition (15th ed.).

Cengage Learning.

[2]: Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

[3]: Noor, M. H. M., & Ige, A. O. (2024). A survey on state-of-the-art deep learning applications and challenges. arXiv preprint arXiv:2403.17561.

[4]: SnapCalorie. (n.d.). SnapCalorie: AI calorie counter from a photo. Retrieved May 29, 2025, from <https://www.snapcalorie.com/>

[5]: CalorieMama. (n.d.). CalorieMama AI: Automatic food recognition & calorie estimation. Retrieved May 29, 2025, from <https://www.caloriemama.ai/>

[6]: CalAI. (n.d.). CalAI: AI Calorie Counter & Nutrition Assistant. Retrieved May 29, 2025, from <https://www.calai.app/>

[7]: Kili Technology. (n.d.). YOLO Algorithm: Real-Time Object Detection from A to Z. Retrieved May 29, 2025, from <https://kili-technology.com/data-labeling/machine-learning/yolo-algorithm-real-time-object-detection-from-a-to-z#introduction>

[8]: Roboflow. (n.d.). Roboflow: Give your software the sense of sight. Retrieved May 29, 2025, from <https://roboflow.com/>

[9]: Google. (n.d.). Google Colab. Retrieved May 29, 2025, from <https://colab.google/>