



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الوطنية الخاصة
قسم هندسة الحاسوب

مشروع أعد لنيل درجة الإجازة في تخصص هندسة الحاسوب بعنوان:

تطوير نظام ذكي لمراقبة دوام العمال باستخدام الذكاء

الاصطناعي والرؤية الحاسوبية

إعداد الطالبات:

رغد الشيخ خليل

نانسي اسحق

إشراف الدكتور المهندس:

أحمد رياض كردي

2025-2024

بسم الله الرحمن الرحيم

{ يَرْفَعُ اللَّهُ الَّذِينَ آمَنُوا مِنْكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ }

{ وَآخِرُ دَعْوَاهُمْ أَنِ الْحَمْدُ لِلَّهِ رَبِّ الْعَالَمِينَ }

إله لا يطيب الليل إلا بذكره ولا يطيب النهار إلا بطاعته ولا تطيب اللحظات إلا بذكره جل جلاله

إلى من بعث الرسالة وأدى الأمانة سيدنا محمد صلى الله عليه وسلم

من قال أنا لها نالها...

لم تكن الرحلة قصيرة ولا ينبغي لها أن تكون، لم يكن الحلم قريباً ولا الطريق كان محفوفاً بالتسهيلات لكننا فعلناها...

الحمد لله حباً وشكراً وامتناناً الذي بفضله نحن اليوم ننظر إلى حلم طال انتظاره وقد أصبح واقعاً نفتخر به،

فالحمد لله الذي أعاننا ويسر لنا الوصول إلى هذا الإنجاز

الحمد لله الذي يسر البدايات وأكمل النهايات وبلغنا الغايات الحمد لله رب العالمين وبين العلم والصبر، كانت

رحلتنا...

الشكر كل الشكر إلى الذين مهدوا لنا طريق العلم والمعرفة, إلى من أشعل شمعة في دروب علمنا....

إلى الهيئة التدريسية في كلية هندسة المعلوماتية عامة والهيئة التدريسية في قسم الحاسوب خاصة ونخص

بالشكر

الدكتور الفاضل (أحمد كردي)

بمناسبة انتهاء مشروع التخرج، نتقدم بخالص الشكر والتقدير لجهودكم القيمة وتوجيهاتكم الثمينة التي أسهمت في

إنجاح هذا العمل.

لقد كان تشریفاً لنا أن نكون تحت إشرافكم خلال هذه الرحلة التعليمية، حيث استفدنا من خبرتكم الأكاديمية

والعملية في تطوير المشروع وتحسينه. كما نقدر دعمكم المستمر لنا طوال السنوات الخمس الماضية، والتي كانت

بمثابة أساس متين لمسيرتنا الأكاديمية.

نتمنى لكم دوام التوفيق، ونأمل أن نكون عند حسن ظنكم.

نتقدم بأسمى آيات الشكر والعرفان لكل من:

معالي العميد الأستاذ الدكتور هاني الخطيب

رئيس القسم الأستاذ الدكتور وسيم رمضان

الدكتورة الفاضلة سمر الحلبي

الأستاذ الدكتور نايف الحاج يونس

على جهودكم المتميزة في تعليمنا وإرشادنا طوال خمس سنوات من العطاء. لقد كان شرفاً لنا أن نكون تحت

رعايتكم، حيث تعلمنا من علمكم وحكمتكم ما يفوق المناهج الأكاديمية.

نعدكم بأن نحمل دائماً اسم كليتنا بفخر، ونتمنى لكم دوام التوفيق في إعداد الأجيال القادمة.

الملخص:

يهدف المشروع إلى تطوير نظام ذكي يعتمد على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية لحساب الساعات الفعلية للعمل لكل موظف في الشركة بدقة تصل إلى الثواني، مع التمييز بين الحضور الفعلي والغياب أو أي محاولات للتهرب من العمل مثل مغادرة منطقة العمل دون إذن. يعمل النظام على تتبع حركة الموظفين باستخدام نماذج متقدمة مثل YOLO و DeepSORT للكشف عن العمال وتتبعهم داخل مناطق العمل المحددة. يتم تسجيل بيانات الحضور والانصراف تلقائيًا، حيث تُخزن بيانات الموظفين مثل المعرّفات (IDs) ومدة العمل وأرقام المكاتب والتواريخ في قاعدة بيانات خاصة، ثم تُستخرج هذه البيانات لتكون متاحة في ملف Excel في نهاية كل دوام، مما يسهل عملية المراجعة والتقارير الإدارية. يتم دمج مكتبات مثل pandas و datetime لتحليل الوقت وحساب ساعات العمل بدقة. يشمل المشروع عدة مراحل رئيسية تبدأ بدراسة وتحليل المتطلبات ثم جمع البيانات وتحضيرها، يليها تصميم النموذج واختيار الأدوات المناسبة، وأخيراً تنفيذ النموذج وتدريبه لتحقيق أفضل أداء.

الكلمات المفتاحية:

الذكاء الاصطناعي، الرؤية الحاسوبية، تتبع الموظفين، حساب ساعات العمل، تعلم عميق

ABSTRACT:

The project aims to develop an intelligent system based on artificial intelligence and computer vision technologies to accurately calculate the actual working hours of each employee in the company, down to the second. It distinguishes between actual attendance, absence, and any attempts to evade work such as leaving the work area without permission. The system tracks employee movements using advanced models like YOLO and DeepSORT to detect and monitor workers within designated work areas. Attendance and departure data are recorded automatically, storing employee information such as IDs, working hours, office numbers, and dates in a dedicated database. This data is then extracted into an Excel file at the end of each workday to facilitate administrative review and reporting. Libraries such as datetime and pandas are integrated to analyze time and accurately calculate working hours. The project involves several key stages, starting with studying and analyzing requirements, followed by data collection and preparation, then model design and tool selection, and finally, implementing and training the model to achieve optimal performance.

Keywords:

Artificial Intelligence, Computer Vision, Employee Tracking, Working Hours Calculation, Deep Learning.

المحتويات

1 الفصل الأول: مقدمة المشروع ومراجعة الدراسات السابقة 1

1-1 مقدمة عامة..... 2

2-1 دراسات سابقة..... 2

1-2-1 نظام دعم القرار الذكي الآلي لإدارة الموارد البشرية (AIDSS-HR) 3

2-2-1 نظام CleverControl لمراقبة الموظفين 6

3-2-1 مقارنة الدراسة السابقة مع المشروع..... 8

3-1 الخلفية النظرية..... 9

1-3-1 مفهوم الذكاء الاصطناعي 9

2-3-1 تعلم الآلة مقابل التعلم العميق: لماذا لم يتم اعتماد تعلم الآلة في هذا المشروع؟ 11

3-3-1 الشبكات العصبية الاصطناعية (ANN) 13

4-3-1 مفهوم التعلم الزائد ودوال التفعيل 17

4-1 أساسيات معالجة الصور..... 20

1-4-1 مفهوم الصورة الرقمية..... 20

2-4-1 التعرف على الكائنات..... 21

2 الفصل الثاني: خوارزمية YOLO (You Only Look Once) 24

1-2 مقدمة عن YOLO 25

27	2-2 خطوات عمل YOLO
27	1-2-2 تقسيم الصورة إلى خلايا
29	2-2-2 معالجة الخلايا باستخدام CNN
32	3-2-2 إنتاج البوكسات
33	3-2 تقنية IoU
35	4-2 أدوات ومكتبات YOLO
37	3 الفصل الثالث: تتبع الكائنات
38	1-3 مفهوم تتبع الكائنات (Object Tracking)
38	2-3 استخدامات وأنواع تتبع الكائنات
39	1-2-3 تتبع الفيديو (Video Tracking)
40	2-2-3 التتبع البصري (Visual Tracking)
40	3-2-3 تتبع الصور (Image Tracking)
41	4-2-3 كاميرا تتبع الكائنات (Object Tracking Camera)
42	3-3 التحديات الشائعة لتتبع الكائنات
42	1-3-3 سرعة التدريب والتتبع
42	2-3-3 تشويش الخلفية
43	3-3-3 اختلاف أحجام الكائنات في الصور

44	4-3-3 التداخل
45	4-3 مستويات تتبع الكائنات
45	1-4-3 تتبع الكائنات المتعددة (MOT)
47	5-3 تتبع الكائن الفردي (SOT)
48	6-3 خوارزميات تتبع الكائنات المتعددة (MOT)
48	1-6-3 مكتبة OpenCV
50	2-6-3 خوارزمية DeepSORT
50	3-6-3 برنامج MATLAB
50	4-6-3 خوارزمية MDNet
52	4 الفصل الرابع: البناء التطبيقي للنظام الذكي
53	1-4 مقدمة الفصل
53	2-4 مراحل تطور العمل
54	3-4 مخطط خوارزمية العمل
55	4-4 عرض النظام أثناء التنفيذ
57	5-4 الخاتمة والآفاق المستقبلية
60	5 الملحق
65	6 المراجع

فهرس الأشكال

- الشكل (1-1): إدارة الأداء - التوظيف. 4
- الشكل (2-1): المعمارية المقترحة لنظام AIDSS-HR. 5
- الشكل (3-1): نموذج تطوير النظام التزايدى. 6
- الشكل (4-1): نظام CleverControl. 6
- الشكل (5-1): استخدام الذكاء الاصطناعي والرؤية الحاسوبية لإدارة أداء الموظفين. 10
- الشكل (6-1): الفرق بين تعلم الآلة والتعلم العميق. 12
- الشكل (7-1): بنية الشبكة العصبية الاصطناعية. 13
- الشكل (8-1): بنية الشبكة العصبية العميقة. 16
- الشكل (9-1): الفرق بين Overfitting و Balanced و Underfitting. 18
- الشكل (10-1): آلية عمل دالة التفعيل في الشبكة العصبية الاصطناعية. 19
- الشكل (11-1): التعرف على الكائنات. 21
- الشكل (1-2): سرعة خوارزمية YOLO مقارنة بخوارزميات التعرف على الكائنات الأخرى تطورًا. 25
- الشكل (2-2): مقارنة بين إصدارات YOLO المختلفة من حيث الدقة مقابل زمن التنفيذ. 27
- الشكل (3-2): خطوات عمل خوارزمية YOLO. 28
- الشكل (4-2): بنية شبكة CNN. 30
- الشكل (5-2): آلية عمل تقنية IoU. 34

- الشكل (2-6): مكتبة Ultralytics..... 35
- الشكل (2-7): مكتبة OpenCV..... 36
- الشكل (3-1): تتبع الكائنات (Object Tracking)..... 38
- الشكل (3-2): تتبع الكائنات في لقطات الفيديو المباشرة (الزمن الحقيقي)..... 39
- الشكل (3-3): كشف وتتبع معدات الحماية الشخصية في تطبيقات المرافق والطاقة..... 41
- الشكل (3-4): إزالة الخلفية لتسهيل تتبع الكائنات بدقة باستخدام مكتبة OpenCV..... 43
- الشكل (3-5): تنفيذ هرم الميزات..... 44
- الشكل (3-6): مثال على التداخل في كشف وتتبع الكائنات: الشخص مخفي جزئياً خلف الصناديق..... 44
- الشكل (3-7): الفرق بين تتبع الكائنات المتعددة وكشف الكائنات..... 46
- الشكل (3-8): تتبع الكرة فقط ضمن مشهد يحوي عدة لاعبين..... 47
- الشكل (3-9): تتبع الأشخاص داخل المتاجر باستخدام تقنيات الرؤية الحاسوبية..... 49
- الشكل (4-1): مخطط خوارزمية العمل للنظام..... 54
- الشكل (4-2): تتبع الحضور الفعلي للموظفين داخل مناطق العمل المحددة..... 55
- الشكل (4-3): رصد مغادرة أحد الموظفين لمنطقة العمل المحددة..... 56

فهرس الجداول

الجدول (1-1): مقارنة بين أشهر خوارزميات التعرف على الكائنات. 23

الفصل الأول: مقدمة

المشروع ومراجعة

الدراسات السابقة

1-1 مقدمة عامة

في الشركات التقليدية، يواجه مديرو الموارد البشرية تحديًا كبيرًا يتمثل في تحديد الساعات الفعلية التي يقضيها الموظفون في العمل. غالبًا ما تعتمد هذه الشركات على أنظمة يدوية أو إلكترونية بسيطة لتسجيل الحضور والانصراف، مثل استخدام بصمات الأصابع أو البطاقات الذكية. ومع ذلك، فإن هذه الأنظمة تعاني من قصور واضح، إذ لا تقدم حلولاً دقيقة للتعامل مع حالات الغياب غير المبرر أو التهرب من العمل، مثل مغادرة الموظف منطقة العمل دون إذن أو قضاء وقت طويل خارج نطاق مهامه الرسمية. هذا النقص في الدقة يؤثر سلبيًا على كفاءة إدارة الوقت والإنتاجية العامة للشركة.

من هنا تأتي أهمية المشروع المقترح الذي يستهدف تحسين إدارة الموارد البشرية باستخدام تقنيات حديثة تعتمد على الذكاء الاصطناعي والرؤية الحاسوبية. فبدلاً من الاعتماد على الأساليب التقليدية التي قد تكون عرضة للأخطاء أو التلاعب، يقدم المشروع نظامًا ذكيًا قادرًا على تتبع الموظفين بدقة ومراقبة أدائهم بشكل مستمر. هذا النظام ليس مجرد أداة لتسجيل الحضور والانصراف، بل هو حل شامل يمكنه تمييز الحضور الفعلي عن الغياب أو التهرب من العمل، مما يساهم في تعزيز الشفافية ورفع مستوى الانضباط الوظيفي.

يهدف المشروع إلى تصميم نظام ذكي يستطيع حساب الساعات الفعلية للعمل بكل دقة، حتى على مستوى الثواني، بما يعكس الصورة الحقيقية لأداء الموظفين. يعمل النظام على تتبع الموظفين داخل مناطق العمل المحددة باستخدام تقنيات متقدمة مثل الكشف عن الكائنات وتتبع الحركة. يتم تخزين بيانات الموظفين الأساسية، مثل المعرفات (IDs) ومدة العمل وأرقام المكاتب والتواريخ، في قاعدة بيانات خاصة، ثم يتم استخراجها كتقارير شاملة في ملف Excel في نهاية كل دوام، مما يسهل عملية المراجعة


والتحليل الإداري. بهذه الطريقة، يصبح بإمكان الشركات ضمان استغلال الوقت بشكل أمثل وتحقيق أعلى مستويات الكفاءة والإنتاجية.

2-1 دراسات سابقة

1-2-1 نظام دعم القرار الذكي الآلي لإدارة الموارد البشرية (AIDSS-HR)

تسلط هذه الدراسة الضوء على أهمية تحسين أداء الموظفين في المؤسسات من خلال استخدام أنظمة ذكاء اصطناعي مدعومة بتقنيات تكنولوجيا المعلومات والاتصالات. طور فريق بحث من قسم علوم الحاسوب في كلية بوليتكنيك أكرا وكلية بوليتكنيك كوماسي في غانا نظامًا يُعرف باسم "AIDSS-HR"، وهو اختصار لنظام دعم القرار الذكي الآلي لإدارة الموارد البشرية. يهدف هذا النظام إلى تقديم حلول مبتكرة لتحسين إدارة الأداء الوظيفي من خلال تتبع عدد السنوات التي قضاها الموظف في منصبه، إدارة المخزون اللوجستي، وتحليل تقارير تقييم الأداء الفردي، بالإضافة إلى تقديم تنبيهات فورية دون إنذارات خاطئة [1].

تتناول الدراسة مشكلة ضعف الأداء الوظيفي الناجم عن عوامل مثل التراخي في العمل أو عدم توفر الموارد اللازمة، حيث تشير الأبحاث إلى أن هذه العوامل تؤثر سلبيًا على الإنتاجية. كما تشير إلى أن أنظمة إدارة الأداء التقليدية غالبًا ما تعتمد على التدخل البشري، مما يجعلها عرضة للأخطاء أو التلاعب. ولحل هذه المشكلات، تم اقتراح نظام AIDSS-HR الذي يستخدم تقنيات متقدمة لتحليل البيانات وتقديم توصيات ذكية تساعد مديري الموارد البشرية على اتخاذ قرارات أفضل. يوضح الشكل (1-1) العلاقة بين إدارة الأداء والتوظيف، مما يعكس كيف يمكن للنظام أن يساهم في تحقيق أهداف المنظمة بشكل شامل.




الشكل (1-1): إدارة الأداء - التوظيف.


يتكون النظام من عدة مكونات رئيسية، بما في ذلك واجهة المستخدم التي تتيح التفاعل بين الإنسان والآلة، ووحدة التحليل الذكي التي تقوم بتحليل البيانات اليومية بناءً على خمسة أهداف رئيسية، ووحدة إدخال البيانات التي تعالج الأخطاء، ومستودع بيانات آمن لتخزين المعلومات. يوضح الشكل (2-1) البنية المقترحة للنظام، حيث يتم ربط المؤسسات المحلية بقاعدة بيانات مركزية عبر الإنترنت مع ضمان حماية البيانات من خلال وحدة حماية البيانات.

اعتمدت الدراسة على منهجية تطوير البرمجيات التزايدية، وهي نموذج يتضمن تصميم النظام وتنفيذه واختباره في مراحل متعددة. هذا النموذج يتيح مرونة في التعامل مع المتطلبات وتقليل التكاليف المرتبطة بالتغييرات. يوضح الشكل (3-1) خطوات تطبيق هذه المنهجية، مما يؤكد على أهمية الاختبار المبكر وإدارة المخاطر في كل مرحلة.

في الختام، توصي الدراسة المؤسسات في الدول النامية، مثل غانا، بتبني أنظمة ذكية مثل AIDSS-HR لتحسين إدارة الموارد البشرية وتخفيف العبء عن مديري الموارد البشرية. يعتقد الباحثون أن هذا النظام يمكن أن يكون أداة فعالة لتعزيز الإنتاجية وتحقيق أهداف المنظمات على مستوى الأفراد والمؤسسات بأكملها [1].



الشكل (1-2): المعمارية المقترحة لنظام AIDSS-HR.



الشكل (1-3): نموذج تطوير النظام التزايدي.

2-2-1 نظام CleverControl لمراقبة الموظفين



الشكل (1-4): نظام CleverControl.

برنامج CleverControl يقدم نهجًا جديدًا وأكثر دقة في مراقبة الموظفين باستخدام الذكاء الاصطناعي. يعتمد البرنامج على نظام تسجيل درجات يحلل أنشطة الموظفين مع الأخذ بعين الاعتبار طبيعة عملهم ومتطلبات صناعتهم. يتميز هذا النظام بمرونة أكبر ودقة أعلى مقارنة بالحلول التقليدية، حيث يقدم تقييمات أكثر موضوعية وقابلة للتخصيص [2].

يعمل نظام CleverControl عن طريق جمع بيانات مفصلة حول نشاط الموظفين، مثل استخدام التطبيقات والمواقع الإلكترونية، ومقارنتها بمعايير الصناعة ومناصب الموظفين. ولكي يضمن البرنامج حماية خصوصية الموظفين، يقوم بإخفاء هوياتهم قبل تحليل البيانات، ويقتصر التحليل على المعلومات

اللازمة لتقييم الإنتاجية فقط. يقوم النظام بفحص المدة الزمنية التي يقضيها الموظفون على التطبيقات والمواقع المختلفة، ويصنف الأنشطة إلى منتجة وغير منتجة بناءً على طبيعة عملهم. بعد ذلك، يصدر البرنامج درجات إنتاجية لكل موظف مصحوبة بتفسيرات واضحة لأنماط العمل والأنشطة غير المنتجة.

من خلال هذا النهج القائم على البيانات، يحصل المديرون على تقييم شامل وشخصي لكل موظف، مما يساعدهم على اتخاذ قرارات مستنيرة بشأن الترقيات أو خطط تحسين الأداء. كما يساعد النظام في تحديد نقاط الضعف والأنشطة التي تستهلك وقت الموظفين دون فائدة، مما يساهم في تحسين إدارة الوقت والإنتاجية. ومن الجدير بالذكر أن استخدام هذا النظام لا يتطلب أي معرفة تقنية متقدمة؛ إذ يمكن لأي مدير تفعيل الميزة وإدخال معلومات أساسية مثل مجال العمل ووظائف الموظفين، ليبدأ النظام في العمل تلقائيًا وتقديم التقارير بشكل مستمر.

في الواقع العملي، أثبت CleverControl فعاليته في العديد من الشركات. على سبيل المثال، استخدمت شركة تقنية متخصصة في تطوير البرمجيات النظام لتحليل أداء فريق المبيعات لديها. كشف التحليل أن الموظفين كانوا يقضون وقتًا طويلًا في الأعمال الإدارية الروتينية بدلاً من التركيز على بناء العلاقات مع العملاء المحتملين. بناءً على هذه النتائج، قامت الشركة بأتمتة بعض العمليات، مما أدى إلى زيادة إنتاجية الفريق بنسبة 17%. وفي حالة أخرى، استخدمت شركة تعمل في مجال دعم العملاء النظام لتحديد الفجوات المعرفية لدى موظفيها، ونظمت برامج تدريبية ساهمت في تحسين الأداء بشكل ملحوظ.

يمثل CleverControl نقلة نوعية في كيفية مراقبة أداء الموظفين وإدارتهم. من خلال تحليل دقيق للبيانات وتقديم رؤى قائمة على الأدلة، يتيح النظام للمديرين اتخاذ قرارات مدروسة تعزز من إنتاجية الفرق وتساهم في تحقيق أهداف الشركة. وفي عالم يزداد فيه التنافس يوميًا بعد يوم، يمكن للشركات أن تستفيد بشكل كبير من هذه الأدوات الذكية لتحسين أدائها وتحقيق النجاح المستدام [2].

1-2-3 مقارنة الدراسة السابقة مع المشروع

يتميز نظام CleverControl ونظام دعم القرار الذكي الآلي لإدارة الموارد البشرية (AIDSS-HR) بمجموعة من النقاط القوية التي تعزز كفاءة إدارة الأداء الوظيفي، مثل استخدام تقنيات الذكاء الاصطناعي لتحليل بيانات الموظفين وتوفير تقييمات دقيقة وشخصية. يعتمد نظام CleverControl على تتبع أنشطة الموظفين باستخدام معايير خاصة بالصناعة والوظيفة، مما يجعله أكثر دقة من الحلول التقليدية التي تعتمد على معايير عامة قد لا تناسب جميع الحالات. كما يقدم AIDSS-HR حلولاً أوتوماتيكية لتتبع سنوات الخدمة وإدارة المخزون اللوجستي وتحليل تقارير الأداء الفردي، مما يساعد في تحسين الإنتاجية بشكل شامل. ومع ذلك، فإن هذه الأنظمة ليست خالية من التحديات؛ فعلى سبيل المثال، قد تكون البيانات التي يتم جمعها حساسة وتثير مخاوف بشأن الخصوصية، كما أن الاعتماد الكامل على الذكاء الاصطناعي قد يؤدي إلى إغفال العوامل الإنسانية التي تؤثر على الأداء.

مشروعنا الحالي يعالج هذه الثغرات من خلال الجمع بين دقة التكنولوجيا ومراعاة السياق البشري. فعندما يتعلق الأمر بالخصوصية، نحرص على تصميم نظام يتضمن إجراءات صارمة لحماية البيانات. بالإضافة إلى ذلك، نركز على توفير نظام ذكي يستطيع تمييز الحضور الفعلي عن الغياب أو التهرب من العمل دون الحاجة إلى تتبع دائم لأنشطة الموظفين الشخصية، مما يقلل من التدخل غير الضروري في حياتهم اليومية. كما أن مشروعنا يعتمد على تقنيات مثل YOLO و DeepSORT للكشف عن الموظفين وتتبع حركتهم داخل منطقة العمل بدقة، مما يقلل من احتمالية حدوث إنذارات خاطئة ويضمن تقديم بيانات دقيقة وفورية للمديرين. بهذه الطريقة، نقدم حلاً متوازنًا يجمع بين الاستفادة من تقنيات الذكاء الاصطناعي والتقليل من التحديات الأخلاقية والتقنية التي تواجه الأنظمة السابقة.

3-1 الخلفية النظرية

1-3-1 مفهوم الذكاء الاصطناعي

الذكاء الاصطناعي هو أحد العلوم الحديثة التي تهدف إلى تمكين الآلات من أداء مهام تتطلب عادةً ذكاءً بشرياً، حيث يتم تصميم أنظمة وبرامج قادرة على التعلم من البيانات، التعرف على الأنماط، واتخاذ قرارات ذاتية التشغيل دون الحاجة إلى تدخل بشري مباشر. يعتمد هذا العلم على تقنيات تحاكي العمليات العقلية البشرية مثل الإدراك، التحليل، والاستنتاج، مما يجعله قادراً على التعامل مع المشكلات المعقدة بطريقة مرنة ومبتكرة. أهمية الذكاء الاصطناعي تبرز بشكل خاص في حل المشكلات التي قد تكون صعبة أو مستحيلة الحل باستخدام الأساليب التقليدية. ففي العديد من الحالات، تعجز الأساليب الكلاسيكية عن التعامل مع كميات هائلة من البيانات أو مع حالات تتطلب استجابة سريعة ودقيقة، وهنا يأتي دور الذكاء الاصطناعي الذي يمكنه تحليل هذه البيانات بسرعة فائقة واستخلاص نتائج دقيقة [3].

على سبيل المثال، في مجال الرعاية الصحية، يتم استخدام الذكاء الاصطناعي لتحليل الصور الطبية مثل الأشعة السينية والرنين المغناطيسي لتشخيص الأمراض بدقة عالية، مما يساعد الأطباء على اتخاذ قرارات أفضل وأسرع. كما يتم استخدامه في تطوير أدوية جديدة من خلال تحليل بيانات بيولوجية ضخمة لاكتشاف مركبات فعالة محتملة. في الصناعة، يُستخدم الذكاء الاصطناعي في تحسين خطوط الإنتاج من خلال روبوتات ذكية تقوم بأداء مهام دقيقة ومعقدة، مما يزيد من كفاءة العمليات ويقلل من الأخطاء البشرية. أما في التعليم، فقد أصبح الذكاء الاصطناعي أداة أساسية في تخصيص تجارب التعلم للطلاب بناءً على احتياجاتهم الفردية، حيث يمكنه تحليل أدائهم وتحديد نقاط القوة والضعف لديهم لتوفير محتوى تعليمي مخصص [3].

ربط هذا المفهوم بالمشروع المقترح يظهر بوضوح عند النظر إلى كيفية استخدام الذكاء الاصطناعي لتحسين إدارة أداء الموظفين وتتبعهم داخل المؤسسات. في كثير من الأحيان، تواجه الشركات تحديات كبيرة في مراقبة أداء موظفيها وضمان تحقيقهم للأهداف المرسومة، خاصة عندما يتعلق الأمر بتتبع الحضور والغياب أو تقييم الإنتاجية اليومية. هنا يأتي دور الذكاء الاصطناعي في تقديم حلول مبتكرة تساهم في تحسين هذه العمليات. على سبيل المثال، يمكن للنظام المقترح استخدام تقنيات مثل التعلم العميق والرؤية الحاسوبية لتحليل بيانات الموظفين بشكل دقيق، مثل تتبع حركاتهم داخل مكان العمل وتحديد ما إذا كانوا يقومون بمهامهم بشكل فعال أم لا [3].



الشكل (1-5): استخدام الذكاء الاصطناعي والرؤية الحاسوبية لإدارة أداء الموظفين.

بالإضافة إلى ذلك، يمكن للنظام أن يقدم تنبيهات فورية للمديرين في حالة ملاحظة أي انحراف عن القواعد المحددة، مثل مغادرة الموظف منطقة العمل دون إذن أو قضاء وقت طويل في أنشطة غير متعلقة بالعمل. هذا النوع من الحلول يتيح للمؤسسات إدارة وقت موظفيها بشكل أكثر كفاءة وشفافية، مما يؤدي إلى تحسين الإنتاجية العامة وتحقيق الأهداف التنظيمية. بفضل الذكاء الاصطناعي، يمكن للشركات

أن تنتقل من أساليب الإدارة التقليدية التي تعتمد على التدخل البشري والملاحظات الشخصية إلى أنظمة ذكية تستند إلى البيانات والأدلة، مما يعزز من الشفافية والإنصاف في تقييم الأداء [3].


بهذه الطريقة، يصبح الذكاء الاصطناعي أداة قوية لحل مشكلة تتبع الموظفين وتحسين إدارتهم، حيث يوفر نظامًا ذكيًا قادرًا على العمل بشكل مستمر ودقيق دون الحاجة إلى تدخل بشري كبير. هذا النظام ليس مجرد أداة لمراقبة الحضور والانصراف، بل هو حل شامل يمكنه تحليل الأداء اليومي للموظفين، تقديم تقارير دقيقة، واقتراح تحسينات مستقبلية لتعزيز كفاءة العمل. وبالتالي، يمكن اعتبار الذكاء الاصطناعي حجر الزاوية في تطوير أنظمة إدارة الموارد البشرية الحديثة، حيث يجمع بين قوة التكنولوجيا وإمكانات الإنسان لتحقيق نتائج أفضل وأكثر استدامة [3].

1-3-2 تعلم الآلة مقابل التعلم العميق: لماذا لم يتم اعتماد تعلم الآلة في هذا المشروع؟

يُعتبر تعلم الآلة (Machine Learning) أحد الفروع الرئيسية في علوم الذكاء الاصطناعي، حيث يعتمد على تصميم خوارزميات قادرة على تمكين الآلات من تعلم الأنماط من البيانات واتخاذ قرارات بناءً عليها. ومع ذلك، فإن تعلم الآلة يتطلب استخراج الخصائص يدويًا من البيانات الخام، وهو ما يعني أن المهندسين أو العلماء بحاجة إلى تحديد الخصائص المهمة في البيانات بشكل مسبق لتدريب النموذج. على سبيل المثال، إذا كانت المهمة تتضمن تصنيف الصور، فسيكون على الإنسان تحديد العناصر التي يمكن أن تكون ذات صلة، مثل الألوان أو الأشكال أو الحواف. هذه العملية تستهلك وقتًا وجهدًا كبيرًا، كما أنها تعتمد بشكل كبير على خبرة الشخص الذي يقوم بالاستخراج [4].

في المقابل، يُعد التعلم العميق (Deep Learning) جزءًا أكثر تطورًا من تعلم الآلة، حيث يعتمد على شبكات عصبية متعددة الطبقات قادرة على استخراج الخصائص تلقائيًا من البيانات الخام دون الحاجة

إلى تدخل بشري مسبق. هذا يعني أن النظام يمكنه تحليل البيانات المعقدة مثل الصور أو الفيديو مباشرةً، حيث تقوم الطبقات المختلفة باستخراج الخصائص من البسيطة إلى الأكثر تعقيدًا بشكل تدريجي. على سبيل المثال، في حالة تصنيف الصور، يمكن للشبكة العصبية العميقة أن تبدأ باكتشاف الحواف في الطبقات الأولى، ثم الأشكال في الطبقات الوسطى، وأخيرًا الكائنات الكاملة في الطبقات النهائية. هذا يجعل التعلم العميق أداة قوية للغاية عند التعامل مع البيانات المعقدة التي تحتوي على كميات هائلة من المعلومات [4].



الشكل (6-1): الفرق بين تعلم الآلة والتعلم العميق.


بالنظر إلى طبيعة المشروع المقترح، فإن اختيار التعلم العميق كان ضروريًا نظرًا لقدرته على التعامل مع البيانات المعقدة مثل الصور دون الحاجة إلى معالجة يدوية مسبقة. في حالة استخدام تعلم الآلة التقليدي، كان سيتطلب الأمر الكثير من الوقت والجهد لاستخراج الخصائص يدويًا، مما قد يؤدي إلى نتائج أقل دقة

بسبب احتمالية فقدان بعض التفاصيل المهمة أثناء هذه العملية. بينما يمكن للتعلم العميق أن يوفر حلولاً أكثر كفاءة ودقة، حيث يتمكن النظام من تعلم الأنماط ذات الصلة مباشرةً من البيانات الخام، مما يجعله الخيار الأمثل لهذا المشروع [4].

3-3-1 الشبكات العصبية الاصطناعية (ANN)

الشبكات العصبية الاصطناعية هي نماذج تحاكي عمل الدماغ البشري، وتتكون من عدة طبقات رئيسية تعمل معًا لمعالجة البيانات. تبدأ العملية بطبقة الإدخال التي تستقبل البيانات الأولية، ثم تمررها إلى الطبقات المخفية التي تقوم بتحليل المعلومات واستخلاص الأنماط منها. أخيرًا، تقوم طبقة الإخراج بإنتاج النتائج النهائية بناءً على التحليل الذي تم إجراؤه في الطبقات السابقة. هذه البنية المتعددة الطبقات تجعل الشبكات قادرة على التعامل مع بيانات معقدة وتقديم حلول دقيقة [5].

في الشكل (1-7)، يُظهر المخطط البنية الأساسية للشبكة العصبية المتعددة الطبقات، والتي توضح كيفية عمل كل طبقة وكيف يتم نقل البيانات بينها باستخدام "الوزن" و"الانحياز".



الشكل (1-7): بنية الشبكة العصبية الاصطناعية.

• كيفية عمل كل طبقة:

1. **طبقة الإدخال (Input Layer):** هذه الطبقة تتلقى البيانات الخام التي سيتم معالجتها. على سبيل المثال، إذا كانت المهمة هي تصنيف الصور، فإن بيانات الإدخال قد تكون مجموعة من القيم الرقمية تمثل ألوان أو خصائص البكسلات في الصورة. لا تحتوي طبقة الإدخال على عمليات حسابية مركبة، بل تقوم فقط بنقل البيانات إلى الطبقات التالية [5].
2. **الطبقات المخفية (Hidden Layers):** هذه الطبقات هي القلب النابض للشبكة العصبية. كل طبقة مخفية تحتوي على عقد (Neurons) تعمل على استخلاص خصائص معينة من البيانات الواردة من الطبقات السابقة [5].
3. **طبقة الإخراج (Output Layer):** هذه الطبقة تقيم النتائج النهائية بناءً على المعالجة التي حدثت في الطبقات المخفية. على سبيل المثال، إذا كان الهدف هو تصنيف الصور، فإن طبقة الإخراج قد تنتج احتمالات مختلفة لكل فئة ممكنة (مثل تحديد ما إذا كانت الصورة تحتوي على "كلب" أو "قطعة") [5].

• نقل البيانات بين الطبقات باستخدام "الوزن" و"الانحياز":

1. **الوزن (Weight):** عند نقل البيانات بين الطبقات، يتم استخدام "الوزن" كمعامل رقمي يحدد مدى تأثير كل إدخال على المخرجات. على سبيل المثال، إذا كانت هناك روابط بين عقدتين في الطبقات المختلفة، فإن كل رابط يحمل وزنًا معينًا. هذا الوزن يعكس أهمية الإدخال بالنسبة للمخرجات النهائية. في الشكل (1-7)، يمكن ملاحظة أن كل رابط بين العقد في الطبقات المختلفة يمثل وزنًا مختلفًا. أثناء التدريب، يتم تعديل هذه الأوزان تلقائيًا لتحسين دقة النموذج [5].

2. **الانحياز (Bias):** بالإضافة إلى الوزن، يتم استخدام "الانحياز" كقيمة ثابتة تضاف إلى العملية الحسابية في كل عقدة. الانحياز يمنح النظام مرونة أكبر لأنه يسمح بتغيير مستوى الإدخالات بشكل عام دون الحاجة إلى تعديل جميع الأوزان. كما أن الانحياز يلعب دورًا مهمًا في تدريب النموذج على التعامل مع الأخطاء أو التشوهات في البيانات، مثل الإضاءة السيئة، زوايا التصوير غير المثالية، أو الضوضاء في الصور. من خلال ضبط الانحياز أثناء عملية التدريب، يمكن للنموذج أن يتكيف مع هذه العوامل ويحسن من دقته في استخلاص الأنماط والعلاقات من البيانات المعقدة [5].

• **عملية النقل الأمامي (Feed-forward):** عند تقديم البيانات إلى الشبكة، تمر عبر الطبقات بطريقة تدريجية:

1. تنتقل البيانات من طبقة الإدخال إلى الطبقات المخفية.
2. في كل طبقة، يتم ضرب كل إدخال بالوزن المرتبط به، ثم يتم إضافة الانحياز.
3. يتم تطبيق دالة تفعيل (Activation Function) على النتيجة لإضافة عنصر غير خطي إلى العملية.
4. النتائج النهائية تصل إلى طبقة الإخراج، حيث يتم إنتاج المخرجات النهائية.


• **عملية الرجوع العكسي (Back-propagation):**

1. بعد الحصول على النتائج النهائية، يتم مقارنتها بالمخرجات المرغوبة (البيانات الصحيحة). إذا كانت هناك أخطاء، يتم تحديث الأوزان والانحيازات باستخدام تقنية الرجوع العكسي.
2. يتم حساب الخطأ بين المخرجات الفعلية والمطلوبة.
3. يتم توزيع هذا الخطأ عائدًا إلى الطبقات السابقة، ويتم تعديل الأوزان والانحيازات بناءً على قاعدة التعلم (مثل خوارزمية Gradient Descent).

4. هذه العملية تستمر حتى تصبح الأخطاء صغيرة بما يكفي، مما يعني أن النموذج أصبح قادرًا على التعامل مع البيانات بدقة [5].

1-3-3-1 الشبكات العصبية العميقة (DNN)

الشبكات العصبية العميقة (Deep Neural Networks - DNN) هي إصدار أكثر تعقيدًا من الشبكات العصبية الاصطناعية التقليدية، حيث تحتوي على عدد أكبر من الطبقات المخفية التي تتيح لها التعامل مع البيانات المعقدة بشكل أكثر كفاءة (انظر الشكل 1-8). هذه الطبقات الإضافية تمنح الشبكة قدرة استثنائية على استخلاص الخصائص تدريجيًا عبر مستويات مختلفة من التعقيد. في المراحل الأولى من الشبكة، تعمل الطبقات المخفية على استخراج الخصائص البسيطة مثل الحواف أو النقاط الأساسية في الصورة. ومع تقدم البيانات عبر الطبقات، تبدأ الشبكة في استخلاص خصائص أكثر تعقيدًا مثل الأشكال الهندسية أو الأنماط المرتبطة بالكائنات المحددة. في النهاية، تصل البيانات إلى طبقات متقدمة قادرة على التعرف على الكائنات الكاملة أو الأفكار المعقدة بناءً على التحليل الذي تم إجراؤه في الطبقات السابقة [5].



الشكل (1-8): بنية الشبكة العصبية العميقة.


هذه الخاصية الفريدة للشبكات العصبية العميقة تجعلها أداة مثالية لمعالجة البيانات المعقدة مثل الصور أو الفيديوها. على سبيل المثال، عند تصنيف صورة لحيوان، يمكن للطبقات الأولى أن تركز على اكتشاف الحواف أو التدرجات اللونية، بينما تتولى الطبقات الوسطى تحديد الأجزاء الرئيسية مثل الأذنين أو الذيل، وأخيرًا تقوم الطبقات الأخيرة بتحديد نوع الحيوان بدقة بناءً على الأنماط المستخلصة. هذا النهج المتدرج يتيح للشبكة فهم البيانات بعمق وتحليلها بطريقة تتناسب مع تعقيدها الطبيعي، مما يجعلها الخيار الأمثل للتعامل مع مشكلات تتطلب دقة عالية ومعالجة كبيرة للبيانات [5].

1-3-4 مفهوم التعلم الزائد ودوال التفعيل

1-4-3-1 التعلم الزائد (Overfitting)

التعلم الزائد هو مشكلة شائعة تحدث عندما يصبح النموذج المدرب على بيانات التدريب مفرطًا في التخصيص لهذه البيانات، مما يجعله يتعلم الأنماط الخاصة بها بدقة كبيرة ولكن بطريقة قد تكون غير ضرورية أو زائدة. نتيجة لذلك، يتمكن النموذج من تحقيق دقة عالية جدًا على البيانات التي تم استخدامها في التدريب، ولكنه يواجه صعوبة في التعامل مع بيانات جديدة لم يرها من قبل. بمعنى آخر، النموذج يصبح "مفرط التركيز" على التفاصيل الصغيرة والأنماط العشوائية الموجودة في بيانات التدريب، مما يجعله غير قادر على الاستيعاب بشكل صحيح للبيانات المستقبلية [3].

يمكننا فهم هذا المفهوم من خلال الشكل (1-9)، الذي يوضح ثلاث حالات مختلفة:



الشكل (9-1): الفرق بين Underfitting و Balanced و Overfitting.

1. **الإفراط في التبسيط (Underfitting):** في هذه الحالة، يكون النموذج بسيطًا جدًا ولا يستطيع

التقاط الأنماط الأساسية في البيانات.

2. **التوازن (Balanced):** هنا، يكون النموذج مثاليًا حيث يتعلم الأنماط الرئيسية في البيانات دون أن

يركز على التفاصيل الزائدة.


3. **التعلم الزائد (Overfitting):** في هذه الحالة، يصبح النموذج معقدًا جدًا ويبدأ في اتباع الأنماط

العشوائية في بيانات التدريب بدلاً من الأنماط الأساسية، مما يؤدي إلى أداء سيئ على البيانات الجديدة.

يحدث التعلم الزائد عندما يتم تدريب نموذج الذكاء الاصطناعي على مجموعة بيانات تدريبية بطريقة تجعله يصبح معقدًا جدًا بالنسبة لحجم البيانات أو نوعيتها. في هذه الحالة، بدلاً من أن يتعلم النموذج الأنماط الأساسية التي تساعد على التنبؤ بدقة على بيانات جديدة، فإنه يبدأ "بحفظ" التفاصيل الدقيقة والأنماط العشوائية الموجودة في بيانات التدريب. على سبيل المثال، إذا كان النموذج يحاول التنبؤ بالقيم المستقبلية لسلسلة زمنية معينة، فقد ينتهي به الأمر بتعلم الأخطاء أو التقلبات العشوائية في البيانات بدلاً من التركيز على الأنماط الرئيسية. هذا يؤدي إلى أداء استثنائي على بيانات التدريب ولكنه يفشل عند التعامل مع بيانات اختبار جديدة لأن النموذج لم يفهم الأنماط العامة بشكل صحيح [3].

2-4-3-1 دوال التفعيل (Activation Functions)

في الشبكات العصبية، تلعب دوال التفعيل دورًا أساسيًا في تمكين النموذج من التعامل مع المشكلات المعقدة. كما يظهر في الشكل (10-1)، يتم إدخال البيانات إلى الشبكة عبر عقد متعددة، حيث يتم ضرب كل إدخال بوزن معين ثم جمع هذه الإدخالات الموزونة في نقطة الجمع لإنتاج قيمة مجمعة. لكن قبل أن يتم إخراج النتيجة النهائية، يتم تمرير هذه القيمة المجمعة إلى دالة التفعيل، وهي الخطوة التي تضيف عنصرًا غير خطي إلى النظام [3].



الشكل (10-1): آلية عمل دالة التفعيل في الشبكة العصبية الاصطناعية.

بدون دوال التفعيل، تعمل الشبكات العصبية كأنظمة خطية فقط، مما يعني أنها لن تكون قادرة على حل المشكلات المعقدة أو التعرف على الأنماط الغير خطية الموجودة في البيانات. دوال التفعيل تضيف عنصرًا غير خطي إلى العملية الحسابية، مما يسمح للنموذج بالتعامل مع العلاقات المعقدة بين الإدخالات والنتائج. يمكن اعتبار دوال التفعيل بمثابة "مفتاح" يمنح الشبكة القدرة على التعلم من البيانات بشكل أكثر فعالية ودقة.

من بين الأمثلة الشائعة لدوال التفعيل: DReLU و Sigmoid و Tanh. هذه الدوال تُستخدم بكثافة في مختلف التطبيقات، حيث تساعد في تسريع عملية التعلم وتوفير نتائج دقيقة. في الشكل (1-10)، يمكننا رؤية كيفية عمل دوال التفعيل. بعد جمع الإدخالات الموزونة في نقطة الجمع، يتم تمرير الناتج إلى دالة التفعيل. هذه الدالة تضيف عنصرًا غير خطي إلى الناتج، مما يسمح للشبكة بتوليد استجابات مختلفة بناءً على القيم المختلفة للمدخلات. على سبيل المثال، إذا كانت دالة التفعيل هي DReLU، فإن أي قيمة سالبة ستتحول إلى صفر، مما يساعد في تقليل الضوضاء في الإشارات غير المهمة. أما إذا كانت دالة Sigmoid، فإن الناتج سيصبح قيمة احتمالية بين 0 و 1، مما يجعلها مناسبة لمشاكل التصنيف الثنائي [3].

4-1 أساسيات معالجة الصور


1-4-1 مفهوم الصورة الرقمية

الصورة الرقمية هي تمثيل بصري يتم إنشاؤه باستخدام شبكة من الوحدات الصغيرة تُعرف بالبكسلات. كل بكسل يمثل جزءًا صغيرًا من الصورة ويعمل بمثابة عنصر أساسي في بناء الصورة بأكملها. يمكن اعتبار البكسلات اللبنات الأساسية التي تتكون منها الصور الرقمية، حيث يتم ترتيبها بشكل مصفوفي لتكوين صورة كاملة. يتم تمثيل كل بكسل باستخدام قيم عددية تعكس شدة اللون أو الدرجات الرمادية في ذلك الجزء من الصورة. على سبيل المثال، في الصور الملونة، يتم استخدام نموذج الألوان RGB (الأحمر، الأخضر، والأزرق)، حيث يحتوي كل بكسل على ثلاث قيم تمثل شدة كل لون. من خلال دمج هذه القيم، يتم إنتاج مجموعة واسعة من الألوان التي تعطي الصورة مظهرها النهائي [6].

عندما يتم عرض الصورة على الشاشة أو طباعتها، يتم تجميع البكسلات معًا بحيث لا يمكن للعين البشرية تمييز الحدود الفاصلة بينها، مما يجعل الصورة تبدو متصلة ومتجانسة. كلما زاد عدد البكسلات في الصورة، أصبحت أكثر وضوحًا ودقة، وهو ما يُعرف بدقة الصورة أو "الوضوح". وبالتالي، فإن تمثيل الصور الرقمية يعتمد بشكل أساسي على كيفية تنظيم وتحديد قيم البكسلات التي تشكل الصورة [6].

1-4-2 التعرف على الكائنات

مفهوم التعرف على الكائنات (Object Detection) هو أحد الحلول التي تقدمها رؤية الحاسوب، حيث يتم استخدامه لتحديد الأشياء ومواقعها في الصورة. يعيد نظام التعرف على الكائنات إحداثيات الأشياء الموجودة في الصورة التي تم تدريبه على التعرف عليها، بالإضافة إلى مستوى الثقة الذي يعبر عن مدى دقة التوقع. يمكن استخدام هذا النظام بسهولة من خلال أدوات مثل صفحة Roboflow الرئيسية، حيث يمكن للمستخدمين اختبار نموذج قادر على التعرف على 80 كائنًا مختلفًا، بدءًا من الكتب إلى البشر والحيوانات [6].



الشكل (1-11): التعرف على الكائنات.

التعرف على الكائنات ليس مجرد تحديد وجود الأشياء، بل يقدم أيضًا إمكانيات أكبر من خلال معالجة البيانات المستخرجة من الصور أو الفيديوهات. على سبيل المثال، يمكن الإجابة على أسئلة مثل "كم من الوقت يظهر فيه كائن معين في مقطع فيديو؟" أو "كم عدد مرات ظهور كائن معين في منطقة محددة؟". يتم ذلك باستخدام النموذج عبر كل إطار من الفيديو وتتبع ظهور الكائن واختفائه [6].

لكي يعمل نظام التعرف على الكائنات بشكل فعال، يجب أن يتم تدريبه أولاً. عملية التدريب تعتمد على شبكة عصبية تقوم بتعلم السمات المرتبطة بالأشياء من خلال مجموعة من الصور المعلمة. هذه العملية تتطلب تقديم صور للأشياء في سيناريوهات مختلفة، مثل زوايا متعددة وخلفيات متنوعة، مما يساعد الشبكة على فهم السياق وتحسين دقته. يتم حفظ ما تتعلمه الشبكة في هيئة "الأوزان" و"الانحياز"، وهي عناصر تُستخدم لاحقًا أثناء الاختبار والتنفيذ العملي [6].

تُستخدم تقنية التعرف على الكائنات في العديد من المجالات، مثل البنية التحتية للنقل، حيث يمكن التحقق من وجود العوائق على القضبان أو التأكد من عدم وجود أشخاص في المناطق المحظورة. كما تُستخدم في صناعة الغذاء لضمان جودة المنتجات قبل تغليفها، وفي السيارات ذاتية القيادة لتحديد المشاة والإشارات المرورية وغيرها من العناصر. هناك عدة نماذج معمارية شائعة للتعرف على الكائنات، مثل الشبكات العصبية التلافيفية (CNNs) ونموذج YOLO، وكلاهما كان له دور كبير في تطوير صناعة رؤية الحاسوب الحديثة، يبين الجدول (1-1) مقارنة بين أشهر خوارزميات التعرف على الكائنات [6].

في السنوات الأخيرة، برزت أيضًا نماذج "الإطلاق الصفري" (Zero-shot)، مثل Grounding DINO، التي يمكنها التعرف على الأشياء بناءً على موجهات نصية دون الحاجة إلى المزيد من التدريب. ومع ذلك، فإن هذه النماذج قد تتطلب ضبطًا إضافيًا لتحقيق أداء أفضل في مجالات محددة [6].

على الرغم من أن التعرف على الكائنات يقدم تحديدًا دقيقًا لمواقع الأشياء في الصورة، إلا أنه يختلف عن تصنيف الصور الذي يحدد فقط الفئة العامة للصورة، ولا يقدم تفاصيل عن مواقع الكائنات. كما أن هناك تقنيات أكثر دقة مثل التجزئة (Segmentation)، التي تحدد موقع الكائنات بدقة على مستوى البكسل، ولكنها تتطلب وقتًا وجهدًا أكبر لوضع العلامات [6].


الجدول (1-1): مقارنة بين أشهر خوارزميات التعرف على الكائنات.

Fast R-CNN	R-CNN	YOLO	
معالجة الصورة بأكملها مرة واحدة واستخلاص المناطق المقترحة بشكل متزامن.	يستخرج مناطق اقتراح باستخدام طرق مثل Selective Search، ثم يصنف كل منطقة على حدة.	يقوم بتقسيم الصورة إلى شبكة ثابتة ويعمل على التنبؤ بالمربعات المحيطة والفئات في خطوة واحدة.	آلية العمل
أسرع من R-CNN، ولكنه لا يزال أبطأ من YOLO.	بطيء جدًا بسبب معالجة كل منطقة اقتراح بشكل منفصل.	سريع جدًا ومناسب للتطبيقات الزمنية الفورية (Real-Time).	سرعة الأداء
أكثر دقة من YOLO.	دقيق للغاية، لكنه يتطلب قدرًا كبيرًا من الحسابات.	أقل دقة مقارنةً بـ R-CNN و Fast R-CNN، خاصةً مع الكائنات الصغيرة أو المتداخلة.	الدقة
أقل استهلاكًا للموارد مقارنةً بـ R-CNN.	استهلاك عالي للموارد بسبب معالجة كل منطقة اقتراح بشكل منفصل.	أقل استهلاكًا للموارد بسبب تصميمه البسيط والمباشر.	استهلاك الموارد
خطوة واحدة: معالجة الصورة بأكملها واستخلاص المناطق المقترحة معًا.	خطوتان: أولاً، استخراج مناطق الاقتراح، ثم تصنيفها باستخدام شبكة عصبية.	خطوة واحدة فقط: التنبؤ بالمربعات المحيطة والفئات مباشرة من الصورة.	عدد مرات المعالجة

الفصل الثاني : خوارزمية YOLO (You Only Look Once)

1-2 مقدمة عن YOLO

خوارزمية YOLO (You Only Look Once) هي واحدة من أكثر الخوارزميات تطوراً في مجال التعرف على الكائنات، حيث تقدم حلاً سريعاً وفعالة لتحديد الأشياء ومواقعها داخل الصور أو الفيديوها. تعتمد هذه الخوارزمية على مبدأ بسيط ولكنه قوي، يتمثل في معالجة الصورة بأكملها مرة واحدة فقط، بدلاً من البحث عن الكائنات عبر مناطق متعددة بشكل منفصل كما هو الحال في بعض الأساليب التقليدية. هذا النهج يجعلها أسرع بكثير مقارنة بالطرق الأخرى، مما يجعلها مناسبة للتطبيقات التي تتطلب استجابات فورية مثل السيارات ذاتية القيادة وأنظمة المراقبة [6].



الشكل (2-1): سرعة خوارزمية YOLO مقارنة بخوارزميات التعرف على الكائنات الأخرى الأكثر تطوراً.


تتميز YOLO بأنها لا تقوم فقط بتحديد نوع الكائن الموجود في الصورة، بل تحدد أيضاً موقعه بدقة من خلال رسم مربعات حدودية حوله وإعطاء مستوى ثقة يعكس احتمالية دقة التوقع. هذا يعني أن النظام يمكنه التعامل مع صور تحتوي على عدة كائنات مختلفة، ويقوم بتحليلها بشكل شامل في خطوة واحدة.

بفضل تصميمها البسيط والمباشر، أصبحت YOLO خيارًا شائعًا في العديد من التطبيقات العملية، حيث تجمع بين السرعة والدقة بطريقة تلبي احتياجات المؤسسات والأفراد الذين يحتاجون إلى حلول فعالة للتعرف على الكائنات في الزمن الحقيقي [6].

بالتدرج في تطوير إصدارات YOLO، يمكن ملاحظة أن كل إصدار جديد كان يضيف تحسينات ملموسة على الإصدار السابق له. فقد جاء YOLOv5 ليحقق سرعة تنفيذ عالية مع خفة النموذج، ولكنه كان لا يزال محدودًا نسبيًا من حيث الدقة في الحالات المعقدة. ثم تبعه YOLOv6 و YOLOv7 بتحسينات في التعامل مع الكائنات الصغيرة والكثيرة ضمن نفس الصورة، مع رفع الدقة دون التضحية الكبيرة بسرعة الأداء. أما YOLOv8 فقد أدخل تحسينات إضافية على بنية النموذج وطريقة المعالجة لتحقيق نتائج أكثر ثباتًا في مختلف أنواع البيانات. بعد ذلك جاء YOLOv9 بتعديلات متقدمة على تصميم الشبكة العصبية ساهمت في زيادة الدقة بشكل ملحوظ مع الحفاظ على زمن تنفيذ مقبول. مع YOLOv10، تم التركيز أكثر على تقنيات جديدة لتحقيق توازن أفضل بين سرعة الأداء ودقة النتائج، إلى أن وصلنا إلى YOLO11 الذي يعتبر حاليًا الأكثر تطورًا، حيث استطاع أن يتفوق بوضوح على جميع الإصدارات السابقة من حيث الدقة وسرعة الاستجابة في نفس الوقت [6].

عند النظر إلى الشكل (2-2)، يتضح مسار هذا التطور بشكل عملي، حيث يوضح المخطط العلاقة بين دقة النموذج (على المحور الرأسي) وزمن المعالجة لكل صورة (على المحور الأفقي) باستخدام منصة تسريع خاصة (TensorRT10 FP16). يظهر بوضوح أن سلسلة إصدارات YOLO، وخاصة YOLO11 الممثل بالخط الأزرق العريض، تقدم أعلى قيم للدقة مع المحافظة على زمن تنفيذ منخفض، وهو ما يدل على الكفاءة العالية للنموذج. كما يمكن ملاحظة أن الإصدارات الأقدم مثل YOLOv5 و YOLOv6-3.0 تحتل مراتب أدنى من حيث الأداء، بينما تقترب بعض النماذج الأخرى مثل PP-YOLOE و DAMO-

YOLO من تحقيق نتائج جيدة ولكن دون الوصول إلى مستوى YOLO11. في المقابل، تبدو نماذج أخرى مثل EfficientDet أقل تنافسية، حيث تظهر بزمان تنفيذ أطول ودقة أقل. هذه النتائج تؤكد أن سلسلة YOLO قد شهدت عبر إصداراتها المتعاقبة تحسينات منظمة ومدروسة، مما جعلها واحدة من أهم الخوارزميات المعتمدة في تطبيقات الرؤية الحاسوبية التي تتطلب سرعة ودقة عاليتين في نفس الوقت، مع احتفاظها بمرونة مناسبة للاستخدام في مجالات متنوعة [6].




الشكل (2-2): مقارنة بين إصدارات YOLO المختلفة من حيث الدقة مقابل زمن التنفيذ.

2-2 خطوات عمل YOLO

1-2-2 تقسيم الصورة إلى خلايا

في الخطوة الأولى من عمل YOLO، يتم تقسيم الصورة إلى مجموعة من الخلايا المتساوية الحجم. كل خلية في هذه الشبكة تمثل جزءًا مستقلًا من الصورة وتعمل كوحدة معالجة منفصلة. الهدف من هذا التقسيم هو تبسيط عملية البحث عن الكائنات داخل الصورة، حيث يتم التعامل مع كل خلية على حدة لتحديد ما إذا كانت تحتوي على كائن معين أم لا [6].



الشكل (2-3): خطوات عمل خوارزمية YOLO.

تُعتبر كل خلية بمثابة صورة جزئية صغيرة تحمل جزءًا من المعلومات البصرية للصورة الأصلية. هذا النهج يتيح للنظام التركيز على المناطق المختلفة من الصورة بشكل منهجي ومنظم، مما يساهم في تسريع عملية التحليل وتحسين الدقة. أثناء هذه الخطوة، يتم تحديد مواقع الكائنات المحتملة داخل كل خلية، مما يمهد الطريق لخطوات التحليل اللاحقة [6].

بهذه الطريقة، يتمكن YOLO من معالجة الصورة بأكملها مرة واحدة فقط، بدلاً من البحث المتكرر عن الكائنات عبر مناطق متعددة كما يحدث في بعض الأساليب التقليدية. هذا يجعل النظام أكثر كفاءة وأسرع في تقديم النتائج، خاصة عند التعامل مع تطبيقات تتطلب استجابات فورية مثل السيارات ذاتية القيادة أو أنظمة المراقبة [6].

2-2-2 معالجة الخلايا باستخدام CNN

1-2-2-2 الشبكة العصبية التلافيفية (CNN)

الشبكات العصبية التلافيفية (CNN) هي نوع متخصص من الشبكات العصبية المصممة خصيصًا لمعالجة البيانات ذات الطبيعة البصرية، مثل الصور. تُستخدم هذه الشبكات بشكل واسع في مجال رؤية الحاسوب بسبب قدرتها الفائقة على استخلاص الأنماط والخصائص المكانية من البيانات البصرية. تعتمد CNN على مبدأ المحاكاة الجزئية لعملية الإدراك البشري للصور، حيث تركز على اكتشاف الخصائص المهمة مثل الحواف، الأشكال، والأنماط المعقدة بطريقة تتناسب مع طبيعة الصور. يميزها عن غيرها من النماذج قدرتها على التعامل مع كميات ضخمة من البيانات البصرية بكفاءة عالية، مما يجعلها أداة أساسية في التطبيقات التي تتطلب تحليل الصور أو الفيديوهات بدقة وسرعة [3].

2-2-2-2 لماذا اعتمدنا CNN لمعالجة الصور بدلاً من DNN؟


عند التعامل مع الصور، تواجه الشبكات العصبية العميقة (DNN) تحديات كبيرة تجعلها غير كافية لتحقيق الأداء المطلوب في معالجة البيانات البصرية. السبب الرئيسي لذلك يعود إلى طبيعة الصور ذاتها، حيث تحتوي على كميات ضخمة من البيانات التي يتم تمثيلها عادةً في صورة مصفوفات بكسل متعددة الأبعاد. إذا حاولنا استخدام DNN لمعالجة الصور، فإننا سنحتاج إلى معالجة كل بكسل على حدة، مما يؤدي إلى زيادة هائلة في عدد المعلمات الحسابية وتعقيد النظام بشكل كبير. هذا يجعل العملية غير فعالة من حيث الوقت والموارد الحاسوبية.

على الجانب الآخر، تأتي الشبكات العصبية التلافيفية (CNN) كحل مثالي لهذه المشكلة. تعتمد CNN على تصميم خاص يتيح لها استخلاص الخصائص المكانية من الصور بطريقة أكثر كفاءة. تعمل هذه الشبكات

باستخدام عمليات مثل التحويل التلافيفي (Convolution) والجمع الأقصى (Pooling)، مما يقلل بشكل كبير من عدد المعلمات المطلوبة ويسمح للنظام بالتركيز على الأنماط المهمة في الصورة. على سبيل المثال، يمكن لـ CNN اكتشاف الحواف والأشكال البسيطة في البداية، ثم بناء أنماط أكثر تعقيدًا تدريجيًا عبر الطبقات المختلفة.

بالإضافة إلى ذلك، تتميز CNN بقدرتها على المحافظة على العلاقات المكانية بين البكسلات، وهو أمر أساسي في تحليل الصور. بينما تعاني DNN من فقدان هذه العلاقات بسبب معالجتها الخطية للبيانات، فإن CNN تحافظ على البنية المكانية للصورة من خلال تصميمها المتدرج، مما يجعلها أكثر ملاءمة لمهام مثل تصنيف الصور أو الكشف عن الأشياء. لهذا السبب، تم تبني CNN كأداة أساسية في مجال رؤية الحاسوب، حيث توفر حلولاً أكثر ذكاءً وكفاءة لمعالجة الصور مقارنةً بالشبكات العصبية العميقة التقليدية.

3-2-2-2 خطوات عمل شبكة CNN



الشكل (2-4): بنية شبكة CNN.

1. Input: يتم تقديم الصورة كمدخل إلى الشبكة. الصورة عادةً تكون مصفوفة ثلاثية الأبعاد تحتوي على

بيانات عن الألوان (مثل RGB) أو الدرجات الرمادية.

2. Convolution: بعد الإدخال، تمر الصورة عبر طبقات التحويل التلفيقي (Convolution Layers) ،

حيث تقوم المرشحات (Filters) باستخلاص الخصائص البصرية من الصورة. المرشحات هي عبارة

عن مصفوفات صغيرة يتم سحبها عبر الصورة باستخدام عملية التحويل التلفيقي. خلال هذه العملية،

يتم ضرب كل بكسل في الصورة بالمرشح وتجميع النتائج لإنتاج (Feature Maps). تساعد

المرشحات في اكتشاف الأنماط البصرية الأساسية مثل الحواف، الأشكال، أو الألوان، حيث يركز كل

مرشح على جزء معين من الصورة مما يسمح للشبكة باستخلاص أنماط مختلفة بناءً على الغرض

المطلوب.

3. Pooling: بعد مرحلة التحويل التلفيقي، يتم تطبيق عملية التجميع (Pooling) على الـ Feature maps

بهدف تقليل حجم البيانات من خلال تقليل عدد البكسلات دون فقدان المعلومات الرئيسية. تلعب

عملية التجميع دورًا مهمًا في تقليل تعقيد النظام وتحسين الكفاءة، حيث يتم التركيز على الاحتفاظ

بالأنماط الأساسية فقط. يعتبر "التجميع الأقصى" (Max Pooling) من أبرز أنواع التجميع، وفيه يتم

اختيار القيم الأعلى في كل منطقة صغيرة من الصورة، مما يساعد على تسليط الضوء على الخصائص

الأكثر أهمية. كما يوجد أيضًا نوع آخر يُعرف بـ "التجميع المتوسط" (Average Pooling)، الذي يقوم

بإيجاد متوسط القيم في كل منطقة لضمان الحفاظ على توازن في البيانات المستخرجة.

4. Flattening: بعد مرحلتَي التحويل التلفيقي والتجميع، يتم تسطيح الإخراج إلى شكل متجه واحد.

عملية التسطيح تهدف إلى تحويل البيانات المتعددة الأبعاد، مثل الصور، إلى شكل واحد الأبعاد

لتسهيل التعامل معها في المراحل التالية. تأتي أهمية هذه الخطوة من كون الطبقات الكاملة الارتباط

التي تتبعها غير قادرة على التعامل مباشرة مع البيانات المتعددة الأبعاد، وبالتالي يتم تنظيم جميع القيم المستخرجة من الخرائط المولدة لفيفة في متجه واحد. هذا التنظيم يساعد على إعداد البيانات بشكل مناسب ليتم تحليلها واستخدامها في الطبقات التالية.

5. Fully Connected Layers: بعد التسطيح، يتم تمرير الإخراج إلى طبقات كاملة الارتباط (Fully

Connected Layers) التي تعمل على تحليل الأنماط المستخلصة من الصورة وتحديد الفئات المختلفة. في كل طبقة، يتم استخدام دوال التفعيل (Activation Functions) مثل ReLU لضمان إضافة عنصر غير خطي إلى النظام. تتميز الطبقات الكاملة الارتباط بأنها تربط بين جميع العقد الموجودة فيها، مما يسمح لها بتحليل العلاقات المعقدة بين البيانات وفهم الأنماط بشكل أعمق. هذه العملية تعزز قدرة الشبكة على استخلاص معلومات دقيقة وتصنيف الصور بشكل فعال.

6. Classification: في المرحلة الأخيرة، يتم إنتاج النتائج النهائية من خلال طبقة خروج تحتوي على عدد

من العقد يتناسب مع عدد الفئات التي يتم التعرف عليها. غالبًا ما تستخدم الطبقات النهائية دالة تفعيل خاصة مثل Softmax، والتي تعمل على توليد احتمالات لكل فئة ممكنة بناءً على البيانات المستخلصة من الصورة. الناتج النهائي يكون عبارة عن مجموعة من القيم تمثل احتمالية وجود كل فئة في الصورة، مما يساعد في تحديد الفئة الأكثر احتمالاً واتخاذ القرار المناسب بناءً على هذه الاحتمالات.

3-2-2 إنتاج البوكسات

بعد معالجة الصورة باستخدام شبكة CNN واستخلاص الأنماط والخصائص المكانية منها، يتم الانتقال إلى خطوة إنتاج البوكسات (Bounding Boxes) التي تحيط بالكائنات المكتشفة. في هذه المرحلة، يبدأ النظام بتحديد مواقع الكائنات داخل الصورة بناءً على المعلومات المستخلصة من الطبقات السابقة. يتم

إنشاء عدد كبير من البوكسات حول المناطق التي يُحتمل أن تحتوي على كائنات (كما هو واضح في الشكل 2-3)، حيث يتم تحليل كل بوكس لمعرفة ما إذا كان يحتوي على كائن ذي صلة أم لا.


تُعتبر عملية إنتاج البوكسات جزءًا أساسيًا من نظام YOLO، حيث يتم ربط كل بوكس بموقع معين في الصورة وتحديد احتمالية وجود كائن داخله. يتم تحديد هذه البوكسات باستخدام خوارزميات تقوم بتقسيم الصورة إلى مناطق محتملة، ثم تحليل كل منطقة بشكل مستقل. بعد ذلك، يتم تعيين درجة ثقة لكل بوكس تعكس مدى دقة التنبؤ بوجود كائن داخله.

بفضل هذا النهج، يمكن للنظام التعامل مع عدة كائنات في نفس الوقت داخل الصورة الواحدة، مما يجعله أكثر كفاءة مقارنة بالأساليب التقليدية التي تعتمد على البحث المتكرر عن الكائنات عبر مناطق متعددة. ومع ذلك، فإن ظهور عدد كبير من البوكسات قد يؤدي إلى تداخل بعضها مع الآخر، مما يستدعي استخدام تقنيات مثل "Non-Maximum Suppression" لتقليل التكرار واختيار أفضل بوكس لكل كائن مكتشف. بهذه الطريقة، يتمكن YOLO من تقديم نتائج دقيقة وسريعة، حيث يتم تحديد مواقع الكائنات بدقة وإعطاء احتمالات موثوقة لوجودها في الصورة. هذه الخطوة تعتبر حاسمة لتحقيق التوازن بين السرعة والدقة، خاصة عند التعامل مع تطبيقات تتطلب استجابات فورية مثل السيارات ذاتية القيادة أو أنظمة المراقبة.

3-2 تقنية IoU

Intersection over Union (IoU) هو طريقة شائعة تُستخدم لتقييم مدى دقة تحديد موقع الكائنات في نماذج التعرف على الأشياء. يعمل هذا المقياس على حساب نسبة التداخل بين بوكس مُقترح من

النموذج وبوكس آخر يمثل الموقع الحقيقي للكائن (الحقيقة الأساسية). كلما زاد التداخل بين البوكسين، كانت النتيجة أكثر دقة (انظر الشكل 5-2) [7].



الشكل (5-2): آلية عمل تقنية IoU.

4-2 أدوات ومكتبات YOLO

• **Ultralytics:** في المشروع الخاص بنا، تم اعتماد استخدام النماذج الجاهزة المقدمة من فريق Ultralytics بدلاً من بناء نموذج YOLO من الصفر. يوفر فريق Ultralytics نماذج متطورة مثل YOLOv5 و YOLOv8، والتي تعتبر أدوات قوية وفعالة للكشف عن الأشياء في الصور والفيديوهات. هذه النماذج تم تدريبها مسبقاً على مجموعة واسعة من البيانات، مما يجعلها قادرة على التعامل مع العديد من الحالات المختلفة بسرعة ودقة. باستخدام هذه النماذج الجاهزة، يمكن توفير الوقت والجهد المطلوبين لتطوير نموذج جديد تمامًا، مما يتيح التركيز على تخصيص النموذج بما يناسب احتياجات المشروع الخاصة.



الشكل (2-6): مكتبة Ultralytics.

• **OpenCV:** تلعب مكتبة OpenCV دورًا مهمًا في تسهيل عمل خوارزمية YOLO من خلال معالجة الصور وعرض النتائج بطريقة مرئية سهلة الفهم. باستخدام OpenCV، يمكن للنظام قراءة الصور أو مقاطع الفيديو وتحضيرها لتحليلها بواسطة YOLO. بعد أن تقوم YOLO بتحديد الكائنات ورسم المربعات حولها، تستخدم OpenCV هذه المعلومات لعرض الصورة النهائية بشكل واضح، حيث يتم إظهار

المربعات المحيطة بالكائنات مع كتابة أسمائها ونسبة الثقة بجانبها. هذا يساعد المستخدمين على رؤية النتائج مباشرة وبشكل بسيط دون الحاجة إلى فهم التفاصيل البرمجية المعقدة. باختصار، OpenCV تعمل كأداة تربط بين تقنية YOLO والمستخدم، مما يجعل عملية التعرف على الكائنات أكثر سهولة وتفاعلية.



الشكل (2-7): مكتبة OpenCV.

الفصل الثالث: تتبع الكائنات

1-3 مفهوم تتبع الكائنات (Object Tracking)

تتبع الكائنات هو أحد تطبيقات التعلم العميق، حيث يقوم البرنامج أولاً بالتعرّف على مجموعة من الكائنات الظاهرة في المشهد، ثم يخصص لكل كائن هوية فريدة، ويتابع حركته أثناء انتقاله بين الإطارات في مقطع الفيديو. بمعنى آخر، يتضمن تتبع الكائنات عملية التعرف التلقائي على الأجسام داخل الفيديو، ثم تمثيل حركتها على شكل مسارات دقيقة توضح كيفية تنقلها عبر الزمن. وغالباً ما يتم الإشارة إلى الكائن المتعقّب بإطار محيط — مثل مربع — يتحرك معه، مما يساعد المستخدم على معرفة موقعه على الشاشة بشكل مستمر [8].



الشكل (3-1): تتبع الكائنات (Object Tracking).


2-3 استخدامات وأنواع تتبع الكائنات

يُستخدم تتبع الكائنات في مجموعة متنوعة من التطبيقات التي تعتمد على أنواع مختلفة من الوسائط المُدخلة. ويؤثر نوع المحتوى المُتوقّع — سواء كان صورة ثابتة، فيديو مسجلاً، أو بثاً مباشراً في الوقت

الحقيقي — على نوع الخوارزميات المستخدمة في تصميم هذه التطبيقات. كما أن نوع المُدخل يؤثر أيضاً على تصنيف التتبع واستخداماته وتطبيقاته المختلفة [8].

1-2-3 تتبع الفيديو (Video Tracking)

يُعد تتبع الفيديو أحد تطبيقات تتبع الكائنات، حيث يُستخدم لتحديد مواقع الكائنات المتحركة داخل مشاهد الفيديو. وتتميز أنظمة تتبع الفيديو بقدرتها على معالجة كل من لقطات الفيديو المباشرة (الزمن الحقيقي) وكذلك مقاطع الفيديو المسجلة مسبقاً (الشكل 2-3) [8].



الشكل (2-3): تتبع الكائنات في لقطات الفيديو المباشرة (الزمن الحقيقي).

تختلف الإجراءات والخوارزميات المستخدمة في تنفيذ مهام تتبع الفيديو بناءً على نوع مدخل الفيديو، سواء كان مباشراً أو مسجلاً. تُستخدم تقنيات تتبع الفيديو بشكل واسع في تحليل الفيديو وفهم المشاهد، وتلعب دوراً مهماً في العديد من المجالات، مثل أنظمة الأمن والمراقبة، والتطبيقات العسكرية، وقطاع النقل، وغيرها من الصناعات. وفي الوقت الراهن، تعتمد العديد من تطبيقات الرؤية الحاسوبية والتعلم العميق في الزمن الحقيقي على أساليب تتبع الفيديو كعنصر أساسي في عملها.

3-2-3 2-2-3 التتبع البصري (Visual Tracking)

يُعد التتبع البصري، أو ما يُعرف بتتبع الكائنات البصرية، أحد المواضيع البحثية في مجال الرؤية الحاسوبية، ويُستخدم في نطاق واسع من التطبيقات اليومية. يهدف هذا النوع من التتبع إلى تقدير الموقع المستقبلي لكائن بصري تم تحديده في بداية الفيديو، دون الحاجة إلى توفر بقية مشاهد الفيديو مسبقاً [8].

يعتمد التتبع البصري على تحليل مظهر الكائن ومتابعة حركته اعتماداً على الإطار الأول فقط، وهو ما يجعله مناسباً في الحالات التي لا يكون فيها الفيديو كاملاً متاحاً عند بدء التتبع، كما في تطبيقات البث المباشر أو التفاعل الفوري مع البيانات المرئية.

3-2-3 3-2-3 تتبع الصور (Image Tracking)

تتبع الصور هو تقنية تُستخدم لتحديد صورة ثنائية الأبعاد (مثل شعار أو ملصق) داخل مشهد معين، ثم متابعة حركتها إذا تغيّر مكانها أو اتجاهها. عند التعرف على الصورة المستهدفة، يبقى النظام يتبعها بشكل مستمر أثناء تحركها [8].

تُعد هذه التقنية مفيدة بشكل خاص عندما تكون الصورة المراد تتبعها واضحة ومميزة عن غيرها، مثل أن تكون ألوانها متباينة (كالأبيض والأسود)، أو تحتوي على تفاصيل فريدة تسهل تمييزها.

يعتمد تتبع الصور على تقنيات الرؤية الحاسوبية، حيث يتم أولاً تحديد الصورة الهدف، ثم يستخدم النظام الذكاء الاصطناعي لمتابعتها وتحسين عرضها، كما هو الحال في تطبيقات الواقع المعزز أو في بعض الأنظمة التعليمية والتجارية.

4-2-3 كاميرا تتبع الكائنات (Object Tracking Camera)

تُستخدم تقنيات تتبع الكائنات الحديثة مع الفيديو المباشر القادم من أي نوع من الكاميرات تقريبًا، سواء كانت كاميرا USB عادية أو كاميرا شبكية (IP Camera). يتم ذلك من خلال إرسال لقطات الفيديو (الإطارات) واحدة تلو الأخرى إلى خوارزمية التتبع، التي تقوم بتحليلها ومتابعة حركة الكائنات داخل المشهد [8].

ولتسريع الأداء عند العمل مع الفيديو المباشر، خاصة عند استخدام أكثر من كاميرا، تُستخدم تقنيات مثل تجاوز بعض الإطارات (Frame Skipping) أو المعالجة المتوازية (Parallel Processing). تساعد هذه الطرق في الحفاظ على سرعة التتبع ودقته في الوقت الحقيقي.



الشكل (3-3): كشف وتتبع معدات الحماية الشخصية في تطبيقات المرافق والطاقة.

3-3 التحديات الشائعة لتتبع الكائنات

1-3-3 سرعة التدريب والتتبع

تهدف خوارزميات تتبع الكائنات إلى التعرف على الكائنات المهمة وتحديد مواقعها بدقة، مع ضرورة القيام بذلك في أقل وقت ممكن. وتزداد أهمية زيادة سرعة التتبع بشكل خاص في نماذج التتبع التي تعمل في الوقت الحقيقي [8].

لضمان أن النموذج يعمل بسرعة مناسبة، يجب اختيار أو تعديل الخوارزمية المستخدمة لبناء نموذج التتبع بعناية. على سبيل المثال، تقنيتا Fast R-CNN و Faster R-CNN تُستخدمان لتحسين سرعة الطريقة الشائعة R-CNN.

وبما أن الشبكات العصبية الالتفافية (CNN) تُعد من الأدوات الأساسية في كشف الكائنات، فإن التعديلات التي تُجرى على هذه الشبكات يمكن أن تكون السبب في اختلاف سرعة النموذج بين سريع وبطيء. بالإضافة إلى نوع إطار الكشف، تؤثر الاختيارات التصميمية الأخرى على التوازن بين سرعة ودقة النموذج.

2-3-3 تشويش الخلفية

تؤثر خلفيات الصور المدخلة أو الصور المستخدمة في تدريب النماذج بشكل كبير على دقة تتبع الكائنات. فعندما تكون الخلفية مزدحمة أو تحتوي على العديد من التفاصيل، يصبح من الصعب على النظام اكتشاف الكائنات الصغيرة. أما في حال كانت الخلفية ضبابية أو ذات لون واحد، فإن مهمة اكتشاف وتتبع الكائنات تصبح أسهل على نظام الذكاء الاصطناعي. وفي المقابل، الخلفيات التي تحتوي على ألوان مشابهة للون الكائن، أو التي تكون فوضوية للغاية، قد تُسبب صعوبة في تتبع الكائنات الصغيرة أو ذات الألوان الفاتحة [8].




الشكل (3-4): إزالة الخلفية لتسهيل تتبع الكائنات بدقة باستخدام مكتبة OpenCV.

3-3-3 اختلاف أحجام الكائنات في الصور

الكائنات التي نرغب في تتبعها تأتي بأحجام وأشكال مختلفة. هذا الاختلاف قد يربك البرامج ويجعلها تعتقد أن الكائن أكبر أو أصغر مما هو عليه بالفعل، وهذا يؤثر على دقة وسرعة التتبع. للتغلب على هذه المشكلة، يستخدم المطورون عدة تقنيات تساعد البرنامج على التعرف على الكائنات مهما اختلف حجمها، منها:

- **الصناديق المرجعية (Anchor Boxes):** هي إطارات بأحجام وأشكال محددة تساعد في تقدير حجم وشكل الكائنات. يتم اختيار هذه الصناديق بناءً على متوسط حجم الكائنات في البيانات التي يتعلم منها البرنامج، مما يسمح بالتعرف على كائنات مختلفة بدون تغيير الإطارات لكل كائن.
- **خرائط الخصائص (Feature Maps):** هي صور تُظهر التفاصيل التي تعرفت عليها الشبكة العصبية بعد تحليل الصورة. هذه الخرائط تساعد البرنامج في فهم ملامح الكائنات. أحياناً، قد تفقد التفاصيل الصغيرة عند تقليل حجم الصورة داخل الشبكة، لذلك يستخدم البرنامج عدة خرائط لخصائص من طبقات مختلفة، خاصة التي تحافظ على دقة أعلى، ليتعرف على الكائنات الصغيرة بدقة أكبر.
- **الأهرامات الصورية وخرائط الخصائص (Image and Feature Pyramids):** هذه طرق تمثل الصورة بأكثر من حجم أو مستوى، مما يساعد في اكتشاف الكائنات مهما اختلفت أحجامها. الأهرامات

الخاصة بخرائط الخصائص أقل استهلاكًا للطاقة لأن البرنامج لا يعيد تغيير حجم الصورة أكثر من مرة، بل يستخدم المعلومات الموجودة في الشبكة [8].



الشكل (3-5): تنفيذ هرم الميزات.

4-3-3 التداخل

في مهام الرؤية الاصطناعية باستخدام التعلم العميق، يحدث التداخل عندما تتقارب عدة كائنات بشكل كبير وتتداخل مع بعضها البعض. يُسبب هذا مشاكل في أنظمة تتبع الكائنات، حيث قد يتم تتبع الكائنات المتداخلة بشكل خاطئ أو يُخطئ النظام في التعرف عليها ويعتبرها كائنًا واحدًا بدلاً من عدة كائنات. قد يؤدي ذلك إلى ارتباك النظام وتحديد الكائن المتتبع في البداية على أنه كائن جديد [8].



الشكل (3-6): مثال على التداخل في كشف وتتبع الكائنات: الشخص مخفي جزئياً خلف الصناديق.

4-3 مستويات تتبع الكائنات

1-4-3 تتبع الكائنات المتعددة (MOT)

يُعرّف تتبع الكائنات المتعددة بأنه العملية التي تهدف إلى التعرف على عدة كائنات داخل مقطع فيديو وتتبع مسارات حركتها بدقة عالية. ويُستخدم هذا النوع من التتبع في تحليل تسلسلات الصور الرقمية، حيث يتم تمثيل كل كائن بمسار مستقل يوضح حركته خلال الزمن. ويُطلق على هذا النوع أيضاً "تتبع الأهداف المتعددة"، لأنه لا يقتصر على كائن واحد فقط، بل يشمل كائنات مختلفة تنتمي إلى فئات معروفة مسبقاً، مثل السيارات أو الأشخاص أو الدراجات. ويُعتبر هذا المجال أساسياً في العديد من التطبيقات، أبرزها القيادة الذاتية، حيث تُستخدم تقنيات التتبع لرصد تحركات المشاة والمركبات الأخرى والتنبؤ بسلوكهم [8].

يُعد تتبع الكائنات المتعددة من المهام المعقدة بسبب التداخل بين الكائنات، وتغيّر الإضاءة، والانقطاعات البصرية التي قد تؤثر على دقة التتبع، خاصة في البيئات الواقعية والمزدحمة. لذلك، يتم استخدام مجموعات بيانات متقدمة لتدريب الخوارزميات واختبارها، ومن أشهرها مجموعة بيانات KITTI، التي تُعد معياراً معتمداً في أبحاث الرؤية الحاسوبية، خاصة في مجال القيادة الذاتية، نظراً لما تتضمنه من مشاهد حقيقية ومتنوعة.


من أحدث وأدق الخوارزميات المستخدمة في هذا المجال: خوارزمية DEFT التي حققت دقة 88.95 وفق معيار MOTA، وخوارزمية CenterTrack بدقة 89.44، وخوارزمية SRK ODESA التي وصلت إلى دقة 90.03. وعلى الرغم من ارتفاع مستوى الدقة في هذه الخوارزميات، فإن بعضها لا يزال يواجه تحديات تتعلق بسرعة الأداء، مما يجعل من الضروري إيجاد توازن بين الدقة والسرعة في الأنظمة العملية.

3-4-1-1 تتبع الكائنات المتعددة vs الكشف العام عن الكائنات

يُنتج نظام كشف الكائنات عادة مجموعة من الصناديق المحيطة (Bounding Boxes) التي تُحدد مواقع الكائنات داخل الصورة. أما في أنظمة تتبع الكائنات المتعددة (MOT)، فلا تعتمد الخوارزميات غالبًا على تدريب مسبق دقيق يتعلق بشكل الكائنات أو عددها، بل تكفي بيانات عامة لتحديدتها. يتم تمييز كل صندوق محيط عبر معايير مثل الطول والعرض والإحداثيات وغيرها من الخصائص [8].

إضافةً إلى ذلك، تقوم خوارزميات MOT بإعطاء معرف فريد (ID) لكل كائن يتم اكتشافه، مما يُتيح للنظام تتبع كل كائن على حدة، حتى لو كانت الكائنات تنتمي إلى نفس الفئة. يُعرف هذا المعرف باسم "الكشف" (Detection)، وهو ضروري لتمييز الكائنات عن بعضها البعض داخل نفس الفئة.

فعلى سبيل المثال كما هو موضح في الشكل (3-7)، عند وجود عدة سيارات في صورة واحدة، فإن أنظمة الكشف العامة قد تصنفها جميعًا تحت تسمية "سيارة" فقط، أما خوارزميات تتبع الكائنات المتعددة فتقوم بتمييز كل سيارة عن الأخرى، وتمنح كل واحدة منها رقمًا خاصًا بها لتتبع حركتها بشكل مستقل.



الشكل (3-7): الفرق بين تتبع الكائنات المتعددة وكشف الكائنات.

5-3 تتبع الكائن الفردي (SOT)

تتبع الكائن الفردي (Single Object Tracking - SOT) هو تقنية تُستخدم لتتبع كائن واحد فقط داخل سلسلة من الصور أو مقاطع الفيديو. في هذا النوع من التتبع، يتم تحديد الكائن المراد تتبعه يدويًا في الإطار الأول (الصورة الأولى)، حيث يُرسم حوله صندوق يحدد موقعه. بعد ذلك، يعمل النظام على متابعة هذا الكائن نفسه في باقي الإطارات [8].



الشكل (3-8): تتبع الكرة فقط ضمن مشهد يحوي عدة لاعبين.

يُطلق على هذا الأسلوب أحيانًا اسم "التتبع البصري للكائنات" (Visual Object Tracking)، ويتميز بتركيزه على كائن واحد فقط، حتى في حال وجود كائنات أخرى في المشهد. ويُعد هذا النوع من التتبع مناسبًا عندما يكون الهدف الأساسي هو مراقبة حركة عنصر واحد دون الحاجة إلى التعامل مع كائنات متعددة.

يندرج هذا النوع تحت فئة التتبع غير المعتمد على الاكتشاف (Detection-Free Tracking)، حيث لا يقوم النظام بالكشف التلقائي عن الكائنات، بل يعتمد على تهيئة يدوية في بداية السلسلة. من عيوب هذا

الأسلوب أنه لا يمكنه التعامل مع الكائنات الجديدة التي قد تظهر في منتصف المشهد، فهو يتتبع فقط الكائن الذي تم تحديده في البداية.

3-6 خوارزميات تتبع الكائنات المتعددة (MOT)

تعتمد خوارزميات تتبع الكائنات المتعددة (MOT) بشكل رئيسي على طريقة "التتبع عن طريق الاكتشاف"، حيث يحدد كاشف الكائنات في كل إطار بشكل مستقل، ثم يربط المتتبع هذه الاكتشافات لتعقب مسار كل كائن عبر الفيديو بإعطائه معرفًا ثابتًا. تنقسم الخوارزميات إلى نوعين: الدفعية التي تستخدم معلومات من الإطارات المستقبلية لتحسين الدقة، والمتزامنة التي تعتمد فقط على الإطارات الحالية والسابقة لتلبية متطلبات التتبع في الوقت الحقيقي. تمر خوارزميات التتبع بثلاث مراحل رئيسية هي: الاكتشاف، التنبؤ بموقع الكائن، والربط بين الكائنات عبر الإطارات. تختلف الخوارزميات في كيفية تنفيذ هذه المراحل، مما يؤثر على دقتها وأدائها حسب التطبيق المستخدم [8].

3-6-1 مكتبة OpenCV

هو أحد الطرق الشائعة في هذا المجال، ويرجع ذلك إلى توافر العديد من الخوارزميات المدمجة داخل المكتبة، والتي تم تحسينها خصيصًا لتلبية متطلبات وأهداف تتبع الأجسام أو الحركة [8].

تتضمن مكتبة OpenCV مجموعة من المتتبعات المختلفة مثل BOOSTING و MIL و KCF و CSRT و MedianFlow و TLD و MOSSE و GOTURN، وكل منها مصمم لأغراض محددة. على سبيل المثال، يعتبر متتبع CSRT الأفضل عندما يحتاج المستخدم إلى دقة عالية في التتبع، مع إمكانية تقبل سرعة معالجة أقل (عدد إطارات في الثانية FPS).

يعتمد اختيار خوارزمية التتبع المناسبة في OpenCV على مزايا وعيوب كل متتبع ومدى ملاءمته للاستخدام. فعلى سبيل المثال، متتبع KCF لا يتمتع بدقة عالية مقارنة بـ CSRT، لكنه يوفر سرعة أكبر في معالجة الإطارات. أما متتبع MOSSE فهو الأسرع من حيث الأداء، لكنه يقدم دقة أقل من KCF، لذلك يُعد خيارًا مناسبًا إذا كان الهدف هو تحقيق أقصى سرعة في التتبع. أما متتبع GOTURN فهو المتتبع الوحيد في OpenCV الذي يعتمد على تقنيات التعلم العميق، وتم تطويره في الأصل باستخدام إطار العمل Caffe، ثم تم دمجها ضمن واجهة برمجة التطبيقات الخاصة بتتبع OpenCV.



الشكل (9-3): تتبع الأشخاص داخل المتاجر باستخدام تقنيات الرؤية الحاسوبية.

2-6-3 خوارزمية DeepSORT

تُعد خوارزمية DeepSORT من الخيارات الجيدة في مجال تتبع الأجسام، وهي واحدة من أكثر الأطر استخدامًا لهذا الغرض. يتم دمج معلومات المظهر البصري (Appearance) ضمن الخوارزمية، مما يساهم بشكل كبير في تحسين أدائها. وبفضل هذا الدمج، يمكن تتبع الأجسام حتى أثناء فترات الحجب الجزئي أو الكلي (Occlusion) لفترات طويلة، مما يقلل من حالات تبديل الهوية بين الأجسام المتتبعة.

3-6-3 برنامج MATLAB

برنامج MATLAB هو أداة قوية تُستخدم في العمليات الحسابية، ويُستخدم أيضًا لتتبع الأجسام في الفيديو، لكن طريقته تختلف عن الطرق المستخدمة في OpenCV أو DeepSORT. رغم هذا، فإنه يعتبر خيارًا جيدًا لتتبع الأجسام. يوفر MATLAB من خلال أداة اسمها Computer Vision Toolbox بعض الخوارزميات التي تساعد على تتبع الأجسام، مثل خوارزمية CAMShift التي تتكيف مع تغيير مكان الجسم، وخوارزمية KLT التي تتتبع النقاط المهمة في الجسم أثناء حركته. يمكن استخدام هذه الخوارزميات لتتبع جسم واحد، أو استخدامها ضمن نظام أكبر لتتبع عدة أجسام في نفس الوقت [8].

4-6-3 خوارزمية MDNet

تُعد خوارزمية MDNet من خوارزميات تتبع الأجسام الدقيقة والسريعة، وتعتمد في عملها على الشبكات العصبية الالتفافية (CNN)، وقد استلهم تصميمها من خوارزمية R-CNN المستخدمة في اكتشاف الأجسام. تعمل هذه الخوارزمية من خلال أخذ أجزاء معينة من الصورة (مناطق يُحتمل أن يكون فيها الجسم)، وتمريرها عبر شبكة عصبية. تكون هذه الشبكة عادة مدربة مسبقًا على مجموعة بيانات كبيرة، ثم يتم تعديلها لتناسب الجسم المطلوب تتبعه بدءًا من أول إطار في الفيديو [8].

لذلك، تُستخدم MDNet بشكل فعال في تطبيقات التتبع اللحظي (في الوقت الحقيقي). ومع أنها تحتاج إلى وقت وجهد حسابي كبير بسبب تعقيدها، فإنها تظل من الخيارات الدقيقة في تتبع الأجسام. وللتقليل من هذا العبء الحسابي، يمكن استخدام تقنية تُعرف باسم RoI Pooling، وهي طريقة تساعد على تقليل التكرار في معالجة الصورة وتسريع التنبؤ بمكان الجسم.

الفصل الرابع: البناء التطبيقي للنظام الذكي

1-4 مقدمة الفصل

يعرض هذا الفصل كيفية تجربة النظام المطور على مقطع فيديو يحاكي مشهداً مكتبياً يحتوي على موظفين. تم الاعتماد على هذا الفيديو لاختبار النموذج وتقييم قدرته على كشف الأشخاص وتتبعهم داخل منطقة العمل، وحساب مدة التواجد الزمني لكل منهم. كما يتضمن الفصل عرضاً لمراحل التنفيذ، مخطط الخوارزمية، لقطات من نتائج التجريب، ومقتطفات من الكود البرمجي المستخدم، بالإضافة إلى خاتمة توضح النتائج والآفاق الممكنة للتطوير.


2-4 مراحل تطور العمل

مرّ تنفيذ المشروع بعدة مراحل مترابطة تمثل دورة تطوير متكاملة، انطلقت من الفكرة النظرية إلى بناء نظام ذكي عملي وقابل للاستخدام. نوضح فيما يلي أبرز هذه المراحل:

- **تحليل المتطلبات:** تم تحديد احتياجات النظام بدقة، ومن بينها ضرورة التمييز بين الحضور الفعلي والتغيب أو التهرب من الدوام، وتوفير آلية ذكية لحساب وقت العمل الحقيقي بالدقة المطلوبة.
- **جمع البيانات وتحضيرها:** تم الحصول على تسجيلات فيديو من بيئة العمل لاستخدامها في تدريب نموذج الكشف والتتبع. كما تم استخدام أدوات لتعليم الصور يدوياً وفق تنسيق YOLO.
- **تصميم النموذج:** تم اختيار YOLOv8 للكشف عن الأشخاص، ودمجه مع DeepSORT لتتبعهم. كما تم تخصيص منطقة عمل محددة للتحقق من وجود العامل ضمنها.
- **التكامل البرمجي:** جرى تطوير كود مخصص لحساب مدة تواجد العامل بدقة باستخدام مكتبات pandas و datetime، مع ربط النتائج بقاعدة بيانات مخصصة.

- اختبار النظام وتحسينه: تم اختبار النظام في بيئة شبه حقيقية، وتمت معالجة التحديات المتعلقة بتراكب الأشخاص وفقدان التتبع المؤقت.


3-4 مخطط خوارزمية العمل




الشكل (4-1): مخطط خوارزمية العمل للنظام.

4-4 عرض النظام أثناء التنفيذ

توضح الصورتان المرفقتان، المشار إليهما بالشكل (2-4) والشكل (3-4)، تطبيق نظام تتبع الموظفين القائم على الرؤية الحاسوبية، والذي يستخدم نماذج مثل YOLO و DeepSORT. في الشكل (2-4)، يتم الكشف عن جميع الأفراد الموجودين داخل منطقة العمل وتحديدهم بواسطة مربعات حمراء، بينما تظهر مناطق العمل المحددة بخطوط خضراء، مع الإشارة إلى عدد الثواني التي قضاها كل شخص في الحقل المرئي. أما في الشكل (3-4)، فيستمر النظام في تتبع الموظفين، ولكن يظهر أحد الموظفين (الموظف الذي كان في منطقة العمل رقم 5 في الصورة السابقة) قد غادر منطقة العمل المحددة، مما أدى إلى تحول حدود منطقة العمل الخاصة به إلى اللون الأحمر، بينما تم تحديد الموظف الذي غادر المنطقة بمربع أحمر كبير خارج المنطقة الخضراء، وهذا يوضح قدرة النظام على التمييز بين الحضور الفعلي والغياب عن منطقة العمل المسموح بها، وإرسال تنبيهات في حالات التهرب من العمل.



الشكل (2-4): تتبع الحضور الفعلي للموظفين داخل مناطق العمل المحددة.



الشكل (4-3): رصد مغادرة أحد الموظفين لمنطقة العمل المحددة.

id	desk_number	total_seconds	date
1	1	0	2025-07-17
2	2	10.366666666666667	2025-07-17
3	3	11.5	2025-07-17
4	4	11.5	2025-07-17
5	5	11.5	2025-07-17
6	6	11.5	2025-07-17

الشكل (4-4): قاعدة بيانات النظام يظهر فيها ID الموظفين، أرقام المكاتب، مدة العمل والتاريخ.

	A	B	C	D	E	F	G	H	I	J
1	Id	desk_number	total_seconds	date						
2	1	0	10.3	17/07/2025						
3	2	3	10.36666667	17/07/2025						
4	3	1	11.5	17/07/2025						
5	4	2	11.5	17/07/2025						
6	5	4	11.5	17/07/2025						
7	6	5	11.5	17/07/2025						
8										
9										
10										
11										
12										
13										
14										
15										
16										
17										
18										
19										
20										
21										
22										
23										
24										
25										
26										
27										
28										
29										

الشكل (4-5): استخراج قاعدة البيانات في ملف إكسل.

5-4 الخاتمة والآفاق المستقبلية

تختتم هذه الدراسة بتأكيد فعالية النظام المقترح في رصد أوقات عمل الموظفين بدقة متناهية، متجاوزة التحديات التقليدية في تتبع الحضور والانصراف، ولقد أثبتت النتائج الأولية للنظام قدرته على تحقيق الهدف الأساسي للمشروع والمتمثل في حساب الساعات الفعلية للعمل لكل موظف بدقة تصل إلى الثواني، مع القدرة على التمييز بفاعلية بين الحضور الفعلي والغياب، أو حتى محاولات التهرب من العمل مثل مغادرة منطقة العمل دون إذن مسبق، وذلك بالاعتماد على نماذج متقدمة في مجال الرؤية الحاسوبية مثل YOLO و DeepSORT، التي أتاحت الكشف الدقيق عن العمال وتتبع حركتهم ضمن المناطق المحددة للعمل. لم يقتصر دور النظام على مجرد الرصد، بل امتد ليشمل إرسال تنبيهات فورية للمديرين في حالات الغياب غير المبرر أو التواجد خارج المناطق المسموح بها، مما يعزز من كفاءة الإدارة

ويقلل من الهدر الزمني. لقد تمكن المشروع من دمج البيانات الزمنية للموظفين بشكل سلس، حيث تم تسجيل بيانات الحضور والانصراف تلقائيًا وتخزينها في قاعدة بيانات مصممة خصيصًا لهذا الغرض، تحتوي على معلومات شاملة عن الموظفين وسجلاتهم الزمنية ومدة دوامهم، وقد استخدمت مكتبات مثل `pandas` و `datetime` لتحليل الوقت وحساب ساعات العمل بدقة فائقة، مما وفر نظامًا متكاملًا وشاملاً لإدارة الحضور.

في سبيل تطوير هذا المشروع الطموح، تتجه أنظارنا نحو العديد من التحسينات المستقبلية التي من شأنها أن تعزز من قدراته وتوسع من نطاق تطبيقاته، ومن أبرز هذه التحسينات هي زيادة دقة التعرف على الوجوه، ليس فقط لتعزيز الأمن وتجنب أي محاولات للتحايل، بل أيضًا لضمان أن النظام يتعرف بشكل لا لبس فيه على كل موظف، مما يضيف طبقة إضافية من الموثوقية للبيانات التي يتم جمعها. كذلك، نطمح إلى تحسين أداء النظام في ظروف الإضاءة المتغيرة، حيث يمكن أن تؤثر الإضاءة المنخفضة أو الساطعة جدًا على دقة الكشف والتتبع، ولتحقيق ذلك، يمكن استكشاف تقنيات معالجة الصور المتقدمة أو استخدام كاميرات ذات قدرات أفضل في الإضاءة المنظورة وغير المنظورة.

علاوة على ذلك، من المخطط دمج النظام مع أنظمة إدارة الموارد البشرية (HRM) الحالية في الشركات، مما سيتيح تدفقًا سلسًا للبيانات بين الأنظمة المختلفة، ويسهل على أقسام الموارد البشرية إدارة سجلات الدوام، وإعداد التقارير، وحساب الرواتب بشكل أكثر فعالية وكفاءة، مما يقلل من الأعباء الإدارية ويزيد من دقة العمليات. ولا يقل أهمية عن ذلك، تطوير واجهة مستخدم (UI) وتجربة مستخدم (UX) أكثر سهولة وبديهية للمديرين والموظفين على حد سواء، بحيث يمكن للمديرين تتبع فرق العمل بسهولة، والوصول إلى التقارير في الوقت الفعلي، بينما يتمكن الموظفون من الاطلاع على سجلات دوامهم وتصحيح أي أخطاء محتملة.

تتضمن الرؤية المستقبلية للمشروع أيضًا إمكانية إضافة وظائف تحليلية متقدمة، مثل تحليل أنماط الحضور والانصراف للموظفين، وتحديد أوقات الذروة في الحضور أو الغياب، مما يمكن أن يوفر رؤى قيمة للإدارة حول كفاءة العمل وتخطيط الموارد البشرية، على سبيل المثال، يمكن للنظام أن يقترح أفضل الأوقات لعقد الاجتماعات أو تنفيذ المهام التي تتطلب وجود عدد كبير من الموظفين. كما يمكن تطوير نظام تنبيهات أكثر ذكاءً وقابلية للتخصيص، بحيث يمكن للمديرين تحديد معايير معينة لإرسال التنبيهات، مثل تجاوز عدد معين من الدقائق للغياب غير المبرر، أو التواجد في منطقة غير مسموح بها لفترة طويلة. وأخيرًا، قد يشمل التوسع المستقبلي للمشروع تطبيق تقنيات تعلم التعزيز (Reinforcement Learning) لتحسين سلوك النظام بمرور الوقت، مما يسمح للنظام بالتعلم من الأخطاء السابقة وتكييف استراتيجياته لتحقيق أفضل أداء ممكن، على سبيل المثال، يمكن للنظام أن يتعلم كيفية التمييز بشكل أفضل بين الأنشطة المتعلقة بالعمل وتلك غير المتعلقة به، مما يساهم في حساب أكثر دقة لساعات العمل الفعلية. مع كل هذه التحسينات، يهدف المشروع إلى أن يصبح أداة لا غنى عنها في بيئة العمل الحديثة، تدعم الإنتاجية، وتعزز الشفافية، وتوفر بيئة عمل أكثر كفاءة وتنظيمًا للشركات.

الملحق

الكود البرمجي

```

33 while cap.isOpened():
34     _,frame=cap.read()
35     c+=1
36     # frame=cv2.resize(frame,(100,100))
37     res=model.track(frame, persist=True)
38     cls = res[0].boxes.cls.cpu().tolist()
39     names = res[0].names
40
41     boxes=res[0].boxes.xywh.cpu()
42     id=res[0].boxes.id.int().cpu().tolist()
43
44     for i, box in enumerate(boxes):
45         x,y,w,h=box
46         x=int(x)
47         y=int(y)
48         h=int(h)
49         w=int(w)
50         x1 = x - w // 2
51         y1 = y - h // 2
52         y2 = y + h // 2
53         x2 = x + w // 2
54         name_ob=class_name[cls[i]]
55         if name_ob!="person" :
56             continue
57         cv2.putText(frame, f"{name_ob}", (x1, y1 - 10), cv2.FONT_HERSHEY_DUPLEX, 1, (0, 0, 200), 1)
58         cv2.rectangle(frame, (x1, y1), (x2, y2), (0, 0, 200), 1)
59         person_info.append([x,y,h,w])
60     for index, pos in enumerate(working_area):
61         pos=np.array(pos)
62         cv2.polyline(frame, [pos], isClosed=True, color=color, thickness=2)
63     for per in person_info:
64

```

الملحق

```
65     xp,yp,hp,wp=per
66     x1 = xp - wp // 2
67     y1 = yp - hp // 2
68     y2 = yp + hp// 2
69     x2 = xp + wp // 2
70
71     r=cv2.pointPolygonTest(np.array(pos,dtype=np.int32), (xp,yp), False)
72     if(r>0):
73         cv2.polylines(frame, [pos], isClosed=True, color=color, thickness=2)
74
75         area_time[index]+=1
76         break
77     else:
78         cv2.polylines(frame, [pos], isClosed=True, color=color_r, thickness=2)
79
80
81
82     for n,ti in area_time.items():
83
84         cv2.putText(frame, str(n)+" :"+str(int(ti/10)), (40, 40+(n*30)),
85                     cv2.FONT_HERSHEY_SIMPLEX, 1, (0, 0, 0), 2)
86     print(c)
87     cv2.imshow("ss", frame)
88     k=cv2.waitKey(1)
89     if k== ord("q"):
90         break
91
92 cap.release()
93 cv2.destroyAllWindows()
```

الملحق

```
1 import cv2
2 import numpy as np
3 from ultralytics import YOLO
4
5 cap = cv2.VideoCapture("C:\\Users\\Laptopi-Homs\\Desktop\\work-desk.mp4")
6 fourcc = cv2.VideoWriter_fourcc(*'mp4v') # Codec for .mp4
7 out = cv2.VideoWriter('output_video/work_desk_output.mp4', fourcc, 30.0, (int(cap.get(3)), int(cap.get(4))))
8
9 model = YOLO('D:\\pro\\yolo11n.pt')
10
11
12 working_area = [
13     [(499, 41), (384, 74), (377, 136), (414, 193), (417, 112), (548, 91)],
14     [(547, 91), (419, 113), (414, 189), (452, 289), (453, 223), (615, 164)],
15     [(158, 84), (294, 85), (299, 157), (151, 137)],
16     [(151, 139), (300, 155), (321, 251), (143, 225)],
17     [(143, 225), (327, 248), (351, 398), (142, 363)],
18     [(618, 166), (457, 225), (454, 289), (522, 396), (557, 331), (698, 262)]
19 ]
20 area_time={
21     0:0,
22     1:0,
23     2:0,
24     3:0,
25     4:0,
26     5:0
27 }
28 class_name=model.names
29 person_info=[]
30 color=(0,255,0)
31 color_r=(0,0,255)
32 c=0
33 while cap.isOpened():
34     _,frame=cap.read()
```

جدول المصطلحات

المعنى بالعربية	المعنى الإنجليزية	الاختصار
الذكاء الاصطناعي	Artificial Intelligence	AI
الرؤية الحاسوبية	Computer Vision	CV
أنت تنظر لمرة واحدة	You Only Look Once	YOLO
التتبع البسيط عبر الانترنت وفي الوقت الفعلي باستخدام مقياس ارتباط عميق	Simple Online and Realtime Tracking With a Deep Association Metric	DeepSORT
واجهة المستخدم	User Interface	UI
تجربة المستخدم	User Experience	UX
إدارة الموارد البشرية	Human Resources Management	HRM
قيم مفصولة بفواصل	Comma-Separated Values	CSV
تدوين كائن جافا سكريبت	JavaScript Object Notation	JSON
منطقة الاهتمام	Region Of Interest	ROI
إطارات في الثانية	Frames Per Second	FPS

المراجع

- [1] Asabere, N. Y., & Gyamfi, N. K. (2013). AIDSS-HR: An Automated Intelligence Decision Support System For Enhancing the Performance of Employees. IJCSN International Journal of Computer Science and Network, 2(4), 1. Retrieved from www.ijcsn.org
- [2] CleverControl. (2024, November 14). مراقبة الموظفين بالذكاء الاصطناعي. <https://clevercontrol.com/ar/ai-powered-employee-monitoring/>
- [3] Saini, N. (2023). RESEARCH PAPER ON ARTIFICIAL INTELLIGENCE & ITS APPLICATIONS. International Journal for Research Trends and Innovation, 8(4), 356.
- [4] Wu, Z. (2023). Studies on the Application of Machine Learning and Deep Learning in Image Recognition. In Proceedings of the 3rd International Conference on Digital Economy and Computer Application (DECA 2023). Atlantis Press.
- [5] Montesinos López, O. A., Montesinos López, A., & Crossa, J. (2022). Fundamentals of Artificial Neural Networks and Deep Learning. In Multivariate Statistical Machine Learning Methods for Genomic Prediction. National Center for Biotechnology Information (NCBI). <https://www.ncbi.nlm.nih.gov/books/NBK583971/>
- [6] Datacamp. (n.d.). YOLO object detection explained. DataCamp. <https://www.datacamp.com/blog/yolo-object-detection-explained>
- [7] Shah, D. (2023, May 30). Intersection over Union (IoU): Definition, Calculation, Code. V7 Labs. <https://www.v7labs.com/blog/intersection-over-union-guide>

المراجع

- [8] Viso.ai. (n.d.). Object tracking in computer vision: Complete guide. Viso.ai.
<https://viso.ai/deep-learning/object-tracking/#what-is-object-tracking>

Syrian Arab Republic
Ministry of Higher Education and Scientific Research
Al-Wataniya Private University
Department of Computer Engineering



A project prepared for the Bachelor's degree in Computer Engineering, entitled:

Development of an Intelligent System for Monitoring Workers' Attendance Using Artificial Intelligence and Computer Vision

Prepared By:

Raghad Al sheikh Khalil

Nancy Eshak

Supervised By:

Dr.Eng.Ahmad Ryad Kurdi

2025-2024