



الجمهورية العربية السورية
وزارة التعلم العالي والبحث العلمي
الجامعة الوطنية الخاصة
قسم هندسة الحاسوب

مشروع فصلي بعنوان:

تطوير نظام لكشف المخالفات في قاعات الامتحانات باستخدام تقنيات الرؤية الحاسوبية

إعداد الطالبات:

آيه حريري - اعتدال شنتوت - ميسم خليل

إشراف:

الدكتور المهندس أحمد رياض كردي

2025-2024

ملخص المشروع:

يهدف هذا المشروع إلى تطوير نظام ذكي قادر على كشف محاولات الغش في قاعات الامتحانات من خلال تتبع سلوكيات الطلاب باستخدام تقنيات الرؤية الحاسوبية والذكاء الاصطناعي. تم بناء النظام ليعتمد على تحليل حركات الرأس والجسم عبر كاميرات مراقبة تقليدية أو مدمجة، باستخدام خوارزميات متقدمة مثل YOLO لتحديد الأجسام، وتقنية MediaPipe لتقدير الوضعيات. يقوم النظام باكتشاف أي حركة غير طبيعية كالتفات الرأس أو النظر المتكرر بعيداً عن الشاشة، ويُطلق تنبيهاً فورياً للمراقبين متضمناً زمن وموقع الحركة المشبوهة. يساهم المشروع في تقليل الاعتماد على العنصر البشري في المراقبة، وتخفيض التكاليف التشغيلية، كما يعزز من نزاهة العملية الامتحانية ويضمن معايير تقييم عادلة بين الطلاب. أظهرت نتائج التطبيق العملي قدرة النظام على التمييز بفعالية بين حالات التركيز والانحراف، حيث كشف بدقة حالات الالتفات أو الحركة الجسدية غير الطبيعية، مقابل الحالات المستقيمة التي تعكس التزام الطالب.

الكلمات المفتاحية:

كشف الغش، الرؤية الحاسوبية، الذكاء الاصطناعي، YOLO، تقدير الوضعيات، MediaPipe

ABSTRACT:

This project aims to develop an intelligent system capable of detecting cheating attempts in exam halls by analyzing students' behavior using computer vision and artificial intelligence techniques. The system utilizes traditional or mobile cameras to track head and body movements, employing advanced algorithms such as YOLO for object detection and MediaPipe for pose estimation. It identifies abnormal actions such as head turning or frequent gaze deviation from the screen, triggering immediate alerts to invigilators with the exact timestamp and location of the suspicious activity. The system reduces reliance on human surveillance, minimizes operational costs, and promotes academic integrity by ensuring fair evaluation standards. Practical implementation results demonstrated the system's effectiveness in distinguishing between focused and suspicious behavior, successfully detecting unnatural body or head movements while validating forward-facing postures as compliant.

Keywords:

Cheating Detection, Computer Vision, Artificial Intelligence, YOLO, Pose Estimation, MediaPipe.

فهرس المحتويات

1 الفصل الأول: الإطار العام للمشروع	6
1-1 السياق والمشكلة البحثية	2
2-1 أهداف المشروع	4
3-1 مراجعة لمشاريع سابقة مشابهة	5
1-3-1 كشف الغش في قاعات الامتحانات باستخدام تقنيات المراقبة بالفيديو	5
2-3-1 استكشاف إمكانات الهيكل العظمي والتعلم الآلي في كشف الغش في الفصول الدراسية	7
3-3-1 الفجوة البحثية	10
2 الفصل الثاني: الأسس التقنية والنظرية	11
1-2 معالجة الصور الرقمية	12
2-2 الذكاء الاصطناعي: من التعلم الآلي إلى التعلم العميق	13
1-2-2 التعلم الآلي (ML) مقابل التعلم العميق (DL)	13
3-2 الشبكات العصبية الاصطناعية (Neural Networks)	16
1-3-2 الشبكات العصبية الترشيحية (CNNs)	18

26.....	4-2 كشف الكائنات (Object Detection)
26.....	1-4-2 تصنيف الصور (Image Classification)
27.....	2-4-2 تحديد موقع الكائن (Object Localization)
27.....	3-4-2 خوارزمية YOLO لكشف الكائنات
36	3 الفصل الثالث: تقدير الوضعيات
37.....	1-3 مفهوم تقدير الوضعيات (Pose Estimation)
40.....	2-3 لمحة عن مكتبة MediaPipe
43.....	3-3 تقدير وضعيات الجسم باستخدام MediaPipe BlazePose
46.....	4-3 تتبع اليدين باستخدام MediaPipe Hands
49.....	5-3 تتبع الوجه باستخدام MediaPipe Face Mesh
54	4 الفصل الرابع: التنفيذ العملي والنتائج
55.....	1-4 إعداد بيئة العمل
55.....	2-4 مخطط خوارزمية العمل
57.....	3-4 المخطط الصندوقي
57.....	4-4 التطبيق العملي للنظام
59.....	5-4 النتائج

5 الفصل الخامس: الخاتمة والآفاق المستقبلية 60

6 المراجع 65

فهرس الأشكال

- الشكل 1-1: نتائج الدراسة. 6
- الشكل 1-2: النقاط المميزة للهيكل العظمي. 7
- الشكل 1-3: الزوايا المختلفة للكاميرا في الفصل الدراسي. 8
- الشكل 1-4: تقسيم الإطارات في الفيديو. 8
- الشكل 1-5: سلوكيات الغش التي تم تدريب النظام عليها. 9
- الشكل 1-6: كشف الغش في الوقت الفعلي. 9
- الشكل 2-1: جزء من الصورة الرقمية. 12
- الشكل 2-2: كيفية عمل التعلم الآلي (Machine Learning). 13
- الشكل 2-3: كيفية عمل التعلم العميق. 14
- الشكل 2-4: طبقات الشبكة العصبية الاصطناعية. 17
- الشكل 2-5: مراحل الشبكة العصبية الترشيحية. 19
- الشكل 2-6: عملية الترشيح. 20
- الشكل 2-7: الفرق بين أنواع ال Padding الثلاث. 22
- الشكل 2-8: الهيكلية الهرمية لعمل المرشحات الإضافية. 23
- الشكل 2-9: الفرق بين Max Pooling و Average Pooling. 24
- الشكل 2-10: كشف الكائنات. 26

الشكل 2-11: تقسيم الصورة إلى خلايا.....	28
الشكل 2-12: مثال على IOU: المنطقة الخضراء (التداخل) مقسومة على المنطقة البنفسجية (الاتحاد).....	29
الشكل 2-13: النتيجة النهائية للكشف باستخدام YOLO.....	30
الشكل 2-14: توضيح مصفوفة التشويش.....	31
الشكل 2-15: تقنية NMS.....	33
الشكل 2-16: تقنية YOLO-Pose.....	35
الشكل 3-1: تقنية Pose Estimation.....	37
الشكل 3-2: مكتبة MediaPipe.....	41
الشكل 3-3: النقاط الرئيسية للجسم.....	45
الشكل 3-4: النقاط الرئيسية لليدين.....	46
الشكل 3-5: تسلسل مراحل معالجة الصورة في نظام MediaPipe Hands.....	47
الشكل 3-6: النقاط الرئيسية للوجه.....	50
الشكل 3-7: آلية عمل MediaPipe Face Mesh.....	51
الشكل 4-1: مخطط خوارزمية العمل.....	56
الشكل 4-2: المخطط الصندوقي لعملية كشف حالات الغش.....	57
الشكل 4-3: كشف حالات غش.....	58
الشكل 4-4: حالة عدم غش.....	58

جدول المصطلحات

الاختصار	المعنى بالإنجليزية	المعنى بالعربية
AI	Artificial Intelligence	الذكاء الاصطناعي
ML	Machine Learning	التعلم الآلي
DL	Deep Learning	التعلم العميق
CNN	Convolutional Neural Network	الشبكة العصبية الترشيحية
RNN	Recurrent Neural Network	الشبكة العصبية المتكررة
GAN	Generative Adversarial Network	الشبكة التوليدية التنافسية
SVM	Support Vector Machine	آلة المتجهات الداعمة
YOLO	You Only Look Once	أنت فقط تنظر مرة واحدة (خوارزمية)
NMS	Non-Maximum Suppression	قمع القيم غير القصوى

نظام إدارة التعلم	Learning Management System	LMS
التقاطع على الاتحاد	Intersection Over Union	IOU
الإيجابية الحقيقية	True Positive	TP
الإيجابية الكاذبة	False Positive	FP
السلبية الحقيقية	True Negative	TN
السلبية الكاذبة	False Negative	FN
وحدة الخطية المستقيمة (دالة تنشيط)	Rectified Linear Unit	ReLU
متصلة بالكامل (طبقة في الشبكات العصبية)	Fully Connected	FC
الواقع المعزز/الواقع الافتراضي	Augmented Reality / Virtual Reality	AR/VR
مجموعة بيانات	Canadian Institute for Advanced Research Dataset	CIFAR-10

قاعدة بيانات لصور الأرقام اليديوية	Modified National Institute of Standards and Technology	MNIST
تحدي التعرف البصري واسع النظام (ImageNet)	ImageNet Large Scale Visual Recognition Challenge	ILSVRC
شبكة مجموعة الهندسة البصرية	Visual Geometry Group Network	VGGNet
الشبكة المتبقية	Residual Network	ResNet
شبكة زيلر وفيرغوس	Zeiler and Fergus Network	ZFNet
مكتبة الرؤية الحاسوبية مفتوحة المصدر	Open-Source Computer Vision Library	OpenCV

الفصل الأول: الإطار العام للمشروع

1-1 السياق والمشكلة البحثية

تُعد ظاهرة الغش في الامتحانات واحدة من أبرز المشكلات التي تواجه المنظومة التعليمية على اختلاف مراحلها، بدءًا من المدارس وحتى الجامعات، حيث تؤثر سلبيًا على مصداقية الشهادات العلمية وتقوض مبدأ العدالة بين الطلاب [1]. ففي البيئات التقليدية، يعتمد الكشف عن الغش بشكل أساسي على المراقبة البشرية، والتي تواجه تحديات جمة تبدأ من الصعوبة في مراقبة عدد كبير من الطلاب في آن واحد، وصولاً إلى التحيزات غير الواعية التي قد تنشأ من اختلاف المعايير بين المراقبين. على سبيل المثال، قد يغفل المراقب عن حركة طالب يلتفت بشكل متكرر أو يُغير وضعيته جسده بشكل مريب، أو يفشل في رصد السلوكيات الدقيقة التي تُشير إلى محاولة غش، مثل الإشارات البصرية بين الطلاب [2]. هذه الثغرات لا تُضعف فقط نزاهة التقييم، بل تُعزز أيضًا ثقافة الاعتماد على الحيل غير المشروعة بدلًا من الجهد الفردي، مما يُنتج جيلاً من الخريجين يفتقرون إلى المهارات الحقيقية المطلوبة في سوق العمل.

علاوة على ذلك، تُشكل التكلفة المالية والبشرية المرتفعة للأساليب التقليدية عبئًا كبيرًا على المؤسسات التعليمية. ففي الامتحانات الكبيرة التي يشارك فيها مئات الطلاب، يلزم توظيف فرق مراقبة ضخمة تعمل لساعات طويلة، مع ما يرافق ذلك من تكاليف لوجستية (كتجهيز القاعات وتوزيع المراقبين) ومالية (رواتب المراقبين الإضافية) [3]. كما أن التعب والإرهاق البشري قد يؤديان إلى انخفاض كفاءة المراقبة مع تقدم وقت الامتحان، مما يخلق فجوات في الرصد الفوري للسلوكيات المشبوهة [4][5]. في المقابل، يُظهر الطلاب أحيانًا سلوكيات غش مبتكرة، مثل استخدام إشارات بدنية مُقنعة أو تغيير وضعيات الجلوس

لتمرير إجابات، مما يجعل مهمة المراقب البشري أكثر تعقيداً ويُبرز ضرورة وجود نظام قادر على تحليل الحركات البشرية بدقة وسرعة فائقين.

من هنا، يبرز النظام المقترح كحلٍ تقني مبتكر يعتمد على تقنيات الرؤية الحاسوبية والذكاء الاصطناعي لتعزيز نزاهة الامتحانات. فمن خلال معالجة إطارات الفيديو المُجمعة من كاميرات المراقبة المثبتة في القاعات، يتمكن النظام من تحليل حركات الطلاب في الزمن الحقيقي باستخدام خوارزميات متقدمة مثل YOLO (You Only Look Once) لتحديد مناطق الاهتمام في الصورة، وتقنيات Pose Estimation (تحليل وضعية الجسم) عبر مكتبات مثل MediaPipe لرصد الحركات غير الطبيعية. على سبيل المثال، إذا حاول طالب الالتفات المتكرر نحو زميله، أو قام بثني جسده بشكل مريب لمحاولة إخفاء حركة، يُحلل النظام هذه السلوكيات عبر مئات الإطارات في الثانية، ويُقارنها مع أنماط محددة مسبقاً لتحديد مدى احتمالية الغش.

ما يميز هذا النظام هو قدرته على التركيز على تحليل الحركات البدنية كمؤشر رئيسي للكشف عن الغش. كما أنه يُقلل من التدخل البشري وما يرتبط به من تحيز أو أخطاء، حيث يعمل وفق معايير موحدة قابلة للتعديل وفقاً لسياسات المؤسسة التعليمية. بالإضافة إلى ذلك، يُرسل النظام تنبيهات فورية إلى المراقبين عند رصد أي نشاط مشبوه، مع تسجيل اللحظة الزمنية والمكان الدقيق للحركة، مما يُسهل عملية المراجعة اللاحقة ويُسهل في إنشاء سجلات موثوقة لضمان الشفافية. بجانب ذلك، يُخفض النظام التكاليف التشغيلية على المدى الطويل، حيث يُغني عن الحاجة إلى توظيف فرق مراقبة ضخمة، ويمكن دمجه مع أنظمة إدارة التعلم (LMS) لربط بيانات الغش مباشرةً بسجلات الطلاب.

علاوة على الجوانب التقنية، يُسهم النظام في تعزيز ثقة الطلاب أنفسهم في نزاهة العملية التعليمية، حيث يُدرك الجميع أن التقييم يخضع لمعايير موضوعية لا تتأثر بالعوامل الشخصية. كما أنه يُمكن تطويره ليشمل تقنيات إضافية، مثل تحليل تعابير الوجه لاكتشاف علامات القلق أو التردد التي قد تشير إلى محاولة غش، أو دمج أنظمة التعلم الآلي (Machine Learning) لتحسين دقة النموذج باستمرار عبر تزويده بمزيد من بيانات التدريب.

يُقدم هذا المشروع إطارًا تقنيًا متكاملًا لمواجهة تحديات الغش في الامتحانات، معالجًا جذور المشكلة عبر توظيف أحدث التقنيات، ورافعًا شعار "العدالة في التقييم" كأساس لبناء منظومة تعليمية أكثر مصداقية وفعالية.

1-2 أهداف المشروع

1. بناء نظام ذكي لاكتشاف السلوكيات المشبوهة: تصميم نظام يعمل تلقائيًا باستخدام الذكاء الاصطناعي والرؤية الحاسوبية لتحليل حركات الطلاب خلال الامتحانات، مثل الالتفات المتكرر أو تغيير وضعية الجسد بشكل غير طبيعي، دون الحاجة إلى تدخل بشري مباشر.
2. تحليل الحركات البدنية بدقة عالية: تتبع حركات الجسم (كالرأس، اليدين، والجذع) عبر تقنيات مثل Pose Estimation لتحديد الأنماط التي تشير إلى محاولات غش، مثل محاولة التواصل البصري مع زملاء الدراسة.

3. إرسال تنبيهات فورية للمراقبين: عند رصد أي سلوك غير طبيعي، يُرسل النظام إشعارات فورية إلى المراقبين مع تحديد اللحظة الزمنية والمكان الدقيق للحركة المشبوهة، مما يسمح بالتعامل السريع مع الموقف.
4. تقليل التكلفة البشرية والمادية: استبدال الاعتماد الكثيف على المراقبين البشريين بأنظمة آلية قادرة على مراقبة مئات الطلاب معاً، مما يخفض التكاليف التشغيلية ويحسن كفاءة إدارة الامتحانات.
5. تعزيز النزاهة الأكاديمية: ضمان تطبيق معايير تقييم موحدة وعادلة بين جميع الطلاب، بعيداً عن التحيز البشري أو الأخطاء الناتجة عن التعب، مما يعزز ثقة الجميع في مصداقية الشهادات العلمية.
6. إنشاء سجلات موثوقة للمراجعة: تسجيل جميع الحركات المشبوهة مع تحديد زمن حدوثها، مما يُسهّل مراجعة الامتحانات لاحقاً واتخاذ قرارات مبنية على أدلة واضحة.
7. دعم التحسين المستمر للنظام: تصميم النظام ليكون قابلاً للتطوير بإضافة تقنيات إضافية مستقبلاً، مثل تحليل تعابير الوجه أو دمج بيانات التعلم الآلي لزيادة دقة الاكتشاف.


1-3-3 مراجعة لمشاريع سابقة مشابهة

1-3-1 كشف الغش في قاعات الامتحانات باستخدام تقنيات المراقبة بالفيديو

في إطار مراجعة المشاريع السابقة المشابهة، تبرز دراسة حديثة تناولت تصميم نظام ذكي لاكتشاف حالات الغش في قاعات الامتحانات باستخدام تقنيات تحليل الفيديو. يعتمد النظام على مراقبة سلوك الطلاب عبر كاميرات مثبتة في القاعات، مع تركيز خاص على ثلاث تقنيات رئيسية: تتبع حركة الرأس، وتحليل اتجاه حركة العين (القرحجية)، ورصد التفاعلات بين الطلاب باستخدام الـ [6].

أولاً، يحلل النظام حركة الرأس من خلال كشف الوجه باستخدام خوارزمية Viola-Jones، التي تُحدد اتجاه النظر بدقة. إذا انحرف الطالب بشكل متكرر عن ورقة الإجابة (مثل النظر إلى زميله)، يُصنف النظام هذا السلوك كمشبوّه. ثانيًا، يُتابع النظام حركة العين عبر تقنية Gabor Filters لتحديد لحظات التركيز على مصادر خارجية (كالهواتف أو الأوراق المخبأة)، مع استخدام PCA لتعزيز دقة التحليل. ثالثًا، يُراقب النظام حركة اليدين عبر كشف المناطق الجلدية وتتبع التلامس بين الطلاب (مثل تبادل الأوراق)، حيث تُحيط مربعات حمراء بالمناطق المشبوهة في الفيديو.

الدراسة أظهرت أن النظام قادر على تصنيف السلوكيات إلى طبيعية أو غير طبيعية في الوقت الفعلي، مع إرسال تنبيهات فورية عند اكتشاف أي نشاط مريب. على سبيل المثال، تُظهر الصورة (a4) في الدراسة سلوكًا طبيعيًا مع مربعات خضراء حول الطلاب، بينما تُظهر الصور (b4، c4، d4) حالات غش مكتشفة (استخدام الهاتف، الاطلاع على أوراق الآخرين، تبادل المواد الممنوعة) مع مربعات حمراء للتنبيه.




الشكل 1-1: نتائج الدراسة.

يتميز النظام بقدرته على التقليل من الأخطاء البشرية المرتبطة بالمراقبة التقليدية، كما يُقلل التكاليف التشغيلية عبر الأتمتة. ومع ذلك، أشارت الدراسة إلى تحديات مثل الحاجة إلى إضاءة مناسبة ودقة أعلى في كشف الحركات الدقيقة، مما يفتح المجال لتحسينات مستقبلية.

1-3-2 استكشاف إمكانات الهيكل العظمي والتعلم الآلي في كشف الغش في الفصول الدراسية

تناولت الدراسة تطوير نظام للكشف التلقائي عن سلوكيات الغش في الامتحانات باستخدام تقنيات الذكاء الاصطناعي. ركزت الدراسة على تحليل حركة الطلاب عبر تحديد الهيكل العظمي للجسم (الشكل 1-1) باستخدام نموذج YOLO-Pose، الذي يتعرف على 18 نقطة رئيسية في الجسم، مثل الرأس واليدين. بعد استخراج هذه النقاط، تم تحليل التسلسل الزمني للحركات عبر نماذج مثل SVM وXGBoost، بالإضافة إلى شبكة Ac-LSTM المُعدلة لفهم السياق الزمني للسلوكيات [7].

	kp0_X	kp0_Y	kp0_Confi	kp1_X	kp1_Y	kp1_Confi	kp2_X	kp2_Y	kp2_Confi
1506	0.617659	0.839054	0.863150	0.684358	0.875559	0.844554	0.563378	0.886501	0.764939
1507	0.618699	0.840609	0.875331	0.684703	0.878015	0.855298	0.564693	0.888477	0.785752
1508	0.622940	0.843531	0.846056	0.687709	0.880058	0.815234	0.569388	0.889436	0.746726
1509	0.620980	0.836386	0.881042	0.687272	0.873766	0.862819	0.566025	0.883769	0.797772
1510	0.619537	0.838653	0.887448	0.685610	0.876426	0.871103	0.564638	0.886251	0.806280



الشكل 1-2: النقاط المميزة للهيكل العظمي.

تم بناء مجموعة بيانات مخصصة لهذه الغاية، حيث شارك 12 طالبًا في تسجيل مقاطع فيديو من زوايا متعددة (الشكل 1-3) لمحاكاة سيناريوهات الغش في الامتحانات الورقية. قُسمت المقاطع إلى فترات "غش" (مثل النظر إلى أوراق الآخرين أو استخدام مراجع) و"عدم غش" (الشكل 1-4). أظهرت النتائج

تفوق نموذج XGBoost بدقة 95%، بينما حقق Ac-LSTM دقة 94%، مع قدرة النظام على معالجة الفيديو بسرعة 10-12 إطارًا في الثانية، مما يناسب التطبيقات العملية.



Left side view




Frontal view




Right side view

الشكل 1-3: الزوايا المختلفة للكاميرا في الفصل الدراسي.




الشكل 1-4: تقسيم الإطارات في الفيديو.


واجهت الدراسة تحديات مثل صعوبة تمييز حركة التفكير الطبيعي (مثل التحديق في الفراغ) عن الغش، وضرورة إزالة نقاط الهيكل العظمي غير الضرورية (مثل الساقين) لتحسين الكفاءة. كما استخدم الباحثون خوارزمية IoU لتتبع حركة الطلاب بين الإطارات المتتالية لضمان دقة التحليل. أكدت النتائج إمكانية تطبيق النظام في الفصول الدراسية أو الامتحانات عبر الإنترنت، مع توصيات بتحسين جودة البيانات وتجربة نماذج متقدمة مثل GCN في المستقبل. تتوضح آلية عمل النظام في الشكل (1-5) والشكل (1-6).




Exchanging exam papers



Discussing exam result




Copying answers



Looking at other examinees' papers

الشكل 1-5: سلوكيات الغش التي تم تدريب النظام عليها.



الشكل 1-6: كشف الغش في الوقت الفعلي.


1-3-3 الفجوة البحثية

بينما تسعى الدراسات السابقة إلى تطوير أنظمة لكشف الغش في قاعات الامتحانات باستخدام تقنيات مختلفة، تظهر فجوة بحثية واضحة في الجمع بين الدقة العالية والكفاءة الزمنية مع مرونة التكيف مع الظروف البيئية المتنوعة. فالدراسة الأولى التي تعتمد على تحليل الفيديو عبر خوارزميات تقليدية مثل Viola-Jones ومرشحات Gabor تواجه تحديات في التعامل مع الإضاءة غير المثلى والتفاصيل الدقيقة في الحركات، مما يحد من قدرتها على التعميم في بيئات حقيقية. من ناحية أخرى، الدراسة الثانية التي تستند إلى تحليل الهيكل العظمي عبر نموذج YOLO-Pose مع نماذج التعلم الآلي (مثل XGBoost وAc-LSTM) تحقق دقة مرتفعة، لكنها تقتصر إلى الكفاءة في معالجة الإطارات بسرعة كافية للتطبيقات الفورية، كما تواجه صعوبة في تمييز السلوكيات الطبيعية المعقدة (كالتفكير العميق) عن محاولات الغش. أما المشروع المرفق في الملف، الذي يجمع بين استخدام تقنيات الكشف بالفيديو (YOLO) وتقدير الوضعيات (Pose Estimation) مع أدوات معالجة الصور (OpenCV)، فيقدم نهجاً متكاملاً يركز على الشبكات العصبية العميقة لتحسين دقة الكشف، لكنه لا يعالج بشكل كافٍ التحديات المتعلقة بتقلبات الإضاءة أو زوايا التصوير المختلفة، والتي تُعدّ عائقاً رئيسياً في البيئات التعليمية المتنوعة. وهكذا، تظل الحاجة ملحة لتطوير أنظمة تجمع بين الاعتماد على نماذج تعلم عميق متقدمة (مثل GCN أو النماذج التفرعية) وتحسينات هندسية في جمع البيانات (كزيادة دقة الكاميرات أو دمج مستشعرات متعددة) لسد الفجوة بين الأداء المختبري والتطبيق العملي.

الفصل الثاني: الأسس التقنية والنظرية

1-2 معالجة الصور الرقمية

تُمثل الصورة الرقمية كشبكة من النقاط الصغيرة المسمى بكسلات، حيث يحمل كل بكسل معلومات عن اللون والسطوع في موقع محدد. يتكون كل بكسل من ثلاث قيم تُعبر عن الألوان الأساسية: الأحمر (Red)، الأخضر (Green)، والأزرق (Blue)، وتتراوح كل قيمة بين 0 (غياب اللون) و255 (أقصى شدة). على سبيل المثال، ينتج اللون الأبيض عند دمج القيم القصوى لجميع الألوان (255, 255, 255). بينما يُمثل اللون الأخضر النقي بقيم (0, 255, 0) [8].



الشكل 1-2: جزء من الصورة الرقمية.


يظهر الشكل (1-2) شبكة ثنائية الأبعاد (Grid System) تمثل البكسلات في الصورة، مع تحديد مواقعها عبر نظام إحداثيات (Coordinates) يعتمد على محورين: x-axis (الأفقي) و y-axis (الرأسي). لكل بكسل مكان محدد (مثل: البكسل في الموقع (1, 1) له لون أصفر بقيم RGB = (255, 255, 0))، بينما يظهر البكسل الأزرق في الموقع (2, 5) بقيم (51, 51, 255). توضح الأسهم في

الشكل كيفية ربط الإحداثيات بالقيم اللونية، مما يسهل فهم كيف تُخزَّن وتُحلَّل البيانات البصرية رقمياً. هذا التمثيل أساسي في تقنيات مثل كشف الغش عبر تحليل حركة الطلاب أو الكائنات في الفيديو، حيث تعتمد الخوارزميات على تغييرات الألوان والسطوع لتحديد السلوكيات المشبوهة.

2-2 الذكاء الاصطناعي: من التعلم الآلي إلى التعلم العميق

2-2-1 التعلم الآلي (ML) مقابل التعلم العميق (DL)


في رحلة البحث عن أنظمة ذكية للكشف عن الغش في قاعات الامتحانات، تبرز أهمية فهم الفروق الجوهرية بين التعلم الآلي التقليدي والتعلم العميق، وكيفية توظيف كل منهما في حل المشكلات البصرية المعقدة. يُعرّف التعلم الآلي بأنه مجموعة من الخوارزميات التي تتعلم من البيانات لاتخاذ قرارات أو توقعات دون برمجة صريحة، حيث يعتمد على ميزات مُصمَّمة يدوياً مثل الحواف أو الأشكال الهندسية لتحليل الصور [9].



الشكل 2-2: كيفية عمل التعلم الآلي (Machine Learning).

على سبيل المثال، قد تستخدم خوارزمية مثل SVM (آلة المتجهات الداعمة) ميزات محددة مسبقًا لتمييز حركة اليدين أو اتجاه الرأس في الفيديو، لكنها غالبًا ما تفشل في فهم السياقات الدقيقة، كتمييز حركة طبيعية كتحريك اليد لمسح العرق عن حركة مشبوهة كمحاولة تمرير ورقة. هنا تكمن قيود التعلم الآلي: اعتماده على التدخل البشري في اختيار الميزات، وعدم قدرته على التعامل مع التعقيدات البصرية التي تتطلب تحليل تفاصيل دقيقة أو تغيرات سريعة في الإضاءة أو الزوايا.

من ناحية أخرى، يُعتبر التعلم العميق تطورًا طبيعيًا للتعلم الآلي، حيث يعتمد على شبكات عصبية متعددة الطبقات قادرة على استخراج الميزات تلقائيًا من البيانات الخام دون الحاجة إلى تعريفها مسبقًا. في تطبيقات مثل نظام الكشف عن الغش، تُدرَّب الشبكات العصبية (مثل YOLO أو CNN) على آلاف الساعات من مقاطع الفيديو لتحليل كل بكسل في الصورة، بدءًا من اكتشاف الحواف البسيطة في الطبقات الأولى، وصولًا إلى تمييز أنماط معقدة مثل حركة العين نحو مصدر خارجي أو تفاعل الأيدي بين الطلاب [9].



الشكل 2-3: كيفية عمل التعلم العميق.

هذه القدرة على التعلم الذاتي تجعل النموذج أكثر مرونة في التعامل مع التحديات الواقعية، مثل تغير الإضاءة في قاعات الامتحانات أو اختلاف زوايا الكاميرات، مما يفسر تفوقه في دقة التصنيف مقارنة بالخوارزميات التقليدية.

لكن هذا لا يعني أن التعلم العميق خالٍ من العيوب. فبالرغم من دقته العالية، فإنه يحتاج إلى كميات هائلة من البيانات المُعلَّمة (مُصنَّفة) لتجنب التحيز في النتائج، كما يتطلب بنية تحتية حاسوبية قوية (مثل معالجات GPU) لتسريع عملية التدريب التي قد تستغرق أيامًا أو أسابيع. بالإضافة إلى ذلك، تبقى "مشكلة الصندوق الأسود" قائمة، حيث يصعب فهم الآلية الداخلية التي توصل بها النموذج إلى قراره، مما يحد من قابليته للشرح أو التعديل اليدوي.

في المقابل، يتميز التعلم الآلي التقليدي ببساطته وسرعته في المهام البسيطة، حيث لا يحتاج إلى موارد حاسوبية ضخمة، كما يسمح للمطورين بالتحكم في اختيار الميزات وتعديلها حسب الحاجة. لكنه يفقد فعاليته في المهام التي تتطلب فهمًا دقيقًا للسياق أو التعامل مع بيانات غير منتظمة، مثل مقاطع الفيديو عالية الدقة أو الصور ذات الخلفيات المعقدة [9].

في سياق مشروع الكشف عن الغش، يتجلى هذا الفرق بوضوح: بينما قد تفشل خوارزمية SVM في تمييز حركة طالب يرفع يده لطلب الإذن بالخروج عن حركة طالب آخر يحاول نقل إجابة، بسبب اعتمادها على قواعد ثابتة لا تتكيف مع التفاصيل الدقيقة، فإن شبكة عصبية عميقة مثل YOLO قادرة على تحليل حركة الهيكل العظمي للطلاب عبر الزمن، وتتبع التفاعلات بينهم بدقة، حتى في ظل وجود تشويش أو تغيرات في الإضاءة. هذا التفوق يعود إلى قدرة الشبكات العصبية على بناء "فهم هرمي"

للأنماط، حيث تتعلم كل طبقة ميزات أكثر تعقيداً من الطبقة السابقة، مما يجعلها أداة لا غنى عنها في التطبيقات الواقعية التي تتطلب معالجة بيانات بصرية في الوقت الفعلي.


ومع ذلك، لا يمكن إنكار أن التعلم العميق ليس الحل الأمثل لكل المهام. ففي المشاريع ذات الميزانيات المحدودة أو البيانات القليلة، قد يكون التعلم الآلي التقليدي أكثر عملية، خاصةً إذا كانت الميزات المطلوبة واضحة ومحددة مسبقاً. لكن في عالم اليوم، حيث تتوافر كميات هائلة من البيانات وتقنيات الحوسبة السحابية، أصبح التعلم العميق هو الخيار الأفضل لبناء أنظمة ذكية قادرة على التعامل مع التعقيدات البصرية والسلوكية.

2-3 الشبكات العصبية الاصطناعية (Neural Networks)

هي نماذج حاسوبية مستوحاة من بنية الدماغ البشري، صُممت لمحاكاة آلية عمل الخلايا العصبية في معالجة المعلومات واتخاذ القرارات. تتكون كل شبكة من وحدات صغيرة تُسمى الخلايا العصبية الاصطناعية، والتي تتصل ببعضها عبر روابط مُوزونة تحاكي التشابك العصبي في الكائنات الحية. تُعتبر هذه الشبكات العمود الفقري للتعلم العميق، حيث تُستخدم لحل مهام معقدة مثل التعرف على الصور أو تحليل اللغة الطبيعية أو التنبؤ بالبيانات [9].

في قلب الشبكة العصبية تكمن الطبقات (الشكل 2-4)، التي تُنظم في تسلسل هرمي: تبدأ بالطبقة المدخلة (Input Layer) التي تستقبل البيانات الأولية (مثل بكسلات الصورة أو موجات الصوت)، تليها سلسلة من الطبقات المخفية (Hidden Layers) التي تعالج البيانات عبر عمليات رياضية معقدة. كل خلية عصبية في هذه الطبقات تأخذ مدخلات من الخلايا السابقة، تُطبق عليها دالة تنشيط (Activation

Function) مثل ReLU أو Sigmoid لتحديد ما إذا كانت ستُمرر الإشارة إلى الطبقة التالية، مما يسمح للشبكة بتعلم أنماط غير خطية. تنتهي الشبكة بالطبقة المخرجة (Output Layer) التي تُنتج النتيجة النهائية، مثل تصنيف صورة إلى "غش" أو "لا غش" في أنظمة المراقبة.



الشكل 4-2: طبقات الشبكة العصبية الاصطناعية.

تتنوع أنواع الشبكات العصبية حسب طبيعة المهام: ففي مجال الرؤية الحاسوبية، تُستخدم الشبكات العصبية الترشيحية (CNNs) التي تعتمد على مرشحات (Filters) لاكتشاف الحواف والأنماط في الصور، مما يجعلها مثالية لمشاريع مثل كشف حركة الطلاب في الفيديو. بينما تُستخدم الشبكات العصبية المتكررة (RNNs) في معالجة البيانات المتسلسلة (كالكلام أو مقاطع الفيديو الطويلة)، حيث تحتفظ بذاكرة قصيرة المدى لفهم السياق الزمني. من الأمثلة المتقدمة أيضًا الشبكات العصبية التوليدية (GANs)، التي تتنافس فيها شبكتان لإنشاء بيانات جديدة (كصور واقعية) أو تحسين دقة النماذج. في تطبيقات الحياة الواقعية، تُعتبر الشبكات العصبية أساسًا لأنظمة مثل التعرف على الوجوه (التي تُستخدم في فتح الهواتف)، أو تحليل المشاعر في منصات التواصل الاجتماعي، أو حتى تشخيص الأمراض.

عبر تحليل الصور الطبية. في سياق مشروع كشف الغش، تعتمد الشبكات العصبية (مثل YOLO أو Pose Estimation) على تحليل حركة الهيكل العظمي للطلاب عبر الزمن، حيث تتعلم تلقائيًا ميزات مثل اتجاه الرأس أو تفاعلات الأيدي، وتُصنفها بناءً على أنماط مُدرّبة مسبقًا.

رغم قوتها، تواجه الشبكات العصبية تحديات مثل الحاجة إلى كميات هائلة من البيانات المُعلّمة لتجنب التحيز، أو استهلاكها الكبير لموارد الحوسبة (خاصة في النماذج الكبيرة). لكن مع تطور الأجهزة (كالمعالجات الرسومية GPUs) وتقنيات التدريب المُحسّنة، أصبحت هذه النماذج أداة لا غنى عنها في بناء أنظمة ذكية قادرة على فهم التعقيدات البصرية والسلوكية بدقة تفوق قدرات البشر في بعض الحالات.

2-3-1 الشبكات العصبية الترشيحية (CNNs)

2-3-1-1 تعريف الشبكات العصبية الترشيحية


الشبكات العصبية الترشيحية، أو ما تُعرف اختصارًا بـ CNNs، هي نوع متخصص من الشبكات العصبية الاصطناعية صُممت لمعالجة البيانات ذات البنية الشبكية، مثل الصور أو الإشارات الثنائية الأبعاد. تعتمد فكرتها الأساسية على محاكاة آلية عمل النظام البصري في الكائنات الحية، حيث تستخدم طبقاتٍ متتالية من المرشحات (أو النواقل) لتحليل المدخلات عبر اكتشاف أنماط محددة، كحواف الأشكال أو التفاصيل النسيجية. تتميز هذه الشبكات بقدرتها على تعلم واستخراج السمات المهمة من البيانات تلقائيًا، دون الحاجة إلى برمجة صريحة لتحديد هذه السمات مسبقًا. تُنظّم طبقاتها في هيكل هرمي، حيث تُعالج الطبقات الأولى تفاصيل بسيطة (مثل الخطوط)، بينما تتولى الطبقات الأعمق دمج هذه التفاصيل لتكوين تمثيلات معقدة للعناصر داخل البيانات. يعتمد أداؤها على عملية الترشيح التي تُطبّق عبر نوافذ صغيرة

تتحرك على كامل المدخلات، مما يسمح بالتعرف على الأنماط بغض النظر عن موقعها أو اتجاهها. هذه الخصائص جعلت منها أداة فعالة في التعامل مع البيانات عالية الأبعاد، مع الحفاظ على كفاءة الحساب وخفض العبء التخزيني مقارنةً بالشبكات العصبية التقليدية.

2-1-3-2 كيف تعمل الشبكات العصبية الترشيحية؟

تتميز الشبكات العصبية الترشيحية عن الشبكات العصبية الأخرى بأدائها الفائق في معالجة المدخلات من الصور أو الكلام أو الإشارات الصوتية. تحتوي على ثلاثة أنواع رئيسية من الطبقات، هي [10]:

- الطبقة الترشيحية
- طبقة التجميع
- الطبقة المتصلة بالكامل (FC)




الشكل 2-5: مراحل الشبكة العصبية الترشيحية.

الطبقة الترشيحية هي الطبقة الأولى في الشبكة الترشيحية. بينما يمكن أن تتبعها طبقات ترشيحية إضافية أو طبقات تجميع، تكون الطبقة المتصلة بالكامل هي الطبقة النهائية. مع كل طبقة، تزداد تعقيدًا في

الشبكة العصبية الترشيحية، حيث تحدد أجزاءً أكبر من الصورة. تركز الطبقات المبكرة على ميزات بسيطة، مثل الألوان والحواف. ومع تقدم بيانات الصورة عبر طبقات الشبكة العصبية الترشيحية، تبدأ في التعرف على عناصر أو أشكال أكبر للعنصر حتى تتعرف أخيراً على الكائن المقصود [10].

• الطبقة الترشيحية:

الطبقة الترشيحية هي الوحدة الأساسية في الشبكات العصبية الترشيحية (CNN)، حيث تحدث معظم العمليات الحسابية فيها. تتكون من ثلاثة عناصر رئيسية: المدخلات (مثل صورة ملونة ممثلة بمصفوفة ثلاثية الأبعاد للطول والعرض والعمق، والذي يتوافق مع قيم الألوان RGB)، والمرشح (أو كاشف الميزات)، وخريطة الميزات الناتجة [10].



الشكل 6-2: عملية الترشيح.

المرشح عبارة عن مصفوفة ثنائية الأبعاد من الأوزان، تمثل جزءًا من الصورة. يتحرك هذا المرشح فوق مناطق متداخلة من الصورة (تُسمى حقول الاستقبال)، ويُجري عملية ترشيح (التفاف) عن طريق حساب حاصل الضرب النقطي بين وحدات البكسل في المنطقة المحددة وقيم المرشح. بعد كل عملية، ينتقل المرشح بمقدار خطوة (stride) محددة، ويكرر العملية حتى يغطي كامل الصورة. الناتج النهائي لهذه العمليات المتكررة هو خريطة الميزات، التي تُظهر مدى تطابق أجزاء الصورة مع النمط الذي يبحث عنه المرشح.

تبقى أوزان المرشح ثابتة أثناء حركته، لكنها قد تُعدّل لاحقًا أثناء تدريب الشبكة عبر خوارزميات مثل الانتشار العكسي. هناك ثلاث معلمات اختيارية تُحدد قبل التدريب وتؤثر على حجم الخرج:

1. **Number of Filters**: كل مرشح يُنتج خريطة ميزات منفصلة، مما يزيد عمق الخرج.


2. **Strid**: المسافة التي يتحركها المرشح في كل مرة. كلما زادت الخطوة، قل حجم الخرج.

3. **Zero-Padding**: يُستخدم عندما لا يتناسب حجم المرشح مع الصورة. أنواعه:

a. **Valid Padding**: لا يُضيف أصفارًا، وقد يُقلص حجم الخرج.

b. **Same Padding**: يُحافظ على حجم الخرج مساويًا لحجم المدخلات.

c. **Full Padding**: يُزيد حجم الخرج بإضافة أصفار حول حواف الصورة.




الشكل 7-2: الفرق بين أنواع الـ Padding الثلاث.

بعد كل عملية ترشيح، تُطبَّق دالة ReLU (وحدة الخطية المستقيمة) على خريطة الميزات لإضافة عدم الخطية إلى النموذج، مما يساعده على تعلم أنماط معقدة.

• طبقة ترشيحية إضافية:

كما ذكرنا سابقاً، يمكن أن تتبع طبقة ترشيحية أخرى الطبقة الترشيحية الأولى. عند حدوث ذلك، تصبح هيكلية الشبكة العصبية الترشيحية (CNN) هرمية، حيث تتمكن الطبقات اللاحقة من "رؤية" البكسلات ضمن حقول الاستقبال في الطبقات السابقة. على سبيل المثال، لنفترض أننا نحاول تحديد ما إذا كانت صورة تحتوي على دراجة هوائية. يمكن اعتبار الدراجة مجموع أجزاء: هيكلها، المقود، العجلات، الدواسات، وهكذا. كل جزء من هذه الأجزاء يُشكّل نمطاً بسيطاً (منخفض المستوى) في الشبكة العصبية، بينما يُمثّل تجميع هذه الأجزاء معاً نمطاً معقداً (عالي المستوى)، مما يُنشئ تسلسلاً هرمياً للميزات داخل الشبكة. في النهاية، تُحوّل الطبقة الترشيحية الصورة إلى قيم رقمية، مما يسمح للشبكة العصبية بفهم واستخراج الأنماط ذات الصلة [10].



الشكل 8-2: الهيكلية الهرمية لعمل المرشحات الإضافية.


• التجميع:

تُعرف طبقات التجميع (أو التصغير) بتقليل الأبعاد وعدد المعلومات في المدخلات. مشابهة للطبقة الترشيحية، حيث تمرر عملية التجميع مرشحًا (فلتر) على كامل الصورة المدخلة، لكن الاختلاف هو أن هذا المرشح لا يحتوي على أوزان. بدلاً من ذلك، يطبق المرشح دالة تجميع على القيم داخل المنطقة المحددة من الصورة، ويملأ المصفوفة الناتجة. هناك نوعان رئيسيان من التجميع [10]:

a. **التجميع الأقصى (Max pooling):** عند تحرك المرشح فوق الصورة، يختار القيمة العظمى (الأكبر) ضمن المنطقة المحددة لإرسالها إلى المصفوفة الناتجة. تُستخدم هذه الطريقة بشكل أكثر شيوعًا.

b. **التجميع المتوسط (Average pooling):** يحسب المرشح القيمة المتوسطة للبكسلات داخل المنطقة المحددة لإرسالها إلى المصفوفة الناتجة.

على الرغم من فقدان بعض المعلومات في طبقة التجميع، إلا أنها تساعد في تقليل التعقيد، وتحسين الكفاءة، وتقليل خطر الـ (overfitting).



الشكل 9-2: الفرق بين Max Pooling و Average Pooling.

• الطبقة المتصلة بالكامل:

اسم هذه الطبقة يصف وظيفتها بدقة. كما ذكر سابقاً، في الطبقات المتصلة جزئياً (مثل الترشيحية أو التجميع)، لا تتصل قيم البكسلات في الصورة المدخلة مباشرة بطبقة الإخراج. أما في الطبقة المتصلة بالكامل، فإن كل عقدة في طبقة الإخراج تتصل بشكل مباشر بكل العقدة في الطبقة السابقة [10].

تُنفَّذ هذه الطبقة مهمة تصنيف البيانات بناءً على الميزات التي تم استخراجها عبر الطبقات السابقة ومرشحاتها المختلفة. بينما تستخدم الطبقات الترشيحية والتجميع عادةً دالة التنشيط ReLU، فإن الطبقات

المتصلة بالكامل تعتمد غالباً دالة التنشيط SoftMax لتصنيف المدخلات بشكل دقيق، مما يُنتج احتمالية (قيمة بين 0 و 1) لانتماء البيانات إلى فئة محددة.

2-3-1-3 أنواع الشبكات العصبية الترشيحية


وضع الباحثان كونييهيكو فوكوشما ويان لُكن الأسس البحثية للشبكات العصبية الترشيحية من خلال أعمالهما في عام 1980، وورقة بحثية مشهورة بعنوان "الانتشار العكسي مُطبق على تمييز الرموز البريدية المكتوبة بخط اليد" عام 1989. بشكل أكثر شهرةً، نجح يان لُكن في تطبيق الانتشار العكسي لتدريب الشبكات العصبية على التعرف على الأنماط في سلسلة من الرموز البريدية المكتوبة بخط اليد. استمر في أبحاثه مع فريقه خلال تسعينيات القرن الماضي، لتُتوج جهودهم بتطوير "LeNet-5"، الذي طبق المبادئ ذاتها على تمييز المستندات [10].

منذ ذلك الحين، ظهرت العديد من هياكل الشبكات العصبية الترشيحية المتنوعة مع ظهور مجموعات بيانات جديدة (مثل MNIST و CIFAR-10) ومسابقات مثل تحدي التعرف البصري واسع النطاق لـ ImageNet (ILSVRC). ومن أبرز هذه الهياكل:

- AlexNet
- VGGNet
- GoogLeNet
- ResNet
- ZFNet

2-4 كشف الكائنات (Object Detection)

اكتشاف الأشياء هو قدرة أساسية في الرؤية الحاسوبية تُحدد وتُحدد مواقع الأشياء داخل صورة أو فيديو. على عكس تصنيف الصور، لا يقتصر اكتشاف الأشياء على تصنيف الأشياء فحسب، بل يُحدد موقعها أيضًا برسم صندوق محيط حول كل كائن. تستخدم نماذج اكتشاف الأشياء، مثل R-CNN و-Fast R-CNN و-Faster R-CNN و-YOLO، الشبكات العصبية الترشيحية (CNNs) لتصنيف الأشياء، وشبكات الانحدار للتنبؤ الدقيق بإحداثيات الصندوق المحيط لكل كائن مكتشف [11].



الشكل 10-2: كشف الكائنات.

2-4-1 تصنيف الصور (Image Classification)

تصنيف الصور هو مهمة أساسية في الرؤية الحاسوبية. عند إدخال صورة، يهدف نموذج التصنيف إلى إسنادها إلى واحدة من مجموعة محددة مسبقًا من الفئات. تعتمد معظم نماذج التصنيف على الشبكات

العصبية الترشيحية (CNNs)، المصممة خصيصًا لمعالجة بيانات البكسلات والاستحواذ على الميزات المكانية. تُدرب هذه النماذج على مجموعات بيانات ضخمة (مثل ImageNet) وتستطيع تصنيف الصور إلى 1000 فئة، مثل لوحة المفاتيح والفأرة والقلم وأنواع عديدة من الحيوانات [10].

2-4-2 تحديد موقع الكائن (Object Localization)


تحديد موقع الكائن هو مهمة أخرى مهمة في الرؤية الحاسوبية، تُحدد موقع الكائن داخل الصورة. يُضيف هذا التصنيف إلى نموذج التصنيف العادي جزءًا انحداريًا (regression head) للتنبؤ بإحداثيات الصندوق المحيط بالكائن. يُمثل الصندوق المحيط عادةً بأربع إحداثيات تُحدد موقعه وحجمه. يُعتبر تحديد الموقع خطوة أساسية في اكتشاف الأشياء، حيث الهدف ليس فقط تصنيف الكائن الرئيسي في الصورة، بل أيضًا تحديد موقعه بدقة [10].

2-4-3 خوارزمية YOLO لكشف الكائنات

YOLO (اختصارًا لـ You Only Look Once) هو خوارزمية شهيرة للكشف الفوري عن الأشياء. يدمج YOLO عملية كانت تُنفَّذ سابقًا عبر خطوات متعددة، باستخدام شبكة عصبية واحدة لتصنيف الأشياء والتنبؤ بالصناديق المحيطة بها (Bounding Boxes) في آنٍ واحد. وبذلك، يُحسّن النظام بشكل كبير لأداء الكشف، ويصبح قادرًا على العمل بسرعة أكبر بكثير مقارنة باستخدام شبكتين عصبيتين منفصلتين (واحدة للكشف وأخرى للتصنيف). ويتحقق هذا عبر إعادة استخدام مُصنِّفات الصور التقليدية لتناسب مهمة الانحدار (Regression) الخاصة بتحديد الصناديق المحيطة بالأشياء [11].

2-3-4-1 كيفية عمل خوارزمية YOLO

يعتمد YOLO على فكرة تقسيم الصورة إلى أجزاء صغيرة. تُقسّم الصورة إلى شبكة مربعة بقياس $S \times S$ ، كما يلي [11]:




$S \times S$ grid on input

الشكل 11-2: تقسيم الصورة إلى خلايا.

الخلية التي يقع فيها مركز الكائن (مثل مركز كلب في الصورة) هي المسؤولة عن اكتشاف ذلك الكائن. كل خلية تنتبأ بـ B صندوق محيط (Bounding Boxes) ودرجة ثقة لكل صندوق. الإعداد الافتراضي للنظام هو توقع صندوقين محيطين. تُقاس درجة التصنيف (Classification Score) من 0.0 إلى 1.0، حيث 0.0 تعني عدم وجود كائن، و1.0 تعني يقيناً تاماً بالنتيجة. هذه الدرجات تعكس ثقة النموذج في وجود كائن داخل الخلية ودقة الصندوق المحيط.

يتكون كل صندوق محيط من 5 قيم:


- x, y : إحداثيات مركز الصندوق المحيط.
- العرض (w) والارتفاع (h): مقاسان كنسب من حجم الصورة الإجمالي.
- درجة الثقة: تمثل التداخل النسبي (IOU) بين الصندوق المتنبأ به والصندوق الحقيقي (Ground Truth Box). التداخل النسبي (IOU) يُحسب كمساحة التداخل بين الصندوقين (المتنبأ والفعلي) مقسومة على مساحة الاتحاد بينهما. تكون النتيجة بين 0 (لا تداخل) و1 (تداخل كامل). كلما زادت القيمة، كان التنبؤ أكثر دقة.



الشكل 12-2: مثال على IOU: المنطقة الخضراء (التداخل) مقسومة على المنطقة البنفسجية (الاتحاد).

بالإضافة إلى الصناديق ودرجات الثقة، تنتبأ كل خلية بفئة الكائن (Class) عبر متجه one-hot بطول C (عدد الفئات في البيانات). مع ذلك، تجدر الإشارة إلى أن كل خلية تنتبأ بفئة واحدة فقط، حتى لو

احتوت على كائنات من فئات مختلفة. هذا يُعتبر قيودًا في YOLO، حيث قد يفشل في تصنيف كائنات متعددة في خلية واحدة.



الشكل 13-2: النتيجة النهائية للكشف باستخدام YOLO.

2-3-4-2 مقاييس تقييم نموذج YOLO

في سياق تطوير أنظمة الذكاء الاصطناعي مثل YOLO (You Only Look Once) للكشف عن الأحداث في الفيديو (كالغش في الامتحانات)، تبرز أهمية فهم المقاييس الأساسية التي تُقيّم دقة النموذج، مثل الاسترجاع (Recall) والنتائج الإيجابية الحقيقية (TP) والنتائج الإيجابية الكاذبة (FP) والنتائج السلبية الحقيقية (TN) والنتائج السلبية الكاذبة (FN). تُعرّف النتيجة الإيجابية الحقيقية (TP) عندما يُصنف النموذج حدثًا ما بشكل صحيح على أنه إيجابي (مثل اكتشاف حركة مشبوهة لطالب أثناء الامتحان)، بينما تُشير النتيجة الإيجابية الكاذبة (FP) إلى حالات التصنيف الخاطئ لحدث طبيعي على أنه إيجابي (مثل اعتبار تحريك اليد لتعديل النظارة "غشًا"). من ناحية أخرى، النتيجة السلبية الحقيقية

(TN) تحدث عندما يتجاهل النظام الأحداث الطبيعية بشكل صحيح (كعدم وجود حركة مشبوهة)، بينما النتيجة السلبية الكاذبة (FN) تعكس فشل النظام في اكتشاف حدث إيجابي حقيقي (كعدم اكتشاف طالب ينقل إجابة من زميله) [11].

CONFUSION MATRICES, EXPLAINED

		Actual	
		CAT	NOT CAT
Predicted	CAT		
	NOT CAT		

الشكل 14-2: توضيح مصفوفة التشويش.


في خوارزمية YOLO، التي تُستخدم للكشف عن الأشياء في الوقت الفعلي عبر تقسيم الصورة إلى شبكة من الخلايا وتوقع مربعات إحاطة (Bounding Boxes) مع احتمالات التصنيف، تتأثر هذه المقاييس بشكل مباشر بتصميم النموذج وعتبة الثقة (Confidence Threshold) المحددة. على سبيل المثال، إذا خفض المطورون عتبة الثقة لزيادة عدد التوقعات، فقد يرتفع عدد النتائج الإيجابية الكاذبة (FP) بسبب تصنيف حركات غير ضارة كغش، بينما رفع العتبة قد يؤدي إلى زيادة النتائج السلبية

الكاذبة (FN) بسبب إهمال حالات غش حقيقية. هنا يأتي دور معدل الاسترجاع (Recall)، الذي يُعرّف على أنه نسبة النتائج الإيجابية الحقيقية (TP) إلى مجموع النتائج الإيجابية الحقيقية (TP) والنتائج السلبية الكاذبة (FN):

$$Recall = \frac{TP}{TP + FN}$$

يُعتبر الاسترجاع مقياسًا حاسمًا في تطبيقات مثل كشف الغش، حيث يُعد اكتشاف جميع الحالات المشبوهة (خفض FN) أكثر أهمية من تقليل الأخطاء الإيجابية الكاذبة (FP)، لأن إهمال حالة غش واحدة قد تكون لها عواقب أخطر من الإنذارات الكاذبة [11].

في مشروع مثل نظام كشف الغش باستخدام YOLO، حيث تُحلل مقاطع الفيديو لاكتشاف التفاعلات بين الطلاب أو استخدام الهواتف، يلعب الاسترجاع دورًا مركزيًا في ضمان شمولية النظام. ففي حالة ارتفاع FN (كفشل اكتشاف طالب يستخدم هاتفًا مخفيًا)، قد يفقد النظام مصداقيته، بينما ارتفاع FP (كتصنيف حركة طبيعية كغش) قد يسبب إزعاجًا للمراقبين، لكنه أقل خطورة من تجاهل الغش الفعلي. لتحقيق توازن بين هذه المقاييس، يعتمد مطورو YOLO على تحسين بنية الشبكة العصبية (مثل زيادة عمق الطبقات أو استخدام أنكير بوكسز Anchor Boxes لتناسب أحجام الأشياء المختلفة) وضبط عتبات الثقة عبر تقنيات مثل Non-Maximum Suppression (NMS) لتقليل التداخل بين التوقعات. بالإضافة إلى ذلك، تُستخدم تقنيات زيادة البيانات (Data Augmentation) لتدريب النموذج على سيناريوهات متنوعة (كالإضاءة الضعيفة أو الحركات السريعة)، مما يعزز قدرته على تمييز TP من FP و FN.



الشكل 15-2: تقنية NMS.

من الناحية العملية، يُقاس أداء YOLO عبر مصفوفة التشويش (Confusion Matrix)، التي تربط بين التوقعات الفعلية والنتائج المُصنَّفة، مما يسمح بحساب مقاييس مثل الاسترجاع والدقة (Precision). في سياق كشف الغش، قد يُضطر المطورون إلى تفضيل نماذج ذات استرجاع عالي حتى لو انخفضت الدقة، لأن أولوية النظام هي اكتشاف أكبر عدد ممكن من الحالات المشبوهة، حتى لو تطلب ذلك تحمل بعض الإنذارات الكاذبة. على سبيل المثال، إذا بلغ عدد TP 120 حالة، و FN 30 حالة، فإن Recall:

$$Recall = \frac{120}{120 + 30} = 80\%$$


مما يعني أن النظام اكتشف 80% من حالات الغش الفعلية. لتحقيق هذه النسبة، قد يُدمج YOLO مع تقنيات أخرى مثل تحليل الهيكل العظمي (Pose Estimation) لتعزيز دقة استخراج الميزات، أو استخدام شبكات عصبية متكررة (RNNs) لفهم السياق الزمني للحركات عبر الإطارات المتتالية، مما يقلل من FN عبر تتبع الأنماط السلوكية على المدى الطويل [11].

YOLO – Pose 3-3-4-2

تُعد تقنية YOLO-Pose امتدادًا لتقنية YOLO الشهيرة في التعرف على الأجسام، لكنها تركز بشكل خاص على تقدير وضعيات الأجسام، أي تحديد مواقع النقاط الرئيسية في جسم الإنسان مثل الرأس، اليدين، المرفقين، الركبتين، والكاحلين. وبدلاً من الاكتفاء بتحديد إطار يحوي الجسم، تعمل هذه التقنية على تحليل التفاصيل الدقيقة لحركة وتوزيع المفاصل، مما يجعلها مثالية لتطبيقات تتطلب فهماً دقيقاً لوضعية الجسم، مثل التمارين الرياضية، الرعاية الصحية، والألعاب التفاعلية [11].

يعتمد YOLO-Pose على مبدأ التنبؤ الفوري، إذ تقوم الشبكة العصبية بمعالجة الصورة دفعة واحدة لتحديد مواضع النقاط الرئيسية بدقة عالية وفي وقت قصير، مما يمنحه ميزة واضحة في الأداء مقارنةً بالنماذج التقليدية التي كانت تعتمد على مراحل متعددة لاستخلاص هذه المعلومات. يُستخدم في هذه التقنية بنية شبكية متقدمة تسمح لها بالتعامل مع الصور المعقدة والخلفيات المزدحمة دون التأثير على جودة النتائج، وذلك بفضل قدرتها على استخلاص الخصائص البصرية الهامة وتمييز الأجزاء المختلفة من الجسم حتى في أوضاع غير اعتيادية [11].

وقد ساهم إدماج YOLO-Pose في العديد من الأنظمة الذكية في تحسين التفاعل بين الإنسان والآلة، مثل مراقبة الأنشطة الحركية، وتقييم الأداء البدني، وحتى دعم الأبحاث الطبية المتعلقة بتحليل الحركة. كما أنها تُستخدم في أنظمة الأمان للتعرف على وضعيات الأشخاص في المشاهد الحساسة، مثل السقوط أو الحركات غير الطبيعية التي قد تدل على خطر [11].




الشكل 16-2: تقنية YOLO-Pose.

تتسم هذه التقنية أيضًا بمرونتها في التكيف مع البيانات المختلفة، سواء كانت في الداخل أو الخارج، ومع اختلاف ظروف الإضاءة وزوايا التصوير، مما يعزز من اعتماديتها في التطبيقات الواقعية. وبفضل سرعة المعالجة التي تتميز بها، فإنها تُعد خيارًا مثاليًا للأنظمة التي تتطلب استجابات فورية [11].

الفصل الثالث : تقدير الوضعيّات

3-1 مفهوم تقدير الوضعيات (Pose Estimation)

تقنية تقدير الوضعيات (Pose Estimation) تُعدّ من أبرز تطبيقات الذكاء الاصطناعي في مجال تحليل الصور والفيديو، حيث تهدف إلى استنتاج المواقع الدقيقة للنقاط المفصلية على جسم الإنسان من خلال صورة أو مقطع مرئي. تعتمد هذه التقنية على نماذج متقدمة من الشبكات العصبية التي تُمكن الحاسوب من "رؤية" الأشخاص في المشاهد الرقمية والتعرف على أوضاعهم الجسدية، مثل الوقوف، الجلوس، أو رفع اليد، من خلال تتبع نقاط محددة تمثل المفاصل والمناطق الرئيسية في الهيكل العظمي. لا تكتفي خوارزميات التقدير بتحديد وجود الأشخاص، بل تميز أيضًا بين أجزاء أجسامهم وتحدد مواضعها بدقة ضمن الإطار البصري، وهو ما يسمح بفهم الشكل الهندسي العام للجسم في لحظة معينة [12].



الشكل 3-1: تقنية Pose Estimation.

يرتكز عمل هذه التقنية على مراحل متسلسلة تبدأ برصد الشخص في المشهد، ثم استخراج المعالم البارزة باستخدام نموذج مدرب على مجموعات بيانات ضخمة تحتوي على صور لأشخاص بأوضاع مختلفة. بعد ذلك، تُحلل هذه المعالم لتحديد الإحداثيات الثنائية أو الثلاثية الأبعاد للنقاط المفصلية، مثل الكتفين، المرفقين، الركبتين، والقدمين، مما يمنح النموذج القدرة على تمثيل وضعية الجسم بدقة في الفضاء. تُصمم هذه النماذج لتكون قادرة على التعامل مع التغيرات في الإضاءة، الملابس، الخلفيات، وزوايا التصوير، وهو ما يعزز مرونتها وموثوقيتها في البيئات الواقعية [12].

تختلف منهجيات التقدير بين النماذج التي تُقدّر النقاط لجسم واحد فقط في كل إطار، وتلك التي تدعم تحليل عدة أشخاص في المشهد ذاته، مع تزايد الحاجة لاستخدام خوارزميات فعالة لتتبع النقاط من إطار إلى آخر دون انقطاع أو أخطاء. كما تراعي النماذج الحديثة الخصائص الفسيولوجية للبشر، مثل أطوال الأطراف ونسب الجسم، لضمان أن تكون النتائج منطقية ومتناسقة مع التكوين البشري الطبيعي. تعتمد بعض الأساليب على البنية العظمية ضمن النموذج لتوليد تخمينات ذكية حتى في حالة تغطية أجزاء من الجسم أو ضعف الرؤية في جزء من الإطار [12].

تُطور نماذج التقدير باستخدام بيانات واقعية تشمل آلاف الوضعيات والسيناريوهات، ويتم تحسينها باستمرار لضمان دقة أعلى وسرعة أكبر في الاستجابة، خاصة في التطبيقات التي تتطلب تحليل الفيديو في الزمن الحقيقي. ومن الجدير بالذكر أن هذه التقنية لا تحتاج بالضرورة إلى معدات تصوير احترافية، إذ يمكن تطبيقها على فيديوهات من كاميرات تقليدية، مما يجعلها متاحة للاستخدام في نطاق واسع من الأنظمة الذكية. هذا التنوع في القدرة على فهم وتحليل حركات الإنسان من خلال الصور قد فتح المجال

لتطبيقات متعددة في مختلف القطاعات، ويعكس تطوراً مهماً في فهم الحاسوب للبيئة البشرية المحيطة به [12].

تمثل تقنية تقدير الوضعيات نقطة تحول في فهم العلاقة بين الإنسان والآلة، حيث مكّنت الحواسيب من تحليل حركات الإنسان بطريقة دقيقة وواقعية، دون الحاجة لأجهزة استشعار مادية أو تلامس مباشر. هذا الفهم العميق للحركة البشرية عبر الصور والفيديوهات فتح الباب أمام تطبيقات واسعة ومتنوعة، تخدم العديد من القطاعات وتسهم في تطوير حلول ذكية أكثر تكيفاً مع السلوك البشري الطبيعي. أهمية هذه التقنية لا تكمن فقط في قدرتها على قراءة الحركة، بل في مساهمتها الجوهرية في تحسين حياة الأفراد وكفاءة الأنظمة. تشمل أبرز مجالات الأهمية ما يلي:

- **مراقبة الحركة والسلوك:** تُستخدم في المدارس والجامعات لمراقبة التزام الطلبة، وفي المنشآت الأمنية لتحليل تحركات الأشخاص المشبوهين، كما تُوظف في تحليل أداء اللاعبين في الملاعب والمباريات.
- **التحكم بالإيماءات (Gesture Control):** تُعدّ أساساً لتطوير أنظمة تفاعل طبيعي مع الأجهزة الإلكترونية، مثل التحكم في الشاشات أو الأجهزة المنزلية عبر حركة اليد أو الجسم دون لمس مباشر.
- **التأهيل الطبي وتحسين الأداء الرياضي:** تساعد المعالجين الفيزيائيين والمدربين على تتبع وضعيات الجسم أثناء التمارين والعلاج الحركي، مما يسهل الكشف عن الأخطاء أو الإصابات المحتملة وتصحيحها بشكل لحظي.

- دعم أنظمة الذكاء الاصطناعي في كشف الغش: عبر مراقبة تفاصيل دقيقة في سلوك الأفراد، مثل التفات الرأس المتكرر أو حركة اليدين غير المعتادة، يمكن للنظام رصد الأنماط المشبوهة خلال الامتحانات أو الاختبارات الرقمية.
- تعزيز الواقع المعزز والافتراضي (AR/VR): تُستخدم هذه التقنية في تحسين تجارب المستخدم ضمن البيئات الافتراضية، من خلال تتبع دقيق لحركات الجسم وتحويلها إلى عناصر تفاعلية داخل النظام.
- تحسين تجربة المستخدم في الألعاب الذكية: تسمح بتطوير ألعاب تعتمد على الحركة الجسدية الكاملة، مما يعزز الجانب التفاعلي والترفيهي في الألعاب الرقمية.
- رصد حالات الطوارئ والسقوط لكبار السن: يمكن للنظام التعرف على السقوط أو الحركات غير الطبيعية في دور الرعاية أو المنازل الذكية، وبالتالي إطلاق تنبيه سريع لإنقاذ الشخص.
- تحليل بيانات الجمهور في الفعاليات: تُستخدم في تتبع تفاعل الجمهور مع عروض معينة في المؤتمرات أو المعارض، مما يساعد المنظمين على تقييم جودة التفاعل وتحسين المحتوى.
- التعرف على لغة الإشارة: تُسهم في تطوير أدوات تتيح التفاعل مع الصم والبكم من خلال تفسير إشارات اليد وتحويلها إلى نص أو صوت.

3-2 لمحة عن مكتبة MediaPipe

في سياق التطور السريع في تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، برزت مكتبة MediaPipe كأحدى الأدوات الرائدة التي طورتها شركة Google لتكون منصة مفتوحة المصدر تهدف إلى تسهيل

تطوير تطبيقات تعتمد على تحليل الفيديو والصور في الزمن الحقيقي. وتُعد MediaPipe خيارًا مثاليًا للباحثين والمطورين الذين يسعون إلى بناء أنظمة ذكية قادرة على فهم المشاهد المرئية وتحليلها بدقة، دون الحاجة إلى إعدادات معقدة أو موارد حسابية ضخمة، مما يجعلها أداة ذات قيمة عالية من حيث الكفاءة والمرونة وسهولة الاستخدام [12].



الشكل 2-3: مكتبة MediaPipe.

تم تصميم MediaPipe لتكون منصة متعددة الاستخدامات تدعم مجموعة واسعة من المهام المتعلقة بالرؤية الحاسوبية، مثل تتبع الكائنات، اكتشاف الوجوه، التعرف على الإيماءات، تحليل الحركة، تقسيم الخلفية، وأكثر من ذلك بكثير. أحد أبرز ما يميز هذه المكتبة هو أنها توفر نماذج مدربة مسبقًا تعتمد على تقنيات متقدمة في تعلم الآلة، ما يُمكن المستخدم من توظيف حلول جاهزة دون الحاجة إلى تدريب النماذج من الصفر. ويشمل ذلك كذلك إمكانية تخصيص النماذج أو إعادة تدريبها على بيانات جديدة وفقًا لاحتياجات كل تطبيق [12].

من الناحية التقنية، تعتمد MediaPipe على بنية مرنة تُعرف باسم graph-based architecture، والتي تُسهّل تنظيم العمليات التي تتم على البيانات المرئية داخل ما يُسمى بـ "graph" أو مخطط بياني. يتكون هذا المخطط من "عُقد" (Nodes) تمثل خطوات المعالجة، مثل إدخال الفيديو، الكشف عن

الكائنات، التحليل، والإخراج. تسمح هذه البنية للمستخدم ببناء مسارات معالجة دقيقة وقابلة للتعديل بسهولة، ما يتيح إمكانية دمج وحدات مختلفة من المعالجة البصرية في إطار زمني فعال [12].

إحدى نقاط القوة الجوهرية في MediaPipe هي قدرتها على العمل على عدة أنظمة أساسية، بما في ذلك Python لأنظمة سطح المكتب، وC++ للأداء العالي، بالإضافة إلى دعمها لتطبيقات الهواتف المحمولة على أنظمة Android وiOS. هذا التعدد في الدعم يفتح الباب أمام استخدام المكتبة في مجموعة كبيرة من المشاريع، بدءًا من تطبيقات الهواتف الذكية التفاعلية، مرورًا بأنظمة المراقبة الذكية، وصولًا إلى المشاريع الأكاديمية والبحثية المتقدمة. وقد صُممت المكتبة بحيث تستفيد من تسريع العتاد (hardware acceleration) عند توفره، مما يعزز من أدائها على الأجهزة ذات الموارد المحدودة مثل الهواتف والألواح الإلكترونية [12].

إلى جانب مرونتها وفعاليتها، تمتاز MediaPipe كذلك بكونها مدعومة بمجتمع نشط من المطورين، بالإضافة إلى توثيق رسمي شامل من Google. يتضمن هذا التوثيق شروحات مفصلة، وأمثلة عملية، وأدوات مساعدة تجعل من المكتبة بيئة تطوير متكاملة تُمكن حتى غير المختصين في مجالات الذكاء الاصطناعي من الدخول إلى هذا المجال وتطبيق الأفكار بسهولة. وتُعد هذه السهولة في الوصول نقطة تحول مهمة في تعميم تقنيات الرؤية الحاسوبية، حيث لم تعد هذه الأدوات حكرًا على الشركات أو المؤسسات البحثية الكبرى فقط، بل أصبحت في متناول الجميع، من طلاب الجامعات إلى رواد الأعمال والمطورين المستقلين [12].

من الناحية الأكاديمية والبحثية، ساهمت MediaPipe في تسريع الكثير من الدراسات والتجارب التطبيقية، إذ توفر واجهات برمجية مبسطة لمعالجة البيانات البصرية، مما يوفر وقتًا وجهدًا كان يُستهلك سابقًا في بناء خوارزميات معقدة من الصفر. كما أن قابليتها للدمج مع مكتبات أخرى مثل TensorFlow أو OpenCV يُعد من المزايا التكاملية التي تعزز من قيمتها كأداة تطويرية [12].

3-3 تقدير وضعيات الجسم باستخدام MediaPipe BlazePose


يُعد تقدير وضعيات الجسم أحد أبرز تطبيقات الذكاء الاصطناعي في تحليل الصور والفيديو، حيث يركّز هذا المجال على فهم موقع أجزاء الجسم البشري من خلال الصور الثابتة أو الفيديوهات المتحركة. وتعتمد هذه التقنية على تحليل المظهر العام للشخص داخل المشهد، واستخلاص ما يُعرف بالنقاط الأساسية أو المفصلية في الجسم، مثل الرأس، الرقبة، الكتفين، المرفقين، الرسغين، الوركين، الركبتين، والكاحلين. الهدف الأساسي من هذا التحليل هو بناء تصور رقمي لوضعية الجسم، بحيث يتمكن النظام من تتبع الحركة بدقة، وتحديد ما إذا كان الشخص واقفًا أو جالسًا أو يميل إلى أحد الجانبين، أو يرفع ذراعه، أو يدير رأسه إلى اليمين أو اليسار، وغيرها من السلوكيات المرتبطة بالوضع الجسدي [12].

تعتمد نماذج التقدير على شبكات عصبية مدربة على مجموعات ضخمة من البيانات التي تتضمن صورًا لأشخاص بوضعيات متنوعة، حيث تتعلم هذه النماذج التعرف على الأنماط البصرية الدقيقة التي تميز كل نقطة مفصلية. بمجرد التقاط صورة أو إطار من فيديو، يقوم النظام بتحليل الشكل العام للجسم داخل الإطار وتحديد مواضع هذه النقاط بدقة متناهية. ويتم تمثيل النتائج عادة على هيئة نموذج هيكلي رقمي

يظهر فوق الشخص في الصورة، ما يتيح مراقبة سلوكه أو تفاعله مع البيئة المحيطة بشكل لحظي أو عند المراجعة لاحقاً [12].

هذه القدرة على قراءة وضعيات الجسم ليست مقتصرة على تتبع الحركة فقط، بل تمتد لفهم السياق الكامل للنشاط الذي يقوم به الشخص، وهو ما يُمكن الأنظمة من رصد السلوكيات غير الاعتيادية، أو تحليل الأداء الحركي في مجالات مثل الرياضة والتعليم، وحتى الأمن. كما يُعد فهم وضعية الجسم مدخلاً أساسياً لتطبيقات أكثر تقدماً، مثل التعرف على الأنشطة اليومية، أو تحديد حالات الإرهاق، أو اكتشاف الإيماءات، وكل ذلك يتم دون الحاجة إلى أجهزة استشعار إضافية على الجسد، بل بالاعتماد فقط على صورة أو فيديو [12].

تُعد MediaPipe من أبرز مكتبات Google المتخصصة في بناء نماذج رؤية حاسوبية فعالة، وقد طورت نموذجاً متقدماً يُعرف باسم BlazePose، وهو مصمم خصيصاً لتقدير وضعيات الجسم بدقة عالية وفي الزمن الحقيقي. يتميز هذا النموذج بقدرته على تتبع 33 نقطة رئيسية موزعة على مختلف مناطق الجسم البشري، مما يوفر تمثيلاً تفصيلياً لوضعية الفرد وحركاته اللحظية. هذه الكثافة في تحديد النقاط تتيح إمكانية تفسير سلوكيات دقيقة أو غير اعتيادية، وهو ما يجعل BlazePose خياراً مثالياً لتطبيقات تتطلب مراقبة دقيقة مثل قاعات الامتحان، أو تتبع أداء الرياضيين، أو تحليل حركات الجسم في الوقت الفعلي ضمن بيئات تفاعلية [12].



الشكل 3-3: النقاط الرئيسية للجسم.


تمر عملية التقدير عبر عدة مراحل مترابطة تؤدي في مجموعها إلى استخلاص معلومات الوضعية من الصورة أو الفيديو المدخل، وتشمل هذه المراحل ما يلي:

- قراءة صورة أو فيديو من الكاميرا أو مصدر آخر.
- تحليل شكل الجسم داخل الإطار لتحديد معالمه العامة.
- استخراج الإحداثيات ثلاثية الأبعاد للنقاط المكتشفة على الجسم.
- استخدام هذه البيانات لتفسير الوضعية وتحليلها وفقاً للسياق المطلوب.

يسمح هذا الترتيب الدقيق في العمل لنموذج BlazePose بالتفاعل بسلاسة مع البيانات التي تتطلب استجابة لحظية، مما يعزز من كفاءته في مراقبة السلوك البشري بفعالية تعتمد على الذكاء الاصطناعي ومعالجة الصور [12].

3-4 تتبع اليدين باستخدام MediaPipe Hands


يُعد MediaPipe Hands من النماذج المتقدمة في مجال رؤية الحاسوب، حيث طورته شركة Google ليكون قادراً على تتبع اليد البشرية وتحليل حركتها بدقة في الوقت الحقيقي. يعتمد هذا النموذج على تقنيات الذكاء الاصطناعي لتحديد نقاط رئيسية على اليد، يصل عددها إلى 21 نقطة تشمل المفاصل وأطراف الأصابع والمعصم، مما يمكنه من فهم تفاصيل دقيقة لحركة اليد وشكلها. ما يميز هذا النموذج هو قدرته على العمل بكفاءة دون الحاجة إلى أجهزة معقدة، إذ يمكن تشغيله باستخدام كاميرات بسيطة، مثل تلك الموجودة في الحواسيب المحمولة أو الهواتف الذكية، مما يجعله قابلاً للتطبيق في مجالات متعددة كالتعليم، والواقع المعزز، والتفاعل مع الآلات، وحتى في البيئات التي تتطلب مراقبة سلوكيات معينة [12].



الشكل 3-4: النقاط الرئيسية لليدين.

يوفر MediaPipe Hands إطاراً مرناً وسهل الدمج في التطبيقات البرمجية، ويُستخدم بشكل واسع من قبل المطورين والباحثين لكونه مفتوح المصدر ومتاحاً مجاناً. وتكمن أهمية هذا النموذج في أنه يقدم للمستخدمين وسيلة فعالة لتحليل إشارات اليد وتفسيرها، مما يفتح آفاقاً واسعة لتطبيقات تعتمد على

التواصل غير اللفظي أو التحكم عن بُعد، كما أنه يساعد في تصميم أنظمة أكثر تفاعلية وإنسانية في تفاعلها مع المستخدمين [12].



الشكل 5-3: تسلسل مراحل معالجة الصورة في نظام MediaPipe Hands.

كما هو موضح في الشكل (3-5)، تبدأ العملية عندما تلتقط الكاميرا صورة تحتوي على يد. في البداية، يقوم النظام بفحص الصورة ليرى إن كانت اليد موجودة بوضوح. إذا كانت هذه أول صورة يراها، أو إذا لم تكن اليد ظاهرة من قبل، فإنه يُشغّل مرحلة الكشف عن اليد (تُوضح في الجزء العلوي من المخطط حيث يُكتب: Hand Detection only runs on: 1. First Frame, 2. Hand is missing).

بعد أن يجد النظام اليد، يُحوّل مكانها إلى مستطيل لتحديد موقعها بدقة (كما يظهر في المربعات التي تشير إلى DetectionToRectangle و ImageCropping في وسط المخطط). ثم يقوم بقص الجزء الذي يحتوي على اليد من الصورة حتى يركّز عليه فقط.

في المرحلة التالية، يستخدم النظام تقنية ذكية جدًا تُسمى "تقدير العلامات" لتحديد 21 نقطة رئيسية على اليد، مثل أطراف الأصابع والمفاصل (هذه المرحلة موضحة في المربع "HandLandmark").

بعد أن يتم تحديد النقاط، تُرسم هذه النقاط على اليد وتُعرض على الشاشة (كما في الجزء السفلي الأيمن من المخطط في AnnotationRenderer ثم Display).

الخطوط الزرقاء في المخطط تمثل كيف يستخدم النظام معلومات من الصورة السابقة ليساعد نفسه على تتبع اليد بشكل أفضل في الصورة التالية، مما يجعله أسرع وأكثر دقة مع مرور الوقت.


على الرغم من أن تقنية MediaPipe Hands تُعد من الأدوات الفعّالة في تتبع حركة اليد بدقة، إلا أن هناك بعض التحديات التي قد تؤثر على أدائها في بيئات معينة. من أبرز هذه التحديات هو فقدان القدرة على تتبع اليد عندما تختفي خلف جسم آخر، مثل الطاولة أو الرأس، مما يجعل النموذج غير قادر على مواصلة التعرف على موقع اليد أو حركتها. كما أن جودة الإضاءة تلعب دورًا كبيرًا في دقة التتبع؛ ففي

حال كانت الإضاءة ضعيفة أو غير متوازنة، فإن النموذج قد يواجه صعوبة في التعرف على اليد بدقة. كذلك، إذا لم تكن اليد واضحة في مجال رؤية الكاميرا، مثل أن تكون خارج الإطار أو غير بارزة بوضوح، فقد يفشل النموذج في اكتشافها تمامًا، مما يؤثر على استمرارية التتبع.

3-5 تتبع الوجه باستخدام MediaPipe Face Mesh

تُعد تقنية تتبع الوجه باستخدام MediaPipe Face Mesh من أبرز الابتكارات في مجال رؤية الحاسوب (Computer Vision)، لما توفره من مستوى غير مسبوق من التفاصيل في تحليل ملامح الوجه البشري. تعتمد هذه التقنية على نموذج ذكي قادر على توليد شبكة ثلاثية الأبعاد دقيقة مكونة من 468 نقطة مرجعية (Landmarks) تغطي ملامح الوجه الرئيسية (الشكل 3-6)، بما في ذلك العينين، الأنف، الفم، الحاجبين، وال فك. هذه النقاط لا تُستخرج عشوائيًا، بل تتموضع بطريقة مدروسة تُمكن الخوارزمية من إعادة بناء تمثيل هندسي دقيق لبنية الوجه في الزمن الحقيقي، حتى أثناء الحركة أو التعبير [12].

إن وجود عدد كبير من النقاط الدقيقة يسمح بتحليل تعابير الوجه الدقيقة، مثل ابتسامة خفيفة، رفع الحاجب، أو حتى ارتعاش الجفن. كما يمكن من خلال هذا النموذج تتبع حركة العين وتغير اتجاه النظر بدقة عالية، وهو أمر يصعب تحقيقه باستخدام نماذج تقليدية تعتمد على عدد أقل من النقاط أو على تحليل ثنائي الأبعاد فقط. الجدير بالذكر أن هذه التقنية لا تقتصر على تتبع الملامح الثابتة فحسب، بل تتابع أيضًا التحولات الدقيقة والانفعالية في تعابير الوجه، مما يجعلها أداة قوية في مجالات مثل التفاعل الإنساني مع الآلة، الواقع المعزز، والواجهات الذكية التي تعتمد على فهم السلوك البشري [12].




الشكل 6-3: النقاط الرئيسية للوجه.

ميزة MediaPipe Face Mesh لا تكمن فقط في قدرتها التحليلية، بل أيضاً في أدائها العملي؛ فهي خفيفة الوزن وفعالة بشكل يسمح بتشغيلها على الأجهزة المحمولة وضمن متصفحات الإنترنت دون الحاجة إلى عتاد متخصص أو وحدات معالجة رسومية متقدمة. كما أنها مبنية على تقنيات تعلم الآلة المتقدمة التي تتيح لها التكيف مع اختلافات الأوجه من حيث الشكل واللون والجنس والفئة العمرية، مما يعزز من شموليتها وعدالة استخدامها عبر مختلف البيئات والتطبيقات [12].

في تتبع الوجه باستخدام MediaPipe Face Mesh، تبدأ العملية من لحظة تشغيل الكاميرا، حيث يلتقط النظام صورة حية للوجه. بعد ذلك، يتم تحديد مكان الوجه داخل الصورة وقصّه ليُصبح بحجم

مناسب للتحليل (كما يظهر في يسار الشكل 3-7). هذا يساعد النموذج على التركيز فقط على ملامح الوجه بدلاً من الصورة الكاملة [12].



الشكل 3-7: آلية عمل MediaPipe Face Mesh.

بعد قص الوجه، تأتي مرحلة التحليل. هنا يدخل الوجه إلى "مستخرج الخصائص"، وهو جزء نكي من البرنامج يعمل مثل العدسة المكبرة، لكن بدلاً من التكبير البصري، يقوم بتحليل التفاصيل الصغيرة جدًا في الوجه مثل شكل العين، القزحية (الجزء الملون من العين)، والفم. هذا التحليل لا يكون عشوائيًا، بل يتم على مراحل، بحيث يُعطى كل جزء من الوجه (مثل العين أو الشفاه) اهتمامًا خاصًا.

الشكل (3-7) توضح كيف يتم هذا التحليل خطوة بخطوة:

- في البداية يتم مسح الوجه بالكامل.
- ثم تُفحص مناطق مهمة مثل العينين والفم بمزيد من الدقة.
- وأخيرًا، يُرسم "شبكة" دقيقة جدًا مكونة من مئات النقاط الصغيرة تغطي ملامح الوجه بالكامل.

تخيل أن وجهك يُغطى بشبكة شفافة مثل التي تُستخدم في الرسوم المتحركة ثلاثية الأبعاد - هذه الشبكة تتحرك مع وجهك وتتغير مع تعابيرك. فمثلاً، إذا رفعت حاجبيك أو ابتسمت، ستتتحرك النقاط على هذه الشبكة لتعكس التغير [12].

بهذه الطريقة، يمكن للنظام متابعة كل حركة صغيرة في الوجه، مثل فتح العين، تحريك البؤبؤ، أو حتى تغيير شكل الفم. وهذا التحليل مفيد جداً في التطبيقات التي تحتاج إلى فهم تعابير الوجه أو تتبع سلوك المستخدم بدقة [12].

يمكن لتقنية تتبع الوجه باستخدام الذكاء الاصطناعي أن تكون أداة فعالة جداً في مراقبة سلوك الأشخاص خلال الامتحانات، وخاصة عند استخدامها للكشف عن محاولات الغش. تعمل هذه التقنية على مراقبة ملامح الوجه بشكل لحظي، حيث تقوم بتحديد مواضع دقيقة مثل العيون والفم وتتابع حركتها باستمرار أثناء فترة الجلوس أمام الكاميرا. فعلى سبيل المثال، إذا قام الطالب بتكرار النظر إلى نقطة معينة خارج إطار الشاشة، فقد يُشير ذلك إلى وجود ورقة خارجية أو محاولة التواصل مع شخص ما، وهو ما يمكن أن تلتقطه الخوارزميات باعتباره سلوكاً مريباً يستدعي المراجعة [12].

أما بالنسبة للفم، فغالباً ما يكون مؤشراً مهماً على التحدث بصوت منخفض أو محاولة التهامس، خاصة إذا تم تسجيل حركة غير اعتيادية للشفاه دون صدور صوت واضح. مثل هذه التفاصيل يصعب ملاحظتها بالعين المجردة، لكن التقنية قادرة على تتبعها من خلال شبكة النقاط الدقيقة التي تغطي ملامح الوجه، كما رأينا في الصورة التوضيحية السابقة. هذه الشبكة تساعد في رصد حتى أصغر التغيرات في التعبير، مثل شد الشفاه أو تحريكها بشكل متكرر بطريقة غير طبيعية [12].

والى جانب ذلك، تستطيع التقنية التعرف على تعابير الوجه التي قد تكون مرتبطة بمشاعر القلق أو التوتر المفرط. على سبيل المثال، قد يُظهر الطالب الذي يحاول الغش تركيزًا زائدًا أو يتصرف بطريقة تختلف عن نمط الجلوس الطبيعي، مما يُسجل على أنه سلوك غير معتاد. لا تعني هذه الإشارات بالضرورة أن الشخص يغش، لكنها تُستخدم كمؤشرات أولية تساعد على لفت الانتباه إلى حالات تستدعي التحقق [12].

ورغم هذه القدرات المتقدمة، إلا أن هناك بعض القيود التي يجب أخذها في الحسبان. فالذكاء الاصطناعي يعتمد بشكل كبير على وضوح الرؤية للوجه الكامل. فإذا كان الوجه مغطى جزئيًا، مثل وجود يد تغطي جزءًا من الفم أو ارتداء نظارات شمسية داكنة أو كمامة، فقد يصبح من الصعب على النظام التقاط الإشارات الدقيقة. كذلك تؤثر الإضاءة بشكل كبير على فعالية النظام؛ فالإضاءة الزائدة قد تؤدي إلى ظهور انعكاسات على الوجه تُربك الخوارزميات، في حين أن الظلال أو الإضاءة الضعيفة قد تُخفي بعض ملامح الوجه وتقلل من دقة التحليل [12].


الفصل الرابع: التنفيذ العملي والنتائج

4-1 إعداد بيئة العمل

تم إعداد بيئة العمل الخاصة بهذا المشروع باستخدام نظام التشغيل Windows، حيث يتم تطوير النظام باستخدام لغة البرمجة Python. ولتوفير بيئة تفاعلية تسهل كتابة الأكواد وتنفيذها، تم اختيار استخدام بيئة التطوير المتكاملة Visual Studio Code، التي تتيح إمكانية تحرير الكود وتنظيمه بشكل فعال، مع دعمها المتقدم للعديد من المكتبات البرمجية. تم اختيار مكتبة OpenCV الخاصة بمعالجة الصور والفيديوهات، وهي أساسية لتنفيذ تقنيات الرؤية الحاسوبية التي يعتمد عليها النظام في تحليل حركات الطالب. كما تم الاستفادة من مكتبة MediaPipe التي تقدم حلولاً جاهزة لاستخراج الملامح والروابط بين مختلف أجزاء الجسم، وهي مفيدة في مراقبة حركة الطالب. علاوة على ذلك، يتم استخدام نموذج YOLO (You Only Look Once) لاكتشاف الأشياء وتحليل السلوكيات المشبوهة بشكل فعال وسريع.

4-2 مخطط خوارزمية العمل

يوضح الشكل (4-1) خوارزمية العمل المتبعة في النظام، يبدأ النظام بتحميل نموذج YOLO لتمييز الأشخاص، ثم يلتقط الفريمات من الكاميرا. بعد ذلك، يتم استخراج صورة الشخص وتحويلها إلى صيغة RGB. تُرسل الصورة إلى Mediapipe لاستخراج النقاط المطلوبة. إذا تم اكتشاف حركة مشبوهة مثل التوجه للغش، يتم إطلاق إنذار وتحديد الإشارة الحمراء. إذا لم يتم اكتشاف ذلك، يعود النظام للمتابعة بشكل دوري.



الشكل 1-4: مخطط خوارزمية العمل.

3-4 المخطط الصندوقي




الشكل 2-4: المخطط الصندوقي لعملية كشف حالات الغش.

4-4 التطبيق العملي للنظام


في التطبيق العملي لنظام كشف الغش المعتمد على تقنيات الرؤية الحاسوبية، تم اختبار فعالية النظام في تتبع حركة رأس الطالب وتحديد ما إذا كان يحافظ على تركيزه المباشر على الشاشة أم لا. يعتمد النظام على تحليل زاوية التفات الرأس، ويُصنف الحالات بناءً على هذا التحليل باستخدام مؤشرات بصرية واضحة تظهر في الصور الملتقطة.

كما هو موضح في الشكل (2-4)، عندما يقوم الطالب بالالتفات برأسه قليلاً نحو اليسار أو ينفذ التفاتة كاملة في نفس الاتجاه، أو في حال قام بالحركة نفسها نحو اليمين، يتعرف النظام تلقائياً على هذه الحالات باعتبارها مشبوهة. يتم تحديد هذه الحالات عبر إطار أحمر يُرسم حول وجه الطالب في الصورة، ويُعدّ هذا الإطار إشارة إلى أن سلوك الطالب قد يشير إلى محاولة للغش أو عدم التركيز على الشاشة. تعتمد هذه النتيجة على قراءة دقيقة لحركة الرأس باستخدام خوارزميات متقدمة، تتابع وضع الوجه وتحلل زاويته مقارنة بمحور الرؤية الأمامي.

في المقابل، كما نرى في الشكل (4-3)، عندما يكون وجه الطالب موجّهًا بشكل مستقيم نحو الشاشة، دون أي انحرافات تُذكر، يعتبر النظام أن الوضع طبيعي ولا يشير إلى أي سلوك مريب. في هذه الحالة، يُحيط وجه الطالب إطار أخضر، وهو ما يدل على أن المستخدم يلتزم بوضعية الرأس المطلوبة للتركيز أثناء الاختبار، مما يعني أن الحالة لا تتطلب أي تدخل.



الشكل 4-3: كشف حالات غش.



الشكل 4-4: حالة عدم غش.

4-5 النتائج

أظهرت نتائج الاختبار أن النظام يعمل بكفاءة في تصنيف الحالات بدقة، حيث يستجيب بشكل فوري لتغيرات اتجاه الرأس. كلما انحرف الطالب عن الوضع الأمامي، سواء بشكل طفيف أو كامل، يتم التعرف على الحالة كمشوهة. أما في حال حافظ على توجيه رأسه نحو الشاشة دون انحراف، فيُسجَل ذلك كحالة طبيعية. هذه السلوكيات البسيطة كانت كافية ليُظهر النظام دقة ملحوظة في التمييز بين التركيز والانحراف، مما يدل على نجاحه في تحقيق الهدف من تتبّع مؤشرات الغش المرتبطة بوضعية الرأس.

الفصل الخامس : الخاتمة والآفاق المستقبلية

مع التطور المتسارع في تقنيات الذكاء الاصطناعي وتزايد اعتماد المؤسسات التعليمية على الأدوات الرقمية في مختلف عملياتها، برزت الحاجة إلى ابتكار آليات ذكية تواكب التحديات المستجدة، لا سيما في مجال مراقبة الامتحانات وضبط السلوكيات غير القانونية أثناءها. وقد تناول هذا المشروع فكرة تصميم نظام ذكي قائم على تقنيات الرؤية الحاسوبية من أجل دعم عملية كشف الغش في قاعات الامتحان. ومن خلال الاعتماد على خوارزميات متقدمة في تحليل الصور والفيديو، وسعي دائم لتحقيق استجابة آلية وسريعة للسلوكيات المشبوهة، تم تطوير نموذج مبدئي يُمثل خطوة أولى في هذا الاتجاه.

اعتمد النظام المُصمم على تحليل تحركات الطالب ضمن إطار زمني مرئي، بالاستفادة من أدوات متخصصة مثل YOLO لاكتشاف الكائنات، وMediaPipe لتقدير وضعيات الجسم واليدين والوجه. وقد تم تنفيذ التجارب ضمن بيئة خاضعة للضبط من حيث الحركة والإضاءة وزاوية التصوير، باستخدام كاميرا عادية، بهدف مراقبة وتحليل الإشارات السلوكية المرتبطة بالعين أو الرأس أو الأطراف. وقد بيّنت النتائج الأولية أن النظام قادر على النقاط بعض الأنماط الحركية التي ترتبط غالباً بسلوكيات مشبوهة، مثل الالتفات المتكرر أو تحريك اليدين بشكل غير اعتيادي أثناء الامتحان.

وعلى الرغم من أن التجربة لم تُجرى داخل قاعات امتحان مزدحمة أو بيئات تعليمية حقيقية متعددة المستخدمين، إلا أنها شكّلت منصة اختبار فعالة لتقنيات التحليل البصري المستخدمة، كما ساعدت على تقييم أداء النماذج في ظروف مختلفة، وقياس مدى دقة النقاط السلوكيات وتسجيلها زمنياً. وقد ساهم هذا النموذج التجريبي في تكوين تصور واضح حول نقاط القوة ونقاط التحسين التي يجب معالجتها في النسخ

اللاحقة من النظام، خصوصًا فيما يتعلق بالتعامل مع الضجيج البصري، وموثوقية تتبع الحركات الدقيقة، والتمييز بين السلوك العفوي والسلوك الذي يحتمل نية الغش.

وما يمكن التأكيد عليه هو أن هذا المشروع لم يكن مجرد تجربة تقنية معزولة، بل كان نتاج عملية تحليل وتصميم مدروسة، تضمنت استعراضًا للجهود السابقة في المجال، وفهمًا عميقًا للأنظمة التقليدية والحديثة في مراقبة الامتحانات، إلى جانب دراسة التحديات المرتبطة بالتحليل الآلي للسلوك البشري ضمن بيئة تعليمية. وقد وفر هذا الإطار رؤية تطبيقية قابلة للتوسع، مع مراعاة الجوانب الأخلاقية والتقنية اللازمة عند نقل التجربة من النطاق المحدود إلى بيئة تعليمية واقعية.

إن الأهمية التي يحملها هذا النوع من المشاريع لا تتجلى فقط في البُعد التقني، وإنما أيضًا في أثره المحتمل على تحسين جودة البيئة التعليمية ككل. فنظام الكشف الآلي عن السلوكيات المشبوهة لا يهدف إلى استبدال دور المراقب البشري بالكامل، بل يسعى إلى تقديم أداة داعمة تسهم في تحسين الكفاءة والعدالة وتقليل نسبة الخطأ، خاصة في الامتحانات التي تضم أعدادًا كبيرة من الطلاب. وبناءً على ما تم تحقيقه في النموذج الحالي، وبما تفرضه البيئة الواقعية من متطلبات أعلى، يمكن الإشارة إلى مجموعة من المقترحات التي من شأنها تطوير أداء النظام ورفع كفاءته وتوسيع نطاق تطبيقه، ومنها:

- توسيع نطاق التجريب ليشمل قاعات امتحان فعلية تحتوي على أعداد كبيرة من الطلاب، بهدف تقييم أداء النظام في بيئات تعليمية أكثر واقعية وتنوعًا.
- الاعتماد على كاميرات متعددة الزوايا ودقة أعلى لتغطية مشهد القاعة بشكل شامل، وتحسين جودة التتبع وتجاوز مشكلات الإضاءة والتشويش البصري.

- دمج خوارزميات تعتمد على تسلسل الحركات عبر الزمن مثل RNN أو LSTM، بما يسمح للنظام بفهم تطور السلوك بدقة أكبر بدلاً من تحليل لقطات فردية فقط.
- تدريب النظام على مجموعة بيانات موسعة وأكثر تنوعاً تشمل طلاباً من فئات عمرية ومؤسسات مختلفة، لضمان تعميم النتائج وتقليل تحيز النموذج.
- إدخال طبقة إضافية لتحليل تعابير الوجه والانفعالات للكشف عن مؤشرات غير لفظية مثل التوتر أو القلق أو التركيز الموجه، بما يدعم قرار الكشف.
- تصميم واجهة استخدام تفاعلية للمراقبين البشريين تتيح استعراض التنبيهات التي يُطلقها النظام، وتقديم ملاحظات فورية تساهم في تحسين دقة النظام لاحقاً.
- ربط النظام بمنصات إدارة التعليم (مثل LMS أو أنظمة الامتحانات الرقمية) بهدف إنشاء ملفات رقمية متكاملة توثق السلوك الامتحاني لكل طالب.
- دراسة إمكانية دمج الحساسات الصوتية أو البيئية كعنصر داعم لتحسين عملية التصنيف وتقليل الاعتماد الكلي على الرؤية الحاسوبية فقط.
- تحسين كفاءة النموذج باستخدام خوارزميات خفيفة وقابلة للتنفيذ على الأجهزة منخفضة الموارد لتوسيع فرص النشر في المدارس أو المراكز محدودة التجهيز.
- إجراء دراسات تقييم لاحقة بمشاركة طاقم تعليمي ومراقبين للتحقق من موثوقية التنبيهات، وموازنة العلاقة بين الكشف التلقائي والتدخل البشري.

في ضوء ما سبق، يمكن اعتبار هذا المشروع بمثابة اللبنة الأولى في مسار طويل من البحث والتطوير الرامي إلى بناء أنظمة رقابة ذكية تُعزز من صدقية التقييم الأكاديمي. لقد نجح النموذج المطور في إثبات صلاحية الفكرة وفعالية المنهج المستخدم ضمن بيئة اختبار محدودة، ووضع حجر الأساس لتطبيقات مستقبلية واعدة في مجال كشف الغش وتحليل السلوكيات داخل الفصول الدراسية. ومن المؤمل أن يواصل هذا العمل طريقه في التوسع والتعميق من خلال التعاون مع مؤسسات تعليمية وتجريب تقنيات أكثر دقة وتخصصًا، حتى يصبح نظامًا ذكيًا متكاملًا يحقق أهدافه الأكاديمية والأخلاقية والعملية على حد سواء.

المراجع

- [1] Roopikha, S., Roshini, S., & Rithika, S. (2023). Automatic Cheating Detection In Exam Hall. *International Journal of Novel Research and Development*, 8(11), a834–a844.
- [2] Unknown. (2024). Cheating Detection in Examinations Using Improved YOLOv8 and Attention Mechanism. *Journal of Computer Science and Simulation*, 39(5), 1668–1680.
- [3] Kumar, K. S., Mulla, T., Prabhakar, R. R., & Patil, S. (2025). AI-Powered Cheating Detection in Examination Halls. *International Research Journal of Modernization in Engineering Technology and Science*, 7(05), 7659–7667.
- [4] Anonymous. (March 2025). AI-Based Proctoring System for Cheating Prevention in Online Exams. *International Research Journal of Education and Technology*, 7(03), 1638–1645.
- [5] Anonymous. (May 2025). Exam Cheating Detection System with Multiple-Human Pose Estimation. *International Research Journal of Modernization in Engineering Technology and Science*, 7(05), 7659–7667.
- [6] Al_airaji, R. M., Aljazaery, I. A., ALRikabi, H. Th. S., & Alaidi, A. H. M. (2022). Automated cheating detection based on video surveillance in the examination classes. *International Journal of Interactive Mobile Technologies*, 16(08), 114–130.
- [7] Tran, N., Nguyen, M., Le, T., Huynh, T., Nguyen, T., & Nguyen, T. (2023). Exploring the potential of skeleton and machine learning in classroom cheating detection. *Indonesian Journal of Electrical Engineering and Computer Science*, 32(3), 1533–1544.

- [8] Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing (4th ed.). Pearson.
- [9] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [10] IBM. (n.d.). Convolutional neural networks. IBM.
<https://www.ibm.com/think/topics/convolutional-neural-networks>
- [11] Ayoosh, K. (2018, May 20). YOLO explained. Medium.
<https://medium.com/analytics-vidhya/yolo-explained-5b6f4564f31>
- [12] Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2019). OpenPose: Realtime multi-person 2D pose estimation using part affinity fields. IEEE Transactions on Pattern Analysis and Machine Intelligence, 43(1), 172–186.