



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الوطنية الخاصة
قسم هندسة الحاسوب

مشروع أعد لنيل درجة الإجازة في بكالوريوس هندسة الحاسوب بعنوان:

تصميم نظام تعليمي تفاعلي للأطفال باستخدام

الذكاء الاصطناعي والرؤية الحاسوبية

إعداد الطالبتين:

دانيا عثمان الطباع

تسنيم عبد الله الطيار

إشراف:

د. زيد قريطم

2025-2024

ملخص المشروع:

يهدف هذا المشروع إلى تصميم نظام تعليمي تفاعلي للأطفال باستخدام تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، مع التركيز على ثلاث وظائف رئيسية. أولاً، يقوم النظام بالتعرف على الألوان باستخدام نموذج HSV (Hue, Saturation, Value) لتحديد الألوان المختلفة في البيئة المحيطة. ثانياً، يستخدم النظام خوارزمية YOLO للكشف عن الحيوانات في الصور والفيديوهات، مما يساعد الأطفال على تعلم أسماء الحيوانات والتعرف عليها بشكل تفاعلي. ثالثاً، يتم استخدام تقنية OCR (التعرف على النصوص) لتحويل الأرقام المكتوبة إلى نصوص قابلة للقراءة، مما يساهم في تعليم الأطفال الأرقام وتعزيز مهاراتهم الحسابية.

تعتمد هذه الوظائف على تقنيات متقدمة في الذكاء الاصطناعي مثل الرؤية الحاسوبية والشبكات العصبية، حيث يقوم النظام بتحليل الصور والتفاعل مع الطفل بشكل تفاعلي لتعزيز عملية التعلم. أظهرت التجارب العملية أن النظام يعمل بكفاءة عالية في كل من وظائفه، مع استجابة سريعة وسلسلة في التعرف على الألوان، الحيوانات، والأرقام.

الكلمات المفتاحية:

تفاعل، تعلم تفاعلي، ذكاء اصطناعي، YOLO، OCR، HSV، رؤية حاسوبية.

Project Summary:

This project aims to design an interactive educational system for children using artificial intelligence and computer vision technologies, focusing on three main functions. First, the system recognizes colors using the HSV (Hue, Saturation, Value) model to identify various colors in the surrounding environment. Second, it employs the YOLO algorithm to detect animals in images and videos, helping children learn animal names and recognize them interactively. Third, the system uses OCR (Optical Character Recognition) technology to convert written numbers into readable text, contributing to teaching children numbers and enhancing their mathematical skills.

These functions rely on advanced AI techniques such as computer vision and neural networks, allowing the system to analyze images and interact with children in an engaging way to enhance the learning process. Practical experiments have shown that the system operates efficiently in all its functions, with fast and smooth responses in recognizing colors, animals, and numbers.

Keywords:

Interaction, Interactive Learning, Artificial Intelligence, YOLO, OCR, HSV, Computer Vision.

المحتويات

14.....	1 الفصل الأول: المقدمة
19.....	2 الفصل الثاني: الخلفية النظرية والأعمال السابقة
20.....	1-2 الصورة الرقمية
21.....	2-2 الذكاء الاصطناعي (Artificial Intelligence – AI)
24.....	1-2-2 التعلم الآلي VS التعلم العميق
26.....	3-2 الشبكات العصبية الاصطناعية (ANN)
29.....	1-3-2 الشبكة العصبية العميقة (DNNs)
30.....	2-3-2 الشبكة العصبية التلافيفية (CNNs)
34.....	4-2 مراجعة المشاريع والدراسات السابقة
34.....	FINNger1-4-2 : تطبيق الذكاء الاصطناعي لتسهيل تعلّم الرياضيات للأطفال
	2-4-2 تصميم وتقييم نظام تعليمي تفاعلي للأطفال باستخدام تقنيات التفاعل بين الطفل والحاسوب
37.....	
40.....	3 الفصل الثالث: الخوارزميات الأساسية المستخدمة
41.....	1-3 نموذج HSV في تحليل الألوان
45.....	1-1-3 HSV Thresholding نظرة عامة على
48.....	2-3 كشف الكائنات (Object Detection)

48.....	1-2-3 مفهوم كشف الكائنات
50.....	2-2-3 أنواع كاشفات الكائنات
51.....	3-2-3 معايير تقييم أداء نماذج كشف الكائنات
53.....	4-2-3 خوارزمية YOLO (You Only Look Once)
56.....	3-3 تقنية OCR
56.....	1-3-3 ماهي تقنية OCR؟
57.....	2-3-3 تاريخ تقنية OCR
58.....	3-3-3 كيف تعمل تقنية OCR؟
61.....	4-3-3 أنواع تقنية OCR
62.....	5-3-3 فوائد استخدام تقنية OCR
63.....	6-3-3 حالات استخدام تقنية OCR
65.....	7-3-3 أحدث التطورات في تقنية OCR
66.....	4 الفصل الرابع: تصميم النظام
67.....	1-4 وصف فكرة النظام وأهدافه التعليمية
68.....	2-4 مكونات النظام المادية والبرمجية
68.....	1-2-4 مكونات النظام المادية (Hardware)

68	2-2-4 مكونات النظام البرمجية (Software)
71	3-4 مخطط معالجة البيانات
73	4-4 وظائف النظام
73	1-4-4 وظيفة التعرف على الألوان
73	2-4-4 وظيفة التعرف على الأرقام
73	3-4-4 وظيفة التعرف على الكائنات
74	4-4-4 وظيفة النطق الصوتي
74	5-4 مخطط الواجهات
74	6-4 مخطط حالات الاستخدام
76	5 الفصل الخامس: التنفيذ العملي
77	1-5 المخططات التدفقية
77	1-1-5 وظيفة التعرف على الحيوانات
78	2-1-5 وظيفة التعرف على الألوان
79	3-1-5 وظيفة التعرف على الأرقام
80	2-5 التطبيق العملي النهائي
84	3-5 النتائج

84..... 1-3-5 مقاييس أداء النماذج في الذكاء الاصطناعي

86..... 2-3-5 كشف الحيوانات

101..... 3-3-5 كشف الألوان

102..... 4-3-5 كشف الأرقام

106..... 4-5 الخاتمة

107..... 5-5 الافاق المستقبلية

108..... 6 المراجع

الأشكال

- الشكل (2-1): تمثيل الصورة الرقمية. 20.....
- الشكل (2-2): مجالات استخدام الذكاء الاصطناعي. 24.....
- الشكل (2-3): الفرق بين طريقة عمل التعلم الآلي وطريقة عمل التعلم العميق. 25.....
- الشكل (2-4): بنية الشبكة العصبية الاصطناعية. 28.....
- الشكل (2-5): الفرق بين الشبكة العصبية والشبكة العصبية العميقة. 29.....
- الشكل (2-6): خطوات عمل شبكة CNN. 31.....
- الشكل (2-7): آلية عمل المرشحات. 32.....
- الشكل (2-8): الفرق بين Max Pooling و Average Pooling. 33.....
- الشكل (2-9): واجهة التطبيق. 34.....
- الشكل (2-10): مجموعة البيانات المستخدمة. 35.....
- الشكل (2-11): استخدام خوارزمية كشف الحواف. 36.....
- الشكل (2-12): معدل تحسن تأثير التعلم لدى الأطفال في الفئات العمرية المختلفة (a) الصفوف 3-1، (b) الصفوف 4-6. 38.....
- الشكل (2-13): مخطط واجهة النظام: تمثيل بصري للعناصر الرئيسية لتفاعل المستخدم وتصميم الواجهة. 38.....
- الشكل (2-14): آلية مشاركة المستخدم وتقديم الملاحظات. 39.....
- الشكل (3-1): المكعب اللوني الخاص بنظام الألوان RGB. 42.....

43	الشكل (3-2): الأسطوانة اللونية لنموذج الألوان HSV.....
44	الشكل (3-3): تأثير تغيير التشبع والضوء على الألوان في نموذج HSV.....
44	الشكل (3-4): تأثير تغيير التشبع والضوء على الألوان في نموذج HSV.....
46	الشكل (3-5): نطاق الألوان في نموذج HSV.....
49	الشكل (3-6): كشف الكائنات.....
50	الشكل (3-7): أمثلة على خوارزميات كشف الكائنات حسب مراحل المعالجة.....
52	الشكل (3-8): حساب IoU.....
55	الشكل (3-9): هيكل خوارزمية YOLO.....
56	الشكل (3-10): تقنية OCR.....
59	الشكل (3-11): خطوات عمل تقنية OCR.....
64	الشكل (3-12): استخدام تقنية OCR للتعرف على الأرقام.....
69	الشكل (4-1): مكتبة OpenCV.....
69	الشكل (4-2): مكتبة NumPy.....
70	الشكل (4-3): COCO Dataset.....
70	الشكل (4-4): واجهة بسيطة مصممة باستخدام TKinter.....
71	الشكل (4-5): مخطط معالجة البيانات.....
74	الشكل (4-6): مخطط الواجهات.....
75	الشكل (4-7): مخطط حالات الاستخدام.....
77	الشكل (5-1): المخطط التدفقي لوظيفة التعرف على الحيوانات.....

- الشكل (5-2): المخطط التدفقي لوظيفة التعرف على الألوان.....78
- الشكل (5-3): المخطط التدفقي لوظيفة التعرف على الأرقام.....79
- الشكل (5-4): الواجهة الرئيسية.....80
- الشكل (5-5): واجهة التعرف على الحيوانات.....81
- الشكل (5-6): التعرف على الحيوانات.....81
- الشكل (5-7): واجهة التعرف على الألوان.....82
- الشكل (5-8): التعرف على الألوان.....82
- الشكل (5-9): واجهة التعرف على الأرقام.....83
- الشكل (5-10): التعرف على الأرقام.....83
- الشكل (5-11): أداء نموذج كشف العقاب.....86
- الشكل (5-12): منحنى الاستدعاء - الثقة لنموذج كشف العقاب.....87
- الشكل (5-13): منحنى الدقة - الاستدعاء لنموذج كشف العقاب.....88
- الشكل (5-14): صور عينات كشف العقاب.....89
- الشكل (5-15): مصفوفة الالتباس لنموذج كشف العقاب.....90
- الشكل (5-16): منحنى F1 - الثقة لنموذج كشف العقاب.....90
- الشكل (5-17): أداء نموذج كشف القطط.....91
- الشكل (5-18): منحنى الاستدعاء - الثقة لنموذج كشف القطط.....92
- الشكل (5-19): منحنى الدقة - الاستدعاء لنموذج كشف القطط.....93
- الشكل (5-20): منحنى الدقة - الثقة لنموذج كشف القطط.....93

94	الشكل (5-21): صور عينات كشف القطط.....
95	الشكل (5-22): مصفوفة الالتباس لنموذج كشف القطط.....
95	الشكل (5-23): منحنى F1 - الثقة لنموذج كشف القطط.....
96	الشكل (5-24): أداء نموذج كشف الأسماك.....
97	الشكل (5-25): منحنى الاستدعاء - الثقة لنموذج كشف الأسماك.....
98	الشكل (5-26): منحنى الدقة - الثقة لنموذج كشف الأسماك.....
99	الشكل (5-27): عينات كشف الأسماك.....
100	الشكل (5-28): مصفوفة الالتباس لنموذج كشف الأسماك.....
100	الشكل (5-29): منحنى F1 - الثقة لنموذج كشف الأسماك.....
103	الشكل (5-30): قيم مقاييس الأداء في الكشف عن الأرقام.....
103	الشكل (5-31): أداء EasyOCR.....

فهرس الجداول

الجدول (5-1): نتائج أداء النموذج.....	86
الجدول (5-2): نتائج منحنى الاستدعاء - الثقة لنموذج كشف العقاب.....	87
الجدول (5-3): نتائج منحنى الدقة - الاستدعاء لنموذج كشف العقاب.....	88
الجدول (5-4): نتائج منحنى F1 - الثقة لنموذج كشف العقاب.....	90
الجدول (5-5): نتائج أداء نموذج كشف القطط.....	91
الجدول (5-6): نتائج منحنى الاستدعاء - الثقة لنموذج كشف القطط.....	92
الجدول (5-7): نتائج منحنى الدقة - الاستدعاء لنموذج كشف القطط.....	93
الجدول (5-8): نتائج منحنى الدقة - الثقة لنموذج كشف القطط.....	94
الجدول (5-9): نتائج منحنى F1 - الثقة لنموذج كشف القطط.....	96
الجدول (5-10): نتائج أداء نموذج كشف الأسماك.....	96
الجدول (5-11): نتائج منحنى الاستدعاء - الثقة لنموذج كشف الأسماك.....	97
الجدول (5-12): نتائج منحنى الدقة - الثقة لنموذج كشف الأسماك.....	98
الجدول (5-13): نتائج منحنى F1 - الثقة لنموذج كشف الأسماك.....	101
الجدول (5-14): نتائج مقاييس الأداء لكشف الأرقام.....	103
الجدول (5-15): العينات.....	104

جدول المصطلحات

الاختصار	المعنى بالإنجليزية	المعنى بالعربية
AI	Artificial Intelligence	الذكاء الاصطناعي
OCR	Optical Character Recognition	التعرف الضوئي على الحروف
HSV	Hue, Saturation, Value	صبغة، تشبع، قيمة
YOLO	You Only Look Once	أنت تنظر مرة واحدة
CNN	Convolutional Neural Networks	الشبكات العصبية التلافيفية
DNN	Deep Neural Networks	الشبكات العصبية العميقة
ANN	Artificial Neural Networks	الشبكات العصبية الاصطناعية
SVM	Support Vector Machine	آلة المتجهات الداعمة
IoU	Intersection over Union	التقاطع على الاتحاد
mAP	Mean Average Precision	متوسط الدقة

1 🧡 الفصل الأول: المقدمة

في العصر الرقمي الحالي، أصبحت تقنيات الذكاء الاصطناعي والرؤية الحاسوبية جزءًا لا يتجزأ من العديد من التطبيقات المبتكرة في مختلف المجالات، بما في ذلك التعليم. على الرغم من التطورات الكبيرة في مجال التعليم التقليدي، إلا أن هناك حاجة ملحة لتطوير أنظمة تعليمية تفاعلية تستفيد من هذه التقنيات الحديثة لتعزيز عملية التعلم، وخاصة للأطفال في مراحلهم المبكرة. الأطفال في هذه المراحل يحتاجون إلى بيئة تعليمية تحفزهم على التفاعل والتعلم بشكل ممتع وبطرق مبتكرة، بعيدًا عن الطرق التقليدية التي قد لا تواكب احتياجاتهم المتزايدة في عصر التكنولوجيا. من هنا، يهدف هذا المشروع إلى تصميم نظام تعليمي تفاعلي للأطفال يعتمد على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، بحيث يساهم في تطوير قدراتهم البصرية، المعرفية، والذهنية من خلال تفاعلهم مع النظام.

يتضمن هذا النظام التعليمي ثلاث وظائف رئيسية تعزز من تجربة التعلم لدى الأطفال. الوظيفة الأولى هي التعرف على الألوان باستخدام نموذج HSV (Hue, Saturation, Value)، الذي يُعتبر أداة فعالة في التعرف على الألوان وتحليلها بطريقة تساعد الطفل على التفاعل مع المحيط بشكل مرئي ومعرفي. الوظيفة الثانية هي التعرف على الحيوانات، حيث يستخدم النظام خوارزمية YOLO (You Only Look Once) لاكتشاف الحيوانات في الصور والفيديوهات. من خلال هذا التعرف، يصبح بإمكان الأطفال تعلم أسماء الحيوانات والتعرف على أنواعها في بيئة تعليمية مرحة. أما الوظيفة الثالثة فهي التعرف على الأرقام باستخدام OCR (التعرف الضوئي على الحروف)، مما يساهم في تعليم الأطفال الأرقام وتطوير مهاراتهم في الحساب بطريقة تفاعلية وذكية.

تعد أهمية هذا المشروع كبيرة في إطار التعليم الحديث، حيث يوفر النظام أدوات تعليمية مبتكرة للأطفال تجعل عملية التعلم أكثر تفاعلاً وسهولة. باستخدام تقنيات الذكاء الاصطناعي مثل YOLO و OCR، يصبح من الممكن دمج التفاعل البصري والعملي مع التعلم الأكاديمي، مما يعزز قدرة الأطفال على التعلم بسرعة أكبر وبشكل ممتع. إضافة إلى ذلك، يعتمد النظام على تقنيات الرؤية الحاسوبية التي تتيح له تحليل الصور والفيديوهات بفعالية، مما يساهم في تحسين الفهم البصري والتفاعل بين الطفل والنظام.

تعتمد أهمية هذا النظام على مجموعة من العوامل الرئيسية التي تساهم في تحسين تجارب التعلم للأطفال. أولاً، يُمكن النظام من التفاعل المباشر مع الأطفال من خلال واجهة مستخدم مرنة وبمبسطة. ثانياً، يُشجع الأطفال على التفاعل مع المحتوى التعليمي باستخدام أساليب مرئية تعزز من قدرتهم على الاستيعاب. ثالثاً، يُمكن للنظام أن يُعدل من نفسه وفقاً لاحتياجات الطفل، مما يوفر تجربة تعليمية مخصصة تتكيف مع مستوى كل طفل على حدة. هذه الخصائص تساهم في جعل النظام أكثر فاعلية من الطرق التعليمية التقليدية، التي قد تكون ثابتة ولا توفر التفاعل المرن مع الطفل.

يهدف هذا المشروع إلى تحسين عملية التعلم للأطفال باستخدام تقنيات الذكاء الاصطناعي والرؤية الحاسوبية من خلال عدة أهداف رئيسية، ومنها: تصميم وتطوير نظام تعليمي تفاعلي يستخدم تقنيات الذكاء الاصطناعي والرؤية الحاسوبية لتحفيز الأطفال على التفاعل مع المحتوى التعليمي، وتنفيذ تقنية التعرف على الألوان باستخدام نموذج HSV، مما يساعد الأطفال على تعلم الألوان بشكل دقيق، ودمج خوارزمية YOLO لاكتشاف الكائنات الحيوانية في الصور والفيديوهات، مما يعزز

من تجربة تعلم الأطفال حول الحيوانات، وتنفيذ تقنيات OCR للتعرف على الأرقام المكتوبة، مما يساهم في تعزيز تعليم الأرقام للأطفال، وضمان تفاعل فوري ومرن بين الطفل والنظام من خلال استجابة فورية عند التفاعل مع المدخلات، واختبار النظام في بيئات تعليمية حقيقية لتقييم فعاليته في تعزيز تجربة التعلم وتفاعل الأطفال مع المحتوى.

تعاني العديد من أساليب التعليم التقليدية من صعوبة في تحفيز الأطفال على التفاعل مع المحتوى التعليمي. حيث تعتمد المناهج التقليدية على طرق ثابتة قد لا تناسب احتياجات الأطفال المتزايدة، ولا توفر لهم الفرص للتفاعل مع المعلومات بشكل عملي. هذا يؤدي إلى قلة الدافعية لدى الأطفال في بعض الأحيان، مما يؤثر على جودة التعلم. بالإضافة إلى ذلك، فإن معظم الأنظمة التعليمية الحالية تفتقر إلى استخدام تقنيات الذكاء الاصطناعي التي يمكن أن تضيف قيمة كبيرة من خلال توفير تعليم مخصص ومرن يتناسب مع احتياجات الأطفال.

هذا المشروع يهدف إلى حل هذه المشكلة عن طريق تطوير نظام تعليم تفاعلي يعتمد على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، ليحفز الأطفال على التفاعل مع المحتوى التعليمي في بيئة مرئية تفاعلية. بتوفير أدوات مثل التعرف على الألوان والحيوانات والأرقام، يعزز النظام قدرة الأطفال على التعلم بسهولة أكبر، ويجعل العملية التعليمية أكثر جذبًا وإمتاعًا، بالإضافة إلى تقديم تجربة تعليمية تلئم احتياجات كل طفل.


من خلال هذا المشروع، يتم تقديم نظام تعليمي تفاعلي يُدمج تقنيات الذكاء الاصطناعي المتقدمة في بيئة تعليمية مناسبة للأطفال. يتمثل الإسهام الرئيس في تطوير بيئة تعلم ممتعة وحيوية، مما يساهم في تحسين الفهم البصري للطفل، وزيادة تفاعله مع المواد التعليمية. كما يفتح المشروع

الطريق لاستخدام تقنيات YOLO و OCR و HSV في تطبيقات تعليمية مبتكرة لم تُستخدم بكثرة في مجال التعليم للأطفال، مما يجعل هذا النظام إضافة قيمة إلى المنظومة التعليمية الرقمية.

2 الفصل الثاني: الخلفية النظرية والأعمال السابقة

1-2 الصورة الرقمية

تُعد الصورة الرقمية تمثيلًا رياضيًا للعالم المرئي، حيث تُنقّط وتُحوّل إلى مجموعة من النقاط الصغيرة المنظمة في شبكة ثنائية الأبعاد، تُسمى البكسلات (Pixels)، والتي تُشكّل الوحدة الأساسية لتكوين أي صورة رقمية. كل بكسل يُمثّل جزءًا صغيرًا من الصورة، ويحمل قيمة رقمية تعكس خصائص اللون والسطوع في تلك النقطة الدقيقة. على سبيل المثال، في الصورة الملونة، يُعبّر عن لون البكسل عبر نموذج ألوان مثل RGB (الأحمر الأخضر الأزرق)، حيث تُحدد ثلاث قيم رقمية لكل قناة لونية لتحديد ظلال اللون الدقيق. أما في الصور الرمادية، فتُستخدم قيمة واحدة لكل بكسل لتمثيل درجة السطوع بين الأسود والأبيض [1].



الشكل (2-1): تمثيل الصورة الرقمية.

تُنظَّم البكسلات في شبكة مستطيلة ذات بعدين (X للأفقية و Y للعمودية)، كما يظهر في الشكل (2-1)، حيث يُعرَّف موقع كل بكسل بواسطة إحداثياته الثنائية (x, y). كلما زاد عدد البكسلات في الوحدة المساحية (مثل 4K أو 8K)، ازدادت الدقة وتحسنت جودة التفاصيل المرئية. تُخزَّن البيانات الرقمية للبكسلات في ملفات الصور (مثل JPEG أو PNG)، والتي تُحوَّل إلى إشارات كهربائية يمكن عرضها على الشاشات أو طباعتها. بهذه الآلية، تتحول الصورة الواقعية إلى بيانات رقمية قابلة للتعديل والتحليل بواسطة الحواسيب، مما يفتح المجال أمام تطبيقات واسعة في الرؤية الحاسوبية والمعالجة الرقمية للصور [1].

2-2 الذكاء الاصطناعي (Artificial Intelligence – AI)

الذكاء الاصطناعي (Artificial Intelligence - AI) يُعد أحد أبرز المجالات التكنولوجية التي أعادت رسم ملامح العالم الحديث، حيث يهدف إلى تصميم أنظمة وآليات قادرة على محاكاة القدرات العقلية البشرية، مثل الفهم، التعلم، الاستنتاج، والتفاعل مع البيئة المحيطة بطريقة ذكية. يُعرَّف الذكاء الاصطناعي عمومًا بأنه فرع من علوم الحاسوب يركّز على تطوير خوارزميات ونماذج تُمكن الآلات من تنفيذ مهام تتطلب عادةً ذكاءً بشريًا، سواء في اتخاذ القرارات أو تحليل البيانات أو التفاعل مع المدخلات المعقدة. لا يقتصر هذا المفهوم على الروبوتات أو الأنظمة الفيزيائية فقط، بل يشمل أيضًا البرمجيات والتطبيقات التي تُعالج معلومات بطرق متطورة، مثل محركات البحث، ومساعدات الصوت، وأنظمة التشخيص الطبي، وحتى الألعاب الإلكترونية التي تتكيف مع سلوك المستخدم [2].

في صميم الذكاء الاصطناعي تكمن فكرة المحاكاة الرقمية للتفكير البشري، حيث تُستخدم نماذج رياضية ومعالجة بيانات ضخمة لمحاكاة العمليات الإدراكية، مثل التعرف على الأنماط، فهم اللغة الطبيعية، أو اتخاذ قرارات استباقية. على سبيل المثال، عندما يُستخدم الذكاء الاصطناعي في التعرف على الوجوه، فإنه لا يلتقط الصورة فحسب، بل يحلل ملايين النقاط والخصائص الفريدة لكل وجه ويقارنها بقواعد بيانات ضخمة لتحديد الهوية بدقة عالية. وفي هذا السياق، تُستخدم الشبكات العصبية التي تعتمد على معادلة تُحدد العلاقة بين المدخلات والأوزان والانحيازات، كما في المعادلة التالية:

$$y = f(b + \sum_{i=1}^n x_i w_i)$$

حيث:

y : الخرج، x_i : الدخل، w_i : الأوزان، b : الانحياز، f : دالة التنشيط

هذا النوع من التطبيقات يُظهر كيف يمكن للأنظمة الذكية أن تتجاوز البساطة في الأداء وتصل إلى مستويات من التعقيد والدقة تُشابه أحياناً التحليل البشري. لتحديد مدى دقة النظام في التنبؤ، يتم استخدام معادلة دالة الخسارة، التي تُعبر عن الفرق بين التنبؤات والنتائج الفعلية كما في المعادلة التالية:


$$L = \frac{1}{m} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

حيث:

L : الخسارة، m : عدد العينات، Y_i : الخرج الفعلي، $\hat{Y}_i$: الخرج المتوقع من النموذج.

تتميز أنظمة الذكاء الاصطناعي بمرونتها في التكيف مع مختلف المجالات (الشكل 2-2)، من خلال دمجها مع تقنيات أخرى مثل الرؤية الحاسوبية، معالجة اللغة الطبيعية، والروبوتات. ففي التعليم، يمكن لذكاء اصطناعي أن يُحلّل تفاعل الطالب مع المواد الدراسية ويُقدّم تغذية راجعة مخصصة، بينما في الطب، يُستخدم لتحليل الصور الطبية وتحديد الأمراض بدقة تفوق أحياناً التشخيص البشري. حتى في الصناعات الإبداعية، مثل الموسيقى والفنون، برزت تطبيقات تعتمد على الذكاء الاصطناعي لإنتاج أعمال فنية أو موسيقى جديدة بناءً على أنماط تعلمتها من بيانات سابقة. هذه القدرة على التعلم والتكيف تجعل الذكاء الاصطناعي أداة قوية تتجاوز حدود التخصصات التقليدية [2].

ما يميّز الذكاء الاصطناعي عن الأنظمة التقليدية هو اعتماده على البيانات كأساس للتطوير. كلما زادت كمية البيانات المُدخلة وزادت جودتها، زادت قدرة النظام على اتخاذ قرارات دقيقة أو تنبؤات موثوقة. هذا المبدأ يُفسّر كيف تستطيع أنظمة مثل السيارات ذاتية القيادة أن تتعلم من ملايين الساعات من قيادة الإنسان، أو كيف تستطيع تطبيقات الترجمة الفورية أن تُحسّن دقة ترجمتها مع كل استخدام. في جوهره، الذكاء الاصطناعي ليس مجرد برمجيات ثابتة، بل هو نظام ديناميكي يتطور باستمرار عبر التغذية بالبيانات والتجارب التي يتعرض لها.




الشكل (2-2): مجالات استخدام الذكاء الاصطناعي.

مع ذلك، لا يزال الذكاء الاصطناعي في طور التطوير المستمر، حيث تتركز الجهود البحثية على تحسين كفاءة المعالجة، الحد من التحيز في البيانات، وتعزيز الأمان والخصوصية. كما أن هناك تركيزًا متزايدًا على جعل هذه الأنظمة أكثر شفافية وقابلية للتفسير، حتى يمكن للمستخدمين فهم كيفية اتخاذ القرار داخل النظام، خاصة في المجالات الحساسة مثل الطب أو القضاء. بفضل هذه التطورات، أصبح الذكاء الاصطناعي اليوم أداة لا غنى عنها في تحويل الأفكار النظرية إلى حلول عملية تلامس الحياة اليومية، مما يفتح آفاقًا جديدة للاستكشاف والابتكار في كل مجال من مجالات البشرية [2].

1-2-2 التعلم الآلي VS التعلم العميق

التعلم الآلي (Machine Learning) يعتمد على استخراج ميزات يدوية من البيانات، مما يتطلب تدخلًا بشريًا كبيرًا في اختيار الأنماط المطلوبة. بينما التعلم العميق (Deep Learning) يستخدم

الشبكات العصبية متعددة الطبقات لاستخلاص الميزات تلقائيًا من البيانات، مما يجعله أكثر كفاءة في معالجة الصور المعقدة مثل الكائنات أو الأرقام.



الشكل (2-3) : الفرق بين طريقة عمل التعلم الآلي وطريقة عمل التعلم العميق.

في مجال معالجة الصور، يواجه التعلم الآلي صعوبات في التعامل مع التحديات البصرية مثل التغير في الإضاءة أو الزوايا، حيث تعتمد على تقنيات مثل SVM أو الغابات العشوائية. أما التعلم العميق، فإنه يُستخدم الشبكات العصبية التلافيفية (CNN) التي تستخرج الأنماط المكانية بشكل آلي، مما يتيح له فهم التفاصيل الدقيقة حتى في وجود ضوضاء أو تشويه. الشبكات العصبية التلافيفية (CNN) تعمل وفقًا لمعادلة الخسارة الخاصة بها، التي تُستخدم لتدريب النموذج على تصنيف الأنماط بدقة، كما في المعادلة التالية:

$$\mathcal{L} = - \sum_{c=1}^c y_c \log \hat{y}_c$$

حيث:

$\mathcal{L}$: الخسارة، c : عدد الفئات في تصنيف الصور، y_c : التصنيف الحقيقي للفئة c ، $\hat{y}_c$: التنبؤ الاحتمالي للفئة c .


السبب الرئيسي لاختيار التعلم العميق هو قدرته على التكيف مع التعقيدات البصرية دون الحاجة إلى تصميم ميزات يدويًا، بالإضافة إلى قدرته على التعامل مع كميات كبيرة من البيانات وتحقيق دقة عالية في التعرف على الأنماط الجديدة. هذا يجعله الخيار الأمثل للمهام التي تتطلب سرعة وكفاءة عالية، مثل الكشف الفوري عن الكائنات باستخدام YOLO أو أنظمة المراقبة الذكية، حيث يتمتع بقدرة أكبر على التعميم والتكيف مع بيئات مختلفة.

3-2 الشبكات العصبية الاصطناعية (ANN)

الشبكات العصبية الاصطناعية (Artificial Neural Networks) هي نماذج حاسوبية مُصممة لمحاكاة آلية عمل الدماغ البشري في معالجة المعلومات، حيث تُعدّ الأداة الأساسية لفهم وتطوير أنظمة الذكاء الاصطناعي التي تتطلب تعلمًا ذاتيًا وتحليلًا معقدًا للبيانات. تتكوّن هذه الشبكات من وحدات أساسية تُسمى الخلايا العصبية الاصطناعية (Artificial Neurons)، والتي تشبه في وظيفتها الخلايا العصبية الحقيقية في الدماغ، لكنها تُنفّذ رياضيًا باستخدام خوارزميات تعتمد على العمليات الحسابية البسيطة. تتصل هذه الخلايا ببعضها عبر روابط وزنية (Weighted Connections) تحمل قيمًا عددية تمثل قوة العلاقة بين الخلايا، وتُستخدم لتحديد مدى تأثير إشارة دخل معينة على ناتج

الخلية التالية. تعمل الشبكة ككل من خلال تمرير البيانات عبر طبقات متتالية من هذه الخلايا، حيث يتم تحويل المدخلات الأولية إلى مخرجات نهائية عبر عمليات تراكمية من التحليل والتعديل [3].

في تصميم الشبكات العصبية، تُنظم الخلايا العصبية في طبقات (Layers) كما هو موضح في الشكل (4-1)، تبدأ بـ الطبقة الإدخالية (Input Layer) التي تستقبل البيانات الخام، مثل بكسلات الصور أو قيم الصوت، وتنتهي بـ الطبقة الإخراجية (Output Layer) التي تُنتج النتيجة النهائية، مثل تصنيف صورة أو التنبؤ بقيمة مستقبلية. بين هاتين الطبقتين تقع الطبقات المخفية (Hidden Layers)، والتي تلعب دورًا حاسمًا في استخراج الأنماط وتحويل البيانات عبر عمليات رياضية متعددة. كل خلية في الطبقة المخفية تأخذ مدخلات من الخلايا السابقة، وتُطبّق عليها مجموعة من الأوزان والتحيزات (Biases) لحساب قيمة مُعدّلة، ثم تمرّ هذه القيمة عبر دالة تنشيط (Activation Function) تضيف طبيعة غير خطية للحسابات، مما يسمح للشبكة بفهم العلاقات المعقدة بين المتغيرات. تشمل الدوال الشائعة دالة (Sigmoid) ودالة (Relu)، والتي تُحدّد ما إذا كانت الخلية "تنشط" أم "تبقى صامتة" بناءً على قيم المدخلات. هذه العملية لا تُعدّ تنبؤًا بالأخطاء مثل التشويش أو الضجيج، بل تُساهم في تحسين قدرة الشبكة على التمييز بين الأنماط المفيدة وغير المفيدة عبر تضخيم أو تقليل الإشارات المهمة أثناء التدريب.



الشكل (2-4): بنية الشبكة العصبية الاصطناعية.


القوة الحقيقية للشبكات العصبية تكمن في قدرتها على التعلم من البيانات دون برمجة صريحة، حيث تُدرَّب الشبكة على مجموعة من الأمثلة المُصنَّفة مسبقًا، مثل صور للقطط والكلاب مُرفقة بتسمياتها. أثناء التدريب، تُحسَّن الأوزان والتحييزات تلقائيًا باستخدام خوارزميات مثل الانتشار العكسي (Backpropagation) والانحدار التدريجي (Gradient Descent)، بهدف تقليل الفرق بين النتائج المتوقعة والنتيجة فعليًا. هذا الفرق يُقاس عبر دالة الخسارة (Loss Function)، والتي تُحدِّد مدى دقة الشبكة في الأداء. مع كل دورة تدريبية، تُعدَّل الشبكة معلماتها الداخلية لتصبح أكثر دقة في التعرف على الأنماط، حتى تتمكن من التعامل مع بيانات جديدة لم ترها من قبل.

تُستخدم الشبكات العصبية في نطاق واسع من التطبيقات، من التعرف على الوجوه وتحليل النصوص إلى التنبؤ بالطقس وتطوير الألعاب الذكية. في سياق المشروع التعليمي للأطفال، تُوظَّف هذه الشبكات في تحليل الصور الرقمية لتحديد الكائنات أو الأرقام أو الألوان، حيث تتعلم من بيانات تعليمية مُعدَّة مسبقًا لربط البكسلات المحددة بفئات معرفة، مثل "مربع" أو "رقم 5" أو "لون أزرق". رغم بساطة المفهوم نظريًا، فإن تنفيذ هذه الشبكات يتطلب قوة معالجة حاسوبية عالية،

خاصة عند التعامل مع بيانات ضخمة مثل الصور عالية الدقة. ومع ذلك، فإن مرونتها في التكيف مع مختلف أنواع البيانات ودقتها في التعلم الذاتي جعلتها العمود الفقري للثورة الحديثة في الذكاء الاصطناعي، حيث تحوّلت من فكرة نظرية إلى أداة عملية تُعيد تعريف إمكانيات الآلات في فهم العالم المحيط [3].

1-3-2 الشبكة العصبية العميقة (DNNs)

الشبكات العصبية العميقة (DNNs) هي نماذج حاسوبية متقدمة تُستخدم لمحاكاة آلية عمل الدماغ البشري، حيث تعتمد على طبقات متعددة من الخلايا العصبية الاصطناعية المتصلة عبر روابط وزنية. يتم تمرير البيانات عبر هذه الطبقات بشكل خطي، حيث تحلل كل طبقة ميزات جديدة بناءً على النتائج التي تنتجها الطبقة السابقة. ومع ذلك، عند معالجة الصور الرقمية، تواجه هذه الشبكات تحديات كبيرة بسبب عدم قدرتها على فهم العلاقات المكانية بين البكسلات. فهي تتعامل مع الصور كمتجهات خطية مستقلة بدلاً من معالجتها كهيكل ثنائي الأبعاد يحتوي على أنماط هندسية وعلاقات جوار، مما يجعل من الصعب استخراج ميزات مرئية مهمة مثل الحواف أو الزوايا دون تدخل بشري [3].




الشكل (5-2): الفرق بين الشبكة العصبية والشبكة العصبية العميقة.

تتميز الصور الرقمية بعدد كبير من البكسلات، مما يتطلب قدرة معالجة حاسوبية ضخمة وتخزينًا عاليًا، ويؤدي إلى بطء عملية التدريب على الأجهزة ذات الموارد المحدودة. بالإضافة إلى ذلك، تعاني DNN من صعوبة في التعميم، حيث يفشل النموذج غالبًا في التعرف على الكائنات نفسها في ظروف مختلفة مثل تغيير الإضاءة أو الزاوية. كما أنها تعتمد افتراضًا خاطئًا بأن كل بكسل مستقل عن محيطه، بينما في الواقع، العلاقات بين البكسلات القريبة هي التي تُشكل الميزات المرئية الأساسية. هذه القيود جعلت DNN غير مناسبة للتطبيقات التي تتطلب دقة واستجابة فورية، مثل الأنظمة التعليمية للأطفال، مما دفع إلى تطوير نماذج أكثر تخصصًا مثل الشبكات العصبية التلافيفية (CNN) لمعالجة الصور بكفاءة أعلى.

2-3-2 الشبكة العصبية التلافيفية (CNNs)

الشبكات العصبية التلافيفية (CNN – Convolutional Neural Networks) هي نموذج حاسوبي متخصص في معالجة البيانات ثنائية الأبعاد مثل الصور، حيث تُصمم لمحاكاة آلية الرؤية البشرية عبر استخراج الميزات المرئية تلقائيًا دون تدخل بشري. تتميز هذه الشبكات بوجود طبقات تلافيفية (Convolutional Layers) وعمليات تجميع (Pooling)، والتي تعمل معًا لتحليل العلاقات المكانية بين البكسلات واستخلاص الأنماط المعقدة في الصور [3].


2-3-1 كيف تعمل الشبكة العصبية التلافيفية (CNN)؟



الشكل (2-6): خطوات عمل شبكة CNN.

1. الطبقة التلافيفية (Convolutional Layer):


- تبدأ العملية بإدخال الصورة الرقمية إلى الطبقة التلافيفية الأولى، حيث تُطبق عليها فلاتر تلافيفية (Filters) صغيرة الحجم (مثل 3×3 بكسل).
- تتحرك هذه الفلاتر عبر كل جزء من الصورة، وتقوم بحساب المنتج الداخلي (Dot Product) بين قيم البكسلات في المنطقة المحيطة بالفلتر وأوزان الفيلتر نفسه.
- النتيجة هي خريطة ميزات (Feature Map) تمثل ملامح بصرية أولية مثل الحواف، الزوايا، أو التباين اللوني.
- كل طبقة تلافيفية تُضيف طبقة جديدة من التعقيد، حيث تتعلم الطبقة الثانية أنماطًا أكثر تعقيدًا (مثل الأشكال الهندسية)، والطبقة الثالثة تجمع هذه الأنماط لتكوين كيانات كاملة (مثل وجه إنسان أو رقم).



الشكل (2-7): آلية عمل المرشحات.

2. الطبقة التجميعية (Pooling Layer):

- بعد كل طبقة تلافيفية، تأتي الطبقة التجميعية لتخفيض أبعاد الخريطة المميزة دون فقدان المعلومات الأساسية.
- تُستخدم عمليات مثل (Max Pooling) أو (Average Pooling)، حيث تختار أعلى قيمة (أو المتوسط) في منطقة محددة (مثل 2x2 بكسل).
- هذا يساعد في تقليل من الضوضاء مثل التشويش أو التغيرات في الإضاءة، الحفاظ على الميزات الرئيسية مثل شكل الكائن حتى لو اختلفت زاويته أو حجمه وتسريع الحسابات عبر تخفيض عدد البكسلات المُعالَجة في الخطوات التالية.



الشكل (8-2): الفرق بين Max Pooling و Average Pooling.

3. طبقة التسطيح (Flattening Layer):

- بعد استخراج جميع الميزات عبر الطبقات التلافيفية والتجميعية، تُحوّل الخرائط المميزة المتعددة إلى متجه خطي (Vector) واحد.
- هذه الخطوة ضرورية لإعداد البيانات للانتقال إلى الجزء الأخير من الشبكة، الذي يعتمد على الربط الكامل (Fully Connected Layers)

4. الطبقة المرتبطة بالكامل (Fully Connected Layer):

- هنا، يتم تمرير المتجه المسطح إلى طبقات عصبية تقليدية (مثل تلك الموجودة في الشبكات العصبية العميقة DNN)، لكن مع اختلاف جوهري: البيانات الآن تحتوي على ميزات مرئية مُستخلصة بدقة.
- تقوم هذه الطبقات بدمج الميزات المُستخرجة لاتخاذ قرار نهائي، مثل تصنيف الصورة إلى "قط" أو "كلب"، أو تحديد موقع رقم في الصورة [3].

4-2 مراجعة المشاريع والدراسات السابقة

FINNger 1-4-2: تطبيق الذكاء الاصطناعي لتسهيل تعلُّم الرياضيات للأطفال


استكشف الباحثان رافائيل أوديبيرت وفينيسيوس ماسكيو كيفية استخدام التكنولوجيا لجعل الرياضيات أكثر متعة وسهولة للأطفال عبر تطبيقٍ يعتمد على التفاعل البصري. الفكرة الأساسية للتطبيق هي تمييز الأصابع المرفوعة عبر كاميرا الجهاز (مثل الهاتف أو الحاسوب) وتحويلها إلى عمليات حسابية بسيطة، مما يُحوّل التعلُّم إلى لعبة تفاعلية (الشكل 14).



الشكل (2-9): واجهة التطبيق.


تشير الدراسة إلى أن الأطفال يواجهون صعوبات في فهم الرياضيات مقارنة بتعلُّم القراءة، رغم مهارتهم في استخدام الأجهزة الإلكترونية، مما دفع الباحثين لسد هذه الفجوة عبر دمج تقنيتي كشف الحواف والشبكة العصبية التلافيفية (CNN) [4].

استُخدمت مجموعتي بيانات: الأولى "koryakinp/fingers" (21,600 صورة لأيدي في خلفيات ضبابية موحدة الإضاءة)، مُقسّمة إلى بيانات تدريب واختبار (الشكل 2a). الثانية مجموعة مخصصة (3,200 صورة لأيدي في بيئات واقعية متنوعة)، مما يعكس تحديات العالم الحقيقي (الشكل 2b).



الشكل (2-10): مجموعة البيانات المستخدمة.

بالنسبة لخوارزمية كشف الحواف، تعمل على تحويل الصورة إلى نظام ألوان HSV لعزل لون البشرة (الشكل 2-11a)، ثم تطبيق قناع لتمييز اليد باستخدام القشرة المحدبة (الشكل 2-11b)، وتُطبّق دائرة افتراضية لعزل الأصابع (الشكل 2-11c). حققت دقة 72.4%، لكنها واجهت صعوبة في الخلفيات المعقدة أو الأصابع المتشابكة (الشكل 2-11d). أما الشبكة العصبية التلافيفية (FINNger)، فُصِّمَت بثلاث كتل تلافيفية مع طبقات تعطيل عشوائي وتعزيز الصورة، محققة دقة 98% على بيانات الاختبار، لكنها فشلت مع أيدي الأطفال أو الوضعيات غير الاعتيادية.



الشكل (2-11): استخدام خوارزمية كشف الحواف.

من التحديات: صعوبة تمييز الأيدي في بيئات غير مضبوطة (كخلفيات مشابهة للبشرة)، وانخفاض دقة النموذج مع أيدي الأطفال بسبب اختلاف حجم الأصابع. كما أظهر النموذج خطأً في العدّ عند وجود خطوط في الخلفية (مثل الأثاث).

أوصت الدراسة بتوسيع قاعدة البيانات لتشمل أيدي الأطفال وبيئات متنوعة، واستخدام بيانات مُصنَّعة لتعويض نقص البيانات الواقعية، وتطوير نسخة محمولة من التطبيق. خلصت إلى أن الجمع بين الذكاء الاصطناعي والتفاعل البصري يُظهر إمكانيات كبيرة في تحسين تعلّم الرياضيات، لكنه يحتاج إلى بيانات أكثر تنوعًا ونماذج مُحسَّنة لضمان فعاليته [4].


2-4-2 تصميم وتقييم نظام تعليمي تفاعلي للأطفال باستخدام تقنيات التفاعل بين

الطفل والحاسوب


في دراسة حديثة بعنوان " Design and Evaluation of Children's Education Interactive Learning System Based on Human-Computer Interaction Technology"، تم تطوير نظام تعليمي مخصص للأطفال يعتمد على التفاعل المباشر مع الجهاز باستخدام تقنيات حديثة مثل الواقع المعزز (AR)، الواقع الافتراضي (VR)، والتعرف على الصوت. تهدف هذه الدراسة إلى تحسين تجربة التعلم للأطفال من الصف الأول وحتى الصف السادس من خلال جعل العملية التعليمية أكثر متعة وتفاعلية وملائمة لقدرات كل طفل [5].

اعتمد الباحثون في هذه الدراسة على تجارب عملية لاختبار فعالية النظام، حيث تم إجراء اختبار للأطفال قبل وبعد استخدامهم للنظام، وتبين أن أداء الطلاب تحسن بشكل واضح في مواد الرياضيات والعلوم. فمثلاً، تحسن مستوى طلاب الصفوف 1 إلى 3 في مادة العلوم بنسبة 28.1%، والرياضيات بنسبة 24.6%، بينما تحسن طلاب الصفوف 4 إلى 6 بنسبة 26.8% في العلوم و22.2% في الرياضيات، كما هو موضح في الشكل (2-12).

النظام مصمم بطريقة تتيح للطفل التفاعل معه بسهولة، حيث تظهر واجهة مليئة بالألوان والعناصر التفاعلية مثل الصور والفيديوهات والألعاب التعليمية، ما يجعل التعلم شبيهاً باللعب. يوضح الشكل (2-13) هذه الواجهة التي تم تصميمها خصيصاً لتكون مناسبة لعمر الطفل وتفكيره، وتوفر تفاعلاً مباشراً مع كل حركة أو ضغطة يقوم بها الطفل.




الشكل (2-12): معدل تحسن تأثير التعلم لدى الأطفال في الفئات العمرية المختلفة (a) الصفوف 1-3، (b) الصفوف 4-6.



الشكل (2-13): مخطط واجهة النظام: تمثيل بصري للعناصر الرئيسية لتفاعل المستخدم وتصميم الواجهة.

واحدة من المميزات المهمة في هذا النظام هي أنه يحتوي على زر مخصص لإرسال الملاحظات أو المشاكل التي قد يواجهها الطفل أثناء التعلم. هذا يسمح للمعلمين أو فريق الدعم الفني بمعرفة هذه المشكلات بسرعة والعمل على حلها. كما يوضح الشكل (2-14)، هناك نظام متكامل لجمع هذه الملاحظات وتحليلها لتحديث النظام باستمرار.



الشكل (14-2): آلية مشاركة المستخدم وتقديم الملاحظات.

من ناحية الأداء، كان النظام سريعًا جدًا في الاستجابة لتصرفات الطفل، حيث بلغ متوسط زمن الاستجابة 1.77 ثانية فقط، وهو زمن ممتاز مقارنة بأنظمة تعليمية أخرى. أما من حيث استقرار النظام وعدد الأخطاء، فقد أظهرت الدراسة أن النظام نادرًا ما يرتكب أخطاء أثناء التشغيل، سواء عند تسجيل الدخول أو تحميل المحتوى أو التفاعل مع الطفل.

تم استطلاع رأي المستخدمين (الأطفال، المعلمين، وأولياء الأمور) حول مدى رضاهم عن النظام. النتيجة كانت إيجابية جدًا، حيث عبّر 94% من المستخدمين عن رضاهم العام، واعتبر معظمهم أن النظام مفيد وسهل الاستخدام [5].

3 الفصل الثالث:

الخوارزميات الأساسية المستخدمة

3-1 نموذج HSV في تحليل الألوان


في مجال معالجة الصور، يعد اختيار نموذج الألوان المناسب أمرًا ضروريًا لتحليل الصور بدقة وكفاءة. هناك العديد من نماذج الألوان، ولكن الأكثر شيوعًا هما نموذج RGB ونموذج HSV. لفهم الفرق بينهما، يجب التعمق في كيفية تمثيل كل نموذج للألوان وطريقة استخدامه في التطبيقات المختلفة [6].

نموذج الألوان RGB يعتمد على المزج الجمعي للألوان، حيث يتم تكوين الألوان من خلال دمج كميات مختلفة من الأحمر (Red)، الأخضر (Green)، والأزرق (Blue). كل لون يتم تمثيله باستخدام قيم تتراوح بين 0 و 255، مما يعني أن هناك (أكثر من 16 مليون) لونًا ممكنًا. يستخدم RGB بشكل أساسي في الشاشات الرقمية، حيث تصدر وحدات البكسل الضوء لإنشاء الألوان المختلفة. نظرًا لطبيعته الإضافية، فإن دمج جميع القيم عند الحد الأقصى (255,255,255) ينتج اللون الأبيض، بينما يؤدي غياب جميع القيم (0,0,0) إلى اللون الأسود [6].

الشكل (3-1) يوضح المكعب اللوني لنموذج RGB، وهو تمثيل ثلاثي الأبعاد يوضح كيفية تداخل الألوان الأساسية الثلاثة لتشكيل مجموعة واسعة من الألوان. كل محور يمثل قيمة إحدى القنوات اللونية (R، G، B)، ويظهر تأثير تغيير كل مكون على اللون الناتج. يمكن ملاحظة أن كل ركن من أركان المكعب يمثل لونًا معينًا:

- الركن (0,0,0) يمثل اللون الأسود، حيث لا يوجد أي انبعاث للضوء.
- الركن (255,255,255) يمثل اللون الأبيض، حيث يتم خلط جميع الألوان بأقصى شدة.

الأركان الأخرى تمثل الألوان الأساسية والثانوية، حيث ينتج اللون الأحمر من (255,0,0)، والأخضر من (0,255,0)، والأزرق من (0,0,255). بينما يتم إنتاج الأصفر من مزج الأحمر والأخضر (255,255,0)، والسماعي من الأخضر والأزرق (0,255,255)، والارجواني من الأحمر والأزرق (255,0,255). [6]




الشكل (3-1): المكعب اللوني الخاص بنظام الألوان RGB.

على الرغم من فاعلية RGB في توليد الألوان، إلا أنه ليس دائماً النموذج الأمثل لمعالجة الصور، خاصة عند تحليل الألوان أو فصلها بناءً على درجات اللون. هنا يأتي دور نموذج HSV، الذي يعتمد على ثلاث مكونات: الصبغة اللونية (Hue)، التشبع (Saturation)، والإضاءة (Value). تم تطوير هذا النموذج ليكون أكثر توافقاً مع الطريقة التي يدرك بها البشر الألوان، مما يجعله أكثر فائدة في العديد من تطبيقات الرؤية الحاسوبية [6].

الشكل (3-2) يمثل الأسطوانة اللونية لنموذج HSV، حيث يتم ترتيب الألوان في شكل أسطواني لتوضيح العلاقات بين مكوناته الثلاثة. المحور الرأسي للأسطوانة يمثل قيمة الإضاءة (V)، حيث

يكون اللون أكثر سطوعًا في الأعلى وأكثر ظلامًا في الأسفل. الزاوية حول المحور تمثل الصبغة اللونية (H)، وهي التي تحدد اللون الأساسي مثل الأحمر، الأخضر، الأزرق. يتم قياسها بالدرجات من 0° إلى 360°، حيث يمثل 0° اللون الأحمر، و120° اللون الأخضر، و240° اللون الأزرق. أما البعد من المركز إلى الحافة فيمثل التشبع (S)، وهو مدى نقاء اللون. إذا كانت القيمة قريبة من المركز، فإن اللون يكون باهتًا أو رماديًا، أما إذا كانت قريبة من الحافة، فإن اللون يكون أكثر تشبعًا وقوة [6].

HSV (Hue, Saturation and Value)



الشكل (2-3): الأسطوانة اللونية لنموذج الألوان HSV.

عند تحليل الألوان في الصور، يكون نموذج HSV أكثر كفاءة ووضوحًا من نموذج RGB لعدة أسباب. أحد أبرز هذه الأسباب هو فصل اللون عن الإضاءة، حيث يمكن أن تتغير قيم الألوان في RGB بشكل كبير مع تغير الإضاءة، مما يجعل من الصعب تحليل الألوان بثبات. أما في HSV، فإن الصبغة اللونية (H) لا تتأثر كثيرًا بالإضاءة، مما يسهل تحديد الألوان حتى في ظروف الإضاءة غير المتناسقة [6].

إضافةً إلى ذلك، تسهل بنية HSV عمليات التعديل والمعالجة اللونية. عند التعامل مع التعديلات اللونية مثل تغيير الدرجة اللونية أو تحسين التشبع، يكون التعامل مع HSV أكثر بساطة مقارنة بـ RGB. على سبيل المثال، يمكن ضبط التشبع (S) لزيادة أو تقليل حدة اللون دون التأثير على درجته اللونية، وهو أمر يصعب تحقيقه في نموذج RGB حيث تتداخل القنوات الثلاثة [6].

تُستخدم HSV أيضًا بشكل واسع في تطبيقات التعرف على الألوان والتصنيف، حيث تتيح الصبغة اللونية (H) تقسيم الألوان إلى نطاقات محددة بسهولة. هذا مفيد جدًا في تطبيقات الرؤية الحاسوبية مثل تتبع الأجسام أو تحديد الكائنات بناءً على لونها، حيث يمكن استبعاد تأثيرات الإضاءة والتركيز فقط على درجة اللون [6].

الشكل (3-3) يوضح تأثير تغيير التشبع والإضاءة على الألوان في نموذج HSV. في الصف العلوي، يتم تثبيت الصبغة اللونية (H) وتغيير التشبع (S) من 0% (رمادي تمامًا) إلى 100% (لون نقي). أما في العمود الأول، يتم تثبيت الصبغة والتشبع، بينما يتم تعديل الإضاءة (V) من 0% (أسود) إلى 100% (لون كامل السطوع). الشكل (3-3): تأثير تغيير التشبع والضوء على الألوان في نموذج HSV. يمكن ملاحظة أن استخدام HSV يسهل معالجة الألوان بطرق أكثر طبيعية ووضوحًا [6].



الشكل (3-4): تأثير تغيير التشبع والضوء على الألوان في نموذج HSV.

تعتمد العديد من أنظمة تحليل الصور الحديثة على نموذج HSV بدلاً من RGB لضمان دقة وثبات النتائج، خاصة في بيئات الإضاءة المتغيرة. إذ يمكن للكاميرات والأنظمة الذكية تحليل الألوان في المشاهد المختلفة دون أن تتأثر بظروف الإضاءة المتفاوتة، مما يعزز من أداء تقنيات الرؤية الحاسوبية في مجالات متعددة مثل القيادة الذاتية، التصوير الطبي، والأمن والمراقبة [6].


1-1-3 نظرة عامة على HSV Thresholding

فصل الألوان باستخدام HSV Thresholding يعتمد على تحويل الصورة من النظام اللوني الافتراضي BGR إلى نظام HSV، حيث يتم تحديد نطاقات معينة لقيم Hue و Saturation و Value من أجل استخراج اللون المطلوب مع استبعاد بقية الألوان الموجودة في الصورة. يتيح هذا الأسلوب مرونة كبيرة في معالجة الصور، خاصة في البيئات التي تتأثر فيها الإضاءة بشدة، حيث يمكن ضبط العتبات للحصول على نتائج أكثر دقة [7].

عند استخدام OpenCV لتنفيذ هذه العملية، تكون الخطوة الأولى هي استيراد المكتبات اللازمة، والتي تشمل OpenCV للتعامل مع الصور والفيديو، بالإضافة إلى مكتبة NumPy التي تتيح إنشاء المصفوفات العددية الضرورية لمعالجة البيانات البصرية. بعد ذلك، يتم تهيئة مصدر الإدخال سواء كان صورة ثابتة أو فيديو مباشر باستخدام كائن VideoCapture، مما يسمح بالحصول على الإطارات بشكل متتابع لمعالجتها في الزمن الحقيقي [7].

قبل البدء في تطبيق العتبات اللونية، من الضروري فهم طبيعة القيم التي يحددها نموذج HSV، حيث يمثل Hue اللون الأساسي ويمتد من 0 إلى 179، بينما يعبر Saturation عن مدى تشبع اللون ويتراوح بين 0 و 255، أما Value فيحدد سطوع اللون ويقع أيضًا ضمن النطاق نفسه.

أحد التحديات الرئيسية عند تطبيق HSV Thresholding هو اختيار القيم المناسبة للعتبات الدنيا والعليا لكل لون، حيث تختلف القيم المطلوبة حسب ظروف الإضاءة وطبيعة الكاميرا المستخدمة. على سبيل المثال، عند محاولة فصل اللون الأحمر، يجب تحديد نطاقين مختلفين لأن اللون الأحمر يظهر في الطرفين الأقصى والأدنى لمجال Hue في النموذج HSV. وكما هو موضح في الشكل (3-4)، فإن اللون الأحمر يظهر في كلا الطرفين من الدائرة اللونية، مما يتطلب تقسيمه إلى قسمين منفصلين لضمان التعرف عليه بدقة. يتم تحديد هذه القيم على شكل مصفوفات NumPy تحتوي على الحدود الدنيا والعليا، والتي يتم استخدامها لاحقاً في إنشاء القناع اللوني [7].



الشكل (3-5): نطاق الألوان في نموذج HSV.

بعد تحديد القيم المناسبة، يتم تحويل كل إطار يتم التقاطه من BGR إلى HSV باستخدام دالة `cvtColor()`. ثم يتم تطبيق عملية الفصل اللوني من خلال دالة `inRange()`، والتي تأخذ الصورة بعد تحويلها إلى HSV، ثم تستخدم القيم المحددة مسبقاً لإنشاء قناع ثنائي، حيث يتم تصنيف كل

بكسل ضمن الصورة إلى داخل أو خارج نطاق اللون المحدد. هذا القناع هو عبارة عن صورة ثنائية القيم، حيث تظهر مناطق اللون المطلوب باللون الأبيض، بينما تظهر بقية المناطق باللون الأسود. عندما يتعلق الأمر بمعالجة أكثر تعقيدًا، يتم استخدام تقنيات إضافية مثل عمليات التآكل والتوسع (Dilation و Erosion) لتحسين القناع الناتج، حيث تساعد هذه العمليات في تقليل الضوضاء الناتجة عن الألوان غير المرغوبة وإبراز المناطق الصحيحة. على سبيل المثال، يمكن استخدام `cv2.erode()` لتقليل المساحات الصغيرة غير المرغوبة، بينما تساعد `cv2.dilate()` في إعادة تكبير المناطق التي تم تحديدها بشكل غير مكتمل [7].

بعد الحصول على القناع النهائي، تأتي مرحلة استخراج الكائنات ذات الألوان المطابقة من خلال العثور على حدودها باستخدام دالة `findContours()`. تقوم هذه الدالة بتحليل القناع الثنائي وتحديد الخطوط الخارجية للكائنات الموجودة فيه. وبما أن بعض الكائنات قد تحتوي على ضوضاء أو قد تكون صغيرة جدًا، يتم تصفية هذه الحدود بناءً على مساحتها، حيث يمكننا تجاهل الأشكال التي تقل مساحتها عن حد معين، مثل 4000 بكسل مربع، لضمان أن الكائنات المستخرجة ذات أهمية [7].

بمجرد العثور على حدود الكائنات، يتم رسم هذه الحدود باستخدام `drawContours()`، والتي تأخذ معلومات مثل الصورة الأصلية، قائمة الحدود المكتشفة، لون الخط، وسمكه. لمزيد من التفاعل، يمكن أيضًا رسم دائرة في مركز كل كائن مكتشف، وذلك عبر حساب مركز الكتلة باستخدام دالة `moments()`. ثم يتم استخدام `circle()` لرسم النقطة في مركز الكائن، مما يسهل تحديده بصريًا.

إضافة إلى ذلك، يمكن تعزيز النظام عبر وضع تسميات نصية فوق الكائنات المكتشفة، حيث يتم استخدام `putText()` لإضافة اسم اللون أو أي معلومات أخرى، مما يجعل عملية التعرف على الألوان أكثر وضوحًا عند عرض الفيديو أو الصورة المعالجة. تتطلب هذه الخطوة اختيار نوع الخط وحجمه ولونه بدقة لضمان قراءة النصوص بوضوح [7].

أثناء تنفيذ هذه العملية، يجب مراعاة تأثيرات الإضاءة المختلفة على اكتشاف الألوان، حيث قد تؤدي الإضاءة القوية أو الظلال إلى تغييرات غير متوقعة في قيم HSV، مما يؤثر على دقة الكشف. لذلك، يمكن تحسين النظام من خلال تجارب عملية لضبط العتبات بشكل يدوي أو حتى استخدام تقنيات تعلم الآلة لضبطها تلقائيًا [7].


أخيرًا، يتم عرض الإطارات المعالجة باستخدام `imshow()`، والتي تعرض كل من الصورة الأصلية مع الكائنات المكتشفة والقناع اللوني الناتج، مما يسمح للمستخدم بمراقبة أداء النظام في الوقت الفعلي.

2-3 كشف الكائنات (Object Detection)

1-2-3 مفهوم كشف الكائنات

كشف الكائنات (Object detection) هو أحد مهام الرؤية الحاسوبية، ويهدف إلى تحديد وتمييز أماكن وجود الكائنات داخل الصور أو مقاطع الفيديو. تُعد هذه المهمة جزءًا أساسيًا في العديد من التطبيقات العملية مثل أنظمة المراقبة، والسيارات ذاتية القيادة، والروبوتات. وتنقسم خوارزميات


كشف الكائنات بشكل عام إلى نوعين رئيسيين: كاشفات من مرحلة واحدة (single-shot detectors)، وكاشفات من مرحلتين (two-stage detectors) [8].



الشكل (3-6): كشف الكائنات.

من أوائل المحاولات الناجحة لمعالجة مشكلة كشف الكائنات باستخدام التعلم العميق كان نموذج R-CNN، والذي يعني "المناطق مع ميزات الشبكات العصبية التلافيفية"، وقد طوره روس غيرشيك وفريقه في شركة Microsoft Research عام 2014 [9]. اعتمد هذا النموذج على دمج خوارزميات اقتراح المناطق مع الشبكات العصبية التلافيفية بهدف كشف الكائنات وتحديد مواقعها داخل الصور.

2-2-3 أنواع كاشفات الكائنات



الشكل (3-7): أمثلة على خوارزميات كشف الكائنات حسب مراحل المعالجة.

1-2-2-3 كشف الكائنات ذي المرحلة الواحدة

كشف الكائنات ذي المرحلة الواحدة يعتمد على معالجة الصورة المدخلة مرة واحدة فقط للتنبؤ بوجود الكائنات ومواقعها داخل الصورة. يتم معالجة الصورة كاملة في خطوة واحدة، مما يجعل هذه الطريقة فعالة من حيث استهلاك الموارد الحسابية. مع ذلك، فإن دقة الكشف باستخدام هذه الطريقة عادةً أقل مقارنةً بالطرق الأخرى، كما أنها أقل كفاءة في اكتشاف الكائنات الصغيرة. تُستخدم هذه الخوارزميات عادةً للكشف عن الكائنات في الوقت الحقيقي، خاصة في البيئات التي تقتصر مواردها الحسابية. يُعد نموذج YOLO من أشهر خوارزميات كشف الكائنات ذي المرحلة الواحدة، حيث يعتمد على شبكة عصبية تلافيفية كاملة لمعالجة الصورة.

3-2-2-2 كشف الكائنات بمرحلتين

الكشف عن الكائنات ثنائي المرحلة يعتمد على تمرير الصورة المدخلة مرتين من خلال النموذج للتنبؤ بوجود الكائنات وتحديد مواقعها. في التمرير الأول، يتم توليد مجموعة من المواقع المحتملة لوجود الكائنات، بينما يُستخدم التمرير الثاني لتحسين هذه المواقع وإعطاء التنبؤات النهائية. تتميز هذه الطريقة بدقة أعلى مقارنة بالكشف أحادي المرحلة، لكنها تتطلب قدرة حسابية أكبر [8].

بشكل عام، يعتمد اختيار طريقة الكشف بين أحادي المرحلة وثنائي المرحلة على متطلبات التطبيق والقيود المرتبطة به. عادةً ما تكون طريقة الكشف أحادي المرحلة أكثر ملاءمة للتطبيقات التي تتطلب الاستجابة في الوقت الحقيقي، بينما تكون طريقة الكشف ثنائي المرحلة أنسب للتطبيقات التي تكون فيها الدقة أولوية.


3-2-3 معايير تقييم أداء نماذج كشف الكائنات

1-3-2-3 مقياس التقاطع على الاتحاد (IoU - Intersection over Union)

يُعد مقياس التقاطع على الاتحاد من المقاييس الشائعة لتقييم دقة التحديد المكاني (الموقع والحجم) وحساب أخطاء التحديد في نماذج كشف الكائنات [8].

لحساب قيمة IoU بين الصندوق التنبؤي والصندوق الحقيقي (المرجعي)، يتم أولاً تحديد المساحة المشتركة بين الصندوقين اللذين يمثلان نفس الكائن. بعد ذلك، تُحسب المساحة الكلية المغطاة من قبل كلا الصندوقين، وتُعرف هذه بالـ "اتحاد"، بينما تُسمى المساحة المشتركة بينهما بـ "التقاطع".

يتم الحصول على قيمة IoU من خلال قسمة مساحة التقاطع على مساحة الاتحاد. وتمثل هذه النسبة مدى تطابق الصندوق التنبؤي مع الصندوق المرجعي، وبالتالي فهي تقدير فعال لمدى دقة التحديد المكاني للنموذج.



الشكل (3-8): حساب IoU.

2-3-2-3 مقياس الدقة المتوسطة (Average Precision - AP)

يُحسب مقياس الدقة المتوسطة (AP) من خلال حساب المساحة تحت منحنى العلاقة بين الدقة والاسترجاع لمجموعة من التنبؤات [8].

- **الاسترجاع (Recall)** يُقاس بنسبة عدد التنبؤات الصحيحة من بين جميع الحالات الفعلية لفئة معينة.
- **الدقة (Precision)** تمثل نسبة التنبؤات الصحيحة (الكائنات التي تم تحديدها بشكل صحيح) إلى إجمالي عدد التنبؤات التي قدّمها النموذج لتلك الفئة.

تُظهر العلاقة بين الدقة والاسترجاع نوعًا من التوازن، ويُرسم هذا التوازن كمنحنى يتم توليده عن طريق تغيير عتبة التصنيف. المساحة تحت هذا المنحنى تمثل الدقة المتوسطة لتلك الفئة. وعند حساب متوسط هذه القيم لجميع الفئات، نحصل على ما يُعرف بـ الدقة المتوسطة الإجمالية (mean Average Precision - mAP).

في سياق كشف الكائنات، لا تُستخدم الدقة والاسترجاع لتقييم تصنيف الفئات فقط، بل تُستخدم أيضًا لتقييم دقة تحديد مواقع الكائنات. يتم اعتبار التنبؤ إيجابيًا إذا كانت قيمة IoU أكبر من 0.5، وسلبًا إذا كانت أقل من 0.5.

4-2-3 خوارزمية YOLO (You Only Look Once)

يقترح نموذج YOLO (You Only Look Once) استخدام شبكة عصبية متكاملة تقوم بتحديد مواقع الكائنات داخل الصورة (من خلال إطارات التحديد) وتوقع الفئة التي ينتمي إليها كل كائن دفعة واحدة، ومن دون الحاجة إلى خطوات منفصلة. يختلف هذا النموذج جذريًا عن النماذج السابقة في كشف الكائنات، والتي كانت تعتمد على إعادة استخدام نماذج التصنيف (Classifiers) لتأدية مهمة الكشف [8].

اعتمد YOLO نهجًا مختلفًا كليًا في التعامل مع مشكلة كشف الكائنات، وحقق نتائج رائدة مقارنة ببقية النماذج المخصصة للكشف في الزمن الحقيقي، متفوقًا عليها بهامش كبير من حيث السرعة والكفاءة. فعلى سبيل المثال، تعمل خوارزميات مثل Faster R-CNN من خلال تحديد مناطق يُحتمل وجود كائنات فيها باستخدام شبكة اقتراح المناطق (Region Proposal Network)، ثم


تُجري التعرف على هذه المناطق بشكل منفصل. أما YOLO، فيقوم بجميع التنبؤات من خلال طبقة واحدة متصلة بالكامل (Fully Connected Layer)، مما يختصر الخطوات ويزيد من سرعة الأداء. النماذج التي تعتمد على اقتراح المناطق تحتاج إلى تنفيذ عدة تمريرات على الصورة نفسها، في حين أن YOLO يكتفي بتمرير واحد فقط. منذ إصدار YOLO الأول عام 2015، تم تطوير عدة إصدارات جديدة من النموذج، وقد أضاف كل إصدار تحسينات على ما سبقه، سواء من حيث السرعة أو الدقة أو الكفاءة العامة.

3-2-4-1 كيف تعمل خوارزمية YOLO؟

تعتمد خوارزمية YOLO (اختصارًا لـ You Only Look Once) على فكرة بسيطة وفعّالة، وهي تحليل الصورة دفعة واحدة لتحديد مواقع الكائنات داخلها وتسمية كل كائن منها بشكل مباشر. تقوم الخوارزمية بتقسيم الصورة إلى شبكة من الخلايا، وتكون كل خلية مسؤولة عن محاولة التنبؤ ما إذا كان هناك كائن ضمن نطاقها، وإذا وُجد، فإنها تقدّر مكانه بدقة على شكل "صندوق محيط" يحتوي على معلومات الموقع والحجم. الشكل (3-8) يوضح هذه العملية بشكل مرئي؛ ففي البداية تُعرض الصورة الأصلية، ثم يتم تقسيمها إلى شبكة، وتبدأ الخلايا بتحليل محتوى كل جزء، وبعدها تُرسم صناديق حول الكائنات المكتشفة مثل الكلب والدراجة والسيارة، مع تسميات لكل منها [8].

تبدأ الصورة رحلتها داخل نموذج YOLO بمرورها في شبكة عصبية تسمى DarkNet، حيث تُستخرج منها خصائص بصرية مهمة. بعدها، تُمرر هذه الخصائص إلى طبقات عصبية متصلة بالكامل (fully connected layers) تقوم بتوليد التوقعات المتعلقة بموقع كل كائن واحتمال انتمائه لفئة معينة. يظهر ذلك في الجزء السفلي من الشكل (3-8) حيث يتم تمثيل الصورة المدخلة بحجم

$448 \times 344 \times 8$ ، ويتم استخراج خصائصها عبر شبكة DarkNet لتصبح بحجم $7 \times 7 \times 1024$ ، ثم تمر على طبقة فيها 4096 وحدة عصبية، وتخرج النتيجة على شكل شبكة 7×307 . كل خلية من الشبكة تكون مسؤولة عن التنبؤ بعدة صناديق، وكل صندوق يحتوي على خمسة عناصر رئيسية: الإحداثيات (x, y) لمركز الكائن، العرض (w) ، الارتفاع (h) ، ودرجة الثقة (object score)، بالإضافة إلى احتمالات تصنيفه ضمن الفئات الممكنة (مثل كلب، دراجة، سيارة وغيرها) [8].



الشكل (3-9): هيكل خوارزمية YOLO.

يمكن تلخيص خطوات عمل YOLO فيما يلي:

1. يتم إدخال الصورة إلى شبكة عصبية تلافيفية (CNN) لاستخراج الخصائص المهمة منها.
2. تُمرر هذه الخصائص إلى طبقات عصبية كثيفة لتوقع إحداثيات الصناديق واحتمالات الفئات.
3. تُقسّم الصورة إلى شبكة من الخلايا، بحيث تتنبأ كل خلية بعدة صناديق تصف احتمال وجود كائن فيها.


4. يخرج النموذج بمجموعة من الصناديق المصحوبة باحتمالات التصنيف لكل خلية في الشبكة.
5. يتم تطبيق خوارزمية تُدعى Non-Max Suppression لإزالة الصناديق المتكررة والمتداخلة، مع الاحتفاظ فقط بالصندوق الذي يحمل أعلى درجة ثقة.
6. تكون النتيجة النهائية مجموعة صناديق مرفقة بتسميات الفئات، تمثل الكائنات المكتشفة في الصورة.

من أبرز ما يميز YOLO هو أنه يعالج الصورة دفعة واحدة، مما يجعله سريعًا جدًا مقارنة بالخوارزميات التي تستخدم مرحلتين للكشف، مثل R-CNN والإصدارات المتقدمة منه.

3-3 تقنية OCR

1-3-3 ماهي تقنية OCR؟

التعرف الضوئي على الحروف (OCR) هو تقنية تستخدم لاستخراج البيانات تلقائيًا من الصور التي تحتوي على نصوص، وتحويلها بسرعة إلى صيغة يمكن للكمبيوتر قراءتها والتعامل معها [10].



الشكل (10-3): تقنية OCR.

ويُعرف أحيانًا باسم التعرف على النصوص. حيث يقوم برنامج OCR بالتعرف على النصوص الموجودة في المستندات الممسوحة ضوئيًا، أو الصور الملتقطة بالكاميرا، أو ملفات PDF التي تحتوي فقط على صور. يعمل البرنامج على تحديد الأحرف داخل الصورة، ثم تجميعها في كلمات، وبعدها في جمل، مما يجعل من الممكن الوصول إلى النص الأصلي وتحريره. وهذا يوفّر الكثير من الجهد الذي قد يُهدر في إدخال البيانات يدويًا [10].

تستخدم أنظمة OCR مزيجًا من الأجهزة والبرمجيات لتحويل المستندات الورقية أو المطبوعة إلى نص يمكن للآلة قراءته. فالأجهزة، مثل الماسحات الضوئية أو الدوائر الإلكترونية المتخصصة، تقوم بقراءة النصوص، بينما تتولى البرمجيات عمليات المعالجة المتقدمة.

ويمكن لبرامج OCR الاستفادة من تقنيات الذكاء الاصطناعي (AI) لتطبيق أساليب أكثر تطورًا تُعرف باسم التعرف الذكي على الحروف (ICR)، والتي تساعد في التعرف على اللغات المختلفة أو حتى الخط اليدوي.

تستخدم المؤسسات هذه التقنية عادة لتحويل المستندات القانونية أو التاريخية المطبوعة إلى ملفات PDF قابلة للتعديل والبحث، وكأنها كُتبت باستخدام برنامج لمعالجة النصوص [10].

2-3-3 تاريخ تقنية OCR

في عام 1974، أسّس "راي كورزويل" شركة تُدعى Kurzweil Computer Products, Inc، وابتكر منتج OCR مميز قادر على التعرف على النصوص المطبوعة بمختلف أنواع الخطوط تقريبًا، وهو ما يُعرف بـ "Omni-font OCR". رأى كورزويل أن أفضل استخدام لهذه التقنية هو مساعد الأشخاص

الذين يعانون من ضعف البصر، فقام بتطوير جهاز يمكنه "قراءة" النصوص بصوت عالٍ باستخدام تقنية تحويل النص إلى كلام (Text-to-Speech) [11].

وفي عام 1980، باع كورزويل شركته إلى شركة "زيروكس" Xerox، التي كانت ترغب في تطوير وتسويق التقنية لتحويل النصوص من الورق إلى الكمبيوتر.

أصبحت تقنية OCR شائعة في أوائل التسعينيات، حيث استُخدمت بكثرة في تحويل الصحف التاريخية إلى صيغة رقمية. ومنذ ذلك الوقت، تطورت هذه التقنية كثيرًا، وأصبح من الممكن اليوم تحقيق دقة عالية جدًا تصل إلى حد الكمال تقريبًا في قراءة النصوص. كما بات بالإمكان استخدام طرق متقدمة لأتمتة معالجة المستندات المعقدة.

قبل ظهور تقنية OCR، كانت الطريقة الوحيدة لتحويل مستند ورقي إلى صيغة رقمية هي كتابة النص يدويًا مرة أخرى، وهي عملية تستغرق وقتًا طويلًا، وتؤدي غالبًا إلى أخطاء في الإدخال. أما اليوم، فأصبحت خدمات OCR متاحة بسهولة للجميع. على سبيل المثال، يمكن استخدام خدمة Google Cloud Vision OCR لمسح المستندات ضوئيًا وتخزينها على الهاتف الذكي [11].

3-3-3 كيف تعمل تقنية OCR؟

تستخدم برامج OCR الماسح الضوئي (السكرانر) لتحويل النسخة الورقية من المستندات إلى نص رقمي قابل للتعديل. يمكن تشغيل برنامج OCR كبرنامج مستقل، أو كواجهة برمجية (API)، أو كخدمة عبر الإنترنت [10].



الشكل (3-11): خطوات عمل تقنية OCR.

1. **الحصول على الصورة (Image acquisition):** يتم نسخ جميع صفحات المستند ضوئياً، ثم

يحول محرك OCR المستند إلى صورة ذات لونين فقط (أبيض وأسود). بعدها يحلل البرنامج

الصورة لتحديد الأجزاء الداكنة والفاتحة:

- **الأجزاء الداكنة:** يُفترض أنها حروف أو رموز يجب التعرف عليها.

- **الأجزاء الفاتحة:** تُعتبر الخلفية.

2. **المعالجة المسبقة (Preprocessing):** في هذه المرحلة، يتم "تنظيف" الصورة الرقمية من أي

نقاط أو شوائب غير ضرورية. تشمل هذه المرحلة:

- تصحيح الميل (Deskewing): تعديل ميل الصورة إذا كانت مائلة عند المسح.

- إزالة الخطوط أو الإطارات غير الضرورية التي كانت جزءاً من الصورة المطبوعة.

- تحديد ما إذا كان هناك نص مكتوب بخط اليد ضمن المستند.

3. **التعرف على النصوص (Text recognition):** يبدأ البرنامج بتحليل الأجزاء الداكنة لاكتشاف

الحروف، الأرقام، أو الرموز. يتم ذلك عادةً حرفاً حرفاً، أو كلمة بكلمة، أو فقرة بفقرة. يستخدم

البرنامج أحد طريقتين:

- **التعرف بالنمط (Pattern recognition):** في هذه الطريقة، يتم تدريب البرنامج مسبقًا على مجموعة من الخطوط (Fonts) لتتم مقارنة الأحرف في المستند مع أنماط محفوظة. كل شكل مميز يُعرف باسم "رمز مرئي" (Glyph). لكن، يجب أن يكون الخط الموجود في المستند من الخطوط التي يعرفها البرنامج مسبقًا.

- **التعرف على السمات (Feature recognition):** إذا لم يكن الخط معروفًا للبرنامج، فإنه يستخدم قواعد خاصة للتعرف على الحروف من خلال سماتها، مثل:

- عدد الخطوط المائلة
- أماكن تقاطع الخطوط
- الحلقات أو الانحناءات

مثلًا: حرف "A" الكبير يُعرف بأنه يتكوّن من خطين مائلين يلتقيان في الأعلى، ويتوسطهما خط أفقي. بعد التعرف على الحرف، يتم تحويله إلى رمز ASCII، وهو رمز قياسي يمكن للكمبيوتر معالجته.

4. **التعرف على تخطيط الصفحة (Layout recognition):** البرامج المتقدمة من OCR لا تكتفي بالتعرف على الحروف، بل تقوم أيضًا بتحليل ترتيب الصفحة، وتقسمها إلى فقرات نص، جداول وصور. ثم تقسم الأسطر إلى كلمات، والكلمات إلى حروف، وتقارنها بالنماذج المحفوظة لتحديد النص الصحيح.

5. **المعالجة اللاحقة (Postprocessing):** في النهاية، يتم حفظ المعلومات التي تم جمعها كملف رقمي يمكن تعديله، مثل ملفات PDF أو Word. بعض الأنظمة تحتفظ بنسخة من الصورة الأصلية والنسخة المعالجة للمقارنة أو للمراجعة لاحقًا، مما يسهل إدارة المستندات [10].

3-3-4 أنواع تقنية OCR

1. OCR البسيط (Simple OCR): يعتمد هذا النوع على التعرف على كل حرف على حدة من خلال

مطابقة الأشكال (النمط). يقوم بمقارنة كل حرف يتم مسحه ضوئياً مع الحروف المخزنة مسبقاً

في قاعدة بيانات البرنامج. لكن نظراً لوجود عدد هائل من الخطوط واللغات المختلفة، فإن هذا

النوع يواجه صعوبة في التعرف على مستندات متنوعة، ويكون محدود الاستخدام [10].

2. التعرف الضوئي على العلامات (OMR - Optical Mark Recognition): هذا النوع مخصص

للتعرف على العلامات والرموز، وليس الحروف. مثلاً:

- مربعات أو دوائر التحديد في الاستبيانات.

- التوقيعات.

- الشعارات والرموز والعلامات المائية.

يقوم البرنامج بمطابقة هذه العلامات مع صور مخزنة لديه، بنفس الطريقة التي يعمل بها OCR

البسيط.

3. التعرف الذكي على الحروف (ICR - Intelligent Character Recognition): هذا النوع

يستخدم الذكاء الاصطناعي (AI)، ويعتمد على التعلم الآلي أو التعلم العميق. البرنامج لا يكتفي

بالمقارنة، بل يتعلم مع الوقت من خلال التدريب المستمر، مثلما يفعل الإنسان. يستخدم شبكة

عصبية لتحليل الحروف مراراً وتكراراً لاكتشاف السمات المميزة، مثل:

- أماكن وجود الانحناءات

- تقاطعات الخطوط

• الحلقات

• عدد واتجاه الخطوط

4. التعرف الذكي على الكلمات (Intelligent Word Recognition): هذا هو التطور الطبيعي

للنوع السابق (ICR)، لكنه يتعرف على الكلمة كاملة من صورة واحدة، وليس حرفًا حرفًا. لأن

الذكاء الاصطناعي أصبح مدربيًا على التعرف على الكلمات دفعة واحدة، فإن هذا النوع أسرع

وأكثر كفاءة في معالجة النصوص [10].

3-5 فوائد استخدام تقنية OCR

• توفير التكاليف: من خلال تقليل أو إلغاء الحاجة إلى إدخال البيانات يدويًا بشكل متكرر وممل.

• تسريع سير العمل: يمكن إدخال المستندات المطبوعة أو النماذج المكتوبة بسهولة، مما يساعد

في تسريع البحث والوصول إلى البيانات الرقمية.

• أتمتة معالجة المستندات: تساعد في توجيه الملفات تلقائيًا، ومعالجة المحتوى، وتحضيره

لتحليله لاحقًا (مثل تحليل النصوص).

• توفير مساحة التخزين: تقلل من الحاجة إلى تخزين كميات كبيرة من الأوراق، مما يعني توفير

تكاليف التخزين الورقي.

• حماية البيانات: عند تحويل المستندات الورقية إلى ملفات رقمية، يمكن تخزينها بشكل مركزي

وآمن، مما يحميها من الحريق أو السرقة أو الضياع في أماكن التخزين التقليدية مثل خزائن

البنوك.

- تسهيل الوصول للمكفوفين أو ضعاف البصر: تساعد في جعل المحتوى المقروء متاحًا للموظفين والعملاء من ذوي الإعاقات البصرية.
- تحسين جودة الخدمة: من خلال توفير معلومات دقيقة ومحدثة للموظفين، ما يعزز سرعة وجودة تعاملهم مع العملاء.

6-3-3 حالات استخدام تقنية OCR

أكثر استخدام شائع لتقنية التعرف الضوئي على الحروف (OCR) هو تحويل المستندات الورقية المطبوعة إلى ملفات نصية رقمية يمكن للكمبيوتر قراءتها. فبعد أن يتم مسح الورقة ضوئيًا ومعالجتها باستخدام هذه التقنية، يمكن تعديل النص الموجود فيها باستخدام برامج تحرير النصوص مثل Microsoft Word أو Google Docs. وتُستخدم OCR في مجالات كثيرة لتسريع وتسهيل العمل، مثل التعليم والبنوك والرعاية الصحية والنقل، حيث تساهم في معالجة واسترجاع مستندات القروض، وسجلات المرضى، واستثمارات التأمين، والفواتير، والإيصالات، وغيرها من المستندات المكتوبة.

وفي كثير من الأحيان، تعمل تقنية OCR في الخلفية دون أن يشعر بها المستخدم، فهي تندمج في العديد من الأنظمة والخدمات المعروفة التي نستخدمها في حياتنا اليومية. كما تدخل هذه التقنية في استخدامات مهمة ولكنها غير مشهورة، مثل أتمتة إدخال البيانات بدلًا من كتابتها يدويًا، ومساعدة المكفوفين وضعاف البصر في قراءة النصوص، وفهرسة المستندات لمحركات البحث. ومن أمثلة ذلك استخدامها في قراءة الجوازات، ولوحات السيارات، والفواتير، وكشوف الحسابات البنكية،

والشيكات، وبطاقات الأعمال، وحتى في أنظمة تحويل النصوص المكتوبة إلى ملفات رقمية قابلة للبحث.



الشكل (3-12): استخدام تقنية OCR للتعرف على الأرقام.

كما تساعد OCR في تحسين تحليل البيانات الضخمة من خلال تحويل المستندات الورقية أو الصور الممسوحة ضوئياً إلى ملفات PDF رقمية يمكن للأنظمة قراءتها والبحث داخلها. وحتى تتمكن أنظمة تحليل البيانات من استخراج معلومات مفيدة، يجب أولاً تحويل المستندات التي لا تحتوي على طبقات نص إلى مستندات رقمية قابلة للقراءة باستخدام OCR. ومن خلال هذه التقنية، يمكن إدخال المستندات الممسوحة ضوئياً في أنظمة البيانات الضخمة التي تستطيع تحليل معلومات العملاء من مستندات مثل العقود وكشوف الحسابات. وهذا يغني المؤسسات عن الحاجة إلى قيام الموظفين بمراجعة الصور يدوياً وإدخال البيانات بأنفسهم، مما يوفر الكثير من الوقت والجهد. كما أن برامج OCR قادرة على استخراج النص من الصور وحفظه كملف نصي، وهي تدعم صيغاً متعددة مثل jpg وjpeg وpng وbmp وtiff وpdf.

7-3-3 أحدث التطورات في تقنية OCR

لقد تطورت تقنية التعرف الضوئي على الحروف (OCR) بشكل كبير منذ أولى أنظمتها التجارية في عام 1974، ولا يزال التقدم مستمرًا. فبرامج OCR المتقدمة اليوم قادرة على استخراج المعلومات المهمة من المستندات حتى في ظروف غير مثالية، مثل الخطوط غير المنتظمة، أو دقة الصور المنخفضة، أو الإضاءة السيئة الناتجة عن التصوير عبر الهواتف، أو تنوع الألوان والخلفيات.

وبفضل دمج تقنيات الرؤية الحاسوبية ومعالجة اللغة الطبيعية، إضافة إلى تحسين طرق تمثيل المعلومات وتطوير نماذج الذكاء الاصطناعي، أصبحت الشركات اليوم قادرة على الاستفادة من أفضل مستويات فهم المستندات. وتشمل هذه التحسينات القدرة على تحليل تنسيق الصفحة وترتيب قراءة النصوص في المستندات المعقدة، إلى جانب فهم العناصر البصرية وتمثيلها على شكل مخططات ورسومات توضيحية. كما تعتمد بعض برامج OCR الحديثة على الذكاء الاصطناعي التوليدي، مما يساهم في تنظيم بيانات المستندات بشكل أسرع. وهكذا، فإن هذه "التقنية القديمة" لا تزال تتعلم مهارات جديدة يوماً بعد يوم.

4 الفصل الرابع: تصميم النظام

1-4 وصف فكرة النظام وأهدافه التعليمية

في سياق تصميم نظام تفاعلي يُسهم في دعم العملية التعليمية لدى الأطفال، تم تطوير نظام يستخدم تقنيات الذكاء الاصطناعي والرؤية الحاسوبية بهدف تعزيز الفهم اللغوي والبصري لديهم. يقوم النظام على مبدأ التفاعل الحي، حيث يُعرض أمام كاميرا الجهاز عنصر ما—سواء كان كائنًا، لونيًا، أو رقمًا—ليتعرف عليه البرنامج تلقائيًا، ثم ينطق اسمه بصوت واضح ومباشر. وقد صُمم هذا التفاعل ليحدث بشكل سلس وسريع، بما يعزز من ارتباط الطفل بالصوت والصورة في آن واحد، ما يسهم في ترسيخ المعلومات بطريقة طبيعية وقرينة من أسلوب التعلم الحسي الذي يميز مراحل الطفولة المبكرة.

تم بناء النظام ليجمع بين البساطة في الاستخدام والدقة في الأداء، بحيث يتمكن الطفل من التعامل معه دون الحاجة إلى إشراف دائم من البالغين، مما يتيح له اكتساب المعرفة بطريقة مرنة ومستقلة. ويُعد النطق الصوتي أحد العناصر المحورية في التصميم، إذ يُقدّم المحتوى الصوتي باللغة العربية بهدف تنمية المهارات اللغوية لدى الطفل. كما تم ربط هذا الأداء التعليمي بواجهة رسومية جذابة، تُراعي طبيعة المتعلم الطفل من حيث الألوان والحجم وسهولة التفاعل.

تتجلى القيمة التعليمية للنظام في كونه لا يعتمد فقط على تقديم المعلومة، بل على دمج الطفل في تجربة تعلم تفاعلية تساعد على إدراك العناصر المحيطة به وتمييزها، مع تعزيز قدرته على الربط بين الشكل البصري والمسموع، وهو ما يُعد من الركائز الأساسية في بناء المفاهيم الإدراكية واللغوية في مرحلة التأسيس المعرفي. وقد جاءت أهداف النظام منسجمة مع هذا التوجه، حيث سعى إلى أن

يكون وسيلة تعليمية فعالة قادرة على تحفيز الأطفال للتعلم بطريقة ممتعة، وتعزيز نطقهم الصحيح، وتوسيع مداركهم عبر بيئة ذكية مدعومة بالتقنيات الحديثة.

2-4 مكونات النظام المادية والبرمجية

1-2-4 مكونات النظام المادية (Hardware)

بالاعتماد على بساطة التصميم وفاعليته، تم الاكتفاء في تنفيذ النظام بجهاز حاسوب محمول (لابتوب) يُوفّر العناصر المادية الأساسية لتشغيل النظام، دون الحاجة إلى أجهزة خارجية إضافية. إذ يحتوي الحاسوب المستخدم على كاميرا مدمجة تُستخدم لالتقاط الصور المباشرة للعناصر المراد التعرف عليها، سواء كانت كائنات، ألوان، أو أرقام. وتُعد الكاميرا المدمجة كافية من حيث الدقة وجودة الصورة لتلبية متطلبات النظام في عمليات المعالجة البصرية. كما يتم الاعتماد على مكبر الصوت الداخلي في الحاسوب لتشغيل الملفات الصوتية الناتجة عن عملية النطق الآلي، مما يُسهّم في تبسيط البنية المادية للنظام وجعل تجربته أكثر سلاسة وقابلية للنقل والاستخدام على نطاق واسع، دون الحاجة إلى تجهيزات تقنية متقدمة أو مكلفة.

2-2-4 مكونات النظام البرمجية (Software)

في تطوير هذا النظام، تم الاعتماد على مجموعة من المكتبات والخوارزميات الأساسية في مجال الذكاء الاصطناعي والرؤية الحاسوبية، والتي تُعد الركيزة التي بُني عليها أداء النظام وفعاليته.

تُستخدم مكتبة OpenCV لمعالجة الصور الملتقطة من كاميرا الجهاز وتحليلها، حيث تشمل مهامها تحويل ألوان الصور إلى فضاء HSV لتحديد اللون السائد، وتحسين جودة الصور قبل المعالجة. كما تدعم مكتبة NumPy العمليات الحسابية الضرورية على المصفوفات البصرية والبيانات الرقمية.



الشكل (4-1): مكتبة OpenCV.



الشكل (4-2): مكتبة NumPy.


للكشف والتعرف على الكائنات المختلفة داخل الصور، تم توظيف خوارزمية YOLO (You Only Look Once)، نظرًا لما تتمتع به من سرعة ودقة في الكشف في الوقت الحقيقي. ويعتمد هذا النموذج على قاعدة بيانات مدربة مسبقًا تُعرف باسم COCO Dataset، والتي تحتوي على أكثر من 200,000 صورة مُصنفة ضمن 80 فئة متنوعة من الكائنات الشائعة في البيئات الواقعية. هذا الاعتماد على إصدار مدرب مسبقًا من YOLO المبني على COCO يسرّع عملية التطوير ويضمن دقة معقولة في التعرف على الكائنات.



الشكل (4-3): COCO Dataset.

أما بالنسبة للتعرف على الأرقام ضمن الصور، فقد تم اعتماد تقنية التعرف البصري على الحروف (OCR) كخيار فعال لاستخراج الأرقام بدقة من الصور. يتم ذلك عبر دمج مكتبة OpenCV في مرحلة ما قبل المعالجة لتحسين الصور وتقليل الضجيج، ثم تمريرها إلى محرك OCR مثل Tesseract لاستخراج النصوص الرقمية، مما يتيح تحويلها لاحقاً إلى صوت منطوق.


كما تم تطوير واجهة مستخدم رسومية بسيطة باستخدام مكتبة Tkinter، تتيح للمستخدمين التفاعل مع النظام بسهولة، مع دعم عرض النتائج بصرياً وسمعيّاً في آن واحد، مما يجعل النظام مناسباً خاصةً للاستخدام التعليمي



الشكل (4-4): واجهة بسيطة مصممة باستخدام Tkinter.

تم تطوير النظام باستخدام لغة Python، والتي تُعد من أكثر لغات البرمجة شيوعًا في مجالات الذكاء الاصطناعي والرؤية الحاسوبية. تتميز Python ببنيته البسيطة وسهولة قراءة الكود، مما يتيح تطوير البرمجيات بشكل سريع وفعال. كما تدعم اللغة عددًا هائلًا من المكتبات المتخصصة في المعالجة الصورية، تعلم الآلة، التعلم العميق، والتفاعل مع الأجهزة الطرفية مثل الكاميرات والمستشعرات.

3-4 مخطط معالجة البيانات



الشكل (4-5): مخطط معالجة البيانات.

يوضح الشكل التخطيطي (4-5) تسلسل خطوات معالجة البيانات التي يمر بها النظام بدءًا من التقاط الصورة ووصولاً إلى تقديم التعليقات الصوتية للطفل. فيما يلي شرح تفصيلي لكل خطوة:

1. **مدخل الكاميرا (حية) – Camera Input (Live):** تبدأ العملية بالتقاط صورة مباشرة من كاميرا الجهاز بشكل حي ومستمر، وهي نقطة الانطلاق الأساسية لمعالجة البيانات.
2. **معالجة الإطار المسبق – Frame Preprocessing:** يتم في هذه المرحلة إجراء بعض المعالجات المسبقة على الإطار (الصورة)، مثل تصغير الحجم، تحويل الألوان، وتصفية الضوضاء، بهدف تحسين جودة البيانات المُدخلة قبل تطبيق تقنيات التحليل المختلفة.
3. **كشف الحيوانات باستخدام YOLO – YOLO Animal Detection:** يتم تمرير الإطار إلى نموذج YOLO المُدرَّب مسبقًا، للكشف عن الكائنات الحيوانية في الصورة. تتميز هذه الخطوة بالدقة والسرعة، ما يجعلها مناسبة للتعامل مع الصور في الوقت الحقيقي.
4. **كشف الألوان باستخدام HSV – HSV Color Detection:** بعد ذلك، يتم تحويل الإطار اللوني إلى فضاء HSV، ومن ثم تحليل الألوان السائدة في الصورة باستخدام خوارزميات تعتمد على عتبات محددة لكل لون مستهدف، ما يسمح بالتعرف على لون العنصر المراد وصفه.
5. **التعرف على الأرقام باستخدام OCR – OCR Number Recognition:** إذا كانت الصورة تحتوي على أرقام، يتم استخدام تقنية التعرف البصري على الحروف (OCR) لاستخراج الرقم كنص رقمي. تُعد هذه الخطوة مهمة لتفسير العناصر الرقمية داخل الصور، مثل لوحات أو بطاقات.
6. **تجميع النصوص (بالعربية) – Text Aggregation (Arabic):** يتم في هذه المرحلة دمج المعلومات المستخرجة من المراحل السابقة (اسم الحيوان، لونه، رقمه إن وُجد) في نص عربي موحد وجاهز للنطق.

7. تحويل النص العربي إلى كلام – **Arabic Text-To-Speech**: يُحوّل النص العربي الناتج إلى

صوت منطوق باستخدام مكتبة تحويل النص إلى كلام، مما يسهل على الطفل فهم واستيعاب

المعلومة بشكل سمعي.

8. تعليقات صوتية فورية للطفل – **Real-Time Voice Feedback to the Child**: أخيرًا، يتم

تشغيل الصوت الناتج مباشرة ليصل إلى الطفل في الزمن الحقيقي، ما يحقق التفاعل الفوري،

ويعزز من الأثر التعليمي والترفيهي للنظام.

4-4 وظائف النظام

1-4-4 وظيفة التعرف على الألوان

يلتقط النظام صورة للعنصر المعروض أمام الكاميرا، ثم يحوّلها إلى نموذج HSV لتحديد اللون

السائد. بعد التعرف، يُعرض اسم اللون على الشاشة ويُشغّل الملف الصوتي المسجل المرتبط به.

2-4-4 وظيفة التعرف على الأرقام

يُستخدم نظام OCR لاستخراج الرقم الظاهر في الصورة بعد إجراء معالجة بصرية. يتم عرض الرقم

على الواجهة بشكل نصي، ويُشغّل الملف الصوتي المخصص له تلقائيًا.

3-4-4 وظيفة التعرف على الكائنات

يعتمد النظام على نموذج YOLO المدرب مسبقًا لتحديد الكائنات ضمن الصورة بالاستناد إلى بيانات


COCO. بعد اكتشاف الكائن، يُعرض اسمه على الشاشة، ويمكن عرض صورة رمزية له، ثم يُشغّل

الملف الصوتي المقابل.

4-4-4 وظيفة النطق الصوتي

يتم تشغيل ملف صوتي مسجل مسبقًا باستخدام مكتبة Playsound يتوافق مع النتيجة المعروضة (اسم اللون، الرقم، أو الكائن). يدعم النظام النطق بلغة واحدة فقط، وتتم عملية التشغيل تلقائيًا دون تدخل من المستخدم.


5-4 مخطط الواجهات



الشكل (4-6): مخطط الواجهات.

6-4 مخطط حالات الاستخدام

المخطط في الشكل (4-7) يوضح حالات الاستخدام لنظام يتضمن واجهتين رئيسيتين: واحدة للمستخدم وأخرى لمسؤول النظام. بالنسبة للمستخدم، يمكنه تحميل الصور واستخدام الكاميرا لاكتشاف الحيوانات والأرقام والألوان، كما يمكنه التنقل بين الصفحات وعرض النتائج. بينما مسؤول النظام يمكنه عرض الإحصائيات وتعديل النظام من خلال إضافة أو حذف الميزات.




الشكل (4-7): مخطط حالات الاستخدام.

5 الفصل الخامس: التنفيذ العملي


1-5 المخططات التدفقية

1-1-5 وظيفة التعرف على الحيوانات




الشكل (5-1): المخطط التدفقي لوظيفة التعرف على الحيوانات.

2-1-5 وظيفة التعرف على الألوان



الشكل (5-2): المخطط التدفقي لوظيفة التعرف على الألوان.

3-1-5 وظيفة التعرف على الأرقام



الشكل (3-5): المخطط التدفقي لوظيفة التعرف على الأرقام.

2-5 التطبيق العملي النهائي


يبدأ التطبيق العملي للنظام التعليمي الموجه للأطفال بفتح الواجهة الرئيسية كما هو موضح في الشكل (4-5)، والتي تحتوي على ثلاثة أزرار مخصصة لكل وظيفة من وظائف النظام: التعرف على الألوان، التعرف على الحروف، والتعرف على الأرقام. عند الضغط على الزر المخصص للتعرف على الحيوانات، تُعرض واجهة جديدة كما يظهر في الشكل (5-5)، حيث يظهر للطفل خياران هما "فتح الكاميرا" و"الرجوع". عند اختيار "فتح الكاميرا"، يُسمح للطفل بتوجيه الكاميرا لالتقاط صورة لأي حيوان ليتمكن النظام من التعرف عليه وتشغيل الملف الصوتي الخاص به، كما هو موضح في الشكل (5-6).



الشكل (4-5): الواجهة الرئيسية.



الشكل (5-5): واجهة التعرف على الحيوانات.




الشكل (5-6): التعرف على الحيوانات.

عند الانتقال إلى وظيفة التعرف على الألوان، تظهر واجهة مشابهة كما في الشكل (5-7)، والتي تحتوي على زر "فتح الكاميرا" لتمكين الطفل من وضع أي جسم أمام الكاميرا لتحديد لونه وتشغيل الصوت المرتبط به، كما هو موضح في الشكل (5-8).



الشكل (5-7): واجهة التعرف على الألوان.



الشكل (5-8): التعرف على الألوان.

أما بالنسبة لوظيفة التعرف على الأرقام، فبعد الضغط على الزر المخصص لذلك، تفتح واجهة مماثلة كما يظهر في الشكل (5-9)، حيث يمكن للطفل وضع رقم أمام الكاميرا ليقوم النظام بالتعرف عليه وتشغيل الصوت المرافق لهذا الرقم، كما هو موضح في الشكل (5-10).



الشكل (5-9): واجهة التعرف على الأرقام.



الشكل (5-10): التعرف على الأرقام.

3-5 النتائج

1-3-5 مقاييس أداء النماذج في الذكاء الاصطناعي

تعد المقاييس الأساسية لقياس أداء النماذج في مجال الذكاء الاصطناعي والتعلم الآلي أمرًا حيويًا لفهم دقة وكفاءة النماذج. تختلف هذه المقاييس حسب نوع المهمة والبيانات المستخدمة. في هذا السياق، نعرض مجموعة من المقاييس الأساسية التي تُستخدم لتقييم جودة النماذج وتحديد مدى قدرتها على التنبؤ بشكل صحيح.

1. معدل الدقة المتوسط (mAP): هو مقياس يُستخدم لتقييم النماذج في تصنيف متعدد الفئات أو في مهام الكشف عن الكائنات. يتم حسابه عن طريق أخذ متوسط دقة الاسترجاع عبر جميع الفئات.

$$mAP = \frac{1}{n} \sum_{k=1}^{k=n} AP_k$$

حيث: AP متوسط دقة الاسترجاع للفئة k ، و n عدد الفئات.

2. الدقة (Precision): تقيس الدقة نسبة التنبؤات الإيجابية الصحيحة من إجمالي التنبؤات الإيجابية المتنبأ بها.

$$Precision = \frac{TP}{TP + FP}$$

حيث: TP التنبؤات الإيجابية الصحيحة، و FP التنبؤات الإيجابية الخاطئة.

3. **الاسترجاع (Recall):** يعكس الاسترجاع قدرة النموذج على اكتشاف الحالات الإيجابية الحقيقية. ويحسب كالتالي:

$$Recall = \frac{TP}{TP + FN}$$

حيث: TP التنبؤات الإيجابية الصحيحة، و FN التنبؤات السلبية الخاطئة.

4. **مصفوفة الارتباك (Confusion Matrix):** تُستخدم مصفوفة الارتباك لعرض نتائج التصنيف في شكل جدول يُظهر التنبؤات الصحيحة والخاطئة عبر الفئات المختلفة.

5. **الإيجابيات الخاطئة (False Positives):** الحالات التي تم تصنيفها بشكل خاطئ على أنها إيجابية.

$$False\ positive\ rate\ (FPR) = \frac{FP}{FP + TN}$$

حيث: FP التنبؤات الإيجابية الخاطئة، و TN التنبؤات السلبية الصحيحة.

6. **السلبات الخاطئة (False Negatives):** الحالات التي تم تصنيفها بشكل خاطئ على أنها سلبية.

$$False\ negative\ rate\ (FNR) = \frac{FN}{FN + TP}$$

حيث: FN التنبؤات السلبية الخاطئة، و TP التنبؤات الإيجابية الصحيحة.

7. **زمن الاستجابة أو التنبؤ (Latency):** يُقاس زمن الاستجابة من خلال الوقت الذي يستغرقه النموذج لإعطاء استجابة بعد تلقي البيانات المدخلة.

$$Letancy = \frac{Response\ Time}{Number\ of\ Input\ Data}$$

2-3-5 كشف الحيوانات

بعد الانتهاء من تدريب نموذج YOLOv11 على مجموعة بيانات مخصصة لكشف الحيوانات، تم تحليل أداء النموذج باستخدام مجموعة من مؤشرات التقييم مثل الدقة (Precision) والاستدعاء (Recall) ومتوسط الدقة (mAP).

1-2-3-5 كشف العُقاب باستخدام YOLOv11

أظهرت النتائج الموضحة في الجدول (1-5) أن النموذج حقق دقة عالية مع أداء ممتاز في مختلف العتبات. تشير هذه القيم إلى قدرة النموذج على الكشف الفعال عن الكائنات مع تقليل الأخطاء، مما يعكس جودة أدائه. كما يبين الجدول سرعة المعالجة لكل مرحلة (معالجة مسبقة، استدلال، ومعالجة لاحقة)، مما يوفر نظرة شاملة على كفاءة النموذج.

```

Ultralytics 8.3.168 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tesla T4, 15095MiB)
YOLO11m summary (fused): 125 layers, 20,030,803 parameters, 0 gradients, 67.6 GFLOPs
val: Fast image access (ping: 0.0±0.0 ms, read: 1038.4±455.8 MB/s, size: 50.9 KB)
val: Scanning /content/a/valid/labels.cache... 166 images, 0 backgrounds, 0 corrupt: 100%|██████████| 166/166 [00:00<?, ?it/s]
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%|██████████| 11/11 [00:05<00:00, 2.14it/s]
   all      166       179      0.926    0.908    0.956    0.824
Speed: 1.5ms preprocess, 18.8ms inference, 0.0ms loss, 3.2ms postprocess per image
Results saved to runs/detect/val6
mAP50: 0.9563720725122674
mAP50-95: 0.8237116658556257


```

الشكل (5-11): أداء نموذج كشف العُقاب.

الجدول (5-1): نتائج أداء النموذج.

المقياس	mAP50	mAP50-95	سرعة المعالجة المسبقة	سرعة الاستدلال	الخسارة	سرعة المعالجة اللاحقة
القيمة	0.956	0.824	1.5 ms	18.8 ms	0.0 ms	3.2 ms


يوضح منحنى الاستدعاء-الثقة (الشكل 5-12) العلاقة العكسية بين الاستدعاء ومستوى الثقة، حيث يؤدي زيادة الثقة إلى انخفاض الاستدعاء. هذا يبرز أهمية تحديد العتبة المثلى للثقة لتحقيق التوازن بين الحساسية والدقة. في نفس السياق، يظهر منحنى الدقة-الاستدعاء (الشكل 5-13) أداء النموذج عند مستويات مختلفة من الاستدعاء، حيث يقترب المنحنى من الزاوية العلوية اليمنى، مما يدل على تحسين الأداء مع الحفاظ على دقة عالية في معظم مستويات الاستدعاء.



الشكل (5-12): منحنى الاستدعاء - الثقة لنموذج كشف العقاب.

الجدول (5-2): نتائج منحنى الاستدعاء - الثقة لنموذج كشف العقاب.

الحد الأدنى للثقة (Confidence)	الاستدعاء عند هذا الحد (Recall)
0.000	0.97




الشكل (5-13): منحنى الدقة - الاستدعاء لنموذج كشف العقاب.

الجدول (5-3): نتائج منحنى الدقة - الاستدعاء لنموذج كشف العقاب.


المقياس	القيمة
mAP@0.5 لجميع الفئات	0.956

تُظهر صور الكشف على العينات (الشكل 5-14) نتائج الكشف التي أنجزها النموذج على صور مختلفة، حيث تم تحديد موقع العقاب وتصنيفه بدقة عالية، مع عرض مربعات الكشف بأسماء الفئة (عقاب) ونسب الثقة.




الشكل (14-5): صور عينات كشف العقاب.

أما مصفوفة الالتباس (الشكل 5-15) فتوفر ملخصاً لعدد العينات التي تم تصنيفها بشكل صحيح (168 إيجابي صحيح) مقابل عدد العينات التي تم تصنيفها بشكل خاطئ (25 تم تصنيفها بشكل خاطئ كخلفية)، مما يعكس فعالية النموذج في تقليل الأخطاء. وأخيراً، يُظهر منحنى F1-الثقة (الشكل 5-16) التوازن بين الدقة والاستدعاء عبر مستويات الثقة المختلفة، مما يساعد في تحديد أفضل قيمة للثقة التي تحقق أعلى توازن بين الدقة والاستدعاء باستخدام مؤشر F1.



الشكل (5-15): مصفوفة الالتباس لنموذج كشف العقاب.



الشكل (5-16): منحنى F1 - الثقة لنموذج كشف العقاب.

الجدول (5-4): نتائج منحنى F1 - الثقة لنموذج كشف العقاب.

المقياس	القيمة
---------	--------

0.92	F1 Score لجميع الفئات
0.409	عتبة الثقة (Confidence)

5-2-3-2 كشف القطط باستخدام YOLOv11

حقق النموذج أداءً متميزًا في اكتشاف القطط كما هو موضح في الجدول (5-5)، حيث سجل دقة عالية، مما يعكس قدرته على تصنيف القطط بشكل صحيح في جميع الحالات.

```

Ultralytics 8.3.168 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tesla T4, 15095MiB)
YOLOv11m summary (fused): 151 layers, 20,013,715 parameters, 0 gradients, 76.5 GFLOPs
Downloading https://ultralytics.com/assets/Arial.ttf to '/root/.config/Ultralytics/Arial.ttf'...
100%|██████████| 755k/755k [00:00<00:00, 122MB/s]val: Fast image access (ping: 0.0±0.0 ms, read: 28.0±7.0 MB/s, size: 54.8 KB)
val: Scanning /content/a/valid/labels... 68 images, 0 backgrounds, 0 corrupt: 100%|██████████| 68/68 [00:00<00:00, 613.50it/s]val: New cache created: /cc
Class Images Instances Box(P R mAP50 mAP50-95): 100%|██████████| 5/5 [00:07<00:00, 1.44s/it]
all 68 68 0.967 1 0.992 0.704
Speed: 16.7ms preprocess, 28.4ms inference, 0.0ms loss, 12.4ms postprocess per image
Results saved to runs/detect/val
mAP50: 0.9923613445378151
mAP50-95: 0.7035872262692737

```


الشكل (5-17): أداء نموذج كشف القطط.

الجدول (5-5): نتائج أداء نموذج كشف القطط.

المقياس	mAP50	mAP50-95	سرعة المعالجة المسبقة	سرعة الاستدلال	الخسارة	سرعة المعالجة اللاحقة
القيمة	0.992	0.784	16.7 ms	28.4 ms	0.0 ms	12.4 ms

يوضح منحنى الاستدعاء-الثقة (الشكل 5-18) كيف يقل الاستدعاء بزيادة مستوى الثقة، مما يظهر العلاقة العكسية بين الاستدعاء والثقة ويساعد في اختيار العتبة المثلى التي تقلل من الأخطاء مع الحفاظ على عدد كافٍ من العينات. بينما يبين منحنى الدقة-الاستدعاء (الشكل 5-19) التوازن بين الدقة والاستدعاء، حيث حافظ النموذج على دقة عالية عبر معظم مستويات الاستدعاء، مما يدل


على فعالية النموذج في الكشف عن القطط. من جهة أخرى، يظهر منحنى الدقة-الثقة (الشكل 5-20) كيف ترتفع الدقة مع زيادة الثقة، مما يعكس أهمية تحديد العتبة الأمثل للثقة بهدف تقليل الإيجابيات الكاذبة.



الشكل (5-18): منحنى الاستدعاء - الثقة لنموذج كشف القطط.

الجدول (5-6): نتائج منحنى الاستدعاء - الثقة لنموذج كشف القطط.


الحد الأدنى للثقة (Confidence)	الاستدعاء عند هذا الحد (Recall)
0.000	1.00



الشكل (5-19): منحنى الدقة - الاستدعاء لنموذج كشف القطط.

الجدول (5-7): نتائج منحنى الدقة - الاستدعاء لنموذج كشف القطط.

المقياس	القيمة
mAP@0.5 لجميع الفئات	0.992



الشكل (5-20): منحنى الدقة - الثقة لنموذج كشف القطط.

الجدول (5-8): نتائج منحنى الدقة - الثقة لنموذج كشف القطط.

المقياس	القيمة
الدقة (Precision) لجميع الفئات	1.00
عتبة الثقة (Confidence)	0.799


صور الكشف (الشكل 5-21) تعرض نتائج الكشف التي أنجزها النموذج على صور القطط، حيث يتم تحديد موقع القطط وتصنيفها بدقة عالية في مشاهد متنوعة وظروف إضاءة مختلفة. هذه الصور تؤكد قدرة النموذج على التعرف على القطط في بيئات متعددة.




الشكل (5-21): صور عينات كشف القطط.

مصفوفة الالتباس (الشكل 5-22) تُظهر أن النموذج صنف معظم الصور بشكل صحيح، حيث تم تصنيف 64 صورة كـ "قط" بدقة، مع وجود أخطاء قليلة جدًا في التصنيف مع الخلفية.

منحنى F1-الثقة (الشكل 5-23) يوضح العلاقة بين مؤشر F1 ومستوى الثقة. يظهر المنحنى أن القيمة المثلى لـ F1 تكون عند ثقة 0.4، حيث يتم تحقيق أفضل توازن بين الدقة والاستدعاء.



الشكل (5-22): مصفوفة الالتباس لنموذج كشف القطط.



الشكل (5-23): منحنى F1 – الثقة لنموذج كشف القطط.

الجدول (5-9): نتائج منحنى F1 - الثقة لنموذج كشف القطط.

المقياس	القيمة
F1 Score لجميع الفئات	0.98
عتبة الثقة (Confidence)	0.591

5-2-3-3-5 كشف الأسماك باستخدام YOLOv11

يُظهر الجدول (5-9) نتائج أداء النموذج، والتي تعكس قدرته على تحقيق مستويات عالية من الدقة في الكشف عن الأسماك ضمن عتبات مختلفة. بالإضافة إلى ذلك، يقدم الجدول تفاصيل حول كفاءة النموذج من حيث سرعة المعالجة لكل مرحلة من مراحل العملية، بدءًا من المعالجة المسبقة وصولاً إلى المعالجة اللاحقة، مما يوفر تقييماً شاملاً لأدائه.

```

Ultralytics 8.3.168 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tesla T4, 15095MiB)
YOLOv9m summary (fused): 151 layers, 20,013,715 parameters, 0 gradients, 76.5 GFLOPs
val: Fast image access (ping: 0.0±0.0 ms, read: 557.0±341.2 MB/s, size: 25.3 KB)
val: Scanning /content/aa/valid/labels... 223 images, 0 backgrounds, 0 corrupt: 100%|██████████| 223/223 [00:00<00:00, 785.20it/s]
val: New cache created: /content/aa/valid/labels.cache
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%|██████████| 14/14 [00:07<00:00, 1.82it/s]
   all         223         1113    0.847    0.787    0.856    0.551
Speed: 1.7ms preprocess, 21.2ms inference, 0.0ms loss, 2.6ms postprocess per image
Results saved to runs/detect/val4
mAP50: 0.8561126433506929
mAP50-95: 0.5513754651582986


```

الشكل (5-24): أداء نموذج كشف الأسماك.

الجدول (5-10): نتائج أداء نموذج كشف الأسماك.

المقياس	mAP50	mAP50-95	سرعة المعالجة المسبقة	سرعة الاستدلال	الخسارة	سرعة المعالجة اللاحقة
القيمة	0.856	0.551	1.7 ms	21.2 ms	0.0 ms	2.6 ms


يوضح منحنى الاستدعاء-الثقة (الشكل 5-25) العلاقة العكسية بين الاستدعاء ومستوى الثقة، حيث يقل الاستدعاء مع زيادة الثقة. هذا التغير يساعد في تحديد العتبة المثلى التي توازن بين تقليل الأخطاء والحفاظ على عدد كافٍ من العينات. أما منحنى الدقة-الثقة (الشكل 5-26) فيوضح كيف ترتفع الدقة مع زيادة الثقة، مما يشير إلى أهمية تحديد العتبة المثلى للثقة لتقليل الإيجابيات الكاذبة.



الشكل (5-25): منحنى الاستدعاء - الثقة لنموذج كشف الأسماك.

الجدول (5-11): نتائج منحنى الاستدعاء - الثقة لنموذج كشف الأسماك.

الحد الأدنى للثقة (Confidence)	الاستدعاء عند هذا الحد (Recall)
0.000	0.95



الشكل (5-26): منحنى الدقة - الثقة لنموذج كشف الأسماك.

الجدول (5-12): نتائج منحنى الدقة - الثقة لنموذج كشف الأسماك.


المقياس	القيمة
الدقة (Precision) لجميع الفئات	1.00
عتبة الثقة (Confidence)	0.942

صور الكشف (الشكل 5-27) تعرض نتائج الكشف التي أنجزها النموذج على صور الأسماك، حيث يتم تحديد مواقع الأسماك وتصنيفها بدقة عالية في مشاهد متنوعة وظروف إضاءة مختلفة، مما يبرهن على قدرة النموذج على التعرف على الأسماك في بيئات متعددة.

أما مصفوفة الالتباس (الشكل 5-28) فتوضح أن النموذج صنف معظم الصور بشكل صحيح، حيث تم تصنيف 948 صورة كـ "سمكة" بدقة، بينما حدثت بعض الأخطاء مع 331 صورة تم تصنيفها بشكل خاطئ كـ "سمكة" من قبل النموذج (إيجابيات خاطئة) و165 صورة تم تصنيفها على أنها "خلفية" بينما كانت "سمكة" (سلبيات خاطئة).




الشكل (27-5): عينات كشف الأسماك.



الشكل (5-28): مصفوفة الالتباس لنموذج كشف الأسماك.

منحنى F1-الثقة (الشكل 5-29) يوضح العلاقة بين مؤشر F1 ومستوى الثقة، حيث تظهر النتائج أن القيمة المثلى لـ F1 تكون عند ثقة 0.449، مما يحقق أفضل توازن بين الدقة والاستدعاء.



الشكل (5-29): منحنى F1 - الثقة لنموذج كشف الأسماك.

الجدول (5-13): نتائج منحنى F1 - الثقة لنموذج كشف الأسماك.

المقياس	القيمة
F1 Score لجميع الفئات	0.81
عتبة الثقة (Confidence)	0.449

5-3-3 كشف الألوان

لقد تم إجراء اختبار لحساب دقة التعرف على الألوان باستخدام الكود المعتمد على قيم HSV. يعتمد الكود على قراءة لون نقطة في وسط الشاشة، ومن ثم يقوم بتحديد اسم اللون بناءً على هذه القيم. إلا أن الكود لا يحسب الدقة تلقائيًا، لذا تم إجراء اختبار يدوي لحساب دقة النموذج في التعرف على الألوان.

تم اتباع الخطوات التالية لحساب الدقة: تم عرض الألوان المعروفة أمام الكاميرا مثل الأحمر والأخضر والأزرق وغيرها، ثم تم مقارنة الاسم المتوقع الذي يطبّعه الكود مع اللون الحقيقي المعروض أمام الكاميرا. إذا كان الاسم الذي يظهر صحيحًا، تم تسجيله كتوقع صحيح، وإذا كان الاسم خاطئًا، تم تسجيله كتوقع خاطئ. تم تكرار هذه الخطوات مع مجموعة من الألوان وهي: الأحمر، الأخضر، الأزرق، الأصفر، البرتقالي، البني، الأبيض، الأسود، البنفسجي، والزهري، بحيث تم التحقق من دقة الكود في كل اختبار. تم استخدام المعادلة التالية لحساب الدقة:

$$Accuracy = \frac{C}{T} \times 100$$

حيث: C : عدد التوقعات الصحيحة، T : العدد الكلي للمحاولات.

بناءً على هذا المثال، إذا تم اختبار 10 ألوان وكانت 6 منها صحيحة، فإن الدقة ستكون:

$$Accuracy = \frac{6}{10} \times 100 = 60\%$$

هناك عدة عوامل تؤثر على دقة التعرف على الألوان، مثل:

- **الإضاءة:** قد تؤثر الإضاءة الضعيفة أو القوية على القيم المقاسة للألوان، مما يؤدي إلى تغييرات في التعرف.
- **نوع الكاميرا:** جودة الكاميرا قد تؤثر في كيفية قراءة الألوان، إذ أن بعض الكاميرات قد تغير الألوان بناءً على خصائصها.
- **الظلال والانعكاسات:** قد تؤثر الظلال والانعكاسات على دقة قراءة اللون، خاصة إذا كانت الإضاءة غير متجانسة.
- **تشابه الألوان:** بعض الألوان المتشابهة مثل البرتقالي والبني قد تؤدي إلى خلط بينهما أثناء عملية التعرف.
- **المسافة من الكاميرا:** إذا كان اللون بعيدًا أو صغيرًا في الإطار، قد يكون من الصعب التعرف عليه بدقة.


5-3-4 كشف الأرقام

تم حساب دقة التعرف باستخدام OCR بناءً على نفس المعادلة التي تم استخدامها لحساب دقة التعرف على الألوان.

```
ocr Accuracy
(Accuracy): 87.4%
(Precision): 0.89
(Recall): 0.83
F1-Score: 0.86

(False Positives): 45
(False Negatives): 81
```

الشكل (5-30): قيم مقاييس الأداء في الكشف عن الأرقام.



الشكل (5-31): أداء EasyOCR.

الجدول (5-14): نتائج مقاييس الأداء لكشف الأرقام.

المقياس	الدقة (Accuracy)	الدقة (Precision)	الاستدعاء (Recall)	F1-Score	الإيجابيات الخاطئة (False Positives)	السلبيات الخاطئة (False Negatives)
القيمة	87.4%	0.89	0.83	0.86	45	81

في هذا السياق، تم اختبار الأرقام من 1 إلى 10، وتم مقارنة النصوص الفعلية مع النصوص المقروءة من الكود لحساب الدقة. يوضح الجدول (5-1) المثال التجريبي لقراءة OCR للأرقام من 1 إلى 10:

الجدول (5-15): العينات.

الرقم المقروء من OCR	الرقم المعروض أمام الكاميرا
1	1
2	2
3	3
4	4
S	5
6	6
7	7
B	8
9	9
10	10

• حساب الدقة:

عدد المحاولات: 10، عدد القراءات الصحيحة: 7، بالتالي:

$$Accuracy = \frac{7}{10} \times 100 = 70\%$$

• ملاحظات على الأخطاء:

- الرقم 5 تم قراءته ك S بسبب التشابه بين الشكليين.
- الرقم 8 تم قراءته ك B لنفس السبب.
- الرقم 10 تم التعرف عليه ك "O1" بحرف O بدل الرقم 0، وهذا شائع جدًا في الخطوط غير الواضحة.

• العوامل التي تؤثر على دقة OCR:

- **جودة الكاميرا:** الكاميرا الضعيفة تؤدي إلى صور ضبابية، مما يصعب التعرف على النصوص.
- **الإضاءة:** الإضاءة الضعيفة أو القوية جدًا قد تؤدي إلى تشويش القراءة.
- **حجم الخط:** الخطوط الصغيرة أو الرقيقة قد تكون صعبة على النموذج لقراءتها.
- **الخلفية:** النصوص ذات الخلفيات المشوشة أو غير الواضحة تؤثر بشكل كبير على دقة القراءة.
- **نوع الخط:** الخطوط المعقدة أو الغير واضحة تقلل من دقة النموذج في التعرف على النص.
- **الزاوية:** إذا كان النص مائلًا أو غير مركزي في الكاميرا، فإن ذلك يؤثر على دقة قراءة النص.

• الحلول لتحسين دقة OCR:

- **تحسين الإضاءة:** تأكد من أن الإضاءة موزعة وناعمة، ويفضل استخدام ضوء أبيض مباشر بدون ظل.
- **زيادة تباين الصورة (Contrast):** استخدام أدوات مثل cv2.threshold () لتحسين التباين بين النص والخلفية.

- استخدام خط رقمي واضح ومقروء: تأكد من استخدام خطوط واضحة مثل Arial أو Times New Roman أو OCR-B.
- تكبير الأرقام قليلاً: تأكد من أن الأرقام واضحة ومقروءة، ويفضل أن تغطي مساحة كبيرة من الصورة.
- ضبط زاوية الكاميرا: تأكد من أن النص موجه مباشرة للكاميرا دون ميل أو زوايا غريبة.
- فلترة النصوص الخطأ بذكاء: بعد قراءة النص، يمكن تصحيح الأخطاء البسيطة مثل تحويل O إلى 0 و B إلى 8 باستخدام كود بسيط.

4-5 الخاتمة

في هذا المشروع، تم تصميم نظام تعليمي تفاعلي للأطفال باستخدام تقنيات الذكاء الاصطناعي والرؤية الحاسوبية. يهدف النظام إلى تحسين تجربة التعلم للأطفال في المراحل المبكرة من خلال تقديم بيئة تعليمية مرنة ومبتكرة. من خلال التقنيات المتقدمة مثل التعرف على الألوان باستخدام نموذج HSV، واكتشاف الحيوانات عبر خوارزمية YOLO، وتحويل الأرقام المكتوبة إلى نصوص قابلة للقراءة باستخدام تقنية OCR، تم تمكين الأطفال من التفاعل مع النظام بشكل مباشر وسلس.

لقد أثبت النظام فعاليته في المراحل التجريبية، حيث أظهر كفاءة عالية في التعرف على الألوان، الحيوانات، والأرقام، مما يساهم في تعزيز مهارات الأطفال البصرية والمعرفية. كما تم تقديم استجابة سريعة ودقيقة مع القدرة على التفاعل الفوري مع المدخلات، مما يساهم في تحسين التجربة التعليمية بشكل عام. وبالتالي، يعتبر هذا المشروع إضافة قيمة إلى المنظومة التعليمية التفاعلية، خصوصاً في مجالات التعليم المبكر.

5-5 الآفاق المستقبلية

1. تحسين دقة التعرف على الكائنات في بيئات معقدة مثل الإضاءة المتغيرة والخلفيات المزدحمة.
2. إضافة تقنيات التعرف على الصوت لتعزيز التفاعل الصوتي مع النظام.
3. التكامل مع تقنيات الواقع المعزز (AR) والواقع الافتراضي (VR) لتوسيع تجربة التعلم.
4. دعم لغات متعددة لتوسيع نطاق الاستخدام في بيئات تعليمية متنوعة.
5. دمج التعلم التكيفي لتحسين تجربة التعلم وفقاً لمستوى الطفل.
6. تعزيز قدرة النظام على التنبؤ بالأنماط السلوكية للأطفال استناداً إلى تفاعلاتهم السابقة.
7. إدخال التفاعل الجماعي من خلال أنشطة تعليمية تعاونية بين الأطفال.
8. إضافة أدوات تحليلات الأداء لمراقبة تقدم الأطفال وتقديم تقارير مخصصة.
9. تحسين النظام باستمرار عبر التعلم من البيانات التفاعلية التي يتم جمعها أثناء الاستخدام.
10. مواكبة التغيرات التقنية بتحديث الخوارزميات والتقنيات المستخدمة لتوفير تجربة تعليمية أكثر تطوراً.

المراجع

- [1] Gonzalez, R. C., & Woods, R. E. (2008). Digital Image Representation. In Digital Image Processing (3rd ed., pp. 3–5). Pearson Education.
<http://cmrcet.ac.in/files/ECE/ececoursefile/13.pdf>
- [2] Nilsson, N. J. (2010). What is artificial intelligence? In The Quest for Artificial Intelligence: A History of Ideas and Achievements (pp. 3–10). Cambridge University Press. Retrieved from <https://ai.stanford.edu/~nilsson/QAI/qai.pdf>
- [3] Li, Z., Yang, W., Peng, S., & Liu, F. (2020). A survey of convolutional neural networks: Analysis, applications, and prospects. arXiv.
<https://arxiv.org/abs/2004.02806>
- [4] Audibert, R. B., & Maschio, V. M. (2021). FINNger: Applying artificial intelligence to ease math learning for children. UFRGS - INF.
- [5] Li, M., Lv, Y., Pu, Y., & Wu, M. (2025). Design and evaluation of children's education interactive learning system based on human computer interaction technology. Scientific Reports, 15, 6135.
- [6] DIYCoding. (n.d.). Color models in image processing: Understanding RGB and HSV for computer vision. Medium. Retrieved February 9, 2025, from <https://medium.com/@DIYCoding/color-models-in-image-processing-understanding-rgb-and-hsv-for-computer-vision-a629641cdc40>
- [7] TENOCLOGY. (n.d.). Color detection with OpenCV and Python. Medium. Retrieved February 9, 2025, from <https://medium.com/@TENOCLOGY/color-detection-with-opencv-and-python-db82ec1113e7>
- [8] Kundu, R. (2023, January 17). YOLO: Algorithm for object detection explained [+examples]. V7 Labs. <https://www.v7labs.com/blog/yolo-object-detection>

- [9] Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. In Advances in Neural Information Processing Systems (NeurIPS).
- [10] Wang, J. (2023). A Study of The OCR Development History and Directions of Development. Highlights in Science, Engineering and Technology, 72, 409.
- [11] Rüegg, C., Christ, D., Hartl, A., Balbach, N., Wehner, M., Springmann, U., Wick, C., Grundig, K., Beutner, A., & Bopp, F. (2019). OCR4all – A semi-automatic open-source workflow for OCR of historical printings. arXiv preprint.

Syrian Arab Republic

Ministry of Higher Education and Scientific Research

Private National University

Department of Computer Engineering



The project was prepared to obtain a Bachelor's degree in Computer Engineering titled:

Designing an Interactive Educational System for Children Using Artificial Intelligence and Computer

Vision

By:

Dania Othman Al-Tabbaa

Tasneem Abdullah Al-Tayar

Supervised By:

Dr. Zaid Kraitem

2025-2024