



الجمهورية العربية السورية

وزارة التعليم العالي والبحث العلمي

جامعة حماة

الكلية التطبيقية – قسم تقنيات الحاسوب

التحكم عن بعد لتطبيقات أجهزة الحاسوب باستخدام تقنية الذكاء

الاصطناعي

مشروع أعد لنيل درجة الإجازة في تقنيات الحاسوب

إعداد الطالبات:

رقية الصباغ – ريم الصالح – دلال البرازي

إشراف:

الدكتور المهندس أحمد رياض كردي

الدكتور المهندس نصر القاسم

2026 – 2025

1	الفصل الأول: مقدمة
6	2 الفصل الثاني: أساسيات الذكاء الاصطناعي
7	1-2 مقدمة الفصل
7	2-2 الذكاء الاصطناعي: المفاهيم والتطبيقات في التفاعل بين الإنسان والحاسوب
7	1-2-2 مفهوم الذكاء الاصطناعي وتطوره التاريخي
9	2-2-2 دور الذكاء الاصطناعي في أنظمة التحكم عن بعد والواجهات اللاتلامسية
11	3-2-2 تحديات واجهات المستخدم القائمة على الإيماءات (Gesture-Based UI)
12	3-2 الشبكات العصبية الاصطناعية (ANNs): الأسس وآليات التعلم
12	1-3-2 البنية الهيكلية للشبكة العصبية (Neuron, Layers)
14	2-3-2 الأوزان (Weights) والانحياز (Bias): المفهوم والدور الرياضي
15	3-3-2 خوارزميات التدريب: الانتشار العكسي (Backpropagation) والنزول المتدرج (Gradient Descent)
16	4-3-2 دوال التنشيط (Activation Functions) وتحسين الأداء (Optimization)
17	4-2 أساسيات الصور الرقمية وتمثيل البيانات المرئية
17	1-4-2 ماهية البكسل (Pixel) والدقة المكانية للصورة
19	2-4-2 الفضاءات اللونية (Color Spaces)

فهرس المحتويات

21	3-4-2 أهمية التحويل بين أنظمة الألوان في مهام الرؤية الحاسوبية.....
22	5-2 تقنيات معالجة الصور الرقمية (Digital Image Processing).....
	1-5-2 عمليات المعالجة الأولية (Preprocessing): تقليل الضوضاء وتنعيم الصورة
22	(Smoothing).....
25	2-5-2 كشف الحواف (Edge Detection) واستخراج الميزات الهندسية.....
	3-5-2 عمليات العتبة (Thresholding) والفصل الخلفي (Background
26	Subtraction).....
30	6-2 الشبكات العصبية الالتقافية (CNNs) في تحليل الصور.....
30	1-6-2 الهيكلية المعمارية لشبكات CNN.....
31	2-6-2 استخراج الخصائص (Feature Extraction) وتصنيف الصور.....
31	3-6-2 التكامل بين CNN وتقنيات التعرف على الإيماءات.....
32	7-2 أدوات الرؤية الحاسوبية: مكتبة OpenCV.....
	1-7-2 التعريف بمكتبة OpenCV ودورها في التطبيقات الزمن الحقيقي (Real-time)
32	
33	2-7-2 الوظائف الأساسية في OpenCV.....
33	3-7-2 إدارة العمليات الحسابية المصفوفية للصور داخل OpenCV.....
34	8-2 تقنية MediaPipe وتتبع الهيكل البشري.....
35	1-8-2 بنية إطار عمل MediaPipe وخطوط المعالجة (Pipelines).....

فهرس المحتويات

2-8-2 نموذج MediaPipe Hands المعمارية والأداء	36
2-8-3 الرسم البياني لليد (Hand Graph) واستخراج النقاط المميزة (Landmarks)	38
2-9-9 تقدير الوضعية (Pose Estimation) وتحليل حركة اليد.....	39
2-9-1 مفهوم تقدير الوضعية: من ثنائي الأبعاد إلى ثلاثي الأبعاد	39
2-9-2 الخريطة الطبوغرافية لليد: دلالات النقاط الـ 21 وعلاقاتها الهندسية.....	40
2-9-3 استخدام العلاقات الهندسية بين النقاط لتفسير الإيماءات.....	41
2-10-10 موضوعات متقدمة في أنظمة التعرف على الإيماءات	42
2-10-1 المعالجة الزمنية للإيماءات باستخدام LSTM أو GRU	42
2-10-2 النموذج الهجين: التكامل بين MediaPipe و CNN.....	43
2-10-3 التحديات البيئية: الإضاءة، التداخل، وتنوع الخلفيات.....	43
2-10-4 مقاييس تقييم الأداء.....	44
2-11-11 الدراسات السابقة.....	45
2-11-1 خلاصة الدراسات السابقة.....	48
2-11-2 مقارنة الدراسات السابقة مع فكرة المشروع المقترح.....	49
3 الفصل الثالث: الدراسة التحليلية.....	51
3-1 مقدمة.....	52
3-2 تحليل المشكلة.....	52

فهرس المحتويات

54	1-2-3 تحليل الحلول الحالية وتحديد الفجوة البحثية
55	2-2-3 صياغة فرضيات الحل
55	3-3 تحليل متطلبات النظام
55	1-3-3 المتطلبات الوظيفية للنظام
57	2-3-3 المتطلبات غير الوظيفية
57	3-3-3 حالات الاستخدام
60	4-3 التحليل البنيوي للنظام
62	1-4-3 تدفق البيانات عبر النظام
64	6-3 التحليل الخوارزمي
66	7-3 تحليل الأداء المتوقع
68	8-3 القيود والمخاطر
70	4 الفصل الرابع: التنفيذ العملي والنتائج
71	1-4 بيئات التطوير والأدوات المستخدمة
71	1-1-4 بيئة Anaconda
72	2-1-4 بيئة Visual Studio Code
72	3-1-4 دور بيئات التطوير في تنفيذ النظام
73	2-4 تنفيذ نظام التحكم بمستوى السطوح باستخدام إيماءات اليد

فهرس المحتويات

- 74 1-2-4 الإيماءة الأولى: تخفيض السطوع
- 75 2-2-4 الإيماءة الثانية: رفع السطوع
- 76 3-2-4 الإيماءة الثالثة: السطوع الأقصى
- 77 3-4 الإيماءات المستخدمة في النظام
- 78 4-4 نتائج التجربة وتقييم الأداء
- 79 5 الفصل الخامس: الخاتمة والآفاق المستقبلية

فهرس الأشكال

- الشكل 1-1: تتبع اليد باستخدام تقنيات الذكاء الاصطناعي.....2
- الشكل 1-2: البنية المعمارية العامة لنظام التفاعل بين الإنسان والحاسوب.....9
- الشكل 2-2: مقارنة بين العصبون البيولوجي والعصبون الاصطناعي.....12
- الشكل 2-3: عملية الانتشار العكسي في الشبكات العصبونية.....15
- الشكل 2-4: البكسلات في الصورة الرقمية.....17
- الشكل 2-5: البعد المكاني للبكسل في الصورة.....18
- الشكل 2-6: مفهوم الدقة المكانية.....18
- الشكل 2-7: مفهوم كثافة البكسلات.....19
- الشكل 2-8: نظام الألوان RGB.....19
- الشكل 2-9: نظام الألوان HSV.....20
- الشكل 2-10: نظام YCrCb.....20
- الشكل 2-11: الضوضاء الغوسية.....22
- الشكل 2-12: ضوضاء Salt & Pepper.....23
- الشكل 2-13: ضوضاء بواسون.....23
- الشكل 2-14: عملية التنعيم في معالجة الصورة.....24
- الشكل 2-15: نواتج تطبيق خوارزميات كشف الحواف المختلفة على صورة اليد.....26
- الشكل 2-16: آلية تحويل الصورة الرمادية إلى صورة ثنائية باستخدام عمليات العتبة.....28
- الشكل 2-17: مبدأ الفصل الخلفي وإنتاج قناع المقدّمة.....29
- الشكل 2-18: البنية المعمارية العامة لشبكة عصبية التلافيفية (CNN).....31
- الشكل 2-19: البنية العامة لخط المعالجة (Pipeline) في إطار MediaPipe.....36

فهرس الأشكال

- الشكل 20-2: نقاط اليد الـ 21 39
- الشكل 21-2: مقارنة بين تقدير الوضعية ثنائي الأبعاد (2D) وثلاثي الأبعاد (3D) لليد 40
- الشكل 22-2: مخطط معالجة الإيماءات الزمنية باستخدام CNN و LSTM 43
- الشكل 23-2: لقطات شاشة للتعرف على الإيماءات في الوقت الفعلي 46
- الشكل 24-2: لوحة المفاتيح الافتراضية 47
- الشكل 1-3: حالات استخدام المستخدم العادي 58
- الشكل 2-3: حالات استخدام المطور 60
- الشكل 3-3: مخطط تدفق البيانات عبر النظام 63
- الشكل 4-3: مخطط خوارزمية العمل 64
- الشكل 1-4: شعار بيئة Anaconda 71
- الشكل 2-4: شعار بيئة VS Code 72
- الشكل 3-4: إيماءة تخفيض سطوع الشاشة باستخدام تقارب الإبهام والسبابة 74
- الشكل 4-4: إيماءة زيادة سطوع الشاشة من خلال إبعاد الإبهام عن السبابة 75
- الشكل 5-4: إيماءة الوصول إلى السطوع الأقصى (100%) 76

فهرس الجداول

الجدول 1-2: التسلسل التاريخي لتطور الذكاء الاصطناعي وأبرز محطاته التاريخية.....	8
الجدول 2-2: مقارنة تقنيات التفاعل الحديثة في HCI.....	11
الجدول 3-2: مقارنة أنواع الشبكات العصبية الرئيسية.....	14
الجدول 4-2: دوال التنشيط الشائعة ومقارنتها.....	16
الجدول 5-2: مقارنة الفضاءات اللونية في مهام تتبع اليد.....	21
الجدول 6-2: مقارنة أداء مرشحات التنعيم.....	25
الجدول 7-2: مقارنة خوارزميات كشف الحواف.....	25
الجدول 8-2: أنواع عمليات العتبة واستخداماتها.....	27
الجدول 9-2: خوارزميات الفصل الخلفي الشائعة.....	29
الجدول 10-2: مقارنة العتبة والفصل الخلفي.....	29
الجدول 11-2: الطبقات الأساسية في شبكات CNN.....	30
الجدول 12-2: دور طبقات CNN في الاستخراج والتصنيف.....	31
الجدول 13-2: الوظائف الأساسية لمكتبة OpenCV.....	33
الجدول 14-2: تصنيف العمليات المصفوفية في OpenCV.....	34
الجدول 15-2: مقارنة أداء MediaPipe Hands مع OpenPose و MoveNet.....	38
الجدول 16-2: الخريطة الطبوغرافية لليد ودلالات النقاط الـ 21 وعلاقتها الهندسية.....	41
الجدول 17-2: التحديات البيئية في أنظمة التعرف على الإيماءات.....	44
الجدول 18-2: مقاييس تقييم أداء أنظمة التعرف على الإيماءات.....	45

المخلص

يهدف هذا المشروع إلى تطوير نظام ذكي للتحكم عن بعد بتطبيقات الحاسوب باستخدام إيماءات اليد دون الحاجة إلى أجهزة إدخال تقليدية. يعتمد النظام على تقنيات الرؤية الحاسوبية والذكاء الاصطناعي، حيث تُستخدم مكتبة MediaPipe لاستخراج معالم اليد وتتبعها في الزمن الحقيقي، بينما تتولى OpenCV معالجة الصور والفيديو الواردة من كاميرا الويب.

يقوم النظام بتحويل الإيماءات إلى أوامر حاسوبية مثل تحريك المؤشر، النقر، التحكم بالوسائط، والتنقل بين التطبيقات، مع الحفاظ على سرعة استجابة عالية ودقة مناسبة للتشغيل الفوري. يساهم المشروع في تعزيز التفاعل الطبيعي بين الإنسان والحاسوب، ويوفر حلاً عملياً منخفض التكلفة يمكن تطبيقه في البيئات التعليمية والمكتبية والصحية.

الكلمات المفتاحية:

الذكاء الاصطناعي، الرؤية الحاسوبية، MediaPipe، OpenCV، إيماءات اليد، التفاعل بين الإنسان والحاسوب، تتبع اليد، التحكم عن بعد.

ABSTRACT

This project aims to develop an intelligent system for remote control of computer applications using hand gestures without relying on traditional input devices. The system employs Artificial Intelligence and Computer Vision techniques, utilizing MediaPipe for real-time hand landmark detection and tracking, while OpenCV is used for image and video processing.

The proposed system translates hand gestures into computer commands such as cursor movement, clicking, multimedia control, and application navigation while maintaining high responsiveness and real-time performance. The project enhances natural Human–Computer Interaction (HCI) and provides a practical, low-cost solution suitable for educational, office, and healthcare environments.

Keywords:


Artificial Intelligence, Computer Vision, MediaPipe, OpenCV, Hand Gesture Recognition, Human–Computer Interaction, Hand Tracking, Remote Control.

قائمة المصطلحات

English	العربية
Artificial Intelligence (AI)	الذكاء الاصطناعي
Computer Vision	الرؤية الحاسوبية
Digital Image Processing	معالجة الصور الرقمية
Hand Tracking	تتبع اليد
Hand Landmarks	معالم اليد
Hand Gesture Recognition	التعرف على الإيماءات
Convolutional Neural Networks (CNN)	الشبكات العصبية الالتفافية
Pose Estimation	تقدير الوضعية
Real-Time Processing	الزمن الحقيقي
OpenCV Library	مكتبة OpenCV
MediaPipe Framework	إطار MediaPipe
Human-Computer Interaction (HCI)	التفاعل بين الإنسان والحاسوب
Video Processing	معالجة الفيديو
Deep Learning	التعلم العميق
Virtual Cursor	المؤشر الافتراضي

الفصل الأول: مقدمة

يندرج مشروع التحكم عن بعد باستخدام إيماءات اليد عبر خوارزمية MediaPipe ضمن الجهود البحثية الحديثة في مجال الحوسبة الإدراكية (Perceptual Computing)، وهو فرع متقدم من علوم الحاسوب يسعى لتمكين الآلات من "رؤية" و"فهم" العالم المحيط بها بطريقة تحاكي الإدراك البشري، حيث يعتمد هذا التوجه على دمج خوارزميات التعلم العميق (Deep Learning) مع تقنيات معالجة الصور الرقمية لاستخلاص المعلومات الدلالية من المدخلات البصرية في الوقت الفعلي [1]. وتعد تقنية MediaPipe، التي طورتها شركة Google، نقلة نوعية في مجال رؤية الحاسوب لأنها تجاوزت الطرق التقليدية التي كانت تعتمد على معدات باهظة ومقيدة مثل قفازات البيانات أو كاميرات العمق، معتمدةً في ذلك على خط أنابيب (Pipeline) من الشبكات العصبية المتلاحقة تبدأ بعمليات كشف اليد (Palm Detection) لتحديد المنطقة ذات الاهتمام، تليها شبكة نقاط المعالم (Hand Landmarks Model) التي تستنتج الإحداثيات المكانية ثلاثية الأبعاد لـ 21 نقطة مفصلية في اليد بدقة عالية [2].



الشكل 1-1: تتبع اليد باستخدام تقنيات الذكاء الاصطناعي.

ومن منظور بحثي معمق، لا يكفي هذا النظام بمجرد الرؤية السطحية، بل يقوم بنمذجة الهيكل الكينماتيكي (Kinematic Structure) الكامل لليد، حيث تُعامل التغيرات في إحداثيات النقاط المفصلية عبر الزمن كسلسلة زمنية (Time-series data) من الإشارات الحركية، مما يتطلب خوارزميات متطورة قادرة على تمييز "الضجيج" الحركي العرضي عن "الإيماءة" المقصودة، وهو ما يتم تنفيذه غالباً باستخدام تقنيات هندسية (Geometric heuristics) أو شبكات عصبية متكررة (RNNs/LSTMs) لفهم الديناميكية الزمنية للحركة [3]. ويمثل هذا العمل تطبيقاً لافتاً لمفهوم الذكاء الاصطناعي الحافي (Edge AI) أو المعالجة على الجهاز، حيث يتم تشغيل نماذج الذكاء الاصطناعي المعقدة محلياً دون الحاجة لخوادم سحابية، مما يقلل من زمن الوصول (Latency) ويضمن استجابة فورية لضرورية لتطبيقات التحكم [2].

وعلى الرغم من هذا التطور التقني، إلا أن مجال تفاعل الإنسان مع الحاسوب (HCI) لا يزال يشهد فجوة تفاعلية؛ فبينما يتجه العالم نحو واجهات المستخدم الطبيعية (NUI)، لا تزال الغالبية العظمى من أنظمة التحكم الحالية تعتمد بشكل كلي على الأجهزة الطرفية الملموسة مثل الفأرة ولوحة المفاتيح، وهو ما يحد من حرية المستخدم ويفرض قيوداً تشغيلية في السيناريوهات التي تتطلب تعقيماً طبياً، أو تلك التي يصعب فيها الوصول المادي للجهاز [6]. وتتمحور المشكلة البحثية هنا في التعقيد الحسابي المرتبط بتفسير الحركات البشرية في الوقت الفعلي؛ إذ واجهت الحلول المعتمدة على الأجهزة القابلة للارتداء عقبات تتعلق بالتكلفة وصعوبة الاستخدام [7]، بينما اصطدمت الحلول القائمة على رؤية الحاسوب التقليدية بتحديات "مشكلة الانسداد" (Occlusion) وتباين الإضاءة وتنوع ألوان البشرة، مما يؤدي لارتفاع معدلات الخطأ [8]. علاوة على ذلك، فإن

خوارزميات التعلم العميق التقليدية تتطلب موارد حاسوبية هائلة (GPUs)، مما يجعلها غير صالحة للتطبيق على الأجهزة الشخصية ذات الموارد المحدودة [9].

لذا، تبرز الحاجة الملحة لهذا المشروع الذي يهدف بشكل رئيسي إلى تصميم وتطوير نظام واجهة مستخدم طبيعية (NUI) يستغل البنية الهيكلية لنموذج MediaPipe لاستبدال وحدات الإدخال التقليدية بإيماءات يد ديناميكية. ويسعى البحث لتحقيق أهداف استراتيجية تبدأ بتطوير خوارزمية تتبع ورسم خرائط حركية دقيقة تقوم بدمج إحداثيات الـ 21 نقطة مفصلية وتحويلها من فضاء الكاميرا إلى أوامر تحكم في المؤشر على الشاشة لضمان ترجمة الحركة الفيزيائية إلى فعل رقمي دقيق [1]. كما يهدف المشروع إلى تحقيق أعلى مستويات الكفاءة الحسابية لضمان عمل النظام بمعدل إطارات لا يقل عن 30 إطاراً في الثانية على المعالجات العادية (CPU)، مع تقليل زمن الكمون إلى الحد الأدنى [2]. ويرافق ذلك تصميم قاموس إيماءات بديهي ومريح يغطي وظائف النقر والتمرير والتكبير، بما يقلل العبء المعرفي والجسدي على المستخدم، مع إخضاع النظام لاختبارات صارمة لتقييم المتانة والموثوقية في بيئات بصرية متباينة وظروف إضاءة متغيرة [3].

وتكمن الأهمية الجوهرية لهذا البحث في مواكبته للتحويلات نحو واجهات المستخدم الصفرية (Zero UI)، حيث تشير التوجهات الحديثة إلى تقليل الاعتماد على اللمس خاصة بعد جائحة COVID-19 التي عززت الحاجة لتقنيات "عدم التلامس" [5]. إن القيمة العلمية للمشروع تبرز في حل معضلة الموازنة بين الكفاءة الحسابية ودقة التتبع التي طالما واجهت الباحثين [1]. ومن الناحية التطبيقية، يوفر النظام حلاً مبتكراً للبيئات الصناعية التي تتطلب بقاء الأيدي حرة، وللمجالات الطبية في غرف العمليات لضمان التعقيم [4]. أما من البعد الإنساني، فيعد المشروع تقنية مساعدة حيوية تعزز مفهوم التصميم الشامل (Inclusive Design) عبر منح الأشخاص ذوي الإعاقة

الحركية، الذين يواجهون صعوبات في استخدام الفأرة التقليدية، استقلالية أكبر في التعامل مع التكنولوجيا [2].

وفيما يتعلق بنطاق المشروع وحدوده التقنية، فإنه يركز على تطوير برمجية ذكية تعمل بالوقت الفعلي بلغة Python، وتعتمد على كاميرا الويب العادية دون الحاجة لمستشعرات إضافية. وينقسم النظام وظيفياً إلى وحدات محاكاة الماوس (تحريك، نقر، سحب)، ووحدات التحكم في الوسائط (ضبط الصوت، التشغيل والإيقاف)، واختصارات الإنتاجية (التنقل بين الشرائح والتكبير). وتعتمد المنهجية المقترحة للتنفيذ على هيكلية خطية تبدأ بالانقاط والمعالجة المسبقة عبر OpenCV وعكس الصورة لخلق تأثير المرآة، ثم الانتقال لمرحلة استخراج الخصائص بضبط عتبات ثقة عند 0.7 لتقليل الاكتشافات الخاطئة. ويتم اعتماد نهج هجين يجمع بين الهندسة الحسابية للعمليات السريعة مثل المسافة الإقليدية للنقر، وبين مصنفات تعلم الآلة (مثل KNN أو SVM) لتصنيف الإيماءات المعقدة والثابتة. ولضمان سلاسة التجربة، يشتمل النطاق التقني على خوارزميات التنعيم (Smoothing Algorithms) لمعالجة ارتعاش المؤشر (Jitter) وتطبيق تقنيات المنطقة النشطة (ROI) لتمكين التحكم الشامل في الشاشة بأقل مجهود حركي ممكن، مما يجعل هذا النظام سيبرفيزيائياً (Cyber-Physical System) يدمج الرؤية والحس والذكاء لتحويل النوايا البشرية إلى أوامر رقمية بدقة فائقة.

الفصل الثاني: أساسيات الذكاء

الاصطناعي

1-2 مقدمة الفصل

2-2 الذكاء الاصطناعي: المفاهيم والتطبيقات في التفاعل بين الإنسان والحاسوب

1-2-2 مفهوم الذكاء الاصطناعي وتطوره التاريخي

يعتبر الذكاء الاصطناعي (Artificial Intelligence) أحد الركائز الأساسية لعلوم الحاسب الحديثة، حيث يُعرّف بأنه المحاولة العلمية لإنشاء أنظمة وبرمجيات تمتلك القدرة على محاكاة السلوك الذكي للبشر، خاصة في جوانب الإدراك، والتعلم، وحل المشكلات، واتخاذ القرار. واستناداً إلى المرجع الكلاسيكي لـ "رسل ونورفيغ"، فإن الذكاء الاصطناعي هو دراسة الوكلاء (Agents) الذين يتلقون إدراكات من البيئة المحيطة ويقومون بتنفيذ إجراءات تهدف لتحقيق أهداف محددة بأفضل كفاءة ممكنة [10].

التطور التاريخي للذكاء الاصطناعي:

لم يكن الذكاء الاصطناعي وليد اللحظة، بل مرّ بمراحل تطور دراماتيكية يمكن تلخيصها في الجدول التالي [10]:

الفترة الزمنية	المرحلة	الخصائص وأبرز المنجزات
1940 - 1950	الأصول والأسس النظرية	وضع القواعد الرياضية والمنطقية للحوسبة والذكاء. برزت خلالها ورقة "آلان تورنغ" حول قدرة الآلات على التفكير، وظهر أول النماذج الرياضية للخلايا العصبية (McCulloch-Pitts).
1956	الميلاد الرسمي (مؤتمر دارتموث)	تم الإعلان عن الذكاء الاصطناعي كحقل بحثي مستقل. شهدت هذه المرحلة صياغة المصطلح على يد "جون

ماكارتشي" وظهور برامج قادرة على حل الألغاز الرياضية وإثبات النظريات.		
مرحلة من الركود وتراجع التمويل نتيجة المبالغة في التوقعات وعدم قدرة الأجهزة (Hardware) آنذاك على معالجة الخوارزميات المعقدة، ومحدودية البيانات المتاحة.	شتاء الذكاء الاصطناعي الأول	عقد 1970
انتعاش المجال تجارياً عبر تطوير أنظمة تعتمد على "قواعد المعرفة" لمحاكاة قرارات الخبراء في مجالات محددة كالتشخيص الطبي والتحليل الكيميائي، وظهور لغات برمجة متخصصة مثل LISP.	عصر الأنظمة الخبيرة (Expert Systems)	عقد 1980
التحول من البرمجة القائمة على القواعد الصريحة إلى الخوارزميات الإحصائية التي تتعلم من البيانات. شهدت انتصار الحاسوب "Deep Blue" على بطل العالم في الشطرنج.	ثورة التعلم الآلي (Machine Learning)	1990 - 2000
بزوغ عصر البيانات الضخمة (Big Data) والمعالجات الرسومية القوية (GPUs). تميزت بظهور الشبكات العصبية العميقة المتطورة، وتطبيقات الرؤية الحاسوبية (مثل MediaPipe)، والنماذج اللغوية الضخمة.	التعلم العميق والذكاء التوليدي	2012 - الحاضر

الجدول 1-2: التسلسل التاريخي لتطور الذكاء الاصطناعي وأبرز محطاته التاريخية.

تصنيف أنواع الذكاء الاصطناعي:

يتم تصنيف الذكاء الاصطناعي حسب قدراته إلى ثلاث فئات رئيسية [10]:

1. الذكاء الاصطناعي الضيق (Narrow AI): وهو المتخصص في أداء مهمة محددة بدقة


(مثل أنظمة Siri أو MediaPipe)، وهو النوع الوحيد المتاح عملياً اليوم [10].

2. الذكاء الاصطناعي العام (AGI): ذكاء يحاكي القدرات البشرية الشاملة في كافة المجالات (مفهوم نظري) [10].

3. الذكاء الاصطناعي الفائق (ASI): مفهوم بحثي يشير إلى ذكاء يتجاوز القدرات البشرية في الإبداع والحكمة وحل المشكلات [10].

2-2-2 دور الذكاء الاصطناعي في أنظمة التحكم عن بعد والواجهات اللاتلامسية

يشهد مجال التفاعل بين الإنسان والحاسوب (HCI) تحولاً جذرياً مدفوعاً بدمج تقنيات الذكاء الاصطناعي لتحويل التفاعل إلى تجربة أكثر طبيعية وبديهية. تهدف هذه الأنظمة إلى ردم الفجوة بين العالم الفيزيائي والرقمي عبر استخدام الحوسبة الإدراكية (Perceptual Computing) [11].



الشكل 2-1: البنية المعمارية العامة لنظام التفاعل بين الإنسان والحاسوب.

تتجلى أهمية الذكاء الاصطناعي في هذا السياق عبر عدة تطبيقات:

- واجهات المحادثة (NLP): مثل Google Assistant و Alexa التي تعتمد على فهم اللغة الطبيعية [11].

- التفاعل بالإيماءات (Gesture Recognition): وهو جوهر مشروعنا، حيث يتم استخدام رؤية الحاسوب والتعلم العميق لتحليل حركات الجسم واليد [11][12].
- التفاعل العاطفي (Affective Computing): تحليل مشاعر المستخدم عبر تعابير الوجه باستخدام الشبكات التلافيفية [11].
- الواقع المعزز والافتراضي (AR/VR): دمج البيئات الرقمية مع الفيزيائية وتكييف المحتوى باستخدام التعلم الآلي [11].

في إطار دراسة تقنيات التفاعل الحديثة في مجال التفاعل بين الإنسان والحاسوب (Human-Computer Interaction, HCI)، يوضح الجدول 2-2 مقارنةً شاملة بين أبرز هذه التقنيات، مع إبراز مزايا كل تقنية والقيود المرتبطة بها، إضافةً إلى أمثلة تطبيقية شائعة تُستخدم في الأنظمة الذكية والتطبيقات التفاعلية الحديثة. تساعد هذه المقارنة على فهم الفروق الجوهرية بين أساليب التفاعل المختلفة واختيار التقنية الأنسب بحسب طبيعة النظام ومتطلبات المستخدم [11].

التقنية	المزايا	العيوب	أمثلة تطبيقية
الإيماءات	تفاعل طبيعي، لا تلامس، لا تحتاج معدات إضافية.	تتأثر بالإضاءة، تتطلب خوارزميات معقدة.	MediaPipe، Leap Motion
الصوتية	سهولة الاستخدام، دعم تعدد المهام.	مشاكل في الضوضاء، مخاوف الخصوصية.	Amazon Siri، Alexa
المسسية	دقة عالية، رد فعل فوري.	محدودة المساحة، قد تسبب نقل العدوى.	شاشات اللمس التقليدية

Eye Trackers	إجهاد العين، معدات باهظة الثمن.	سريعة جداً، مناسبة لبعض الإعاقات.	العينية
--------------	------------------------------------	--------------------------------------	---------

الجدول 2-2: مقارنة تقنيات التفاعل الحديثة في HCI.

3-2-2 تحديات واجهات المستخدم القائمة على الإيماءات (Gesture-Based UI)

على الرغم من الابتكار الذي تقدمه الواجهات اللائلمسية، إلا أنها تواجه تحديات تقنية وتصميمية معقدة [12]:


- **تحديات الإدراك والاستكشاف:** نظراً لغياب "الأزرار" أو الإشارات الفيزيائية، يجد المستخدم أحياناً صعوبة في اكتشاف الإيماءات المتاحة أو حدود المساحة التفاعلية (Affordance Issues).
- **الإرهاق البدني (Gorilla Arm Syndrome):** وهو المصطلح العلمي للتعب الناتج عن إبقاء الذراع معلقة في الهواء لفترات طويلة أثناء التفاعل الجوي فوق الشاشة.
- **دقة الإشارة وضجيج البيانات:** التباين الفردي في تنفيذ الإيماءات، واختلاف أحجام الأيدي، وضوضاء المستشعرات تجعل تفسير الحركة بدقة 100% أمراً صعباً.
- **التغذية الراجعة (Feedback):** صعوبة توفير تأكيد "لمس" للمستخدم بنجاح العملية، مما يتطلب ابتكار تغذية راجعة بصرية (تغير ألوان) أو صوتية.
- **العوامل البيئية:** الإضاءة المنخفضة، الخلفيات المشوشة التي تشبه لون البشرة، وتداخل الأجسام (Occlusion) تعيق خوارزميات التتبع التقليدية.

2-3 الشبكات العصبية الاصطناعية (ANNs): الأسس وآليات التعلم

2-3-1 البنية الهيكلية للشبكة العصبية (Neuron, Layers)

تُعد الشبكات العصبية الاصطناعية (ANN) نماذج حوسبة مستوحاة بيولوجياً من بنية الدماغ البشري. تتكون من وحدات معالجة مترابطة تسمى العصبونات الاصطناعية، وتنظم في هيكلية

طبقة [13]:



الشكل 2-2: مقارنة بين العصبون البيولوجي والعصبون الاصطناعي.

- **طبقة المدخلات (Input Layer):** تستقبل البيانات الخام (في مشروعنا هي إحداثيات 21 نقطة معلمية لليد 3×3 أبعاد = 63 ميزة).
- **الطبقات الخفية (Hidden Layers):** هي المحرك الرئيسي لتعلم الأنماط المعقدة. تشمل على طبقات كثيفة (Dense)، وتلافيفية (CNN) لاستخراج السمات، وطبقات (Dropout) لمنع الإفراط في التعلم (Overfitting).

- **طبقة المخرجات (Output Layer):** تقوم بإنتاج التنبؤ النهائي وتصنيف الإيماءة إلى فئتها المحددة (مثل: "نقر"، "تمرير"، "إبهام للأعلى").

يوضح الجدول (2-3) عرضاً مقارناً لأهم الأنواع الشائعة من الشبكات العصبية، مع التركيز على طبيعة هيكل كل شبكة ووظيفتها الأساسية، وأبرز مجالات استخدامها، إضافةً إلى التحديات التقنية التي قد تواجه تطبيقها. يساعد هذا العرض في إبراز الفروقات الجوهرية بين هذه النماذج ودورها في دعم تطبيقات الذكاء الاصطناعي المختلفة [13][14].

النوع	الهيكل والوظيفة	التطبيقات الرئيسية	العيوب
CNN	تعتمد على مرشحات تلافيفية لاكتشاف الأنماط المكانية والخصائص المحلية في البيانات.	معالجة الصور والفيديو، الرؤية الحاسوبية.	مكلفة حسابياً وتحتاج إلى بيانات تدريب كبيرة.
RNN / LSTM	شبكات ذات اتصالات تغذية راجعة قادرة على الاحتفاظ بالمعلومات السابقة عبر الذاكرة.	تحليل السلاسل الزمنية، معالجة اللغة الطبيعية.	مشكلة اختفاء التدرج وصعوبة التدريب الطويل.
GNN	تعالج البيانات على شكل رسوم بيانية تتكون من عقد وحواف لتمثيل العلاقات البنيوية.	تمثيل الهيكل العظمي للبيد، الشبكات الاجتماعية.	بنية معقدة جداً وصعوبة في الضبط.

تتطلب حسابية متطلبات حسابية وذاكرة هائلة.	الترجمة الآلية، نمذجة اللغة، النماذج التوليدية.	تتطلب على آليات الانتباه الذاتي (Self- Attention) لمعالجة العلاقات بعيدة المدى.	Transformers
---	--	--	--------------

الجدول 2-3: مقارنة أنواع الشبكات العصبية الرئيسية.

2-3-2 الأوزان (Weights) والانحياز (Bias): المفهوم والدور الرياضي

تعتمد قدرة الشبكة العصبية على التعلم بشكل كامل على تعديل المعاملات الرياضية الداخلية [13]:

- **الأوزان (Weights - w):** تعبر عن قوة الاتصال بين العصبونات. كل مدخل يُضرب في وزن يحدد مدى أهمية هذا المدخل بالنسبة للمخرج النهائي. في الشبكات التلافيفية، تسمى "الأوزان المشتركة".

- **الانحياز (Bias - b):** هو قيمة ثابتة تضاف للمجموع المرجح للمدخلات. وظيفته الأساسية هي إزاحة دالة التنشيط أفقياً أو رأسياً لتمكين العصبون من اتخاذ قرار حتى لو كانت المدخلات صفراً، مما يزيد من مرونة النموذج في محاكاة البيانات.

المعادلة الرياضية للعصبون [13]:

$$y = f\left(\sum_{i=1}^n (w_i \cdot x_i) + b\right) \quad (1-2)$$


حيث: y هو المخرج، f هو دالة التنشيط، x المدخلات، و w الأوزان.

2-3-3 خوارزميات التدريب: الانتشار العكسي (Backpropagation) والنزول المتدرج

(Gradient Descent)

عملية التدريب هي رحلة البحث عن "القيم المثلى" للأوزان والتحييزات لتقليل "دالة الخسارة" (Loss Function) [14].

- الانتشار العكسي (Backpropagation): خوارزمية تستخدم "قاعدة السلسلة" (Chain Rule) في التفاضل لحساب تدرج الخطأ بالنسبة لكل وزن في الشبكة، بدءاً من المخرجات وصولاً للمدخلات [14].



الشكل 2-3: عملية الانتشار العكسي في الشبكات العصبونية.

- النزول المتدرج (Gradient Descent): هو المحسن (Optimizer) الذي يقوم بتحديث الأوزان بناءً على التدرجات المحسوبة. يهدف للوصول إلى "القاع" أو الحد الأدنى للخطأ [14].

أنواع النزول المتدرج [14]:

- Batch GD: يحسب التدرج لكامل مجموعة البيانات (مستقر ولكنه بطيء جداً).

- **Stochastic GD (SGD)**: يحسب التدرج لكل عينة على حدة (سريع ولكنه متذبذب).
- **Mini-batch GD**: يستخدم دفعة صغيرة (مثل 32 أو 64 عينة)، وهو الخيار الأفضل للموازنة بين السرعة والاستقرار.

2-3-4 دوال التنشيط (Activation Functions) وتحسين الأداء (Optimization)

تعمل دوال التنشيط على إدخال اللاخطية (Non-linearity) إلى الشبكة، مما يمنحها القدرة على تعلم الأنماط المعقدة التي لا يمكن تمثيلها بخطوط مستقيمة [13]. يبين الجدول (2-4) مقارنة بين دوال التنشيط (Activation Functions) الأكثر شيوعاً، مع توضيح صيغها الرياضية، مجال قيمها، وأبرز المزايا والقيود المرتبطة بكل دالة. تُعد دوال التنشيط عنصراً محورياً في تحديد قدرة الشبكة العصبية على تمثيل العلاقات غير الخطية وتحسين كفاءة عملية التعلم.

الدالة	المدى	الميزة / العيب
Sigmoid	$(0, 1)$	سهولة الفهم والتنفيذ / تسبب مشكلة اختفاء التدرج (Vanishing Gradient).
Tanh	$(-1, 1)$	متوسطها الصفري يساعد على تسريع التقارب / لا تزال تعاني من اختفاء التدرج.
ReLU	$[0, \infty)$	سريعة جداً وخيار افتراضي للطبقات الخفية / مشكلة «العصبون الميت».
Leaky ReLU	$(-\infty, \infty)$	تقلل مشكلة العصبون الميت عبر السماح بتدرج صغير للقيم السالبة.
Softmax	$(0, 1)$	تُستخدم في طبقة المخرجات لتحويل القيم إلى احتمالات.

الجدول 2-4: دوال التنشيط الشائعة ومقارنتها.

محسنات الأداء الحديثة (Optimizers) [15]:


لتحسين سرعة التقارب، تُستخدم خوارزميات متطورة مثل:

- **Adam**: يجمع بين ميزة الزخم (Momentum) والتكيف (Adaptive Learning Rate)، وهو الأكثر شيوعاً في تتبع الإيماءات.
- **RMSprop**: يعالج مشكلة تضائل معدل التعلم في البيانات المتسلسلة.

2-4 أساسيات الصور الرقمية وتمثيل البيانات المرئية

2-4-1 ماهية البكسل (Pixel) والدقة المكانية للصورة


البكسل (Picture Element) هو أصغر وحدة بنائية للصورة الرقمية، ويمثل عينة بيانات تحمل قيمة عددية تعبر عن اللون والسطوع [16].



الشكل 2-4: البكسلات في الصورة الرقمية.

- **الخصائص الفنية**: يمتلك كل بكسل بعداً مكانياً (y, x) في مصفوفة الصورة، وعمقاً لونياً (Bit Depth) يحدد دقة الألوان [16].

A Pixel and its Friendly Neighbors:



الشكل 5-2: البعد المكاني للبكسل في الصورة.

- **الدقة المكانية (Spatial Resolution):** هي إجمالي عدد البكسلات المكونة للصورة (العرض × الارتفاع). كلما زادت الدقة، زادت تفاصيل معالم اليد (Landmarks) التي يمكن للخوارزمية التقاطها، ولكن هذا يزيد من "التكلفة الحسابية" [16].



High Spatial Resolution




Medium Spatial Resolution



Low Spatial Resolution

الشكل 6-2: مفهوم الدقة المكانية.

- **كثافة البكسلات (PPI):** عدد البكسلات في البوصة الواحدة، وهو ما يحدد وضوح الصورة عند العرض [16].



الشكل 2-7: مفهوم كثافة البكسلات.

2-4-2 الفضاءات اللونية (Color Spaces)


يتم تمثيل الألوان في الرؤية الحاسوبية عبر نماذج رياضية تسمى الفضاءات اللونية، ولكل منها

استخدام محدد [16][17]:

- **نظام RGB (Red, Green, Blue):** نظام جمعي تعتمد عليه الشاشات والكاميرات. مشكلته


الأساسية هي الارتباط الوثيق بين "اللون" و"الإضاءة"، مما يجعله غير مستقر عند تغيير

ظروف الإضاءة في الغرفة [16].




الشكل 2-8: نظام الألوان RGB.

- نظام HSV/HSB (Hue, Saturation, Value): يحاكي إدراك الإنسان. يفصل بين اللون الأساسي (Hue) وكثافته (Saturation) وسطوعه (Value). هذا النظام هو الأفضل لكشف لون البشرة لأن الصبغة (Hue) تبقى ثابتة نسبياً حتى لو تغيرت شدة الإضاءة [17].



الشكل 2-9: نظام الألوان HSV.

- نظام Grayscale (التدرج الرمادي): تمثيل أحادي البعد (قناة واحدة) يقلل حجم البيانات إلى الثلث، مما يسرع المعالجة عند الكشف عن الحركة أو الحواف [17].
- نظام YCrCb: يفصل الإضاءة (Y) عن مكونات اللون (Cr, Cb)، ويُستخدم بكثرة في ضغط الفيديو وفصل اليد عن الخلفيات المعقدة [17].



الشكل 2-10: نظام YCrCb.

في إطار معالجة الصور الخاصة بمهام تتبّع اليد والرؤية الحاسوبية، يوضّح الجدول (5) مقارنةً بين أشهر الفضاءات اللونية المستخدمة في هذا المجال [17].

الفضاء اللونى	عدد القنوات	المزايا	الاستخدام المقترح في المشروع
RGB	3	مباشر وبسيط، متوافق مع أجهزة الالتقاط والعرض.	المدخل الأولي من الكاميرا وعرض النتائج النهائية.
HSV	3	فصل الإضاءة عن المعلومة اللونية، أكثر ثباتاً أمام تغيّر الإضاءة.	تحديد نطاق لون البشرة وعزل اليد عن الخلفية.
Grayscale	1	حجم بيانات صغير وسرعة عالية في المعالجة.	الكشف السريع عن الحركة والحواف.
LAB	3	فضاء إدراكي يفصل الإضاءة عن اللون بشكل فعّال.	تحسين التباين في ظروف الإضاءة الصعبة.

الجدول 5-2: مقارنة الفضاءات اللونية في مهام تتبّع اليد.

2-4-3 أهمية التحويل بين أنظمة الألوان في مهام الرؤية الحاسوبية

التحويل بين أنظمة الألوان (Color Space Conversion) هو خطوة "معالجة مسبقة" لا غنى عنها. على سبيل المثال:

- مكتبة OpenCV تقرأ الصور بتنسيق BGR، بينما يحتاج نموذج MediaPipe لتنسيق RGB [17].
- يتم التحويل إلى HSV لتطبيق "قناع البشرة" (Skin Mask) لعزل اليد عن الخلفية [17].
- يتم التحويل إلى LAB لتطبيق تقنية CLAHE لتحسين الإضاءة وتوضيح مفاصل اليد في الأماكن المظلمة [17].


2-5 تقنيات معالجة الصور الرقمية (Digital Image Processing)

2-5-1 عمليات المعالجة الأولية (Preprocessing): تقليل الضوضاء وتنعيم الصورة (Smoothing)

المعالجة الأولية هي حجر الأساس لضمان دقة عمل الشبكة العصبية، حيث تهدف لتحسين جودة الصورة الملتقطة من الكاميرا وإزالة "الضجيج" البصري [18].

أنواع الضوضاء في الصور الرقمية:

- الضوضاء الغوسية (Gaussian Noise): ناتجة عن الحرارة في مستشعرات الكاميرا وتظهر كتمويه ناعم [18].




الشكل 11-2: الضوضاء الغوسية.

- ضوضاء الملح والفلفل (Salt & Pepper): تظهر كنقاط سوداء وبيضاء عشوائية نتيجة أخطاء في نقل البيانات [18].



الشكل 2-12: ضوضاء Salt & Pepper.

- ضوضاء بواسون (Poisson): تظهر في الصور ذات الإضاءة المنخفضة جداً [18].



الشكل 2-13: ضوضاء بواسون.

تقنيات التنعيم (Smoothing) والمرشحات (Filters)

تعمل المرشحات على تمرير "نواة" (Kernel) فوق الصورة لإعادة حساب قيم البكسلات [18]:

- مرشح المتوسط (Mean Filter): يستبدل البكسل بمتوسط جيرانه (يسبب ضبابية في الحواف).
- مرشح غوسي (Gaussian Filter): يعطي وزناً أكبر للبكسلات القريبة (ممتاز للضوضاء العادية).
- مرشح الوسيط (Median Filter): يستبدل البكسل بالقيمة الوسطى لجيرانه (هو الأفضل لضوضاء الملح والفلفل مع الحفاظ على الحواف).
- المرشح الثنائي (Bilateral Filter): تقنية متقدمة تزيل الضوضاء مع الحفاظ الكامل على الحواف الحادة لليد، مما يسهل على MediaPipe اكتشاف المعالم بدقة.
- تصفية كالمان (Kalman Filter): تُستخدم برمجياً لمعالجة "الارتعاش" (Jitter) في حركة المؤشر الناتج عن تذبذب إحداثيات النقاط المفصلية عبر الزمن.

23	25	30	35	30
25	30	35	37	40
45	40	37	43	45
38	40	43	42	46
35	40	42	45	47

→

		39		

الشكل 2-14: عملية التنعيم في معالجة الصورة.

يوضح الجدول (2-6) مقارنةً بين أشهر مرشحات التنعيم (Smoothing Filters) المستخدمة لتقليل الضوضاء، مع التركيز على قدرتها في الحفاظ على الحواف، مستوى التعقيد الحسابي، ونوع الضوضاء التي تكون أكثر فعالية في معالجتها. يساهم هذا العرض في تبرير اختيار المرشح الأنسب بحسب طبيعة الصورة ومتطلبات النظام [18].

المعيار	مرشح المتوسط	مرشح غوسي	مرشح الوسيط	مرشح ثنائي الجانب
الحفاظ على الحواف	ضعيف جداً	متوسط	جيد جداً	ممتاز
التعقيد الحسابي	منخفض جداً	منخفض	متوسط	عالٍ
الفعالية	ضوضاء بسيطة	ضوضاء غوسية	ضوضاء ملح وفلفل	ضوضاء مع حواف حادة

الجدول 2-6: مقارنة أداء مرشحات التنعيم.


2-5-2 كشف الحواف (Edge Detection) واستخراج الميزات الهندسية

كشف الحواف هو عملية تهدف إلى تحديد التحولات المفاجئة في شدة البكسل داخل الصورة الرقمية، والتي تمثل الحدود الفاصلة بين الأجسام [18]. وتُستخدم هذه الحدود بوصفها تمثيلاً هندسياً مختصراً للشكل، يسهل تحليل البنية العامة للأجسام ضمن تطبيقات الرؤية الحاسوبية. توجد عدة خوارزميات شائعة لكشف الحواف تختلف في مبدأ العمل والدقة والحساسية للضوضاء [18]، كما هو موضح في الجدول (2-7).

الفئة	الخوارزميات	الخصائص العامة	الملاحظات
مشتقات الدرجة الأولى	Sobel, Prewitt	سريعة وبسيطة	حساسية للضوضاء
مشتقات الدرجة الثانية	Laplacian	دقيقة في إبراز الزوايا	شديدة الحساسية للضوضاء
متعددة المراحل	Canny	توازن بين الدقة والاستقرار	الأكثر استخداماً عملياً

الجدول 2-7: مقارنة خوارزميات كشف الحواف.

يوضح الشكل (2-15) نواتج تطبيق خوارزميات كشف الحواف المختلفة على صورة اليد، وإبراز الحدود الهندسية الناتجة.



الشكل 2-15: نواتج تطبيق خوارزميات كشف الحواف المختلفة على صورة اليد.

بعد كشف الحواف، يمكن استخدامها لاستخلاص ميزات هندسية مثل المستقيمات، الزوايا، أو المنحنيات، والتي تمثل الشكل العام للجسم. وتُعد هذه الميزات مدخلاً مناسباً للتحليل الهندسي دون الاعتماد على التفاصيل اللونية [18].

في تطبيق التحكم بالإيماءات باستخدام MediaPipe، يُستفاد من كشف الحواف والميزات الهندسية بوصفها مرحلة داعمة للكشف عن معالم اليد، حيث تُستخدم المسافات والزوايا بين المفاصل والنسب الهندسية في دعم تصنيف الإيماءات، لما تتمتع به من ثبات نسبي مع تغير المسافة عن الكاميرا [19].

3-5-2 عمليات العتبة (Thresholding) والفصل الخلفي (Background

Subtraction)

تُعدّ عمليات العتبة والفصل الخلفي من التقنيات الأساسية في تجزئة الصور (Image Segmentation)، حيث تهدفان إلى فصل مناطق الاهتمام، مثل اليد في تطبيقات التحكم

بالإيماءات، عن الخلفية. وتُستخدم هذه التقنيات كمرحلة معالجة مسبقة لتحسين جودة المدخلات البصرية قبل تمريرها إلى نماذج التتبع مثل MediaPipe [19].


عمليات العتبة (Thresholding)

العتبة هي عملية تحويل الصورة إلى صورة ثنائية اعتمادًا على قيمة حدّية، بحيث يتم تصنيف البكسلات إلى مقدّمة وخلفية. وتُعد من أبسط وأسرع طرق التجزئة، خاصة عند وجود تباين واضح بين اليد والخلفية [18].

نوع العتبة	الوصف المختصر	الاستخدام الأمثل
ثنائية (Binary)	فصل مباشر بين المقدّمة والخلفية	صور عالية التباين
ثنائية معكوسة	عكس نتيجة العتبة الثنائية	خلفيات فاتحة
Truncate	تقطيع القيم فوق العتبة	الحفاظ على التدرج
To Zero	عزل المناطق الساطعة	إبراز اليد
Otsu	تحديد عتبة تلقائيًا	Histogram ثنائي الذروة
Adaptive	عتبة محلية لكل منطقة	إضاءة غير متجانسة

الجدول 8-2: أنواع عمليات العتبة واستخداماتها.

يوضح الشكل (2-16) مبدأ تحويل الصورة إلى صورة ثنائية باستخدام عمليات العتبة، حيث يتم فصل المقدمة عن الخلفية اعتمادًا على قيمة حدية محددة.



الشكل 2-16: آلية تحويل الصورة الرمادية إلى صورة ثنائية باستخدام عمليات العتبة.

الفصل الخلفي (Background Subtraction)


الفصل الخلفي هو تقنية تعتمد على تحليل سلسلة من الإطارات لفصل الخلفية الثابتة عن المقدمة المتحركة. وتستخدم بكثرة في تطبيقات الفيديو، مثل تتبع الحركة والتحكم بالإيماءات في الزمن الحقيقي [18][19].

الخوارزمية	المبدأ	الملاحظات
MOG	نمذجة الخلفية بخليط غاوسي	حساس للتغيرات المفاجئة
MOG2	نسخة محسنة بمرونة أعلى	الأكثر استخدامًا عمليًا
GMG	تجزئة إحصائية	بطيء في البداية
KNN	تصنيف اعتمادًا على الجيران	مقاوم للضوضاء

LSBP	أنماط محلية ثنائية	معقد في التنفيذ
------	--------------------	-----------------

الجدول 2-9: خوارزميات الفصل الخلفي الشائعة.

يوضح المخطط في الشكل (2-17) آلية الفصل الخلفي من خلال مقارنة الإطار الحالي بنموذج الخلفية وتحديثه تدريجيًا لاستخراج قناع المقدمة.



الشكل 2-17: مبدأ الفصل الخلفي وإنتاج قناع المقدمة.

المقارنة بين العتبة والفصل الخلفي

المعيار	العتبة	الفصل الخلفي
نوع البيانات	صورة ثابتة	فيديو
الاعتماد الزمني	لا	نعم
التعقيد الحسابي	منخفض	متوسط-عالي
الاستخدام الأمثل	تباين عالي	خلفية شبه ثابتة
التكيف	محدود	مرتفع

الجدول 2-10: مقارنة العتبة والفصل الخلفي.

التطبيق في التحكم بالإيماءات باستخدام MediaPipe

في تطبيقات التحكم بالإيماءات، تُستخدم تقنيات الفصل الخلفي لعزل اليد عن الخلفية المتحركة، ثم تُطبق عمليات العتبة على قناع المقدّمة لتحسين حدود اليد. يسهم هذا التسلسل في تقليل الضوضاء، وتحسين دقة كشف معالم اليد قبل معالجتها بواسطة MediaPipe [19].

2-6 الشبكات العصبية الالتفافية (CNNs) في تحليل الصور

تُعَدّ الشبكات العصبية الالتفافية (Convolutional Neural Networks – CNNs) من أكثر تقنيات التعلم العميق استخدامًا في تحليل الصور، نظرًا لقدرتها على استخراج الميزات البصرية تلقائيًا من البيانات الخام، مع الحفاظ على البنية المكانية للصورة. تعتمد هذه الشبكات على طبقات متخصصة تمكّنها من تعلّم تمثيلات هرمية تبدأ من الميزات البسيطة كالحواف، وصولًا إلى الأنماط المعقدة [20].


2-6-1 الهيكلية المعمارية لشبكات CNN

تعتمد الهيكلية المعمارية لشبكات CNN على تتابع من الطبقات، لكل منها وظيفة محددة ضمن عملية التعلم [20].

الطبقة	الوظيفة الأساسية	الدور في الشبكة
Convolution	استخراج الميزات المكانية باستخدام مرشحات	تعلم الأنماط البصرية
Pooling	تقليل الأبعاد المكانية	تقليل الحساسية للتغيرات
Fully Connected	دمج الميزات واتخاذ القرار	التصنيف النهائي

الجدول 2-11: الطبقات الأساسية في شبكات CNN.

يوضّح الشكل (2-18) الهيكلية العامة لشبكات CNN، حيث تتولى طبقات الالتفاف والتجميع استخراج الخصائص، بينما تقوم الطبقات المتصلة بعملية التصنيف [20].



الشكل 2-18: البنية المعمارية العامة لشبكة عصبية التلافيفية (CNN).

2-6-2 استخراج الخصائص (Feature Extraction) وتصنيف الصور

تعمل شبكات CNN على استخراج الخصائص بشكل تلقائي من خلال طبقات الالتفاف المتتالية، حيث تتعلم الطبقات الأولى ميزات منخفضة المستوى مثل الحواف والزوايا، بينما تتعلم الطبقات الأعمق أنماطاً أكثر تجريداً. بعد ذلك، تُمرّر هذه الميزات إلى الطبقات المتصلة بالكامل لتحويلها إلى قرارات تصنيف [20].

المرحلة	نوع الميزات	الوظيفة
الطبقات الأولى	حواف، زوايا	توصيف الشكل العام
الطبقات الوسطى	أنماط مركبة	تمثيل الأجزاء
الطبقات الأخيرة	ميزات عالية التجريد	التصنيف

الجدول 2-12: دور طبقات CNN في الاستخراج والتصنيف.

2-6-3 التكامل بين CNN وتقنيات التعرف على الإيماءات

في أنظمة التعرف على الإيماءات، يُستخدم التكامل بين MediaPipe و CNN لتحقيق دقة أعلى. حيث يتولى MediaPipe مهمة استخراج معالم اليد (Landmarks)، بينما تُستخدم شبكات

CNN لتصنيف الإيماءات اعتمادًا على التمثيل البنيوي لهذه المعالم بدلاً من الاعتماد على الصورة الخام [21].

7-2 أدوات الرؤية الحاسوبية: مكتبة OpenCV

تُعد مكتبة (Open Source Computer Vision Library) OpenCV من أكثر أدوات الرؤية الحاسوبية استخدامًا في التطبيقات العملية، نظرًا لكونها مكتبة مفتوحة المصدر وتحتوي على عدد كبير من الخوارزميات المحسّنة لمعالجة الصور والفيديو. تلعب OpenCV دورًا محوريًا في بناء الأنظمة الزمن الحقيقي، خاصة عند دمجها مع أطر مثل MediaPipe في تطبيقات التعرف على الإيماءات [23].

1-7-2 التعريف بمكتبة OpenCV ودورها في التطبيقات الزمن الحقيقي (Real-time)

OpenCV هي مكتبة مفتوحة المصدر للرؤية الحاسوبية والتعلم الآلي، تحتوي على أكثر من 2500 خوارزمية محسّنة لمعالجة الصور، كشف الملامح، تتبع الفيديو، والتعرف على الأنماط. تتميز المكتبة بكونها مكتوبة بلغات منخفضة المستوى (C/C++) مع واجهات برمجية للغات عالية المستوى مثل Python، مما يجعلها مناسبة للتطبيقات الزمن الحقيقي [22].

ويمكن تلخيص الخصائص التي تجعل مكتبة OpenCV مناسبة للتطبيقات الزمن الحقيقي في النقاط التالية [22]:

- تحسين عالٍ للأداء عبر استغلال SIMD و OpenCL
- دعم المعالجة متعددة الخيوط (Multi-threading)
- تقليل زمن الكمون (Latency)

- كفاءة عالية في قراءة الفيديو ومعالجة الإطارات

يسمح هذا التكامل بتنفيذ أنظمة تعمل بمعدلات إطارات مرتفعة تتجاوز 30 إطار/ثانية، وهو ما يجعل OpenCV مناسبة لتطبيقات التفاعل الفوري [23].

2-7-2 الوظائف الأساسية في OpenCV

تُستخدم OpenCV في أنظمة الرؤية الحاسوبية لتنفيذ مجموعة من الوظائف الأساسية التي تشكل خط المعالجة البصري [22].

الوظيفة	الوصف
التقاط الفيديو	قراءة الفيديو من الكاميرا أو الملفات
معالجة الإطارات	تحويل الألوان، الترشيح، التحسين
الرسم على الصور	رسم النقاط، الخطوط، المعالم
التكامل مع MediaPipe	تمرير الإطارات لمعالجة المعالم

الجدول 2-13: الوظائف الأساسية لمكتبة OpenCV.

تُستخدم هذه الوظائف معاً لبناء أنظمة تتبع اليد، حيث تقوم OpenCV بتهيئة ومعالجة الإطارات، بينما يتولى MediaPipe استخراج معالم اليد وتتبعها [23].

2-7-3 إدارة العمليات الحسابية المصفوفية للصور داخل OpenCV

تعتمد OpenCV في تمثيل الصور على المصفوفات الرقمية، حيث تُخزن الصور ككائنات من نوع Mat، تمثل القيم اللونية لكل بكسل [22]. تشكل هذه البنية الأساس لتنفيذ العمليات الحسابية المختلفة على الصور [22].

تمثيل الصورة كمصفوفة [22]

- الصفوف (Rows): تمثل ارتفاع الصورة
- الأعمدة (Columns): تمثل عرض الصورة
- القنوات (Channels): تمثل مكونات اللون

تصنيف العمليات المصفوفية [22]

الاستخدام	النوع	الفئة
دمج الصور	جمع، طرح، ضرب	عمليات حسابية
الأقنعة	XOR ،OR ،AND	عمليات منطقية
التحويلات	ضرب مصفوفي	عمليات جبر خطي
الترشيح	Convolution	عمليات التفاف

الجدول 2-14 تصنيف العمليات المصفوفية في OpenCV.

تحسين الأداء والذاكرة

توفر OpenCV آليات لإدارة الذاكرة بكفاءة عالية، مثل مشاركة البيانات بدل نسخها، واستخدام العمليات المتجهة لتقليل زمن التنفيذ، مما يجعلها مناسبة للأنظمة الزمن الحقيقي [22].

2-8 تقنية MediaPipe وتتبع الهيكل البشري

تمثل تقنية MediaPipe إطار عمل متقدم مفتوح المصدر طورته Google، يهدف إلى بناء خطوط معالجة (Pipelines) فعالة لتطبيقات الرؤية الحاسوبية والتعلم الآلي في الزمن الحقيقي [23]. يتميز MediaPipe بقدرته على معالجة تدفقات الفيديو واستخراج المعالم الهيكلية للبدن والجسم بدقة عالية مع كفاءة حسابية مناسبة للتطبيقات التفاعلية [23].

2-8-1 بنية إطار عمل MediaPipe وخطوط المعالجة (Pipelines)


يعتمد MediaPipe على مفهوم الرسوم البيانية (Graphs) لتمثيل خطوط المعالجة، حيث يتم تنظيم تدفق البيانات على شكل عقد (Calculators) وروابط (Streams) [23]. كل Calculator يمثل وحدة معالجة مستقلة، بينما تمثل Streams قنوات نقل البيانات بين الوحدات المختلفة [23].

تتسم خطوط المعالجة في MediaPipe بالخصائص التالية [23]:

- المعالجة المتوازية للإطارات
- دعم التدفق الزمني المستمر للبيانات
- المرونة في إعادة ترتيب أو استبدال وحدات المعالجة
- الكفاءة في استغلال موارد المعالج

يسمح هذا التصميم ببناء أنظمة قابلة للتوسع تعمل في الزمن الحقيقي حتى على الأجهزة محدودة الموارد [23].

يوضح الشكل التالي البنية العامة لإطار عمل MediaPipe وآلية تنظيم خطوط المعالجة (Pipelines)، حيث يتم تمثيل النظام على شكل رسم بياني يحدد وحدات المعالجة وتدفق البيانات بينها من مرحلة الإدخال حتى الإخراج [23].



الشكل 2-19: البنية العامة لخط المعالجة (Pipeline) في إطار MediaPipe.

2-8-2 نموذج MediaPipe Hands المعمارية والأداء

يعد MediaPipe Hands أحد الحلول الجاهزة ضمن إطار MediaPipe، وهو مصمم لاكتشاف

وتتبع اليدين في الزمن الحقيقي. يعتمد النموذج على مرحلتين أساسيتين [24]:

- كشف راحة اليد (Palm Detection) باستخدام نموذج BlazePalm خفيف الوزن.

- تقدير معالم اليد (Hand Landmarks) عبر نموذج شبكي تلافيفي يستخرج 21 نقطة رئيسية لكل يد.

يمتاز النموذج بما يلي [24]:

- دعم التتبع ثلاثي الأبعاد النسبي.
- العمل بمعدلات إطارات مرتفعة.
- تقليل الحاجة لإعادة الاكتشاف في كل إطار عبر آلية التتبع.
- حجم نموذج صغير مقارنة بالبدائل الأخرى.

لتقييم كفاءة نموذج MediaPipe Hands من حيث السرعة والدقة وقابلية التشغيل في الزمن الحقيقي، من المفيد مقارنته مع أطر عمل شائعة أخرى في مجال تتبع اليد والوضعية مثل OpenPose و MoveNet [24]. يوضح الجدول التالي مقارنة أداء مختصرة بين هذه النماذج، مع التركيز على الخصائص الأكثر ارتباطًا بتطبيقات التحكم بالإيماءات والتفاعل الفوري مع الحاسوب.

المعيار	MediaPipe Hands	OpenPose	MoveNet
سرعة المعالجة	عالية جدًا (زمن حقيقي)	متوسطة	عالية
الدقة	عالية	عالية جدًا	عالية
عدد النقاط	21 نقطة لليد	حتى 21 نقطة لليد (ضمن نموذج كامل للجسم)	يركّز على الجسم (لا يد تفصيلي)

دعم الزمن الحقيقي	نعم	محدود	نعم
المتطلبات الحاسوبية	منخفضة	مرتفعة	متوسطة
دعم الأجهزة المحمولة	ممتاز	ضعيف	جيد
سهولة التكامل	عالية	متوسطة	عالية
ملاءمة التحكم بالإيماءات	ممتازة	محدودة	محدودة


الجدول 2-15: مقارنة أداء MediaPipe Hands مع OpenPose و MoveNet.

2-8-3 الرسم البياني لليد (Hand Graph) واستخراج النقاط المميزة (Landmarks)

يمثل Hand Graph توصيفاً هندسياً لبنية اليد، حيث تُنمذج اليد على شكل رسم بياني مكوّن من عقد (النقاط المميزة) وروابط تمثل العلاقات التشريحية بين المفاصل. تعتمد MediaPipe Hands على استخراج 21 نقطة مميزة تمثل الرسغ، مفاصل الأصابع، وأطرافها [24].

تُستخدم هذه البنية في [24]:

- تتبع الحركة الدقيقة للأصابع.
- فهم شكل الإيماءة.
- بناء علاقات هندسية قابلة للتحليل الرياضي.



الشكل 2-20: نقاط اليد الـ 21.

2-9 تقدير الوضعية (Pose Estimation) وتحليل حركة اليد


يُعد تقدير الوضعية أحد المفاهيم الأساسية في أنظمة التعرف على الإيماءات، حيث يهدف إلى تحديد مواضع المفاصل والعلاقات المكانية بينها من الصور أو الفيديو [24].

2-9-1 مفهوم تقدير الوضعية: من ثنائي الأبعاد إلى ثلاثي الأبعاد

في التقدير ثنائي الأبعاد (2D Pose Estimation)، يتم تحديد إحداثيات (x, y) للنقاط المفصلية ضمن مستوى الصورة، بينما يسعى التقدير ثلاثي الأبعاد (3D Pose Estimation) إلى استعادة البعد الثالث (z) لتمثيل الحركة في الفراغ [24].

يُعد الانتقال من 2D إلى 3D تحديًا رئيسيًا بسبب فقدان معلومات العمق أثناء التصوير، ويتم التعامل معه باستخدام نماذج تعلم عميق أو استنتاج هندسي مبني على المعرفة التشريحية [25].

يوضح الشكل التالي الفرق المفاهيمي بين تقدير الوضعية ثنائي الأبعاد وثلاثي الأبعاد، من خلال تمثيل النموذج ثلاثي الأبعاد لليد وآلية إسقاطه على مستوى الصورة لاستخراج الإحداثيات المفصلية المستخدمة في تحليل الحركة [24].



الشكل 2-21: مقارنة بين تقدير الوضعية ثنائي الأبعاد (2D) وثلاثي الأبعاد (3D) لليد.

2-9-2 الخريطة الطبوغرافية لليد: دلالات النقاط الـ 21 وعلاقتها الهندسية

تمثل الخريطة الطبوغرافية لليد توصيفاً هندسياً للعلاقات بين النقاط المميزة، حيث تُحدد المسافات، الزوايا، والتسلسل الهرمي من الرسغ إلى أطراف الأصابع [24]. تساعد هذه الخريطة في فهم الوضعية العامة لليد وتفسير الإيماءات المعقدة [24].

ولتوضيح هذا التوصيف الهندسي بصورة منهجية، يبين الجدول التالي توزيع النقاط المفصلية لليد ودلالاتها الوظيفية، مع إبراز العلاقات الهندسية الأساسية التي تربط بينها ضمن الخريطة الطبوغرافية [24].

مجموعة النقاط	أرقام النقاط (MediaPipe)	الموقع التشريحي	الدور الطبوغرافي	العلاقات الهندسية الأساسية	الدلالة في تفسير الإيماءات
الرسغ	0	قاعدة اليد	نقطة الجذر (Root)	مرجع المسافات والاتجاه العام	تحديد اتجاه اليد وحركتها العامة

الإبهام	1 – 4	مفاصل وطرف الإبهام	فرع مستقل عن بقية الأصابع	زوايا الانثناء + المسافة عن الرسغ	التمييز بين القبض، النقر، والإشارة
السبابة	5 – 8	مفاصل وطرف السبابة	إصبع تحكمي رئيسي	زاوية المفاصل + المسافة مع الإبهام	الإشارة، النقر، النتبع
الوسطى	9 – 12	مفاصل وطرف الوسطى	محور مركزي لليد	زوايا الانثناء والاستقامة	دعم الإيماءات المركبة
البنصر	13 – 16	مفاصل وطرف البنصر	إصبع داعم للحركات	علاقات توازي مع الوسطى	تعزيز استقرار الوضعية
الخنصر	17 – 20	مفاصل وطرف الخنصر	طرف توازني	المسافة عن مركز الكف	التمييز بين فتح وغلق اليد
أطراف الأصابع	4، 8، 12، 20، 16	نهايات الأصابع	نقاط تفاعل	مسافات بين الأطراف	التعرف على الإيماءات الدقيقة
مفاصل الأصابع	باقي النقاط	نقاط الانثناء	تمثيل الحركة	زوايا بين ثلاث نقاط متتالية	تحليل شكل الإيماءة

الجدول 2-16: الخريطة الطبوغرافية لليد ودلالات النقاط الـ 21 وعلاقاتها الهندسية

2-9-3 استخدام العلاقات الهندسية بين النقاط لتفسير الإيماءات

تعتمد عملية تفسير الإيماءات على تحليل العلاقات الهندسية بين النقاط [25]، مثل:

- المسافات بين أطراف الأصابع
- الزوايا بين المفاصل
- التغير الزمني في مواضع النقاط

تسمح هذه العلاقات بتمييز الإيماءات المتشابهة شكلياً ولكن المختلفة حركياً [25].


2-10 موضوعات متقدمة في أنظمة التعرف على الإيماءات

يتجاوز هذا القسم التعرف اللحظي للإيماءات ليتناول الجوانب الزمنية، النماذج الهجينة، والتحديات الواقعية وتقييم الأداء [25].

2-10-1 المعالجة الزمنية للإيماءات باستخدام LSTM أو GRU

تعتمد الإيماءات الديناميكية على تسلسل زمني من الوضعيات، مما يستدعي استخدام نماذج قادرة على تمثيل الاعتماد الزمني [26]. تُستخدم شبكات LSTM و GRU لمعالجة هذه التسلسلات وتحليل تطور الإيماءة عبر الزمن [26].

يوضح الشكل التالي آلية معالجة الإيماءات الديناميكية اعتماداً على تسلسل زمني من الإطارات المستخرجة من الفيديو، حيث يتم أولاً استخراج الإطارات ومعالجتها مبدئياً، ثم تحليل الميزات المكانية باستخدام الشبكات الالتفافية، قبل تمرير التمثيلات الناتجة إلى نماذج LSTM لالتقاط الاعتماد الزمني بين الوضعيات المتعاقبة وصولاً إلى تصنيف الإيماءة [26].



الشكل 2-22: مخطط معالجة الإيماءات الزمنية باستخدام CNN و LSTM.

2-10-2 النموذج الهجين: التكامل بين MediaPipe و CNN

يجمع النموذج الهجين بين [25][27]:

- MediaPipe لاستخراج الميزات الهندسية الدقيقة
- CNN لتصنيف الإيماءات اعتمادًا على تمثيل بصري أو مُعاد تشكيله

يوفر هذا الدمج توازنًا بين الدقة والكفاءة الزمنية [27].

2-10-3 التحديات البيئية: الإضاءة، التداخل، وتنوع الخلفيات

تؤثر العوامل البيئية بشكل مباشر على دقة أنظمة التعرف على الإيماءات، وتشمل [28]:

- تغيرات الإضاءة
- التداخل بين الأجسام
- الخلفيات المعقدة

تتطلب هذه التحديات حلولاً متعددة المستويات تشمل المعالجة المسبقة، النمذجة المتقدمة، وزيادة البيانات [28].

التحدي البيئي	التأثير على النظام	الحلول المقترحة
تغير الإضاءة	ضعف دقة الكشف عن اليد	توحيد الإضاءة، المعالجة المسبقة
التداخل بين الأجسام	أخطاء في تتبع اليد	فصل الخلفية، تتبع المعالم
الخلفيات المعقدة	اكتشافات خاطئة	نماذج مقاومة للضوضاء، زيادة البيانات
اختلاف المستخدمين	تباين في الإيماءات	تدريب على بيانات متنوعة

الجدول 2-17: التحديات البيئية في أنظمة التعرف على الإيماءات.

2-10-4 مقاييس تقييم الأداء

يتم تقييم أنظمة التعرف على الإيماءات باستخدام عدة مقاييس، أهمها [29]:

- الدقة (Accuracy)

- مصفوفة الارتباك (Confusion Matrix)

- زمن الاستجابة (Latency)

توفر هذه المقاييس رؤية شاملة لموثوقية النظام وكفاءته في الزمن الحقيقي.

ولتوضيح هذه المقاييس بصورة منهجية، يعرض الجدول التالي أهم مؤشرات تقييم أداء أنظمة

التعرف على الإيماءات، مع بيان وصف كل مقياس ودلالته العملية في قياس موثوقية النظام

وكفاءته في بيئات الزمن الحقيقي [29].

المقياس	الوصف	الدلالة العملية
Accuracy	نسبة التنبؤات الصحيحة	التقييم العام للنظام
Confusion Matrix	توزيع التنبؤات الصحيحة والخاطئة	تحليل الأخطاء
Latency	زمن الاستجابة	ملاءمة الزمن الحقيقي
Throughput	عدد الإطارات المعالجة	كفاءة الأداء


الجدول 2-18: مقاييس تقييم أداء أنظمة التعرف على الإيماءات.

2-11 الدراسات السابقة

شهد مجال التفاعل بين الإنسان والحاسوب (Human-Computer Interaction, HCI) تطوراً ملحوظاً خلال السنوات الأخيرة، مدفوعاً بالتقدم السريع في تقنيات الرؤية الحاسوبية والتعلم العميق، لا سيما في أنظمة التفاعل القائم على إيماءات اليد [30]. وقد برز إطار العمل MediaPipe الذي طوّره شركة Google كأحد أهم الحلول العملية والبحثية لتتبع اليد في الزمن الحقيقي، نظراً لدقته العالية وقدرته على العمل على الأجهزة محدودة الموارد دون الحاجة إلى معدات استشعار إضافية [24].

التحكم في الحاسوب باستخدام إيماءات اليد

تناولت عدة دراسات ومشاريع تطبيقية تصميم أنظمة تتيح التحكم عن بعد في الحاسوب باستخدام إيماءات اليد، حيث اعتمدت هذه الأعمال بشكل أساسي على وحدة MediaPipe Hands القادرة على استخراج 21 نقطة معلمية (Landmarks) لليد بدقة عالية وفي الزمن الحقيقي. وقد مكّن هذا التمثيل الهندسي الدقيق لليد من تحليل أوضاع الأصابع والمسافات والزوايا بينها، مما أتاح التعرف على إيماءات مختلفة وربطها بأوامر حاسوبية محددة [24][30].




الشكل 2-23: لقطات شاشة للتعرف على الإيماءات في الوقت الفعلي.

في هذا السياق، طُوّرت أنظمة تحكم بالوسائط المتعددة وسطح المكتب، تسمح بتنفيذ أوامر مثل تشغيل وإيقاف الفيديو، التحكم بمستوى الصوت، التنقل بين الشرائح التقديمية، وتحريك مؤشر الفأرة، وذلك بالاعتماد على كاميرا ويب تقليدية فقط [30]. استخدمت هذه الأنظمة مكتبات مثل OpenCV لمعالجة الصور وعرض التغذية المرئية، إلى جانب مكتبات محاكاة الإدخال مثل PyAutoGUI و pynput لتنفيذ أحداث لوحة المفاتيح والفأرة [30]. وقد أثبتت هذه المقاربة فعاليتها في توفير واجهات تفاعل طبيعية لا تلامسية، خاصة في البيئات التي تتطلب تقليل الاتصال المباشر بالأجهزة [30].

وقد شكّلت الورقة المرجعية لـ MediaPipe Hands الأساس النظري لهذه التطبيقات، حيث قدّم Zhang وآخرون نموذجاً هجيناً يجمع بين الكشف الأولي لليد باستخدام الشبكات العصبية والتتبع اللاحق للنقاط المعلمية، مما حقق توازناً بين الدقة العالية والكفاءة الحسابية، وجعل النظام مناسباً للتطبيقات التفاعلية الفورية [24].

لوحات مفاتيح وفأرات افتراضية قائمة على الإيماءات

اتجهت دراسات أخرى إلى توسيع مفهوم التحكم بالإيماءات ليشمل محاكاة لوحة المفاتيح والفأرة الافتراضية، بهدف تحسين تجربة المستخدم وزيادة كفاءة التفاعل، خصوصاً للأشخاص ذوي الإعاقات الحركية أو في بيئات العمل التي تتطلب تقليل الجهد البدني [31]. في هذا الإطار، تم اقتراح أنظمة تعتمد على MediaPipe بالتكامل مع مصنفات تعلم آلة خفيفة مثل Support Vector Machine (SVM) أو Random Forest، حيث يتم تدريب النموذج على بيانات إيماءات مسجلة مسبقاً بدلاً من الاعتماد فقط على المنطق الشرطي القائم على المسافات [31].



الشكل 2-24: لوحة المفاتيح الافتراضية.

أظهرت هذه الدراسات أن استخدام خوارزميات التصنيف يسهم في تحسين دقة التعرف على الإيماءات المعقدة وتقليل معدلات الخطأ، خاصة في الحالات التي تتشابه فيها أوضاع اليد [31]. كما بينت النتائج أن هذه الأنظمة قادرة على العمل بكفاءة في الزمن الحقيقي، مع استجابة مقبولة من ناحية الأداء، مما يجعلها مناسبة للتطبيق العملي في أنظمة HCI الحديثة [31].

التفاعل بالإيماءات في بيئات التطوير والواقع الافتراضي

لم يقتصر استخدام إيماءات اليد على التحكم الأساسي بالحاسوب، بل امتد ليشمل بيئات التطوير المتكاملة (IDEs) والعروض التقديمية التفاعلية [30]. فقد تناولت بعض المشاريع تصميم أنظمة مساعدة للمبرمجين أثناء جلسات البرمجة أو العروض الحية، تتيح تنفيذ أوامر شائعة مثل تشغيل الشيفرة أو التنقل بين التبويبات دون لمس لوحة المفاتيح [30]. وقد اعتمدت هذه الأنظمة على وحدة MediaPipe Holistic التي تجمع بين تتبع اليد والجسم والوجه، مما وفر مجموعة أوسع من الإشارات الحركية الغنية [24].

إضافة إلى ذلك، تناولت دراسات حديثة استخدام إيماءات اليد للتحكم التفاعلي في العوالم الافتراضية والمعززة (VR/AR)، وفي العروض المعروضة على شاشات كبيرة في المتاحف وقاعات المؤتمرات [30]. وقد استُخدمت حزمة MediaPipe بلغة JavaScript لتشغيل هذه الأنظمة مباشرة في المتصفح، بالتكامل مع مكتبات رسومية مثل Three.js و p5.js [30]. كما لجأت بعض الأعمال إلى استخدام خوارزميات تنعيم الحركة، مثل مرشح Kalman، لتحسين استقرار التتبع وتقليل الاهتزاز، مما عزز من سلاسة التفاعل وتجربة المستخدم [30].

2-11-1 خلاصة الدراسات السابقة

من خلال استعراض هذه الأعمال، يتضح أن MediaPipe يشكّل منصة قوية ومرنة لتطوير أنظمة التفاعل بالإيماءات، حيث أثبتت الدراسات السابقة فعاليته في التحكم بالحاسوب، دعم التطبيقات المساعدة، والتفاعل مع البيئات الافتراضية، مع الحفاظ على متطلبات عتادية منخفضة نسبياً. ومع ذلك، تشير بعض الدراسات إلى تحديات تتعلق بتأثر الأداء بظروف الإضاءة وتعقيد

بعض الإيماءات، مما يفتح المجال أمام مزيد من التحسينات في مراحل المعالجة المسبقة والتصنيف.

2-11-2 مقارنة الدراسات السابقة مع فكرة المشروع المقترح

بالرغم من تعدد الدراسات والمشاريع السابقة التي تناولت استخدام إيماءات اليد في التفاعل بين الإنسان والحاسوب، إلا أن معظم هذه الأعمال ركزت على تطبيقات جزئية أو محدودة الوظائف، مثل التحكم في الوسائط المتعددة، محاكاة الفأرة ولوحة المفاتيح، أو دعم بيانات محددة كالعروض التقديمية أو البيانات الافتراضية. وقد اعتمدت هذه الدراسات بشكل أساسي على إطار العمل MediaPipe لاستخراج المعالم اليدوية في الزمن الحقيقي، مع توظيف منطق شرطي أو مصنفات تعلم آلة بسيطة لربط الإيماءات بأوامر حاسوبية.

في المقابل، تأتي فكرة المشروع المقترح بعنوان التحكم عن بعد لتطبيقات أجهزة الحاسوب باستخدام إيماءات اليد عبر تقنية الذكاء الاصطناعي باستخدام خوارزمية MediaPipe لتوسّع نطاق هذه الأعمال السابقة من خلال تقديم نظام تحكم عام وشامل قادر على التفاعل مع تطبيقات الحاسوب المختلفة، وليس مقتصرًا على سيناريو استخدام واحد. إذ يهدف المشروع إلى تصميم واجهة تفاعل ذكية تسمح بتنفيذ أوامر متعددة عن بعد، مثل التحكم بالتطبيقات، إدارة النوافذ، والتنقل داخل النظام، اعتماداً على تحليل إيماءات اليد بشكل دقيق وموثوق.

كما يتميز المشروع المقترح عن بعض الدراسات السابقة باعتماده الواضح على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية ضمن إطار متكامل، يبدأ من النقاط الصورة ومعالجتها مسبقاً، مروراً بتتبع معالم اليد باستخدام MediaPipe، وصولاً إلى تفسير الإيماءات وربطها بأوامر حاسوبية في الزمن الحقيقي. هذا التكامل يهدف إلى تحسين دقة التعرف على الإيماءات وتقليل

الأخطاء الناتجة عن تغيّر الإضاءة أو اختلاف أوضاع اليد، وهي تحديات أشار إليها عدد من الباحثين في الأعمال السابقة.

إضافةً إلى ذلك، يركّز المشروع على تحقيق تفاعل لا تلامسي بالكامل دون الحاجة إلى أجهزة استشعار خاصة أو معدات إضافية، مما يجعله عملياً وقابلاً للتطبيق في البيئات التعليمية، المكتبية، والصحية. وبذلك، يمكن اعتبار المشروع امتداداً عملياً للدراسات السابقة، حيث يستفيد من الأسس النظرية والتقنية التي قدمتها، مع تقديم حل أكثر شمولية ومرونة يخدم عدداً أوسع من تطبيقات الحاسوب.

وعليه، فإن المشروع المقترح لا يكرر ما ورد في الدراسات السابقة، بل يبني عليها ويطورها من خلال توسيع نطاق الاستخدام، وتحسين آلية التفاعل، وتقديم نموذج تطبيقي متكامل يعكس الإمكانيات الحديثة لتقنيات الذكاء الاصطناعي في مجال التفاعل بين الإنسان والحاسوب.

الفصل الثالث: الدراسة التحليلية

3-1 مقدمة

3-2 تحليل المشكلة

تعتمد أنظمة التفاعل السائدة بين الإنسان والحاسوب على وسائط إدخال مادية مثل الفأرة ولوحة المفاتيح كنموذج رئيسي للتحكم. وعلى الرغم من التطور الكبير في قدرات المعالجة الحاسوبية، فإن هذا النموذج لا يزال يفرض آلية تفاعل مصطنعة تتطلب من المستخدم التكيف مع أدوات وسيطة بدلاً من استخدام حركاته الطبيعية.

تتمثل المشكلة البحثية في غياب نموذج تفاعل بديل أكثر طبيعية ومرونة وشمولية، قادر على تجاوز القيود المادية للنماذج التقليدية مع الحفاظ على مستوى مناسب من الدقة والكفاءة. ويمكن تحديد أبعاد هذه المشكلة في المحاور التالية:

أولاً، الطبيعة غير الطبيعية للتفاعل، حيث يُطلب من المستخدم تعلم آليات تحكم تعتمد على أدوات وسيطة واختصارات محددة، بدلاً من الاستفادة من لغة الجسد الطبيعية.

ثانياً، القيود التشغيلية التي تفرض وجود المستخدم بالقرب من الجهاز وإمكانية لمسه، مما يحد من مرونة الاستخدام في حالات تتطلب تفاعلاً غير تلامسي.

ثالثاً، الإقصاء الرقمي، إذ تواجه بعض الفئات، وخاصة ذوي الإعاقات الحركية، صعوبة أو استحالة في استخدام وسائل الإدخال التقليدية.

وعلى الرغم من أن التحكم بالإيماءات يُعد بديلاً واعداً، فإن تطوير أنظمة عملية وموثوقة في هذا المجال واجه مجموعة من التحديات التقنية التي يمكن تصنيفها ضمن ثلاثة محاور رئيسية:

أولاً: التحديات البصرية والبيئية

- تؤثر البيئة المحيطة بشكل مباشر على أداء أنظمة الرؤية الحاسوبية. ومن أبرز هذه التحديات:
- **تغير ظروف الإضاءة:** تؤدي الإضاءة القوية إلى تشبع بصري، بينما تسبب الإضاءة الخافتة فقداناً في التفاصيل الدقيقة لليد، مما ينعكس على دقة التتبع.
- **تعقيد الخلفية:** وجود عناصر أو ألوان مشابهة للبشرة في الخلفية يصعب عملية فصل اليد عن الخلفية، ويزيد من حساسية النظام للأخطاء.
- **مشكلة الانسداد (Occlusion):** قد تحجب أجزاء من اليد أجزاءً أخرى أثناء الحركة، مما يؤدي إلى فقدان معلومات مهمة حول وضعية الأصابع.
- **تنوع ألوان وأحجام البشرة:** يتطلب النظام القدرة على التكيف مع اختلافات المستخدمين من حيث لون البشرة وحجم اليد وشكلها دون الاعتماد على افتراضات ثابتة.

ثانياً: التحديات الحسابية

- **الموازنة بين الدقة والسرعة:** تحقيق دقة عالية يتطلب نماذج حاسوبية معقدة تستهلك موارد كبيرة، بينما تحتاج تطبيقات الزمن الحقيقي إلى سرعة معالجة لا تقل عن 30 إطاراً في الثانية لضمان سلاسة التفاعل. تمثل الموازنة بين هذين العاملين تحدياً أساسياً.
- **ارتعاش المؤشر (Jitter):** الطبيعة غير الثابتة لحركة اليد البشرية تؤدي إلى اهتزاز المؤشر، مما يؤثر على تجربة الاستخدام، ويستدعي استخدام تقنيات تنعيم تقلل الارتعاش دون زيادة زمن الاستجابة.

ثالثاً: التحديات المرتبطة بتفسير الإيماءات

- التمييز بين الإيماءة القصدية والحركة العشوائية: يتطلب النظام القدرة على التفريق بين الحركات اليومية غير المقصودة والإيماءات التي تمثل أمراً فعلياً للتحكم.
- غموض الإيماءات: توجد إيماءات متشابهة شكلياً ولكن تختلف ديناميكياً من حيث السرعة أو مدى الحركة. فعلى سبيل المثال، قد تختلف حركة النقر من مستخدم لآخر، مما يتطلب نموذجاً قادراً على فهم النمط الحركي وليس الشكل اللحظي فقط.
- الإيماءات الديناميكية: تفسير الحركات التي تتغير عبر الزمن، مثل التمرير أو الرسم في الهواء، يتطلب معالجة تسلسل زمني من البيانات وفهم تطور الحركة عبر عدة إطارات متتالية، وليس الاعتماد على إطار واحد فقط.

3-2-1 تحليل الحلول الحالية وتحديد الفجوة البحثية

تم تحليل الحلول المطروحة في الأدبيات وتصنيفها إلى فئتين رئيسيتين:

- الحلول القائمة على الأجهزة القابلة للارتداء (Wearable-based): مثل القفازات المزودة بمستشعرات، والتي تتميز بدقة عالية في التتبع، إلا أنها تعاني من ارتفاع التكلفة، الحاجة إلى أجهزة إضافية، وصعوبة الاستخدام، مما يقلل من طبيعة التفاعل.
- الحلول القائمة على الرؤية الحاسوبية التقليدية (Vision-based): تعتمد على كاميرات عمق أو خوارزميات تقليدية، وقد واجهت مشكلات تتعلق بالانسداد، الحساسية للإضاءة، والحاجة إلى تجهيزات خاصة ومكلفة.

من خلال هذا التحليل تتحدد الفجوة البحثية في غياب حل يجمع بين دقة التتبع، التكلفة المنخفضة باستخدام كاميرا ويب عادية، القدرة على العمل في الزمن الحقيقي على الأجهزة الشخصية، والمرونة في التعامل مع اختلافات البيئة المحيطة.

3-2-2 صياغة فرضيات الحل

استنادًا إلى ما سبق، يقوم الحل المقترح على الفرضيات التالية:

1. يمكن تحقيق تتبع دقيق وموثوق لليد في الزمن الحقيقي باستخدام كاميرا ويب عادية من خلال توظيف نموذج MediaPipe.
2. يمكن تفسير الإيماءات عبر نهج هجين يجمع بين الحسابات الهندسية للإيماءات البسيطة واستخدام مصنفات تعلم الآلة للإيماءات الأكثر تعقيدًا.
3. يمكن تحسين متانة النظام ضد تغيرات الإضاءة والخلفية عبر دمج مراحل معالجة مسبقة مثل التحويل بين الفضاءات اللونية وتقنيات فصل الخلفية.
4. يمكن تصميم قاموس إيماءات بديهي يغطي الوظائف الأساسية للتحكم بالحاسوب دون التسبب بإرهاق حركي.

3-3 تحليل متطلبات النظام

3-3-1 المتطلبات الوظيفية للنظام

يجب أن يحقق النظام الوظائف التالية:

- الاتصال بكاميرا الويب والنقاط فيديو حي.
- اكتشاف اليد وتتبعها في الزمن الحقيقي.
- استخراج 21 نقطة معلمية تمثل مفاصل اليد وأطراف الأصابع.
- عرض تغذية بصرية راجعة تتضمن صورة الكاميرا ورسم النقاط المعلمية والإيماءة المتعرف عليها.

- تحريك مؤشر الفأرة بناءً على حركة السبابة.
- تنفيذ النقر عند جمع الإبهام والسبابة.
- تنفيذ النقر المزدوج عند تكرار إيماءة الجمع بسرعة.
- تنفيذ النقر الأيمن عند طي السبابة.
- تنفيذ السحب والإفلات عند قبضة اليد وتحريكها.
- رفع مستوى الصوت عند تحريك اليد المفتوحة لأعلى.
- خفض مستوى الصوت عند تحريك اليد المفتوحة لأسفل.
- تشغيل أو إيقاف الفيديو عند عرض كف مفتوح ثابت.
- التكبير عند بسط الأصابع.
- التصغير عند قبض الأصابع.
- تنفيذ التمرير العمودي عند تحريك إصبعين مضمومين.
- تمييز الإيماءات القصدية وتجاهل الحركات العشوائية.
- توفير آلية لجمع بيانات الإيماءات لأغراض التدريب.
- دعم توسيم البيانات (Data Labeling).
- تدريب نماذج تعلم الآلة لتحسين دقة التصنيف.
- تقييم أداء النموذج باستخدام مقاييس مناسبة.
- تحديث قاموس الإيماءات.
- ضبط المعلمات مثل عتبات الثقة ومسافات النقر وزوايا الإيماءات.

3-3-2 المتطلبات غير الوظيفية

- العمل في الزمن الحقيقي بمعدل 25-30 إطارًا في الثانية.
- زمن استجابة لا يتجاوز 150 مللي ثانية.
- تحقيق دقة تعرف تتجاوز 90% في ظروف الإضاءة الجيدة وألا تقل عن 85% في الظروف الصعبة.
- العمل بكفاءة على المعالج المركزي دون الحاجة إلى معالج رسومات قوي.
- المتانة في مواجهة تغيرات الإضاءة والخلفيات المختلفة.
- سهولة الاستخدام وبديهية قاموس الإيماءات.
- الاستقرار وعدم التوقف المفاجئ أثناء الاستخدام الطويل.
- قابلية التوسع لإضافة إيماءات جديدة مستقبلاً.
- الحفاظ على الخصوصية بعدم تخزين أو إرسال الفيديو الحي.
- توثيق الكود وآلية الاستخدام بشكل واضح.

3-3-3 حالات الاستخدام

يمثل مخطط حالات استخدام المستخدم العادي التفاعل المباشر بين المستخدم والنظام في مرحلة التشغيل. يظهر الفاعل "المستخدم العادي" خارج حدود النظام، وتتفرع منه جميع حالات الاستخدام المرتبطة بوظائف التحكم الأساسية. يعكس المخطط أن المستخدم يتفاعل مع النظام حصريًا من خلال مجموعة محددة من الإيماءات الثابتة التي تُترجم إلى أوامر تشغيلية، وتشمل: تحريك مؤشر الفأرة (عبر إيماءة القبضة 🖐️)، تنفيذ النقر الأيسر (بإشارة النصر 🖐️)، النقر الأيمن (بفتح ثلاثة أصابع 🖐️)، النقر المزدوج (بالسبابة فقط 🖐️)، عملية السحب والإفلات (بجمع الإبهام

The diagram illustrates the use cases for the Control System (نظام التحكم بالإيماءات). The actor is the 'Regular User' (مستخدم النظام (المستخدم العادي)).

Use Cases:


- تحريك المؤشر (قبضة اليد □)
- نقر أبسر (السبابة + الوسطى □)
- نقر أيمن (سبابة + وسطى + خنصر □)
- نقر مزدوج (السبابة فقط □)
- سحب وإفلات (إبهام + سبابة □)
- التحكم بالصوت (المشروع الفرعي)
- التحكم بالسطوح (المشروع الفرعي)
- إيقاف الطوارئ (Fail-Safe أو Q)
- معاينة رد الفعل (عرض التقاط على الشاشة)
- إفلات / إيقاف (كف مفتوح □)

Relationships:

- Primary use cases (1-6) are connected to the actor.
- Use cases 7 and 8 are marked as 'اختياري' (Optional).
- Use case 9 is an 'extend' of use case 6, labeled '«extend» (إنهاء السحب)'.
- Use case 10 is an 'extend' of use case 2, labeled '«extend» (إلغاء النقر)'.
- Use case 11 is an 'extend' of use case 10, labeled '«extend» (إنهاء السحب)'.
- Use case 12 is an 'extend' of use case 11, labeled '«extend» (إنهاء السحب)'.

58

أما مخطط حالات استخدام المطور، فيمثل التفاعل المرتبط بمرحلة بناء النظام وضبطه وتحسين أدائه دون التدخل في خوارزميات الذكاء الاصطناعي الأساسية (حيث يُستخدم نموذج MediaPipe الجاهز). يظهر الفاعل "المطور" خارج حدود النظام، ويرتبط بمجموعة من الوظائف التطويرية التي تشمل: ضبط الإعدادات العامة للنظام عبر ملف التهيئة المركزي (تعديل دقة الكاميرا، حساسية الماوس، عدد إطارات تأكيد الإيماءة، وعتبات الكشف)، تشغيل أدوات التشخيص المستقلة لاختبار الكاميرا واستقرارها، بناء النسخة التنفيذية القابلة للتشغيل (EXE) لتوزيع التطبيق، تفعيل وضع التصحيح لعرض الحالة التفصيلية لكل إصبع أثناء التشغيل، معايرة العتبات الرياضية الخاصة بامتداد الأصابع وتنعيم الحركة، إضافة إيماءات جديدة عبر توسيع منطق التعرف في الكود المصدري، وأخيراً مراقبة سجلات الأخطاء لتحليل أي أعطال أثناء التشغيل. يعكس المخطط الفصل الواضح بين مرحلة التطوير ومرحلة الاستخدام، حيث يختص المطور بضبط معايير النظام وتحسين استجابته وتوسعة قاموس الإيماءات برمجياً، بينما لا يتداخل هذا الدور مع وظائف التحكم المباشرة التي ينفذها المستخدم العادي. يوضح هذا الفصل البنوي أن النظام يتكون من بيئة تشغيل جاهزة للمستخدم النهائي، وأخرى تطويرية تمنح المطور صلاحية التخصيص والتشخيص والبناء، دون تداخل في الصلاحيات أو المسؤوليات، مع الحفاظ على استقرار النموذج الأساسي لكشف اليد.



الشكل 2-3: حالات استخدام المطور.

3-4 التحليل البنيوي للنظام

تعتمد البنية المعمارية للنظام على نموذج الطبقات (Layered Architecture)، حيث تم تقسيم النظام إلى أربع طبقات رئيسية مترابطة، تبدأ من تفاعل المستخدم مع الكاميرا وتنتهي بتنفيذ الأوامر وعرض التغذية الراجعة على الشاشة. يوضح المخطط البنية الكاملة للنظام ومسار انتقال البيانات بين مكوناته.

أولاً: طبقة العرض والتفاعل

تمثل هذه الطبقة نقطة التفاعل المباشر مع المستخدم، وتتضمن:

- المستخدم
- كاميرا الويب
- الشاشة

تبدأ العملية عندما يقوم المستخدم بأداء إيماءة أمام الكاميرا، حيث يتم التقاط الفيديو وإرساله إلى طبقة المعالجة. في المقابل، يتم عرض التغذية البصرية الراجعة على الشاشة، ما يشكل حلقة تفاعل مستمرة بين المستخدم والنظام.

ثانياً: طبقة الالتقاط والمعالجة

تتولى هذه الطبقة استقبال الإطار الخام من الكاميرا وإعداده للمعالجة التحليلية، وتتكون من:

- وحدة الالتقاط (Capture Module)

- وحدة التحويل اللوني (RGB to HSV)

- وحدة العكس المرآتي (Mirroring)

تقوم وحدة الالتقاط باستخراج الإطارات من تدفق الفيديو الحي، ثم يتم تحويل الفضاء اللوني عند الحاجة لتحسين المعالجة البصرية. بعد ذلك، يتم تطبيق العكس المرآتي لضمان توافق حركة اليد مع اتجاه حركة المؤشر على الشاشة، بما يحقق تجربة استخدام طبيعية.

ثالثاً: طبقة التحليل والتفسير

تمثل هذه الطبقة القلب المنطقي للنظام، حيث يتم تحويل البيانات البصرية إلى أوامر قابلة للتنفيذ. وتتكون من:

- وحدة اكتشاف وتتبع اليد (MediaPipe Hands)

- وحدة استخراج الخصائص (Feature Extraction)

- وحدة تصنيف الإيماءات (Hybrid Classifier: قواعد هندسية + SVM/KNN)

- وحدة تعيين الأوامر (Command Mapping)

تستقبل وحدة التتبع الإطار المعالج وتستخرج 21 نقطة معلمية تمثل مفاصل اليد. بعد ذلك، تقوم وحدة استخراج الخصائص بحساب المسافات والزوايا اللازمة لتمييز الإيماءات. تُمرر هذه الخصائص إلى وحدة التصنيف الهجين التي تجمع بين القواعد الهندسية والمصنفات الإحصائية لتحديد نوع الإيماءة. أخيراً، يتم تحويل الإيماءة المصنفة إلى أمر منطقي محدد عبر وحدة تعيين الأوامر.

رابعاً: طبقة التنفيذ والنظام

تتولى هذه الطبقة تنفيذ الأوامر الصادرة عن طبقة التحليل، وتتضمن:


- وحدة تنعيم المؤشر (Smoothing Filter)
- وحدة محاكاة الإدخال (Input Simulation – PyAutoGUI)
- وحدة التغذية الراجعة البصرية (Visual Feedback)

يمر الأمر المنطقي أولاً عبر وحدة التنعيم لتقليل الاهتزاز وضمان سلاسة الحركة. بعد ذلك، تقوم وحدة محاكاة الإدخال بترجمة الأمر إلى عملية فعلية داخل نظام التشغيل، مثل تحريك المؤشر أو تنفيذ النقر. بالتوازي مع ذلك، تقوم وحدة التغذية الراجعة بتحديث العرض على الشاشة لعرض النقاط المعلمية وحالة الإيماءة، مما يغلق حلقة التفاعل مع المستخدم.

3-4-1 تدفق البيانات عبر النظام

يمثل مخطط تدفق البيانات المسار المنطقي للمعلومات داخل النظام، موضحاً كيفية تحويل إيماءة اليد إلى أمر قابل للتنفيذ على الحاسوب. يبدأ التدفق من كاميرا الويب التي تغذي النظام بإطارات فيديو خام، ثم تمر البيانات بسلسلة من عمليات المعالجة المتسلسلة: تبدأ بكشف اليد واستخراج


النقاط المرجعية الـ 21 عبر نموذج MediaPipe، تليها عملية تطبيع الإحداثيات وحساب مركز اليد، ثم التعرف على الإيماءة من خلال تحليل امتداد الأصابع وتنعيم الحالات عبر آليات التصويت الزمني، وأخيراً تصل إلى وحدة التحكم بالمؤشر التي تحول الحركة النسبية إلى أوامر فعلية (تحريك، نقر، سحب) باستخدام مكتبة PyAutoGUI. يرتبط التدفق بعدة مخازن بيانات مساعدة، أبرزها ملف الإعدادات المركزي الذي يتحكم بمعاملات الحساسية والكشف، وسجلات الحالات السابقة المستخدمة في تنعيم الحركة ومنع الاهتزاز. يكتمل المخطط بحلقة تغذية راجعة مرئية، حيث تُعرض النقاط والإيماءة الحالية على واجهة المستخدم، مما يسمح له بمراقبة رد فعل النظام لحظياً والتحكم فيه عبر مفاتيح التشغيل السريعة (كالإيقاف الطارئ أو تبديل أوضاع التصحيح).



الشكل 3-3: مخطط تدفق البيانات عبر النظام.

3-6 التحليل الخوارزمي

مخطط خوارزمية العمل - نظام التحكم بالماوس بالإيماءات



الشكل 3-4: مخطط خوارزمية العمل.

يمثل مخطط خوارزمية العمل التسلسل المنطقي لتحويل إيماءة اليد إلى أمر ماوس قابل للتنفيذ، موضحاً المعادلات الرياضية والمعاملات الرقمية المستخدمة في كل مرحلة.

يبدأ المخطط بعملية التهيئة، حيث تُحمل إعدادات النظام الأساسية (معامل التنعيم $\alpha=0.4$ ، المنطقة الميتة 8 بكسل، وفترة التبريد 0.3 ثانية)، ثم يدخل في حلقة تكرارية تمثل معالجة كل إطار فيديو. تتفرع المعالجة عند نقطة كشف اليد: فإذا لم تُكتشف يد، يُعاد ضبط المتغيرات لمنع قفزات الماوس؛ وإذا اكتُشفت، تُستخرج النقاط الـ 21 وتُحول إلى بكسلات.

تمر البيانات بمرحلة الحسابات الرياضية لحالة كل إصبع، حيث يُحدد امتداد الإبهام عبر 3 شروط بأغلبية 2، وبقية الأصابع عبر نسبة مسافة أكبر من 1.15 أو استقامة أكبر من 0.85، ثم تُنعم هذه الحالات عبر تصويت الأغلبية لآخر 5 إطارات. بعدها، تُحدد الإيماءة الحالية بناءً على نمط الأصابع المفتوحة، وتؤكد بتكرارها 3 إطارات متتالية لضمان الاستقرار.

تتفرع الخوارزمية عند نوع الإيماءة: إذا كانت MOVE (قبضة اليد)، تُطبق سلسلة من المعادلات المتسلسلة (حساب الدلتا، ضربها بمعامل الحساسية 2.0، تنعيمها أسياً، ثم تجاهل الحركات الأصغر من 8 بكسل) قبل تحريك الماوس. أما إذا كانت إيماءة نقر/سحب، فيُتحقق أولاً من فترة التبريد (0.3 ثانية) لمنع التكرار، ثم يُنفذ الأمر المناسب (نقر أيسر، أيمن، مزدوج، سحب، أو إفلات).

يُكتمل المخطط بمرحلة العرض البصري (عكس الإطار، رسم النقاط، كتابة الإيماءة) وتفاعل المستخدم عبر مفاتيح التحكم (Q للإيقاف، S لتبديل التنعيم، D لتبديل التصحيح، R لإعادة الضبط)، مع استمرار الحلقة حتى الضغط على Q. يكشف هذا المخطط عن الطبقات المتعددة للتنعيم (على مستوى الأصابع، الإيماءة، وحركة الماوس) التي تضمن تجربة تحكم سلسلة ودقيقة.

3-7 تحليل الأداء المتوقع

يرتكز تحليل الأداء المتوقع على تقييم قدرة النظام المقترح على تحقيق متطلبات الزمن الحقيقي، والدقة، والاستقرار، ضمن بيئات تشغيل مختلفة. يعتمد هذا التحليل على خصائص الخوارزمية المعتمدة، وخط المعالجة المصمم، ونموذج MediaPipe المستخدم في التتبع.

أولاً: مقاييس الأداء الزمنية

يُعد الأداء الزمني العامل الأهم في أنظمة التفاعل بالإيماءات، نظراً لارتباطه المباشر بإحساس المستخدم بالسلاسة والاستجابة الفورية.

من المتوقع أن يعمل النظام بمعدل إطارات لا يقل عن 30 إطاراً في الثانية في الظروف المثالية، وهو ما يعني أن زمن معالجة الإطار الواحد يجب ألا يتجاوز 33 مللي ثانية. كما يُستهدف أن يكون زمن الاستجابة الكلي بين حركة اليد وتنفيذ الأمر أقل من 150 مللي ثانية، بحيث لا يشعر المستخدم بتأخير ملحوظ.

بالاعتماد على توزيع زمن المعالجة عبر مراحل خط المعالجة، يمكن تحليل زمن الاستجابة الكلي كما يلي:

$$T_{total} = T_{capture} + T_{preprocess} + T_{tracking} + T_{classify} + T_{map} + T_{execute} \quad (1-3)$$

حيث يتوقع أن تتراوح قيمة T_{total} بين 47 و 100 مللي ثانية في الظروف الجيدة، وهو أقل من الحد الأقصى المستهدف، مما يشير إلى قدرة النظام نظرياً على تحقيق أداء زمن حقيقي مستقر.

ثانياً: دقة التصنيف والموثوقية

تعتمد دقة النظام على مرحلتين رئيسيتين: دقة تتبع اليد، ودقة تصنيف الإيماءة.

من المتوقع أن تصل دقة تصنيف الإيماءات إلى أكثر من 90% في ظروف الإضاءة الجيدة، وألا تقل عن 85% في الظروف المتوسطة. أما الإيماءات البسيطة المعتمدة على عتبات مسافة واضحة (مثل النقر)، فمن المتوقع أن تحقق دقة تقارب 95% نظرًا لاعتمادها على قواعد هندسية مباشرة.

يُتوقع أن يكون معدل الإيجابيات الكاذبة أقل من 5%، وذلك بفضل آلية التحقق من الثقة، واستخدام متغيرات حالة تمنع التكرار غير المقصود للأوامر. كما يُتوقع أن يكون معدل السلبات الكاذبة أقل من 10% في الظروف الطبيعية.

أما استقرار التتبع، فمن المتوقع أن يتجاوز 95% من زمن التشغيل في البيئات المناسبة، مع فقدان مؤقت نادر لليد عند حدوث انسداد أو تغيير مفاجئ في الإضاءة.

ثالثًا: الكفاءة الحسابية

نظرًا لاعتماد النظام على نموذج MediaPipe خفيف الوزن، فمن المتوقع أن يعمل بكفاءة على معالجات تقليدية دون الحاجة إلى وحدة معالجة رسومية متخصصة.

يُتوقع أن يبقى استهلاك المعالج أقل من 30% على جهاز متوسط المواصفات، وألا يتجاوز استهلاك الذاكرة 500 ميغابايت أثناء التشغيل. هذا يعزز قابلية تشغيل النظام على الحواسيب الشخصية دون متطلبات عتادية مرتفعة.

رابعًا: العوامل المؤثرة على الأداء

يتأثر الأداء المتوقع بعدة عوامل بيئية وتقنية.

من الناحية البيئية، تؤثر الإضاءة غير المتوازنة، والخلفيات المعقدة، والمسافة غير المناسبة من الكاميرا على دقة التتبع. تم التخفيف من هذه التأثيرات عبر استخدام تحويل لوني مناسب، وضبط عتبات الثقة، والاعتماد على نموذج مدرب على بيانات متنوعة.

أما من الناحية التقنية، فتؤثر دقة الكاميرا وقدرات المعالج على معدل الإطارات وزمن الاستجابة. تم اختيار دقة متوسطة (مثل 480×640 أو 720×1280) لتحقيق توازن بين جودة الصورة وسرعة المعالجة.

خامسًا: تحليل السيناريوهات التشغيلية

في السيناريو المثالي (إضاءة جيدة، خلفية بسيطة، معالج متوسط)، من المتوقع أن يتراوح معدل الإطارات بين 30-35 إطارًا في الثانية، وزمن الاستجابة بين 50-80 مللي ثانية، مع دقة تصنيف تتجاوز 92%.

في السيناريو المتوسط، قد ينخفض معدل الإطارات إلى 25-30 إطارًا في الثانية، ويزداد زمن الاستجابة إلى 80-120 مللي ثانية، مع دقة تتراوح بين 87-92%.

أما في السيناريو الصعب (إضاءة ضعيفة أو خلفية معقدة)، فقد ينخفض معدل الإطارات إلى 15-25 إطارًا في الثانية، وقد يقترب زمن الاستجابة من 150-180 مللي ثانية، مع دقة تتراوح بين 75-85%.

3-8 القيود والمخاطر

استنادًا إلى التحليل النظري، من المتوقع أن يعمل النظام بكفاءة أعلى في ظروف إضاءة مناسبة وخلفيات غير معقدة، بينما قد تتأثر دقة التتبع في البيئات ذات الإضاءة الشديدة أو الخلفيات

المشوشة. كما أن الاعتماد على كاميرا واحدة يعني أن تقدير العمق يتم حسابياً، مما قد يفرض حدوداً على بعض الإيماءات ثلاثية الأبعاد.

قد ينخفض معدل الإطارات أو يزداد زمن الاستجابة على الأجهزة محدودة الإمكانيات، كما قد تتطلب الإيماءات المتشابهة شكلياً تمييزاً أدق خاصة في حال محدودية بيانات التدريب ضمن إطار المشروع.

من ناحية التطوير، قد تظهر تحديات تتعلق بضبط معلمات المصنف، تكامل المكونات البرمجية، أو الحفاظ على زمن استجابة ثابت في جميع الظروف. سيتم التحقق عملياً من تأثير هذه العوامل ضمن الفصل التطبيقي.

الفصل الرابع: التنفيذ العملي

والنتائج

4-1 بيئات التطوير والأدوات المستخدمة

4-1-1 بيئة Anaconda

تم اعتماد بيئة Anaconda لإدارة الحزم البرمجية والاعتماديات الخاصة بالمشروع، نظراً لما توفره من إمكانيات متقدمة في إنشاء البيئات الافتراضية وعزل المشاريع عن بعضها البعض. يعد هذا الأمر مهماً في تطبيقات الرؤية الحاسوبية والذكاء الاصطناعي التي تعتمد على مكتبات متعددة قد تتطلب إصدارات محددة من لغة Python أو من المكتبات المرافقة لها.



الشكل 4-1: شعار بيئة Anaconda.

ساهمت Anaconda في تسهيل عملية تطوير النظام من خلال إنشاء بيئة مستقلة تحتوي على جميع الحزم المطلوبة مثل MediaPipe و OpenCV و NumPy، مما منع حدوث تعارضات بين المكتبات المستخدمة في المشروع والمكتبات المثبتة على النظام. كما أتاحت إمكانية التحكم بإصدارات الحزم والمحافظة على استقرار بيئة العمل طوال فترة التطوير والاختبار.

إضافة إلى ذلك، توفر Anaconda دعماً جيداً للمكتبات العلمية ومكتبات الذكاء الاصطناعي، الأمر الذي يجعلها خياراً مناسباً لتطوير الأنظمة التي تعتمد على معالجة الصور واستخراج المعالم الحيوية في الزمن الحقيقي.

Visual Studio Code بيئة 2-1-4

تم استخدام محرر الأكواد Visual Studio Code (VS Code) كبيئة التطوير الرئيسية للمشروع، وذلك لما يوفره من أدوات متقدمة تساعد على تطوير التطبيقات البرمجية واختبارها بكفاءة عالية.



الشكل 2-4: شعار بيئة VS Code.

يتميز VS Code بدعمه الكامل للغة Python وإمكانية التكامل المباشر مع بيئات Anaconda، حيث يمكن اختيار البيئة الافتراضية المناسبة للمشروع والعمل ضمنها بسهولة. كما يوفر أدوات تصحيح الأخطاء (Debugging) التي تسمح بمراقبة تنفيذ البرنامج خطوة بخطوة وتتبع القيم المتغيرة أثناء تشغيل التطبيق.

ساهمت الإضافات البرمجية المتاحة داخل VS Code في تسريع عملية التطوير، مثل أدوات الإكمال التلقائي للأكواد، وتحليل الأخطاء البرمجية، وإدارة الإصدارات باستخدام Git، مما ساعد على تنظيم الكود وتحسين جودة التطبيق النهائي.

3-1-4 دور بيئات التطوير في تنفيذ النظام

اعتمد النظام على التكامل بين Anaconda و Visual Studio Code لتوفير بيئة تطوير مستقرة وفعالة. حيث تم استخدام Anaconda لإدارة الحزم وإنشاء البيئة البرمجية الخاصة بالمشروع، بينما تم استخدام VS Code في كتابة الشيفرات البرمجية واختبارها وتصحيحها.

وقد ساهم هذا التكامل في تسهيل عملية تطوير نظام التحكم بالسطوع باستخدام إيماءات اليد، بدءاً من النقاط الصور من الكاميرا ومعالجتها، مروراً باستخراج نقاط اليد باستخدام MediaPipe، وانتهاءً بحساب مستوى السطوع وإرساله إلى نظام التشغيل لتطبيقه بشكل فوري.

4-2 تنفيذ نظام التحكم بمستوى السطوع باستخدام إيماءات اليد


تم تطوير نظام يسمح بالتحكم بمستوى سطوع الشاشة اعتماداً على إيماءات اليد دون الحاجة إلى استخدام لوحة المفاتيح أو أدوات التحكم التقليدية. يعتمد النظام على النقاط الفيديو بشكل مباشر من كاميرا الحاسوب ثم تحليل صورة اليد باستخدام مكتبة MediaPipe Hands التي تقوم بتحديد مواقع مفاصل الأصابع واستخراج الإحداثيات الخاصة بها.

بعد اكتشاف اليد يتم تحديد موقع طرف الإبهام وطرف السبابة وحساب المسافة بينهما بشكل مستمر. بعد ذلك يتم تحويل هذه المسافة إلى قيمة رقمية تمثل نسبة السطوع المطلوبة، ومن ثم إرسال هذه القيمة إلى نظام التشغيل لتعديل سطوع الشاشة بشكل فوري ومتزامن مع حركة المستخدم.

كما يتم عرض معلومات مرئية على الشاشة تتضمن نموذج اليد المكتشفة، والمسافة المحسوبة بين الإصبعين، إضافة إلى شريط بياني يوضح مستوى السطوع الحالي لتسهيل متابعة أداء النظام أثناء التشغيل.

4-2-1 الإيماءة الأولى: تخفيض السطوع

- وصف الإيماءة: تظهر في هذه الحالة وضعية تكون فيها المسافة بين الإبهام والسبابة صغيرة نسبياً، حيث يكون الإصبعان متقاربين من بعضهما البعض. تعبر هذه الإيماءة عن رغبة المستخدم في تقليل مستوى السطوع.
- آلية المعالجة: يقوم النظام بحساب المسافة القصيرة بين الإصبعين ثم يطابقها مع المجال الأدنى لقيم السطوع المحدد مسبقاً داخل البرنامج. وبناءً على ذلك يتم إرسال قيمة منخفضة إلى وحدة التحكم بالسطوع.



الشكل 4-3: إيماءة تخفيض سطوع الشاشة باستخدام تقارب الإبهام والسبابة.

4-2-2 الإيماءة الثانية: رفع السطوع

- وصف الإيماءة: في هذه الحالة تزداد المسافة بين الإبهام والسبابة بشكل ملحوظ مقارنة بالحالة السابقة، مما يؤدي إلى رفع قيمة السطوع الناتجة عن النظام.
- آلية المعالجة: بعد حساب المسافة الجديدة يقوم البرنامج بتحويلها إلى قيمة أعلى ضمن مجال السطوع المعتمد، ويتم تحديث القيمة مباشرة أثناء حركة اليد.




الشكل 4-4: إيماءة زيادة سطوع الشاشة من خلال إبعاد الإبهام عن السبابة.

3-2-4 الإيماءة الثالثة: السطوع الأقصى

وصف الإيماءة: تمثل هذه الحالة أكبر مسافة ممكنة تقريباً بين الإبهام والسبابة ضمن مجال رؤية الكاميرا، حيث يكون الإصبعان متباعدين بشكل واضح.

آلية المعالجة: تؤدي هذه الوضعية إلى إنتاج أكبر قيمة للمسافة المقاسة، وبالتالي يقوم النظام بتعيين قيمة السطوع القصوى المسموح بها.



الشكل 4-5: إيماءة الوصول إلى السطوع الأقصى (100%).

3-4 الإيماءات المستخدمة في النظام

يمثل نظام الإيماءات المعتمد في هذا المشروع مجموعة متكاملة من ست حركات يدوية، صممت وفق أسس علمية تجمع بين البداهة الحركية وسهولة التمييز البصري، لتغطي كامل احتياجات التحكم الأساسية بالماوس. استند اختيار هذه الإيماءات إلى معايير دقيقة، أبرزها التوزيع المتوازن على طيف انفتاح اليد (من القبضة المغلقة إلى الكف المفتوح بالكامل)، والتباين الواضح بين الإيماءات في عدد الأصابع المفتوحة وأنماطها لتجنب الخلط، بالإضافة إلى استيعاء أشكالها من إشارات يومية مألوفة كإشارة النصر أو الرقم واحد، مما يقلل الجهد الإدراكي ويسرع منحنى التعلم. كما صممت الإيماءات لتوزع على أربع فئات وظيفية: التحريك المستمر، الأوامر النبضية، إدارة الحالة، والتحكم الآمن، لتعكس تنوع أنماط التفاعل بين المستخدم والنظام.

تتوزع الإيماءات الست كالتالي: إيماءة القبضة  حيث تكون جميع الأصابع مغلقة، وهي الأنسب للتحريك المستمر للمؤشر نظراً لثبات شكل اليد وسهولة الحركة في الفضاء. إيماءة النقر الأيسر  بفتح السبابة والوسطى معاً، وإيماءة النقر الأيمن  بإضافة الخنصر إليهما، وإيماءة النقر المزدوج  بالسبابة فقط، وكلها تمثل أوامر نبضية قصيرة ومحددة المدة، وتخضع لفترة تبريد زمنية لمنع التكرار غير المقصود. إيماءة السحب والإفلات  بفتح الإبهام والسبابة كأن المستخدم يمسك شيئاً صغيراً، وهي حالة ذات استمرارية زمنية حيث يظل زر الماوس مضغوطاً طالما استمرت الإيماءة. وأخيراً إيماءة الكف المفتوح  بفتح أربعة أو خمسة أصابع، وهي بمثابة مفتاح أمان يعيد النظام إلى حالته المحايدة وينهي أي أمر قيد التنفيذ، كإلغاء السحب أو تحرير أي زر مضغوط، مما يضمن للمستخدم قدرة دائمة على تصحيح الأخطاء واستعادة السيطرة.

4-4 نتائج التجربة وتقييم الأداء

تم اختبار النظام عملياً باستخدام عدة أوضاع مختلفة لليد أمام الكاميرا للتحقق من دقة التعرف على الإيماءات وقدرته على التحكم بمستوى السطوع بصورة لحظية. أظهرت النتائج نجاح النظام في تتبع اليد واستخراج المعالم المطلوبة بدقة عالية، كما تمكن من تحويل المسافة بين الإبهام والسبابة إلى قيم سطوع مناسبة بشكل متدرج ومستمر.

أثبتت التجارب أن النظام قادر على الانتقال بين مستويات السطوع المختلفة بسلاسة، بدءاً من القيم المنخفضة جداً وصولاً إلى الحد الأقصى للسطوع، دون الحاجة إلى أي أدوات إدخال تقليدية. كما أظهرت النتائج استقراراً جيداً في عملية التتبع وعدم وجود تأخير ملحوظ بين حركة المستخدم وتحديث قيمة السطوع.

وتؤكد هذه النتائج فعالية استخدام تقنيات الرؤية الحاسوبية ومكتبة MediaPipe في تطوير أنظمة تحكم ذكية تعتمد على الإيماءات، مما يفتح المجال لاستخدامها في تطبيقات التفاعل الطبيعي بين الإنسان والحاسوب والتحكم بدون لمس.

الفصل الخامس : الخاتمة والآفاق

المستقبلية

في ختام هذا المشروع، تم تطوير نظام ذكي للتحكم عن بعد بتطبيقات الحاسوب اعتماداً على إيماءات اليد وتقنيات الرؤية الحاسوبية والذكاء الاصطناعي، بهدف توفير وسيلة تفاعل طبيعية ومرنة تغني المستخدم عن وسائل الإدخال التقليدية في العديد من السيناريوهات. وقد اعتمد النظام على مكتبة MediaPipe لاستخراج معالم اليد في الزمن الحقيقي، إضافة إلى مكتبة OpenCV لمعالجة الصور والفيديو، مما أتاح بناء واجهة تفاعل لا تلامسية قادرة على ترجمة حركات اليد إلى أوامر فعلية تنفذ مباشرة على الحاسوب. وتُعد فكرة المشروع امتداداً للتوجهات الحديثة في مجال التفاعل بين الإنسان والحاسوب التي تسعى إلى جعل عملية التحكم أكثر طبيعية وسلاسة من خلال الاستفادة من قدرات الذكاء الاصطناعي وتقنيات الرؤية الحاسوبية.

أظهرت نتائج التطبيق العملي قدرة النظام على اكتشاف اليد وتتبع معالمها بدقة جيدة في الزمن الحقيقي، كما نجح في تنفيذ مجموعة من الوظائف المختلفة مثل التحكم بالمؤشر وبعض أوامر النظام ومستويات الصوت والسطوع اعتماداً على إيماءات محددة مسبقاً. وقد بينت التجارب العملية أن استخدام الإحداثيات المستخرجة من النقاط المرجعية لليد يوفر أساساً فعالاً لبناء أنظمة تحكم ذكية منخفضة التكلفة لا تحتاج إلى أجهزة استشعار إضافية أو معدات متخصصة، وإنما تكفي بكاميرا ويب عادية متوفرة في معظم الحواسيب الحديثة.

كما أثبت المشروع إمكانية الاستفادة من تقنيات الذكاء الاصطناعي في تطوير واجهات مستخدم طبيعية (Natural User Interfaces) تتيح للمستخدم التفاعل مع التطبيقات والخدمات الرقمية بطريقة أكثر راحة ومرونة، الأمر الذي يفتح المجال أمام استخدامها في البيئات التعليمية والطبية والصناعية، إضافة إلى دعم الأشخاص الذين يواجهون صعوبات في استخدام وسائل الإدخال التقليدية.

أما فيما يتعلق بالآفاق المستقبلية للمشروع، فيمكن تطوير النظام وتوسيعه من خلال:

- إضافة مجموعة أكبر من الإيماءات الديناميكية لزيادة عدد الأوامر والوظائف المدعومة.
- دمج تقنيات التعلم العميق لتصنيف الإيماءات المعقدة وتحسين دقة التعرف عليها.
- دعم التعرف على كلتا اليدين في الوقت نفسه لتنفيذ أوامر أكثر تقدماً.
- دمج الأوامر الصوتية مع الإيماءات لبناء واجهة تفاعل متعددة الوسائط.
- تطوير نسخة تعمل على الهواتف الذكية والأجهزة اللوحية وأنظمة الواقع المعزز.
- توسيع وظائف النظام لتشمل التحكم الكامل بالعروض التقديمية والتطبيقات المكتبية والوسائط المتعددة.

- تحسين أداء النظام في ظروف الإضاءة المتغيرة والخلفيات المعقدة.
- ربط النظام بتطبيقات المنزل الذكي وإنترنت الأشياء للتحكم بالأجهزة الخارجية باستخدام الإيماءات.

وبناءً على ما تم تحقيقه، يمكن اعتبار هذا المشروع خطوة عملية ناجحة نحو بناء أنظمة تفاعل ذكية تعتمد على الإيماءات كوسيلة إدخال حديثة، وتؤكد الإمكانيات الكبيرة التي توفرها تقنيات الرؤية الحاسوبية والذكاء الاصطناعي في تطوير جيل جديد من واجهات الاستخدام التي تجعل التواصل بين الإنسان والحاسوب أكثر طبيعية وفعالية، وتمهد الطريق أمام تطبيقات مستقبلية أكثر تطوراً واعتماداً على التفاعل اللا تلامسي.

- [1] Uboweja, E., Bazarevsky, V., Sokal, K., Sung, G., Baccash, J., Chang, C. L., & Grundmann, M. (2023). On-Device Real-Time Custom Hand Gesture Recognition. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*.
- [2] Google AI Edge. (2025). Hand Landmarker for Python. Google Developers Documentation. Retrieved from Google AI Edge Documentation.
- [3] Meng, Y., Zhang, Y., & Colleagues. (2024). Real-Time Hand Gesture Monitoring Model Based on Triple Loss. *Sensors*, 24(19), 6262. <https://doi.org/10.3390/s24196262>
- [4] Zhang, T., Li, X., & Colleagues. (2025). Intelligent Human–Computer Interaction for Building Information Modeling Based on Gesture Interaction. *Biomimetics*, 10(1), 5.
- [5] SSRN Research. (2025). Gesture Recognition Solution for Zero-UI and Contactless Interaction Systems. *SSRN Electronic Journal*.
- [6] Chang, V., Eniola, R. O., Golightly, L., & Xu, Q. A. (2023). Hand Gesture Recognition Management in a Challenging Environment. *SN Computer Science*, 4, Article 417.
- [7] Mohamed, A. S., & Colleagues. (2024). Real-Time Hand Gesture Recognition: A Comprehensive Review. *Computer and Information Technologies*.
- [8] Marques, P., Ferreira, J., & Colleagues. (2025). Real-Time Gesture-Based Hand Landmark Detection for Human–Computer Interaction Under Variable Lighting Conditions. *Electronics*, 14(4), 704.
- [9] Amprimo, G., Murgia, A., & Colleagues. (2023). Validation of the Google MediaPipe Hand Framework and an Enhanced RGB-Depth Version for Accurate Finger Tracking. *IEEE Access*.
- [10] Dwivedi, Y. K., Hughes, L., Baabdullah, A. M., Ribeiro-Navarrete, S., Giannakis, M., Al-Debei, M. M., Dennehy, D., Metri, B., Buhalis, D., Cheung, C. M. K., Conboy, K., Doyle, R., Dubey, R., Dutot, V., Felix, R., Goyal, D. P., Gustafsson, A., Hinsch, C., Jebabli, I., ... Wamba, S. F. (2023). So what if ChatGPT wrote it? Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy. *International Journal of Information Management*, 71, 102642.
- [11] Shneiderman, B., Plaisant, C., Cohen, M., Jacobs, S., Elmqvist, N., & Diakopoulos, N. (2022). *Designing the User Interface: Strategies for Effective Human–Computer Interaction* (7th ed.). Pearson.
- [12] Mohamed, A. S., Al-Hammadi, Y., & Al-Ali, A. (2024). Real-time hand gesture recognition: A comprehensive review. *Computer and Information Technologies*, 56(2), 121–139.
- [13] Goodfellow, I., Bengio, Y., & Courville, A. (2023). *Deep Learning: Adaptive Computation and Machine Learning* (Updated ed.). MIT Press.
- [14] Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2023). *Dive into Deep Learning*. Cambridge University Press.
- [15] Khan, A., Sohail, A., Zahoora, U., & Qureshi, A. S. (2024). A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review*, 57(1), 1–45.
- [16] Gonzalez, R. C., & Woods, R. E. (2022). *Digital Image Processing* (5th ed.). Pearson.
- [17] Kaehler, A., & Bradski, G. (2024). *Learning OpenCV 5: Computer Vision with OpenCV Library*. O'Reilly Media.
- [18] Gonzalez, R. C., & Woods, R. E. (2022). *Digital Image Processing* (5th ed.). Pearson.
- [19] Kaehler, A., & Bradski, G. (2024). *Learning OpenCV 5: Computer Vision with OpenCV Library*. O'Reilly Media.
- [20] Khan, A., Sohail, A., Zahoora, U., & Qureshi, A. S. (2024). A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review*, 57(1), 1–45.
- [21] Uboweja, E., Bazarevsky, V., Sokal, K., Sung, G., Baccash, J., Chang, C. L., & Grundmann, M. (2023). On-Device Real-Time Custom Hand Gesture Recognition. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*.

- [22] Kaehler, A., & Bradski, G. (2024). Learning OpenCV 5: Computer Vision with OpenCV Library. O'Reilly Media.
- [23] Google AI Edge. (2025). MediaPipe Hand Landmarker Documentation. Google Developers.
- [24] Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C. L., & Grundmann, M. (2021). MediaPipe Hands: On-device Real-time Hand Tracking. Google Research.
- [25] Uboweja, E., Bazarevsky, V., Sokal, K., Sung, G., Baccash, J., Chang, C. L., & Grundmann, M. (2023). On-Device Real-Time Custom Hand Gesture Recognition. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW).
- [26] Sherstinsky, A. (2021). Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Networks. Physica D: Nonlinear Phenomena, 404, 132306.
- [27] Meng, Y., Zhang, Y., & Li, H. (2024). Real-Time Hand Gesture Monitoring Model Based on Triple Loss. Sensors, 24(19), 6262.
- [28] Marques, P., Ferreira, J., & Rodrigues, R. (2025). Real-Time Gesture-Based Hand Landmark Detection under Variable Lighting Conditions. Electronics, 14(4), 704.
- [29] Sokolova, M., & Lapalme, G. (2021). A Systematic Analysis of Performance Measures for Classification Tasks. Information Processing & Management, 58(5).
- [30] Meng, Y., Zhang, Y., & Li, H. (2024). Real-Time Hand Gesture Monitoring Model Based on Triple Loss. Sensors, 24(19), 6262.
- [31] Uboweja, E., Bazarevsky, V., Sokal, K., Sung, G., Baccash, J., Chang, C. L., & Grundmann, M. (2023). On-Device Real-Time Custom Hand Gesture Recognition. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW).