



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الوطنية الخاصة
قسمي هندسة الحاسوب والاتصالات

مشروع أعد لنيل درجة البكالوريوس في هندسة الحاسوب والاتصالات بعنوان:

تصميم وتنفيذ كف روبوتية تحاكي حركة اليد البشرية باستخدام الذكاء الاصطناعي والرؤية الحاسوبية

إعداد الطالبات:

ضحى المديني

جيداء خطاب

إشراف:

د.م. ثائر داؤد

د. محمد المحمد

2025-2024

بسم الله الرحمن الرحيم

{وقل ري زدني علما}

إلى الأساتذة المشرفين الأكاديميين على مشروع التخرج:

الدكتور المهندس ثائر داؤد

الدكتور محمد المحمد

نتقدم إليكم بخالص الشكر والتقدير على ما بذلتموه من وقت وجهد في توجيهنا ودعمنا خلال مراحل هذا المشروع.

لقد كنتم مثالا يحتذى به في المهنية، والدقة، والحرص على جودة العمل الهندسي.
فلكم منا كل الاحترام والامتنان.

إلى السادة أعضاء لجنة التقييم المحترمين،

نشكر لكم حضوركم الكريم، ومساهماتكم القيمة في تقييم مشروعنا.
إن توجيهاتكم كانت حافزا لنا نحو مزيد من التطوير والتحسين،
فلكم منا كل التقدير على حرصكم على الارتقاء بالمستوى الأكاديمي والمهني.

إلى من زرعوا في داخلي بذور الطموح، وسقوها بالصبر والدعاء،

إلى والدي ووالدي الغاليين،

لا كلمات توفيكما حقكما، ولا عبارات تفي ما قدمتماه من دعم، وتضحية، ومحبة غير مشروطة.
أهدي هذا المشروع إليكما، عربون شكرٍ وامتنان لا ينتهي.

إلى من كنّ بجانبى قلباً وقالباً، في كل قاعة، وكل زاوية من الجامعة،

صديقاتي المقربات،

هذا التخرج ليس إنجازي وحدي، بل إنجاز كل من ساندني بكلمة، وابتسامة، ووقت،
ممتنة لكل لحظة جمعتني بكنّ، وستبقين من أجمل ما حصدته من هذه الرحلة.

المحتويات

1 الفصل الأول: مقدمة 1

1-1 مقدمة عن المشروع وأهدافه 2

2-1 مراجعة لدراسات سابقة 6

1-2-1 تصميم وتطوير ذراع روبوتية بخمس درجات حرية قابلة للتحكم عبر حركة اليد البشرية ... 6

2-2-1 نظام إمساك روبوتي تعاوني مدفوع بالرؤية ويعتمد على التحكم الكهروميكانيكي السطحي

9.....

3-2-1 ذراع روبوتية ناعمة حلزونية تضاهي اليد البشرية في الأداء والمهام 13

2 الفصل الثاني: الأساس النظري 15

1-2 مقدمة في الرؤية الحاسوبية 16

1-1-2 تعريف الرؤية الحاسوبية 16

2-1-2 كيف يتم معالجة الصور رقميًا 18

2-2 الذكاء الاصطناعي وتعلم الآلة 21

1-2-2 تعريف الذكاء الاصطناعي 21

2-2-2 تعلم الآلة كفرع من الذكاء الاصطناعي 22

3-2 التعلم العميق 26

1-3-2 تعريف التعلم العميق 26

29 2-3-2 تطور التعلم العميق من تعلم الآلة

31 3-3-2 أهمية التعلم العميق في معالجة الصور

33 4-2 الشبكات العصبية الاصطناعية (Artificial Neural Network)

36 1-4-2 الشبكات العصبية العميقة (Deep Neural Networks)

38 2-4-2 الشبكات العصبية الالتفافية (Convolutional Neural Networks)

42 3 الفصل الثالث: تقدير الوضعيات

43 1-3 مفهوم تقدير الوضعيات (Pose Estimation)

46 2-3 لمحة عن مكتبة MediaPipe

48 1-2-3 تقدير وضعيات الجسم باستخدام MediaPipe BlazePose

51 2-2-3 تتبع اليدين باستخدام MediaPipe Hands

54 3-2-3 تتبع الوجه باستخدام MediaPipe Face Mesh

58 4 الفصل الرابع: التطبيق العملي النهائي

59 1-4 توصيف العناصر الكهربائية المستخدمة

59 1-1-4 لوحة Arduino UNO

60 2-1-4 محرك السيرفو

61 3-1-4 منظم الجهد

61 4-1-4 وحدة البلوتوث HC-05

62	2-4 المخطط الصندوقي لتكامل المكونات.....
63	3-4 المخطط التدفقي.....
65	4-4 تنفيذ المشروع النهائي.....
67	5-4 النتائج.....
68	5 الفصل الخامس: الخاتمة والآفاق المستقبلية.....
72	6 المراجع.....

الأشكال

7	الشكل 1-1: مكونات نظام الذراع الروبوتية.....
7	الشكل 1-2: درجات الحرية (a)، تمثيل للميل، الدوران والانحراف (b).....
8	الشكل 1-3: التمثيل التخطيطي لآلية الشفط.....
11	الشكل 1-4: وضعية ما قبل الإمساك للنظام الروبوتي المحسوبة بواسطة خوارزمية الرؤية.....
11	الشكل 1-5: نظام التخطيط الكهربائي للعضلات السطحي (sEMG) يقوم بجمع البيانات من أحد الأشخاص.....
12	الشكل 1-6: خطوات الطريقة لحساب زوج من نقاط التماس.....

الشكل 7-1: مخطط يوضح الطريقة المقترحة المطبقة في نظام تشغيل الروبوت (ROS) ويظهر وحدات الاتصال بين الخطوات المختلفة.....	12
الشكل 8-1: الذراع الروبوتية الحلزونية.....	14
الشكل 1-2: حجم سوق الرؤية الحاسوبية حسب الصناعة بالنسبة المئوية.....	17
الشكل 2-2: خصائص الصورة الرئيسية.....	19
الشكل 3-2: تحويل الصورة إلى مصفوفة.....	20
الشكل 4-2: تقنيات الذكاء الاصطناعي.....	22
الشكل 5-2: عملية تدريب نموذج التعلم الآلي.....	24
الشكل 6-2: تطبيقات التعلم العميق.....	28
الشكل 7-2: تطور نماذج التعلم العميق.....	32
الشكل 8-2: آلية عمل الشبكة العصبية الاصطناعية.....	34
الشكل 9-2: بنية الشبكة العصبية العميقة.....	37
الشكل 10-2: آلية عمل شبكة CNN.....	39
الشكل 1-3: تقنية Pose Estimation.....	43
الشكل 2-3: مكتبة MediaPipe.....	47
الشكل 3-3: النقاط الرئيسية للجسم.....	50
الشكل 4-3: النقاط الرئيسية لليدين.....	52
الشكل 5-3: مراحل معالجة الصورة في نظام MediaPipe Hands.....	53
الشكل 6-3: النقاط الرئيسية للوجه.....	56
الشكل 7-3: آلية عمل MediaPipe Face Mesh.....	56

59	الشكل 4-1: لوحة Arduino UNO
60	الشكل 4-2: محرك السيرفو.....
61	الشكل 4-3: وحدة البلوتوث HC-05.....
63	الشكل 4-4: تكامل مكونات النظام.....
64	الشكل 4-5: المخطط التدفقي.....
65	الشكل 4-6: الذراع الروبوتية.....
66	الشكل 4-7: اليد مبسطة.....
66	الشكل 4-8: اليد مقبوضة.....

الجدول

7	الجدول 1-1: الأوامر.....
30	الجدول 2-1: الفرق بين تعلم الآلة والتعلم العميق.....

جدول الاختصارات

الاختصار	المعنى بالإنجليزية	المعنى بالعربية
AI	Artificial Intelligence	الذكاء الاصطناعي
CV	Computer Vision	الرؤية الحاسوبية
sEMG	Surface Electromyography	تخطيط كهربائية العضلات السطحي
ROS	Robot Operating System	نظام تشغيل الروبوت
ANN	Artificial Neural Network	الشبكات العصبية الاصطناعية
DNN	Deep Neural Network	الشبكات العصبية العميقة
CNN	Convolutional Neural Network	الشبكات العصبية الالتفافية
ML	Machine Learning	التعلم الآلي
DL	Deep Learning	التعلم العميق
RGB	Red Green Blue	أحمر، أخضر، أزرق
HSV	Hue Saturation Value	تدرج اللون، التشبع، القيمة
CMYK	Cyan Magenta Yellow Black	سماوي، أرجواني، أصفر، أسود
DOF	Degrees Of Freedom	درجات الحرية

الملخص

يهدف هذا المشروع إلى تطوير كف روبوتية قادرة على محاكاة حركة اليد البشرية في الزمن الحقيقي باستخدام تقنيات الذكاء الاصطناعي والرؤية الحاسوبية. يتم تحليل وضعيات الأصابع من خلال كاميرا متطورة تقوم باستقبال إشارات من اليد البشرية، ويتم معالجة هذه البيانات باستخدام نماذج ذكاء اصطناعي مخصصة لتحويلها إلى أوامر تحكم دقيقة، مما يسمح للكف الروبوتية بتنفيذ الحركات بسلاسة ودقة مشابهة للحركات البشرية. يشمل المشروع تصميم الكف الروبوتية وتطوير نموذج ذكاء اصطناعي للتعرف على وضعيات اليد، بالإضافة إلى إنشاء نظام تحكم فعال لتحريك الكف بناءً على البيانات المستلمة. تم اختبار النظام في بيئات متنوعة لضمان دقته وكفاءته في محاكاة الحركات البشرية الحقيقية. وقد أثبت النظام كفاءته في أداء الحركات الروبوتية الدقيقة مثل الإمساك بالأشياء الصغيرة والمعقدة، وتمكن من تقليد الحركات البشرية بشكل قريب جداً للطبيعة. كما تم تحسين النظام بشكل مستمر لضمان استجابة سريعة وتقليل التأخير الزمني، مما جعله مناسباً لتطبيقات مختلفة في المجالات الصناعية والطبية.

الكلمات المفتاحية:

التحكم الآلي - محاكاة الحركة - الذراع الروبوتية - الرؤية الحاسوبية - الذكاء الاصطناعي

ABSTRACT

This project aims to develop a robotic hand capable of mimicking human hand movements in real-time using artificial intelligence (AI) and computer vision techniques. Finger postures are analyzed via an advanced camera that receives signals from the human hand. This data is then processed using specialized AI models to convert it into precise control commands, allowing the robotic hand to execute movements smoothly and accurately, similar to human actions. The project encompasses the design of the robotic hand, the development of an AI model for hand posture recognition, and the creation of an efficient control system to actuate the hand based on received data. The system was tested in various environments to ensure its accuracy and efficiency in simulating real human movements. The system proved efficient in performing precise robotic movements, such as grasping small and complex objects, and was able to imitate human movements very closely to nature. The system was also continuously improved to ensure rapid response and minimize time delay, making it suitable for various applications in industrial and medical fields.

KEYWORDS:

Automated Control - Movement Simulation - Robotic Arm - Computer Vision - Artificial Intelligence

الفصل الأول: مقدمة

1-1 مقدمة عن المشروع وأهدافه

في عالم اليوم الذي يشهد تطورًا متسارعًا في تقنيات الروبوتات والذكاء الاصطناعي، برزت الحاجة إلى ابتكارات تجمع بين قدرة الإنسان على التفاعل الحسي والحركي وبين الكفاءة التشغيلية للآلات. يدور مشروعنا حول تطوير كف روبوتية متقدمة قادرة على محاكاة حركة اليد البشرية بأسلوب دقيق وسريع الاستجابة. الفكرة العامة للمشروع تعتمد على دمج الذكاء الاصطناعي مع الرؤية الحاسوبية لتحليل حركة اليد البشرية من خلال كاميرا متطورة تعمل على استشعار الإشارات المرئية التي تصدر عن اليد. بعد ذلك يتم معالجة هذه البيانات باستخدام نماذج ذكاء اصطناعي مخصصة لتحويلها إلى أوامر تحكم دقيقة توجه الذراع الروبوتية لتنفيذ نفس الحركات بشكل سلس ومتناغم. هذا النظام لا يقتصر فقط على تقليد الحركات الأساسية، بل يهدف أيضًا إلى تحقيق مستوى عالٍ من الدقة يجعله قادرًا على التعامل مع المهام المعقدة التي تتطلب تنسيقًا دقيقًا بين الأصابع والجسم الرئيسي للذراع.

أهمية هذا المشروع تتجلى في كونه يفتح آفاقًا جديدة أمام العديد من المجالات التي تعتمد على الروبوتات في أدائها. إذ إن تقليد حركة اليد البشرية باستخدام الذراع الروبوتية يمثل خطوة ثورية في مجالات مثل الطب، حيث يمكن استخدام هذه التقنية لتطوير أطراف صناعية ذكية تمنح الأشخاص الذين فقدوا أطرافهم القدرة على استعادة وظائفهم الحركية بشكل طبيعي. كما أن هذه التقنية قد تكون ذات قيمة كبيرة في الصناعة، حيث يمكن للذراع الروبوتية أن تقوم بمهام تتطلب مرونة ودقة عالية، مثل التجميع الدقيق للأجزاء الصغيرة أو التعامل مع المواد الحساسة. بالإضافة إلى ذلك، فإن التطبيقات التعليمية والإنسانية لهذا المشروع لا تقل أهمية، إذ يمكن استخدامه لتعليم المهارات الحركية أو حتى تقديم المساعدة للأشخاص ذوي الاحتياجات الخاصة. لقد أظهرت الدراسات الحديثة أن الجمع بين تقنيات

الفصل الأول: مقدمة

الرؤية الحاسوبية والذكاء الاصطناعي يمكن أن يؤدي إلى تحسين كبير في أداء الروبوتات في بيئات العمل الديناميكية، مما يجعل هذا المشروع ليس مجرد فكرة إبداعية فحسب، بل خطوة ضرورية نحو مستقبل أكثر تقدمًا وتكنولوجياً.

على الرغم من التقدم الملحوظ في تطوير الروبوتات ونظم الأتمتة، لا تزال هناك فجوة كبيرة بين قدرات الإنسان الحركية والحسية وبين ما يمكن للآلات تحقيقه. المشكلة الأساسية التي يسعى مشروعنا إلى معالجتها تكمن في صعوبة محاكاة التعقيد الكبير الذي تتسم به حركة اليد البشرية. فاليد البشرية ليست مجرد أداة للحركة، بل هي نظام دقيق ومعقد يجمع بين القوة والمرونة والقدرة على التكيف مع البيئات المتغيرة. هذا النظام يتطلب مستوى عالٍ من التنسيق بين العضلات والأعصاب والدماغ، وهو ما يجعل تقليد هذه الحركات باستخدام الذراع الروبوتية تحديًا كبيرًا. إذ أن الروبوتات التقليدية غالبًا ما تكون مقيدة ببرمجيات محددة مسبقًا أو تعليمات ثابتة، مما يجعلها غير قادرة على التفاعل بشكل طبيعي مع المهام التي تتطلب تنوعًا وسرعة استجابة.

يعود السبب الرئيسي لصعوبة تقليد حركة اليد البشرية إلى أنها ليست عملية خطية أو بسيطة. فاليد البشرية تمتلك عددًا كبيرًا من درجات الحرية، حيث يمكن للأصابع والمعصم والكفين العمل بشكل مستقل أو متزامن لتحقيق مجموعة واسعة من الحركات الدقيقة والمعقدة. هذا التنوع في الحركة يجعل من الصعب تصميم نموذج رياضي أو خوارزمية تقليدية قادرة على محاكاة جميع الاحتمالات المحتملة. بالإضافة إلى ذلك، فإن اليد البشرية تعتمد بشكل كبير على الإدراك البصري والحس الحركي، حيث يتم استخدام المعلومات المرئية بشكل دائم لتحديث الحركات وتوجيه الأفعال بدقة. هذا يعني أن أي نظام روبوتي يهدف إلى تقليد هذه القدرات يجب أن يكون قادرًا على معالجة كميات هائلة من البيانات الحسية في الزمن الحقيقي، وهو أمر يتجاوز قدرات النظم التقليدية.

في هذا السياق، يأتي دور الذكاء الاصطناعي والرؤية الحاسوبية كأدوات أساسية لمواجهة هذه التحديات. الذكاء الاصطناعي يقدم حلولاً مرنة وديناميكية تمكن الروبوتات من التعلم والتكيف مع البيئات المتغيرة، بدلاً من الاعتماد على برمجيات ثابتة. من خلال استخدام تقنيات مثل التعلم العميق والشبكات العصبونية، يمكن للنظام أن يتعلم كيفية تحليل الحركات البشرية وفهم الأنماط المختلفة التي تتبعها اليد أثناء أدائها للمهام. أما الرؤية الحاسوبية، فهي تمثل الجسر الذي يربط بين العالم المادي والعالم الرقمي، حيث تعمل الكاميرات المتطورة على التقاط البيانات المرئية المتعلقة باليد البشرية وتحويلها إلى إشارات يمكن معالجتها باستخدام الذكاء الاصطناعي. هذه العملية تتيح للذراع الروبوتية فهم الحركات البشرية بدقة عالية وتنفيذها بنفس المستوى من السلاسة والتناغم. وبفضل هذه التكنولوجيا، يمكن للنظام أن يتجاوز حدود النظم التقليدية ويصبح قادرًا على التعامل مع المهام المعقدة التي تتطلب مرونة واستجابة سريعة، مما يعزز من قيمته في التطبيقات العملية.

يهدف المشروع إلى تحقيق مجموعة من الأهداف الرئيسية التي تسعى إلى دفع عجلة الابتكار في مجال الروبوتات والذكاء الاصطناعي، مع التركيز على تعزيز التفاعل بين الإنسان والتكنولوجيا. أول هذه الأهداف يتمثل في تصميم وبناء كف ميكانيكية متقدمة قادرة على محاكاة حركة اليد البشرية بدقة عالية وسلاسة، بحيث تكون قادرة على أداء المهام المعقدة التي تتطلب تنسيقًا دقيقًا بين الأصابع والمعصم والجسم الرئيسي للذراع. هذا الهدف لا يقتصر فقط على تقليد الحركات البسيطة، بل يتعداه إلى تمكين الذراع الروبوتية من التعامل مع المهام التي تحتاج إلى مستوى عالٍ من الدقة والمرونة، مثل الإمساك بالأشياء الصغيرة أو تنفيذ حركات دقيقة في بيئات عمل متغيرة.

بالإضافة إلى ذلك، يسعى المشروع إلى تطوير نموذج ذكاء اصطناعي متخصص يعتمد على تقنيات الرؤية الحاسوبية لتحليل وضعية اليد البشرية بشكل فوري ودقيق. يتمثل هذا الهدف في إنشاء نظام قادر على

الفصل الأول: مقدمة

استقبال البيانات المرئية من كاميرا متطورة، ومعالجتها باستخدام خوارزميات ذكاء اصطناعي متقدمة، ليتم تحويلها إلى أوامر تحكم دقيقة توجه الذراع الروبوتية لتنفيذ نفس الحركات بشكل طبيعي. يهدف النظام أيضًا إلى تحقيق استجابة سريعة في الزمن الحقيقي، مما يجعله قادرًا على التعامل مع المهام الديناميكية التي تتطلب تحديثًا مستمرًا للحركات بناءً على المعلومات المرئية المستلمة.

علاوة على ذلك، يركز المشروع على إنشاء نظام تحكم متكامل يعتمد على البيانات المستخرجة من تحليل صور اليد البشرية، بحيث يكون النظام قادرًا على العمل بشكل مستقل دون الحاجة إلى تدخل بشري مباشر. يهدف هذا النظام إلى تعزيز كفاءة الذراع الروبوتية في تنفيذ المهام المختلفة، مع تقليل التأخير الزمني في الاستجابة وتحقيق أعلى مستوى من التناغم بين الحركات البشرية والروبوتية. كما يسعى المشروع إلى اختبار أداء الذراع الروبوتية في بيئات عمل مختلفة، لضمان قدرتها على التعامل مع التحديات العملية التي قد تواجهها، سواء في المجال الطبي أو الصناعي أو التعليمي.

أخيرًا، يعمل المشروع على تحسين النظام بشكل مستمر لزيادة دقة المحاكاة وتقليل التأخير الزمني الذي قد يحدث أثناء تنفيذ الحركات. يهدف هذا التحسين إلى جعل النظام أكثر كفاءة واعتمادية في التطبيقات العملية، مما يعزز من قيمته كأداة تقنية متقدمة يمكن استخدامها في مجموعة واسعة من المجالات. بهذه الأهداف، يسعى المشروع إلى تقديم حلول مبتكرة تلبي احتياجات المجتمع الحديث، وتفتح آفاقًا جديدة أمام تطوير التكنولوجيا التي تجمع بين الذكاء البشري والآلي لتحقيق أقصى استفادة ممكنة.

2-1 مراجعة لدراسات سابقة

1-2-1 تصميم وتطوير ذراع روبوتية بخمس درجات حرية قابلة للتحكم عبر حركة اليد

البشرية


قام مجموعة من الباحثين من قسم الهندسة الميكانيكية في المعهد الوطني للتكنولوجيا في مدينة وارانغال بالهند، بتصميم وتطوير ذراع روبوتية مبتكرة تحتوي على خمس درجات حرية (DOF) تتيح لها تقليد حركة اليد البشرية بشكل دقيق [1]. يعتمد هذا المشروع على استخدام مستشعرات الحركة لالتقاط إشارات اليد البشرية وإرسالها إلى الذراع الروبوتية عبر وحدة اتصال لاسلكية. تم تصميم أجزاء الذراع باستخدام برنامج CATIA (V5 R21)، واختيرت مادة الأكريلونيتريل بوتادين ستايرين (ABS) لطباعتها ثلاثية الأبعاد لتحقيق المتانة والمرونة المطلوبة.

في قلب النظام، يتم استخدام مضخة شفت تعمل بمبدأ الشفط الفراغي لتثبيت الأشياء، وهي آلية مستوحاة من طريقة عمل لسان الحرباء. تم تجهيز الذراع الروبوتية بمحركات سيرفو متعددة يتم التحكم بها بواسطة برمجة Arduino، مما يمنحها القدرة على تنفيذ حركات دقيقة مثل الإمساك والرفع والتحريك. يتم تحويل حركة اليد البشرية إلى إشارات كهربائية باستخدام مستشعرات تسارع ثلاثية المحاور، والتي تلتقط التحركات في المحاور الثلاثة X و Y و Z، ثم يتم معالجة هذه الإشارات بواسطة وحدة تحكم رئيسية تقوم بإرسال الأوامر إلى محركات السيرفو الموجودة في مفاصل الذراع.

يتضمن المشروع العديد من الأشكال والجداول التي توضح تصميم النظام ومكوناته المختلفة. على سبيل المثال، يُظهر الشكل (1-1) المكونات الأساسية لنظام الذراع الروبوتية، بينما يوضح الشكل (2-1) درجات الحرية المختلفة للذراع، بما في ذلك الحركات الدورانية والخطية. كما تم تقديم جدول يوضح أوامر

الفصل الأول: مقدمة

التحكم المرتبطة بحركات اليد اليمنى واليسرى، حيث يتم تحديد كل حركة مرتبطة بمفاصل الذراع المختلفة، مما يعزز من فهم كيفية تنفيذ الحركات المعقدة.



الشكل 1-1: مكونات نظام الذراع الروبوتية.




الشكل 1-2: درجات الحرية (a)، تمثيل للميل،الدوران والانحراف (b).

الجدول 1-1: الأوامر.

أوامر اليد اليسرى	أوامر اليد اليمنى
90 درجة إلى اليمين - السيرفو 3 للأسفل	إلى اليمين - السيرفو 1 إلى اليمين (دوران)
90 درجة لليسار - السيرفو 3 للأعلى	إلى اليسار - السيرفو 1 إلى اليسار
45 درجة لليمين - السيرفو 4 عكس عقارب الساعة	إلى الامام - السيرفو 2 إلى الأعلى
45 درجة لليسار - السيرفو 4 مع عقارب الساعة	إلى الخلف - السيرفو 2 إلى الأسفل
إلى الامام - السيرفو 5 للأعلى	
إلى الخلف - السيرفو 5 للأسفل	

فيما يتعلق بالآلية التشغيلية، تعتمد الذراع الروبوتية على نظام شفط يتكون من كوب شفط مصنوع من مادة مرنة مثل السيليكون أو البلاستيك الناعم، وهو مرتبط بأنبوب ومضخة هوائية تعمل على إزالة الهواء من الكوب لإنشاء فراغ يساعد في الإمساك بالأشياء. يوضح الشكل (1-3) هذا النظام بتفصيل كبير، حيث يشرح كيفية عمل المضخة الهوائية والصمامات في إنشاء ضغط سلبي داخل الكوب.



الشكل 1-3: التمثيل التخطيطي لآلية الشفط.

تم اختبار النظام في بيئات مختلفة وأثبت كفاءته في تنفيذ مهام دقيقة مثل الإمساك بالأجسام الرقيقة والحساسة مثل البيض والأوراق، بالإضافة إلى استخدامه المحتمل في المجال الطبي مثل التعامل مع الأدوات الجراحية أثناء العمليات. يشير الباحثون إلى أن هناك فرصًا مستقبلية لتحسين النظام من خلال استبدال مواد التصنيع بأخرى أكثر صلابة مثل الألومنيوم، واستخدام وحدات اتصال بعيدة المدى مثل Wi-Fi بدلاً من Zigbee، بالإضافة إلى دمج تقنيات معالجة الصور لتعزيز القدرات المستقبلية.

بهذه الطريقة، يقدم المشروع نموذجًا مبتكرًا للذراع الروبوتية التي يمكن أن تكون ذات قيمة كبيرة في التطبيقات الصناعية والطبية، ويبرز كيف يمكن الجمع بين تقنيات التصميم الحديثة والبرمجيات الذكية لتطوير حلول عملية ومتطورة [1].

2-2-1 نظام إمسك روبوتي تعاوني مدفوع بالرؤية ويعتمد على التحكم

الكهروميكانيكي السطحي

قام فريق من الباحثين في جامعة أليكانتي بإسبانيا بتطوير نظام مبتكر يجمع بين تقنيات الرؤية الحاسوبية والتحكم باستخدام الإشارات الكهربائية السطحية لعضلات الجسم (sEMG) لتحسين قدرة الروبوتات على الإمساك بالأشياء بطريقة دقيقة ومريحة. الهدف الأساسي من هذا المشروع هو تسهيل التفاعل بين الإنسان والروبوتات، حيث يمكن للنظام أن يساعد في تنفيذ مهام معقدة مثل الإمساك بالأجسام بدقة عالية سواء في البيئات الصناعية أو الطبية [2].

النظام يعتمد على كاميرا متخصصة تُسمى RealSense SR300، التي تعمل على تحديد العمق باستخدام تقنية الإضاءة المشفرة. هذه الكاميرا قادرة على التقاط صور ثلاثية الأبعاد للأجسام المحيطة، مما يساعد النظام على تحديد مواقع الأجسام وحساب النقاط المناسبة للإمساك بها. بعد ذلك، يتم تحليل البيانات المرئية باستخدام خوارزميات ذكاء اصطناعي لتحديد أفضل طريقة لإمساك الجسم بشكل مستقر. على سبيل المثال، يتم تقسيم المشهد إلى نقاط تمثل كل جسم على حدة، ثم يتم اختيار النقاط التي توفر إمساكًا آمنًا بناءً على شكل الجسم وزاوية التماس.


بعد تحديد النقاط المناسبة، يتم توجيه الذراع الروبوتية إلى الموقع المحسوب مسبقًا باستخدام نظام تحكم متطور يعتمد على نظام ROS (Robot Operating System). الذراع الروبوتية المستخدمة في هذا

المشروع من طراز PA-10، وهي تحتوي على سبع درجات حرية تمنحها القدرة على الحركة بمرونة. كما أنها مزودة بيد روبوتية تُعرف باسم Allegro Hand، تحتوي على أربعة أصابع وستة عشر مفصلاً مستقلاً، مما يجعلها قادرة على تنفيذ حركات دقيقة ومعقدة. يتم توجيه اليد الروبوتية إلى موقع قريب من الجسم المستهدف، حيث يتم استخدام بيانات sEMG المسجلة من عضلات الساعد لإجراء تعديلات دقيقة قبل إتمام عملية الإمساك.

تتمثل إحدى أهم ميزات هذا النظام في استخدام إشارات sEMG لتحسين دقة الإمساك. يتم تسجيل هذه الإشارات من عضلات الساعد أثناء حركات انثناء ومد المعصم، ثم يتم معالجتها وإزالة الضوضاء منها باستخدام مرشحات خاصة. بعد ذلك، يتم تصنيف الإشارات إلى ثلاث حالات رئيسية: انثناء ضعيف، مد ضعيف، وانثناء قوي. يتم استخدام الانثناء والمد الضعيفين لإجراء تعديلات دقيقة على وضعية اليد الروبوتية، بينما يتم استخدام الانثناء القوي لبدء الإمساك النهائي. يتم نشر الأوامر الناتجة عبر نظام ROS، الذي يوجه اليد الروبوتية لتنفيذ الحركة المطلوبة.

يتضمن المشروع العديد من الصور والرسوم التوضيحية التي تشرح كيفية عمل النظام. على سبيل المثال، يوضح الشكل (4-1) الموقع المبدئي للذراع الروبوتية المحسوب بواسطة خوارزمية الرؤية، بينما يوضح الشكل (5-1) كيفية تسجيل إشارات sEMG من أحد الأشخاص المشاركين في التجارب. كما يوضح الشكل (6-1) خطوات حساب نقاط التماس على سطح الجسم المستهدف، بدءاً من تقسيم المشهد إلى نقاط وصولاً إلى تحديد أفضل زوج من نقاط التماس. بالإضافة إلى ذلك، يقدم الشكل 5 مخططاً يوضح كيفية تفاعل المكونات المختلفة لنظام ROS مع بعضها البعض لتنفيذ مهام الإمساك.

الفصل الأول: مقدمة




الشكل 1-4: وضعية ما قبل الإمساك للنظام الروبوتي المحسوبة بواسطة خوارزمية الرؤية.




الشكل 1-5: نظام التخطيط الكهربائي للعضلات السطحي (sEMG) يقوم بجمع البيانات من أحد الأشخاص.

تم اختبار النظام باستخدام ستة أشخاص لم يكونوا على دراية مسبقاً بأنظمة التحكم الكهروميكانيكية. تم وضع جسم أسطوانى الشكل في ثلاث مواضع مختلفة (رأسي، أفقي، ومائل)، وتم تنفيذ كل مهمة إمساك خمس مرات لكل موضع. أظهرت النتائج معدل دقة مرتفعاً في تصنيف إشارات sEMG بلغ حوالي 87.23%، ومعدل دقة إمساك بلغ حوالي 95.29%. كما أظهرت المقارنة مع التجارب السابقة التي اعتمدت فقط على الرؤية الحاسوبية زيادة في دقة الإمساك بنسبة تصل إلى 13.8% عند إضافة التحكم باستخدام sEMG.



الشكل 6-1: خطوات الطريقة لحساب زوج من نقاط التماس.



الشكل 7-1: مخطط يوضح الطريقة المقترحة المطبقة في نظام تشغيل الروبوت (ROS) ويظهر وحدات الاتصال بين الخطوات المختلفة.

يمكن اعتبار هذا النظام خطوة مهمة نحو تحقيق تكامل أكبر بين البشر والروبوتات في بيئات العمل الصناعية والطبية. من خلال الجمع بين تقنيات الرؤية الحاسوبية والتحكم الكهروميكانيكي السطحي،

يقدم هذا المشروع حلاً مبتكرة لتحسين دقة الإمساك واستقراره، مما يجعله أداة قيمة لتطوير الروبوتات المساعدة في المستقبل [2].

1-2-3 ذراع روبوتية ناعمة حلزونية تضاهي اليد البشرية في الأداء والمهام

في إطار الجهود المستمرة لتطوير الروبوتات القادرة على محاكاة الحركات البشرية، نجح فريق من العلماء من جامعة العلوم والتكنولوجيا الصينية في تصميم ذراع روبوتية ناعمة ذات هيكل حلزوني مبتكر. هذه الذراع الروبوتية تميزت بقدرتها الفائقة على تنفيذ مهام الإمساك المتعددة بمرونة ودقة عالية، مما يجعلها أداة متعددة الاستخدامات في مجالات مختلفة [3].

تمتلك الذراع الروبوتية قدرة ملحوظة على التعامل مع مجموعة واسعة من الأجسام، بدءاً من المواد الهشة مثل البيض والفراولة وكابلات "يو إس بي"، وصولاً إلى الإمساك بكرة تنس سريعة بشكل آمن وضرب كرة تنس طاولة بدقة وسرعة. هذا المستوى من الأداء يعكس براعة التصميم الهندسي الذي استند إلى تقنيات متقدمة مستوحاة من الطبيعة.

استخدم الباحثون، بقيادة العالم نيكولوس فريريس، تقنيات الهندسة العكسية لمحاكاة الهياكل الحلزونية الشكل اللوغاريتمية الموجودة في الطبيعة، والتي تتميز بمرونتها وقدرتها على التكيف مع مختلف الظروف. وأدى هذا النهج إلى تطوير نظام آلي مستوحى من علم الأحياء أطلق عليه اسم "سبايروبس". هذا النظام أظهر كفاءة عالية في تنفيذ مناورات الإمساك المعقدة من خلال سلسلة من الحركات المتنوعة، بما في ذلك اللف والمد والإمساك، حيث حقق معدل نجاح يصل إلى حوالي 95%، وفقاً للدراسة التي نشرت في مجلة "ديفايس".

من جهة أخرى، يتميز المقبض الحلزوني للذراع الروبوتية بزاوية مخروطية تبلغ 15 درجة، وهو مدعوم بآلية تشغيل تعتمد على كابلين أو ثلاث كابلات مرنة. هذه الآلية تمنح الذراع قدرة استثنائية على تحمل أحمال تصل إلى 260 ضعف وزنها، مما يجعلها واحدة من أكثر التصاميم كفاءة ومتانة حتى الآن.

تعكس هذه الدراسة خطوة مهمة نحو تطوير الروبوتات التي يمكنها العمل في بيئات ديناميكية تتطلب مرونة ودقة عالية. كما تفتح الباب أمام تطبيقات مبتكرة في مجالات مثل الطب، الصناعة، والتعليم، حيث يمكن لهذه التكنولوجيا أن تساهم في تحسين الأداء البشري وتسهيل تنفيذ المهام المعقدة [3].



الشكل 8-1: الذراع الروبوتية الحلزونية.

الفصل الثاني: الأساس

النظري

يعد الفصل الثاني بمثابة الأساس النظري الذي يُمهّد الطريق لفهم التقنيات والأساليب المستخدمة في مشروعنا. سيتم التركيز على مفاهيم أساسية مثل الرؤية الحاسوبية، الذكاء الاصطناعي، وتعلم الآلة، مع الغوص عميقًا في كيفية معالجة الصور رقميًا واستخدام الشبكات العصبونية الاصطناعية لاستخلاص المعلومات منها. بالإضافة إلى ذلك، سيتم تسليط الضوء على التحديات التي تواجه تقنيات تعلم الآلة التقليدية في التعامل مع الصور، وكيف ساهم التعلم العميق في التغلب على هذه التحديات من خلال بنى أكثر تعقيدًا مثل شبكات DNN. كما سيتم توضيح المفاهيم المرتبطة بالعصبونات الصناعية، دوال التفعيل، وأساليب تجنب مشكلة التعلم الزائد لضمان تحقيق أداء فعال ودقيق للنماذج المستخدمة.

1-2 مقدمة في الرؤية الحاسوبية

1-1-2 تعريف الرؤية الحاسوبية


تُعد الرؤية الحاسوبية، والتي يُشار إليها اختصارًا بـ CV، تقنية متقدمة تجمع بين علوم الحوسبة والهندسة لتمكين الأجهزة والآلات من فهم وتحليل البيانات المرئية مثل الصور ومقاطع الفيديو. هذه التقنية، التي تُعتبر جزءًا أساسيًا من مجال الذكاء الاصطناعي، تهدف إلى محاكاة قدرة الإنسان على استيعاب العالم المحيط من خلال المعطيات البصرية واستخلاص المعلومات منها لاتخاذ قرارات أو تنفيذ مهام محددة [4].

تكمُن أهمية الرؤية الحاسوبية في قدرتها على تحويل البيانات المرئية إلى معلومات ذات قيمة يمكن استخدامها في العديد من التطبيقات العملية. فهي لا تقتصر فقط على التعرف على الأشياء أو تمييز الألوان، بل تمتد إلى فهم البيئة المحيطة بشكل أعمق، مما يجعلها أداة أساسية في تطوير أنظمة ذكية تستجيب للمتغيرات المختلفة. بفضل هذه التقنية، أصبح بالإمكان إنشاء أنظمة قادرة على أداء مهام

الفصل الثاني: الأساس النظري

معقدة مثل تحليل الصور الطبية لتشخيص الأمراض، أو تمكين السيارات ذاتية القيادة من "رؤية" الطريق والتنقل بأمان.

مع التطورات الكبيرة في مجالات الذكاء الاصطناعي والتعلم العميق، شهدت الرؤية الحاسوبية طفرة كبيرة في الأداء والدقة، حيث أصبح بالإمكان تحقيق معدل دقة يصل إلى 99% في بعض التطبيقات، مقارنة بـ 50% فقط قبل أقل من عقد من الزمن. هذه التحسينات المذهلة عززت مكانة الرؤية الحاسوبية كأحد التقنيات المحورية في العديد من الصناعات، بدءًا من الرعاية الصحية التي تعتمد عليها في تحليل الصور الطبية، وصولاً إلى السيارات ذاتية القيادة التي تعتمد عليها في "رؤية" البيئة المحيطة.



الشكل 1-2: حجم سوق الرؤية الحاسوبية حسب الصناعة بالنسبة المئوية.

سوق الرؤية الحاسوبية يشهد نموًا هائلًا، ومن المتوقع أن يصل إلى 22.27 مليار دولار أمريكي بنهاية عام 2023، مع توقعات بأن يقفز إلى 50.97 مليار دولار بحلول عام 2028، بمعدل نمو سنوي يبلغ حوالي 12.56%. هذا النمو السريع يعكس الطلب المتزايد على حلول الرؤية الحاسوبية في مختلف المجالات، خاصة في الولايات المتحدة التي تقود السوق بتقدير قيمة يصل إلى 8.3 مليار دولار. ومع استمرار التقدم

في تقنيات التعلم العميق وتوافر كميات ضخمة من البيانات المرئية، ستظل الرؤية الحاسوبية واحدة من أكثر التقنيات الواعدة التي تدفع عجلة الابتكار في العالم الحديث [4].


2-1-2 كيف يتم معالجة الصور رقميًا

1-2-1-2 البكسلات ومفهومها

البكسل هو الوحدة الأساسية التي تتكون منها الصور الرقمية، وهو اختصار لعبارة "Picture Element"، ويعمل كعنصر صغير يمثل لونًا معينًا في نقطة محددة من الصورة. يتم ترتيب البكسلات في شبكة لتكوين الصورة، حيث يساهم كل بكسل بلونه وسطوعه في رسم التفاصيل العامة للصورة. دقة الصورة تعتمد على عدد البكسلات التي تحتويها، ويتم التعبير عنها عادةً بقياس العرض والارتفاع، مثل 1080×1920 بكسل [4].

تتميز البكسلات بعدة خصائص أساسية تحدد جودة ومظهر الصورة. من بين هذه الخصائص "عمق اللون"، الذي يشير إلى عدد البتات المستخدمة لتمثيل لون كل بكسل. على سبيل المثال، في صورة ذات عمق 8 بت، يمكن لكل بكسل أن يمثل 256 لونًا مختلفًا (2^8)، بينما في صورة 24 بت، يمكن لكل بكسل أن يمثل أكثر من 16 مليون لون (2^{24})، مع تخصيص 8 بت لكل قناة من قنوات الألوان الأساسية: الأحمر، الأخضر، والأزرق (RGB). بالإضافة إلى ذلك، هناك نماذج مختلفة للألوان تستخدم في تمثيل البكسلات، مثل نموذج RGB الشائع في الصور الرقمية، ونموذج التدرج الرمادي المستخدم في الصور التي تعتمد على درجات اللون الرمادي فقط، ونموذج CMYK المستخدم في الطباعة، ونموذج HSV الذي يعتمد على الظل، التشبع، والقيمة.

الفصل الثاني: الأساس النظري



الشكل 2-2: خصائص الصورة الرئيسية.

تعتبر دقة الصورة عاملاً حاسماً في تحديد مستوى التفاصيل التي يمكن للصورة تقديمها. كلما زاد عدد البكسلات، كانت الصورة أكثر وضوحاً ودقة، ولكن هذا يأتي أيضاً بتكلفة أعلى من حيث متطلبات التخزين ومعالجة البيانات. عند ترتيب البكسلات في شبكة، فإنها تعمل معاً لتشكيل الصورة الكاملة. على سبيل المثال، إذا تخيلنا صورة بسيطة بحجم 3×3 بكسل، حيث يمثل كل بكسل لوناً معيناً (مثل الأحمر، الأخضر، أو الأزرق)، فإن العين البشرية ستدرك هذه البكسلات المنفصلة كصورة واحدة متصلة عند النظر إليها من مسافة معينة.


تلعب البكسلات دوراً محورياً في العديد من تقنيات معالجة الصور، حيث يمكن تعديل قيمها لتحقيق تحسينات أو إجراء عمليات معينة. على سبيل المثال، يمكن تعديل السطوع عن طريق زيادة أو تقليل قيمة البكسلات، بينما يتم تعديل التباين عن طريق تغيير الفرق بين قيم البكسلات ومتوسط القيم في الصورة. كما يمكن استخدام تقنيات معالجة الألوان لتغيير الظل أو التشبع أو تطبيق فلتر ألوان معينة من خلال تعديل قيم القنوات اللونية. بالإضافة إلى ذلك، تُستخدم المرشحات المختلفة مثل التمويه،

الفصل الثاني: الأساس النظري

التحديد الحواف، والتوضيح لتحسين الصور، وهي تعمل بتطبيق عمليات رياضية على قيم البكسلات وجيرانها. على سبيل المثال، يعمل مرشح التمويه الغاوسي على تنعيم الصورة عن طريق متوسط قيم البكسلات مع جيرانها. كما يمكن إجراء تحويلات هندسية مثل الدوران، التحجيم، أو الإزاحة لتغيير مواقع البكسلات بما يحقق التأثير المطلوب [4].

2-2-1-2 تحويل الصور إلى بيانات قابلة للتحليل

عند العمل مع الصور الرقمية، يتم تحويلها إلى بيانات يمكن للأنظمة الحاسوبية فهمها ومعالجتها. يتم ذلك من خلال تمثيل الصورة على شكل مصفوفة أو مجموعة من الأرقام، حيث يمثل كل عنصر في المصفوفة جزءًا صغيرًا من الصورة. هذه العناصر، التي تُعرف بالبكسلات، يتم ترتيبها بشكل منهجي لتكوين الشكل النهائي للصورة [4].



الشكل 2-3: تحويل الصورة إلى مصفوفة.

لتحويل الصورة إلى أرقام، يتم تخصيص قيمة عددية لكل بكسل بناءً على خصائصه مثل اللون أو الدرجة الرمادية. على سبيل المثال، في صور الألوان، يتم تقسيم كل بكسل إلى قيم تمثل مكوناته الأساسية:

الفصل الثاني: الأساس النظري

الأحمر والأخضر والأزرق (RGB). يتم بعد ذلك تخزين هذه القيم في مصفوفة ذات أبعاد تتناسب مع دقة الصورة. كلما زادت دقة الصورة، احتوت المصفوفة على عدد أكبر من العناصر، مما يعني توفر المزيد من التفاصيل.

بعد تحويل الصورة إلى مصفوفة، يمكن إجراء عمليات رياضية عليها لتحقيق أغراض مختلفة. على سبيل المثال، يمكن تعديل القيم العددية لتحسين الإضاءة أو تغيير الألوان، أو يمكن استخدام خوارزميات متقدمة لتحليل الصورة واستخلاص المعلومات منها. هذا النهج يتيح للبرامج الحاسوبية التعامل مع الصور كبيانات رقمية، مما يجعل من الممكن تطبيق تقنيات الذكاء الاصطناعي والرؤية الحاسوبية لفهم محتوى الصورة وتحليلها بدقة [4].

2-2 الذكاء الاصطناعي وتعلم الآلة

1-2-2 تعريف الذكاء الاصطناعي

الذكاء الاصطناعي هو مجال عام يهدف إلى تمكين الآلات من أداء المهام التي تتطلب عادةً ذكاءً بشريًا. يركز هذا المجال على تطوير خوارزميات ونماذج قادرة على معالجة البيانات واتخاذ قرارات ذات معنى بناءً على تلك البيانات. يمكن للذكاء الاصطناعي أن يشمل مجموعة واسعة من التقنيات، مثل التعلم الآلي الذي يتيح للأنظمة تحسين أدائها بمرور الوقت من خلال الخبرة، والرؤية الحاسوبية التي تمكن الآلات من فهم الصور ومقاطع الفيديو، ومعالجة اللغة الطبيعية التي تسمح لها بفهم النصوص أو الكلام البشري. يُستخدم الذكاء الاصطناعي في العديد من التطبيقات اليومية، بدءًا من المساعدات الرقمية الشخصية وحتى الأنظمة المعقدة المستخدمة في الرعاية الصحية، والصناعة، والنقل. بفضل التقدم الكبير في تقنيات

الذكاء الاصطناعي، أصبحت هذه الأنظمة أكثر كفاءة وقدرة على محاكاة جوانب مختلفة من السلوك البشري بطريقة دقيقة ومبتكرة [4].



الشكل 2-4: تقنيات الذكاء الاصطناعي.

2-2-2 تعلم الآلة كفرع من الذكاء الاصطناعي

1-2-2-2 مفهوم تعلم الآلة

تعلم الآلة (Machine Learning) هو أحد فروع الذكاء الاصطناعي الذي يركز على تطوير خوارزميات ونماذج قادرة على تمكين الأنظمة الحاسوبية من التعلم والتكيف بناءً على البيانات. بمعنى آخر، تعلم الآلة هو عملية تدريب النماذج على استخلاص الأنماط والعلاقات المخفية داخل البيانات دون الحاجة إلى برمجة صريحة للقيام بمهمة معينة. يتم ذلك من خلال تقديم مجموعة كبيرة من البيانات للنظام، حيث يقوم النظام بتحليلها وتحديد القواعد أو الأنماط التي تساعد على اتخاذ قرارات دقيقة عند مواجهة بيانات جديدة [4].

الفصل الثاني: الأساس النظري


تتمثل أهمية تعلم الآلة في قدرته على التعامل مع كميات هائلة من البيانات ومعالجتها بطريقة فعالة وسريعة، مما يجعله أداة لا غنى عنها في العديد من المجالات. على سبيل المثال، يمكن استخدام تعلم الآلة لتحسين عمليات اتخاذ القرار في الرعاية الصحية من خلال تحليل السجلات الطبية، أو لتطوير أنظمة التوصيات التي تعزز تجربة المستخدم في المنصات الرقمية مثل خدمات البث والمواقع الإلكترونية. كما يُستخدم تعلم الآلة في السيارات ذاتية القيادة لتمكينها من فهم البيئة المحيطة بها واتخاذ قرارات آمنة أثناء القيادة.

علاوة على ذلك، فإن تعلم الآلة يتيح للأجهزة تحسين أدائها بشكل مستمر مع مرور الوقت، مما يجعلها أكثر دقة وكفاءة. هذه الخاصية تجعله أداة أساسية في التطبيقات التي تتطلب التكيف مع البيانات المتغيرة باستمرار، مثل الأسواق المالية، وأنظمة الكشف عن الاحتيال، وأنظمة التنبؤ بالطقس. وبفضل هذه الإمكانيات، أصبح تعلم الآلة جزءًا لا يتجزأ من التطورات التكنولوجية الحديثة، وهو يدفع الابتكار في مجالات متعددة، مما يساهم في تحسين جودة الحياة وتحقيق كفاءة أكبر في العمليات اليومية [4].

2-2-2-2 مبدأ التدريب في تعلم الآلة

في مجال تعلم الآلة، يتم بناء النماذج باستخدام مجموعة من الأوزان التي يتم ضبطها بشكل دقيق لفهم الأنماط المخفية في البيانات. تعمل هذه الأوزان كأداة أساسية لتحديد كيفية استجابة النموذج للبيانات الجديدة، حيث يتم تعديلها باستمرار أثناء عملية التدريب (انظر الشكل 2-5) لتحقيق أفضل أداء ممكن. في البداية، يتم تهيئة الأوزان بقيم عشوائية أو قيم محددة مسبقًا، ثم تُستخدم البيانات المتاحة لتدريب النموذج. يتم ذلك عن طريق تقديم بيانات تحتوي على أمثلة معروفة النتائج، مما يسمح للنظام بمقارنة تنبؤاته بالنتائج الحقيقية وتعديل الأوزان لتقليل الفجوة بينهما. تستمر هذه العملية حتى يتمكن النموذج من تحقيق مستوى عالٍ من الدقة عند التعامل مع بيانات جديدة [4].

عملية المعالجة باستخدام التعلم الآلي



الشكل 2-5: عملية تدريب نموذج التعلم الآلي.

البيانات المستخدمة في تعلم الآلة تأتي في أشكال وأنواع متعددة، مما يتيح للنماذج التعامل مع مهام مختلفة. على سبيل المثال، يمكن أن تكون البيانات في شكل صور، حيث يتم استخدام البكسلات كوحدات أساسية لتحليل المعلومات. يتم تحليل الصور باستخدام تقنيات مثل الرؤية الحاسوبية لاستخلاص الخصائص المهمة، مثل الألوان، الأشكال، والأنماط. كما يمكن أن تكون البيانات في شكل مقاطع فيديو، وهي عبارة عن سلسلة من الصور المتتابة، مما يجعلها أكثر تعقيدًا لكنها تتيح إمكانية تحليل الحركة والتغيرات الزمنية. بالإضافة إلى ذلك، تُستخدم الإشارات، مثل البيانات الصوتية أو الإشارات الكهربائية، كمدخلات للنماذج، حيث يتم تحويلها إلى تنسيقات رقمية يمكن تحليلها لاكتشاف الأنماط أو السمات المميزة.

من خلال الجمع بين الأوزان القابلة للتعديل والبيانات المتنوعة، يتمكن نموذج تعلم الآلة من فهم البيئة المحيطة واتخاذ قرارات مستنيرة. على سبيل المثال، يمكن لنظام يستخدم صورًا وفيديوهات أن يتعلم التعرف على الأجسام أو الأشخاص في البيئات المختلفة، بينما يمكن لنظام آخر يعتمد على الإشارات

الفصل الثاني: الأساس النظري

الصوتية أن يميز بين مختلف الأصوات أو حتى يفهم اللغة البشرية. هذا التنوع في أنواع البيانات يفتح آفاقاً واسعة أمام التطبيقات العملية، بدءاً من السيارات ذاتية القيادة التي تعتمد على تحليل الصور والفيديوهات لفهم الطريق، وصولاً إلى الأنظمة الطبية التي تستخدم الإشارات الكهربائية لتحليل نشاط الدماغ أو العضلات. ومع استمرار تحسين النماذج وتطويرها، تزداد قدرتها على التعامل مع البيانات المعقدة وتحقيق نتائج دقيقة ومفيدة [4].

2-2-2-3 تحديات تعلم الآلة في معالجة الصور

- تعلم الآلة التقليدي يواجه تحديات كبيرة عند معالجة الصور بسبب طبيعة البيانات المعقدة التي تتكون منها. الصور عادةً تحتوي على عدد كبير جداً من البكسلات، وكل بكسل يمثل قيمة محددة للون أو الدرجة الرمادية. عند التعامل مع هذه البكسلات بشكل فردي، يتم إنشاء مساحة بيانات ضخمة ومعقدة للغاية، مما يجعل من الصعب بناء نماذج فعالة قادرة على استخلاص الأنماط المفيدة بسرعة وكفاءة.
- عندما يتم التعامل مع البكسلات بشكل فردي، فإن النموذج يحتاج إلى معالجة كل بكسل كوحدة مستقلة دون النظر إلى العلاقات بين البكسلات المجاورة. هذا الأسلوب يعتبر غير فعال لأنه يتجاهل البنية المكانية للصورة، حيث إن البكسلات لا تعمل بشكل منفصل بل تكون مرتبطة ببعضها البعض لتشكيل أشكال وألوان معينة. كما أن هذا الأسلوب يؤدي إلى زيادة في تعقيد الحسابات، مما يجعل من الصعب تحقيق دقة عالية في التعرف على الأنماط أو الأشياء داخل الصورة.
- الوقت اللازم لمعالجة الصور باستخدام تعلم الآلة التقليدي يكون طويلاً جداً بسبب الكم الهائل من البيانات التي يجب تحليلها. كل بكسل يتطلب معالجة منفصلة، مما يعني أن النموذج سيحتاج إلى أداء عدد هائل من العمليات الحسابية. هذا يؤثر سلباً على السرعة العامة للنظام، خاصة إذا كانت

الصور ذات دقة عالية تحتوي على ملايين البكسلات. بالإضافة إلى ذلك، فإن وقت التدريب على البيانات يزداد بشكل كبير، مما يجعل هذا الأسلوب غير عملي للتطبيقات التي تتطلب استجابات سريعة.

- الدقة في تصنيف أو تحليل الصور تتأثر بشكل مباشر عند التعامل مع البكسلات بشكل فردي. نظرًا لأن النموذج لا يستطيع فهم العلاقات بين البكسلات أو اكتشاف الأنماط المعقدة التي تمتد عبر مساحات أكبر من الصورة، فإن النتائج غالبًا ما تكون غير دقيقة. هذا يعود إلى أن المعلومات المكانية والهياكل المرئية التي تشكل جزءًا أساسيًا من الصورة لا يمكن استخلاصها بشكل صحيح إذا تم التعامل مع كل بكسل كوحدة منعزلة.
- القدرة على تعميم النموذج عند استخدام الأساليب التقليدية. نظرًا لأن النماذج التي تعتمد على التعامل الفردي مع البكسلات تحتاج إلى كميات هائلة من البيانات لتغطية جميع الحالات الممكنة، فإنها قد تفشل في تقديم نتائج دقيقة عند مواجهة بيانات جديدة أو بيئات مختلفة. هذا يزيد من صعوبة بناء نماذج قادرة على العمل بكفاءة في مواقف واقعية متغيرة.

3-2 التعلم العميق

1-3-2 تعريف التعلم العميق

التعلم العميق (Deep Learning) هو أحد الأفرع الحديثة والمتطورة في مجال الذكاء الاصطناعي، ويتميز بقدرته على تمكين الأنظمة الحاسوبية من استخلاص الأنماط المعقدة من البيانات دون الحاجة إلى توجيه صريح أو معالجة يدوية. يتم ذلك باستخدام نماذج حسابية مستوحاة من بنية الدماغ البشري، تُعرف بالشبكات العصبية الاصطناعية. في التعلم العميق، يتم تنظيم هذه الشبكات في طبقات متعددة، حيث

الفصل الثاني: الأساس النظري

تقوم كل طبقة بمعالجة جزء معين من المعلومات ثم تمريرها إلى الطبقة التالية. هذا التنظيم المتسلسل للطبقات يسمح للنظام بفهم البيانات بشكل أعمق وأكثر دقة، مما يجعله قادرًا على التعامل مع مهام معقدة مثل التعرف على الصور أو فهم النصوص [4].

أهمية التعلم العميق تأتي من قدرته الفائقة على التعامل مع كميات ضخمة من البيانات غير المهيكلة، مثل الصور، والفيديوهات، والإشارات الصوتية، وحتى النصوص. على عكس الأساليب التقليدية التي تعتمد على قواعد محددة مسبقًا، فإن التعلم العميق يتيح للنماذج تعلم القواعد ذاتيًا من خلال تحليل البيانات مباشرة. هذا يعني أن النظام يمكنه اكتشاف العلاقات والأنماط الخفية دون الحاجة إلى تدخل بشري مباشر. كما أن التعلم العميق يتميز بمرونته الكبيرة، حيث يمكن تطبيقه على مجموعة واسعة من التطبيقات العملية، بدءًا من الرعاية الصحية، حيث يتم استخدامه لتحليل الصور الطبية وتشخيص الأمراض، وصولاً إلى السيارات ذاتية القيادة، التي تعتمد عليه لفهم البيئة المحيطة واتخاذ قرارات آمنة أثناء القيادة.



الشكل 2-6: تطبيقات التعلم العميق.

أحد الجوانب الرئيسية التي تجعل التعلم العميق مهمًا هو قدرته على تحسين الدقة والأداء مع مرور الوقت. عندما يتم تدريب النموذج على بيانات جديدة، فإنه يصبح أكثر كفاءة في استخلاص المعلومات واستخدامها لتحسين قراراته المستقبلية. هذا يجعل التعلم العميق أداة قوية للتعامل مع المشكلات التي تتطلب معالجة مستمرة وسريعة للبيانات، خاصة في القطاعات التي تعتمد على البيانات الضخمة مثل التجارة الإلكترونية، والتكنولوجيا المالية، وحتى الإعلام الرقمي. بفضل هذه الإمكانيات، أصبح التعلم العميق أحد الركائز الأساسية للابتكار في العديد من المجالات، وهو يدفع عجلة التطور نحو مستقبل أكثر ذكاءً وكفاءة [4].

2-3-2 تطور التعلم العميق من تعلم الآلة

1-2-3-2 الفرق بين التعلم العميق وتعلم الآلة التقليدي

الفرق بين التعلم العميق وتعلم الآلة التقليدي يكمن في الطريقة التي يتم بها معالجة البيانات واستخلاص الأنماط منها. تعلم الآلة التقليدي يعتمد بشكل كبير على استخراج السمات (Features) من البيانات يدويًا، حيث يقوم الخبراء بتحديد الخصائص المهمة للبيانات بناءً على خبرتهم ومعرفتهم بالمجال. بعد ذلك، يتم إدخال هذه السمات المستخرجة إلى خوارزميات تعلم الآلة لتدريب النموذج على أداء مهام محددة مثل التصنيف أو التنبؤ. ومع ذلك، فإن هذه العملية تعتمد بشكل كبير على جودة السمات المستخرجة وقد تكون غير فعالة عند التعامل مع بيانات معقدة مثل الصور أو الفيديوهات [4].

على الجانب الآخر، يعتمد التعلم العميق على الشبكات العصبية الاصطناعية التي تحاكي طريقة عمل الدماغ البشري. يتميز التعلم العميق بقدرته على استخراج السمات تلقائيًا من البيانات دون الحاجة إلى تدخل بشري مباشر. هذا يعني أن النموذج يمكنه تعلم الأنماط والخصائص المخفية في البيانات من خلال طبقات متعددة من الشبكة العصبية، حيث تقوم كل طبقة باستخراج مستوى معين من التعقيد في البيانات. على سبيل المثال، في حالة معالجة الصور، قد تستخرج الطبقات الأولى الحواف والزوايا، بينما تستخرج الطبقات الأعمق أنماطًا أكثر تعقيدًا مثل الأشكال والأجسام. هذا يجعل التعلم العميق أكثر كفاءة وأقل اعتمادًا على الخبرة البشرية في استخراج السمات.

لقد تغلب التعلم العميق على العديد من التحديات التي كانت تواجه تعلم الآلة التقليدي، خاصة عند التعامل مع البيانات المعقدة وغير المهيكلة. أحد هذه التحديات هو صعوبة استخراج السمات يدويًا من البيانات، وهو ما يتطلب وقتًا وجهدًا كبيرًا ويتأثر بشكل كبير بجودة البيانات وخبرة الشخص المسؤول عن

الفصل الثاني: الأساس النظري

هذه العملية. باستخدام التعلم العميق، يتم تجاوز هذه المشكلة من خلال السماح للشبكة العصبية باكتشاف السمات ذاتها بشكل تلقائي، مما يزيد من دقة النموذج وكفاءته.

تحدي آخر تم التغلب عليه هو التعامل مع البيانات عالية الأبعاد، مثل الصور أو الفيديو، حيث يصعب على تقنيات تعلم الآلة التقليدية التعامل مع هذه البيانات بسبب تعقيدها الكبير. في التعلم العميق، يتم استخدام طبقات متعددة من الشبكات العصبية لتحليل البيانات بكفاءة، حيث يتم تقسيم المشكلة إلى مستويات مختلفة من التعقيد. على سبيل المثال، يمكن للشبكة العصبية أن تبدأ بتحليل الجوانب البسيطة للصورة ثم تتدرج نحو فهم الأنماط الأكثر تعقيداً، مما يتيح لها التعامل مع البيانات المعقدة بشكل أفضل.

بالإضافة إلى ذلك، يوفر التعلم العميق قدرة أكبر على التكيف مع البيئات الديناميكية والمتغيرة. في تعلم الآلة التقليدي، يتم تصميم النماذج غالباً لمهام محددة ولا تكون مرنة بما يكفي للتعامل مع تغيرات كبيرة في البيانات. أما في التعلم العميق، فإن النماذج قادرة على التعلم المستمر وتحسين أدائها بناءً على البيانات الجديدة، مما يجعلها أكثر مرونة وكفاءة في التعامل مع السيناريوهات المختلفة.

يوضح الجدول (1-2) الفرق الأساسي بين تعلم الآلة والتعلم العميق من حيث الطريقة، التدخل البشري، الأجهزة المطلوبة، الوقت المطلوب، والاستخدامات المختلفة لكل منهما.

الجدول 1-2: الفرق بين تعلم الآلة والتعلم العميق.

الطريقة	تعلم الآلة	التعلم العميق
التدخل البشري	لا تتطلب بيانات منظمة	تتطلب بيانات منظمة
الأجهزة	تتطلب تدخلًا بشريًا لتصحيح الأخطاء	لا تتطلب تدخلًا بشريًا لتصحيح الأخطاء
الوقت	تعمل على وحدات المعالجة المركزية (CPU)	تتطلب وحدات معالجة الرسومات (GPU) أو قدرة حوسبة كبيرة
الاستخدامات	تستغرق من ثوانٍ إلى ساعات	تستغرق أسابيع
	التنبؤ، التوقع والاستخدامات البسيطة الأخرى	تطبيقات أكثر تعقيداً مثل السيارات ذاتية القيادة

2-3-3 أهمية التعلم العميق في معالجة الصور

يُعتبر تصنيف الصور باستخدام التعلم العميق من أبرز التطبيقات التي أثبتت فعاليتها في مجال الذكاء الاصطناعي. يعتمد هذا النوع من التصنيف على استخدام الشبكات العصبية المتعددة الطبقات، والتي تُعرف بـ (Deep Neural Networks)، لتحليل البيانات البصرية واستخلاص الأنماط المخفية منها. يتم ذلك من خلال معالجة الصور بكفاءة عالية، حيث تبدأ الطبقات الأولى من الشبكة العصبية بتحليل الخصائص البسيطة مثل الحواف والزوايا، بينما تتولى الطبقات الأعمق استخراج الأنماط الأكثر تعقيداً مثل الأشكال والأجسام. هذه العملية تتيح للنظام فهم الصور بشكل دقيق وتصنيفها إلى فئات محددة بناءً على خصائصها.

من بين الأمثلة البارزة لاستخدام التعلم العميق في تصنيف الصور، يمكن الإشارة إلى تطبيقات الرؤية الحاسوبية التي تُستخدم في العديد من المجالات العملية. على سبيل المثال، يتم استخدام التعلم العميق في السيارات ذاتية القيادة لتحليل المشاهد المرورية والتعرف على الأجسام المختلفة مثل السيارات، المشاة، والإشارات المرورية. كما أن أنظمة الأمن والمراقبة تعتمد على هذه التقنية لتحديد الأفراد أو الكشف عن الأنشطة غير الطبيعية في المناطق المراقبة. بالإضافة إلى ذلك، تُستخدم تقنيات التعلم العميق في المجال الطبي لتحليل الصور الطبية مثل صور الأشعة السينية والرنين المغناطيسي، حيث يتمكن النظام من تحديد الأمراض أو التشوهات بدقة عالية.


في قطاع التجارة الإلكترونية، يُستخدم التعلم العميق لتحسين تجربة المستخدم من خلال تصنيف المنتجات بناءً على الصور. على سبيل المثال، يمكن لأنظمة التعلم العميق التعرف على نوع المنتج، لونه، وحتى حالته الفيزيائية، مما يساعد في تقديم توصيات أكثر دقة للمستخدمين. كما أن شبكات التواصل

الفصل الثاني: الأساس النظري

الاجتماعي تعتمد على هذه التقنية لتنظيم المحتوى البصري، حيث يتم تصنيف الصور وفقًا لمحتواها، مثل التعرف على الوجوه أو المشاهد الطبيعية. هذه الأمثلة توضح كيف أصبح التعلم العميق أداة أساسية في تحسين كفاءة ودقة تصنيف الصور في مختلف المجالات.

أحد الأمثلة العملية التي توضح قوة التعلم العميق هو نظام "AlexNet"، الذي حقق نتائج مذهلة في مسابقة تصنيف الصور "ImageNet" عام 2012. أثبت هذا النظام أن الشبكات العصبية العميقة قادرة على تحقيق دقة عالية جدًا في تصنيف الصور مقارنة بالأساليب التقليدية. ومنذ ذلك الحين، تم تطوير العديد من النماذج الأكثر تقدمًا مثل "ResNet"، "VGGNet"، و "Inception"، والتي أصبحت تُستخدم على نطاق واسع في مختلف التطبيقات.

المخطط في الشكل (2-7) يوضح تطور معدلات الخطأ في مجال التصنيف البصري عبر السنوات، مع التركيز على عام 2012 حيث حققت بعض النماذج مثل AlexNet و SuperVision معدلات دقيقة للغاية مقارنة بالنماذج السابقة.



الشكل 2-7: تطور نماذج التعلم العميق.


4-2 الشبكات العصبية الاصطناعية (Artificial Neural Network)

الشبكات العصبية الاصطناعية (Artificial Neural Networks) هي أحد فروع الذكاء الاصطناعي وتقنية تعلم الآلة التي تستوحي تصميمها ووظيفتها من الشبكات العصبية البيولوجية الموجودة في أدمغة الكائنات الحية، وتهدف إلى محاكاة طريقة معالجة المعلومات واتخاذ القرارات بشكل يشبه عمل الدماغ البشري. هذه الشبكات تستخدم بشكل واسع في مجالات متعددة مثل التعرف على الصور، معالجة اللغة الطبيعية، التنبؤات، والتصنيف، وغيرها من التطبيقات التي تتطلب قدرة على التعلم واستخلاص الأنماط من البيانات المعقدة. أساس فكرة الشبكات العصبية الاصطناعية هو بناء نموذج رقمي يتكون من وحدات معالجة بسيطة تسمى "الخلايا العصبية الاصطناعية"، والتي ترتبط ببعضها بطريقة تسمح بتمرير المعلومات ومعالجتها بطريقة متسلسلة ومتعددة الطبقات [4].

مكونات الشبكة العصبية الاصطناعية تنقسم بشكل رئيسي إلى ثلاثة أجزاء: طبقة الإدخال، الطبقات الخفية، وطبقة الإخراج. طبقة الإدخال هي نقطة بداية الشبكة حيث يتم استقبال البيانات الخام أو المعلومات التي نريد تحليلها أو معالجتها، وهي تمثل المتغيرات أو الخصائص التي نستخدمها كمدخلات للنموذج. بعد ذلك تأتي الطبقات الخفية، وهي عبارة عن طبقات متتالية من الخلايا العصبية التي تعمل على استخراج وتحويل الميزات والمعلومات من البيانات الأولية بشكل تدريجي، إذ تقوم كل طبقة منها بمعالجة المعلومات القادمة من الطبقة السابقة وتحويلها إلى شكل أكثر تجريداً أو تعقيداً. عدد هذه الطبقات وعدد الخلايا في كل طبقة يعتمد على تعقيد المشكلة المراد حلها. أخيراً، طبقة الإخراج، وهي التي

الفصل الثاني: الأساس النظري

تقوم بإعطاء النتيجة النهائية لمعالجة الشبكة، مثل تصنيف بيانات إلى فئات معينة، أو إعطاء تقدير رقمي، أو غير ذلك بناءً على نوع المهمة.



الشكل 8-2: آلية عمل الشبكة العصبية الاصطناعية.

أما آلية عمل الشبكة العصبية (الشكل 8-2) فتبدأ بعملية التغذية الأمامية (Feedforward)، وهي الطريقة التي تنتقل بها البيانات من طبقة الإدخال عبر الطبقات الخفية وصولاً إلى طبقة الإخراج. في كل خلية عصبية داخل أي طبقة، يتم استقبال مجموعة من القيم (المدخلات) التي تمثل الإشارات القادمة من خلايا الطبقة السابقة، حيث يتم ضرب كل إشارة في وزن معين يعبر عن أهمية هذه الإشارة، ثم يتم جمع كل النتائج للحصول على قيمة واحدة تسمى (القيمة المُجمعة). بعد ذلك، تمر هذه القيمة المُجمعة عبر دالة تنشيط (Activation Function) تقوم بتحويلها إلى إشارة مناسبة للمراحل التالية في الشبكة، بحيث تساعد هذه الدالة على إدخال الالخطية للنموذج، مما يمكن الشبكة من تعلم أنماط معقدة غير خطية.

الفصل الثاني: الأساس النظري

التدريب هو المرحلة التي يتم فيها تعديل أوزان الشبكة بحيث يمكنها أداء المهمة المطلوبة بدقة عالية. يتم ذلك عادة عن طريق تقديم مجموعة كبيرة من الأمثلة (بيانات التدريب) مع النتائج الصحيحة المعروفة، ثم تقوم الشبكة بحساب الفرق بين الناتج المتوقع والناتج الفعلي (الخطأ)، ومن خلال خوارزمية تسمى الانحدار العكسي (Backpropagation)، يتم تحديث الأوزان بطريقة تقلل هذا الخطأ تدريجيًا عبر عدة تكرارات. هذا التحديث يعتمد على حساب المشتقات لتحديد اتجاه وحجم تعديل الأوزان، مما يسمح للشبكة بالتعلم وتحسين دقتها بمرور الوقت.

وظيفة كل مكون داخل الشبكة تبرز من خلال دوره في معالجة المعلومات: طبقة الإدخال تعمل على استقبال البيانات وتحويلها إلى شكل مناسب لتغذية باقي الطبقات، الطبقات الخفية تقوم بتحليل وتحويل هذه البيانات إلى مستويات أكثر تجريدًا من المعلومات باستخدام الأوزان ودوال التنشيط، مما يمكن الشبكة من اكتشاف الأنماط والخصائص المهمة في البيانات، بينما طبقة الإخراج تقدم النتيجة النهائية أو التنبؤ بناءً على المعالجة التي تمت داخل الشبكة. الأوزان بين الخلايا العصبية تشكل جوهر التعلم داخل الشبكة، إذ يتم تعديلها باستمرار أثناء التدريب لتقليل الخطأ وتحسين الأداء. دوال التنشيط تلعب دورًا حيويًا في منح النموذج القدرة على التعامل مع البيانات غير الخطية والمعقدة، كما تساعد في التحكم في إشارات الخلايا العصبية بحيث لا تكون قوية جدًا أو ضعيفة جدًا، مما يضمن استقرار عملية التعلم.


الشبكات العصبية الاصطناعية هي أداة قوية تعتمد على فكرة التكرار والتحسين التدريجي، حيث يبدأ النموذج بتخمينات عشوائية أو شبه عشوائية للأوزان، ثم يتعلم من خلال المعطيات ويعدل هذه التخمينات ليصل إلى نتائج دقيقة وموثوقة، وهذا ما يجعلها مناسبة جدًا لحل مشكلات معقدة لا يمكن للبرمجيات التقليدية التعامل معها بسهولة. نجاح الشبكات العصبية في التعلم واتخاذ القرارات يشبه إلى

حد كبير طريقة دماغ الإنسان في التعامل مع المعلومات، لذا تعتبر من أهم التقنيات الحديثة في مجال الذكاء الاصطناعي.

1-4-2 الشبكات العصبية العميقة (Deep Neural Networks)

الشبكات العصبية العميقة (Deep Neural Networks) تمثل تطورًا طبيعيًا ومتقدمًا للشبكات العصبية الاصطناعية البسيطة، إذ تعتمد على نفس المبادئ الأساسية لكنها تتميز بوجود عدد كبير من الطبقات الخفية المتسلسلة، مما يمنحها القدرة على تحليل بيانات أكثر تعقيدًا واستخلاص ميزات أكثر تجريدًا. في الشبكات البسيطة، عادةً ما تحتوي البنية على طبقة إدخال واحدة، طبقة أو طبقتين خفيتين، وطبقة إخراج واحدة، وهذا كافٍ للتعامل مع مشاكل بسيطة أو ذات طبيعة خطية أو محدودة التعقيد. أما في الشبكات العميقة، فإن البنية تتكون من عدد كبير من الطبقات الخفية التي يمكن أن تتجاوز العشرات أو حتى المئات، وكل طبقة تقوم بمعالجة ناتج الطبقة السابقة بشكل تدريجي من خلال تحويله إلى تمثيل أكثر تعقيدًا وغنى بالمعاني، مما يسمح للنموذج بفهم العلاقات الدقيقة والأنماط الخفية في البيانات. هذا العمق في الطبقات هو ما يميز الشبكات العميقة ويمنحها قدرات استثنائية، لكنه أيضًا يجعلها أكثر تطلبًا من حيث التدريب والموارد [4].

الفصل الثاني: الأساس النظري



الشكل 2-9: بنية الشبكة العصبية العميقة.

أحد أهم الاستخدامات المتقدمة للشبكات العصبية العميقة هو في مجال معالجة الصور والفيديو، إذ أثبتت فعاليتها في فهم وتحليل محتوى الصور بدرجة تقترب من قدرات الإنسان. من أبرز تطبيقاتها تصنيف الصور، حيث يمكنها تحديد محتويات الصورة وتمييز الأجسام المختلفة بدقة عالية، واكتشاف الكائنات (Object Detection) مثل السيارات أو الأشخاص داخل مشهد معين، والتعرف على الوجوه، وتحسين جودة الصور، وحتى توليد صور جديدة من خلال الشبكات التوليدية. في مجال الفيديو، تستخدم الشبكات العميقة لتحليل المشاهد المتحركة والتعرف على الأنشطة والأحداث، مثل اكتشاف السلوك غير الطبيعي في كاميرات المراقبة، أو تحليل تعابير الوجه وتحديد المشاعر، أو تتبع الأجسام المتحركة عبر تسلسل من اللقطات. كذلك تُستخدم في أنظمة الترجمة الفورية للغة الإشارة أو تحليل لقطات الأشعة الطبية في القطاع الصحي، مما يعزز دقة التشخيصات. كل هذه التطبيقات تتطلب قدرة على فهم المعلومات البصرية بمستويات متعددة من التجريد، وهذا ما تتيحه الشبكات العميقة من خلال قدرتها على التعلم من كميات ضخمة من البيانات واستخلاص ميزات تلقائيًا دون الحاجة إلى تدخل بشري مباشر في تصميم خصائص البيانات.


لكن رغم هذه القدرات العالية، تواجه الشبكات العصبية العميقة عدة تحديات كبيرة تحد من استخدامها بشكل واسع أو مباشر في كل التطبيقات. أول هذه التحديات هو حجم البيانات، إذ تحتاج الشبكات العميقة إلى كميات ضخمة من البيانات المتنوعة والممثلة بشكل جيد من أجل أن تتعلم بفعالية وتنتج نتائج دقيقة. قلة البيانات تؤدي إلى ضعف الأداء واحتمالية التعميم الخاطئ، لذلك يتطلب تدريب نموذج عميق توفير قواعد بيانات تحتوي على آلاف أو ملايين العينات، وهو أمر قد لا يكون متاحًا دائمًا، خاصة في المجالات المتخصصة أو الحساسة. التحدي الثاني هو الحاجة إلى قدرة معالجة عالية، حيث أن عملية التدريب تتطلب موارد حسابية ضخمة مثل وحدات معالجة الرسومات (GPUs) أو وحدات معالجة التنسور (TPUs) التي توفر سرعات عالية في تنفيذ العمليات الرياضية المعقدة. الزمن اللازم لتدريب شبكة عميقة على بيانات كبيرة قد يمتد إلى ساعات أو أيام أو حتى أسابيع، ويتطلب تخزينًا كبيرًا وذاكرة عشوائية عالية، وهذا ما يجعل استخدامها مكلفًا في البيئات العادية. إضافة إلى ذلك، فإن الضبط الدقيق للمعاملات (Hyperparameters) مثل معدلات التعلم، وعدد الطبقات، وعدد العقد في كل طبقة، ودوال التنشيط، يتطلب خبرة تقنية كبيرة، ويمكن أن يؤثر بشكل كبير على أداء النموذج. كما تواجه هذه الشبكات تحديات في قابلية التفسير، إذ أن تعقيد بنيتها يجعل من الصعب على البشر فهم كيف ولماذا اتخذت قرارًا معينًا، مما يشكل عائقًا في التطبيقات التي تتطلب الشفافية مثل المجالات القانونية أو الطبية.

2-4-2 الشبكات العصبية الالتفافية (Convolutional Neural Networks)

الشبكات العصبية الترشيحية (Convolutional Neural Networks - CNN) تُعد واحدة من أبرز أنواع الشبكات العصبية العميقة وأكثرها فعالية في مجال معالجة الصور وتحليلها، إذ تم تطويرها خصيصًا للتعامل مع البيانات التي تتميز بالبنية الشبكية أو التوزيع المكاني مثل الصور. تختلف الشبكات العصبية الترشيحية عن الشبكات العصبية التقليدية في طريقة معالجتها للمدخلات، حيث تستفيد من خصائص

الفصل الثاني: الأساس النظري

الصور مثل التجاور المكاني والتكرار البنيوي لتقليل عدد المعاملات وتحسين القدرة على اكتشاف الأنماط المرئية، مثل الحواف، الزوايا، الأشكال، والأنسجة، وذلك بطريقة تحاكي عمل الخلايا البصرية في القشرة الدماغية. أهمية هذه الشبكات تنبع من قدرتها الكبيرة على استخلاص الميزات المفيدة من الصور بشكل تلقائي وفعال دون الحاجة إلى خطوات يدوية لتحديد الخصائص كما كان الحال في الطرق التقليدية، مما يجعلها العمود الفقري للعديد من التطبيقات في رؤية الحاسوب، مثل التعرف على الصور، واكتشاف الأشياء، وتقسيم الصور، والتعرف على الوجوه، والتصوير الطبي، وأنظمة القيادة الذاتية، والمراقبة الذكية، وغيرها من الاستخدامات التي تتطلب فهماً عميقاً للمحتوى البصري [4].



الشكل 10-2: آلية عمل شبكة CNN.

آلية عمل الشبكات العصبية الترشيحية تتضمن مجموعة من الطبقات المتسلسلة التي تعمل بتناغم لاستخلاص وتحويل تمثيلات الصور إلى نتائج مفهومة.

- **الطبقة الترشيحية (Convolutional Layer):** تُعد القلب النابض للشبكة، حيث تستخدم مجموعة من المرشحات (Filters) أو النوى (Kernels) الصغيرة الحجم والتي تنزلق على الصورة الأصلية وتقوم بعملية الترشيح لاستخلاص ميزات محددة من الصورة. كل مرشح يتم تدريبه ليتعرف على نمط

معين، مثل الحواف الأفقية أو الرأسية أو الزوايا أو الانحناءات، ويتم إنتاج ما يسمى بخريطة المميزات (Feature Map) التي تحتوي على استجابات المرشح لمناطق مختلفة من الصورة. هذه الطبقة تمكن الشبكة من اكتشاف الأنماط الأساسية الموجودة في الصور، وهي الطبقة الأولى التي تبدأ منها عملية الفهم البصري. ما يميز الطبقة الترشيحية هو أن المعاملات فيها أقل بكثير من الشبكات الكاملة الاتصال، لأن كل خلية عصبية في الخريطة تتصل بجزء صغير فقط من الصورة وليس بالصورة بأكملها، مما يقلل من التكلفة الحسابية ويزيد من كفاءة التعلم.

- **طبقة التجميع (Pooling Layer):** تأتي بعد الطبقات الترشيحية وتستخدم لتقليل حجم خرائط الميزات الناتجة، مما يؤدي إلى تقليل عدد المعاملات وتسريع عملية التدريب، بالإضافة إلى زيادة قدرة النموذج على التعميم من خلال جعله أقل حساسية للانزياحات الصغيرة في الصورة. أكثر أنواع التجميع شيوعًا هو "التجميع الأقصى" (Max Pooling) حيث يتم اختيار أكبر قيمة في كل منطقة فرعية صغيرة من خريطة الميزات، أو "التجميع المتوسط" (Average Pooling) حيث يتم أخذ المتوسط. وظيفة هذه الطبقة هي تلخيص المعلومات الأهم من كل خريطة ميزات، ما يساعد على الاحتفاظ بالميزات المميزة وتقليل التفاصيل غير الضرورية أو الضوضاء، مع المحافظة على العلاقة المكانية العامة.

- **الطبقة الكاملة الاتصال (Fully Connected Layer):** تظهر عادةً في نهاية الشبكة العصبية الترشيحية، وتُشبه في عملها الشبكات العصبية التقليدية، حيث تتصل كل خلية عصبية بجميع الخلايا في الطبقة السابقة. بعد أن تمر البيانات عبر الطبقات الترشيحية والتجميع وتحويلها إلى تمثيل منخفض الأبعاد ولكنه غني بالميزات، تقوم هذه الطبقة باستخدام هذا التمثيل لاتخاذ القرار النهائي، مثل تصنيف الصورة إلى فئة معينة أو تحديد احتمالية الانتماء لفئات متعددة. هذه الطبقة تعمل

الفصل الثاني: الأساس النظري

كمصنف يأخذ الميزات المستخرجة من الصور ويقوم بترجمتها إلى نتائج نهائية مفهومة مثل تسميات أو تقديرات رقمية.


الشبكات العصبية الترشيحية تتعامل مع الصور بطريقة ذكية ومنهجية لاستخراج المميزات، حيث تبدأ بالنظر إلى تفاصيل صغيرة محلية مثل الحواف والنقاط والزوايا، ثم تجمع هذه التفاصيل تدريجيًا عبر الطبقات المتتالية لتكوين فهم أعمق وأكثر تجريدًا للكيانات الأكبر مثل الأشكال أو الكائنات أو الأنماط المعقدة. بمرور البيانات عبر الشبكة، يتم تكوين خريطة غنية من الميزات التي تمثل الصورة الأصلية بدقة ولكن بطريقة عددية مبسطة تسمح للنموذج بفهم وتفسير محتوى الصورة. كل طبقة تضيف مستوى جديدًا من التحليل والتجريد، إلى أن تصل في النهاية إلى مرحلة يمكن فيها تصنيف الصورة أو فهم محتواها بشكل دقيق. وبفضل هذه الآلية، أصبحت الشبكات العصبية الترشيحية من أكثر الأدوات استخدامًا وموثوقية في تحليل الصور الرقمية، وأسهمت بشكل كبير في تطوير أنظمة الرؤية الحاسوبية في مختلف القطاعات التقنية والصناعية والطبية.

الفصل الثالث: تقدير

الوضعيّات

1-3 مفهوم تقدير الوضعيات (Pose Estimation)

تقنية تقدير الوضعيات (Pose Estimation) تُعدّ من أبرز تطبيقات الذكاء الاصطناعي في مجال تحليل الصور والفيديو، حيث تهدف إلى استنتاج المواقع الدقيقة للنقاط المفصلية على جسم الإنسان من خلال صورة أو مقطع مرئي. تعتمد هذه التقنية على نماذج متقدمة من الشبكات العصبية التي تُمكن الحاسوب من "رؤية" الأشخاص في المشاهد الرقمية والتعرف على أوضاعهم الجسدية، مثل الوقوف، الجلوس، أو رفع اليد، من خلال تتبع نقاط محددة تمثل المفاصل والمناطق الرئيسية في الهيكل العظمي. لا تكتفي خوارزميات التقدير بتحديد وجود الأشخاص، بل تميز أيضًا بين أجزاء أجسامهم وتحدد مواضعها بدقة ضمن الإطار البصري، وهو ما يسمح بفهم الشكل الهندسي العام للجسم في لحظة معينة [6].



الشكل 1-3: تقنية Pose Estimation.

الفصل الثالث: تقدير الوضعيات

يرتكز عمل هذه التقنية على مراحل متسلسلة تبدأ برصد الشخص في المشهد، ثم استخراج المعالم البارزة باستخدام نموذج مدرب على مجموعات بيانات ضخمة تحتوي على صور لأشخاص بأوضاع مختلفة. بعد ذلك، تُحلل هذه المعالم لتحديد الإحداثيات الثنائية أو الثلاثية الأبعاد للنقاط المفصلية، مثل الكتفين، المرفقين، الركبتين، والقدمين، مما يمنح النموذج القدرة على تمثيل وضعية الجسم بدقة في الفضاء. تُصمم هذه النماذج لتكون قادرة على التعامل مع التغيرات في الإضاءة، الملابس، الخلفيات، وزوايا التصوير، وهو ما يعزز مرونتها وموثوقيتها في البيئات الواقعية [6].

تختلف منهجيات التقدير بين النماذج التي تُقدّر النقاط لجسم واحد فقط في كل إطار، وتلك التي تدعم تحليل عدة أشخاص في المشهد ذاته، مع تزايد الحاجة لاستخدام خوارزميات فعالة لتتبع النقاط من إطار إلى آخر دون انقطاع أو أخطاء. كما تراعي النماذج الحديثة الخصائص الفسيولوجية للبشر، مثل أطوال الأطراف ونسب الجسم، لضمان أن تكون النتائج منطقية ومتناسقة مع التكوين البشري الطبيعي. تعتمد بعض الأساليب على البنية العظمية ضمن النموذج لتوليد تخمينات ذكية حتى في حالة تغطية أجزاء من الجسم أو ضعف الرؤية في جزء من الإطار [6].

تُطور نماذج التقدير باستخدام بيانات واقعية تشمل آلاف الوضعيات والسيناريوهات، ويتم تحسينها باستمرار لضمان دقة أعلى وسرعة أكبر في الاستجابة، خاصة في التطبيقات التي تتطلب تحليل الفيديو في الزمن الحقيقي. ومن الجدير بالذكر أن هذه التقنية لا تحتاج بالضرورة إلى معدات تصوير احترافية، إذ يمكن تطبيقها على فيديوهات من كاميرات تقليدية، مما يجعلها متاحة للاستخدام في نطاق واسع من الأنظمة الذكية. هذا التنوع في القدرة على فهم وتحليل حركات الإنسان من خلال الصور قد فتح المجال لتطبيقات متعددة في مختلف القطاعات، ويعكس تطورًا مهمًا في فهم الحاسوب للبيئة البشرية المحيطة به [6].

تمثل تقنية تقدير الوضعيات نقطة تحول في فهم العلاقة بين الإنسان والآلة، حيث مكّنت الحواسيب من تحليل حركات الإنسان بطريقة دقيقة وواقعية، دون الحاجة لأجهزة استشعار مادية أو تلامس مباشر. هذا الفهم العميق للحركة البشرية عبر الصور والفيديوهات فتح الباب أمام تطبيقات واسعة ومتنوعة، تخدم العديد من القطاعات وتُسهم في تطوير حلول ذكية أكثر تكيفًا مع السلوك البشري الطبيعي. أهمية هذه التقنية لا تكمن فقط في قدرتها على قراءة الحركة، بل في مساهمتها الجوهرية في تحسين حياة الأفراد وكفاءة الأنظمة. تشمل أبرز مجالات الأهمية ما يلي:

- **مراقبة الحركة والسلوك:** تُستخدم في المدارس والجامعات لمراقبة التزام الطلبة، وفي المنشآت الأمنية لتحليل تحركات الأشخاص المشبوهين، كما تُوظف في تحليل أداء اللاعبين في الملاعب والمباريات.
- **التحكم بالإيماءات (Gesture Control):** تُعدّ أساسًا لتطوير أنظمة تفاعل طبيعي مع الأجهزة الإلكترونية، مثل التحكم في الشاشات أو الأجهزة المنزلية عبر حركة اليد أو الجسم دون لمس مباشر.
- **التأهيل الطبي وتحسين الأداء الرياضي:** تساعد المعالجين الفيزيائيين والمدربين على تتبع وضعيات الجسم أثناء التمارين والعلاج الحركي، مما يسهل الكشف عن الأخطاء أو الإصابات المحتملة وتصحيحها بشكل لحظي.
- **دعم أنظمة الذكاء الاصطناعي في كشف الغش:** عبر مراقبة تفاصيل دقيقة في سلوك الأفراد، مثل التفات الرأس المتكرر أو حركة اليدين غير المعتادة، يمكن للنظام رصد الأنماط المشبوهة خلال الامتحانات أو الاختبارات الرقمية.

الفصل الثالث: تقدير الوضعيات

- **تعزيز الواقع المعزز والافتراضي (AR/VR):** تُستخدم هذه التقنية في تحسين تجارب المستخدم ضمن البيئات الافتراضية، من خلال تتبع دقيق لحركات الجسم وتحويلها إلى عناصر تفاعلية داخل النظام.
- **تحسين تجربة المستخدم في الألعاب الذكية:** تسمح بتطوير ألعاب تعتمد على الحركة الجسدية الكاملة، مما يعزز الجانب التفاعلي والترفيهي في الألعاب الرقمية.
- **رصد حالات الطوارئ والسقوط لكبار السن:** يمكن للنظام التعرف على السقوط أو الحركات غير الطبيعية في دور الرعاية أو المنازل الذكية، وبالتالي إطلاق تنبيه سريع لإنقاذ الشخص.
- **تحليل بيانات الجمهور في الفعاليات:** تُستخدم في تتبع تفاعل الجمهور مع عروض معينة في المؤتمرات أو المعارض، مما يساعد المنظمين على تقييم جودة التفاعل وتحسين المحتوى.
- **التعرف على لغة الإشارة:** تُسهم في تطوير أدوات تتيح التفاعل مع الصم والبكم من خلال تفسير إشارات اليد وتحويلها إلى نص أو صوت.

2-3 لمحة عن مكتبة MediaPipe

في سياق التطور السريع في تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، برزت مكتبة MediaPipe كأحدى الأدوات الرائدة التي طورتها شركة Google لتكون منصة مفتوحة المصدر تهدف إلى تسهيل تطوير تطبيقات تعتمد على تحليل الفيديو والصور في الزمن الحقيقي. وتُعد MediaPipe خيارًا مثاليًا للباحثين والمطورين الذين يسعون إلى بناء أنظمة ذكية قادرة على فهم المشاهد المرئية وتحليلها بدقة، دون الحاجة إلى إعدادات معقدة أو موارد حسابية ضخمة، مما يجعلها أداة ذات قيمة عالية من حيث الكفاءة والمرونة وسهولة الاستخدام [6].

MediaPipe

الشكل 2-3: مكتبة MediaPipe.

تم تصميم MediaPipe لتكون منصة متعددة الاستخدامات تدعم مجموعة واسعة من المهام المتعلقة بالرؤية الحاسوبية، مثل تتبع الكائنات، اكتشاف الوجوه، التعرف على الإيماءات، تحليل الحركة، تقسيم الخلفية، وأكثر من ذلك بكثير. أحد أبرز ما يميز هذه المكتبة هو أنها توفر نماذج مدربة مسبقًا تعتمد على تقنيات متقدمة في تعلم الآلة، ما يُمكن المستخدم من توظيف حلول جاهزة دون الحاجة إلى تدريب النماذج من الصفر. ويشمل ذلك إمكانية تخصيص النماذج أو إعادة تدريبها على بيانات جديدة وفقًا لاحتياجات كل تطبيق [6].

من الناحية التقنية، تعتمد MediaPipe على بنية مرنة تُعرف باسم graph-based architecture، والتي تُسهّل تنظيم العمليات التي تتم على البيانات المرئية داخل ما يُسمى بـ "graph" أو مخطط بياني. يتكون هذا المخطط من "عُقد" (Nodes) تمثل خطوات المعالجة، مثل إدخال الفيديو، الكشف عن الكائنات، التحليل، والإخراج. تسمح هذه البنية للمستخدم ببناء مسارات معالجة دقيقة وقابلة للتعديل بسهولة، ما يتيح إمكانية دمج وحدات مختلفة من المعالجة البصرية في إطار زمني فعال [6].

إحدى نقاط القوة الجوهرية في MediaPipe هي قدرتها على العمل على عدة أنظمة أساسية، بما في ذلك Python لأنظمة سطح المكتب، و++C للأداء العالي، بالإضافة إلى دعمها لتطبيقات الهواتف المحمولة على أنظمة Android و iOS. هذا التعدد في الدعم يفتح الباب أمام استخدام المكتبة في مجموعة كبيرة من

الفصل الثالث: تقدير الوضعيات

المشاريع، بدءًا من تطبيقات الهواتف الذكية التفاعلية، مرورًا بأنظمة المراقبة الذكية، وصولًا إلى المشاريع الأكاديمية والبحثية المتقدمة. وقد صُممت المكتبة بحيث تستفيد من تسريع العتاد (hardware acceleration) عند توفره، مما يعزز من أدائها على الأجهزة ذات الموارد المحدودة مثل الهواتف والألواح الإلكترونية [6].

إلى جانب مرونتها وفعاليتها، تمتاز MediaPipe كذلك بكونها مدعومة بمجتمع نشط من المطورين، بالإضافة إلى توثيق رسمي شامل من Google. يتضمن هذا التوثيق شروحات مفصلة، وأمثلة عملية، وأدوات مساعدة تجعل من المكتبة بيئة تطوير متكاملة تُمكن حتى غير المختصين في مجالات الذكاء الاصطناعي من الدخول إلى هذا المجال وتطبيق الأفكار بسهولة. وتُعد هذه السهولة في الوصول نقطة تحول مهمة في تعميم تقنيات الرؤية الحاسوبية، حيث لم تعد هذه الأدوات حكرًا على الشركات أو المؤسسات البحثية الكبرى فقط، بل أصبحت في متناول الجميع، من طلاب الجامعات إلى رواد الأعمال والمطورين المستقلين [6].

من الناحية الأكاديمية والبحثية، ساهمت MediaPipe في تسريع الكثير من الدراسات والتجارب التطبيقية، إذ توفر واجهات برمجية مبسطة لمعالجة البيانات البصرية، مما يوفر وقتًا وجهدًا كان يُستهلك سابقًا في بناء خوارزميات معقدة من الصفر. كما أن قابليتها للدمج مع مكتبات أخرى مثل TensorFlow أو OpenCV يُعد من المزايا التكاملية التي تعزز من قيمتها كأداة تطويرية [6].

3-2-1 تقدير وضعيات الجسم باستخدام MediaPipe BlazePose

يُعد تقدير وضعيات الجسم أحد أبرز تطبيقات الذكاء الاصطناعي في تحليل الصور والفيديو، حيث يركّز هذا المجال على فهم موقع أجزاء الجسم البشري من خلال الصور الثابتة أو الفيديوها المتحركة. وتعتمد


هذه التقنية على تحليل المظهر العام للشخص داخل المشهد، واستخلاص ما يُعرف بالنقاط الأساسية أو المفصلية في الجسم، مثل الرأس، الرقبة، الكتفين، المرفقين، الرسغين، الوركين، الركبتين، والكاحلين. الهدف الأساسي من هذا التحليل هو بناء تصور رقمي لوضعية الجسم، بحيث يتمكن النظام من تتبع الحركة بدقة، وتحديد ما إذا كان الشخص واقفًا أو جالسًا أو يميل إلى أحد الجانبين، أو يرفع ذراعه، أو يدير رأسه إلى اليمين أو اليسار، وغيرها من السلوكيات المرتبطة بالوضع الجسدي [6].

تعتمد نماذج التقدير على شبكات عصبية مدربة على مجموعات ضخمة من البيانات التي تتضمن صورًا لأشخاص بوضعيات متنوعة، حيث تتعلم هذه النماذج التعرف على الأنماط البصرية الدقيقة التي تميز كل نقطة مفصلية. بمجرد التقاط صورة أو إطار من فيديو، يقوم النظام بتحليل الشكل العام للجسم داخل الإطار وتحديد مواضع هذه النقاط بدقة متناهية. ويتم تمثيل النتائج عادة على هيئة نموذج هيكلي رقمي يظهر فوق الشخص في الصورة، ما يتيح مراقبة سلوكه أو تفاعله مع البيئة المحيطة بشكل لحظي أو عند المراجعة لاحقًا [6].

هذه القدرة على قراءة وضعيات الجسم ليست مقتصرة على تتبع الحركة فقط، بل تمتد لفهم السياق الكامل للنشاط الذي يقوم به الشخص، وهو ما يُمكن الأنظمة من رصد السلوكيات غير الاعتيادية، أو تحليل الأداء الحركي في مجالات مثل الرياضة والتعليم، وحتى الأمن. كما يُعد فهم وضعية الجسم مدخلًا أساسيًا لتطبيقات أكثر تقدمًا، مثل التعرف على الأنشطة اليومية، أو تحديد حالات الإرهاق، أو اكتشاف الإيماءات، وكل ذلك يتم دون الحاجة إلى أجهزة استشعار إضافية على الجسد، بل بالاعتماد فقط على صورة أو فيديو [6].

الفصل الثالث: تقدير الوضعيات

تُعد MediaPipe من أبرز مكتبات Google المتخصصة في بناء نماذج رؤية حاسوبية فعالة، وقد طورت نموذجًا متقدمًا يُعرف باسم BlazePose، وهو مصمم خصيصًا لتقدير وضعيات الجسم بدقة عالية وفي الزمن الحقيقي. يتميز هذا النموذج بقدرته على تتبع 33 نقطة رئيسية موزعة على مختلف مناطق الجسم البشري، مما يوفر تمثيلًا تفصيليًا لوضعية الفرد وحركاته اللحظية. هذه الكثافة في تحديد النقاط تتيح إمكانية تفسير سلوكيات دقيقة أو غير اعتيادية، وهو ما يجعل BlazePose خيارًا مثاليًا لتطبيقات تتطلب مراقبة دقيقة مثل قاعات الامتحان، أو تتبع أداء الرياضيين، أو تحليل حركات الجسم في الوقت الفعلي ضمن بيئات تفاعلية [6].



الشكل 3-3: النقاط الرئيسية للجسم.

تمر عملية التقدير عبر عدة مراحل مترابطة تؤدي في مجموعها إلى استخلاص معلومات الوضعية من الصورة أو الفيديو المدخل، وتشمل هذه المراحل ما يلي:

- قراءة صورة أو فيديو من الكاميرا أو مصدر آخر.


- تحليل شكل الجسم داخل الإطار لتحديد معالمه العامة.
- استخراج الإحداثيات ثلاثية الأبعاد للنقاط المكتشفة على الجسم.
- استخدام هذه البيانات لتفسير الوضعية وتحليلها وفقاً للسياق المطلوب.

يسمح هذا الترتيب الدقيق في العمل لنموذج BlazePose بالتفاعل بسلاسة مع البيئات التي تتطلب استجابة لحظية، مما يعزز من كفاءته في مراقبة السلوك البشري بفعالية تعتمد على الذكاء الاصطناعي ومعالجة الصور [6].

2-2-3 تتبع اليدين باستخدام MediaPipe Hands

يُعد MediaPipe Hands من النماذج المتقدمة في مجال رؤية الحاسوب، حيث طورته شركة Google ليكون قادراً على تتبع اليد البشرية وتحليل حركتها بدقة في الوقت الحقيقي. يعتمد هذا النموذج على تقنيات الذكاء الاصطناعي لتحديد نقاط رئيسية على اليد، يصل عددها إلى 21 نقطة تشمل المفاصل وأطراف الأصابع والمعصم، مما يمكّنه من فهم تفاصيل دقيقة لحركة اليد وشكلها. ما يميز هذا النموذج هو قدرته على العمل بكفاءة دون الحاجة إلى أجهزة معقدة، إذ يمكن تشغيله باستخدام كاميرات بسيطة، مثل تلك الموجودة في الحواسيب المحمولة أو الهواتف الذكية، مما يجعله قابلاً للتطبيق في مجالات متعددة كالتعليم، والواقع المعزز، والتفاعل مع الآلات، وحتى في البيئات التي تتطلب مراقبة سلوكيات معينة [6].

الفصل الثالث: تقدير الوضعيات




الشكل 4-3: النقاط الرئيسية لليدين.

يوفر MediaPipe Hands إطاراً مرناً وسهل الدمج في التطبيقات البرمجية، ويُستخدم بشكل واسع من قبل المطورين والباحثين لكونه مفتوح المصدر ومتاحاً مجاناً. وتكمن أهمية هذا النموذج في أنه يقدم للمستخدمين وسيلة فعالة لتحليل إشارات اليد وتفسيرها، مما يفتح آفاقاً واسعة لتطبيقات تعتمد على التواصل غير اللفظي أو التحكم عن بُعد، كما أنه يساعد في تصميم أنظمة أكثر تفاعلية وإنسانية في تفاعلها مع المستخدمين [6].

كما هو موضح في الشكل (3-9)، تبدأ العملية عندما تلتقط الكاميرا صورة تحتوي على يد. في البداية، يقوم النظام بفحص الصورة ليرى إن كانت اليد موجودة بوضوح. إذا كانت هذه أول صورة يراها، أو إذا لم تكن اليد ظاهرة من قبل، فإنه يُشغّل مرحلة الكشف عن اليد (تُوضح في الجزء العلوي من المخطط حيث يُكتب: (Hand Detection only runs on: 1. First Frame, 2. Hand is missing).

بعد أن يجد النظام اليد، يُحوّل مكانها إلى مستطيل لتحديد موقعها بدقة (كما يظهر في المربعات التي تشير إلى DetectionToRectangle و ImageCropping في وسط المخطط). ثم يقوم بقص الجزء الذي يحتوي على اليد من الصورة حتى يركّز عليه فقط.



الشكل 5-3: مراحل معالجة الصورة في نظام MediaPipe Hands.

في المرحلة التالية، يستخدم النظام تقنية ذكية جدًا تُسمى "تقدير العلامات" لتحديد 21 نقطة رئيسية على اليد، مثل أطراف الأصابع والمفاصل (هذه المرحلة موضحة في المربع "HandLandmark").

بعد أن يتم تحديد النقاط، تُرسم هذه النقاط على اليد وتُعرض على الشاشة (كما في الجزء السفلي الأيمن من المخطط في AnnotationRenderer ثم Display).

الفصل الثالث: تقدير الوضعيات

الخطوط الزرقاء في المخطط تمثل كيف يستخدم النظام معلومات من الصورة السابقة ليساعد نفسه على تتبع اليد بشكل أفضل في الصورة التالية، مما يجعله أسرع وأكثر دقة مع مرور الوقت.

على الرغم من أن تقنية MediaPipe Hands تُعد من الأدوات الفعّالة في تتبع حركة اليد بدقة، إلا أن هناك بعض التحديات التي قد تؤثر على أدائها في بيئات معينة. من أبرز هذه التحديات هو فقدان القدرة على تتبع اليد عندما تختفي خلف جسم آخر، مثل الطاولة أو الرأس، مما يجعل النموذج غير قادر على مواصلة التعرف على موقع اليد أو حركتها. كما أن جودة الإضاءة تلعب دورًا كبيرًا في دقة التتبع؛ ففي حال كانت الإضاءة ضعيفة أو غير متوازنة، فإن النموذج قد يواجه صعوبة في التعرف على اليد بدقة. كذلك، إذا لم تكن اليد واضحة في مجال رؤية الكاميرا، مثل أن تكون خارج الإطار أو غير بارزة بوضوح، فقد يفشل النموذج في اكتشافها تمامًا، مما يؤثر على استمرارية التتبع.

3-2-3 تتبع الوجه باستخدام MediaPipe Face Mesh

تُعد تقنية تتبع الوجه باستخدام MediaPipe Face Mesh من أبرز الابتكارات في مجال رؤية الحاسوب (Computer Vision)، لما توفره من مستوى غير مسبوق من التفاصيل في تحليل ملامح الوجه البشري. تعتمد هذه التقنية على نموذج ذكي قادر على توليد شبكة ثلاثية الأبعاد دقيقة مكونة من 468 نقطة مرجعية (Landmarks) تغطي ملامح الوجه الرئيسية (الشكل 3-10)، بما في ذلك العينين، الأنف، الفم، الحاجبين، وال فك. هذه النقاط لا تُستخرج عشوائيًا، بل تتموضع بطريقة مدروسة تُمكن الخوارزمية من إعادة بناء تمثيل هندسي دقيق لبنية الوجه في الزمن الحقيقي، حتى أثناء الحركة أو التعبير [6].

إن وجود عدد كبير من النقاط الدقيقة يسمح بتحليل تعابير الوجه الدقيقة، مثل ابتسامة خفيفة، رفع الحاجب، أو حتى ارتعاش الجفن. كما يمكن من خلال هذا النموذج تتبع حركة العين وتغيير اتجاه النظر


بدقة عالية، وهو أمر يصعب تحقيقه باستخدام نماذج تقليدية تعتمد على عدد أقل من النقاط أو على تحليل ثنائي الأبعاد فقط. الجدير بالذكر أن هذه التقنية لا تقتصر على تتبع الملامح الثابتة فحسب، بل تتابع أيضًا التحولات الدقيقة والانفعالية في تعابير الوجه، مما يجعلها أداة قوية في مجالات مثل التفاعل الإنساني مع الآلة، الواقع المعزز، والواجهات الذكية التي تعتمد على فهم السلوك البشري [6].

ميزة MediaPipe Face Mesh لا تكمن فقط في قدرتها التحليلية، بل أيضًا في أدائها العملي؛ فهي خفيفة الوزن وفعالة بشكل يسمح بتشغيلها على الأجهزة المحمولة وضمن متصفحات الإنترنت دون الحاجة إلى عتاد متخصص أو وحدات معالجة رسومية متقدمة. كما أنها مبنية على تقنيات تعلم الآلة المتقدمة التي تتيح لها التكيف مع اختلافات الأوجه من حيث الشكل واللون والجنس والفئة العمرية، مما يعزز من شموليتها وعدالة استخدامها عبر مختلف البيئات والتطبيقات [6].


في تتبع الوجه باستخدام MediaPipe Face Mesh، تبدأ العملية من لحظة تشغيل الكاميرا، حيث يلتقط النظام صورة حية للوجه. بعد ذلك، يتم تحديد مكان الوجه داخل الصورة وقصّه ليُصبح بحجم مناسب للتحليل (كما يظهر في يسار الشكل 3-11). هذا يساعد النموذج على التركيز فقط على ملامح الوجه بدلاً من الصورة الكاملة [6].

بعد قص الوجه، تأتي مرحلة التحليل. هنا يدخل الوجه إلى "مستخرج الخصائص"، وهو جزء ذكي من البرنامج يعمل مثل العدسة المكبرة، لكن بدلاً من التكبير البصري، يقوم بتحليل التفاصيل الصغيرة جدًا في الوجه مثل شكل العين، القزحية (الجزء الملون من العين)، والفم. هذا التحليل لا يكون عشوائيًا، بل يتم على مراحل، بحيث يُعطى كل جزء من الوجه (مثل العين أو الشفاه) اهتمامًا خاصًا.

الفصل الثالث: تقدير الوضعيات



الشكل 6-3: النقاط الرئيسية للوجه.



الشكل 7-3: آلية عمل MediaPipe Face Mesh.

الشكل (3-11) يوضح كيف يتم هذا التحليل خطوة بخطوة:

- في البداية يتم مسح الوجه بالكامل.
 - ثم تُفحص مناطق مهمة مثل العينين والفم بمزيد من الدقة.
 - وأخيرًا، يُرسم "شبكة" دقيقة جدًا مكوّنة من مئات النقاط الصغيرة تغطي ملامح الوجه بالكامل.
- تخيّل أن وجهك يُغطى بشبكة شفافة مثل التي تُستخدم في الرسوم المتحركة ثلاثية الأبعاد - هذه الشبكة تتحرك مع وجهك وتتغير مع تعابيرك. فمثلاً، إذا رفعت حاجبيك أو ابتسمت، ستتحرك النقاط على هذه الشبكة لتعكس التغير [6].
- بهذه الطريقة، يمكن للنظام متابعة كل حركة صغيرة في الوجه، مثل فتح العين، تحريك البؤبؤ، أو حتى تغيير شكل الفم. وهذا التحليل مفيد جدًا في التطبيقات التي تحتاج إلى فهم تعابير الوجه أو تتبع سلوك المستخدم بدقة [6].

الفصل الرابع: التطبيق


العملي النهائي

1-4 توصيف العناصر الكهربائية المستخدمة

1-1-4 لوحة Arduino UNO

تُعد لوحة Arduino Uno من أشهر لوحات الدارات الكهربائية مفتوحة المصدر وأكثرها استخدامًا، وهي مصممة لجعل بناء المشاريع الإلكترونية سهلاً ومرناً [7].

تعتمد هذه اللوحة على المتحكم الدقيق ATmega328P، وتتميز بـ 14 منفذ إدخال/إخراج رقمي (منها 6 تدعم PWM) و 6 منافذ إدخال تناظرية، مما يتيح توصيل مجموعة واسعة من الحساسات والمحركات والمكونات الأخرى. يمكن برمجتها باستخدام بيئة التطوير Arduino IDE بلغة C/C++، وتوفر مكتبات جاهزة لتبسيط عملية البرمجة [7].



الشكل 4-1: لوحة Arduino UNO.

تعمل اللوحة بدورتين أساسيتين: دالة setup() التي تُنفذ مرة واحدة لتهيئة الإعدادات، ودالة loop() التي تُكرر باستمرار لمعالجة البيانات والتفاعل مع البيئة. تدعم Arduino Uno بروتوكولات اتصال تسلسلية

الفصل الرابع: التطبيق العملي النهائي

مثل UART و SPI و I2C، مما يوسع من إمكانيات ربطها بأجهزة أخرى. بفضل تصميمها مفتوح المصدر وسهولة استخدامها، تُعد Arduino Uno خيارًا مثاليًا للمبتدئين والمهندسين على حد سواء لتطوير مشاريع ذكية وتفاعلية [7].

2-1-4 محرك السيرفو

محرك السيرفو هو نوع من المحركات الكهربائية التي تتيح التحكم الدقيق في الموضع الزاوي أو الخطي والسرعة والتسارع. على عكس المحركات الكهربائية التقليدية التي تدور بحرية، يحتوي السيرفو على آلية تغذية راجعة (feedback mechanism) تسمح له بمعرفة موقعه الحالي باستمرار. تتكون هذه الآلية عادةً من مستشعر (مثل مقياس الجهد أو المشفر) يرسل معلومات الموضع إلى دائرة تحكم داخل المحرك. عندما تتلقى دائرة التحكم إشارة معينة (عادةً نبضة عرض متغيرة PWM)، تقوم بتحريك المحرك إلى الموضع المطلوب وتحافظ عليه بدقة، حتى في وجود قوى خارجية تحاول تغيير موقعه. هذا يجعله مثاليًا للتطبيقات التي تتطلب حركة دقيقة ومتكررة ومستقرة، مثل الروبوتات، والتحكم في الطائرات بدون طيار، وأنظمة الأتمتة الصناعية.



الشكل 2-4: محرك السيرفو.

3-1-4 منظم الجهد

منظم الجهد هو مكون إلكتروني أساسي يضمن إمدادًا كهربائيًا مستقرًا وثابتًا للأجهزة الإلكترونية. وظيفته الرئيسية هي الحفاظ على جهد الخرج عند قيمة محددة، بغض النظر عن التقلبات في جهد الدخل (سواء كان أعلى أو أقل) أو التغيرات في الحمل (كمية التيار المسحوب من الدائرة). هذا الاستقرار أمر حيوي لحماية المكونات الحساسة من التلف، وضمان الأداء الأمثل والموثوق للأنظمة الإلكترونية. يُعد منظم الجهد بمثابة صمام أمان كهربائي، حيث يمتص الجهد الزائد أو يرفعه ليضمن وصول الكمية الصحيحة من الطاقة للجهاز، مما يجعله عنصرًا لا غنى عنه في كل شيء بدءًا من الهواتف الذكية وحتى الأنظمة الصناعية المعقدة.

4-1-4 وحدة البلوتوث HC-05



الشكل 4-3: وحدة البلوتوث HC-05.

تُعد وحدة البلوتوث HC-05 قطعة إلكترونية شائعة للاتصال اللاسلكي قصير المدى (10-100 متر) ضمن نطاق تردد 2.4-2.485 جيجاهرتز، تعمل بتقنية بلوتوث V2.0 وتصل سرعة نقل البيانات فيها إلى 3Mbps. تستخدم واجهة UART للتواصل مع المتحكمات الدقيقة مثل الأردوينو، بجهد تشغيلي يتراوح

الفصل الرابع: التطبيق العملي النهائي


بين 3.3-5V، وتتميز باستهلاك منخفض للطاقة. أما الهوائي المستخدم فيها فهو هوائي مدمج على اللوحة (On-board antenna)، عادة ما يكون من نوع هوائي سيراميكي (Ceramic antenna) أو هوائي PCB (Printed Circuit Board antenna)، ويُصمم هذا الهوائي ليعمل بفعالية ضمن نطاق ترددات البلوتوث المذكور لضمان اتصال لاسلكي مستقر.

2-4 المخطط الصندوقي لتكامل المكونات

المخطط في الشكل (3-4) يوضح نظام تحكم بـ 6 محركات سيرفو (SERVO1 إلى SERVO6) باستخدام لوحة Arduino UNO.

- 1. مصدر الطاقة (Power Supply):** هو النقطة التي يبدأ منها النظام بالحصول على الطاقة الكهربائية. قد يكون هذا المصدر بطارية، محول كهربائي، أو أي مصدر آخر يوفر جهدًا كهربائيًا.
- 2. منظم جهد DC-DC Step Down:** هذا المكون يأخذ الجهد من "مصدر الطاقة" ويقوم بتخفيضه (Step Down) إلى مستوى جهد مناسب ومستقر. هذا ضروري لأن مصدر الطاقة قد يوفر جهدًا أعلى مما تحتاجه لوحة الأردوينو أو المحركات، أو قد يكون غير مستقر.
- 3. Arduino UNO:** هذه هي وحدة التحكم الرئيسية في النظام. تستقبل الطاقة المنظمة من "منظم الجهد"، وتتم برمجتها للتحكم في محركات السيرفو الستة.
- 4. SERVO1 إلى SERVO6:** هذه هي محركات السيرفو التي تتلقى إشارات التحكم من لوحة الأردوينو. بناءً على هذه الإشارات، تقوم المحركات بالحركة إلى زوايا محددة، مما يسمح بتطبيقات تتطلب حركة دقيقة ومتحكم بها مثل الروبوتات أو الأذرع الآلية.

الفصل الرابع: التطبيق العملي النهائي



الشكل 4-4: تكامل مكونات النظام.

3-4 المخطط التدفقي

يوضح الشكل (3-4) عملية اكتشاف حركة اليد والتحكم بها في الوقت الفعلي. يبدأ النظام بتهيئة أدوات الكشف وفتح الكاميرا، ثم يدخل في حلقة تكرارية (While) لالتقاط كل إطار ومعالجته (تحويل الصورة إلى تنسيق RGB، تمريرها لخوارزمية الكشف، تحليل النقاط المستخرجة، واستخلاص مصفوفة اليد المفتوحة). يتم بعد ذلك إرسال هذه المصفوفة، التي تمثل حالة اليد المكتشفة، إلى لوحة Arduino لتنفيذ أوامر التحكم المطلوبة، وتستمر هذه الدورة حتى يتم الضغط على مفتاح 'Q' لإيقاف العملية.


الفصل الرابع: التطبيق العملي النهائي



الشكل 4-5: المخطط التدفقي.

4-4 تنفيذ المشروع النهائي

يوضح الشكل (4-5) الذراع الروبوتية المستخدمة في التجربة، حيث تتميز بتصميم يسمح بمحاكاة حركة أصابع اليد البشرية.




الشكل 4-6: الذراع الروبوتية.


تعتمد آلية التحكم على نظام رؤية حاسوبية يقوم بتحليل حركة يد المستخدم بشكل لحظي. فكما يوضح الشكل (4-6)، يتم التقاط صورة ليد المستخدم أثناء بسطها، حيث يقوم البرنامج بتحديد المفاصل الرئيسية للأصابع وتتبع حالتها (مبسوطة أو مقبوضة). تُترجم هذه البيانات إلى مصفوفة رقمية (على سبيل المثال: $[1, 1, 1, 1, 1]$ تشير إلى الأصابع الخمسة مبسوطة)، والتي تُستخدم بعد ذلك كإشارات تحكم للذراع الروبوتية. وعندما تقوم الطالبة بقبض يدها، كما هو موضح في الشكل (4-7)، تتغير حالة

الفصل الرابع: التطبيق العملي النهائي

الأصابع في المصفوفة (على سبيل المثال: [0,0,0,0,0] تشير إلى الأصابع الخمسة مقبوضة)، مما يؤدي إلى استجابة الذراع الروبوتية ومحاكاتها لحركة القبض. يُسلط هذا العرض الضوء على القدرة على الترجمة الفورية للحركة البشرية إلى استجابة روبوتية، مما يفتح آفاقًا واسعة لتطبيقات تتراوح من الأطراف الصناعية الذكية إلى أنظمة التحكم عن بعد في البيئات الخطرة.



الشكل 4-7: اليد مبسوطة.



الشكل 4-8: اليد مقبوضة.

5-4 النتائج

أظهرت النتائج المتحصلة من التنفيذ العملي للمشروع نجاحًا ملموسًا في تحقيق الأهداف المرجوة. تمكنت الذراع الروبوتية من محاكاة حركات اليد البشرية بدقة وفعالية، وذلك بالاعتماد على نظام التعرف على الإيماءات القائم على الرؤية الحاسوبية. وقد أثبت النظام قدرته على ترجمة حالات الأصابع البشرية (مبسوطة أو مقبوضة) إلى إشارات تحكم دقيقة، مما سمح للذراع الروبوتية بالاستجابة بشكل فوري وسلس. تجدر الإشارة إلى أن الاختبارات أظهرت أن الاتصال اللاسلكي كان أكثر كفاءة وموثوقية من الاتصال السلكي في التحكم بالذراع. يشير هذا الإنجاز إلى الإمكانيات الواعدة لمثل هذه الأنظمة في تطبيقات متنوعة، مثل الأجهزة المساعدة لذوي الاحتياجات الخاصة، أو في المجالات التي تتطلب التحكم الدقيق عن بعد.

الفصل الخامس: الخاتمة

والآفاق المستقبلية

الفصل الخامس: الخاتمة والتطورات المستقبلية

بعد رحلة بحث وتطوير مستفيضة، يمثل هذا المشروع في بناء وتجسيد كف روبوتية يتم التحكم بها عبر إيماءات اليد نقطة تحول محورية في دمج التفاعل البشري الطبيعي مع الأنظمة الروبوتية. لقد برهن هذا المسعى الأكاديمي على الجدوى الفنية لإنشاء واجهة تحكم بديهية تتجاوز القيود التقليدية للأجهزة الميكانيكية، وذلك من خلال تسخير قدرات معالجة الصور المتقدمة وتحويل الإيماءات المرئية إلى أوامر حركية دقيقة. إن تحقيق التوافق بين نظام اكتشاف اليد المرئي القائم على الخوارزميات الحاسوبية ولوحة Arduino Uno، التي تعمل كعقل إلكتروني قادر على تفسير هذه الأوامر وترجمتها إلى حركات ميكانيكية بواسطة محركات السيرفو، يعكس التكامل الناجح بين مجالات الرؤية الحاسوبية والتحكم الآلي. هذه الإنجازات لا تقتصر على مجرد إثبات المفهوم، بل تفتح آفاقاً واسعة لتطبيقات عملية متعددة، مما يعزز من إمكانية استخدام الأكف الروبوتية في بيئات تتطلب تفاعلاً مرناً وسهلاً مع المستخدمين، سواء في الصناعة، أو الطب، أو حتى في الحياة اليومية. لقد أثبتت التجربة قدرة المنظومة على الاستجابة الفورية للإيماءات، مما يؤكد على متانة التصميم وقابلية النظام للتوسع والتكيف مع مهام أكثر تعقيداً.

يحمل هذا المشروع في طياته إمكانات تطويرية هائلة يمكن أن تدفعه إلى مستويات غير مسبوقة من الكفاءة والذكاء. يمكن التفكير في تطوير الخوارزميات المستخدمة لاكتشاف اليد وتحليل إيماءاتها لتحقيق دقة وسرعة أكبر، وذلك عبر دمج تقنيات التعلم العميق والشبكات العصبية الاصطناعية، مما سيمكن النظام من فهم الإيماءات الأكثر تعقيداً ومرونة، وتقليل زمن الاستجابة إلى أدنى حد ممكن. إضافة إلى ذلك، يمكن تحسين قدرة الكف الروبوتية على التعامل مع الأوزان والأجسام المختلفة من خلال استبدال محركات السيرفو الحالية بمحركات أكثر قوة ودقة، مثل محركات السائر (stepper motors) أو محركات التيار المستمر المزودة بمشفرات (DC motors with encoders)، والتي توفر تحكماً أدق في عزم الدوران والموضع.

الفصل الخامس: الخاتمة والتطورات المستقبلية

علاوة على ذلك، يمثل توسيع نطاق المستشعرات المدمجة في النظام خطوة طبيعية نحو تحقيق فهم أعمق للبيئة المحيطة. يمكن دمج مستشعرات القوة واللمس في أطراف الكف الروبوتية لتمكينها من التفاعل مع الأجسام بذكاء، مما يسمح لها بالتعامل مع المواد الهشة أو أداء مهام تتطلب حساسية عالية. كما يمكن استكشاف إمكانيات إضافة مستشعرات العمق (مثل كاميرات Depth-sensing) لتحسين قدرة النظام على إدراك الأبعاد الثلاثية للمشهد، مما يسهل على الكف الروبوتية التكيف مع بيئات عمل غير منظمة وأداء مهام أكثر تعقيداً في الفضاء.

من منظور التفاعل البشري الآلي، يمكن استكشاف تطوير واجهة مستخدم أكثر غنى وتنوعاً. يمكن دمج نظام التغذية الراجعة اللمسية (haptic feedback) مع قفازات التحكم، مما يمنح المستخدم إحساساً بالمقاومة أو القوة التي تواجهها الكف الروبوتية، وبالتالي تعزيز التجربة التفاعلية وتوفير تحكم أكثر واقعية وبديهية. كذلك، يمكن التفكير في تطوير نظام التعلم من خلال الملاحظة، حيث يتمكن الروبوت من محاكاة الحركات البشرية وتعلم مهام جديدة بمجرد مراقبة تنفيذها، مما يقلل من الحاجة إلى البرمجة اليدوية لكل مهمة.

كما يمكن دمج الكف الروبوتية ضمن منظومة أكبر من الروبوتات أو الأنظمة الذكية المتصلة بالإنترنت الأشياء (IoT)، مما يتيح للكف الروبوتية التنسيق مع أجهزة أخرى وتبادل المعلومات لتحقيق أهداف مشتركة. على صعيد التطويرات المستقبلية، يمكن العمل على تطوير الكف الروبوتية لتصبح ذراعاً روبوتية كاملة، بالإضافة إلى استكشاف استخدام تقنية GSM للاتصال اللاسلكي لتحسين المدى والموثوقية بدلاً من الاعتماد على تقنية HC-05 الحالية.

الفصل الخامس: الخاتمة والتطورات المستقبلية

أخيراً، يمكن التفكير في تحسين الجانب البرمجي من خلال تطوير إطار عمل (framework) أكثر عمومية ومرنة يسمح بتعديل وتكييف النظام بسهولة ليتناسب مع مهام جديدة أو أنواع مختلفة من الأكف الروبوتية. هذا الإطار يمكن أن يشمل مكتبات متقدمة للتحكم بالحركة وتخطيط المسارات (path planning)، بالإضافة إلى أدوات محاكاة (simulation tools) تسمح باختبار وتطوير الخوارزميات في بيئة افتراضية قبل تطبيقها على الكف الروبوتية الفيزيائية. إن هذه الخطوات التطويرية مجتمعة ستعزز من قدرة هذا المشروع على الانتقال من حيز البحث الأكاديمي إلى واقع تطبيقي واسع النطاق، مما يسهم بشكل فعال في تقدم مجال الروبوتات التفاعلية ويسهم في بناء مستقبل تكون فيه الآلات قادرة على التعاون والتفاعل مع البشر بسلاسة وكفاءة.

المراجع

- [1] Sumithra, G., Kousalya, S., Chandrahaas, R., Rao, E. S., Nikitha, G., Reddy, C. V. K., Rathod, K. M., Kumar, N. S., & Reddy, K. R. N. (2022, August 16–18). 5 DOF wireless hand motion controlled robotic arm. In Proceedings of the 2nd Indian International Conference on Industrial Engineering and Operations Management (Warangal, Telangana, India). IEOM Society International.
- [2] Úbeda, A., Zapata-Impata, B. S., Puente, S. T., Gil, P., Candelas, F., & Torres, F. (2018). A vision-driven collaborative robotic grasping system tele-operated by surface electromyography. *Sensors*, 18(7), 2358.
- [3] الجزيرة نت. (2024, ديسمبر 25). علماء يبتكرون ذراعا روبوتية ناعمة. الجزيرة نت. <https://www.aljazeera.net/tech/2024/12/25/علماء-يبتكرون-ذراعا-روبوتية-ناعمة/>
- [4] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [5] GeeksforGeeks. (n.d.). How does YOLO work for object detection? GeeksforGeeks. Retrieved May 12, 2025, from <https://www.geeksforgeeks.org/computer-vision/how-does-yolo-work-for-object-detection/>
- [6] Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2019). OpenPose: Realtime multi-person 2D pose estimation using part affinity fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(1), 172–186.
- [7] Arduino. (n.d.). Uno Rev3. Retrieved from <https://docs.arduino.cc/hardware/uno-rev3>