



الجمهورية العربية السورية

وزارة التعليم العالي والبحث العلمي

الجامعة الوطنية الخاصة

كلية الهندسة

قسم هندسة الاتصالات

نظام مراقبة وحماية أمني ذكي باستخدام تقنيات الذكاء الاصطناعي

Intelligent Security and Surveillance System Using Artificial Intelligence Technologies

مشروع تخرج أعد لنيل درجة الإجازة في هندسة الاتصالات

إعداد الطالبين:

محمد علي خالد البارودي

محمود عبد الكريم الرستم

إشراف:

د.م. وضاح ملوك

2025-2024

الملخص

يمثل هذا المشروع نظامًا آمنًا ذكيًا لتعزيز حماية محلات الذهب، حيث يعتمد على التكامل بين تقنيات الذكاء الاصطناعي والرؤية الحاسوبية والاستشعار الفيزيائي. يستخدم النظام خوارزمية YOLO لاكتشاف الأسلحة تلقائيًا، إلى جانب خوارزمية RNN لتحليل تسلسل الحركات واكتشاف أنماط العنف داخل الفيديوهات. كما تم توظيف مكتبة Mediapipe لتحليل وضعيات الجسم والتعرف على سلوكيات مشبوهة، مثل محاولة الوصول غير المصرح به إلى أماكن التخزين الحساسة داخل المحل، كفتح الأدراج أو الاقتراب منها من قبل أشخاص غير مخولين. وفي هذا السياق، يعتمد النظام أيضًا على حساسات فيزيائية دقيقة، مثل حساس الحركة (PIR) لرصد أي تحركات غير طبيعية ضمن نطاق معين، وحساس اللهب (Flame Sensor) للكشف المبكر عن أي مؤشرات حريق، ما يضيف طبقة إضافية من الأمان والاستجابة السريعة. وعند اكتشاف سلوك اختلاسي بواسطة Mediapipe، يقوم النظام بإصدار إنذار فوري داخل المحل، بالإضافة إلى حفظ مقطع فيديو يوثق لحظة الحدث في مجلد خاص للرجوع إليه لاحقًا، كما يتم إرسال تنبيه تلقائي إلى صاحب المحل عبر تطبيق Telegram يتضمن وصف الحادثة ورابط الفيديو، لضمان التفاعل السريع حتى في حال عدم تواجده في المكان. تسهم هذه المنظومة في بناء بيئة أمنية لحظية وفعالة، بفضل الدمج العملي بين الذكاء الاصطناعي، الرؤية الحاسوبية، وإنترنت الأشياء، مع قابلية التوسع والدمج في أنظمة حماية أكبر مستقبلاً. أظهرت التجارب فعالية عالية في اكتشاف الأسلحة باستخدام YOLO، وكفاءة ملحوظة في التعرف على سلوكيات العنف عبر RNN، بينما أثبتت مكتبة Mediapipe دقتها في رصد الحركات غير الطبيعية، وأكدت الحساسات الفيزيائية فعاليتها في الكشف السريع عن الحركة والحرائق، مما يعزز موثوقية النظام في البيئات الواقعية.

كلمات مفتاحية

YOLO، RNN، Mediapipe، PIR، Flame Sensor، أمان المحلات، كشف الأسلحة، كشف العنف، سلوك اختلاسي، استشعار ذكي.

Abstract

This project represents an intelligent security system designed to enhance the protection of gold shops, relying on the integration of artificial intelligence, computer vision, and physical sensing technologies. The system utilizes the YOLO algorithm for automatic weapon detection, alongside an RNN-based model to analyze motion sequences and identify violent behavior within surveillance footage. Additionally, the MediaPipe library is employed to estimate human poses and detect suspicious behaviors, such as unauthorized attempts to access sensitive storage areas, including opening drawers or approaching them by unauthorized individuals. The system also incorporates precise physical sensors, such as the PIR motion sensor to detect unusual movement within a defined area, and a flame sensor for early fire detection, adding an extra layer of security and rapid response. Upon detecting suspicious activity through MediaPipe, the system triggers an immediate alarm within the shop, stores a video clip documenting the incident in a dedicated folder for later review, and automatically sends an alert to the shop owner via Telegram, including a description of the event and a link to the recorded footage, ensuring prompt response even when the owner is not on-site. This integrated framework contributes to creating a real-time and efficient security environment by combining AI, computer vision, and IoT technologies, with future scalability for broader security system integration. Experimental results demonstrated high accuracy in weapon detection using YOLO, notable efficiency in identifying violent actions via RNN, and reliable detection of abnormal movements through MediaPipe, while physical sensors proved effective in rapidly detecting motion and fire hazards, thus enhancing the system's reliability in real-world environments.

Keywords:

YOLO, RNN, Mediapipe, PIR, Flame Sensor, shop security, weapon detection, violence recognition, theft behavior, intelligent sensing.

المحتويات

1	الفصل الأول: المقدمة
6	2 الفصل الثاني: الدراسات السابقة والإطار النظري
7	1-2 العناصر الكهربائية وتوصيفها
7	1-1-2 متحكم NodeMCU
10	2-1-2 مستشعر الحركة (Motion Sensor)
20	3-1-2 مستشعر اللهب (Flame Sensor)
22	2-2 تطور الذكاء الاصطناعي
23	3-2 تعلم الآلة (Machine Learning)
24	1-3-2 آلية عمل تعلم الآلة
25	2-3-2 لماذا لا يكفي تعلم الآلة لمعالجة الصور المعقدة؟
27	4-2 التعلم العميق (Deep Learning)
28	1-4-2 الشبكات العصبية الاصطناعية (Neural Networks)
38	5-2 الدراسات السابقة
40	3 الفصل الثالث: التقنيات والخوارزميات المستخدمة
41	1-3 خوارزمية YOLO (You Only Look Once)
41	1-1-3 مقدمة عن YOLO
43	2-1-3 خطوات عمل YOLO
48	3-1-3 تقنية IoU
48	4-1-3 أدوات ومكتبات YOLO
50	2-3 الشبكة العصبية التكرارية (RNN)
50	1-2-3 تعريف الشبكة العصبية التكرارية (RNN)

50.....	2-2-3 كيفية عمل الشبكات العصبية التكرارية (RNN)
52.....	3-2-3 الدوال التنشيطية الشائعة
53.....	4-2-3 أنواع الشبكات العصبية التكرارية (RNNs)
56.....	5-2-3 قيود الشبكات العصبية التكرارية (RNNs)
56.....	3-3 تقدير الوضعيات باستخدام مكتبة Mediapipe
57.....	1-3-3 مكتبة MediaPipe
58.....	2-3-3 آلية عمل مكتبة MediaPipe في تقدير الوضعيات
60.....	3-3-3 تطبيقات MediaPipe
62.....	4 الفصل الرابع: التنفيذ العملي والآفاق المستقبلية
63.....	1-4 مقدمة الفصل
63.....	2-4 مخطط مكونات النظام
64.....	3-4 المخططات التدفقية
64.....	1-3-4 المخطط التدفقي لعملية كشف الأسلحة
65.....	2-3-4 المخطط التدفقي لعملية كشف العنف
66.....	3-3-4 المخطط التدفقي لعملية كشف الاختلاس والسرقة
67.....	4-4 التطبيق العملي النهائي
70.....	5-4 الخاتمة
70.....	6-4 الآفاق المستقبلية
71.....	5 المراجع

الأشكال

- الشكل 1-1: الأنظمة الأمنية التقليدية في المنشآت. 2.....
- الشكل 2-1: : شريحة NodeMCU. 7.....
- الشكل 2-2: مكونات شريحة NodeMCU. 8.....
- الشكل 2-3: مخطط الأقطاب. 9.....
- الشكل 2-4: الرسم التخطيطي للبنية الداخلية. 10.....
- الشكل 2-5: مكونات مستشعر PIR. 11.....
- الشكل 2-6: مخطط يوضح آلية عمل المستشعر البيروني كهربائي. 12.....
- الشكل 2-7: فرق الإشارة في حالة وجود جسم أمام المستشعر (a)، وعدم وجود جسم (b). 12.....
- الشكل 2-8: عدسة فريسل. 13.....
- الشكل 2-9: أقسام عدسة فريسل. 13.....
- الشكل 2-10: تحليل الحركة باستخدام استشعار متعدد المناطق والزوايا. 14.....
- الشكل 2-11: متحكم BISS0001 PIR. 15.....
- الشكل 2-12: منظم الجهد ودايود الحماية. 16.....
- الشكل 2-13: المقاومة المتغيرة لضبط الحساسية. 16.....
- الشكل 2-14: مقاومة متغيرة لضبط زمن التأخير. 17.....
- الشكل 2-15: اختيار وضع التفعيل. 18.....
- الشكل 2-16: وضع التفعيل الفردي. 18.....
- الشكل 2-17: وضع التفعيل المتعدد. 19.....
- الشكل 2-18: مخطط أقطاب المستشعر. 20.....
- الشكل 2-19: مستشعر اللهب. 20.....
- الشكل 2-20: أقطاب مستشعر اللهب. 21.....
- الشكل 2-21: مؤتمر Dartmouth. 23.....
- الشكل 2-22: خطوات عمل التعلم الآلي. 24.....
- الشكل 2-23: بكسلات الصورة. 26.....
- الشكل 2-24: طبقات الشبكات العصبية الاصطناعية. 29.....

الشكل 2-25: العصبونات (العقد).....	29
الشكل 2-26: هيكل الشبكات العصبية العميقة.....	31
الشكل 2-27: مراحل عمل الشبكة العصبية الترشيحية (CNNs).....	33
الشكل 2-28: الفرق بين أنواع الـ Padding الثلاث.....	34
الشكل 2-29: عملية الترشيح.....	35
الشكل 2-30: الهيكلية الهرمية لعمل المرشحات الإضافية.....	36
الشكل 2-31: الفرق بين الـ Max Pooling والـ Average Pooling.....	37
الشكل 3-1: سرعة خوارزمية YOLO مقارنة بخوارزميات التعرف على الكائنات الأخرى تطورًا.....	41
الشكل 3-2: مقارنة بين إصدارات YOLO المختلفة من حيث الدقة مقابل زمن التنفيذ.....	43
الشكل 3-3: خطوات عمل خوارزمية YOLO.....	43
الشكل 3-4: بنية شبكة CNN.....	45
الشكل 3-5: آلية عمل تقنية IoU.....	48
الشكل 3-6: مكتبة Ultralytics.....	49
الشكل 3-7: مكتبة OpenCV.....	49
الشكل 3-8: الشبكات العصبية الأمامية (التغذية الأمامية) VS الشبكات العصبية المتكررة.....	52
الشكل 3-9: الدوال التنشيطية الشائعة في الشبكة العصبية التكرارية.....	53
الشكل 3-10: أنواع مختلفة من الشبكات العصبية التكرارية (RNNs).....	54
الشكل 3-11: تقدير الوضعيات (Pose Estimation).....	57
الشكل 3-12: شعار مكتبة MediaPipe.....	58
الشكل 3-13: النقاط الأساسية للجسم.....	58
الشكل 3-14: النقاط الأساسية للوجه.....	59
الشكل 3-15: النقاط الأساسية لليدين.....	60
الشكل 4-1: مخطط تكامل مكونات النظام.....	63
الشكل 4-2: المخطط التدفقي لعملية كشف الأسلحة.....	64
الشكل 4-3: المخطط التدفقي لعملية كشف العنف.....	65
الشكل 4-4: المخطط التدفقي لعملية كشف السرقة.....	66

- الشكل 4-5: كشف حالة سرقة.....67
- الشكل 4-6: كشف سلاح.....68
- الشكل 4-7: كشف حالة عنف.....69
- الشكل 4-8: إرسال التنبيهات إلى Telegram.....69

الجدول


الجدول 2-1: تفصيل أقطاب NodeMCU.....	9
الجدول 2-2: توصيف أقطاب المستشعر.....	19
الجدول 2-3: توصيف الأقطاب.....	22
الجدول 3-1: الفرق بين شبكة CNN وشبكة RNN.....	51

جدول المصطلحات

الاختصار	المعنى بالإنجليزية	المعنى بالعربية
AI	Artificial Intelligence	الذكاء الاصطناعي
YOLO	You Only Look Once	أنت تنظر لمرة واحدة
RNN	Recurrent Neural Network	الشبكة العصبية التكرارية
PIR	Passive Infrared	حساس الحركة
ROI	Region of Interest	منطقة الاهتمام/ منطقة حساسة

الفصل الأول: المقدمة

تُعد محلات بيع الذهب من أكثر أنواع المنشآت التجارية التي تتعرض لمخاطر السرقة، وذلك بسبب ما تحتويه من معروضات عالية القيمة وسهلة التسييل، ما يجعلها هدفاً مباشراً في حالات الانفلات الأمني أو ضعف المراقبة. وتشير تقديرات منشورة إلى أن معدلات التعدي على محال المجوهرات تتجاوز 30٪ من إجمالي حوادث السطو على المتاجر في البيئات ذات الكثافة السكانية العالية، خاصةً عندما تكون هذه المحلات واقعة ضمن أسواق شعبية أو مناطق تجارية غير مراقبة بشكل كافٍ. وتكمن خطورة هذه المواقع في أنها غالباً ما تفتقر إلى أنظمة حماية متطورة، وتعتمد فقط على وسائل تقليدية مثل الكاميرات الساكنة أو أجهزة إنذار لا توفر تحليلاً ذكياً للحدث أو استجابة آنية. وفي الكثير من الحالات، لا يتم تنبيه صاحب المحل أو الجهات المختصة إلا بعد وقوع الحادثة، ما يضيع فرصة منع الجريمة أو الحد من آثارها [1].



الشكل 1-1: الأنظمة الأمنية التقليدية في المنشآت.

ضمن هذا السياق، بات من الضروري اعتماد أنظمة أمان أكثر تطوراً، قادرة على تقديم حماية لحظية قائمة على الذكاء، وليس فقط التسجيل. وقد شهدت السنوات القليلة الماضية تحولات كبيرة في مجال الأمن الوقائي بفضل دمج تقنيات الذكاء الاصطناعي مع إنترنت الأشياء، مما أوجد حلولاً قادرة على اكتشاف الأسلحة، تحليل أنماط العنف، والتعرف على سلوكيات مشبوهة مثل محاولات الاختلاس، وتحديد التهديدات قبل أن تتحول إلى اعتداء فعلي. تعتمد هذه الأنظمة على حساسات حركة وحرارة متصلة بكاميرات مراقبة ذكية، حيث يتم تحليل البيانات في وحدات معالجة طرفية قريبة أو حتى عبر الخدمات السحابية، ليتم بعدها إرسال تنبيهات فورية إلى

الأجهزة المحمولة أو غرف التحكم. وتسمح هذه البنية بتحقيق استجابة لا تتجاوز ثانية واحدة، وتقلل من الإنذارات الكاذبة بنسبة تصل إلى 25% مقارنة بالأنظمة التقليدية. وتُظهر هذه المنظومات قابلية عالية للتطبيق ضمن محال الذهب، إذ أنها لا تتطلب بنية تحتية معقدة، ويمكن تخصيصها بسهولة لتغطية زوايا محددة من المحل أو التفاعل مع أصوات أو أنماط حركة مريبة. وبذلك، لم تعد الحماية مقتصرة على الحواجز المادية أو المراقبة البشرية، بل أصبحت مدعومة بخوارزميات قادرة على التمييز بين السلوك الطبيعي والخطر، وإطلاق الإنذار في اللحظة الحرجة [2][3].

وبالنظر إلى هذا الواقع الأمني المتزايد تعقيداً، تبرز الحاجة الملحة إلى حلول عملية وفعالة تُعزز من قدرة أصحاب محلات الذهب على حماية ممتلكاتهم بشكل لحظي. فالمشروع المقترح لا يأتي بوصفه نظاماً تكنولوجياً محضاً، بل كضرورة واقعية تستجيب لحاجة واضحة في السوق؛ إذ أن التجار العاملين في هذا القطاع يواجهون تحديات يومية تتراوح بين محاولات التسلل الصامتة والاقترحات العنيفة، وكثيراً ما تكون استجاباتهم مقيدة بعدم وجود أدوات ذكية يمكنها كشف الخطر قبل وقوعه أو حتى أثناء حدوثه. من هنا، فإن توفير نظام قادر على رصد الحركات المريبة، اكتشاف وجود الأسلحة، والتعرف على سلوكيات مشبوهة مثل محاولات الاختلاس، والتنبيه بشكل فوري داخل المحل مع حفظ فيديو هات توثيقية للحوادث، وإرسال تنبيه تلقائي إلى صاحب المحل عبر تطبيق Telegram يتضمن وصف الحادثة ورابط الفيديو، يعني تقليص الخسائر المحتملة إلى حد كبير، سواء من حيث القيمة المالية أو التأثير النفسي والمعنوي على أصحاب المحلات والعاملين فيها.

يتميز النظام المقترح بكونه انتقالاً نوعياً من نموذج الحماية التقليدي إلى مفهوم "الوقاية الذكية"، إذ أن معظم الأنظمة الحالية تعتمد على كاميرات تسجل ما يجري دون تحليل، أو أجهزة إنذار صوتي تطلق إشارات عند حدوث خلل ميكانيكي أو محاولة فتح غير مصرح بها، دون أن تكون قادرة على تفسير طبيعة الخطر أو تصنيفه. أما هذا النظام، فيعتمد على تقنيات متقدمة مثل نماذج التعلم العميق للكشف عن الأسلحة، والتحليل الزمني لحركات الأشخاص لاكتشاف العنف، إضافةً إلى التعرف على وضعيات الجسم التي تشير إلى محاولات اختلاس، مما يتيح له التمييز بين نشاط بشري طبيعي وآخر يوحي بسلوك عدائي أو غير معتاد. كما أن وجود حساسات متصلة بوحدة معالجة مركزية يتيح ربط المعطيات من مصادر متعددة (حركة، لهب، صورة، وضعيات جسم) وتحليلها بشكل متكامل، ما يجعل الاستجابة أكثر دقة وسرعة. هذا الدمج بين الرؤية والتحليل والتفاعل اللحظي يمثل قيمة مضافة حقيقية لأي صاحب محل يبحث عن حلول أمنية فعالة، غير معقدة، وقابلة للتطبيق ضمن بيئات محدودة الموارد أو المساحة، مثل محلات الذهب. فالنظام لا يوفر الحماية فقط، بل يُشعر المستخدم بالسيطرة والجاهزية، ويعيد تعريف علاقة صاحب المنشأة بالتقنيات التي تحميه.

وانطلاقاً من هذه الحاجة الواقعية الملحة، فإن المشروع لا يكتفي بمجرد تقديم حل تقني لمشكلة قائمة، بل يسعى إلى تحقيق رؤية متكاملة تعيد صياغة مفهوم الحماية في محلات الذهب، عبر توظيف الذكاء الاصطناعي والاستشعار الذكي في بيئة أمنية ذات طابع خاص. ولتحقيق هذه الرؤية، تم تحديد مجموعة من الأهداف الواضحة التي تشكل الإطار العام لتوجه المشروع، إلى جانب أهداف تقنية دقيقة تحدد مسارات التنفيذ بشكل منهجي ومدرّوس.

الأهداف العامة للمشروع:

- تصميم نظام أمان ذكي متكامل يلائم طبيعة محلات الذهب وخصوصيتها من حيث القيمة والأمان.
- تقليل الخسائر الناتجة عن السرقات أو الحرائق من خلال الكشف المبكر والإنذار الفوري.
- تحسين كفاءة الاستجابة للحوادث الأمنية من خلال تقديم إنذارات مدعومة بمعلومات دقيقة ومرئية.
- تقديم حل منخفض التكلفة، سهل التثبيت، ويعتمد على تقنيات متاحة للطلاب وواقعية في التطبيق ضمن الأسواق المحلية.
- دعم مفهوم الأمان الاستباقي بدلاً من الاكتفاء بالتوثيق أو الاستجابة بعد حدوث التهديد.

الأهداف التقنية للمشروع:

- استخدام حساس حركة (PIR) لرصد أي دخول أو حركة غير طبيعية داخل أو حول المحل.
- استخدام حساس اللهب (Flame Sensor) للكشف المبكر عن بدايات الحريق وإطلاق إنذار فوري.
- توصيل المستشعرات بوحدة تحكم من نوع NodeMCU قادرة على الربط بالشبكة وتنفيذ التعليمات.
- تطوير نموذج يستخدم خوارزمية YOLO لتحديد وجود أسلحة في الصور أو الفيديوهات الملتقطة.
- استخدام شبكة عصبية تكرارية (RNN) لتحليل تسلسل الحركات داخل فيديو المراقبة واكتشاف أنماط العنف.
- توظيف مكتبة Mediapipe لتحليل وضعيات الجسم والتعرف على محاولات الاختلاس، مثل مد اليد إلى الأدراج من قبل غير المخولين.
- إصدار إنذار محلي داخل المحل عند رصد سلوك اختلاسي بواسطة Mediapipe، مع حفظ مقطع فيديو للحدث في مجلد خاص.

وفي سبيل تحقيق الأهداف المرجوة من هذا المشروع، تم اتباع منهجية عمل منظمة ومبنية على مراحل متسلسلة، تضمن الانتقال من الفكرة إلى النموذج التطبيقي بأسلوب علمي مدروس. بدأت الخطوة الأولى بتحليل المتطلبات، حيث جرى تحديد المشكلة الأمنية التي يعاني منها أصحاب محلات الذهب، وتحديد الاحتياجات التقنية والوظيفية للنظام المقترح، سواء من حيث العتاد المستخدم أو البرمجيات اللازمة. تلت ذلك مرحلة دراسة الخلفية النظرية، والتي شملت البحث في المفاهيم الأساسية المرتبطة بالاستشعار، والذكاء الاصطناعي، وتقنيات المراقبة الذكية، مع الاطلاع على أبرز الخوارزميات والأساليب الحديثة المعتمدة في أنظمة الأمان المتقدمة.

بعد بناء الأساس النظري، تم الانتقال إلى مرحلة التصميم العتادي، والتي جرى فيها تحديد مكونات النظام الفيزيائية وتوصيف العلاقة ما بينها، من خلال رسم دارات التوصيل والربط بين الحساسات، الكاميرا، ووحدة التحكم. تلا ذلك تنفيذ النظام فعلياً وربط مكوناته، بما يشمل تحميل البرمجيات المناسبة، وتدريب نماذج الذكاء الاصطناعي، وضبط الاتصالات الشبكية وإعداد النظام للاستجابة الفورية محلياً. وفي المرحلة الأخيرة، تم تقييم أداء النظام من خلال مجموعة من الاختبارات العملية، بهدف قياس دقة الاكتشاف، سرعة الاستجابة، واستقرار التنبيهات، مما أتاح استخلاص مؤشرات مهمة حول كفاءة النظام في بيئة مشابهة للواقع.

الفصل الثاني: الدراسات السابقة


والإطار النظري

1-2 العناصر الكهربائية وتوصيفها

1-1-2 NodeMCU متحكم

يُعد NodeMCU بيئة تطوير مفتوحة المصدر تشمل البرمجيات والعتاد، وقد تم تطويرها في الأصل للعمل مع شريحة Wi-Fi من نوع ESP8266، وتعتمد على لغة Lua في برمجتها. يتميز NodeMCU بكونه لوحة إلكترونية صغيرة الحجم، منخفضة التكلفة، وذات قدرة معالجة عالية، مما يجعله مناسبًا بشكل خاص لتطبيقات إنترنت الأشياء. وتكمن أهميته في دعمه الكامل لمنصتي Arduino IDE و Python، الأمر الذي يسرّع بشكل كبير من عملية النمذجة الأولية والتجريب البرمجي. وتُعد هذه المزايا مجتمعة السبب الرئيسي في انتشاره الواسع في سوق الإلكترونيات، حيث يُصنّف كأحد أكثر اللوحات استخدامًا في مشاريع إنترنت الأشياء الحديثة [4].

وقد مرّ NodeMCU بعدة إصدارات، حيث يُعرف الإصدار v0.9 بالجيل الأول، ويتميّز بعرضه الكبير الذي يجعله غير عملي على ألواح التجريب (breadboards). هذا العيب تم تجاوزه في الجيل الثاني v1.0 الذي جاء بتصميم أضيق وشريحة محسّنة من ESP-12 إلى ESP-12E. أما الجيل الثالث v3، والذي تنتجه شركة LoLin، فقد شهد تحسينات طفيفة عن سابقه، مثل منفذ USB أكثر متانة واستخدام شريحة CH340G بدلاً من Silabs CP2102، رغم أنه لا يزال أعرض من أن يكون مريحًا في الاستخدام مع ألواح التجريب. وبفضل قابليته للاتصال بالشبكة، فإن هذه اللوحة تُستخدم على نطاق واسع في تطبيقات مثل المنازل الذكية، وأنظمة التحكم الصناعية، والرعاية الصحية الذكية [4].



1-1-1-2 مواصفات ومميزات NodeMCU ESP8266

تحتوي لوحة NodeMCU ESP8266 على شريحة ESP8266 التي تنتجها شركة Espressif Systems، وتضم هذه الشريحة نواة Wi-Fi من نوع ESP8266EX بالإضافة إلى معالج من نوع Tensilica L106 بمعمارية 32-بت، مدمجين ضمن نفس الشريحة. تدعم اللوحة الاتصال اللاسلكي Wi-Fi بتردد 2.4 غيغاهرتز وفقاً لمعايير 802.11b/g/n، وتحتوي على هوائي مدمج يدعم بروتوكولات الحماية WPA و WPA2.



الشكل 2-2: مكونات شريحة NodeMCU.

تتضمن اللوحة 17 منفذ إدخال/إخراج عام (GPIO)، منها 11 منفذاً قابلاً للاستخدام، حيث تُستخدم المنافذ الأخرى للتواصل مع شريحة الذاكرة الداخلية. وتدعم بعض هذه المنافذ ميزات إضافية مثل توليد الإشارة بعرض نبضة (PWM)، ما يتيح استخدام اللوحة للتفاعل مع العالم الخارجي عبر الحساسات والمحركات والمكونات الأخرى. كما تتضمن اللوحة واجهات اتصال متعددة مثل UART و SPI و I2C و SDIO و I2S، بالإضافة إلى واجهة للتحكم عن بعد باستخدام الأشعة تحت الحمراء (IR) [4].


تعمل اللوحة ضمن جهد تشغيل يتراوح بين 2.5 و 3.6 فولت، وتستهلك في المتوسط تياراً قدره 80 ميلي أمبير، ويمكن تشغيلها في درجات حرارة تتراوح من 40 درجة مئوية تحت الصفر وحتى 125 درجة مئوية. تأتي الشريحة في حزمة من نوع QFN تحتوي على 32 دبوساً بأبعاد 5×5 ملم. وتدعم اللوحة تحديث البرمجيات إما من خلال واجهة UART أو عبر الشبكة (OTA)، كما توفر حزمة تطوير برمجية (SDK) لتطوير البرامج المخصصة وربطها بالخوادم السحابية [4].

2-1-1-2 مخطط أقطاب NodeMCU

تُظهر الشكل (3-2) التوزيع العام لأقطاب لوحة NodeMCU ESP8266، والتي تُستخدم للتوصيل مع الحساسات والمكونات المختلفة في التطبيقات الذكية. تتضمن اللوحة مجموعة من المنافذ الرقمية (GPIO) بالإضافة إلى منافذ مخصصة للتواصل التسلسلي مثل UART و I2C و SPI، كما تحتوي على منفذ لقراءة الإشارات التناظرية ومنفذ مخصص لإعادة ضبط اللوحة (Reset). يوضح الجدول (1-2) وظيفة كل مجموعة من هذه الأقطاب [4].


الجدول 2-1: تفصيل أقطاب NodeMCU.

نوع الاتصال	الأقطاب المستخدمة	الوظيفة
GPIO	D0 إلى D8	يمكن استخدامها كمنافذ إدخال/إخراج رقمية عامة
UART	GPIO3 (RX) ، GPIO1 (TX)	تُستخدم لإرسال واستقبال البيانات عبر واجهة UART
I2C	D2 (SDA) ، D1 (SCL)	تُستخدم للتواصل عبر بروتوكول I2C.
SPI	D7 (MOSI) ، D6 (MISO) ، D5 (SCLK) ، D8 (CS)	تُستخدم للتواصل عبر بروتوكول SPI
المنفذ التناظري	A0	المنفذ الوحيد القادر على قراءة الإشارات التناظرية
منفذ LED	GPIO2	متصل مباشرة بالضوء المنبع على اللوحة
إعادة الضبط	Reset	يمكن إعادة ضبط اللوحة عبر الزر أو جعل هذا الطرف في الحالة المنخفضة (LOW)
غير مخصصة للتوصيل الخارجي	GPIO6 إلى GPIO11	لا يمكن استخدامها لأنها متصلة داخليًا بشريحة الذاكرة في اللوحة



الشكل 2-3: مخطط الأقطاب.

الرسم التخطيطي للدائرة الأساسية لشريحة ESP8266EX موضح في الشكل (2-4)، حيث يُبين البنية الداخلية والمعمارية العامة التي تعتمد عليها هذه الشريحة في عملها [4].



الشكل 2-4: الرسم التخطيطي للبنية الداخلية.

2-1-2 مستشعر الحركة (Motion Sensor)

تُستخدم أجهزة الاستشعار بالأشعة تحت الحمراء السلبية (PIR) للكشف عن وجود حركة الأشخاص أو الحيوانات ضمن نطاقها. تُعد هذه التقنية أساسية في العديد من التطبيقات التلقائية، مثل الأبواب التي تفتح عند اقتراب المستخدمين أو الإضاءة التي تشتغل تلقائيًا عند المرور في الممرات ليلاً، دون الحاجة لتدخل يدوي.

يُعتبر حساس HC-SR501 من أكثر أجهزة الاستشعار PIR شيوعًا بين المهتمين بالتجارب والمشاريع الإلكترونية، وذلك لما يمتاز به من عدة خصائص عملية، منها: استهلاكه المنخفض للطاقة (أقل من 2 مللي أمبير)، تكلفته الاقتصادية التي عادةً لا تتجاوز خمس دولارات، قدرته على الكشف عن الحركة لمسافة تصل إلى 21 قدمًا، وسهولة ربطه بالمشاريع الإلكترونية [5].


1-2-1-2 آلية عمل مستشعر PIR

كل ما يحيط بنا—بما في ذلك أجسامنا—يصدر طاقة حرارية على شكل إشعاع في نطاق الأشعة تحت الحمراء. يحدث ذلك طالما كانت درجة حرارة الأجسام أعلى من الصفر المطلق (0 كلفن أو -273.15 درجة مئوية). كلما ارتفعت حرارة الجسم، زادت كمية الإشعاع التي يبعثها، وهو إشعاع غير مرئي للعين المجردة لأنه يقع خارج الطيف الضوئي المرئي للبشر [5].

تستطيع أجهزة استقبال الأشعة تحت الحمراء الأساسية رصد وجود هذا الإشعاع، ولكن الكشف عن الحركة يتطلب القدرة على ملاحظة التغيرات في شدة الإشعاع. وهذا ما يميز حساسات الأشعة تحت الحمراء السلبية (PIR)، إذ تم تصميمها خصيصاً لرصد التغيرات التي تحدث عندما تتحرك أجسام دافئة مثل الإنسان ضمن نطاق عملها [5].

يتألف حساس PIR من عنصرين رئيسيين:

- **المستشعر البيروني كهربائي:** وهو العنصر الأساسي في الجهاز، ويظهر على شكل قطعة معدنية دائرية تحتوي على بلورة مستطيلة في مركزها.
- **عدسة فريسنل:** عدسة خاصة تعمل على جمع وتركيز الإشارات تحت الحمراء باتجاه المستشعر البيروني كهربائي.




الشكل 5-2: مكونات مستشعر PIR.

المستشعر البيروني كهربائي


يحتوي المستشعر البيروني كهربائي على نافذة تحتوي على فتحتين مستطيلتين مصنوعة من مادة، غالباً ما تكون السيليكون مغطاة بطبقة خاصة، تسمح بمرور الإشعاع تحت الأحمر. خلف هذه النافذة توجد إلكترونتان مستقلتان للكشف عن الأشعة تحت الحمراء؛ حيث يُصدر أحدهما إشارة إيجابية بينما يصدر الآخر إشارة سالبة [5].

عندما لا يكون هناك أي جسم متحرك بالقرب من المستشعر، تقوم الجزئيتان برصد نفس كمية الإشعاع تحت الأحمر، مما يؤدي إلى تعادل الإشارتين وعدم توليد أي إشارة كهربائية. ولكن عند دخول جسم دافئ مثل

الإنسان إلى منطقة الكشف، تكتشف إحدى الجزئيتين تغيراً في شدة الإشعاع تحت الأحمر قبل الأخرى، مما يسبب فرقاً بين الإشارتين. هذا الاختلاف يتم تفسيره من قبل المستشعر على أنه وجود حركة [5].




الشكل 2-6: مخطط يوضح آلية عمل المستشعر البيروبي كهربائي.



الشكل 2-7: فرق الإشارة في حالة وجود جسم أمام المستشعر (a)، وعدم وجود جسم (b).

عدسة فريسنل

قد لا يبدو أن عدسة فريسنل تقوم بدور كبير، إلا أنها في الواقع تزيد بشكل ملحوظ من مدى ونطاق رؤية حساس الأشعة تحت الحمراء السلبية. تتكون عدسة فريسنل من مادة بلاستيكية محفورة عليها سلسلة من الأخاديد الدائرية المتحدة المركز. تعمل كل أخدود كسطح كاسر للضوء، حيث تقوم بتركيز أشعة الضوء الموازية على نقطة بؤرية، بطريقة مشابهة لعمل العدسات البصرية التقليدية، لكنها تتميز بتصميم أكثر نحافة [5].




الشكل 8-2: عدسة فريسنل.

لزيادة مدى الكشف ونطاق الرؤية، تُقسّم العدسة إلى عدة أقسام، بحيث يعمل كل قسم كعدسة فريسنل مستقلة بذاتها [5].



الشكل 9-2: أقسام عدسة فريسنل.

تُشكّل هذه الأقسام المتعددة مناطق كشف متداخلة، ولهذا السبب تبدو مراكز العدسات موجهة في اتجاهات مختلفة. حيث تقوم كل عدسة بتوجيه الإشعاع تحت الأحمر القادم من منطقة معينة إلى عنصر الاستشعار في الحساس، مما يتيح للجهاز تغطية مساحة أوسع بكثير [5].



الشكل 10-2: تحليل الحركة باستخدام استشعار متعدد المناطق والزوايا.


يمثل هذا التصميم الذكي السبب في قدرة حساسات PIR على اكتشاف الحركة عبر مساحة واسعة، على الرغم من صغر حجم عنصر الاستشعار الداخلي [5].

2-2-1-2 نظرة عامة على مكونات المستشعر

من أبرز مميزات حساس HC-SR501 للحركة (PIR) هو جاهزيته للاستخدام الفوري دون الحاجة لإعدادات معقدة. يكفي توصيله بمصدر طاقة يتراوح بين 5 إلى 12 فولت وربطه بالأرضي. عند اكتشاف الحركة، ينتقل الإشارة الخارجة إلى مستوى عالٍ (HIGH)، وفي حال عدم وجود حركة تبقى الإشارة منخفضة (LOW).
تتيح هذه البساطة في الأداء استخدام الحساس لتنفيذ العديد من الوظائف المتنوعة ضمن المشاريع، مثل تشغيل أو إطفاء الإضاءة، تنشيط مروحة، تفعيل ديكور خاص بالمناسبات، أو حتى التقاط صورة لزائر غير متوقع.
كما يتميز هذا الحساس باستهلاكه المنخفض للطاقة، حيث لا يتجاوز التيار المقدر 2 مللي أمبير، بالإضافة إلى قدرته على الكشف عن الحركة على مسافة تصل إلى 7 أمتار تقريباً (حوالي 21 قدماً).

BISS0001 PIR Controller

يحتوي الحساس على شريحة مخصصة تعرف بـ BISS0001 PIR Controller، والتي تقوم بمعالجة الإشارات الصادرة من المستشعر البيروني كهربائي (الجزء المسؤول عن اكتشاف الإشعاع تحت الأحمر المنبعث من الأجسام الدافئة) وتحويلها إلى إشارة رقمية [5].




الشكل 2-11: متحكم BISS0001 PIR.

تُعرف هذه الشريحة بقدرتها العالية على مقاومة التشويش، مما يجعلها من أكثر وحدات التحكم في حساسات PIR موثوقية وكفاءة [5].

Power


يتضمن الوحدة منظم جهد دقيق بقيمة 3.3 فولت مدمج، مما يسمح بتشغيلها باستخدام أي مصدر تيار مستمر يتراوح بين 4.5 و12 فولت. وغالبًا ما يتم استخدام جهد 5 فولت نظراً لشيوعه في مشاريع Arduino [5]. كما تحتوي الوحدة على دايود حماية (يُعرف أحيانًا بالدايود الوقائي) يحمي الحساس في حالة توصيل التيار بشكل عكسي. هذا يضمن عدم تلف الجهاز حتى في حال حدوث خطأ في التوصيل الكهربائي [5].



الشكل 12-2: منظم الجهد ودايود الحماية.

Sensitivity Adjustment

يوجد في الجزء الخلفي من حساس PIR مقوم متغير صغير يتيح ضبط درجة حساسية الحساس تجاه الحركة.




الشكل 13-2: المقاومة المتغيرة لضبط الحساسية.

من خلال تدوير هذا المقوم، يمكن التحكم في مدى اكتشاف الحساس للحركة. عند تدويره في اتجاه عقارب الساعة، تزداد الحساسية ويستطيع الحساس الكشف عن الحركة لمسافة تصل حتى حوالي 21 قدمًا. أما عند تدويره في الاتجاه المعاكس، تقل الحساسية ويقتصر الكشف على الحركة ضمن مسافة أقصر تصل إلى حوالي 9 أقدام [5].

يعتبر هذا الضبط مهمًا لتخصيص أداء الحساس بما يتناسب مع متطلبات المشروع، مثل تقليل الحساسية في حالة تركيب ضوء يعمل بالحركة في ممر ضيق، لتجنب تشغيله عند مرور أشخاص في غرف مجاورة [5].

Time-Delay Adjustment

يوجد في الجزء الخلفي من حساس PIR مقوم متغير آخر يتيح ضبط زمن التأخير.




الشكل 14-2: مقاومة متغيرة لضبط زمن التأخير.

يتحكم هذا الضبط في المدة التي يبقى خلالها خرج الحساس في الحالة العالية (أو "مشغل") بعد اكتشاف الحركة. يمكن تعيين زمن التأخير ليكون قصيرًا يصل إلى ثانية واحدة، أو طويلًا يصل إلى ثلاث دقائق. عند تدوير المقوم في اتجاه عقارب الساعة، يزداد زمن التأخير، وعند تدويره عكس عقارب الساعة، يقل الزمن [5].


Trigger Selection Jumper

يتمتع حساس PIR بخيارين مختلفين للاستجابة عند اكتشاف الحركة، وضع التفعيل الفردي ووضع التفعيل المتعدد، يحتوي الحساس على جمبر (أو أحيانًا جسر لحام) يتيح اختيار أحد هذين الوضعين [5].



الشكل 2-15: اختيار وضع التفعيل.


1. **L (وضع التفعيل الفردي):** عند اختيار هذا الوضع، يصبح خرج الحساس عاليًا (HIGH) بمجرد اكتشاف الحركة ويظل في هذه الحالة طوال المدة التي تم ضبطها بواسطة مقوم زمن التأخير. خلال هذه الفترة، يتجاهل الحساس أي حركة جديدة. يبدأ الحساس بالكشف عن الحركة مجددًا فقط بعد انتهاء زمن التأخير وعودة الخرج إلى الحالة المنخفضة (LOW). إذا استمرت الحركة بعد انتهاء فترة التأخير، سيعيد الحساس التفعيل مرة أخرى. وهذا يعني أن بعض الحركات قد تُهمل تمامًا إذا وقعت أثناء فترة التأخير. كما هو موضح في الشكل (2-16)، فإن الحركة رقم 3 تُتجاهل بالكامل في هذا الوضع [5].



الشكل 2-16: وضع التفعيل الفردي.

2. **H (وضع التفعيل المتعدد):** في هذا الوضع، يصبح خرج الحساس عاليًا (HIGH) عند اكتشاف الحركة ويظل كذلك خلال الفترة المحددة بواسطة مقوم زمن التأخير. على عكس وضع التفعيل الفردي، لا يتجاهل الحساس الحركات الجديدة، بل يقوم بإعادة ضبط المؤقت في كل مرة يكتشف فيها حركة جديدة. يعني ذلك أن الخرج يبقى في الحالة العالية طالما استمر وجود الحركة. عند توقف جميع الحركات، يعود الخرج إلى

الحالة المنخفضة (LOW) بعد انقضاء فترة التأخير. يُعد هذا الوضع مناسبًا للحفاظ على تشغيل الإضاءة في غرفة طالما هناك حركة مستمرة [5].



الشكل 2-17: وضع التفعيل المتعدد.

3-2-1-2 أقطاب المستشعر


يحتوي مستشعر HC-SR501 للحركة على موصل بسيط بثلاثة أطراف يجب توصيلها ضمن المشاريع. ونظرًا لأن تسميات هذه الأطراف غالبًا ما تكون مخفية تحت عدسة فريسنل، فقد يكون من الصعب التعرف على وظيفة كل طرف بدون الرجوع إلى مخطط توضيحي [5].

فيما يلي جدول يشرح وظيفة أطراف المستشعر:

الجدول 2-2: توصيف أقطاب المستشعر.

الوصف	الوظيفة	الطرف
يُوصل بمصدر طاقة يتراوح من 5 إلى 12 فولت، وغالبًا ما يُستخدم 5 فولت نظرًا لشيوعه في وحدات Arduino أو متحكمات مشابهة.	مدخل الطاقة	VCC
خرج منطق TTL بقيمة 3.3 فولت، يصبح عاليًا (3.3 فولت) عند اكتشاف الحركة، ويبقى منخفضًا (0 فولت) في حالة عدم وجود حركة.	خرج الإشارة الرقمية	OUTPUT
الطرف المخصص للوصل بالأرضي (المرجع الكهربائي).	الأرضي	GND


الشكل (2-18) يوضح مخطط الأقطاب لمستشعر الحركة.



الشكل 2-18: مخطط اقطاب المستشعر.

3-1-2 مستشعر اللهب (Flame Sensor)

مستشعر اللهب هو جهاز يُستخدم لاكتشاف وجود النار أو اللهب، ويعتمد في عمله بشكل أساسي على استشعار الأشعة تحت الحمراء الصادرة عن مصادر اللهب. ويُستخدم هذا النوع من المستشعرات على نطاق واسع ضمن أنظمة الكشف عن الحرائق في البيئات المنزلية والصناعية [6].



الشكل 2-19: مستشعر اللهب.

1-3-1-2 مبدأ العمل

يعتمد حساس اللهب في عمله على مبدأ استشعار الأشعة تحت الحمراء، حيث يحتوي على مستقبل لهذه الأشعة يلتقط الإشعاع الصادر عن اللهب. عند احتراق المواد، تنتج كمية من الضوء في نطاق الأشعة تحت الحمراء، ويقوم الثنائي الضوئي (مستقبل الأشعة تحت الحمراء) في وحدة الحساس باستقبال هذا الضوء. بعد ذلك، يُستخدم مضخم عمليات لمراقبة تغير الجهد عبر المستقبل، بحيث يُنتج الطرف الرقمي (DO) جهداً منخفضاً (0 فولت) عند اكتشاف اللهب، ويبقى الجهد مرتفعاً (5 فولت) في حال عدم وجوده [6].

2-3-1-2 المميزات

- مدمج بمقاوم متغير (Potentiometer) لضبط الحساسية.
- يحتوي على مؤشر ضوئي لإشارة الخرج؛ حيث تكون الإشارة الفعالة مرتفعة، ويتزامن ذلك مع إضاءة المؤشر، ويمكن توصيل إشارة الخرج مباشرة بمنفذ الإدخال/الإخراج (IO) في المتحكم الدقيق.
- قادر على كشف اللهب أو الأطوال الموجية للضوء ضمن النطاق 760 ~ 1100 نانومتر.
- زاوية الكشف تبلغ حوالي 60 درجة، مع حساسية عالية لطيف اللهب.
- يتميز بحساسية عالية تجاه لهب النار مقارنة بالمصادر الضوئية الثابتة، ويُستخدم غالباً في تطبيقات إنذار الحريق [7].

3-3-1-2 أقطاب المستشعر

يبين الجدول (3-2) والشكل (20-2) أقطاب مستشعر اللهب وتوصيفها [7].



الشكل 20-2: أقطاب مستشعر اللهب.

الجدول 2-3: توصيف الأقطاب.

الوصف	القطب
تغذية 5V	VCC
الأرضي	GND
خرج رقمي (0 أو 1)	OUT

4-3-1-2 التطبيقات

- **أنظمة الكشف عن الحرائق:** يُستخدم حساس اللهب بالأشعة تحت الحمراء بشكل شائع في أنظمة الكشف عن الحرائق، حيث يتيح استشعار الإشعاع تحت الحمراء الصادر عن اللهب إمكانية الاكتشاف المبكر والتنبيه في حال حدوث حريق [7].
- **السلامة الصناعية:** يُوظف هذا الحساس في البيئات الصناعية لأغراض السلامة، إذ يمكنه كشف وجود اللهب أو مصادر الخطر النارية في المناطق التي تحتوي على مواد قابلة للاشتعال، مما يساعد على الاستجابة السريعة واتخاذ الإجراءات الوقائية [7].
- **كشف تسرب الغاز:** يمكن استخدام حساس اللهب بالأشعة تحت الحمراء ضمن أنظمة الكشف عن تسرب الغاز، حيث يتيح رصد اللهب الناتج عن تسربات الغاز، مما يوفر طبقة إضافية من الأمان من خلال التنبيه إلى حالات قد تشكل خطورة محتملة [7].

2-2 تطور الذكاء الاصطناعي

الذكاء الاصطناعي (Artificial Intelligence) هو مجال علمي يهدف إلى تصميم أنظمة قادرة على أداء مهام تتطلب عادةً ذكاءً بشرياً، مثل التعلم، التفكير، الفهم، واتخاذ القرارات. يتضمن هذا المجال تطوير خوارزميات ونماذج تمكن الحواسيب من معالجة المعلومات بطرق تشبه التفكير البشري، مما يسمح لها بالتكيف مع البيانات المتغيرة وحل المشكلات المعقدة [8].

بدأت رحلة الذكاء الاصطناعي في منتصف القرن العشرين، حيث شهدت تطورات ملحوظة عبر العقود. في الأربعينيات والخمسينيات، ظهرت مفاهيم أولية مثل "Cybernetics" التي ركزت على التحكم والتواصل في الأنظمة الحية والآلية. ثم في عام 1956، تم تنظيم مؤتمر "Dartmouth" الذي يُعتبر نقطة الانطلاق الرسمية لمجال الذكاء الاصطناعي، حيث اجتمع باحثون لمناقشة إمكانية بناء آلات قادرة على محاكاة الذكاء البشري.



الشكل 2-21: مؤتمر Dartmouth.

خلال العقود التالية، شهد الذكاء الاصطناعي فترات من التقدم والتراجع، تُعرف بـ "صيف الذكاء الاصطناعي" و"شتاء الذكاء الاصطناعي". في الستينيات والسبعينيات، تم تطوير برامج قادرة على حل مشكلات رياضية ولعب الشطرنج، مما أثار اهتمامًا واسعًا. ومع ذلك، واجه المجال تحديات كبيرة بسبب محدودية القدرة الحاسوبية ونقص البيانات، مما أدى إلى تراجع الاهتمام في بعض الفترات [8].

في الثمانينيات، عاد الاهتمام بالذكاء الاصطناعي مع ظهور "Connectionism"، التي ركزت على بناء نماذج تحاكي الشبكات العصبية في الدماغ البشري. ومع تقدم التكنولوجيا وزيادة القدرة الحاسوبية، شهد المجال نهضة جديدة في العقد الأول من القرن الحادي والعشرين، خاصةً مع تطوير خوارزميات التعلم العميق التي مكنت الحواسيب من معالجة كميات هائلة من البيانات وتحسين أدائها في مهام معقدة مثل التعرف على الصور والكلام [8].

اليوم، يُعتبر الذكاء الاصطناعي جزءًا لا يتجزأ من العديد من التطبيقات اليومية، بدءًا من المساعدات الصوتية إلى أنظمة التوصية وتحليل البيانات الضخمة. ومع استمرار البحث والتطوير، يُتوقع أن يلعب الذكاء الاصطناعي دورًا متزايد الأهمية في تشكيل مستقبل التكنولوجيا والمجتمع [8].


3-2 تعلم الآلة (Machine Learning)

يشكل تعلم الآلة نقطة تحول جوهريّة في تطور مجال الذكاء الاصطناعي. على عكس الأساليب السابقة التي كانت تعتمد على برمجة صريحة لكل حالة محتملة، أدخل تعلم الآلة القدرة على تحسين أداء الأنظمة بشكل ذاتي من خلال التعلم من البيانات. هذا التحول المفاهيمي مكّن الآلات من التعرف على الأنماط واتخاذ القرارات

مع الحد الأدنى من التدخل البشري. من خلال اعتماد خوارزميات قادرة على التعميم بناءً على الأمثلة، تجاوز تعلم الآلة قيود البرمجة المعتمدة على القواعد وفتح آفاقاً جديدة للمرونة وقابلية التوسع في بيئات معقدة. يركز هذا المفهوم على فرضية أن النظام يمكنه تحسين فهمه ودقته بشكل تدريجي عن طريق التعلم من التجارب، مشابهاً للعمليات الإدراكية التي نلاحظ في الذكاء الطبيعي. وقد مهد هذا الإنجاز الطريق أمام تطورات تقنية قادرة على معالجة مشكلات كانت في السابق تعتبر معقدة للغاية بالنسبة للحلول الحاسوبية، مما أعاد تشكيل مسار أبحاث الأنظمة الذكية [8].

2-3-1 آلية عمل تعلم الآلة

يُعد فهم آلية عمل تعلم الآلة من الركائز الجوهرية التي توضح كيف استطاع هذا المجال إحداث نقلة نوعية في الذكاء الاصطناعي. فعلى عكس البرمجة التقليدية التي تتطلب من المبرمج كتابة قواعد محددة لمعالجة المدخلات، فإن تعلم الآلة يمكن النظام من استخلاص الأنماط والعلاقات بنفسه من خلال تحليل كميات هائلة من البيانات. تبدأ العملية بجمع بيانات تمثل المشكلة المراد حلها، وتكون هذه البيانات بمثابة المصدر الأساسي الذي يتعلم منه النموذج. على سبيل المثال، إذا كان الهدف هو التعرف على أنواع الفواكه في الصور، فإن النموذج يحتاج إلى آلاف الصور التي تحتوي على هذه الفواكه مصنفة مسبقاً [8].



الشكل 2-22: خطوات عمل التعلم الآلي.

بعد تجهيز البيانات، تأتي مرحلة المعالجة الأولية التي يتم فيها تنظيف البيانات وتنظيمها، ما يضمن خلوها من الأخطاء أو القيم الشاذة التي قد تؤثر سلباً على عملية التعلم. ثم تُستخدم هذه البيانات لتدريب النموذج. في هذه المرحلة، تُمرّر البيانات عبر نموذج يحتوي على مجموعة من المعاملات القابلة للتعديل تُعرف باسم "الأوزان"،

وهي التي تشكل جوهر عملية التعلم. يقوم النموذج في البداية بتوقعات غير دقيقة، ولكنه يُقارن هذه التوقعات بالقيم الحقيقية (المخرجات الصحيحة) ويحسب مقدار الخطأ [8].

بعد حساب الخطأ، يُعدل النموذج الأوزان داخله بطريقة تدريجية بهدف تقليل هذا الخطأ في التكرارات التالية، وهي عملية تُعرف بـ "التدريب". يتم تكرار هذه العملية آلاف المرات على دفعات من البيانات تُسمى "دفعات التدريب" حتى يتمكن النموذج من تقليل الخطأ بشكل كبير. يستخدم في هذا السياق خوارزميات تحسين خاصة مثل "الانحدار التدريجي" لتحديث الأوزان بطريقة تضمن تحسين الأداء دون الوقوع في فخ التعميم المفرط.

ما إن يكتمل التدريب، يصبح النموذج قادرًا على التعميم واتخاذ قرارات دقيقة عند تقديم بيانات جديدة لم يسبق له رؤيتها، وهي المرحلة التي يُطلق عليها "التوقع". في هذه المرحلة، يمكن للنموذج تطبيق ما تعلمه مسبقًا على بيانات حقيقية في العالم الخارجي، مثل التنبؤ بكمية السرعات الحرارية في صورة طعام أو توقع مستوى سكر الدم بناءً على مؤشرات فسيولوجية. إن هذه القدرة على التنبؤ انطلاقًا من أمثلة سابقة تجعل تعلم الآلة أداة قوية ذات تطبيقات واسعة في مختلف المجالات العلمية والتجارية والطبية [8].


اللافت في آلية عمل تعلم الآلة هو أنه لا يتبع منطقًا ثابتًا كالتعليمات البرمجية التقليدية، بل يعمل من خلال تحسين مستمر قائم على التجربة والخطأ، مما يجعل منه أداة تتطور بمرور الوقت كلما زادت كمية ونوعية البيانات التي يتعلم منها. كما أن تعلم الآلة لا يعتمد فقط على توفير البيانات، بل يتطلب أيضًا هندسة دقيقة لهذه البيانات وضبطًا دقيقًا للمعاملات والمعايير المرتبطة بالنموذج لتحقيق أفضل أداء ممكن [8].

إن تعلم الآلة يُشبه من بعض الزوايا آلية التعلم البشري، حيث يتعلم الإنسان من تكرار التجارب واكتساب الخبرات، ويُحسن قراراته مع مرور الوقت. كذلك تفعل النماذج الذكية، فهي تنطلق من مرحلة غير دقيقة، وتطور قدراتها شيئًا فشيئًا، حتى تتمكن من تقديم نتائج تتسم بالدقة والموثوقية. بهذه الطريقة، يغدو تعلم الآلة آلية ذكية تتفاعل مع الواقع وتتكيف معه بدلًا من أن تُلقن كيفية التعامل معه [8].

2-3-2 لماذا لا يكفي تعلم الآلة لمعالجة الصور المعقدة؟

على الرغم من الإمكانيات الكبيرة التي أتاحتها تعلم الآلة التقليدي في التعامل مع كم هائل من البيانات وتحقيق تقدم ملموس في العديد من التطبيقات، إلا أن هذا النوع من التعلم يواجه صعوبات جوهرية عندما يتعلق الأمر بمعالجة الصور المعقدة. يعود ذلك إلى عدة أسباب تقنية ومنهجية تجعل من تعلم الآلة بأساليبه التقليدية أداة غير كافية للتعامل مع الخصائص الفريدة والمتعددة الأبعاد للصور الرقمية [8].

الصور بطبيعتها تحتوي على قدر هائل من المعلومات المرئية المرتبطة بمستويات مختلفة من التفاصيل، حيث تتضمن كل صورة بيانات بصرية موزعة عبر مصفوفة من البكسلات (الشكل 2-23)، لكل منها قيم محددة تمثل درجات اللون أو شدة الإضاءة. وعندما تُستخدم الطرق التقليدية في تعلم الآلة، مثل خوارزميات الانحدار أو الأشجار العشوائية أو حتى أساليب التصنيف الكلاسيكية، فإن هذه النماذج تفترض غالباً أن السمات المدخلة إلى النموذج هي سمات ذات معنى محدد ومحدد سلفاً، أي أنها تتطلب "هندسة سمات" يدوية يقوم فيها البشر بتحديد الخصائص الأهم في الصور وتحويلها إلى بيانات قابلة للفهم من قبل الخوارزمية [8].



الشكل 2-23: بكسلات الصورة.

لكن هذه العملية اليدوية لهندسة السمات تشكل عائقاً كبيراً في معالجة الصور، لأن الصور عادة لا تحتوي على سمات واضحة المعالم يمكن استخلاصها بسهولة دون خسارة كمية هائلة من المعلومات الدقيقة. فعلى سبيل المثال، يكاد يكون من المستحيل برمجياً تحديد الفرق بين صورة قطة وصورة كلب باستخدام عدد قليل من الخصائص المحددة يدوياً، مثل الطول أو العرض أو عدد الألوان. إن التوزيع البصري في الصور أكثر تعقيداً من أن يُختزل في معايير بسيطة، ما يجعل النماذج التقليدية غير قادرة على تمثيل هذا التعقيد الداخلي بكفاءة [8].

أضف إلى ذلك أن تعلم الآلة التقليدي يعاني من محدودية في فهم السياق المكاني بين عناصر الصورة، أي أنه يتعامل مع كل بكسل أو مجموعة بكسلات بمعزل عن موقعها النسبي أو علاقتها ببقية العناصر البصرية. وهذا يمثل مشكلة كبيرة لأن إدراك شكل معين في صورة يعتمد على كيفية تنظيم البكسلات في نمط معين، وليس

فقط على وجودها. فمثلاً، وجه الإنسان ليس مجرد مجموعة من الخطوط، بل هو نمط معين من العلاقات المكانية بين العينين والأنف والفم. تعلم الآلة التقليدي لا يستطيع بسهولة تمثيل هذه العلاقات أو تفسيرها دون تدخل يدوي معقد ومكلف [8].

من جهة أخرى، فإن حجم البيانات المطلوب لتدريب النماذج التقليدية على الصور يكون هائلاً، لأنه كلما زادت التفاصيل البصرية في الصور، زادت الحاجة إلى إدخال هذه التفاصيل كنقاط بيانات بشكل صريح. هذا يؤدي إلى ما يُعرف بـ "لعنة الأبعاد"، حيث يصبح من الصعب جداً على النموذج أن يتعلم تمثيلاً دقيقاً دون أن يتعرض للإفراط في التخصيص (Overfitting) أو الانخفاض الحاد في الأداء. ويزيد هذا التحدي عندما يكون الهدف هو التعميم على صور لم تُشاهد من قبل النموذج أثناء التدريب، إذ يفشل تعلم الآلة التقليدي في النقاط الأنماط البصرية التي تتطلب مستوى عالٍ من التجريد [8].

وبالإضافة إلى ما سبق، فإن عمليات التدريب في تعلم الآلة التقليدي تصبح أكثر عرضة للأخطاء عندما تكون الصور متغيرة في الإضاءة أو الزاوية أو الأبعاد أو الخلفية. فأي تغيير بسيط في هذه العوامل قد يؤدي إلى تغيير جذري في كيفية تمثيل الصورة ضمن النموذج، مما يؤدي إلى نتائج خاطئة أو غير مستقرة. هذه الحساسية العالية للتغيرات الطفيفة تمثل أحد أبرز العوائق أمام تبني النماذج التقليدية في تطبيقات الرؤية الحاسوبية المعقدة. بناءً على ذلك، يمكن القول إن الفجوة بين قدرة تعلم الآلة التقليدي ومتطلبات فهم الصور المعقدة دفعت الباحثين إلى السعي نحو نماذج أكثر تطوراً، قادرة على استخراج السمات تلقائياً، وتمثيل العلاقات المكانية والبصرية بشكل أعمق، والتعامل بكفاءة مع التغيرات في البيئة البصرية. هذه الحاجة المنهجية أدت لاحقاً إلى نشوء أنماط جديدة من النماذج التي تمثل نقلة نوعية في الذكاء الاصطناعي [8].

4-2 التعلم العميق (Deep Learning)

يُعدّ التعلم العميق (Deep Learning) تطوراً نوعياً في مسار الذكاء الاصطناعي، حيث يمثل نقلة نوعية من الأساليب التقليدية إلى نماذج أكثر قدرة على فهم الأنماط المعقدة في البيانات. ففي حين كانت النماذج التقليدية تعتمد على تمثيلات يحددها الإنسان، جاء التعلم العميق ليتيح للأنظمة القدرة على استخراج التمثيلات المفيدة تلقائياً من البيانات الخام [8].

يتميز التعلم العميق بقدرته على بناء تمثيلات هرمية للبيانات، حيث تتعلم النماذج تمثيلات بسيطة في الطبقات الأولى، وتبني عليها تمثيلات أكثر تعقيداً في الطبقات اللاحقة. هذا التدرج في التمثيل يمكّن النماذج من فهم

البيانات بعمق، مما يتيح لها أداء مهام معقدة مثل التعرف على الصور، ومعالجة اللغة الطبيعية، وغيرها من التطبيقات التي كانت تتطلب تدخلاً بشرياً كبيراً في السابق [8].


الفرق الجوهرى بين التعلم العميق والتعلم الآلى التقليدي يكمن في طريقة تمثيل البيانات والتعلم منها. ففي التعلم الآلى التقليدي، يعتمد الأداء بشكل كبير على جودة التمثيلات التي يصممها الخبراء، مما يتطلب معرفة عميقة بالمجال وتفاصيل البيانات. أما في التعلم العميق، فإن النماذج تتعلم هذه التمثيلات تلقائياً من البيانات، مما يقلل الحاجة إلى التخصيص اليدوي ويزيد من قدرة النماذج على التعميم والتكيف مع مهام جديدة [8].

هذا التحول في طريقة التعلم والتمثيل يجعل التعلم العميق أداة قوية في معالجة البيانات المعقدة والمهام التي تتطلب فهماً عميقاً للأنماط والعلاقات داخل البيانات. ومع التقدم المستمر في هذا المجال، يتوقع أن يستمر التعلم العميق في دفع حدود ما يمكن تحقيقه في الذكاء الاصطناعي وتطبيقاته المتنوعة [8].

1-4-2 الشبكات العصبية الاصطناعية (Neural Networks)


تمثل الشبكات العصبية الاصطناعية نموذجاً رياضياً مستوحى من بنية الدماغ البشري وآلية معالجته للمعلومات. تقوم هذه الشبكات على فكرة أن المعالجة المعقدة للمعلومات يمكن تحقيقها عبر سلسلة من الوحدات البسيطة التي تتصل فيما بينها على شكل طبقات متعاقبة. تتكون هذه الشبكات من مجموعة من المكونات الأساسية التي تعمل بانسجام لتعلم الأنماط من البيانات وتوليد مخرجات دقيقة تمثل التوقع أو التصنيف المطلوب. هذه المكونات تمثل الركائز التي تقوم عليها البنية الحسابية لهذه النماذج، والتي مكّنت الذكاء الاصطناعي من أداء مهام كان يُعتقد سابقاً أنها تتطلب قدرات بشرية بحتة [8].

- الطبقات (Layers): تُقسم الشبكة العصبية عادةً إلى ثلاث أنواع رئيسية من الطبقات: طبقة الإدخال التي تستقبل البيانات الخام، وطبقات خفية تتوسط عملية المعالجة، وطبقة إخراج تعطي النتيجة النهائية. كل طبقة تحتوي على عدد من الوحدات المعالجة تُعرف بالعُقد.



الشكل 2-24: طبقات الشبكات العصبية الاصطناعية.

- العُقد (Neurons): كل عُقدة في الشبكة تمثل وحدة حسابية بسيطة تستقبل مجموعة من المدخلات، وتقوم بتطبيق عملية رياضية عليها، غالبًا ما تشمل جمعًا مرجحًا لتلك المدخلات، يتبعها تطبيق دالة تفعيل غير خطية، لإنتاج خرج يُرسل إلى العقد التالية في الشبكة.



الشكل 2-25: العصبونات (العقد).

- الأوزان (Weights): تُعد الأوزان القيم الرقمية المرتبطة بالروابط بين العقد المختلفة في الشبكة، وتمثل مدى أهمية كل مدخل بالنسبة إلى العقدة المستقبلية. تتغير هذه الأوزان أثناء عملية التدريب لتعكس فهم النموذج للأنماط في البيانات.
- الانحيازات (Biases): تُضاف الانحيازات إلى الناتج الخطي للعقدة قبل تطبيق دالة التفعيل، وهي عناصر تُستخدم لضبط مخرجات العقد وتمنح النموذج مرونة أكبر في التعلم، بحيث لا تكون المخرجات محكومة فقط بوزن المدخلات.

الطبقات الخفية، وهي المكونات التي تتوسط بين الإدخال والإخراج، تُعد المكان الذي تحدث فيه معظم المعالجة الفعلية. في كل طبقة خفية، يتم تحويل البيانات القادمة من الطبقة السابقة عبر العمليات المذكورة سابقًا، بحيث يصبح الخرج المولد بمثابة مدخل للطبقة التالية. كل طبقة من هذه الطبقات تتعلم تمثيلًا مجردًا أكثر تعقيدًا للبيانات الأصلية، مما يتيح للنموذج القدرة على تمثيل العلاقات غير الخطية والتفاعلات المعقدة بين المتغيرات.

تمر البيانات خلال الشبكة في البداية بمرحلة تُعرف بالانتشار الأمامي (Forward Propagation)، حيث تُنقل المدخلات من الطبقة الأولى حتى تصل إلى الطبقة الأخيرة، مرورًا بكل الطبقات الخفية. في كل مرحلة، يتم حساب ناتج العقد وفقًا للأوزان والانحيازات المطبقة، وتُطبق دوال التنفيع لتحويل القيم إلى شكل يسمح بفهم أكثر عمقًا للبيانات. النتيجة النهائية التي تنتج عن طبقة الإخراج يمكن أن تكون قيمة رقمية تمثل تقديرًا كميًا (في حالة التوقع) أو مجموعة احتمالات تمثل التصنيف إلى فئات معينة (في حالة التصنيف).


لكن دقة النموذج لا تتوقف على الانتشار الأمامي فحسب، بل تعتمد أيضًا على آلية تصحيح الأخطاء، والتي تتم من خلال عملية تُعرف بالانتشار العكسي (Backpropagation). في هذه المرحلة، يتم احتساب الخطأ بين ناتج النموذج والناتج الفعلي المرغوب فيه، ثم يُعاد هذا الخطأ إلى الخلف عبر الطبقات باستخدام قواعد اشتقاق رياضية، لتحديث الأوزان والانحيازات بطريقة تقلل من هذا الخطأ في المرات القادمة. يُستخدم في ذلك خوارزمية تُعرف باسم خوارزمية التدرج العكسي، وهي تقوم بضبط الأوزان تدريجيًا باستخدام الانحدار التدرجي (Gradient Descent) بهدف تحسين أداء النموذج مع مرور الوقت.

من خلال هذه البنية المتكاملة من الطبقات والعقد والأوزان والانحيازات، وبالاستفادة من آليتي الانتشار الأمامي والعكسي، تصبح الشبكات العصبية الاصطناعية قادرة على بناء فهم متدرج للبيانات، وتمييز الأنماط الدقيقة التي قد لا تكون مرئية بوضوح للعين البشرية أو قابلة للاكتشاف بالطرق التقليدية. وتُعد النتيجة النهائية التي تُستخلص من طبقة الإخراج تجسيدًا لتعلم الشبكة من البيانات، سواء كان ذلك في صورة تصنيف لفئة معينة، أو توقع لقيمة مستهدفة، مما يعكس مدى قوة هذه النماذج في دعم القرارات الآلية ضمن نطاقات متعددة من التطبيقات الواقعية [8].

1-1-4-2 الشبكات العصبية العميقة (Deep Neural Networks)

تمثل الشبكات العصبية العميقة (DNNs) نقلة نوعية في مجال تعلم الآلة، إذ تُبنى على فكرة توسيع عمق النموذج من خلال مضاعفة عدد الطبقات الداخلية، بحيث لا تقتصر الشبكة على طبقة واحدة أو طبقتين كما في الشبكات البسيطة، بل تتكون من تسلسل طويل من الطبقات التي تُعالج التمثيلات بالتدرج من مفاهيم سطحية

إلى مفاهيم عالية التجريد. هذه الطبقات العديدة تسمح للنموذج بإجراء عمليات تركيبية متسلسلة على البيانات، ما يجعله قادرًا على إدراك العلاقات المعقدة والأنماط المتداخلة في المجالات التطبيقية التي يصعب فيها تحديد السمات يدويًا [8].



الشكل 2-26: هيكل الشبكات العصبية العميقة.

في التطبيقات المعقدة التي تتطلب قدرة كبيرة على تمثيل التفاصيل الدقيقة في البيانات، تُستخدم الشبكات العصبية العميقة بسبب قدرتها على بناء بنى تمثيلية متعددة المستويات دون تدخل بشري مباشر في اختيار السمات. ومن أبرز المجالات التي تستفيد من هذا النوع من الشبكات: أنظمة الفهم اللغوي العميق، الترجمة الآلية دون اعتماد على قواعد لغوية صريحة، تحليل تسلسل الجينوم في التطبيقات الحيوية، والكشف التلقائي عن أنماط سلوك المستخدم في النظم الرقمية. وتبرز أهميتها أيضًا في تحليل بيانات الحساسات متعددة الأبعاد، مثل تلك المستخدمة في المركبات ذاتية القيادة أو الروبوتات المتقدمة، حيث يكون من الضروري التعامل مع تدفقات زمنية ومكانية كثيفة ومعقدة [8].

مع ذلك، لا يمكن الاعتماد على الشبكات العصبية العميقة التقليدية بمفردها لمعالجة الصور بكفاءة. فرغم أنها قادرة على تعلم الأنماط غير الخطية وتمثيل التفاعلات بين السمات المختلفة، إلا أن الصور تمتاز بطبيعة مكانية وبُنْيَة مترابطة لا تتناسب مع الأسلوب العام لتغذية البيانات في DNNs، حيث يتم غالبًا تسطيح الصور وتحويلها إلى متجهات أحادية البعد. هذا الإجراء يفصل البكسلات عن مواقعها النسبية ويؤدي إلى فقدان البنية الهندسية للصورة، وهو أمر بالغ الأهمية في إدراك الكائنات والتراكيب داخل الصور [8].

بالإضافة إلى ذلك، تتطلب معالجة الصور بواسطة الشبكات العميقة التقليدية حجمًا هائلًا من المعاملات، خاصة عندما تكون الصور عالية الدقة. إذ إن كل عقدة في طبقة ما ترتبط بجميع العقد في الطبقة السابقة، مما يؤدي إلى زيادة عدد الأوزان بشكل أسّي مع اتساع حجم الإدخال، وهذا يجعل النماذج أكثر عرضة لمشكلة الإفراط في التعلم، ويزيد من العبء الحسابي بشكل كبير [8].

علاوة على ذلك، تفتقر هذه الشبكات إلى القدرة على التعميم المكاني، أي أنها غير قادرة على اكتشاف أنماط متكررة في مواضع مختلفة من الصورة بنفس الكفاءة، ما يجعلها حساسة لمكان ظهور الكائن أو النمط داخل الصورة. كما أنها لا تستغل التكرار المحلي الموجود في الصور، أي أنها تعيد تعلم نفس الأنماط في مواضع مختلفة بدلاً من مشاركتها عبر المواقع، وهو ما يؤدي إلى هدر في كفاءة التمثيل والتدريب [8].

لذلك، وعلى الرغم من أن DNNs توفر قدرة عالية على التمثيل التعليمي المجرد، إلا أن هذه القدرة وحدها لا تكفي لمعالجة الصور بفعالية دون الاستعانة بهياكل أخرى متخصصة تتعامل مع البيانات الصورية بطريقة تتلاءم مع خصائصها المكانية. إن الاكتفاء بالشبكات العميقة العامة يعوق تحقيق الأداء الأمثل في المهام التي تعتمد على إدراك البنية الهندسية والمكانية، كما في حالات التعرف على الأنماط البصرية أو فهم المشاهد.

2-1-4-2 الشبكات العصبية الترشيحية (Convolutional Neural Networks)


• تعريف الشبكات العصبية الترشيحية

الشبكات العصبية الترشيحية، أو ما تُعرف اختصارًا بـ CNNs، هي نوع متخصص من الشبكات العصبية الاصطناعية صُممت لمعالجة البيانات ذات البنية الشبكية، مثل الصور أو الإشارات الثنائية الأبعاد. تعتمد فكرتها الأساسية على محاكاة آلية عمل النظام البصري في الكائنات الحية، حيث تستخدم طبقاتٍ متتالية من المرشحات (أو النواقل) لتحليل المدخلات عبر اكتشاف أنماط محددة، كحواف الأشكال أو التفاصيل النسيجية. تتميز هذه الشبكات بقدرتها على تعلم واستخراج السمات المهمة من البيانات تلقائيًا، دون الحاجة إلى برمجة صريحة لتحديد هذه السمات مسبقًا. تُنظَّم طبقاتها في هيكل هرمي، حيث تُعالج الطبقات الأولى تفاصيل بسيطة (مثل الخطوط)، بينما تتولى الطبقات الأعمق دمج هذه التفاصيل لتكوين تمثيلات معقدة للعناصر داخل البيانات. يعتمد أدائها على عملية الترشيح التي تُطبَّق عبر نوافذ صغيرة تتحرك على كامل المدخلات، مما يسمح بالتعرف على الأنماط بغض النظر عن موقعها أو اتجاهها. هذه الخصائص جعلت منها أداة فعالة في التعامل مع البيانات عالية الأبعاد، مع الحفاظ على كفاءة الحساب وخفض العبء التخزيني مقارنةً بالشبكات العصبية التقليدية [9].

• كيف تعمل الشبكات العصبية الترشيحية؟

تتميز الشبكات العصبية الترشيحية عن الشبكات العصبية الأخرى بأدائها الفائق في معالجة المدخلات من الصور أو الكلام أو الإشارات الصوتية. تحتوي على ثلاثة أنواع رئيسية من الطبقات، هي [3]:

- الطبقة الترشيحية
- طبقة التجميع
- الطبقة المتصلة بالكامل (FC)



الشكل 2-27: مراحل عمل الشبكة العصبية الترشيحية (CNNs).

الطبقة الترشيحية هي الطبقة الأولى في الشبكة الترشيحية. بينما يمكن أن تتبعها طبقات ترشيحية إضافية أو طبقات تجميع، تكون الطبقة المتصلة بالكامل هي الطبقة النهائية. مع كل طبقة، تزداد تعقيداً في الشبكة العصبية الترشيحية، حيث تحدد أجزاء أكبر من الصورة. تركز الطبقات المبكرة على ميزات بسيطة، مثل الألوان والحواف. ومع تقدم بيانات الصورة عبر طبقات الشبكة العصبية الترشيحية، تبدأ في التعرف على عناصر أو أشكال أكبر للعنصر حتى تتعرف أخيراً على الكائن المقصود [9].

1. الطبقة الترشيحية:


الطبقة الترشيحية هي الوحدة الأساسية في الشبكات العصبية الترشيحية (CNN)، حيث تحدث معظم العمليات الحسابية فيها. تتكون من ثلاثة عناصر رئيسية: المدخلات (مثل صورة ملونة ممثلة بمصفوفة ثلاثية الأبعاد

للطول والعرض والعمق، والذي يتوافق مع قيم الألوان (RGB)، والمرشح (أو كاشف الميزات)، وخريطة الميزات الناتجة [9].

المرشح عبارة عن مصفوفة ثنائية الأبعاد من الأوزان، تمثل جزءًا من الصورة. يتحرك هذا المرشح فوق مناطق متداخلة من الصورة (تسمى حقول الاستقبال)، ويُجري عملية ترشيح (التفاف) عن طريق حساب حاصل الضرب النقطي بين وحدات البكسل في المنطقة المحددة وقيم المرشح. بعد كل عملية، ينتقل المرشح بمقدار خطوة (stride) محددة، ويكرر العملية حتى يغطي كامل الصورة. الناتج النهائي لهذه العمليات المتكررة هو خريطة الميزات، التي تُظهر مدى تطابق أجزاء الصورة مع النمط الذي يبحث عنه المرشح.


تبقى أوزان المرشح ثابتة أثناء حركته، لكنها قد تُعدّل لاحقًا أثناء تدريب الشبكة عبر خوارزميات مثل الانتشار العكسي. هناك ثلاث معلمات اختيارية تُحدد قبل التدريب وتؤثر على حجم الخرج:

- Number of Filters: كل مرشح يُنتج خريطة ميزات منفصلة، مما يزيد عمق الخرج.
- Strid: المسافة التي يتحركها المرشح في كل مرة. كلما زادت الخطوة، قل حجم الخرج.
- a. Zero-Padding: يُستخدم عندما لا يتناسب حجم المرشح مع الصورة. أنواعه:
 - b. Valid Padding: لا يُضيف أصفارًا، وقد يُقلص حجم الخرج.
 - c. Same Padding: يُحافظ على حجم الخرج مساويًا لحجم المدخلات.
 - d. Full Padding: يُزيد حجم الخرج بإضافة أصفار حول حواف الصورة.



الشكل 2-28: الفرق بين أنواع الـ Padding الثلاث.


بعد كل عملية ترشيح، تُطبَّق دالة ReLU (وحدة الخطية المستقيمة) على خريطة الميزات لإضافة عدم الخطية إلى النموذج، مما يساعده على تعلم أنماط معقدة.



الشكل 2-29: عملية الترشيح.

2. طبقة ترشيحية إضافية:

كما ذكرنا سابقاً، يمكن أن تتبع طبقة ترشيحية أخرى الطبقة الترشيحية الأولى. عند حدوث ذلك، تصبح هيكليّة الشبكة العصبية الترشيحية (CNN) هرمية، حيث تتمكن الطبقات اللاحقة من "رؤية" البكسلات ضمن حقول الاستقبال في الطبقات السابقة. على سبيل المثال، لنفترض أننا نحاول تحديد ما إذا كانت صورة تحتوي على دراجة هوائية. يمكن اعتبار الدراجة مجموع أجزاء: هيكلها، المقود، العجلات، الدواسات، وهكذا. كل جزء من هذه الأجزاء يُشكّل نمطاً بسيطاً (منخفض المستوى) في الشبكة العصبية، بينما يُمثّل تجميع هذه الأجزاء معاً نمطاً معقداً (عالي المستوى)، مما يُنشئ تسلسلاً هرمياً للميزات داخل الشبكة. في النهاية، تُحوّل الطبقة الترشيحية الصورة إلى قيم رقمية، مما يسمح للشبكة العصبية بفهم واستخراج الأنماط ذات الصلة [9].




الشكل 2-30: الهرمية لعمل المرشحات الإضافية.

3. التجميع:

تُعرف طبقات التجميع (أو التصغير) بتقليل الأبعاد وعدد المعلومات في المدخلات. مشابهة للطبقة الترشيحية، حيث تمرر عملية التجميع مرشحًا (فلتر) على كامل الصورة المدخلة، لكن الاختلاف هو أن هذا المرشح لا يحتوي على أوزان. بدلاً من ذلك، يطبق المرشح دالة تجميع على القيم داخل المنطقة المحددة من الصورة، ويملاً المصفوفة الناتجة. هناك نوعان رئيسيان من التجميع [9]:

- التجميع الأقصى (Max pooling): عند تحرك المرشح فوق الصورة، يختار القيمة العظمى (الأكبر) ضمن المنطقة المحددة لإرسالها إلى المصفوفة الناتجة. تُستخدم هذه الطريقة بشكل أكثر شيوعاً.
- التجميع المتوسط (Average pooling): يحسب المرشح القيمة المتوسطة للبكسلات داخل المنطقة المحددة لإرسالها إلى المصفوفة الناتجة.

على الرغم من فقدان بعض المعلومات في طبقة التجميع، إلا أنها تساعد في تقليل التعقيد، وتحسين الكفاءة، وتقليل خطر الـ (overfitting).



الشكل 2-31: الفرق بين الـ Max Pooling والـ Average Pooling.

4. الطبقة المتصلة بالكامل:

اسم هذه الطبقة يصف وظيفتها بدقة. كما ذكر سابقاً، في الطبقات المتصلة جزئياً (مثل الترشيحية أو التجميع)، لا تتصل قيم البكسلات في الصورة المدخلة مباشرة بطبقة الإخراج. أما في الطبقة المتصلة بالكامل، فإن كل عقدة في طبقة الإخراج تتصل بشكل مباشر بكل العقدة في الطبقة السابقة [9].

تُنفَّذ هذه الطبقة مهمة تصنيف البيانات بناءً على الميزات التي تم استخراجها عبر الطبقات السابقة ومرشحاتها المختلفة. بينما تستخدم الطبقات الترشيحية والتجميع عادةً دالة التنشيط ReLU، فإن الطبقات المتصلة بالكامل تعتمد غالباً دالة التنشيط SoftMax لتصنيف المدخلات بشكل دقيق، مما يُنتج احتمالية (قيمة بين 0 و 1) لانتماء البيانات إلى فئة محددة [9].

• أنواع الشبكات العصبية الترشيحية:

وضع الباحثان كونيهيكو فوكوشما ويان لُكن الأسس البحثية للشبكات العصبية الترشيحية من خلال أعمالهما في عام 1980، وورقة بحثية مشهورة بعنوان "الانتشار العكسي مُطبق على تمييز الرموز البريدية المكتوبة بخط اليد" عام 1989. بشكل أكثر شهرةً، نجح يان لُكن في تطبيق الانتشار العكسي لتدريب الشبكات العصبية على التعرف على الأنماط في سلسلة من الرموز البريدية المكتوبة بخط اليد. استمر في أبحاثه مع فريقه خلال تسعينيات القرن الماضي، لتُتوج جهودهم بتطوير "LeNet-5"، الذي طبق المبادئ ذاتها على تمييز المستندات [9].

منذ ذلك الحين، ظهرت العديد من هياكل الشبكات العصبية الترشيحية المتنوعة مع ظهور مجموعات بيانات جديدة (مثل MNIST و CIFAR-10) ومسابقات مثل تحدي التعرف البصري واسع النطاق لـ ImageNet (ILSVRC). ومن أبرز هذه الهياكل:

- AlexNet
- VGGNet
- GoogLeNet
- ResNet
- ZFNet

5-2 الدراسات السابقة

في السنوات الأخيرة، تم إجراء العديد من الدراسات التي تركز على استخدام الشبكات العصبية المتكررة (RNN) في أنظمة مراقبة الفيديو للكشف عن الأنشطة غير الطبيعية. تُظهر هذه الدراسات فعالية RNN في تحسين دقة الكشف وتقليل الوقت اللازم للاستجابة [9].

أظهرت دراسة حديثة نُشرت في مجلة Applied Intelligence أن نموذجًا يعتمد على RNN حقق دقة تصل إلى 97.4% في الكشف عن الأنشطة غير الطبيعية في مقاطع الفيديو من مجموعة بيانات UCSD Ped2. تم استخدام بنية Autoencoder مع آلية انتباه متعددة القنوات لاستخراج الميزات المكانية والزمانية بشكل فعال [9].

في دراسة أخرى نُشرت في مجلة MDPI، تم دمج شبكة عصبية تلافيفية (CNN) مع RNN للكشف عن العنف في مقاطع الفيديو الملتقطة بواسطة كاميرات المراقبة. أظهرت النتائج أن النموذج المقترح حقق دقة

عالية في تصنيف الأنشطة إلى طبيعية وغير طبيعية، مما يعزز فعالية أنظمة المراقبة الذكية في الكشف المبكر عن الحوادث [10].

دراسة إضافية نُشرت في مجلة Discover Artificial Intelligence قارنت بين بنى RNN المختلفة في الكشف عن الأنشطة غير الطبيعية في مقاطع الفيديو. أظهرت النتائج أن استخدام RNN مع آلية انتباه متعددة الطبقات يحسن بشكل كبير من دقة الكشف، مما يساهم في تحسين أداء أنظمة المراقبة الذكية [11].

أخيرًا، دراسة نُشرت في مجلة PeerJ اقترحت نموذجًا يعتمد على RNN للكشف عن السرقة في مقاطع الفيديو من مراكز التسوق. أظهرت النتائج أن النموذج المقترح كان قادرًا على تحديد الأنشطة غير الطبيعية بدقة عالية، مما يعزز فعالية أنظمة المراقبة في البيئات التجارية [12].


تشير هذه الدراسات إلى أن دمج RNN في أنظمة المراقبة بالفيديو يمكن أن يحسن بشكل كبير من دقة الكشف عن الأنشطة غير الطبيعية، مما يعزز فعالية هذه الأنظمة في تعزيز الأمان والسلامة العامة.

الفصل الثالث: التقنيات والخوارزميات المستخدمة

1-3 خوارزمية YOLO (You Only Look Once)

1-1-3 مقدمة عن YOLO

خوارزمية YOLO (You Only Look Once) هي واحدة من أكثر الخوارزميات تطوراً في مجال التعرف على الكائنات، حيث تقدم حلاً سريعاً وفعالاً لتحديد الأشياء ومواقعها داخل الصور أو الفيديوها. تعتمد هذه الخوارزمية على مبدأ بسيط ولكنه قوي، يتمثل في معالجة الصورة بأكملها مرة واحدة فقط، بدلاً من البحث عن الكائنات عبر مناطق متعددة بشكل منفصل كما هو الحال في بعض الأساليب التقليدية. هذا النهج يجعلها أسرع بكثير مقارنة بالطرق الأخرى، مما يجعلها مناسبة للتطبيقات التي تتطلب استجابات فورية مثل السيارات ذاتية القيادة وأنظمة المراقبة [13]. (هون المرجع من كتاب حساب أوقات العمل)




الشكل 3-1: سرعة خوارزمية YOLO مقارنة بخوارزميات التعرف على الكائنات الأخرى الأكثر تطوراً.

تتميز YOLO بأنها لا تقوم فقط بتحديد نوع الكائن الموجود في الصورة، بل تحدد أيضاً موقعه بدقة من خلال رسم مربعات حدودية حوله وإعطاء مستوى ثقة يعكس احتمالية دقة التوقع. هذا يعني أن النظام يمكنه التعامل مع صور تحتوي على عدة كائنات مختلفة، ويقوم بتحليلها بشكل شامل في خطوة واحدة [13].

بفضل تصميمها البسيط والمباشر، أصبحت YOLO خياراً شائعاً في العديد من التطبيقات العملية، حيث تجمع بين السرعة والدقة بطريقة تلبى احتياجات المؤسسات والأفراد الذين يحتاجون إلى حلول فعالة للتعرف على الكائنات في الزمن الحقيقي [13].

بالترتيب في تطوير إصدارات YOLO، يمكن ملاحظة أن كل إصدار جديد كان يضيف تحسينات ملموسة على الإصدار السابق له. فقد جاء YOLOv5 ليحقق سرعة تنفيذ عالية مع خفة النموذج، ولكنه كان لا يزال محدودًا نسبيًا من حيث الدقة في الحالات المعقدة. ثم تبعه YOLOv6 و YOLOv7 بتحسينات في التعامل مع الكائنات الصغيرة والكثيرة ضمن نفس الصورة، مع رفع الدقة دون التضحية الكبيرة بسرعة الأداء. أما YOLOv8 فقد أدخل تحسينات إضافية على بنية النموذج وطريقة المعالجة لتحقيق نتائج أكثر ثباتًا في مختلف أنواع البيانات. بعد ذلك جاء YOLOv9 بتعديلات متقدمة على تصميم الشبكة العصبية ساهمت في زيادة الدقة بشكل ملحوظ مع الحفاظ على زمن تنفيذ مقبول. مع YOLOv10، تم التركيز أكثر على تقنيات جديدة لتحقيق توازن أفضل بين سرعة الأداء ودقة النتائج، إلى أن وصلنا إلى YOLO11 الذي يعتبر حاليًا الأكثر تطورًا، حيث استطاع أن يتفوق بوضوح على جميع الإصدارات السابقة من حيث الدقة وسرعة الاستجابة في نفس الوقت [13].

عند النظر إلى الشكل (2-2)، يتضح مسار هذا التطور بشكل عملي، حيث يوضح المخطط العلاقة بين دقة النموذج (على المحور الرأسي) وزمن المعالجة لكل صورة (على المحور الأفقي) باستخدام منصة تسريع خاصة (TensorRT10 FP16). يظهر بوضوح أن سلسلة إصدارات YOLO، وخاصة YOLO11 الممثل بالخط الأزرق العريض، تقدم أعلى قيم للدقة مع المحافظة على زمن تنفيذ منخفض، وهو ما يدل على الكفاءة العالية للنموذج. كما يمكن ملاحظة أن الإصدارات الأقدم مثل YOLOv5 و YOLOv6-3.0 تحتل مراتب أدنى من حيث الأداء، بينما تقترب بعض النماذج الأخرى مثل PP-YOLOE+ و DAMO-YOLO من تحقيق نتائج جيدة ولكن دون الوصول إلى مستوى YOLO11. في المقابل، تبدو نماذج أخرى مثل EfficientDet أقل تنافسية، حيث تظهر بزمن تنفيذ أطول ودقة أقل. هذه النتائج تؤكد أن سلسلة YOLO قد شهدت عبر إصداراتها المتعاقبة تحسينات منظمة ومدروسة، مما جعلها واحدة من أهم الخوارزميات المعتمدة في تطبيقات الرؤية الحاسوبية التي تتطلب سرعة ودقة عاليتين في نفس الوقت، مع احتفاظها بمرونة مناسبة للاستخدام في مجالات متنوعة [13].




الشكل 3-2: مقارنة بين إصدارات YOLO المختلفة من حيث الدقة مقابل زمن التنفيذ.

2-1-3 خطوات عمل YOLO

1-2-1-3 تقسيم الصورة إلى خلايا

في الخطوة الأولى من عمل YOLO، يتم تقسيم الصورة إلى مجموعة من الخلايا المتساوية الحجم. كل خلية في هذه الشبكة تمثل جزءاً مستقلاً من الصورة وتعمل كوحدة معالجة منفصلة. الهدف من هذا التقسيم هو تبسيط عملية البحث عن الكائنات داخل الصورة، حيث يتم التعامل مع كل خلية على حدة لتحديد ما إذا كانت تحتوي على كائن معين أم لا [13].



الشكل 3-3: خطوات عمل خوارزمية YOLO.

تُعتبر كل خلية بمثابة صورة جزئية صغيرة تحمل جزءاً من المعلومات البصرية للصورة الأصلية. هذا النهج يتيح للنظام التركيز على المناطق المختلفة من الصورة بشكل منهجي ومنظم، مما يساهم في تسريع عملية التحليل وتحسين الدقة. أثناء هذه الخطوة، يتم تحديد مواقع الكائنات المحتملة داخل كل خلية، مما يمهد الطريق لخطوات التحليل اللاحقة [13].

بهذه الطريقة، يتمكن YOLO من معالجة الصورة بأكملها مرة واحدة فقط، بدلاً من البحث المتكرر عن الكائنات عبر مناطق متعددة كما يحدث في بعض الأساليب التقليدية. هذا يجعل النظام أكثر كفاءة وأسرع في تقديم النتائج، خاصة عند التعامل مع تطبيقات تتطلب استجابات فورية مثل السيارات ذاتية القيادة أو أنظمة المراقبة [13].

2-2-1-3 معالجة الخلايا باستخدام CNN

الشبكة العصبية التلافيفية (CNN)

الشبكات العصبية التلافيفية (CNN) هي نوع متخصص من الشبكات العصبية المصممة خصيصاً لمعالجة البيانات ذات الطبيعة البصرية، مثل الصور. تُستخدم هذه الشبكات بشكل واسع في مجال رؤية الحاسوب بسبب قدرتها الفائقة على استخلاص الأنماط والخصائص المكانية من البيانات البصرية. تعتمد CNN على مبدأ المحاكاة الجزئية لعملية الإدراك البشري للصور، حيث تركز على اكتشاف الخصائص المهمة مثل الحواف، الأشكال، والأنماط المعقدة بطريقة تتناسب مع طبيعة الصور. يميزها عن غيرها من النماذج قدرتها على التعامل مع كميات ضخمة من البيانات البصرية بكفاءة عالية، مما يجعلها أداة أساسية في التطبيقات التي تتطلب تحليل الصور أو الفيديوها بدقة وسرعة [8].


لماذا اعتمدنا CNN لمعالجة الصور بدلاً من DNN؟

عند التعامل مع الصور، تواجه الشبكات العصبية العميقة (DNN) تحديات كبيرة تجعلها غير كافية لتحقيق الأداء المطلوب في معالجة البيانات البصرية. السبب الرئيسي لذلك يعود إلى طبيعة الصور ذاتها، حيث تحتوي على كميات ضخمة من البيانات التي يتم تمثيلها عادةً في صورة مصفوفات بكسل متعددة الأبعاد. إذا حاولنا استخدام DNN لمعالجة الصور، فإننا سنحتاج إلى معالجة كل بكسل على حدة، مما يؤدي إلى زيادة هائلة في عدد المعلمات الحسابية وتعقيد النظام بشكل كبير. هذا يجعل العملية غير فعالة من حيث الوقت والموارد الحاسوبية [8].

على الجانب الآخر، تأتي الشبكات العصبية التلافيفية (CNN) كحل مثالي لهذه المشكلة. تعتمد CNN على تصميم خاص يتيح لها استخلاص الخصائص المكانية من الصور بطريقة أكثر كفاءة. تعمل هذه الشبكات باستخدام عمليات مثل التحويل التلافيفي (Convolution) والجمع الأقصى (Pooling)، مما يقلل بشكل كبير من عدد المعلمات المطلوبة ويسمح للنظام بالتركيز على الأنماط المهمة في الصورة. على سبيل المثال، يمكن لـ CNN اكتشاف الحواف والأشكال البسيطة في البداية، ثم بناء أنماط أكثر تعقيداً تدريجياً عبر الطبقات المختلفة [8].

بالإضافة إلى ذلك، تتميز CNN بقدرتها على المحافظة على العلاقات المكانية بين البكسلات، وهو أمر أساسي في تحليل الصور. بينما تعاني DNN من فقدان هذه العلاقات بسبب معالجتها الخطية للبيانات، فإن CNN تحافظ على البنية المكانية للصورة من خلال تصميمها المتدرج، مما يجعلها أكثر ملاءمة لمهام مثل تصنيف الصور أو الكشف عن الأشياء. لهذا السبب، تم تبني CNN كأداة أساسية في مجال رؤية الحاسوب، حيث توفر حلاً أكثر ذكاءً وكفاءة لمعالجة الصور مقارنةً بالشبكات العصبية العميقة التقليدية [8].

خطوات عمل شبكة CNN



الشكل 3-4: بنية شبكة CNN.

1. Input: يتم تقديم الصورة كمدخل إلى الشبكة. الصورة عادةً تكون مصفوفة ثلاثية الأبعاد تحتوي على بيانات عن الألوان (مثل RGB) أو الدرجات الرمادية.

2. Convolution: بعد الإدخال، تمر الصورة عبر طبقات التحويل التلوفي (Convolution Layers)، حيث تقوم المرشحات (Filters) باستخلاص الخصائص البصرية من الصورة. المرشحات هي عبارة عن مصفوفات صغيرة يتم سحبها عبر الصورة باستخدام عملية التحويل التلوفي. خلال هذه العملية، يتم ضرب كل بكسل في الصورة بالمرشح وتجميع النتائج لإنتاج (Feature Maps). تساعد المرشحات في اكتشاف الأنماط البصرية الأساسية مثل الحواف، الأشكال، أو الألوان، حيث يركز كل مرشح على جزء معين من الصورة مما يسمح للشبكة باستخلاص أنماط مختلفة بناءً على الغرض المطلوب.

3. Pooling: بعد مرحلة التحويل التلوفي، يتم تطبيق عملية التجميع (Pooling) على الـ Feature maps بهدف تقليل حجم البيانات من خلال تقليل عدد البكسلات دون فقدان المعلومات الرئيسية. تلعب عملية التجميع دورًا مهمًا في تقليل تعقيد النظام وتحسين الكفاءة، حيث يتم التركيز على الاحتفاظ بالأنماط الأساسية فقط. يعتبر "التجميع الأقصى" (Max Pooling) من أبرز أنواع التجميع، وفيه يتم اختيار القيم الأعلى في كل منطقة صغيرة من الصورة، مما يساعد على تسليط الضوء على الخصائص الأكثر أهمية. كما يوجد أيضًا نوع آخر يُعرف بـ "التجميع المتوسط" (Average Pooling)، الذي يقوم بإيجاد متوسط القيم في كل منطقة لضمان الحفاظ على توازن في البيانات المستخرجة.

4. Flatting: بعد مرحلتَي التحويل التلوفي والتجميع، يتم تسطيح الناتج ليأخذ شكل متجه أحادي البعد. تهدف عملية التسطيح إلى تحويل البيانات ذات الأبعاد المتعددة، مثل الصور، إلى صيغة خطية ذات بعد واحد لتسهيل معالجتها في المراحل اللاحقة. تكمن أهمية هذه الخطوة في أن الطبقات الكاملة الارتباط (Fully Connected Layers) لا يمكنها التعامل مع البيانات متعددة الأبعاد بشكل مباشر، لذا يتم تجميع كافة القيم المستخرجة من الخرائط التلافيفية في متجه واحد منظم. هذا الترتيب يساهم في تجهيز البيانات بالشكل المناسب لتحليلها واستثمارها في الطبقات القادمة ضمن النموذج العصبي.

5. Fully Connected Layers: بعد التسطيح، يتم تمرير الإخراج إلى طبقات كاملة الارتباط (Fully Connected Layers) التي تعمل على تحليل الأنماط المستخلصة من الصورة وتحديد الفئات المختلفة. في كل طبقة، يتم استخدام دوال التنفيل (Activation Functions) مثل ReLU لضمان إضافة عنصر غير خطي إلى النظام. تتميز الطبقات الكاملة الارتباط بأنها تربط بين جميع العقد الموجودة فيها، مما يسمح لها بتحليل العلاقات المعقدة بين البيانات وفهم الأنماط بشكل أعمق. هذه العملية تعزز قدرة الشبكة على استخلاص معلومات دقيقة وتصنيف الصور بشكل فعال.

6. Classification: في المرحلة الأخيرة، يتم إنتاج النتائج النهائية من خلال طبقة خروج تحتوي على عدد من العقد يتناسب مع عدد الفئات التي يتم التعرف عليها. غالباً ما تستخدم الطبقات النهائية دالة تفعيل خاصة مثل Softmax، والتي تعمل على توليد احتمالات لكل فئة ممكنة بناءً على البيانات المستخلصة من الصورة. الناتج النهائي يكون عبارة عن مجموعة من القيم تمثل احتمالية وجود كل فئة في الصورة، مما يساعد في تحديد الفئة الأكثر احتمالاً واتخاذ القرار المناسب بناءً على هذه الاحتمالات.

3-2-1-3 إنتاج البوكسات

بعد معالجة الصورة باستخدام شبكة CNN واستخلاص الأنماط والخصائص المكانية منها، يتم الانتقال إلى خطوة إنتاج البوكسات (Bounding Boxes) التي تحيط بالكائنات المكتشفة. في هذه المرحلة، يبدأ النظام بتحديد مواقع الكائنات داخل الصورة بناءً على المعلومات المستخلصة من الطبقات السابقة. يتم إنشاء عدد كبير من البوكسات حول المناطق التي يُحتمل أن تحتوي على كائنات (كما هو واضح في الشكل 2-3)، حيث يتم تحليل كل بوكس لمعرفة ما إذا كان يحتوي على كائن ذي صلة أم لا [13].


تُعتبر عملية إنتاج البوكسات جزءاً أساسياً من نظام YOLO، حيث يتم ربط كل بوكس بموقع معين في الصورة وتحديد احتمالية وجود كائن داخله. يتم تحديد هذه البوكسات باستخدام خوارزميات تقوم بتقسيم الصورة إلى مناطق محتملة، ثم تحليل كل منطقة بشكل مستقل. بعد ذلك، يتم تعيين درجة ثقة لكل بوكس تعكس مدى دقة التنبؤ بوجود كائن داخله [13].

بفضل هذا النهج، يمكن للنظام التعامل مع عدة كائنات في نفس الوقت داخل الصورة الواحدة، مما يجعله أكثر كفاءة مقارنة بالأساليب التقليدية التي تعتمد على البحث المتكرر عن الكائنات عبر مناطق متعددة. ومع ذلك، فإن ظهور عدد كبير من البوكسات قد يؤدي إلى تداخل بعضها مع الآخر، مما يستدعي استخدام تقنيات مثل "Non-Maximum Suppression" لتقليل التكرار واختيار أفضل بوكس لكل كائن مكتشف [13].

بهذه الطريقة، يتمكن YOLO من تقديم نتائج دقيقة وسريعة، حيث يتم تحديد مواقع الكائنات بدقة وإعطاء احتمالات موثوقة لوجودها في الصورة. هذه الخطوة تعتبر حاسمة لتحقيق التوازن بين السرعة والدقة، خاصة عند التعامل مع تطبيقات تتطلب استجابات فورية مثل السيارات ذاتية القيادة أو أنظمة المراقبة [13].

3-1-3 تقنية IoU

Intersection over Union (IoU) هو طريقة شائعة تُستخدم لتقييم مدى دقة تحديد موقع الكائنات في نماذج التعرف على الأشياء. يعمل هذا المقياس على حساب نسبة التداخل بين بوكس مُقترح من النموذج وبوكس آخر يمثل الموقع الحقيقي للكائن (الحقيقة الأساسية). كلما زاد التداخل بين البوكسين، كانت النتيجة أكثر دقة (انظر الشكل 5-2) [14].



الشكل 3-5: آلية عمل تقنية IoU.

4-1-3 أدوات ومكتبات YOLO

- **Ultralytics:** في المشروع الخاص بنا، تم اعتماد استخدام النماذج الجاهزة المقدمة من فريق Ultralytics بدلاً من بناء نموذج YOLO من الصفر. يوفر فريق Ultralytics نماذج متطورة مثل YOLOv5 و YOLOv8، والتي تعتبر أدوات قوية وفعالة للكشف عن الأشياء في الصور والفيديوهات. هذه النماذج تم تدريبها مسبقاً على مجموعة واسعة من البيانات، مما يجعلها قادرة على التعامل مع العديد من الحالات المختلفة بسرعة ودقة. باستخدام هذه النماذج الجاهزة، يمكن توفير الوقت والجهد المطلوبين لتطوير نموذج جديد تماماً، مما يتيح التركيز على تخصيص النموذج بما يناسب احتياجات المشروع الخاصة [13].



الشكل 6-3: مكتبة Ultralytics.

- **OpenCV:** تلعب مكتبة OpenCV دورًا مهمًا في تسهيل عمل خوارزمية YOLO من خلال معالجة الصور وعرض النتائج بطريقة مرئية سهلة الفهم. باستخدام OpenCV، يمكن للنظام قراءة الصور أو مقاطع الفيديو وتحضيرها لتحليلها بواسطة YOLO. بعد أن تقوم YOLO بتحديد الكائنات ورسم المربعات حولها، تستخدم OpenCV هذه المعلومات لعرض الصورة النهائية بشكل واضح، حيث يتم إظهار المربعات المحيطة بالكائنات مع كتابة أسمائها ونسبة الثقة بجانبها. هذا يساعد المستخدمين على رؤية النتائج مباشرة وبشكل بسيط دون الحاجة إلى فهم التفاصيل البرمجية المعقدة. باختصار، OpenCV تعمل كأداة تربط بين تقنية YOLO والمستخدم، مما يجعل عملية التعرف على الكائنات أكثر سهولة وتفاعلية [13].



الشكل 7-3: مكتبة OpenCV.

2-3 الشبكة العصبية التكرارية (RNN)

1-2-3 تعريف الشبكة العصبية التكرارية (RNN)

الشبكة العصبية التكرارية (RNN) هي نوع من الشبكات العصبية العميقة التي تُدرَّب على بيانات تسلسلية أو بيانات السلاسل الزمنية بهدف إنشاء نموذج تعلم آلي قادر على إجراء تنبؤات أو استنتاجات متسلسلة استنادًا إلى المدخلات المتسلسلة [15].

يمكن استخدام الشبكة العصبية التكرارية للتنبؤ بمستويات الفيضانات اليومية بناءً على بيانات سابقة لمستويات الفيضانات اليومية، وبيانات المد والجزر، وبيانات الأرصاد الجوية. كما يمكن أيضًا استخدام الـ RNN لحل المشكلات التي تتعلق بالترتيب الزمني أو الترتيبي مثل ترجمة اللغات، ومعالجة اللغة الطبيعية (NLP)، وتحليل المشاعر، والتعرف على الكلام، والتعليق على الصور. علاوة على ذلك، تُستخدم هذه الشبكات أيضًا في تحليل الفيديوهات لكشف السرقات والحركات المشبوهة في المنشآت، مما يساهم في تعزيز أمان المنشآت والمرافق.

2-2-3 كيفية عمل الشبكات العصبية التكرارية (RNN)

كما هو الحال مع الشبكات العصبية التقليدية مثل الشبكات العصبية الأمامية والشبكات العصبية التلافيفية (CNN)، تعتمد الشبكات العصبية التكرارية على بيانات التدريب لتعلم الأنماط. ما يميز هذه الشبكات هو "الذاكرة" الخاصة بها، حيث أنها تستخدم المعلومات من المدخلات السابقة للتأثير على المدخلات والمخرجات الحالية [15].

بينما تفترض الشبكات العميقة التقليدية أن المدخلات والمخرجات مستقلة عن بعضها البعض، فإن مخرجات الشبكات العصبية التكرارية تعتمد على العناصر السابقة ضمن التسلسل. وعلى الرغم من أن الأحداث المستقبلية قد تكون مفيدة أيضًا في تحديد مخرجات التسلسل المعين، إلا أن الشبكات العصبية التكرارية أحادية الاتجاه لا يمكنها أخذ هذه الأحداث في الحسبان عند إجراء التنبؤات [15].


الجدول 3-1: الفرق بين شبكة CNN وشبكة RNN.

الشبكات العصبية المتكررة (RNNs)	الشبكات العصبية التلافيفية (CNNs)	
تستخدم طبقات متكررة لمعالجة البيانات المتسلسلة.	تستخدم طبقات تلافيفية لاستخراج الميزات من البيانات.	البنية
معالجة اللغة الطبيعية، تحليل السلاسل الزمنية.	التعرف على الصور، مهام الرؤية الحاسوبية.	الاستخدام الأساسي
مدخلات ومخرجات ذات حجم متغير، معالجة البيانات المتسلسلة.	مدخلات ومخرجات ذات حجم ثابت.	إدخال البيانات
تحتفظ بحالة (ذاكرة) للمدخلات السابقة.	لا توجد ذاكرة متصلة للمدخلات السابقة.	معالجة الذاكرة
أقل قابلية للمعالجة في وقت واحد بسبب المعالجة المتسلسلة.	قابلية للمعالجة في وقت واحد بدرجة عالية.	المعالجة في وقت واحد

لتوضيح ذلك، دعنا نأخذ تعبيرًا مجازيًا مثل "feeling under the weather"، والذي يُستخدم عادة عندما يكون شخص ما مريضًا. لفهم هذا التعبير، يجب أن يُقال بهذا الترتيب المحدد. وبالتالي، تحتاج الشبكات العصبية التكرارية إلى مراعاة ترتيب كل كلمة في التعبير، وتستخدم هذه المعلومات للتنبؤ بالكلمة التالية في التسلسل.

كل كلمة في العبارة "feeling under the weather" هي جزء من تسلسل حيث يكون الترتيب ذا أهمية. تتابع الشبكة العصبية التكرارية السياق من خلال الحفاظ على حالة مخفية في كل خطوة زمنية. يتم إنشاء حلقة تغذية راجعة عن طريق تمرير الحالة المخفية من خطوة زمنية إلى أخرى. تعمل الحالة المخفية كذاكرة تخزين معلومات حول المدخلات السابقة. في كل خطوة زمنية، تعالج الشبكة العصبية التكرارية المدخل الحالي (مثل كلمة في جملة) جنبًا إلى جنب مع الحالة المخفية من الخطوة الزمنية السابقة. هذا يسمح للشبكة "بتذكر" النقاط البيانية السابقة واستخدام هذه المعلومات للتأثير على المخرجات الحالية [15].

ميزة أخرى تميز الشبكات العصبية التكرارية هي أنها تشارك المعاملات عبر كل طبقة من الشبكة. بينما تحتوي الشبكات العصبية الأمامية على أوزان مختلفة عبر كل عقدة، تشارك الشبكات العصبية التكرارية نفس معامل الوزن ضمن كل طبقة من الشبكة. ومع ذلك، يتم تعديل هذه الأوزان من خلال عمليات الانتشار العكسي وهبوط التدرج لتسهيل التعلم المعزز [15].



الشكل 3-8: الشبكات العصبية الأمامية (التغذية الأمامية) VS الشبكات العصبية المتكررة.

تستخدم الشبكات العصبية التكرارية خوارزميات الانتشار الأمامي والانتشار العكسي عبر الزمن (BPTT) لتحديد التدرجات (أو المشتقات)، وهو ما يختلف قليلاً عن الانتشار العكسي التقليدي حيث يكون مخصصاً لبيانات التسلسل. المبادئ الأساسية لـ BPTT مشابهة لتلك الخاصة بالانتشار العكسي التقليدي، حيث يقوم النموذج بتدريب نفسه عن طريق حساب الأخطاء من طبقة المخرجات إلى طبقة المدخلات. تسمح هذه الحسابات بضبط المعاملات وتكييفها بشكل مناسب. يختلف BPTT عن الطريقة التقليدية في أنه يقوم بتجميع الأخطاء في كل خطوة زمنية، في حين أن الشبكات العصبية الأمامية لا تحتاج إلى تجميع الأخطاء لأنها لا تشارك المعاملات عبر كل طبقة [15].

3-2-3 الدوال التنشيطية الشائعة


الدالة التنشيطية هي دالة رياضية تُطبّق على ناتج كل طبقة من الخلايا العصبية في الشبكة لإدخال اللاخطية والسماح للشبكة بتعلم أنماط أكثر تعقيداً في البيانات. بدون الدوال التنشيطية، ستقوم الشبكة العصبية التكرارية (RNN) ببساطة بحساب التحويلات الخطية للمدخلات، مما يجعلها غير قادرة على التعامل مع المشاكل غير الخطية. اللاخطية أمر بالغ الأهمية للتعلم ونمذجة الأنماط المعقدة، خصوصاً في المهام مثل معالجة اللغة الطبيعية (NLP)، وتحليل السلاسل الزمنية، والتنبؤ بالبيانات المتسلسلة [15].

الدالة التنشيطية تتحكم في مقدار ناتج الخلية العصبية، مما يبقي القيم ضمن نطاق معين (على سبيل المثال، بين 0 و 1 أو -1 و 1)، مما يساعد في منع القيم من أن تصبح كبيرة جداً أو صغيرة جداً أثناء المرور الأمامي والخلفي. في الشبكات العصبية التكرارية (RNN)، يتم تطبيق الدوال التنشيطية في كل خطوة زمنية على

الحالات المخفية، مما يتحكم في كيفية تحديث الشبكة لذاكرتها الداخلية (الحالة المخفية) بناءً على المدخلات الحالية والحالات المخفية السابقة [15].

الدوال التنشيطية الشائعة تشمل:

- **Sigmoid Function:** تستخدم لتفسير الناتج كاحتمالات أو للتحكم في البوابات التي تقرر مقدار المعلومات التي يجب الاحتفاظ بها أو نسيانها. ومع ذلك، فإن دالة Sigmoid عرضة لمشكلة تلاشي التدرج، مما يجعلها أقل مثالية للشبكات الأعمق.
- **Tanh Function:** غالباً ما تُستخدم لأنها تُنتج قيماً متمركزة حول الصفر، مما يساعد في تدفق التدرجات بشكل أفضل ويسهل تعلم التبعيات الطويلة الأجل.
- **ReLU:** قد تتسبب في مشاكل بسبب تزايد التدرجات بشكل غير محدود نتيجة لطبيعتها غير المحدودة. ومع ذلك، تم استخدام بعض المتغيرات مثل Leaky ReLU و Parametric ReLU لتخفيف بعض هذه المشاكل.




الشكل 3-9: الدوال التنشيطية الشائعة في الشبكة العصبية التكرارية.

4-2-3 أنواع الشبكات العصبية التكرارية (RNNs)

تقوم الشبكات العصبية الأمامية (Feedforward Networks) بربط المدخلات والمخرجات بشكل واحد إلى واحد، ومع أن الشبكات العصبية التكرارية قد تم تمثيلها بهذه الطريقة في الرسوم البيانية السابقة، إلا أنها لا تقتصر على هذا النوع من الربط. على العكس من ذلك، يمكن أن تختلف المدخلات والمخرجات في الشبكات

العصبية التكرارية من حيث الطول، ويُستخدم أنواع مختلفة من الشبكات العصبية التكرارية لأغراض متعددة، مثل توليد الموسيقى، تصنيف المشاعر، والترجمة الآلية. تشمل أبرز المتغيرات في بنية الشبكات العصبية التكرارية [15]:

- الشبكات العصبية التكرارية القياسية (Standard RNNs)
- الشبكات العصبية التكرارية الثنائية الاتجاه (Bidirectional Recurrent Neural Networks - BRNNs)
- الذاكرة قصيرة وطويلة المدى (Long Short-Term Memory - LSTM)
- الوحدات التكرارية البوابية (Gated Recurrent Units - GRUs)
- الشبكات العصبية التكرارية من نوع المشفر-المفكك (Encoder-Decoder RNNs)



الشكل 10-3: أنواع مختلفة من الشبكات العصبية التكرارية (RNNs).

1. **الشبكات العصبية التكرارية القياسية (Standard RNNs):** أبسط نسخة من الشبكة العصبية التكرارية، حيث يعتمد الناتج في كل خطوة زمنية على كل من المدخل الحالي والحالة المخفية من الخطوة الزمنية السابقة. تعاني هذه الشبكة من مشاكل مثل تلاشي التدرجات، مما يجعل من الصعب عليها تعلم التبعية طويلة المدى. ومع ذلك، فإنها تتفوق في المهام البسيطة التي تتطلب التبعية قصيرة المدى، مثل التنبؤ

بالكلمة التالية في جملة (للجمل القصيرة والبسيطة) أو القيمة التالية في سلسلة زمنية بسيطة. تعد الشبكات العصبية التكرارية مناسبة للمهام التي تعالج البيانات تسلسلياً في الوقت الفعلي، مثل معالجة بيانات الحساسات لاكتشاف الشذوذ في فترات زمنية قصيرة، حيث يتم استلام المدخلات واحدة تلو الأخرى وتحتاج التنبؤات إلى أن تتم فوراً بناءً على المدخلات الأخيرة.

2. **الشبكات العصبية التكرارية الثنائية الاتجاه (BRNNs):** بينما يمكن للشبكات العصبية التكرارية أحادية الاتجاه (unidirectional RNNs) الاعتماد فقط على المدخلات السابقة لإجراء التنبؤات حول الحالة الحالية، فإن الشبكات العصبية التكرارية الثنائية الاتجاه (BRNNs) تقوم بسحب البيانات المستقبلية لتحسين دقة التنبؤات. بالرجوع إلى المثال السابق "feeling under the weather"، يمكن لنموذج يعتمد على BRNN التنبؤ بشكل أفضل بأن الكلمة الثانية في هذه العبارة هي "under" إذا كان يعرف أن الكلمة الأخيرة في التسلسل هي "weather".

3. **الذاكرة قصيرة وطويلة المدى (LSTM):** تعد شبكة LSTM واحدة من أشهر بنى الشبكات العصبية التكرارية (RNN)، والتي تم تقديمها بواسطة سييب هوكراتير ويورغن شمديهوبر كحل لمشكلة تلاشي التدرجات. هذا العمل تناول مشكلة التبعيات طويلة المدى، أي أنه إذا كانت الحالة السابقة التي تؤثر على التنبؤ الحالي ليست قريبة من الماضي، فقد لا يكون نموذج RNN قادراً على التنبؤ بدقة بالحالة الحالية. على سبيل المثال، لنفترض أننا أردنا التنبؤ بالكلمات المكتوبة بخط مائل في الجملة التالية: "Alice is allergic to nuts. She can't eat peanut butter". يمكن أن يساعدنا سياق حساسية المكسرات في التنبؤ بأن الطعام الذي لا يمكن تناوله يحتوي على مكسرات. ومع ذلك، إذا كان هذا السياق قد تم ذكره في جمل سابقة، فقد يكون من الصعب أو حتى المستحيل على نموذج RNN ربط المعلومات. لحل هذه المشكلة، تحتوي شبكات LSTM على "خلايا" في الطبقات المخفية للشبكة العصبية الاصطناعية، التي تحتوي على ثلاث بوابات: بوابة الإدخال، وبوابة الإخراج، وبوابة النسيان. هذه البوابات تتحكم في تدفق المعلومات اللازمة للتنبؤ بالمرجات في الشبكة. على سبيل المثال، إذا تم تكرار الضمائر مثل "she" عدة مرات في الجمل السابقة، قد يتم استبعاد ذلك من حالة الخلية.

4. **الوحدات التكرارية البوابية (GRUs):** تعتبر GRU مشابهة لشبكة LSTM حيث أنها تعمل أيضاً على معالجة مشكلة الذاكرة القصيرة في نماذج الشبكات العصبية التكرارية (RNN). بدلاً من استخدام "حالة الخلية" لتنظيم المعلومات، تستخدم GRU الحالات المخفية، وبدلاً من ثلاث بوابات، تحتوي على بوابتين: بوابة إعادة التعيين (reset gate) وبوابة التحديث (update gate). مثل البوابات في LSTM، تتحكم

بوابات الإعادة والتحديث في كمية وأي معلومات يجب الاحتفاظ بها. نظرًا لبنيتها الأبسط، تعد GRUs أكثر كفاءة حسابيًا وتحتاج إلى عدد أقل من المعاملات مقارنة بـ LSTMs. وهذا يجعلها أسرع في التدريب وغالبًا أكثر ملاءمة لبعض التطبيقات في الوقت الفعلي أو التطبيقات ذات الموارد المحدودة.

5. الشبكات العصبية التكرارية من نوع المشفر-المفكك (Encoder-Decoder RNNs): تُستخدم هذه الشبكات عادةً في المهام التي تتطلب تحويل تسلسل إلى تسلسل آخر، مثل الترجمة الآلية. يقوم المشفر (Encoder) بمعالجة تسلسل المدخلات إلى متجه ثابت الطول (السياق)، ثم يستخدم المفكك (Decoder) هذا السياق لتوليد تسلسل المخرجات. ومع ذلك، يمكن أن يصبح المتجه الثابت الطول للسياق عنق الزجاجة، خاصةً بالنسبة للتسلسلات الطويلة من المدخلات.

3-2-5 قيود الشبكات العصبية التكرارية (RNNs)

انخفض استخدام الشبكات العصبية التكرارية (RNNs) في الذكاء الاصطناعي في السنوات الأخيرة، خاصة مع تزايد الاعتماد على نماذج جديدة مثل "نماذج المحولات" (transformers)، ولكن هذا لا يعني أن RNNs أصبحت قديمة تمامًا. كانت الشبكات العصبية التكرارية شائعة في الماضي لمعالجة البيانات المتسلسلة مثل البيانات الزمنية أو نمذجة اللغة بسبب قدرتها على التعامل مع المعلومات التي تتغير بمرور الوقت [15].


لكن الشبكات العصبية التكرارية تعاني من مشكلتين رئيسيتين هما: تلاشي التدرجات (vanishing gradients) وتفجر التدرجات (exploding gradients)، وهذا يجعلها أقل كفاءة في معالجة البيانات المعقدة. ومع ظهور نماذج المحولات مثل BERT و GPT، والتي تتمتع بقدرة أكبر على التعامل مع العلاقات الطويلة بين البيانات، أصبحت المحولات الخيار المفضل، حيث يمكنها معالجة البيانات بشكل أسرع وأدق، خاصة في مهام مثل الترجمة الآلية والتعرف على الكلام والتنبؤ بالبيانات [15].

على الرغم من ذلك، لا تزال RNNs مفيدة في بعض الحالات، مثل التطبيقات التي تتطلب معالجة البيانات خطوة بخطوة، أو في البيئات التي تملك موارد محدودة. في هذه الحالات، تظل الشبكات العصبية التكرارية خيارًا جيدًا [15].

3-3 تقدير الوضعيات باستخدام مكتبة Mediapipe

تقدير الوضعيات هو تقنية تهدف إلى تحديد مواقع أجزاء الجسم البشري في الفضاء باستخدام الصور أو الفيديو. يعتبر هذا المجال جزءًا أساسيًا من الرؤية الحاسوبية، ويستخدم في العديد من التطبيقات مثل مراقبة

الرياضة، وتفاعل الإنسان مع الأجهزة، وتحليل الحركات. تعتمد هذه التقنية على تحديد النقاط الرئيسية في الجسم البشري مثل الرأس، الأكتاف، المرفقين، والركبتين، ومن ثم تحديد وضعية الجسم بناءً على هذه النقاط. يتيح تقدير الوضعيات الفرصة لفهم أفضل لحركة الإنسان في بيئات مختلفة، مما يعزز القدرة على تحسين التفاعل بين الإنسان والآلة [16].



الشكل 11-3: تقدير الوضعيات (Pose Estimation).

1-3-3 مكتبة MediaPipe

مكتبة Mediapipe هي منصة مفتوحة المصدر طورتها شركة Google، تهدف إلى تسهيل تطوير تطبيقات الرؤية الحاسوبية التي تعتمد على الذكاء الاصطناعي في معالجة الفيديو والصور. توفر Mediapipe مجموعة من الأدوات والخوارزميات التي تمكن المطورين من تنفيذ مهام معقدة مثل اكتشاف الأشياء، تتبع الحركات، وتقدير الوضعيات، وغيرها من التطبيقات في الوقت الفعلي. تم تصميم المكتبة لتكون قابلة للتوسع والتخصيص، مما يسمح للمطورين بتعديلها وتكييفها لتلبية احتياجاتهم الخاصة. تعتمد Mediapipe على بنية مرنة تدعم المعالجة المتوازية وتوزيع المهام بين المعالجات المختلفة، مما يساهم في تحسين الأداء وسرعة التنفيذ [16].

ما يميز Mediapipe عن غيرها من المكتبات هو قدرتها على العمل في بيئات متعددة الأنظمة، بما في ذلك الهواتف الذكية وأجهزة الكمبيوتر المكتبية، فضلاً عن دعمها لمجموعة واسعة من خوارزميات الذكاء الاصطناعي الحديثة. تتيح المكتبة للمطورين العمل بسهولة مع البيانات المستخلصة من كاميرات الفيديو وتحليلها في الوقت الفعلي، مما يجعلها أداة مثالية للتطبيقات التي تتطلب استجابة سريعة ودقيقة. بشكل عام،


تعتبر Mediapipe من الحلول المتكاملة التي تسهم في تطوير التطبيقات التي تعتمد على الرؤية الحاسوبية والذكاء الاصطناعي [16].

MediaPipe

الشكل 3-12: شعار مكتبة MediaPipe.


2-3-3 آلية عمل مكتبة MediaPipe في تقدير الوضعيات

تعتمد آلية عمل MediaPipe في تقدير وضعيات الجسم على سلسلة من الخطوات المتكاملة التي تبدأ باستخراج الإطار المرئي من الفيديو ومعالجته باستخدام نماذج تعلم عميق مدربة مسبقاً. عند تمرير صورة أو مقطع فيديو إلى النظام، تقوم MediaPipe أولاً باكتشاف وجود شخص في الصورة من خلال نموذج يُعرف بـ BlazePose، وهو نموذج خفيف الوزن وعالي الكفاءة مصمم لتحديد وضعيات الجسم البشرية بدقة عالية وفي الوقت الفعلي. بعد اكتشاف الشخص، يتم تحديد وتتبع مجموعة من النقاط الأساسية على الجسم، يصل عددها إلى 33 نقطة، تشمل المفاصل والمحاور الحيوية مثل الرأس، الكتفين، المرفقين، الركبتين، والكاحلين [16].




الشكل 3-13: النقاط الأساسية للجسم.

تُحوّل هذه النقاط إلى إحداثيات ثنائية أو ثلاثية الأبعاد، تُستخدم لاحقاً في تحليل الحركة أو بناء نموذج هيكلي للجسم. تستخدم المكتبة تقنيات متقدمة مثل depth-wise separable convolutions و pose landmark refinement لتحسين جودة التقدير وتقليل زمن المعالجة، ما يجعلها مناسبة للتطبيقات التي تتطلب استجابة لحظية. كما تُوظف MediaPipe خوارزميات تتبع متقدمة للحفاظ على استقرار التقدير بين الإطارات المتتالية، مما يُقلل من التذبذب ويزيد من دقة النتائج. هذه البنية تتيح للنظام العمل بكفاءة على أجهزة ذات قدرة معالجة محدودة، مثل الهواتف الذكية، دون التضحية بجودة الأداء أو دقة التقدير. وبالإضافة إلى تقدير وضعيات الجسم، توفر MediaPipe نماذج مخصصة لتتبع ملامح الوجه وتقدير وضعيات اليدين بدقة عالية. ففيما يخص الوجه، تعتمد المكتبة على نموذج Face Mesh الذي يقوم بتحديد 468 نقطة دقيقة على الوجه، تغطي ملامحه الأساسية مثل العيون، الحاجبين، الشفاه، الأنف، والفك، مما يتيح بناء شبكة دقيقة ثلاثية الأبعاد للوجه تُستخدم في تحليل التعابير أو التحقق من الهوية [16].



الشكل 14-3: النقاط الأساسية للوجه.

أما في تتبع اليدين، فتعتمد MediaPipe على نموذج Hand Tracking الذي يتعرف أولاً على وجود اليد ثم يحدد 21 نقطة رئيسية فيها، تشمل المفاصل والعظام من الرسغ وحتى أطراف الأصابع. وتستخدم هذه البيانات في تحليل الإيماءات وحركات الأصابع بدقة زمنية ومكانية عالية، ما يسمح بتطبيقات تفاعلية دقيقة مثل التحكم بالإيماءات أو الترجمة بلغة الإشارة. جميع هذه النماذج تعتمد على بنية معالجة موحدة في MediaPipe تسمح بتشغيلها في الوقت الحقيقي على أجهزة منخفضة الموارد، مع الحفاظ على الاتساق والدقة في تتبع النقاط بين الإطارات المتتالية، مما يجعلها مناسبة بشكل مثالي للتطبيقات الأمنية، الطبية، والتعليمية، وغيرها من السيناريوهات التي تتطلب استجابة حساسة وفورية لحركات الإنسان وتعبيره [16].



الشكل 3-15: النقاط الأساسية لليدين.

3-3-3 تطبيقات MediaPipe

- تُستخدم Mediapipe في تحليل الأداء الحركي للرياضيين من خلال تتبع الوضعيات بدقة عالية، ما يساعد في تحسين التدريب وتجنب الإصابات.
- تُوظف في تطبيقات اللياقة البدنية الذكية التي تقيم جودة التمارين الرياضية وتعطي تغذية راجعة فورية بناءً على وضعيات الجسم.
- تعتمد عليها تطبيقات الواقع المعزز (AR) لتعزيز التفاعل بين المستخدم والبيئة الرقمية باستخدام حركات الجسم بدلاً من أدوات التحكم التقليدية.
- تُستخدم في التعليم الإلكتروني عبر تحليل وضعيات المتعلمين لمراقبة تفاعلهم ومستوى تركيزهم خلال الحصص الافتراضية.


- تساهم في المجال الطبي لإجراء تقييمات حركية للمرضى في جلسات العلاج الفيزيائي ومراقبة تقدمهم دون الحاجة لأجهزة استشعار مادية.
- تُطبق في تحليل تعابير الجسد ضمن مجالات علم النفس أو دعم ذوي الاحتياجات الخاصة، خصوصًا في التعرف على الإشارات غير اللفظية.
- تُستخدم لأغراض أمنية مثل مراقبة سلوك الأفراد في الأماكن الحساسة واكتشاف الحركات غير الطبيعية أو المشبوهة، كتقدير وضعيات الأشخاص في الامتحانات لاكتشاف حالات الغش، أو في أنظمة المراقبة الذكية للتعرف على السلوك العدواني أو المريب في الأماكن العامة.
- يمكن دمجها في الروبوتات التفاعلية لتحسين استجابتها بناءً على وضعيات المستخدم وحركاته، ما يعزز تجربة الإنسان الآلي في البيئات الاجتماعية أو الصناعية.

الفصل الرابع: التنفيذ العملي والآفاق المستقبلية

1-4 مقدمة الفصل

2-4 مخطط مكونات النظام


يعرض الشكل (1-4) مخطط تكامل نظام أمني ذكي مصمم خصيصاً لحماية محلات الذهب، حيث يوضح كيفية ترابط المكونات المختلفة لتحقيق أقصى درجات الأمان. يبدأ النظام باستقبال البيانات من مصادر متعددة؛ فالكاميرا تزود وحدة Python بالمعلومات المرئية اللازمة لتشغيل خوارزميات الذكاء الاصطناعي والرؤية الحاسوبية مثل YOLO لاكتشاف الأسلحة، وRNN لتحليل أنماط العنف، بالإضافة إلى Mediapipe لرصد السلوكيات المشبوهة وحركات الدخلاء. في الوقت نفسه، يعمل حساس الحركة وحساس اللهب على تزويد NodeMCU بمعلومات فورية حول أي تحركات غير طبيعية أو مؤشرات حريق، مما يضيف طبقة أخرى من الاستشعار الفيزيائي. يتولى NodeMCU مسؤولية التنسيق بين هذه المدخلات المختلفة، سواء كانت قادمة من الحساسات المباشرة أو من مخرجات التحليلات المعقدة التي يجريها Python. وفي حال اكتشاف أي تهديد، سواء كان ذلك سلوكاً اختلاسياً عبر Mediapipe، أو وجود أسلحة، أو حركة مريبة، أو مؤشرات حريق، يقوم النظام بإصدار إنذار فوري داخل المحل وحفظ مقطع فيديو للحدث. بعد ذلك، يتولى NodeMCU مهمة إرسال تنبيه فوري ومفصل إلى صاحب المحل عبر Telegram Bot، يتضمن وصفاً للحدث ورابطاً للفيديو، لضمان الاستجابة السريعة حتى في غياب صاحب المحل.



الشكل 1-4: مخطط تكامل مكونات النظام.


3-4 المخططات التدفقية

1-3-4 المخطط التدفقي لعملية كشف الأسلحة




الشكل 4-2: المخطط التدفقي لعملية كشف الأسلحة.

2-3-4 المخطط التدفقي لعملية كشف العنف



الشكل 3-4: المخطط التدفقي لعملية كشف العنف.


3-3-4 المخطط التدفقي لعملية كشف الاختلاس والسرقة



الشكل 4-4: المخطط التدفقي لعملية كشف السرقة.


4-4 التطبيق العملي النهائي

لغرض التنفيذ العملي للنظام الأمني الذكي المصمم لحماية محلات الذهب، أُجريت مجموعة من التجارب لإثبات كفاءة المكونات المختلفة وقدرتها على العمل بتناغم. يوضح الشكل (4-5) توثيقاً بصرياً لاكتشاف سلوك مشبوه تم رصده بواسطة مكتبة Mediapipe. تظهر الصورة بدءاً داخل منطقة محظورة أو منطقة حساسة (ROI - Region of Interest)، ويبرز تنبيه واضح على الشاشة يحمل عبارة "ALERT: Hand in Restricted Area"، مما يؤكد دقة النظام في التعرف على محاولات الوصول غير المصرح بها إلى أماكن التخزين الحساسة داخل المحل، مثل الأدراج أو خزائن العرض، مما يقلل من مخاطر السرقة أو التلاعب.



الشكل 4-5: كشف حالة سرقة.


بالانتقال إلى الشكل (4-6)، نرى جانباً آخر من قدرات الرؤية الحاسوبية للنظام، حيث يعرض لقطة شاشة توثق اكتشاف أداة حادة. تُظهر الصورة شخصاً يحمل سكيناً، ويقوم النظام بتحديد السلاح بوضوح باستخدام خوارزمية YOLO التي تقوم بإحاطة السكين بمربع تحديد مع تصنيف "knife". هذا يؤكد الفعالية العالية للنظام في التعرف على الأسلحة تلقائياً، وهو أمر حيوي في بيئات مثل محلات الذهب حيث قد تكون الأسلحة جزءاً من محاولات السطو.



الشكل 4-6: كشف سلاح.

أما الشكل (4-7)، فيقدم دليلاً على قدرة النظام على اكتشاف حالات العنف وتحليل تسلسل الحركات باستخدام خوارزمية RNN. تُظهر الصورة مشهداً عنيفاً بين شخصين، ويظهر تنبيه على الشاشة يحمل عبارة "Violence Detected!"، مما يدل على كفاءة النظام في التعرف على أنماط العنف ضمن الفيديوهات، وهو ما يمكن أن يكون مؤشراً مبكراً على تطور موقف خطير داخل المحل.

أخيراً، يوضح الشكل (4-8) لقطة شاشة من واجهة المحادثة في تطبيق Telegram، حيث يتلقى صاحب المحل تنبيهات فورية (mo_wpa_bot). تعرض هذه التنبيهات رسائل نصية محددة مثل "تم اكتشاف حركة!"، "تم اكتشاف حالة عنف!"، و"تم اكتشاف سلاح!"، إلى جانب توقيت الكشف الدقيق، مما يبرهن على فعالية النظام في إرسال الإشعارات التلقائية والفورية في الوقت الفعلي عند رصد أي حدث أمني. مجتمعة، تثبت هذه اللقطات العملية القدرة الشاملة للنظام على التكامل بين الذكاء الاصطناعي، الرؤية الحاسوبية، والاستشعار الفيزيائي لتوفير بيئة أمنية لحظية وفعالة.



الشكل 4-7: كشف حالة عنف.



الشكل 4-8: إرسال التنبيهات إلى Telegram.

5-4 الخاتمة

يمثل هذا المشروع نظاماً أمنياً ذكياً ومتكاملاً مصمماً خصيصاً لتعزيز حماية محلات الذهب، حيث نجح في دمج تقنيات الذكاء الاصطناعي، الرؤية الحاسوبية، والاستشعار الفيزيائي بشكل فعال. أثبتت التجارب العملية كفاءة عالية في اكتشاف التهديدات المختلفة مثل الأسلحة، أنماط العنف، والسلوكيات المشبوهة، مع توفير استجابة سريعة وفورية من خلال الإنذارات وحفظ مقاطع الفيديو وإرسال التنبيهات عبر تطبيق Telegram. تسهم هذه المنظومة في بناء بيئة أمنية لحظية وفعالة، مما يعزز موثوقية الحماية في البيئات الواقعية.

6-4 الآفاق المستقبلية

- **قابلية التوسع والدمج في أنظمة حماية أكبر:** يمكن دمج هذا النظام كجزء من أنظمة أمنية مركزية أوسع نطاقاً، لا تقتصر على محلات الذهب فحسب، بل يمكن تطبيقها في المؤسسات الكبيرة، البنوك، أو المتاحف التي تتطلب مستويات عالية من الأمان.
- **تحسين دقة التعرف على الأنماط والسلوكيات:** يمكن تطوير الخوارزميات المستخدمة (YOLO، RNN، Mediapipe) لزيادة دقتها في ظل ظروف إضاءة مختلفة، زوايا رؤية متنوعة، أو مع وجود حشود، مما يقلل من الإنذارات الكاذبة ويزيد من فعالية الاكتشاف.
- **دمج تقنيات استشعار إضافية:** يمكن إضافة أنواع أخرى من الحساسات، مثل حساسات الصوت لاكتشاف أصوات معينة (مثل إطلاق النار أو تحطم الزجاج)، أو حساسات الضغط المدمجة في الأرضيات لاكتشاف الوزن غير الطبيعي في مناطق محددة.
- **تطوير واجهة مستخدم أكثر تفاعلية:** إنشاء لوحة تحكم (Dashboard) متقدمة توفر لصاحب المحل رؤية شاملة للوضع الأمني، مع خرائط حرارية للمناطق الأكثر خطورة، وتقارير تحليلية للسلوكيات المكتشفة على مدى فترات زمنية.
- **التعلم المستمر وتحسين الأداء:** تطوير آلية للتعلم المستمر من البيانات الجديدة (مثل حالات السرقة الفعلية أو التهديدات الجديدة) لتحديث نماذج الذكاء الاصطناعي تلقائياً وتحسين أدائها بمرور الوقت.
- **نظام استجابة متكامل:** توسيع قدرات الاستجابة لتشمل التواصل المباشر مع الشرطة أو شركات الأمن الخاصة، أو تفعيل آليات حماية مادية إضافية مثل إغلاق الأبواب والنوافذ تلقائياً، أو تفعيل أنظمة إخماد الحرائق المباشر.

المراجع

- [1] Afreen, H., Kashif, M., Shaheen, Q., Alfaifi, Y. H., & Ayaz, M. (2023). IoT-based smart surveillance system for high-security areas. *Applied Sciences*, 13(15), 8936
- [2] Sharma, H., & Kanwal, N. (2024). Smart surveillance using IoT: A review. *Radioelectronic and Computer Systems*, (1)109, 116.
- [3] Bharati, S., & Podder, P. (n.d.). Machine and deep learning for IoT security and privacy: Applications, challenges, and future directions. Institute of Information and Communication Technology (IICT), Bangladesh University of Engineering and Technology.
- [4] Robocraze. (n.d.). What is NodeMCU ESP8266? Robocraze. Retrieved July 24, 2025, from https://robocraze.com/blogs/post/what-is-nodemcu-esp8266?srsId=AfmBOooybBgSHwEYPplhbbZLgsiWDtOFIs4ZLSFRAUjtSdEn45aHk_Df#header-1
- [5] Last Minute Engineers. (n.d.). PIR sensor Arduino tutorial. Last Minute Engineers. Retrieved from <https://lastminuteengineers.com/pir-sensor-arduino-tutorial/>
- [6] SunFounder. (n.d.). Flame sensor module. SunFounder. Retrieved June 15, 2025, from https://docs.sunfounder.com/projects/ultimate-sensor-kit/en/latest/components_basic/03-component_flame.html#introduction
- [7] Khan, H. (2023, June 23). IR Flame Sensor Module. Datasheet Hub. Retrieved June 15, 2025, from https://www.datasheethub.com/ir-flame-sensor-module/#google_vignette
- [8] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

- [9] Sabokrou, M., Fayyaz, M., Fathy, M., & Klette, R. (2018). Deep-anomaly: Fully convolutional neural network for fast anomaly detection in crowded scenes. *Applied Intelligence*, 48(1), 289–302.
- [10] Feng, G., Li, Q., Chen, Y., & Zhao, Q. (2021). A hybrid CNN-RNN model for violence detection in video surveillance systems. *Sensors*, 21(8), 2835.
- [11] Wang, T., Liu, Z., & Zhang, J. (2022). Comparative analysis of RNN architectures with multi-layer attention mechanism for abnormal event detection in videos. *Discover Artificial Intelligence*, 2(1), 12.
- [12] Lee, H., & Choi, J. (2020). An RNN-based model for theft detection in shopping malls using surveillance video data. *PeerJ Computer Science*, 6, e293.
- [13] Datacamp. (n.d.). YOLO object detection explained. DataCamp. <https://www.datacamp.com/blog/yolo-object-detection-explained>
- [14] Shah, D. (2023, May 30). Intersection over Union (IoU): Definition, Calculation, Code. V7 Labs. <https://www.v7labs.com/blog/intersection-over-union-guide>
- [15] IBM. (n.d.). Recurrent neural networks (RNNs). IBM. Retrieved July 2, 2025, from <https://www.ibm.com/think/topics/recurrent-neural-networks>
- [16] Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2019). OpenPose: Realtime multi-person 2D pose estimation using part affinity fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(1), 172–186.