



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الوطنية الخاصة
قسم هندسة الحاسوب

مشروع فصلي بعنوان:

كشف الإصابات الرياضية من خلال تحليل الصور والفيديوهات

إعداد الطالبة:

سارة العموري

إشراف الدكتور المهندس:

أحمد رياض كردي

2026-2025

المخلص:

تتمثل فكرة هذا المشروع في تطوير نظام ذكي قادر على تحليل تمارين المقاومة والكشف عن الأخطاء الحركية التي قد تؤدي إلى إصابات عضلية هيكلية، وذلك من خلال الاعتماد على تقنيات الذكاء الاصطناعي والرؤية الحاسوبية. ينطلق المشروع من الحاجة إلى توفير أداة موضوعية منخفضة التكلفة تساعد الرياضيين على تقييم جودة أدائهم في غياب الإشراف المباشر من مدرب مختص.

هدفنا الرئيس كان بناء نموذج قادر على تحويل الفيديو إلى تمثيل عددي للحركة، ثم تحليل هذا التمثيل زمنيًا لاستخلاص حكم دقيق حول صحة الأداء. لتحقيق ذلك، قمنا باستخراج الهيكل العظمي للجسم من مقاطع الفيديو، ثم استخدمنا نموذجًا زمنيًا لتحليل تسلسل الحركة بدل الاكتفاء بلقطة منفردة.

أظهرت نتائج التنفيذ أن النظام قادر على التمييز بين الأداء الصحيح والخاطئ في التمارين المختارة ضمن ظروف تصوير مناسبة، مع استجابة شبه فورية في الزمن الحقيقي. تشير هذه النتائج إلى إمكانية الاستفادة من تقنيات التعلم العميق في دعم السلامة الرياضية والكشف المبكر عن الانحرافات الحركية، مع وجود مجال للتحسين والتطوير في المراحل المستقبلية.

الكلمات المفتاحية:

تحليل الحركة، الذكاء الاصطناعي، تقدير الوضعية البشرية، LSTM، تمارين المقاومة، كشف الأخطاء الحركية.

ABSTRACT:

This project aims to develop an intelligent system capable of analyzing resistance training exercises and detecting movement errors that may lead to musculoskeletal injuries, using artificial intelligence and computer vision techniques. The motivation behind this work is to provide an affordable and objective tool that assists athletes in evaluating their performance without direct professional supervision.

Our main objective was to build a model that converts video input into a numerical representation of human motion and analyzes it temporally to determine exercise correctness. To achieve this, skeletal body landmarks were extracted from video frames, and a temporal model was employed to evaluate the sequence of movement rather than isolated frames.

Experimental results demonstrate that the system can distinguish between correct and incorrect performance in selected exercises under appropriate recording conditions, with near real-time responsiveness. These findings highlight the potential of deep learning techniques in supporting sports safety through automated movement analysis, while leaving room for future improvements and scalability.

Keywords:

Motion Analysis, Artificial Intelligence, Human Pose Estimation, LSTM, Resistance Training, Movement Error Detection.

1	الفصل الأول: المقدمة
2	مقدمة عامة
4	دراسات سابقة
6	2 الفصل الثاني: التقنيات المعتمدة في تحليل الحركة والنمذجة الزمنية
7	1-2 مقدمة
7	2-2 تقدير الوضعية البشرية كأساس لاستخلاص البيانات الحركية
8	3-2 الشبكات العصبية الالتفافية (CNN) في تحليل الصور
8	1-3-2 البنية العامة لـ CNN
14	4-2 MediaPipe Pose ونموذج BlazePose
14	1-4-2 مراحل عمل MediaPipe Pose
16	5-2 التمثيل العددي للفيديو
17	6-2 الشبكات العصبية المتكررة (RNN)
18	1-6-2 مشكلة تلاشي وانفجار التدرج
19	7-2 شبكات الذاكرة طويلة وقصيرة المدى (Long Short-Term Memory – LSTM)
20	1-7-2 البنية الداخلية لخلية LSTM

22	LSTM في تحليل تمارين المقاومة
23	LSTM Autoencoder نموذج 3-7-2 في كشف أخطاء التمارين
27	LSTM الفرق بين LSTM العادي و LSTM Autoencoder 4-7-2
29	3 الفصل الثالث: تنفيذ النظام وآلية عمله
30	1-3 مقدمة
30	2-3 الأدوات البرمجية والمكتبات المستخدمة
31	3-3 البيانات المستخدمة في تدريب النموذج
33	4-3 مراحل عمل المشروع
38	5-3 التنفيذ العملي
45	4 الفصل الرابع: الاستنتاجات والمقترحات
49	5 المراجع

فهرس الأشكال

- الشكل (1-1): التمارين المعتمدة في المشروع المقترح..... 3
- الشكل (1-2): البنية العامة للشبكة العصبية الالتفافية (CNN)..... 9
- الشكل (2-2): آلية عمل المرشحات (Filters) في شبكات CNN..... 11
- الشكل (3-2): أشهر دوال التنشيط المستخدمة في الشبكات العصبونية..... 12
- الشكل (4-2): عملية التجميع..... 13
- الشكل (5-2): آلية عمل MediaPipe Pose..... 14
- الشكل (6-2): الهيكل العظمي الرقمي (Skeleton Representation)..... 16
- الشكل (7-2): تمثيل الشبكة العصبية المتكررة (RNN)..... 18
- الشكل (8-2): البنية الداخلية لخلية LSTM..... 19
- الشكل (9-2): بنية نموذج LSTM Autoencoder..... 25
- الشكل (1-3): منصة PixVerse AI..... 32
- الشكل (2-3): خوارزمية عمل مرحلة جمع البيانات..... 34
- الشكل (3-3): خوارزمية عمل مرحلة التدريب..... 35
- الشكل (4-3): خوارزمية عمل مرحلة الاختبار..... 37
- الشكل (5-3): مخطط سير الواجهات..... 38
- الشكل (6-3): الواجهة الرئيسية للنظام..... 39
- الشكل (7-3): واجهة اختيار مصدر الإدخال..... 40

الشكل (8-3): مثال على نتيجة التحليل. 41

الشكل (9-3): اكتشاف خطأ في تمرين squat. 42

الشكل (10-3): تجربة النظام في بيئة مختلفة. 42

الشكل (11-3): تغيير زاوية التصوير. 43

فهرس الجداول

الجدول (1-2): مقارنة بين LSTM التقليدي و LSTM Autoencoder 28

جدول الاختصارات

المعنى بالعربية	المصطلح بالإنجليزية	الاختصار
الذكاء الاصطناعي	Artificial Intelligence	AI
تعلم الآلة	Machine Learning	ML
التعلم العميق	Deep Learning	DL
الرؤية الحاسوبية	Computer Vision	CV
الشبكة العصبية الالتفافية	Convolutional Neural Network	CNN
الشبكة العصبية المتكررة	Recurrent Neural Network	RNN
الذاكرة طويلة وقصيرة المدى	Long Short-Term Memory	LSTM
الشبكة العصبية الاصطناعية	Artificial Neural Network	ANN
الشبكة العصبية العميقة	Deep Neural Network	DNN
واجهة المستخدم الرسومية	Graphical User Interface	GUI
ملف القيم المفصولة بفواصل	Comma-Separated Values	CSV
تقاطع على اتحاد	Intersection over Union	IoU
نموذج الألوان أزرق-أخضر-أحمر	Blue-Green-Red	BGR
نموذج الألوان أحمر-أخضر-أزرق	Red-Green-Blue	RGB

الفصل الأول: المقدمة

1-1 مقدمة عامة

يشهد المجال الرياضي تطورًا متسارعًا نتيجة التكامل بين علوم الحركة (Biomechanics) وتقنيات الذكاء الاصطناعي (Artificial Intelligence – AI)، حيث لم يعد الاهتمام منصبًا على تحسين الأداء البدني فقط، بل امتد ليشمل الوقاية من الإصابات العضلية الهيكلية وتحليل جودة الحركة بصورة موضوعية [1]. وقد ساهم تطور التعلم العميق (Deep Learning – DL) في إحداث نقلة نوعية في معالجة البيانات عالية الأبعاد مثل الصور والفيديو [2][3].


في هذا السياق، برزت تقنيات الرؤية الحاسوبية (Computer Vision – CV) التي تعتمد على معالجة الصور الرقمية (Digital Image Processing) لاستخلاص معلومات حركية من مقاطع الفيديو [4]. وقد تطورت خوارزميات تقدير الوضعية البشرية (Human Pose Estimation) لتُمكّن من تمثيل الجسم على شكل نقاط مرجعية (Landmarks) يمكن تتبعها عبر الزمن [5]. ومن بين النماذج الحديثة في هذا المجال نموذج BlazePose الذي يسمح بتتبع كامل للجسم في الزمن الحقيقي على أجهزة ذات موارد محدودة [6].

إلا أن تحليل كل إطار فيديو بصورة منفصلة لا يكفي لفهم جودة الأداء الحركي، لأن الحركة بطبيعتها عملية زمنية متسلسلة. ولهذا ظهرت الشبكات العصبية المتكررة (Recurrent Neural Networks – RNN) القادرة على نمذجة الاعتماديات الزمنية بين الإطارات المتتابة [8]. ونظرًا لمشكلة التدرج المتلاشي (Vanishing Gradient) في الشبكات التقليدية، تم تطوير شبكات

الذاكرة طويلة وقصيرة المدى (Long Short-Term Memory – LSTM) القادرة على الاحتفاظ بالمعلومات المهمة عبر الزمن وتحليل الأنماط المتسلسلة بكفاءة أعلى [9].

بناءً على ذلك، قمنا في هذا المشروع بتوظيف تقنيات الرؤية الحاسوبية لاستخلاص الهيكل العظمي الرقمي باستخدام MediaPipe Pose المبنى على BlazePose [6]، ثم قمنا بتحليل التسلسل الزمني للزوايا المفصلية باستخدام نموذج LSTM [9] بهدف التمييز بين الأداء الصحيح والانحرافات الحركية المحتملة.

اخترنا ثلاثة تمارين مقاومة شائعة هي تمرين القرفصاء (Squat)، وتمرين العضلة ثنائية الرؤوس (Bicep Curl)، وتمرين الرفرفة الجانبية أو رفع الأكتاف الجانبي (Lateral Raises)، نظرًا لاختلاف متطلباتها الميكانيكية وحساسيتها للإصابة وفق الأدبيات البيوميكانيكية [10][11].



الشكل (1-1): التمارين المعتمدة في المشروع المقترح.

هدفنا من خلال هذا العمل إلى رصد الانحرافات الحركية الخطرة وتقديم تغذية راجعة فورية تساعد على تصحيح الأداء، مع التركيز على الجانب الوقائي بدل الاكتفاء بالتقييم بعد حدوث الإصابة.

ويقتصر نطاق هذا العمل على التحليل الكينماتيكي ثنائي الأبعاد (2D Kinematic Analysis)، ولا يمتد إلى التشخيص الطبي السريري أو أنظمة الالتقاط الحركي ثلاثية الأبعاد.

يتكون البحث من عدة فصول؛ يعرض الفصل الثاني المفاهيم النظرية الأساسية، ويتناول الفصل الثالث تقنية تقدير الوضعية باستخدام MediaPipe Pose، بينما يشرح الفصل الرابع النمذجة الزمنية باستخدام LSTM، ثم يعرض الفصل الخامس تنفيذ النظام، ويختتم الفصل السادس بعرض النتائج والمناقشة.

2-1 دراسات سابقة

شهد مجال تقدير الوضعية البشرية تطورًا ملحوظًا مع ظهور نماذج تعتمد على الشبكات العصبية الالتفافية (CNN) لاستخلاص المفاصل من الصور، كما في OpenPose [5]. وقد ساهمت التطورات اللاحقة في تحسين سرعة ودقة النماذج لتعمل في الزمن الحقيقي، كما في BlazePose [6].

في المقابل، ركزت أبحاث تحليل السلاسل الزمنية على تطوير نماذج قادرة على تمثيل الاعتماديات طويلة المدى، حيث أثبتت LSTM فعاليتها مقارنة بالشبكات المتكررة التقليدية [8][9].

أما في المجال البيوميكانيكي، فقد أكدت الدراسات أهمية الالتزام بالزوايا الصحيحة أثناء تمارين المقاومة لتجنب الإصابات المزمنة [10][11].

انطلاقًا من ذلك، يهدف هذا المشروع إلى دمج هذه المحاور ضمن إطار تطبيقي موحد لتحليل جودة الأداء الحركي في التمارين الرياضية.

الفصل الثاني : التقنيات المعتمدة في تحليل الحركة والنمذجة الزمنية

1-2 مقدمة

يعتمد النظام المقترح لتحليل تمارين المقاومة على تحويل الحركة البشرية من تمثيل بصري إلى تمثيل عددي قابل للمعالجة الخوارزمية. ويتحقق ذلك عبر مرحلتين مترابطتين: استخراج التمثيل الهيكلي للجسم باستخدام تقنيات تقدير الوضعية البشرية (Human Pose Estimation)، ثم تحليل هذا التمثيل زمنيًا باستخدام نموذج شبكي قادر على تعلّم الاعتماديات الزمنية.

يندرج هذا الإطار ضمن مجال الذكاء الاصطناعي (Artificial Intelligence – AI) الذي يهدف إلى بناء أنظمة قادرة على التعلم واتخاذ القرار [1]، ويعتمد تحديدًا على تقنيات التعلم العميق (Deep Learning – DL) التي تمكّن النماذج من استخلاص السمات تلقائيًا من البيانات الخام [3][5].

2-2 تقدير الوضعية البشرية كأساس لاستخلاص البيانات الحركية

يهدف تقدير الوضعية البشرية إلى تحديد مواقع المفاصل الرئيسية في جسم الإنسان داخل صورة أو فيديو، وتمثيلها كنقاط مرجعية (Landmarks) مترابطة [6]. ويُعد هذا التمثيل أساس التحليل الحركي، إذ يسمح بحساب الزوايا بين المفاصل وتقييم محاذاة الأطراف.


تعتمد النماذج الحديثة لتقدير الوضعية على الشبكات العصبية الالتفافية (Convolutional Neural Networks – CNN)، وهي نوع من الشبكات العميقة المصممة لمعالجة البيانات المكانية مثل الصور [3][5].

3-2 الشبكات العصبية الالتفافية (CNN) في تحليل الصور

1-3-2 البنية العامة لـ CNN

تُعد الشبكات العصبية الالتفافية (Convolutional Neural Networks – CNNs) من أهم النماذج التي أحدثت تحولًا جذريًا في مجال الرؤية الحاسوبية، إذ صُممت خصيصًا للتعامل مع البيانات ذات البنية المكانية المنتظمة مثل الصور والفيديوهات. وعلى خلاف الشبكات العصبية التقليدية التي تتعامل مع المدخلات كمتجهات مسطحة (Flattened Vectors)، تحافظ CNN على البنية ثنائية الأبعاد للصورة، مما يسمح لها باستغلال العلاقات المكانية بين البكسلات المجاورة [7][9].

يمكن النظر إلى CNN على أنها نظام هرمي لاستخلاص السمات (Hierarchical Feature Extractor)، حيث تمر الصورة عبر سلسلة من الطبقات، كل طبقة مسؤولة عن استخراج مستوى معين من التمثيل البصري، بدءًا من السمات الأولية وصولًا إلى الأنماط المعقدة.



الشكل (1-2): البنية العامة للشبكة العصبية الالتفافية (CNN).

أولاً: طبقة الالتفاف (Convolution Layer)

جوهر CNN يكمن في عملية الالتفاف (Convolution)، وهي عملية رياضية يمكن تمثيلها بالشكل التالي:

إذا كانت الصورة ممثلة بالمصفوفة I ، وكان المرشح ممثلًا بالمصفوفة K ، فإن ناتج الالتفاف عند الموضع (i, j) يُعطى بـ:

$$S(i, j) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} I(i + m, j + n) \cdot K(m, n) \quad (1-2)$$

تمثل هذه العملية ضربًا تجميعيًا بين جزء محلي من الصورة والمرشح، وينتج عنها خريطة سمات (Feature Map).

هذه العملية لها خصائص مهمة:

1. التركيز المحلي (Local Receptive Field):

كل مرشح ينظر فقط إلى جزء صغير من الصورة، ما يسمح باكتشاف الأنماط المحلية مثل الحواف والزوايا.


2. مشاركة الأوزان (Weight Sharing):

نفس المرشح يُستخدم عبر كامل الصورة، مما يقلل عدد المعاملات بشكل كبير مقارنة بالشبكات التقليدية.

3. الثبات تجاه الإزاحة (Translation Invariance):

إذا تحرك النمط قليلاً داخل الصورة، يبقى المرشح قادرًا على اكتشافه. في سياق المشروع، تسمح هذه الطبقات باكتشاف:

- حدود الأطراف.
- التباين بين الجسم والخلفية.
- الاتجاه العام للأطراف.
- البنية الأولية للمفاصل.



الشكل (2-2): آلية عمل المرشحات (Filters) في شبكات CNN.

ثانيًا: دالة التنشيط (Activation Function)





بعد الالتفاف، يتم تمرير الناتج عبر دالة تنشيط غير خطية مثل:

$$ReLU(x) = \max(0, x) \quad (2-2)$$

تكمُن أهمية اللاخطية في أن العلاقات بين البكسلات والمفاصل ليست خطية. فالحركة البشرية

تتضمن تغيرات معقدة في الزوايا والمسافات، ولا يمكن تمثيلها بدوال خطية بسيطة.

ReLU تمنع تشبع التدرج، وتُسرع التدريب مقارنة بالدوال التقليدية مثل Sigmoid و Tanh [7].

Sigmoid	Tanh	ReLU	Leaky ReLU
$g(z) = \frac{1}{1 + e^{-z}}$	$g(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$g(z) = \max(0, z)$	$g(z) = \max(\epsilon z, z)$ with $\epsilon \ll 1$
			

الشكل (3-2): أشهر دوال التنشيط المستخدمة في الشبكات العصبونية.

ثالثاً: طبقة التجميع (Pooling Layer)

تعمل طبقات التجميع على تقليل الأبعاد المكانية لخرائط السمات، وغالباً ما يتم استخدام Max


:Pooling

$$P(i, j) = \max_{(m, n) \in R} S(m, n) \quad (3-2)$$

حيث R تمثل المنطقة الفرعية.

الفائدة ليست فقط تقليل الأبعاد، بل أيضاً:

- زيادة ثبات النموذج أمام التغيرات الصغيرة.
- تقليل الضجيج.
- منع الاعتماد المفرط على تفاصيل دقيقة غير مهمة.



الشكل (4-2): عملية التجميع.

رابعًا: الطبقات كاملة الاتصال (Fully Connected Layers)

بعد عدة طبقات التفاف وتجميع، يتم تسطيح (Flattening) خرائط السمات وتحويلها إلى متجه يُمرر إلى طبقات Fully Connected.

هذه الطبقات تقوم بدمج جميع السمات المستخرجة لتكوين القرار النهائي.

في حالة BlazePose داخل MediaPipe، لا يكون القرار تصنيفًا تقليديًا، بل تقدير إحداثيات مفاصل:

$$(x_i, y_i, z_i) \quad (4-2)$$

لكل مفصل i ، وهنا تنتقل الصورة من تمثيل بكسلي إلى تمثيل هندسي للحركة.


BlazePose ونموذج MediaPipe Pose 4-2

يُعد نموذج BlazePose المعتمد ضمن إطار MediaPipe Pose أحد أكثر النماذج تطورًا في مجال تقدير الوضعية البشرية في الزمن الحقيقي. وقد تم تصميمه لتحقيق توازن دقيق بين السرعة الحسابية والدقة الهندسية، مما يجعله مناسبًا للتطبيقات العملية مثل تحليل الأداء الرياضي على أجهزة ذات موارد محدودة [7].

يعتمد MediaPipe على بنية رسومية (Graph-Based Architecture)، حيث يتم تمثيل كل عملية معالجة كعقدة (Node)، ويتم تمرير البيانات بين العقد عبر تدفقات (Streams) ضمن خط معالجة متكامل (Pipeline). تسمح هذه البنية بتقسيم العمليات إلى مراحل مستقلة يمكن تحسينها أو استبدالها دون التأثير على كامل النظام.

في سياق المشروع، يقوم MediaPipe Pose بتحويل كل إطار فيديو إلى مجموعة نقاط مرجعية عديدة تمثل مفاصل الجسم، مما يمهد الطريق لتحليل الحركة رياضيًا وزمنيًا.

1-4-2 مراحل عمل MediaPipe Pose



الشكل (5-2): آلية عمل MediaPipe Pose.

تمر عملية التقدير بمرحلتين:

أولاً: مرحلة كشف الجسم (Pose Detection Stage)

في هذه المرحلة، يتم تحديد موضع الشخص داخل الإطار.

تعتمد هذه الخطوة على نموذج خفيف الوزن مشتق من BlazeFace، يسمح بتحديد:

- موقع الجسم داخل الصورة.
- صندوق الإحاطة (Bounding Box).
- الاتجاه العام للجسم.

هذه المرحلة ضرورية لتقليل مساحة المعالجة، حيث يتم قص المنطقة التي تحتوي على الشخص فقط، مما يقلل العبء الحسابي ويحسن سرعة الأداء.

ثانياً: مرحلة تقدير المعالم (Landmark Estimation Stage)

بعد تحديد منطقة الجسم، يتم تمريرها إلى نموذج تقدير المعالم، الذي يقوم باستخراج:


- 33 نقطة مرجعية.
- إحداثيات ثلاثية الأبعاد (x, y, z) .
- قيمة ثقة (Visibility Score).

تمثل الإحداثيات (x, y) الموضع النسبي داخل الإطار، بينما تمثل z العمق النسبي بالنسبة للكاميرا.

يمكن تمثيل مجموعة المعالم في إطار واحد بالشكل:

$$L_t = \{(x_i, y_i, z_i)\}_{i=1}^{33} \quad (5-2)$$

حيث t هو الزمن (رقم الإطار)، و i يمثل رقم المفصل.



الشكل (6-2): الهيكل العظمي الرقمي (Skeleton Representation).

5-2 التمثيل العددي للفيديو

بعد استخراج المعالم لكل إطار، يتحول الفيديو من سلسلة صور إلى سلسلة متجهات عددية.

إذا كان لدينا T إطارًا، فإن التمرين يُمثل بالمصفوفة الزمنية:

$$X = \begin{bmatrix} L_1 \\ L_2 \\ L_3 \end{bmatrix} \quad (6-2)$$

أي أن:

$$X \in \mathbb{R}^{T \times (33 \times 3)} \quad (7-2)$$

حيث يمثل كل صف متجهًا بطول 99 قيمة عددية (33 نقطة × 3 إحداثيات).

بهذا الشكل، يصبح التمرين الرياضي سلسلة زمنية متعددة الأبعاد (Multivariate Time Series)، يمكن تحليلها باستخدام نماذج مخصصة للبيانات المتسلسلة.

هذا التحويل هو النقطة المحورية التي تنتقل فيها المعالجة من المجال المكاني إلى المجال الزمني.

6-2 الشبكات العصبية المتكررة (RNN)

نظرًا لأن الحركة بطبيعتها عملية زمنية، فإن تحليل كل إطار بصورة منفصلة يؤدي إلى فقدان السياق. لذلك ظهرت الشبكات العصبية المتكررة (Recurrent Neural Networks – RNNs) لمعالجة البيانات المتسلسلة [9].

تعتمد RNN على فكرة تمرير الحالة السابقة إلى الخطوة الحالية.

عند الزمن t ، تستقبل الشبكة:

- المدخل الحالي x_i .
- الحالة السابقة h_{t-1} .

وتنتج الحالة الجديدة:


$$h_t = \tanh (W_x x_t + W_h h_{t-1} + b) \quad (8-2)$$

حيث:

W_x : أوزان المدخل.

W_h : أوزان الحالة السابقة.

b : الانحياز.



الشكل (7-2): تمثيل الشبكة العصبية المتكررة (RNN).

1-6-2 مشكلة تلاشي وانفجار التدرج

أثناء عملية الانتشار العكسي عبر الزمن (Backpropagation Through Time – BPTT)، يتم

ضرب التدرجات عدة مرات عبر المصفوفات.

- إذا كانت القيم أصغر من 1 ← تتلاشى التدرجات.
- إذا كانت أكبر من 1 ← تنفجر التدرجات.


تؤدي مشكلة تلاشي التدرج إلى فقدان القدرة على تعلم الاعتماديات طويلة المدى، وهو أمر حرج في تحليل تمارين مثل السكوات، حيث يعتمد الحكم على تسلسل الحركة بالكامل.

لهذا السبب تم تطوير LSTM [8].

7-2 شبكات الذاكرة طويلة وقصيرة المدى (Long Short-Term Memory – LSTM)

(LSTM)

تُعد LSTM نوعًا خاصًا من RNN، صُممت خصيصًا لمعالجة مشكلة الاعتماديات طويلة المدى. بدلًا من تحديث الحالة بشكل مباشر، تُدخل LSTM مفهوم خلية الذاكرة (Cell State) والبوابات.



الشكل (8-2): البنية الداخلية لخلية LSTM.

1-7-2 البنية الداخلية لخلية LSTM

تتكون خلية LSTM من أربع مكونات رئيسية تعمل معًا للتحكم في تدفق المعلومات عبر الزمن:

- بوابة النسيان (Forget Gate)
- بوابة الإدخال (Input Gate)
- بوابة الإخراج (Output Gate)
- حالة الخلية (Cell State)

يمكن فهم آلية عمل LSTM على أنها نظام تحكم ذكي يقرر في كل لحظة:

- ما الذي يجب الاحتفاظ به من الماضي؟
- ما الذي يجب إضافته من الحاضر؟
- وما الذي يجب إظهاره كمخرج في هذه اللحظة؟

أولاً: بوابة النسيان (Forget Gate)

وظيفة بوابة النسيان هي تحديد مقدار المعلومات السابقة التي يجب الاحتفاظ بها أو حذفها.

فليست كل المعلومات القديمة مفيدة دائماً، ولذلك تقوم هذه البوابة بتقييم الذاكرة السابقة

وتقرر ما إذا كان ينبغي استمرارها أو تجاهلها.

في سياق تحليل التمارين، قد تكون بعض الحركات السابقة غير مؤثرة على التقييم الحالي، فتقوم

الشبكة بتقليل تأثيرها تدريجيًا.

ثانيًا: بوابة الإدخال (Input Gate)

تحدد بوابة الإدخال كمية المعلومات الجديدة التي سيتم إضافتها إلى ذاكرة الخلية. فليس كل تغير في الحركة يستحق أن يُخزّن في الذاكرة طويلة المدى. لذلك تقوم هذه البوابة بتقييم المدخل الحالي (مثل زاوية مفصل معينة) وتقرر مدى أهميته. بمعنى آخر، تقوم هذه البوابة بتحديث الذاكرة بالمعلومات المهمة فقط.

ثالثًا: حالة الخلية (Cell State)

تُمثل حالة الخلية الذاكرة طويلة المدى للنموذج. يمكن تصورها كمسار ممتد عبر الزمن تنتقل خلاله المعلومات المهمة دون أن تتعرض لتلاشي سريع.

تُحدّث هذه الحالة في كل خطوة زمنية بناءً على قرارات بوابة النسيان وبوابة الإدخال، مما يسمح بتراكم المعلومات المفيدة عبر الزمن.

رابعًا: بوابة الإخراج (Output Gate)

تحدد بوابة الإخراج الجزء من المعلومات المخزّنة الذي سيتم استخدامه لإنتاج المخرج في اللحظة الحالية.

فقد تحتوي الذاكرة على معلومات كثيرة، لكن ليس من الضروري استخدام جميعها في كل خطوة.

وبذلك تتحكم هذه البوابة فيما إذا كانت المعلومات السابقة ستؤثر مباشرة على القرار الحالي أم لا.

تعمل هذه المكونات معًا لضمان بقاء المعلومات المهمة لفترات طويلة دون أن تتلاشى، وهو ما يجعل LSTM قادرة على تعلّم الاعتماديات الزمنية المعقدة [8].

2-7-2 دور LSTM في تحليل تمارين المقاومة

في تحليل تمارين المقاومة، لا يكفي تقييم زاوية مفصل في إطار واحد فقط.

فعلى سبيل المثال، في تمرين القرفصاء (Squat)، يجب تحليل تسلسل الحركة بالكامل بدءًا من النزول، مرورًا بأدنى نقطة، وصولًا إلى الصعود مرة أخرى.

قد تبدو زاوية الركبة صحيحة في لحظة معينة، لكن عند النظر إلى تطورها عبر الزمن قد يظهر خلل في التوازن أو عدم استقرار في الحركة. وهنا تكمن أهمية LSTM، إذ تسمح بتحليل النمط الحركي الكامل بدلًا من الحكم على لقطة منفردة.

ورغم ظهور نماذج المحولات (Transformers) المعتمدة على آلية الانتباه (Attention) [12]، فإن LSTM ما تزال مناسبة للأنظمة ذات البيانات المحدودة أو التي تتطلب معالجة تسلسلية خطوة بخطوة، كما في تحليل الفيديو الحركي.

2-7-3 نموذج LSTM Autoencoder في كشف أخطاء التمارين

بعد استعراض البنية التقليدية لشبكات LSTM ودورها في تحليل التسلسل الزمني للحركة، يبرز نموذج أكثر تقدمًا في النمذجة الزمنية يُعرف باسم LSTM Autoencoder، وهو نموذج يجمع بين القدرة الزمنية لشبكات LSTM وفلسفة التعلم غير المراقب التي يعتمد عليها Autoencoder. يستند هذا النموذج إلى فرضية جوهرية مفادها أن الحركة الصحيحة تمتلك بنية زمنية منتظمة يمكن تعلمها وضغطها وإعادة بنائها بدقة، في حين أن الحركة الخاطئة تُحدث اضطرابًا في هذا النسق الزمني، ما يؤدي إلى صعوبة في إعادة بنائها بنفس الكفاءة.

2-7-3-1 المفهوم العام للنموذج

يتكوّن LSTM Autoencoder من جزأين رئيسيين مترابطين:

- جزء أول يُسمى Encoder
- جزء ثانٍ يُسمى Decoder

يقوم الـ Encoder باستقبال تسلسل زمني كامل يمثل تمرينًا رياضيًا (مثل تسلسل زوايا الركبة والورك في السكوات)، ويقوم بضغط هذا التسلسل إلى تمثيل عددي مختصر يُعرف باسم Context Vector أو التمثيل الكامن (Latent Representation).

هذا التمثيل لا يحتوي على كل التفاصيل اللحظية، بل يحتفظ بالخصائص الزمنية الجوهرية للحركة، مثل:

- النمط العام للانحناء
- الاتساق في التكرار
- التوازن بين الأطراف
- التسارع والتباطؤ الطبيعي

بعد ذلك، يقوم الـ Decoder باستقبال هذا التمثيل المضغوط ومحاولة إعادة توليد التسلسل الأصلي.

إذا رمزنا للتسلسل الزمني بـ:

$$X = (x_1, x_2, \dots, x_T) \quad (9-2)$$

فإن الـ Encoder يحوله إلى:

$$h = f(X) \quad (10-2)$$

ثم يقوم الـ Decoder بإعادة توليد:


$$X' = g(h) \quad (11-2)$$

ويتم حساب الفرق بين التسلسل الأصلي والمعاد بناؤه عبر دالة خسارة تُعرف باسم

:Reconstruction Error

$$Loss = \|X - X'\|_2 \quad (12-2)$$

كلما كان الفرق صغيرًا، دلّ ذلك على أن الحركة تتبع النمط الذي تعلمه النموذج. أما إذا كان الفرق كبيرًا، فهذا يعني أن الحركة تحتوي على انحراف غير مألوف.



الشكل (2-9): بنية نموذج LSTM Autoencoder.

2-3-7-2 لماذا يُعد هذا النموذج مهمًا في مشروع كشف الأخطاء؟

في مشروع تحليل التمارين الرياضية، غالبًا ما يكون جمع بيانات خاطئة بجودة عالية أمرًا صعبًا، لأن الأخطاء الحركية:

- متعددة
- متفاوتة
- وغير منظمة

هنا تظهر قوة LSTM Autoencoder، إذ يمكن تدريبه فقط على الحركات الصحيحة.

أي أن النموذج يتعلم “الشكل الطبيعي” للحركة.

عند إدخال تمرين خاطئ:

- لن يتمكن النموذج من إعادة بناء التسلسل بدقة.
- سيظهر Reconstruction Error مرتفع.
- يتم اعتبار التمرين حالة شذوذ (Anomaly).

هذا النهج يُعرف باسم: Anomaly Detection Approach وهو مختلف جذريًا عن أسلوب التصنيف التقليدي.

2-3-7-3 مثال تطبيقي

عند إدخال سكوات صحيح:

- التسلسل الزمني للزوايا يتبع نمطًا منتظمًا.
 - النموذج يعيد بناء الحركة بدقة.
 - Reconstruction Error منخفض.
- أما إذا كانت الركبة تتقدم للأمام بشكل مبالغ فيه:
- يتغير النمط الزمني.
 - يظهر خلل في تمثيل الحركة الكامن.
 - يفشل النموذج في إعادة البناء بدقة.
 - Reconstruction Error يرتفع.

وبتحديد عتبة (Threshold) مناسبة، يمكن للنظام إصدار تنبيه تلقائي.

2-7-3-4 التحديات المرتبطة بالنموذج

رغم قوته، يواجه النموذج عدة تحديات:

- الحاجة إلى بيانات تدريب نظيفة ومتوازنة.
- احتمال الخلط بين البطء في الأداء والخطأ الحقيقي.
- ضرورة ضبط قيمة Threshold بدقة لتجنب الإنذارات الكاذبة.

لكن عند تطبيقه على بيانات Skeleton الناتجة من MediaPipe، يكون مناسبًا جدًا، لأن البيانات تكون:

- منخفضة الأبعاد
- عددية
- مستقرة هندسيًا
- ممثلة للحركة مباشرة دون تشويش بصري

2-7-4 الفرق بين LSTM العادي و LSTM Autoencoder

بعد استعراض نموذج LSTM التقليدي ونموذج LSTM Autoencoder، يصبح من الضروري توضيح الفروق الجوهرية بينهما من حيث الهدف، طبيعة التعلم، وآلية الاستخدام في تحليل التمارين الرياضية. فعلى الرغم من أن كلا النموذجين يعتمدان على البنية الزمنية لشبكات LSTM، إلا أن فلسفة الاستخدام تختلف جذريًا بين التصنيف المباشر وإعادة البناء لاكتشاف الشذوذ. ويوضح الجدول التالي الفروقات الأساسية بين النموذجين:

LSTM Autoencoder	LSTM التقليدي	وجه المقارنة
تعلم غير مُراقب (Unsupervised)	غالبًا تعلم مُراقب (Supervised)	نوع التعلم
إعادة بناء التسلسل الزمني	تصنيف أو تنبؤ بالحركة	الهدف الأساسي
تسلسل مُعاد بناؤه	فئة (صحيح/خاطئ) أو قيمة متوقعة	طبيعة المخرجات
لا، يكفي التدريب على الحركات الصحيحة	نعم، لتدريب النموذج على التصنيف	الحاجة لبيانات خاطئة
ارتفاع Reconstruction Error	قرار تصنيفي مباشر	آلية كشف الخطأ
كشف الانحرافات الحركية والشذوذ	تحديد نوع التمرين أو مرحلته	الاستخدام في المشروع
عالية جدًا في اكتشاف الانحرافات الصغيرة	متوسطة	الحساسية للأخطاء الدقيقة

الجدول (1-2): مقارنة بين LSTM التقليدي وLSTM Autoencoder.

الفصل الثالث: تنفيذ النظام وآلية عمله

1-3 مقدمة

في هذا الفصل نعرض الجانب التطبيقي للمشروع، حيث قمنا بتحويل الإطار النظري المعروض في الفصل السابق إلى نظام عملي متكامل قادر على تحليل التمارين الرياضية واكتشاف الأخطاء الحركية اعتمادًا على تقنيات تقدير الوضعية والنمذجة الزمنية.

اعتمدنا في تنفيذ النظام على تكامل مجموعة من الأدوات البرمجية والمكتبات المتخصصة، ونظمنا العمل ضمن أربع مراحل رئيسية مترابطة: تصميم الواجهات، جمع البيانات، تدريب النموذج، واختبار النظام وتشغيله في الزمن الحقيقي.

2-3 الأدوات البرمجية والمكتبات المستخدمة

اعتمدنا في تنفيذ النظام على عدد من المكتبات البرمجية، حيث أسندنا لكل مكتبة دورًا محددًا ضمن سلسلة المعالجة الكاملة.

استخدمنا مكتبة Tkinter لتطوير الواجهة الرسومية (Graphical User Interface – GUI) [13]، مما مكّننا من إنشاء بيئة تفاعلية تتيح للمستخدم اختيار مصدر الإدخال وتشغيل عملية التحليل بسهولة. كما استخدمنا وحدة filedialog لتحميل ملفات الفيديو بطريقة مرنة [14].

في مرحلة معالجة البيانات المرئية، اعتمدنا على مكتبة OpenCV (cv2) لاستخراج الإطارات وقراءتها إطارًا بإطار، إضافة إلى تنفيذ عمليات التحويل اللوني والمعالجة الأولية [17].. كما استخدمنا مكتبة Pillow (PIL) لتحسين عرض الصور داخل الواجهة الرسومية [16].

لاستخراج الخصائص الحركية، استخدمنا مكتبة MediaPipe لاستخراج النقاط المرجعية للجسم (Pose Landmarks) [19] [20]، والتي تمثل الأساس العددي لتحليل الحركة. بعد ذلك قمنا بمعالجة هذه القيم وتحويلها إلى مصفوفات عددية باستخدام مكتبة NumPy [21].

أما في مرحلة النمذجة، فقد استخدمنا TensorFlow وواجهة Keras لتحميل النموذج المدرب وتنفيذ عمليات التنبؤ [22][23]. كما استخدمنا مكتبة Joblib لحفظ واسترجاع النماذج [24]، ووظفنا مكتبة threading لضمان عدم تجمّد الواجهة أثناء تنفيذ العمليات الحسابية [15].

شكّل هذا التكامل البرمجي منظومة متكاملة تبدأ من إدخال البيانات وتنتهي بعرض النتيجة للمستخدم.

3-3 البيانات المستخدمة في تدريب النموذج

اعتمدنا في هذا المشروع على مجموعة بيانات متنوعة ومتعددة المصادر بهدف بناء نموذج يتمتع بقدرة أعلى على التعميم ودقة أفضل في كشف أخطاء أداء التمارين الرياضية. وقد حرصنا على تنويع مصادر البيانات لضمان تمثيل واسع لمختلف أنماط الأداء الحركي، سواء الصحيح أو الخاطئ، بما يعكس سيناريوهات الاستخدام الواقعية للنظام.

تضمنت البيانات المستخدمة فيديوهات حقيقية تم تصويرها خصيصًا لأشخاص يؤدّون التمارين الرياضية بطرق صحيحة وأخرى خاطئة. أتاح هذا النوع من البيانات الواقعية للنموذج التعرّف على الفروقات الدقيقة في وضعية الجسم، وزوايا المفاصل، وتسلسل الحركة بين الأداء السليم وغير

السليم. وأسهمت هذه المقاطع في تمكين النموذج من التعامل مع أنماط حركة قريبة من بيئة التطبيق الفعلية.

إضافة إلى ذلك، قمنا باستخدام فيديوهات مولدة بالذكاء الاصطناعي عبر منصة PixVerse AI، حيث تم توليد مشاهد تدريبية تمثل أنماطًا حركية متنوعة وأخطاء أداء محددة. أسهم هذا النوع من البيانات في زيادة تنوع العينات وتقليل انحياز النموذج لنمط بصري واحد، كما أتاح لنا التحكم في نوع الخطأ الحركي وشدته، وهو ما يصعب تحقيقه بصورة دقيقة عند الاعتماد الحصري على التصوير اليدوي.




الشكل (1-3): منصة PixVerse AI.

كما استعنا بمجموعات بيانات مفتوحة المصدر من منصة Kaggle، والتي تحتوي على فيديوهات وتمثيلات حركية لتمرين رياضية مختلفة. ساعدت هذه البيانات في توسيع نطاق التنوع من حيث زوايا التصوير، وظروف الإضاءة، والخلفيات، وأنماط الأجسام، مما عزز من قدرة النموذج على التعميم عند اختبارها على بيانات لم يسبق له التدريب عليها.

إن الجمع بين البيانات المصوّرة الواقعية، والبيانات المولّدة بالذكاء الاصطناعي، ومجموعات البيانات المفتوحة المصدر، مكّننا من بناء قاعدة بيانات متوازنة نسبيًا من حيث تنوع الأمثلة وأنماط الأداء. وقد انعكس هذا التنوع إيجابيًا على عملية التدريب، حيث ساعد في تقليل احتمالية فرط التعلّم (Overfitting) وتحسين موثوقية النموذج في كشف الأخطاء الحركية ضمن بيانات مختلفة.


3-4 مراحل عمل المشروع

بدأ العمل بمرحلة جمع البيانات، كما هو موضح في الشكل (3-1). في هذه المرحلة قمنا بتهيئة مكتبة MediaPipe ثم فتح مجلد البيانات الذي يحتوي على الفيديوهات التدريبية. اعتمدنا على حلقة تكرارية لمعالجة الفيديوهات واحدًا تلو الآخر، حيث تم قراءة كل فيديو إطارًا بإطار وتميرد الإطارات إلى خوارزمية MediaPipe لاستخراج النقاط المرجعية المطلوبة. بعد استخراج الإحداثيات اللازمة، قمنا بتجميع النقاط المهمة وتخزينها في قائمة تمثل التسلسل الزمني للحركة. استمرت هذه العملية حتى تم المرور على جميع الفيديوهات داخل مجلد البيانات، وعند اكتمالها قمنا بتحويل قائمة المعلومات إلى ملف بصيغة CSV يحتوي على التمثيل العددي المنظم للحركات، ليشتكّل هذا الملف قاعدة البيانات التي يعتمد عليها النموذج في مرحلة التدريب.



الشكل (2-3): خوارزمية عمل مرحلة جمع البيانات.

انتقلنا بعد ذلك إلى مرحلة التدريب، المبينة في الشكل (2-3).




الشكل (3-3): خوارزمية عمل مرحلة التدريب.

قمنا بتحميل ملف البيانات بصيغة CSV واستخراج المعلومات المطلوبة، ثم أجرينا عمليات تنظيف البيانات ومعالجتها بما يضمن جاهزيتها للإدخال إلى النموذج. بعد تجهيز البيانات قمنا بتهيئة النموذج وبناء البنية الشبكية المعتمدة على طبقات LSTM لتحليل التسلسل الزمني


لنقاط الحركة. تم تدريب النموذج على البيانات المتاحة بهدف تمكينه من التمييز بين الأداء الصحيح والخاطئ في التمارين الرياضية، وبعد انتهاء عملية التدريب قمنا بحفظ النموذج المدرب لاستخدامه لاحقاً في مرحلة الاختبار.

تمثل المرحلة الثالثة مرحلة الاختبار والتشغيل، كما يوضح الشكل (3-3). في هذه المرحلة قمنا بتحميل النموذج المدرب وتهيئة مكتبة MediaPipe مجدداً. عند تشغيل النظام يتم قراءة الفيديو أو بث الكاميرا، ثم يُؤخذ كل إطار ويُمرر إلى MediaPipe لاستخراج النقاط المرجعية. بعد استخراج المعلومات المطلوبة يتم تمريرها إلى النموذج المدرب لإجراء عملية التنبؤ، ثم تُعرض النتيجة مباشرة. تستمر هذه العملية ضمن حلقة تكرارية حتى انتهاء الإطارات الخاصة بالفيديو أو إيقاف التشغيل، وهو ما يعكس التكامل بين استخراج الخصائص الحركية والتحليل الزمني وإظهار نتائج التصنيف في الزمن الحقيقي.

وأخيراً، وبعد التأكد من سلامة عمل النظام خوارزمياً، قمنا بتطوير الواجهة الرسومية، كما هو موضح في الشكل (3-4). صُممت الواجهة باستخدام مكتبة Tkinter لتوفير بيئة تفاعلية تمكّن المستخدم من اختيار مصدر الإدخال سواء كان بثاً مباشراً من الكاميرا أو ملف فيديو محفوظ. تم دمج آلية عرض الإطارات ونتائج التصنيف ضمن نافذة واحدة، مع توفير إمكانية الرجوع وإعادة الاختيار. مثل تصميم الواجهة المرحلة النهائية في تنفيذ المشروع، حيث تم تحويل النظام من نموذج خوارزمي تجريبي إلى تطبيق عملي قابل للاستخدام.



الشكل (3-4): خوارزمية عمل مرحلة الاختبار.




الشكل (3-5): مخطط سير الواجهات.

5-3 التنفيذ العملي

في هذا الجزء من الفصل الثالث، نعرض التنفيذ العملي للنظام المقترح بعد استكمال الجوانب النظرية المتعلقة بتقدير الوضعية البشرية والنمذجة الزمنية. قمنا بتطوير تطبيق عملي يحمل اسم Gym AI بهدف اختبار النموذج المقترح في بيئة تشغيل حقيقية، والتحقق من قدرته على تحليل التمارين الرياضية واكتشاف الأخطاء الحركية بدقة.


الشكل (3-6) يوضح الواجهة الرئيسية للنظام عند تشغيل التطبيق. قمنا بتصميم شاشة ترحيبية تحمل عنوان المشروع وبيانات الطالبة والمشرف والجامعة، وذلك لإضفاء الطابع الأكاديمي على

النظام وربطه بسياقه البحثي. عند الضغط على زر "Start"، يتم تحميل النموذج المدرب إلى الذاكرة، وتهيئة بيئة MediaPipe، وضبط متغيرات المعالجة اللازمة لبدء التحليل. تمثل هذه المرحلة مرحلة الإعداد (Initialization Phase) التي تسبق معالجة البيانات الفعلية.




الشكل (3-6): الواجهة الرئيسية للنظام.

الشكل (3-7) يعرض واجهة اختيار مصدر الإدخال، حيث أتحنا للمستخدم خيارين: استخدام الكاميرا المباشرة (Camera) أو تحليل ملف فيديو محفوظ (Video File). قمنا بإضافة هذه المرونة لضمان إمكانية اختبار النظام في بيئات مختلفة، سواء في الزمن الحقيقي داخل صالة رياضية، أو باستخدام تسجيلات مسبقة. عند اختيار الكاميرا، يبدأ النظام بمعالجة الإطارات بشكل لحظي، أما عند اختيار ملف فيديو، فيتم تحميله ومعالجته إطارًا بعد إطار ضمن تسلسل زمني منظم.



الشكل (3-7): واجهة اختيار مصدر الإدخال.


الشكل (3-8) يوضح مثالاً على تحليل تمرين البايستبس باستخدام الكاميرا. بعد التقاط الإطار، قمنا بتمريره إلى نموذج MediaPipe Pose لاستخراج 33 نقطة مرجعية تمثل المفاصل الرئيسية للجسم. يظهر في الصورة الهيكل العظمي الرقمي، حيث تم ربط المفاصل بخطوط بيضاء لتسهيل الرؤية البصرية. بعد ذلك، قمنا بتحويل الإحداثيات إلى متجه عددي وإدخاله إلى النموذج الزمني، الذي قام بتقييم الحركة وإرجاع النتيجة "Bicep Correct (1.00)". تشير القيمة (1.00) إلى مستوى ثقة مرتفع في صحة الأداء الحركي.




الشكل (8-3): مثال على نتيجة التحليل.

الشكل (9-3) يعرض مثالاً لتحليل تمرين السكوات مع وجود خطأ في الأداء. في هذه الحالة، وبعد استخراج الهيكل العظمي وتحويله إلى تسلسل زمني، قمنا بتمرير البيانات إلى النموذج المدرب على الحركات الصحيحة. عند مقارنة التسلسل المُدخل بالنمط المرجعي، ظهر فرق كبير في إعادة البناء (Reconstruction Error)، ما أدى إلى تصنيف الحركة على أنها "Squat Wrong (1.00)". تعكس هذه النتيجة التطبيق العملي لآلية كشف الشذوذ (Anomaly Detection) التي ناقشناها نظرياً في الفصل الثاني.

الشكل (10-3) يوضح حالة تحليل سكوات في بيئة منزلية مختلفة عن بيئة التدريب. رغم اختلاف الخلفية والإضاءة وزاوية التصوير، نجحنا في استخراج المفاصل بدقة، ما يؤكد كفاءة MediaPipe في عزل الجسم عن الخلفية. كما أظهر النظام قدرة جيدة على التعميم، حيث تمكن من اكتشاف الخطأ الحركي دون أن يتأثر بالعوامل البيئية المحيطة.




الشكل (3-9): اكتشاف خطأ في تمرين squat.



الشكل (3-10): تجربة النظام في بيئة مختلفة.

الشكل (3-11) يعرض مثلاً آخر لسكوات خاطئ من زاوية تصوير أمامية. في هذه الحالة، استطعنا تحليل محاذاة الركبتين مع القدمين بشكل أوضح، وهو عامل أساسي في تقييم صحة تمرين

السكوات. أظهر النموذج انحرافاً عن المسار المثالي للحركة، ما أدى إلى تصنيفها كحركة خاطئة. تؤكد هذه النتيجة قدرة النظام على التعامل مع زوايا تصوير متعددة مع الحفاظ على دقة التقييم.



الشكل (3-11): تغيير زاوية التصوير.

من خلال هذه التجارب العملية، تأكدنا من أن النظام يعمل وفق التسلسل التالي:

1. استقبال الإطار من الكاميرا أو الفيديو.
2. استخراج 33 نقطة مرجعية باستخدام MediaPipe Pose.
3. تحويل الإحداثيات إلى متجه زمني.
4. تمرير التسلسل إلى النموذج الزمني المدرب.
5. حساب النتيجة (تصنيف مباشر أو Reconstruction Error).
6. عرض التقييم النهائي للمستخدم.

يوضح التنفيذ العملي التكامل بين المعالجة المكانية (استخراج المفاصل) والمعالجة الزمنية (تحليل التسلسل الحركي)، مما يبرهن على صحة الإطار النظري الذي تم بناؤه في الفصل الثاني، ويؤكد إمكانية تطبيق النظام في بيئات واقعية لتحليل الأداء الرياضي واكتشاف الأخطاء.

الفصل الرابع:

الاستنتاجات والمقترحات

من خلال هذا المشروع قمنا بتصميم وتنفيذ نظام ذكي لتحليل التمارين الرياضية والكشف عن الأخطاء الحركية التي قد تسهم في حدوث إصابات عضلية هيكلية. اعتمدنا في بناء النظام على دمج تقنيات الرؤية الحاسوبية مع النمذجة الزمنية، بحيث قمنا أولاً باستخراج التمثيل الهيكلي للجسم باستخدام MediaPipe Pose المعتمد على نموذج BlazePose، ثم قمنا بتحويل الإحداثيات المستخرجة إلى تمثيل عددي زمني تمت معالجته باستخدام شبكة الذاكرة طويلة وقصيرة المدى (LSTM). وقد مكّنا هذا التكامل من الانتقال من المعالجة البصرية الخام إلى تحليل حركي منظم يعتمد على بيانات رقمية قابلة للنمذجة.

أظهرت نتائج التنفيذ أن النظام قادر على تتبع المفاصل الأساسية للجسم بدقة مناسبة في الزمن الحقيقي، واستخراج الإحداثيات اللازمة لتحليل زوايا المفاصل وتسلسل الحركة. كما بيّنت مرحلة الاختبار أن النموذج المدرب استطاع التمييز بين الأداء الصحيح والخاطئ في التمارين المختارة ضمن نطاق البيانات التي تم التدريب عليها. وقد أكد ذلك نجاح المنهجية التي اتبعناها في تحويل الحركة البشرية من صورة مرئية إلى سلسلة زمنية عديدة يمكن تحليلها خوارزمياً.

قمنا بالاعتماد على مصادر بيانات متعددة شملت فيديوهات حقيقية تم تصويرها خصيصاً للمشروع، وبيانات مولدة باستخدام تقنيات الذكاء الاصطناعي، إضافة إلى مجموعات بيانات مفتوحة المصدر. وقد ساعدنا هذا التنوع في بناء قاعدة بيانات أكثر توازناً، مما أسهم في تعزيز قدرة النموذج على التعميم وتقليل احتمالية فرط التعلّم. ومن خلال التجارب العملية لاحظنا أن تنوع

زوايا التصوير والخلفيات ساعد النموذج على التعامل مع حالات مختلفة بدرجة مقبولة من الاستقرار.

في المقابل، واجهنا عددًا من التحديات أثناء التنفيذ. فقد لاحظنا أن دقة تتبع المفاصل تنخفض في ظروف الإضاءة الضعيفة أو عند وجود حجب جزئي لأحد الأطراف، كما أن الاعتماد على تحليل ثنائي الأبعاد يجعل تقدير العمق محدودًا ويتأثر بزوايا التصوير المختلفة. كذلك تبين لنا أن الأداء الزمني للنظام يعتمد بشكل مباشر على قدرة المعالجة في الجهاز المستخدم، إذ قد يحدث بطء نسبي في الأجهزة ذات الموارد المحدودة.

ومن أهم الاستنتاجات التي توصلنا إليها أن تحليل إطار منفرد لا يكفي للحكم على جودة الأداء الحركي، بل إن فهم تسلسل الحركة عبر الزمن هو العامل الحاسم في تقييم التمرين. وقد أثبت استخدام LSTM فعاليته في نمذجة الاعتماديات الزمنية والتقاط الأنماط الحركية المتتابة، مثل التذبذب أو فقدان الاتزان أثناء تنفيذ التمرين، وهي أمور لا يمكن ملاحظتها بدقة عند تحليل صورة ثابتة فقط.

بناءً على ما سبق، نرى أن تطوير النظام يمكن أن يسير في عدة اتجاهات مستقبلية. يمكننا توسيع قاعدة البيانات لتشمل عددًا أكبر من التمارين وأنماط الأخطاء، مما يزيد من قدرة النموذج على التعميم في بيئات مختلفة. كما يمكننا الانتقال إلى تقدير الوضعية ثلاثي الأبعاد لتحسين دقة التقييم وتقليل تأثير زاوية التصوير. ونقترح أيضًا دراسة إمكانية دمج نماذج زمنية أكثر تطورًا مثل نماذج المحولات عند توفر بيانات أكبر، بما قد يساهم في تحسين فهم التسلسل الحركي المعقد.

كذلك يمكن تطوير النظام ليقدم تغذية راجعة تفصيلية بدلاً من تصنيف ثنائي فقط، بحيث لا يقتصر على تحديد صحة التمرين، بل يوضح نوع الخطأ الحركي وموقعه ويقترح آلية تصحيحه. ويمكن مستقبلاً ربط النظام بتطبيقات محمولة أو منصات تدريب إلكترونية، بما يجعله أداة مساعدة للرياضيين والمدربين في البيئات المنزلية ومراكز التدريب.

في ضوء ما أنجزناه، نرى أن المشروع حقق هدفه الأساسي في بناء نموذج أولي عملي لتحليل التمارين الرياضية والكشف المبكر عن الانحرافات الحركية. ورغم التحديات التقنية المرتبطة بظروف التصوير وتنوع البيانات، فإن النتائج التي حصلنا عليها تؤكد إمكانية توظيف تقنيات الذكاء الاصطناعي في دعم المجال الرياضي، مع الحاجة إلى استمرار التطوير للوصول إلى أنظمة أكثر دقة وموثوقية في المستقبل.

المراجع

- [1] Russell, S., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.
- [2] Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [4] Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing (4th ed.). Pearson.
- [5] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521, 436–444.
- [6] Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2017). OpenPose. IEEE TPAMI.
- [7] Bazarevsky, V., et al. (2020). BlazePose: On-device Real-time Body Pose Tracking. arXiv preprint arXiv:2006.10204.
- [8] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780.
- [9] Elman, J. L. (1990). Finding structure in time. Cognitive Science, 14(2), 179–211.

- [10] Elman, J. L. (1990). Finding structure in time. *Cognitive Science*, 14(2), 179–211.
- [11] Kendall, F., McCreary, E., & Provance, P. (2005). *Muscles: Testing and Function*. Lippincott Williams & Wilkins.
- [12] Vaswani, A., et al. (2017). Attention Is All You Need. *NeurIPS*.
- [13] Python Software Foundation. (n.d.). Tkinter — Python interface to Tcl/Tk. Retrieved February 16, 2026, from <https://docs.python.org/3/library/tkinter.html>
- [14] Python Software Foundation. (n.d.). tkinter.filedialog — File selection dialogs. <https://docs.python.org/3/library/dialog.html#module-tkinter.filedialog>
- [15] Python Software Foundation. (n.d.). threading — Thread-based parallelism. <https://docs.python.org/3/library/threading.html>
- [16] Clark, A., & Contributors. (n.d.). Pillow (PIL Fork) documentation. <https://pillow.readthedocs.io/>
- [17] OpenCV Developers. (n.d.). OpenCV: Open source computer vision library. <https://opencv.org/>
- [18] OpenCV Developers. (n.d.). OpenCV documentation. <https://docs.opencv.org/>

[19] Google. (n.d.). MediaPipe documentation. <https://mediapipe.dev/>

[20] Google. (n.d.). MediaPipe Pose solution.

<https://google.github.io/mediapipe/solutions/pose.html>

[21] Harris, C. R., et al. (n.d.). NumPy documentation. NumPy Developers.

<https://numpy.org/doc/>

[22] Google. (n.d.). TensorFlow documentation. <https://www.tensorflow.org/>

[23] Chollet, F., & Keras Contributors. (n.d.). Keras documentation. <https://keras.io/>

[24] Joblib Developers. (n.d.). Joblib documentation. <https://joblib.readthedocs.io/>

