



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
جامعة حماة
الكلية التطبيقية
قسم تقانة الحاسوب

مشروع أعد لنيل درجة الإجازة في بكالوريوس تقانة الحاسوب بعنوان:

التعرف على الأشخاص المطلوبين باستخدام تقنيات التعلم العميق

إعداد الطالبين:

عيسى الحسون

أوس الأسعد

إشراف:

الدكتور المهندس أحمد رياض كردي

2025-2024

الإهداءات

المحتويات

1.....	1 الفصل الأول: مقدمة.....
2.....	1-1 خلفية المشروع.....
4.....	2-1 المشاكل التي يحلها المشروع.....
5.....	3-1 أهمية المشروع.....
6.....	4-1 أهداف المشروع.....
7.....	5-1 التحديات التي تواجهها أنظمة المراقبة الذكية.....
8.....	6-1 دراسات سابقة.....
8.....	1-6-1 نظام المراقبة في مدينة لندن.....
9.....	2-6-1 تكنولوجيا مراقبة الحركة في الصين.....
12.....	2 الفصل الثاني: الذكاء الاصطناعي والتعلم العميق.....
13.....	1-2 تمهيد.....
13.....	2-2 الذكاء الاصطناعي (Artificial Intelligence – AI).....
13.....	1-2-2 تعريف الذكاء الاصطناعي.....
16.....	2-2-2 أنواع الذكاء الاصطناعي.....
22.....	3-2-2 تطبيقات الذكاء الاصطناعي.....
24.....	4-2-2 الذكاء الاصطناعي في أنظمة المراقبة الذكية.....

25	3-2 التعلم الآلي (Machine Learning – ML).....
26	1-3-2 تعريف التعلم الآلي.....
27	2-3-2 أنواع التعلم الآلي.....
29	3-3-2 دور التعلم الآلي في أنظمة المراقبة الذكية.....
31	4-3-2 خوارزميات التعلم الآلي المستخدمة في أنظمة المراقبة الذكية.....
35	4-2 التعلم العميق (Deep Learning – DL).....
35	1-4-2 تعريف التعلم العميق.....
36	2-4-2 الشبكات العصبية الاصطناعية.....
38	3-4-2 تطبيقات التعلم العميق في أنظمة المراقبة الذكية.....
40	4-4-2 تحديات التعلم العميق في أنظمة المراقبة.....
41	5-2 العلاقة بين الذكاء الاصطناعي، التعلم الآلي، والتعلم العميق في أنظمة المراقبة الذكية.....
44	3 الفصل الثالث: الرؤية الحاسوبية.....
45	1-3 تمهيد.....
46	2-3 مقدمة عن الرؤية الحاسوبية (Computer Vision).....
48	3-3 الخطوات الثلاث الرئيسية للتعرف على الكائنات.....
49	1-3-3 إدخال الصور.....
51	2-3-3 كشف الكائنات.....

52	3-3-3 تصنيف الكائنات.....
55	4-3 خوارزميات الرؤية الحاسوبية.....
57	1-4-3 خوارزمية (YOLO (You Only Look Once).....
58	2-4-3 التعرف على الوجوه (Face Recognition).....
61	5-3 تحسين جودة الصور.....
65	6-3 تطبيقات الرؤية الحاسوبية في أنظمة المراقبة الذكية.....
66	7-3 التحديات التي تواجهها تقنيات الرؤية الحاسوبية في أنظمة المراقبة الذكية.....
68	4 الفصل الرابع: التنفيذ العملي والنتائج.....
69	1-4 تمهيد.....
69	2-4 أدوات وبيئات التطوير المستخدمة.....
69	1-2-4 اللغات البرمجية والأدوات.....
71	2-2-4 المكتبات.....
72	3-4 تصميم النظام وبنية العمل.....
72	1-3-4 مخطط خوارزمية العمل (Flowchart of Algorithm).....
73	2-3-4 مخطط تدفق البيانات (Data Flow Diagram – DFD).....
73	4-4 التنفيذ النهائي للنظام.....
76	5-4 النتائج.....

5 الفصل الخامس: الخاتمة.....78

6 المراجع.....82

فهرس الأشكال

الشكل [1-1]: أنظمة المراقبة الذكية.....2

الشكل [1-2]: كاميرا مراقبة حديثة مثبتة في أحد شوارع لندن، تُستخدم كجزء من شبكة ضخمة من كاميرات

الدوائر التلفزيونية المغلقة (CCTV) المدعومة بتقنيات التعرف على الوجوه والذكاء الاصطناعي.10

الشكل [1-3]: تقنية التعرف على الأفراد في الشوارع الصينية باستخدام أنظمة مراقبة ذكية تعتمد على

تحليل أنماط المشي وأشكال الأجساد.....11

الشكل [2-1]: السلوك البشري والذكاء: مقارنة بين السلوك البشري والسلوك الذكي مع إشارة إلى اختبار

تورينغ.....15

الشكل [2-2]: الفرق بين الذكاء الاصطناعي المحدود، العام والخاص.....21

الشكل [2-3]: مجالات الذكاء الاصطناعي.....23

الشكل [2-4]: أنواع التعلم الآلي.....27

الشكل [2-5]: Deep Learning VS Machine Learning.....36

الشكل [2-6]: خطوات عمل شبكة CNN.....38

الشكل [3-1]: تزايد عدد المنشورات الأكاديمية حول اكتشاف الأشياء (Object Detection) في مجال

الرؤية الحاسوبية من عام 2010 إلى عام 2024.....47

- الشكل [3-2]: عملية إعادة بناء نموذج ثلاثي الأبعاد باستخدام تقنية التثليث.....48
- الشكل [3-3]: واجهة المستخدم الرسومية (GUI) لبرنامج Ladder والوظائف الرئيسية. تتكون واجهة المستخدم الرسومية من ثلاثة أجزاء (a). يمكنها تحقيق خطوات متتالية للتنبؤ، التعديل، والتحديث لتطوير نموذج كشف الأشياء (b).....50
- الشكل [3-4]: أداء نموذج YOLO v3 المدرب باستخدام نظام Ladder . يتم استخدام خريطة حرارية لمصفوفة الارتباك لعرض دقة نموذج YOLO v3 المدرب في تقييم مستويات مختلفة من شدة صدأ الأوراق في القمح.....51
- الشكل [3-5]: التعرف على الشكل الدائري.....53
- الشكل [3-6]: التعرف على الشكل المربع.....54
- الشكل [3-7]: التعرف على الشكل المثلث.....55
- الشكل [3-8]: عملية الكشف عن الكائنات باستخدام خوارزمية YOLO.....58
- الشكل [3-9]: النقاط المميزة للوجه.....59
- الشكل [3-10]: صورة ذات جودة عالية (على اليسار)، نسختها المضغوطة بجودة منخفضة باستخدام (JPEG) في المنتصف، ونسختها ذات الدقة المكانية المنخفضة (على اليمين).....62
- الشكل [3-11]: تحسين العدالة مع تحسين جودة بيانات التدريب (أي مستويات مختلفة من ضوضاء التسميات) على مجموعة بيانات (FMNIST).....63
- الشكل [3-12]: الإطار العام للتنبؤ بمستوى الجودة والكشف/التعرف على الوجوه المصنفة بناءً على الجودة.....64
- الشكل [4-1]: لغة البرمجة Python.....69
- الشكل [4-2]: Jupyter Notebook.....70

70	الشكل [4-3]: Anaconda
71	الشكل [4-4]: قاعدة البيانات SQLite
72	الشكل [4-5]: خوارزمية العمل
73	الشكل [4-6]: مخطط تدفق البيانات
74	الشكل [4-7]: التعرف على الشخص "issa" في واجهة البرنامج
75	الشكل [4-8]: مخرجات نصية بعد التعرف على "issa"
75	الشكل [4-9]: واجهة البرنامج عند عدم التعرف على الشخص
76	الشكل [4-10]: مخرجات نصية في حالة عدم التعرف
76	الشكل [4-11]: قاعدة بيانات فارغة
76	الشكل [4-12]: قاعدة بيانات تحتوي على بيانات الشخص "Issa"

الملخص

التعرف على الأشخاص المطلوبين باستخدام تقنيات التعلم العميق

تتناول هذه المذكرة تصميم وتطوير نظام مراقبة ذكي يهدف إلى تعزيز الأمن والسلامة في الأماكن العامة. يهدف النظام إلى تحسين كفاءة أنظمة المراقبة التقليدية من خلال توفير مراقبة مستمرة وفعالة، مع التركيز على التعرف على الأفراد المطلوبين، وتحليل البيانات المرئية في الوقت الفعلي. يتناول البحث التحديات التي تواجه أنظمة المراقبة الذكية، مثل التغيرات في الظروف البيئية، الكثافة السكانية العالية، وحجم البيانات الكبير، ويقدم حلولاً لتحسين دقة وكفاءة هذه الأنظمة.

الكلمات المفتاحية: الذكاء الاصطناعي، التعلم العميق، الرؤية الحاسوبية، أنظمة المراقبة

Abstract

Wanted Person Recognition Using Deep Learning Techniques


This memoir focuses on the design and development of an intelligent surveillance system aimed at enhancing security and safety in public spaces. The system seeks to improve the efficiency of traditional surveillance methods by providing continuous and effective monitoring, with a focus on identifying wanted individuals, and analyzing visual data in real-time. The research addresses challenges faced by intelligent surveillance systems, such as environmental variations, high population density, and large data volumes, offering solutions to enhance the accuracy and efficiency of these systems.

Keywords: Artificial Intelligence, Deep Learning, Computer Vision,
Surveillance Systems

الفصل الأول: مقدمة

1-1 خلفية المشروع

منذ اختراع أولى أنظمة المراقبة في الأربعينيات من القرن الماضي، كانت التكنولوجيا في مجال المراقبة الأمنية تشهد تطوراً ملحوظاً على مر العقود. بدأت المراقبة باستخدام الكاميرات التقليدية التي كانت تستخدم لتتبع إطلاق الصواريخ أو مراقبة التجارب النووية، ولكن مع تقدم الزمن، أصبح الحفاظ على النظام والأمن في المجتمعات أكثر تعقيداً نظراً لتزايد النشاطات الإجرامية وتهديدات الأمن العام. اليوم، ومع توسع المدن وتزايد الكثافة السكانية، بات من الصعب بل المستحيل الاعتماد على الطرق التقليدية لمراقبة الحشود، مما أدى إلى ضرورة تبني تقنيات أكثر تطوراً وفعالية [1].



الشكل [1-1]: أنظمة المراقبة الذكية.

في ظل التطور المتسارع لتقنيات الذكاء الاصطناعي ومعالجة الصور، ظهرت حلول جديدة تهدف إلى تحسين أنظمة المراقبة من خلال دمج تقنيات التعرف على الوجوه وتحليل السلوكيات. أنظمة المراقبة الذكية اليوم لا تقتصر على مجرد مراقبة الحشود، بل تتعداها لتقوم بتحليل البيانات بشكل آلي في الوقت الفعلي للكشف عن أي نشاط غير طبيعي أو الأفراد المطلوبين من قبل السلطات. [2] هذه الأنظمة تعتمد بشكل

كبير على تقنيات الذكاء الاصطناعي التي تستطيع التعرف على الأشخاص وتحليل تصرفاتهم للتنبؤ بأي سلوكيات قد تكون غير آمنة أو مشبوهة.[1]

المشروع يهدف إلى تصميم وتطوير نظام مراقبة ذكي يعتمد على مجموعة من الكاميرات الموزعة في أماكن متعددة، حيث تعتمد هذه الكاميرات على خوارزميات متقدمة لمعالجة الصور والتعرف على الأفراد المطلوبين من قائمة معدة مسبقاً. يتميز النظام بقدرته على العمل في الوقت الفعلي، حيث يقوم بتحليل الصور التي تلتقطها الكاميرات بسرعة ودقة باستخدام تقنيات الذكاء الاصطناعي والتعلم العميق للتعرف على الأشخاص وإطلاق إنذارات فورية عندما يتم اكتشاف أي شخص مطلوب.

تأتي أهمية النظام من خلال توفيره حلاً متكاملاً يعزز من مستوى الأمان في الأماكن العامة، مثل المطارات، والمراكز التجارية، والمعابر الحدودية. حيث يساهم النظام في التعرف على الأفراد المطلوبين أو الأشخاص ذوي التصرفات المشبوهة قبل حدوث أي حادثة. بالإضافة إلى ذلك، يمكن لهذا النظام تقليل الحاجة إلى تدخل البشر في عمليات المراقبة المستمرة، مما يجعل من السهل مراقبة مناطق واسعة دون استنزاف الموارد البشرية.[2] كما أن قدرات النظام تتوسع لتشمل تحليل السلوكيات غير الطبيعية، مثل اكتشاف الأصوات غير المعتادة أو الحركات المشبوهة، مما يزيد من فعاليته في التنبؤ بالجرائم قبل وقوعها.[1]

في العديد من الدول المتقدمة، مثل الولايات المتحدة والمملكة المتحدة والصين، تعتمد الحكومات بشكل متزايد على أنظمة المراقبة الذكية التي تعتمد على الذكاء الاصطناعي، مما يعزز من قدراتها على حماية الأمن الوطني ومراقبة الأماكن الحيوية.[1] وفي الدول النامية أيضاً، مثل نيبال، بدأت هذه التقنيات في اكتساب اهتمام كبير، حيث يتم توظيف الذكاء الاصطناعي لتحليل البيانات والتعرف على الأفراد المشبوهين ومنع الجرائم قبل حدوثها.[2]

يهدف هذا المشروع إلى تقديم نموذج أولي يمكن تطويره ليتم تطبيقه على نطاق أوسع، بحيث يمكن للنظام أن يخدم في تعزيز الأمن في الأماكن الحيوية وفي التنبؤ بالأحداث غير المرغوب فيها.

1-2 المشاكل التي يحلها المشروع

المشروع المقترح يساهم في حل العديد من المشكلات الأمنية المتعلقة بالتعرف على الأفراد المطلوبين جنائياً في المناطق العامة والمراقبة الدقيقة دون الحاجة إلى تدخل بشري مباشر. أولاً، يعتمد الأمن التقليدي على المراقبة البشرية التي تتطلب عددًا كبيرًا من الموظفين ووقتًا طويلاً لمراجعة الصور ومقاطع الفيديو، مما يزيد من فرص الخطأ البشري والتأخير في الاستجابة. المشروع يحل هذه المشكلة من خلال **أتمتة العملية** باستخدام خوارزميات التعرف على الوجه، مما يضمن كشف الأفراد المطلوبين بشكل فوري ودقيق دون الحاجة إلى مراقبة مستمرة من قبل الموظفين.

ثانياً، يتعامل المشروع مع مشكلة التغطية الأمنية غير المتكاملة في المناطق المختلفة، حيث لا تستطيع الأنظمة التقليدية توفير مراقبة شاملة لجميع المواقع. باستخدام شبكة من الكاميرات الموزعة، يمكن للنظام تغطية نطاق أوسع والتفاعل فوراً عند اكتشاف شخص مطلوب، مما يحسن من كفاءة المراقبة ويعزز الأمان العام في الأماكن العامة مثل المراكز التجارية، المطارات، ومحطات النقل.

ثالثاً، المشروع يقدم حلاً لمشكلة الاستجابة البطيئة للتهديدات الأمنية. الأنظمة التقليدية تتطلب وقتاً طويلاً لاكتشاف الأفراد المطلوبين وتحليل صورهم يدوياً. باستخدام هذا النظام الذكي، يتم التعرف على الأفراد تلقائياً وتوليد تنبيه في الوقت الحقيقي، مما يتيح للجهات الأمنية التحرك السريع والاستجابة الفعالة للتهديدات المحتملة.

رابعاً، النظام يعالج مشكلة التكاليف المرتفعة للمراقبة التقليدية. توظيف عدد كبير من المراقبين معتمدين على العمل اليدوي يحتاج إلى ميزانيات ضخمة. النظام الذكي يوفر بديلاً أكثر اقتصادية، حيث يمكن أن تعمل الكاميرات والخوارزميات معاً على مدار الساعة دون الحاجة إلى موارد بشرية مستمرة. هذه الحلول مجتمعة تسهم في رفع مستوى الأمن والكفاءة التشغيلية للنظام الأمني، مع تقليل التكاليف والأخطاء البشرية، وتحسين سرعة الاستجابة للمخاطر الأمنية.

1-3 أهمية المشروع

يمثل نظام المراقبة الذكي خطوة حيوية نحو تعزيز الأمان العام. من خلال تقنيات التعرف على الوجوه، يسعى المشروع إلى تقديم حلول فعالة للتصدي للجريمة وتحسين الاستجابة الأمنية. تبرز أهمية هذا المشروع من خلال عدة جوانب رئيسية، حيث يعزز الأمن العام من خلال توفير مستوى أعلى من الأمان عبر الكشف الفوري والدقيق عن الأفراد المطلوبين، مما يساهم في تقليل الجرائم والتهديدات في الأماكن العامة مثل المراكز التجارية والمطارات ومحطات النقل. كما أن النظام يعمل في الوقت الحقيقي، مما يتيح للجهات الأمنية التفاعل بسرعة مع التهديدات المحتملة فور التعرف على الأشخاص المطلوبين، مما يحسن من سرعة وكفاءة التدخل الأمني.

علاوة على ذلك، يقلل المشروع من التكاليف التشغيلية بفضل الأتمتة الكاملة للعملية، مما يؤدي إلى توفير في التكاليف المتعلقة بتوظيف وتدريب فرق المراقبة. وباستخدام شبكة من الكاميرات الموزعة في مواقع مختلفة، يوفر النظام تغطية أمنية شاملة ويضمن مراقبة المناطق الواسعة بفعالية دون الحاجة إلى مراقبة مستمرة من قبل موظفين بشريين.

كما يعالج المشروع مشكلة الأخطاء البشرية التي قد تحدث نتيجة الإرهاق أو قلة التركيز لدى المراقبين، حيث تعتمد الخوارزميات على الدقة العالية في التعرف على الوجوه وتحليل الصور. إضافة إلى ذلك، يقدم

المشروع حلولاً تقنية متقدمة تعتمد على الذكاء الاصطناعي وتقنيات التعرف على الوجوه، مما يرفع من كفاءة وكفاية الأنظمة الأمنية التقليدية ويجعلها أكثر ملاءمة للاستخدام في المدن الذكية. وأخيراً، يمكن دمج المشروع مع أنظمة المراقبة الأمنية الحالية، مما يتيح تحسين وظائف تلك الأنظمة من خلال إضافة القدرة على التعرف على الأشخاص المطلوبين وتتبيه السلطات فوراً.

1-4 أهداف المشروع

1. تطوير نظام مراقبة ذكي: تصميم نظام متكامل يستخدم تقنيات التعرف على الوجوه والذكاء الاصطناعي لتعزيز فعالية عمليات المراقبة والأمن.
2. تحسين الاستجابة الأمنية: توفير أداة فعالة للجهات الأمنية تتيح لها التعامل مع التهديدات المحتملة بشكل سريع ودقيق، مما يساهم في تعزيز الأمان في الأماكن العامة.
3. تقليل معدلات الجريمة: الحد من الجرائم والأنشطة غير المشروعة من خلال الكشف الفوري عن الأفراد المطلوبين وتحذير السلطات في الوقت المناسب.
4. أتمتة العمليات الأمنية: تقليل الاعتماد على المراقبة اليدوية من خلال الأتمتة، مما يسهل عملية رصد الأنشطة المريبة بكفاءة أكبر.
5. تحسين دقة المراقبة: استخدام تقنيات التعرف على الوجوه المتقدمة لتقليل الأخطاء البشرية وضمان دقة أعلى في تحديد الأشخاص.
6. توسيع نطاق المراقبة: إنشاء شبكة من الكاميرات تغطي مناطق واسعة لضمان مراقبة فعالة لجميع الأماكن الحيوية.
7. توفير تقارير وتحليلات مفيدة: تقديم تقارير مفصلة للجهات المعنية حول الأنشطة المشبوهة، مما يساعد في اتخاذ قرارات مبنية على بيانات دقيقة.

8. تسهيل التكامل مع الأنظمة الحالية: ضمان إمكانية دمج النظام الجديد بسلاسة مع أنظمة المراقبة والأمن الحالية لتعزيز كفاءة العمليات الأمنية.
9. رفع مستوى الوعي الأمني: تعزيز ثقافة الوعي الأمني لدى المجتمع من خلال استخدام التكنولوجيا المتقدمة في مجال الأمن والمراقبة.
10. تطبيق التكنولوجيا الحديثة: استخدام أحدث تقنيات الذكاء الاصطناعي وتحليل البيانات لتعزيز القدرات الأمنية وتحسين كفاءة الإجراءات المتخذة.
11. دعم المدن الذكية: المساهمة في رؤية المدن الذكية من خلال توفير حلول أمنية مبتكرة تسهم في تعزيز الأمان العام وكفاءة الخدمات.
12. توفير تكلفة التشغيل: تقليل التكاليف المرتبطة بالعمليات الأمنية من خلال الاعتماد على الأنظمة الآلية بدلاً من القوى العاملة البشرية.

1-5 التحديات التي تواجهها أنظمة المراقبة الذكية

تواجه أنظمة المراقبة الذكية العديد من التحديات التي تؤثر على كفاءتها وفعاليتها في تحقيق الأهداف الأمنية، وخاصة فيما يتعلق بالتعرف على المطلوبين. فمن جهة، تعاني هذه الأنظمة من التحديات المتعلقة بالبنية التحتية المادية مثل ضرورة تركيب أجهزة استشعار وكاميرات ذكية في مواقع حساسة لضمان التغطية الشاملة. هذا يشكل تحدياً كبيراً في الأماكن العامة الواسعة والمزدحمة، حيث يتطلب النظام اتصالاً ثابتاً وشبكة قوية لجمع وتحليل البيانات في الوقت الفعلي، مما يزيد من تعقيد التصميم والتشغيل [4].

كما تلعب تقنيات الذكاء الاصطناعي دوراً محورياً في تمكين هذه الأنظمة، لكن هذه التقنيات تواجه تحديات تقنية مهمة مثل اكتشاف الأفراد المطلوبين بدقة وسط الزحام، أو في حالات الإضاءة المتغيرة وظروف الطقس المختلفة. بالإضافة إلى ذلك، يُعزى جزء كبير من هذه الصعوبات إلى الاعتماد على تحليل البيانات

المكثف عبر برامج متخصصة، حيث تتطلب تلك الأنظمة قدرات تحليلية عالية لتحديد الأشخاص أو كشف السلوكيات غير الطبيعية. ومع ذلك، يمكن أن تحدث أخطاء نتيجة ظروف غير متوقعة أو عوامل بيئية قد تؤثر على فعالية النظام في التعرف [3].

على صعيد آخر، تُعدّ حماية هذه الأنظمة من الهجمات الإلكترونية والتلاعب بالبيانات واحدة من أكبر التحديات. يعتمد العديد من الأنظمة على معايير الأمان العالية لضمان حماية المعلومات الحساسة التي يتم جمعها، إلا أن الثغرات الأمنية يمكن أن تُستغل من قبل جهات غير مصرح لها، ما يؤدي إلى تعطيل النظام أو الوصول إلى بيانات حساسة بطريقة غير مشروعة [3].

وفيما يتعلق بالتوافق مع اللوائح القانونية، تتطلب أنظمة المراقبة الذكية الامتثال لمجموعة متنوعة من التشريعات المتعلقة بالخصوصية وحماية البيانات، مثل قوانين حماية المعلومات الشخصية التي تختلف من منطقة إلى أخرى. إذ يتعين على الأنظمة أن توازن بين الحاجة إلى الحفاظ على الأمن العام وضمان حماية حقوق الأفراد وخصوصياتهم [4].

وأخيراً، غالباً ما تجرى تجارب واختبارات هذه الأنظمة في بيئات مختبرية، لكن عند تطبيقها في بيئات واقعية، قد تظهر تحديات إضافية تتعلق بتكيف الأنظمة مع الظروف المتغيرة، مثل الكثافة البشرية العالية أو تغير السلوكيات في الأماكن العامة، مما يتطلب تحسينات مستمرة لضمان الأداء الأمثل [4].

1-6 دراسات سابقة

1-6-1 نظام المراقبة في مدينة لندن

تعد لندن من أكثر المدن استخداماً لأنظمة المراقبة الحديثة، حيث تعتمد السلطات على شبكة ضخمة من كاميرات الدوائر التلفزيونية المغلقة (CCTV) مدعومة بتقنيات التعرف على الوجوه والذكاء الاصطناعي (الشكل 1-1) لتحسين الأمن العام. تستخدم هذه الشبكة لمراقبة الأماكن العامة وتحديد الأفراد المطلوبين

من خلال مطابقة صورهم مع قاعدة بيانات أمنية، ما يتيح إطلاق إنذارات فورية عند اكتشاف فرد مطلوب. بدأ تطبيق هذه التقنية ضمن مشروع شرطة لندن، الذي يهدف إلى مراقبة السلوك في الوقت الفعلي وتحليل البيانات لتعزيز الأمن.

إلا أن هذا النظام أثار جدلاً واسعاً حول قضايا الخصوصية واحتمالات التعدي على الحريات الشخصية، حيث يعبر بعض النقاد عن مخاوفهم من إساءة استخدام البيانات، إضافةً إلى إمكانية حدوث أخطاء في التعرف على الوجوه بسبب ظروف بيئية غير مثالية مثل الإضاءة السيئة أو زوايا التصوير غير الملائمة. وبالرغم من هذه المخاوف، أظهرت التجربة البريطانية فاعلية تقنية التعرف على الوجوه في رفع مستويات الأمان، مما فتح النقاش حول كيفية استخدام التكنولوجيا بشكل متوازن بين تحسين الأمن العام وحماية الخصوصية الفردية.

تعتبر هذه المبادرة مثلاً مهماً على التحول الرقمي في أنظمة المراقبة، حيث يتم استثمار الذكاء الاصطناعي لمعالجة وتحليل كميات هائلة من البيانات بدقة عالية. [5]

1-6-2 تكنولوجيا مراقبة الحركة في الصين

بدأت السلطات الصينية في تنفيذ نظام مراقبة مبتكر (الشكل 1-2) يعتمد على جهاز مصمم للتعرف على الأفراد من خلال أنماط مشيهم وأشكال أجسادهم. تم نشر هذا الجهاز، المعروف باسم Watrix، في شوارع أكبر مدينتين في البلاد، وهما بكين وشنغهاي، جنباً إلى جنب مع شبكة واسعة من كاميرات المراقبة المزودة بتقنيات التعرف على الوجه.

يشير هذا الجهاز مخاوف كبيرة بين المدافعين عن الخصوصية، الذين يتساءلون عن حدود التدخل الحكومي في حياة المواطنين. وفقاً لهوانغ يونغ تشن، الرئيس التنفيذي لشركة "Watrix" التي قامت بتطوير هذا

الجهاز، يمكنه التعرف على الأشخاص من مسافة تصل إلى 50 مترًا، حتى في الحالات التي يتم فيها تصويرهم من الخلف أو عندما تكون وجوههم مغطاة.

تم تصميم جهاز Watrix لسد الثغرات الموجودة في تقنيات المراقبة الحالية، التي تحتاج عادةً إلى صور دقيقة وقراءات قريبة لوجه الشخص. يعمل هذا الجهاز على تحليل ميزات الجسم بالكامل، مما يجعله قادرًا على التعرف على الأفراد دون الحاجة إلى تعاونهم، حيث لا يمكن خداعه بسهولة من خلال تظاهر الأشخاص بالتعرض للإعاقة أو تغيير أنماط مشيهم.

حتى الآن، حصلت الشركة على تمويل يصل إلى 100 مليون يوان (ما يعادل حوالي 14.5 مليون دولار) ويستخدم الجهاز حاليًا لرصد مخالفات المرور وتحديد الهاربين من بين الحشود. ووفقًا للمسؤولين الأمنيين، فإن هناك خططًا لتطوير نظام وطني شامل يجمع بيانات كاميرات المراقبة، حيث ستُضاف تكنولوجيا التعرف على المشي إلى هذا النظام المتكامل.

هذا التطور يعكس توجه الصين نحو تعزيز تقنيات المراقبة الاجتماعية، مما يثير العديد من الأسئلة حول الخصوصية وحقوق الأفراد في ظل هذه الأنظمة المتطورة [6].



الشكل [1-2]: كاميرا مراقبة حديثة مثبتة في أحد شوارع لندن، تُستخدم كجزء من شبكة ضخمة من كاميرات الدوائر التلفزيونية المغلقة (CCTV) المدعومة بتقنيات التعرف على الوجوه والذكاء الاصطناعي.



الشكل [1-3]: تقنية التعرف على الأفراد في الشوارع الصينية باستخدام أنظمة مراقبة ذكية تعتمد على تحليل أنماط المشي وأشكال الأجساد.

الفصل الثاني: الذكاء

الاصطناعي والتعلم

العميق

2-1 تمهيد

في ظل التطورات المتسارعة التي يشهدها العالم في مجالات التكنولوجيا المختلفة، يأتي الذكاء الاصطناعي كأحد أبرز التحولات التي تركت بصمة عميقة في العديد من المجالات، وخاصة في مجال المراقبة الذكية. أنظمة المراقبة التقليدية، التي كانت تعتمد في السابق بشكل كبير على التدخل البشري، تشهد اليوم تحولا جذرياً بفضل تقنيات الذكاء الاصطناعي والتعلم الآلي والتعلم العميق، التي ساهمت في جعل تلك الأنظمة أكثر كفاءة وفعالية.

هذا التحول التكنولوجي لا يقتصر فقط على تحسين قدرات الأنظمة الأمنية في التعرف على الأفراد أو رصد الأنشطة المشبوهة، بل يمتد ليشمل تحسين مستوى الدقة وتقليل الحاجة إلى العنصر البشري في عمليات الرصد المستمرة. أنظمة المراقبة الحديثة تعتمد على تحليل تدفقات الفيديو في الوقت الحقيقي وتطبيق خوارزميات التعلم الآلي لتحديد الأنماط والتصرفات التي قد تشير إلى وجود تهديد محتمل، مما يوفر مستوى أعلى من الأمان في الأماكن العامة والخاصة.

في هذا الفصل، سنقوم باستعراض شامل ومفصل لأهم التقنيات المتعلقة بالذكاء الاصطناعي، التعلم الآلي، والتعلم العميق، مع التركيز على كيفية توظيف هذه التقنيات في تحسين أنظمة المراقبة الذكية. سنتناول بالتفصيل تعريف كل تقنية، أنواعها، تطبيقاتها العملية، والتحديات التي تواجهها، كما سنستعرض العلاقة المتكاملة بين هذه التقنيات ودورها المشترك في تعزيز كفاءة أنظمة المراقبة الأمنية.

2-2 الذكاء الاصطناعي (Artificial Intelligence – AI)

2-2-1 تعريف الذكاء الاصطناعي

الذكاء الاصطناعي (AI) هو مجال متنامٍ في علوم الكمبيوتر، يسعى إلى محاكاة الذكاء البشري من خلال الآلات والبرمجيات. يهدف هذا المجال إلى تحقيق وظائف متعددة تشمل التعلم من البيانات المتاحة، اتخاذ

قرارات مبنية على تلك البيانات، والتكيف مع الظروف الجديدة، مما يجعل الأنظمة قادرة على أداء مهام تتطلب مستوى معيناً من الإدراك والتفكير الذكي [7].

تتضمن إحدى القدرات الأساسية للذكاء الاصطناعي التعلم الآلي (Machine Learning)، والذي يمكن الآلات من تعلم الأنماط من البيانات واستخدام تلك المعرفة لتحسين أدائها مع مرور الوقت. فعلى سبيل المثال، في حالة نظام يتعلم التعرف على الوجوه، يتم تغذيته بكم هائل من الصور التي يتعلم منها الخصائص التي تجعل كل وجه مميزاً. هذا التعلم التكيفي يمكن النظام من تمييز الأفراد حتى في ظروف معقدة أو بيانات غير كاملة [8].


تشمل تطبيقات الذكاء الاصطناعي مجالات متعددة، مثل الروبوتات التفاعلية، السيارات ذاتية القيادة، والأجهزة الذكية المنزلية التي تتكيف مع تفضيلات المستخدم. على سبيل المثال، الغسالات الذكية المدعومة بالذكاء الاصطناعي توصي بأفضل دورات الغسيل بناءً على نوع القماش وجودة المياه ومستوى الأوساخ [9].

في هذا السياق، يظهر الشكل (2-1)، الذي يتناول المهام التي يجب تنفيذها وتوزيعها بناءً على مستوى الذكاء البشري المطلوب. كما هو مذكور في القسم الأحمر (أ) من الشكل، تُظهر المهام التي تتطلب مستوى متوسطاً من الذكاء البشري، حيث يكون العمل كبير الحجم ومتكرر بطبيعته. كانت أتمتة مثل هذه المهام جزءاً من الثورة الصناعية الثالثة والثورة الرقمية، مع أمثلة مثل الغسالات الأوتوماتيكية وأجهزة البيع الآلي والمعاملات البنكية باستخدام أجهزة الصراف الآلي.

فيما يتعلق بالقسم الأرجواني المتداخل (ب) من الشكل، نجد المهام التي تتطلب مستوى عالٍ من الذكاء. هنا، تعمل الآلات وفقاً لمجموعة من القواعد المحددة مسبقاً، ولكن من خلال الذكاء الاصطناعي، يتجاوز

النظام العمل كآلة عادية ليصبح آلة ذكية، قادرة على التعامل مع بيانات معقدة وتحليل البيانات بشكل

ديناميكي. [7]



الشكل [1-2]: السلوك البشري والذكاء : مقارنة بين السلوك البشري والسلوك الذكي مع إشارة إلى اختبار تورينغ.

يعتبر الذكاء الاصطناعي اليوم حجر الزاوية في العديد من الصناعات، حيث يتم استخدامه في الأتمتة الصناعية، الطب، التعليم، وحتى التفاعل الاجتماعي. في عالم الطب، يمكن لأنظمة الذكاء الاصطناعي تحليل بيانات المرضى والتوصل إلى تشخيصات دقيقة أو تقديم توصيات علاجية مبنية على تحليل دقيق للبيانات. كما تُستخدم أنظمة الذكاء الاصطناعي في القطاع المالي لتحليل الأسواق والتنبؤ بالاتجاهات المستقبلية، مما يساعد الشركات والمستثمرين على اتخاذ قرارات مستنيرة.

تاريخيًا، يمكن تتبع جذور الذكاء الاصطناعي إلى الفلسفات القديمة التي تناولت مفهوم الذكاء. في القرن التاسع عشر، اقترح تشارلز باباج (Charles Babbage) أول مفهوم لحاسوب عام قادر على إجراء عمليات

حسابية معقدة، وهي فكرة توسعتها آدا لوفلايس (Ada Lovelace) لاحقاً، حيث اعتبرت أن الآلات يمكنها معالجة الرموز كما تفعل الأرقام. على الرغم من تشكك لوفلايس في قدرة الآلات على الابتكار، فإنها مهدت الطريق للأبحاث المستقبلية في هذا المجال [7].

مع تقدم العلوم في القرن العشرين، وضع عالم الرياضيات آلان تورينغ (Alan Turing) الأساس النظري للذكاء الاصطناعي الحديث، من خلال اقتراحه أن الحواسيب يمكنها تنفيذ أي عملية حسابية بشرط أن تكون لديها ذاكرة كافية. صاغ تورينغ أيضاً مفهوم "اختبار تورينغ" لتقييم قدرة الآلة على محاكاة التفكير البشري [8].

في خمسينيات القرن العشرين، شهد الذكاء الاصطناعي تحولاً كبيراً مع انعقاد ورشة عمل في دارتموث عام 1956، حيث تم لأول مرة صياغة مصطلح "الذكاء الاصطناعي". رغم التحديات التي واجهتها الأبحاث في ذلك الوقت، مثل "شتاء الذكاء الاصطناعي"، استمر التطور في هذا المجال مع ظهور تقنيات التعلم الآلي في أواخر القرن العشرين، مما مكّن الآلات من التعلم من البيانات وتحليلها بشكل أكثر فعالية [9]. اليوم، يمثل الذكاء الاصطناعي جزءاً لا يتجزأ من الثورة الصناعية الرابعة. يُتوقع أن يستمر تطور الذكاء الاصطناعي نحو "الذكاء الاصطناعي العام"، الذي يسعى إلى محاكاة الذكاء البشري بالكامل. ومع ذلك، يشير هذا التطور السريع تساؤلات أخلاقية وفلسفية حول دوره وتأثيره في المستقبل [9].

2-2-2 أنواع الذكاء الاصطناعي

1-2-2-2 الذكاء الاصطناعي المحدود (Narrow AI)

الذكاء الاصطناعي المحدود (Narrow AI) أو الذكاء الاصطناعي الضعيف (Weak AI) هو نوع من أنظمة الذكاء الاصطناعي المصممة لأداء مهام محددة وضيقة النطاق بشكل فعال. على عكس الذكاء الاصطناعي القوي (General AI) الذي يهدف إلى محاكاة جميع جوانب التفكير البشري والإبداع، فإن

الذكاء الاصطناعي المحدود يركز فقط على إتقان وتنفيذ مهمة واحدة معينة، سواء كانت التعرف على الوجوه، الترجمة الآلية، أو التحكم في مركبة ذاتية القيادة.

تتمثل إحدى الخصائص البارزة لهذا النوع من الذكاء الاصطناعي في عدم قدرته على التكيف مع مهام أخرى خارج نطاقه المحدد. على سبيل المثال، إذا تم تدريب نظام ذكاء اصطناعي على التعرف على الوجوه باستخدام خوارزميات معالجة الصور والشبكات العصبية الاصطناعية، فلن يكون بإمكانه القيام بأي شيء خارج هذا الإطار مثل التعرف على الأصوات أو تحليل النصوص. يعمل هذا النوع من الأنظمة بشكل ممتاز في المهام الضيقة بسبب تركيزه العالي على مجموعة محددة من البيانات والخوارزميات، ولكنه يفتقر إلى القدرة على التعلم أو العمل بمرونة في مجالات أخرى.

تعد أنظمة الذكاء الاصطناعي المحدود جزءًا أساسيًا من العديد من التطبيقات الحديثة في الحياة اليومية. من بين أبرز الأمثلة أنظمة التعرف على الصوت المستخدمة في المساعدات الصوتية مثل "سيري" و"أليكسا"، وأنظمة التوصية المستخدمة في منصات البث مثل "نتفليكس" و"يوتيوب"، حيث تقوم بتحليل سلوك المستخدم وتقديم توصيات بناءً على أنماط المشاهدة السابقة. ومن ناحية أخرى، يعتمد الذكاء الاصطناعي المحدود في مجال الطب على تحليل الصور الطبية، مثل الأشعة السينية أو الصور المقطعية، للكشف عن الأمراض أو الحالات المرضية، ولكن لا يستطيع هذا النظام تقديم أي تحليل خارج نطاق الصور الطبية [10].

التقنيات المستخدمة في الذكاء الاصطناعي المحدود تعتمد بشكل كبير على التعلم الآلي (Machine Learning) والشبكات العصبية الاصطناعية (Artificial Neural Networks). يتم تدريب هذه الأنظمة باستخدام مجموعات ضخمة من البيانات، حيث تتعلم الأنظمة تحديد الأنماط والخصائص المميزة المرتبطة بالمهمة المحددة التي صُممت لأدائها. على سبيل المثال، في نظام التعرف على الوجوه، يتم تغذية النظام

بعدد كبير من الصور لأشخاص مختلفين. يعتمد النظام على تحليل هذه الصور باستخدام تقنيات معالجة الصور لاستخراج السمات المميزة لكل وجه مثل المسافات بين العينين، شكل الفك، وحجم الأنف. بعد التعرف على هذه الأنماط، يصبح النظام قادرًا على التعرف على الأفراد بناءً على الوجوه التي رآها من قبل [10].

وتعتبر الشبكات العصبية الاصطناعية من أكثر النماذج المستخدمة شيوعًا في الذكاء الاصطناعي المحدود، حيث تعمل على محاكاة كيفية عمل الدماغ البشري في معالجة المعلومات. يتم تنظيم هذه الشبكات في طبقات من العقد (neurons)، حيث تعمل كل عقدة على استقبال الإشارات، معالجتها، وإرسال النتيجة إلى العقد التالية. يمكن لنماذج مثل الشبكة العصبية المتقدمة (Feedforward Neural Network) أو الشبكة العصبية العودية (Recurrent Neural Network) أن تكون فعالة للغاية في تنفيذ المهام المحددة [10].

بالإضافة إلى ذلك، تعتمد الأنظمة على مجموعة متنوعة من خوارزميات التدريب لتحسين أدائها. تُستخدم خوارزميات مثل الانتشار الخلفي (Backpropagation) لتعديل الأوزان داخل الشبكات العصبية بناءً على الفرق بين المخرجات الفعلية والمخرجات المستهدفة، بهدف تقليل الخطأ وزيادة دقة النظام. وكلما زادت كمية البيانات المتاحة للنظام وتنوعت، كلما كانت هذه الأنظمة أكثر كفاءة وفعالية في تنفيذ مهمتها.

من المثير للاهتمام أن الذكاء الاصطناعي المحدود يمكن أن يتجاوز البشر في بعض المهام المحددة. على سبيل المثال، أنظمة التعرف على الوجوه الحديثة يمكن أن تكون أكثر دقة وسرعة من الإنسان في التعرف على الأشخاص في الصور أو الفيديوهات [10]. وبالمثل، في مجال الطب، يمكن لأنظمة الذكاء الاصطناعي اكتشاف الأورام أو التشوهات الدقيقة في الصور الطبية بدقة تتجاوز قدرة العين البشرية.

2-2-2-2 الذكاء الاصطناعي العام (General AI)

الذكاء الاصطناعي العام (General AI)، والمعروف أيضًا بالذكاء الاصطناعي القوي، هو نوع من أنظمة الذكاء الاصطناعي الذي يسعى إلى محاكاة القدرات المعرفية للبشر بشكل كامل، بحيث يمكنه تنفيذ مجموعة واسعة من المهام التي تتطلب مستويات مختلفة من الفهم والتفكير والإبداع. على عكس الذكاء الاصطناعي المحدود (Narrow AI) الذي يتم تصميمه للقيام بمهمة معينة مثل التعرف على الوجه أو الصوت، يتميز الذكاء الاصطناعي العام بقدرته على التعلم والتكيف مع مهام متعددة دون الحاجة إلى إعادة برمجته لكل مهمة على حدة.

تتمثل الفكرة الأساسية وراء الذكاء الاصطناعي العام في تطوير أنظمة تتمتع بذكاء يشبه ذكاء الإنسان، حيث يمكن لهذه الأنظمة تحليل المعلومات، التوصل إلى استنتاجات، حل المشاكل، والتعلم من التجارب السابقة. يتم ذلك من خلال محاكاة كيفية عمل الدماغ البشري في التعلم والتفكير، بهدف إنشاء أنظمة قادرة على العمل بشكل مستقل في مختلف المجالات دون الحاجة إلى تدخل بشري مستمر. هذا النوع من الذكاء الاصطناعي لا يزال نظريًا في الوقت الحالي، ولم يتم تحقيقه بعد بشكل كامل، حيث تركز الأبحاث الحالية على محاولة فهم كيفية بناء هذه الأنظمة بشكل فعال وآمن [11].

تشمل التطبيقات المحتملة للذكاء الاصطناعي العام العديد من المجالات، منها التعليم، الصحة، الصناعة، وحتى الأعمال الإبداعية مثل الفن والأدب. في مجال التعليم، على سبيل المثال، يمكن أن يساهم الذكاء الاصطناعي العام في تحسين عملية التعليم من خلال توفير تجارب تعليمية مخصصة لكل طالب، بحيث تتكيف مع احتياجاته واهتماماته، بالإضافة إلى تطوير طرق تقييم مبتكرة تعتمد على قدرات الفهم والتحليل التي يمتلكها النظام. في هذا السياق، يمكن أن يصبح الذكاء الاصطناعي العام جزءًا أساسيًا من العملية التعليمية، حيث يتعاون مع المدرسين لتقديم تعليم أفضل وأكثر فعالية [11].

من جهة أخرى، يتطلب تحقيق الذكاء الاصطناعي العام التعاون بين مجالات متعددة من العلوم مثل علوم الكمبيوتر، علم الأعصاب، علم النفس، والفلسفة. فهم كيفية محاكاة التفكير البشري بشكل كامل هو تحدٍ ضخم يتطلب فهماً عميقاً لكيفية عمل العقل البشري، بالإضافة إلى تطوير تقنيات متقدمة في البرمجة والتحليل. ومع التقدم في مجالات مثل الشبكات العصبية الاصطناعية والتعلم العميق، تزداد احتمالية تحقيق الذكاء الاصطناعي العام في المستقبل، ولكنه لا يزال بعيداً عن الواقع الحالي [11].


ومع أن الذكاء الاصطناعي العام يمتلك إمكانيات هائلة، إلا أنه يواجه تحديات أخلاقية كبيرة. أحد هذه التحديات هو كيفية ضمان أن هذه الأنظمة الذكية تعمل بشكل يتماشى مع القيم الإنسانية، وأن تكون خالية من التحيزات والقرارات الخاطئة التي قد تؤثر على حياة البشر بشكل سلبي. بالإضافة إلى ذلك، يطرح ظهور الذكاء الاصطناعي العام أسئلة حول حقوق الروبوتات والأخلاقيات المتعلقة باستخدام هذه الأنظمة في الحياة اليومية. هل يجب أن نمنح هذه الأنظمة حقوقاً ماثلة لحقوق البشر؟ وكيف يمكننا ضمان أنها لا تتسبب في أضرار غير مقصودة؟ هذه التساؤلات تحتاج إلى دراسة متأنية قبل أن يصبح الذكاء الاصطناعي العام حقيقة واقعة [11].

3-2-2-2 الذكاء الاصطناعي الفائق (Super AI)

تمثل Super AI (الذكاء الاصطناعي الفائق) مرحلة مستقبلية نظرية حيث تتفوق الآلات على الذكاء البشري في جميع المجالات. اكتسب هذا المفهوم زخماً مع استمرار تطور التقدم في الذكاء الاصطناعي. تُعد إمكانيات الذكاء الاصطناعي الفائق كبيرة، حيث يمكن أن تؤدي إلى كفاءات وقدرات غير مسبوقة في مختلف القطاعات، بما في ذلك الإدارة العامة. يمكن أن تتيح هذه التكنولوجيا المتطورة حلولاً مبتكرة لمشكلات معقدة، وتعزيز فعالية الأنظمة الحالية، وتحسين جودة الحياة بشكل عام.

إلا أن البحث يسلط الضوء على أنه في حين أن تقنيات الذكاء الاصطناعي الحالية، مثل الذكاء الاصطناعي الضيق والذكاء الاصطناعي التوليدي، تخطو خطوات كبيرة، فإن القفزة إلى الذكاء الاصطناعي الفائق تتطلب على تحديات معقدة واعتبارات أخلاقية. على سبيل المثال، تتطلب هذه المرحلة فهماً عميقاً لكيفية تفاعل هذه الأنظمة المتقدمة مع المجتمع، وتأثيراتها المحتملة على الأفراد وخصوصياتهم.

بالإضافة إلى ذلك، يمكن أن تؤدي الآثار المترتبة على مثل هذا التطور إلى إعادة تشكيل الحوكمة وتقديم الخدمات وإدارة البيانات في القطاع العام، مما يستلزم إجراء تقييم دقيق لتأثيراته المجتمعية وأطره التنظيمية. يجب أن تكون هناك نقاشات مستمرة حول كيفية استخدام هذه التقنيات بشكل مسؤول وأخلاقي، مع وضع استراتيجيات لضمان أن تبقى الفوائد المترتبة عليها في متناول الجميع.



الشكل [2-2]: الفرق بين الذكاء الاصطناعي المحدود، العام والخارق.


مع تطور الذكاء الاصطناعي الفائق، يجب على المجتمع الأكاديمي وصناع القرار والممارسين العمل معاً لمواجهة التحديات الأخلاقية والاجتماعية المترتبة على هذا التطور. إن إدماج معايير أخلاقية قوية وأطر تنظيمية مناسبة سيكون أمراً حيوياً لضمان أن يساهم الذكاء الاصطناعي الفائق في تعزيز الرفاهية البشرية،

بدلاً من التسبب في عواقب غير مقصودة. [12]

3-2-2 تطبيقات الذكاء الاصطناعي

تطبيقات الذكاء الاصطناعي تتوسع بشكل ملحوظ لتشمل مجموعة متنوعة من المجالات في حياتنا اليومية، مما يسهم في تحسين الكفاءة وتسهيل المهام. من أبرز هذه التطبيقات هو استخدام المساعدين الافتراضيين مثل Siri و Google Assistant، الذين يتيحون للمستخدمين التفاعل مع الأجهزة بطرق طبيعية من خلال الأوامر الصوتية. هذه المساعدات الافتراضية لا تقتصر على مجرد تنفيذ الأوامر، بل تتعلم أيضًا تفضيلات المستخدمين بمرور الوقت، مما يجعل التفاعل أكثر سلاسة وفعالية. على سبيل المثال، يمكن لهذه المساعدات أن تقدم توصيات مخصصة في مجالات مثل الموسيقى، والتسوق، والسفر، بناءً على سلوكيات المستخدم السابقة.

بالإضافة إلى ذلك، تُعتبر السيارات ذاتية القيادة من أبرز الابتكارات التي تعتمد على الذكاء الاصطناعي، حيث تستخدم تقنيات مثل الرؤية الحاسوبية ومعالجة البيانات لتحليل المعلومات من المستشعرات والكاميرات المحيطة. تعمل هذه السيارات على اتخاذ قرارات فورية للقيادة بأمان وكفاءة، مما يقلل من حوادث السير المحتملة. ومع التقدم المستمر في تقنيات الذكاء الاصطناعي، يتوقع أن تتحول هذه السيارات إلى خيار شائع في المستقبل القريب، مما يعيد تشكيل مفهوم النقل ويقلل من الاعتماد على السائقين البشريين.



الشكل [2-3]: مجالات الذكاء الاصطناعي.

في مجال الرعاية الصحية، تلعب تقنيات الذكاء الاصطناعي دوراً محورياً في تحسين دقة التشخيص والعلاج. فمثلاً، تستخدم أنظمة الذكاء الاصطناعي في تحليل الصور الطبية مثل الأشعة السينية والأشعة المقطعية، مما يساعد الأطباء في اكتشاف الأمراض مبكراً، مثل السرطان، مما يساهم في تحسين النتائج الصحية للمرضى. كما يتم استخدام تقنيات التعلم الآلي لتحديد الأنماط في البيانات الصحية الضخمة، مما يمكن من تقديم علاجات مخصصة تتناسب مع احتياجات كل مريض، وبالتالي تحسين فعالية العلاجات وتقليل الآثار الجانبية.

لا يقتصر استخدام الذكاء الاصطناعي على الحياة اليومية والرعاية الصحية فقط، بل يمتد أيضاً إلى مجالات الأمن والمراقبة. تستخدم الأنظمة الأمنية المتقدمة التي تعتمد على الذكاء الاصطناعي في كاميرات المراقبة الذكية لتحديد الأشخاص المطلوبين والتعرف على الأنشطة المشبوهة. هذه الأنظمة تتمتع بقدرة عالية على تحليل مقاطع الفيديو في الوقت الحقيقي، مما يساعد في تحسين الأمن في الأماكن العامة والخاصة على حد سواء. من خلال تقنيات التعلم العميق ومعالجة الصور، تستطيع هذه الأنظمة التعرف على الأنماط والسلوكيات غير الطبيعية، مما يساهم في الحد من الجريمة وزيادة الأمان المجتمعي.

إضافةً إلى ذلك، تُستخدم تقنيات الذكاء الاصطناعي في مجالات مثل التسويق، حيث يتم تحليل سلوكيات العملاء على الإنترنت لتقديم إعلانات مستهدفة تناسب اهتماماتهم. وفي مجال التعليم، يتم استخدام الذكاء الاصطناعي لإنشاء تجارب تعليمية مخصصة، تتكيف مع احتياجات كل طالب، مما يحسن من فعالية التعليم.

بهذه الطريقة، يمثل الذكاء الاصطناعي عنصراً حيوياً في تطور المجتمعات الحديثة، حيث يساهم في تحسين جودة الحياة وزيادة مستوى الأمان. يتواصل البحث والتطوير في هذا المجال لإيجاد حلول مبتكرة تتجاوز القيود الحالية، مما يفتح المجال لتطبيقات جديدة ومثيرة تعزز من قدرتنا على التعامل مع التحديات اليومية وتعزز من مستوى الرفاهية والأمان في المجتمع. [13][14]

4-2-2 الذكاء الاصطناعي في أنظمة المراقبة الذكية

في عصر تتزايد فيه الحاجة إلى الحفاظ على الأمن العام، برز الذكاء الاصطناعي كأداة حيوية لتعزيز قدرات أنظمة المراقبة الذكية وتطويرها بشكل غير مسبوق. يُستخدم الذكاء الاصطناعي في تحليل تدفقات الفيديو في الوقت الحقيقي، مما يسمح بالكشف السريع عن الأنشطة غير المعتادة والتنبؤ بالسلوكيات المشتبها بها قبل وقوعها، حيث تعتمد هذه الأنظمة على خوارزميات متقدمة تتفاعل مع الصور وتحلل البيانات المرئية بشكل دقيق، مما يساهم في الكشف الفوري عن الجرائم المحتملة أو التهديدات الأمنية [3]. تعتمد تقنيات الذكاء الاصطناعي في أنظمة المراقبة على أدوات مثل التعرف على الوجوه، التي تعتمد على تحليل السمات الوجهية للأفراد لتحديد هوياتهم، حتى في البيئات المكتظة. تساهم هذه التقنيات في الكشف السريع عن الأفراد المطلوبين وتعزيز قدرة السلطات على رصد وتحليل الحوادث الأمنية في الوقت الحقيقي، مما يزيد من فعالية الاستجابة الأمنية الفورية ويعزز من كفاءة أنظمة المراقبة في مكافحة الجريمة [15].

إلى جانب ذلك، يسهم الذكاء الاصطناعي في تقليل الاعتماد على العامل البشري في مراقبة الأماكن العامة، حيث تستطيع الأنظمة المعتمدة على الذكاء الاصطناعي تغطية مساحات كبيرة دون الحاجة إلى تدخل بشري مستمر. بفضل خوارزميات التعلم العميق، تتمكن هذه الأنظمة من تحليل الأنماط السلوكية وتحديد الأنشطة غير الاعتيادية، مثل السلوكيات العدوانية أو تجمعات الحشود الكبيرة المفاجئة، مما يقلل من الأخطاء البشرية ويزيد من دقة التحذيرات الأمنية ويخفض من تكاليف العمالة [1].

مع زيادة الاعتماد على الذكاء الاصطناعي في أنظمة المراقبة، أصبحت هذه الأنظمة قادرة على التعامل مع التهديدات الأمنية بشكل استباقي بفضل معالجة البيانات بسرعة ودقة، مما يرفع من مستوى الأمان في الأماكن العامة والخاصة. وبالرغم من فوائدها، يظل هناك أهمية كبيرة لتطبيق معايير أخلاقية تضمن حماية الخصوصية عند استخدام تقنيات مثل التعرف على الوجوه، والتي تعتمد على البيانات الشخصية وتثير المخاوف المتعلقة بالخصوصية [3][15].

تشير الأبحاث الحديثة إلى أن أنظمة المراقبة الذكية المدعومة بالذكاء الاصطناعي تُحدث تحولاً جوهرياً في كيفية تطبيق الأمن في المدن الحديثة، حيث تساهم في بناء بيئة آمنة دون المساس بحقوق الأفراد في الخصوصية. تتيح هذه الأنظمة لصناع القرار الوصول إلى معلومات دقيقة وإحصاءات مفيدة، مما يساعد على تطوير خطط فعّالة للحفاظ على السلامة العامة وتحقيق التنمية المستدامة في المجتمعات المدنية [3][1].

2-3 التعلم الآلي (Machine Learning – ML)

2-3-1 تعريف التعلم الآلي

يُعدّ التعلم الآلي فرعاً حيويًا من الذكاء الاصطناعي يهدف إلى تطوير الأنظمة التي تستطيع التعلم من البيانات واتخاذ القرارات بدون الحاجة إلى برمجة واضحة لكل خطوة، حيث تُدرَّب هذه الأنظمة على مجموعات كبيرة من البيانات لتتعرف على الأنماط الموجودة فيها وتستخدمها في تقديم التنبؤات والتحليلات بناءً على معلومات مشابهة مستقبلاً [16]. يعتمد التعلم الآلي على خوارزميات رياضية متقدمة، تهدف إلى تحسين الأداء التنبؤي للنماذج عبر تعلّم الأنماط والعلاقات بين البيانات وتحسين جودة النتائج كلما زادت البيانات التي تُدرَّب عليها النماذج [18].

يتضمن بناء النماذج عملية تدريب مكثفة على البيانات المتاحة بحيث تتعلم الخوارزميات أنماطاً محددة تمكنها من تقديم التوقعات الدقيقة. على سبيل المثال، في تطبيقات التعرف على الصور، يقوم التعلم الآلي بإنشاء نموذج يستطيع التمييز بين الفئات المختلفة عبر التعرف على الخصائص المميزة في الصور المدخلة، مثل الحدود والألوان وأشكال الكائنات، مما يمكّن النموذج من تصنيف الصور المستقبلية بناءً على ما تعلمه سابقاً [16].


أحد أبرز مميزات التعلم الآلي هو قدرته على التعامل مع البيانات الكبيرة والمعقدة، حيث تتكيف الخوارزميات المستخدمة مع البيانات بشكل متكرر، مما يجعلها قادرة على تحسين أدائها بمرور الوقت وزيادة حجم البيانات المتاحة. هذا التكيف المستمر يساهم في تحسين دقة النماذج وقدرتها على تقديم نتائج ذات موثوقية عالية، خاصة عند تطبيقه في المجالات التي تتطلب معالجة بيانات ضخمة مثل المالية، والطب، وخدمات العملاء [16].

تتضمن تطبيقات التعلم الآلي العديد من المجالات، مثل التحليلات المالية، حيث يُستخدم للتنبؤ بحركة الأسواق وتقييم المخاطر، وكذلك في الرعاية الصحية لتحليل الصور الطبية وتشخيص الأمراض. كما يُعد

التعلم الآلي ركيزة أساسية في تقنيات معالجة اللغة الطبيعية، مما يمكنه من تحسين تجربة المستخدمين من خلال تقديم توصيات مخصصة وتقديم استجابات ذات دقة أعلى، بالإضافة إلى تعزيز كفاءة الأنظمة الذكية عبر أتمتة العديد من العمليات المتكررة [17].

2-3-2 أنواع التعلم الآلي

يعد التعلم الآلي أحد الفروع الرئيسية للذكاء الاصطناعي، حيث يمتلك القدرة على تحسين الأداء من خلال الاستفادة من الخبرات السابقة. يتم تصنيف التعلم الآلي إلى ثلاثة أنواع رئيسية: التعلم تحت الإشراف، التعلم بدون إشراف، والتعلم المعزز. كل نوع من هذه الأنواع يتمتع بخصائص مميزة ويستخدم في مجالات متعددة، مما يتيح له التعامل مع تحديات فريدة في قطاعات متنوعة، بما في ذلك التقنية والقطاعات غير التقنية.



الشكل [2-4]: أنواع التعلم الآلي.

التعلم تحت الإشراف هو أحد الأنواع الأكثر شيوعاً في التعلم الآلي. يتضمن تدريب النماذج باستخدام بيانات مدخلة تحتوي على نتائج معروفة مسبقاً، مما يمكن النظام من التعلم واكتشاف الأنماط والعلاقات بين المدخلات والمخرجات. يُعتبر هذا النوع فعالاً في التطبيقات التي تتطلب تنبؤات دقيقة، مثل تصنيف الصور أو التنبؤ بأسعار الأسهم. على سبيل المثال، عندما يتم تدريب نموذج على بيانات عن أسعار المنازل وخصائصها، يمكن استخدام النموذج لاحقاً لتقدير أسعار المنازل الجديدة بناءً على ميزاتها. يشمل

التعلم تحت الإشراف نوعين رئيسيين هما: التصنيف، حيث يتم تحديد الفئات للبيانات، والانحدار، حيث يتم توقع القيم المستمرة. من المزايا الرئيسية لهذا النوع أنه يوفر دقة عالية في التنبؤ، لكنه يتطلب مجموعات بيانات كبيرة معلمة مسبقاً، مما يزيد من التكلفة والوقت المطلوبين لجمع هذه البيانات. بالإضافة إلى ذلك، يمكن أن يؤدي الاعتماد على البيانات المعلمة إلى إنحيازات إذا كانت البيانات غير تمثيلية أو تتضمن أخطاء.

التعلم بدون إشراف، على النقيض من ذلك، يركز على تحليل البيانات واستخراج الأنماط دون وجود نتائج معروفة مسبقاً. يُستخدم هذا النوع عندما تكون البيانات متاحة بدون أي إشارات أو توجيهات، مما يسمح للنموذج بالبحث عن الأنماط والعلاقات الداخلية بشكل مستقل. يعد التعلم بدون إشراف مفيداً في العديد من التطبيقات مثل تجميع البيانات وتحديد الأنماط المخفية في سلوك المستخدمين، مما يساعد الشركات في تحسين استراتيجياتها التسويقية. من بين التقنيات المستخدمة في هذا النوع، يعتبر التجميع من أبرزها، حيث يتم تقسيم البيانات إلى مجموعات متشابهة وفقاً لخصائصها. كما تُستخدم تقنيات مثل تحليل الارتباط لاكتشاف العلاقات بين المتغيرات. على الرغم من مزايا هذا النوع، بما في ذلك عدم الحاجة إلى بيانات معلمة، فإنه يواجه تحديات تتعلق بصعوبة تفسير الأنماط المكتشفة وإمكانية الحصول على نتائج غير دقيقة أو مضللة.

أما التعلم المعزز، فهو نوع مبتكر يركز على كيفية اتخاذ القرار من خلال تفاعل النظام مع البيئة. يعتمد هذا النوع على فكرة أن النموذج يتعلم من خلال التجربة، حيث يتلقى مكافآت أو عقوبات بناءً على أداؤه. يُستخدم التعلم المعزز بشكل واسع في مجالات تتطلب اتخاذ قرارات متتابعة، مثل تطوير الروبوتات وألعاب الفيديو وأنظمة القيادة الذاتية. يتمثل الهدف الرئيسي من التعلم المعزز في تدريب النموذج لتحقيق أقصى قدر من المكافآت على المدى الطويل، مما يتطلب منه استراتيجيات معقدة لتوقع النتائج المستقبلية. يتميز

هذا النوع بمرونته وقدرته على التكيف، ولكنه أيضًا يتطلب موارد حاسوبية كبيرة، ووقتًا طويلاً للوصول إلى الأداء الأمثل، مما قد يشكل عقبة أمام بعض التطبيقات.

على الرغم من التحديات المرتبطة بكل نوع، يمثل التعلم الآلي مجالًا غنيًا بالتقنيات والتطبيقات المتنوعة التي تساهم في التطور المستمر للحلول الذكية. تستمر الأبحاث في تطوير الأساليب والتقنيات الجديدة لمواجهة هذه التحديات، مما يفتح آفاقًا جديدة في مجال الذكاء الاصطناعي. تقدم التطورات الحديثة في تخزين البيانات وقدرة المعالجة دعمًا كبيرًا لتوسيع نطاق استخدام التعلم الآلي، مما يجعله جزءًا لا يتجزأ من المستقبل في مجالات متعددة مثل الطب، الأمن، والتجارة.

باختصار، يمكن القول إن التعلم الآلي يوفر مجموعة من الحلول المتقدمة التي تعزز كفاءة وفعالية العمليات في مجموعة متنوعة من القطاعات. يساهم كل نوع من أنواع التعلم في إحداث ثورة في كيفية معالجة البيانات واستخدامها، مما يؤكد على أهمية الاستمرار في البحث والتطوير في هذا المجال. يتطلب التقدم في التعلم الآلي فهماً عميقاً للبيانات وسياق استخدامها، مما يجعل الأبحاث في هذا المجال ضرورية لضمان التحسين المستمر وتطبيق هذه التقنيات بشكل فعال [18][19].

2-3-3 دور التعلم الآلي في أنظمة المراقبة الذكية

تعد أنظمة المراقبة الذكية المعتمدة على التعلم الآلي من التطورات الرائدة في مجال الأمن والسلامة، حيث تساهم بشكل كبير في تعزيز القدرة على تحليل وتفسير البيانات الضخمة المأخوذة من الكاميرات المراقبة. تتيح هذه الأنظمة تحليل كميات هائلة من البيانات في الوقت الفعلي، مما يقلل من الحاجة إلى التدخل البشري المستمر ويساعد في تقليل أوقات الاستجابة للمواقف الخطرة. يعتمد النظام على استخدام تقنيات متقدمة لتحليل الأنماط والتعرف على الوجوه والتنبؤ بالسلوكيات المشبوهة، مما يجعلها وسيلة فعالة لتحديد التهديدات قبل وقوعها [20][21].

تحليل البيانات الضخمة هو جانب رئيسي في هذه الأنظمة، حيث تقوم تقنيات التعلم الآلي بتحليل كميات كبيرة من البيانات الناتجة عن كاميرات المراقبة، وهو ما يتطلب موارد حوسبة عالية وأدوات مخصصة لتنفيذ هذا النوع من التحليل. تعتبر كاميرات المراقبة التقليدية وحدها غير كافية لمواجهة التحديات الأمنية المتزايدة، لا سيما مع ارتفاع معدلات الجريمة، وبالتالي يصبح الاعتماد على تقنيات التعلم الآلي ضرورياً لتحليل البيانات بسرعة ودقة. يتم استخدام خوارزميات متطورة مثل الشبكات العصبية التلافيفية (CNNs) لتحليل الإطارات الفردية في الفيديو، وتحليل العلاقة الزمنية بين الإطارات باستخدام الشبكات العصبية المتكررة (RNNs) أو الشبكات ثلاثية الأبعاد التلافيفية (D-CNNs3)، مما يوفر نمطاً أكثر تفصيلاً للمراقبة والتحليل [21].

أما التعرف على الأنماط والوجوه، فيعد من الجوانب الرئيسية التي تعتمد عليها أنظمة المراقبة الذكية الحديثة، حيث يتم استخدام خوارزميات التعلم الآلي مثل OpenCV لتحليل الصور وتحديد الوجوه ومقارنتها بقواعد بيانات للأفراد المطلوبين. يعتمد النظام في هذا المجال على تقنيات التعرف البيومتري التي تحظى بشعبية متزايدة بسبب دقتها، حيث يتم من خلالها استبعاد الحضور المادي للقيام بعملية التحقق. من خلال مقارنة وجوه الأشخاص في الفيديوهات بمكتبات صور، يمكن لهذه الأنظمة إرسال تنبيهات فورية للسلطات عند اكتشاف أفراد مطلوبين، مما يساعد في زيادة كفاءة العمل الأمني وتجنب الاعتماد على تقنيات أقل موثوقية مثل بصمات الأصابع التي قد لا تكون متاحة دائماً في مسارح الجريمة [20].

بالإضافة إلى ذلك، يمكن لتقنيات التعلم الآلي المتقدمة التنبؤ بالسلوكيات المشبوهة من خلال تحليل الأنشطة غير الطبيعية التي تحدث في الأماكن العامة. يتم تدريب الأنظمة على التعرف على أنماط السلوك المألوفة، وعند رصد سلوك غير طبيعي أو مشتببه به، يتم إصدار تنبيهات فورية للجهات المختصة. يتطلب ذلك استخدام بيانات تدريب تحتوي على مجموعة من السيناريوهات الطبيعية والمشبوهة، بالإضافة إلى

توفير كميات كبيرة من البيانات الفعلية لتدريب الخوارزميات على اكتشاف الأنماط غير الاعتيادية. يشمل النظام أيضاً إرسال تنبيهات تلقائية عبر الرسائل النصية القصيرة أو البريد الإلكتروني، مصحوبة بإطارات الصور الملتقطة التي تحتوي على السلوك المشبوه، مما يسهل على الأفراد المسؤولين الوصول إلى المعلومة بسرعة واتخاذ الإجراءات اللازمة في الوقت المناسب [21].

بشكل عام، تمثل أنظمة المراقبة الذكية المدعومة بالتعلم الآلي طفرة في مجال الأمن، حيث تسهم في تعزيز استجابة النظام للمواقف الطارئة وتقليل التكاليف المرتبطة بالمراقبة اليدوية. ومع التطورات المستمرة في تقنيات التعلم العميق ومعالجة الفيديو، يصبح من المتوقع أن تلعب هذه الأنظمة دوراً أكبر في المستقبل لتحسين الأمن والسلامة العامة [20][21].

2-3-4 خوارزميات التعلم الآلي المستخدمة في أنظمة المراقبة الذكية

2-3-4-1 خوارزمية دعم الآلات (Support Vector Machines – SVM)

تُعد خوارزمية دعم الآلات (SVM) من أبرز الخوارزميات المستخدمة في مجال التصنيف، وتعتمد على إيجاد الحد الفاصل الأمثل بين الفئات المختلفة في البيانات. وتهدف هذه الخوارزمية إلى تحديد "الحد الفاصل" الذي يفصل البيانات بوضوح، بحيث تكون أقرب نقطة من كل فئة لهذا الحد بعيدة قدر الإمكان، مما يعزز دقة التصنيف. وتُستخدم خوارزمية دعم الآلات بشكل رئيسي مع البيانات الكبيرة والمعقدة، حيث يمكنها تمييز الأنماط الدقيقة والفئات المتشابهة، مما يجعلها فعالة في تصنيف الكائنات أو الأفراد [22]. في أنظمة المراقبة الذكية، يتم الاستفادة من هذه الخوارزمية لتحليل بيانات الصور أو الفيديو الملتقطة من الكاميرات لتحديد الوجوه أو السمات المستهدفة. ويعتمد النظام على إنشاء نموذج يعتمد على خصائص الخوارزمية للتعرف على السمات الفريدة للأفراد المدرجين في قاعدة البيانات، بحيث يتم تطبيقه مراراً على الصور الجديدة التي تلتقطها الكاميرات، وعند التعرف على وجه مشتببه به أو سمات معينة، يتم إرسال

تنبيه للجهات المختصة. وتُتيح الخوارزمية دقة عالية وسرعة في التصنيف، ما يجعلها ملائمة للتطبيقات الأمنية التي تتطلب تحديد الهوية بسرعة عالية.

مزايا خوارزمية دعم الآلات (SVM):

- تقدم دقة عالية في التصنيف والتعرف على الأنماط.
- تعمل بشكل جيد مع البيانات الكبيرة والمعقدة.
- توفر أداءً قويًا مع بيانات متعددة الفئات.
- تقلل من أخطاء التصنيف بفضل الحد الفاصل الأمثل.
- مثالية للاستخدام في الأنظمة التي تتطلب معالجة دقيقة للصور.

عيوب خوارزمية دعم الآلات (SVM):

- تتطلب قوة حسابية عالية عند التعامل مع مجموعات بيانات ضخمة.
- قد تكون بطيئة في التحليل والاستجابة مقارنةً بخوارزميات أبسط.
- صعوبة التنفيذ في حالة البيانات غير المتوازنة.
- صعوبة تحديد معلمات النموذج في بعض التطبيقات.
- تقل كفاءتها عند التعامل مع بيانات شديدة التشابك أو غير خطية.

2-4-3-2 شجرة القرار (Decision Tree)

تُعتبر خوارزمية شجرة القرار واحدة من أساليب التعلم الآلي المستخدمة بشكل واسع في التصنيف واتخاذ القرارات. تعتمد شجرة القرار على تقسيم البيانات إلى عقد متتابعة تمثل قرارات منطقية تقود في النهاية إلى النتائج أو التصنيفات النهائية. يُعد هذا النهج مناسباً لاكتشاف الأنماط السلوكية، حيث يمكن للخوارزمية تفريع القرارات بناءً على الخصائص المميزة لكل فئة، ما يتيح تفسيرًا واضحًا لكل خطوة من خطوات اتخاذ

القرار. في أنظمة المراقبة الذكية، يمكن أن تُسهم شجرة القرار في الكشف عن الأنشطة المشبوهة من خلال تحليل السمات المتكررة في سلوكيات الأفراد. يتم بناء شجرة قرار تعتمد على بيانات السلوك أو الصور من كاميرات المراقبة، حيث يتم تدريب الشجرة على تحديد النشاطات المعتادة وغير المعتادة، وبذلك يمكن استخدامها لتحديد الأفراد المطلوبين عند ظهورهم في أماكن معينة أو عند اتباعهم لأنماط مشبوهة. يتيح هذا النظام سهولة التفسير وفهم الأسباب التي قادت إلى اتخاذ القرار، مما يجعل الخوارزمية مناسبة لتطبيقات المراقبة التي تتطلب الشفافية في التحليل. [22]

مزايا خوارزمية شجرة القرار:

- توفر بنية واضحة يمكن تفسيرها بسهولة.
- فعالة في الكشف عن الأنماط السلوكية البسيطة والمعقدة.
- تتيح سهولة إضافة أو إزالة بيانات جديدة في أي وقت.
- تتمتع بأداء جيد مع البيانات الصغيرة والمتوسطة الحجم.
- ملائمة للأنظمة التي تحتاج إلى شفافية في اتخاذ القرارات.

عيوب خوارزمية شجرة القرار:

- قد تؤدي إلى نتائج غير دقيقة إذا كانت البيانات كثيرة أو متداخلة.
- قد تتعرض لمشكلة التحسين الزائد (overfitting) مع البيانات التدريبية.
- حساسة جداً للتغيرات البسيطة في البيانات.
- تتطلب عملية بناء شجرة قرارات كبيرة الوقت والموارد.
- قد تكون غير فعالة مع بيانات متعددة الفئات أو شديدة التعقيد.

2-3-4 خوارزمية K-Means للتجميع

تُستخدم خوارزمية K-Means لتجميع البيانات عن طريق تقسيمها إلى مجموعات (clusters) بحيث تكون البيانات داخل كل مجموعة متشابهة قدر الإمكان، بينما تختلف عن المجموعات الأخرى. تُطبق هذه الخوارزمية غالباً في تحليل الأنماط، حيث يتم تحديد عدد المجموعات المستهدف، وتبدأ الخوارزمية بتحديد مراكز مبدئية لهذه المجموعات، ومن ثم تُخصص كل نقطة بيانات للمجموعة الأقرب، ويتم تحديث مراكز المجموعات بناءً على المتوسطات الجديدة حتى يتم الوصول إلى الاستقرار [22]. في أنظمة المراقبة الذكية، تُعتبر K-Means فعّالة لتحديد الأنماط المشتركة بين سلوكيات الأفراد؛ حيث يتم تجميع الأنماط المتشابهة لتصنيف السلوكيات المشتبه بها أو المتكررة. يمكن للنظام تحليل التدفقات الكبيرة من الفيديوها وتحديد الأماكن التي تحدث فيها نشاطات مشابهة، مما يساعد في فهم سلوكيات الأفراد في المكان وتحديد المشبوهين.

مزايا خوارزمية K-Means:

- تتيح تجميع بيانات متشابهة بشكل دقيق وفعال.
- مناسبة لتحليل كميات ضخمة من البيانات.
- توفر أداءً جيداً وسرعة استجابة مناسبة في التطبيقات الأمنية.
- تساعد على اكتشاف الأنماط المشتركة وتحديد الأنشطة المشتبه بها.
- تتيح مرونة عالية في تحديد عدد المجموعات والسمات المميزة.

عيوب خوارزمية K-Means:

- تتطلب تحديد العدد الأمثل للمجموعات مسبقاً.
- قد لا تحقق دقة عالية مع بيانات غير متوازنة.

- تتأثر بقيم البيانات الأولية وقد تتغير نتائجها بناءً على الاختيارات المبدئية.
- غير فعالة في الحالات التي تتداخل فيها المجموعات بشدة.
- تحتاج لتكرار خطوات التجميع للوصول إلى نتائج مستقرة.


2-4 التعلم العميق (Deep Learning – DL)

2-4-1 تعريف التعلم العميق

التعلم العميق هو فرع متقدم من فروع التعلم الآلي يتميز بقدرته العالية على تحليل ومعالجة البيانات المعقدة من خلال استخدام الشبكات العصبية الاصطناعية متعددة الطبقات. يشمل هذا المجال بناء شبكات عميقة تتكون من طبقات متعددة تساهم في تحليل البيانات بشكل تدريجي، حيث تبدأ العملية بطبقات إدخال تتلقى البيانات الأولية وتعمل على تحويلها إلى تمثيلات أبسط في الطبقات المخفية. يتم تدريب الشبكات العصبية الاصطناعية على التعرف على الأنماط غير الظاهرة في البيانات من خلال تكرار عمليات حسابية مستمرة تتيح لها استخراج العلاقات الأساسية التي قد لا تكون واضحة أو سهلة الوصول عبر أساليب التعلم التقليدي [23].

تستخدم الشبكات العصبية عدة طبقات مخفية بين طبقة الإدخال وطبقة الإخراج، وتعمل كل طبقة على معالجة البيانات المدخلة وفقاً لأنماط محددة ومهام خاصة، كاستخراج ميزات معينة أو تحديد سلوك معين، ومن ثم إرسال النتائج إلى الطبقة التالية. تساعد هذه العملية المتسلسلة في الكشف عن ميزات البيانات بعمقٍ متزايد عند الانتقال من طبقة لأخرى، مما يتيح إمكانية استيعاب المعلومات التي تحتوي على مستويات مختلفة من التجريد [23]. يسمح هذا الهيكل متعدد الطبقات للشبكات العميقة بتحليل بيانات معقدة مثل الصور والنصوص والصوت بطريقة تجعلها قادرة على تحديد الخصائص المخفية التي تكون صعبة الفهم من قبل البشر أو الأدوات البرمجية التقليدية.

تمثل الشبكات العصبية العميقة نموذجًا رياضيًا عالي التعقيد، حيث تحتوي كل طبقة على وحدات حسابية تسمى "العصبونات" تعمل معًا لدمج البيانات وتحليلها للوصول إلى نتائج دقيقة. يتم تدريب هذه الشبكات باستخدام كميات ضخمة من البيانات، ويتم تحسينها بشكل مستمر من خلال عملية التعلم المتكرر، والتي تُعرف باسم "التعلم بالإشراف" عندما تكون هناك بيانات معرفة مسبقًا، أو "التعلم غير المُشرف" عندما يتم التعلم مباشرة من البيانات الخام. من خلال هذا التدرج المستمر في تحليل البيانات، يصبح التعلم العميق أداة قوية قادرة على التعرف على الأنماط الدقيقة، بما في ذلك أنماط الصور وتحليل النصوص وحتى فهم السلوكيات المعقدة، مما يجعله حلاً مثاليًا لمشكلات تتطلب ذكاءً عاليًا وتفكيراً حسابياً معقلاً [23].



الشكل [2-5]: Deep Learning VS Machine Learning.

2-4-2 الشبكات العصبية الاصطناعية

الشبكات العصبية الاصطناعية هي نماذج حسابية مستوحاة من الدماغ البشري، وهي مصممة لمعالجة البيانات وتحليل الأنماط بشكل مشابه لعمل الخلايا العصبية البيولوجية. تتألف هذه الشبكات من وحدات معالجة مترابطة تُعرف بالخلايا العصبية، تعمل مجتمعةً من خلال طبقات متعددة، تشمل طبقة الإدخال، وطبقات مخفية، وطبقة الإخراج، ما يجعلها قادرة على التعلم من كميات ضخمة من البيانات. تقوم الشبكات


العصبية الاصطناعية بتمرير البيانات عبر هذه الطبقات، بحيث تُعالج البيانات في الطبقات المخفية وتُستخرج منها خصائص محددة وفقًا للأوزان التي يتم ضبطها تلقائيًا أثناء عملية التعلم. مع مرور الوقت، وبفضل هذه الآلية التكرارية في التحسين، تستطيع الشبكات تكوين نماذج دقيقة تتعرف على الأنماط الخفية وتحدد العلاقات المعقدة في البيانات [23].

في أنظمة المراقبة الذكية، تبرز أهمية نوعين رئيسيين من الشبكات العصبية الاصطناعية: الشبكات العصبية التلافيفية (Convolutional Neural Networks – CNNs) والشبكات العصبية المتكررة (Recurrent Neural Networks – RNNs).

تُستخدم الشبكات العصبية التلافيفية بشكل أساسي لتحليل الصور واكتشاف الأنماط البصرية المعقدة، ما يجعلها أداة فعالة في تطبيقات التعرف على الوجوه والتعرف على الصور في أنظمة المراقبة الذكية. تقوم CNNs بمعالجة الصور من خلال طبقات تلافيفية متعددة، حيث يُطبق كل فلتر تلافيفي على الصورة لتحديد ملامح وخصائص محددة، مثل الحواف والتفاصيل الدقيقة. وبهذا، تصبح الشبكة قادرة على تحديد الأشخاص من خلال ملامح وجوههم، مما يعزز من فعالية الأنظمة الأمنية التي تعتمد على هذا النوع من الشبكات لرصد الأنشطة وتتبع الأفراد بدقة [23].

أما الشبكات العصبية المتكررة، فتستخدم بشكل رئيسي لتحليل البيانات المتسلسلة مثل الفيديوهاات الحية، إذ تتميز بقدرتها على تذكر البيانات السابقة بفضل بنيتها الخاصة، مما يجعلها أداة فعالة في فهم وتحليل التغيرات الزمنية. في أنظمة المراقبة الذكية، تُمكن RNNs من تتبع الأشخاص وتحليل تحركاتهم في الوقت الحقيقي من خلال قراءة الإطارات المتتابعة للفيديو. بفضل هذه القدرة على الاحتفاظ بالتسلسل الزمني للبيانات، تساعد الشبكات العصبية المتكررة في توقع الأنماط وتوفير إشارات إنذار مبكر عندما تُكتشف

تحركات أو أنماط مشبوهة، ما يعزز من مستوى الأمان في الأنظمة المعتمدة على الذكاء الاصطناعي [23].



الشكل [2-6]: خطوات عمل شبكة CNN.

تعمل الشبكات التلافيفية والمتكررة معًا بشكل متكامل في أنظمة المراقبة الذكية، حيث تسهم الأولى في تحديد الأشخاص بدقة، بينما تساعد الثانية في تحليل وتوقع تحركاتهم عبر الزمن.

3-4-2 تطبيقات التعلم العميق في أنظمة المراقبة الذكية

1. التعرف على الوجه: تعتمد أنظمة المراقبة الذكية بشكل كبير على الشبكات العصبية التلافيفية (CNN)

لتحليل وتحديد ملامح الوجه بدقة عالية. تقوم CNNs بمعالجة الصور من خلال عدة طبقات تلافيفية، حيث يتم تطبيق الفلاتر لتحديد السمات الأساسية للوجه مثل العيون، الأنف، والفم. يتم تدريب هذه الشبكات على مجموعات بيانات ضخمة تحتوي على صور للوجوه، مما يمكنها من التعرف على الوجوه في الظروف المختلفة مثل الإضاءة المتغيرة وزوايا الرؤية المتعددة. تساهم هذه التقنية في تعزيز الأمن من خلال التعرف السريع والدقيق على الأفراد في الوقت الحقيقي، مما يجعلها حلاً فعالاً في أنظمة المراقبة المتقدمة [23].

2. اكتشاف الأنماط السلوكية: يستخدم التعلم العميق في تحديد الأنماط السلوكية غير المعتادة أو الأنشطة

المشبوهة في الأماكن العامة. من خلال تحليل البيانات السلوكية المجمعة من كاميرات المراقبة، يمكن

للشبكات العصبية المتكررة (RNN) تحديد الأنماط الزمنية والتغيرات السلوكية. على سبيل المثال، إذا كان هناك شخص يظهر سلوكًا غير عادي مثل التوقف المتكرر أو التحرك في مناطق غير مألوفة، يمكن للنظام التعرف على هذه الأنماط وإصدار تنبيهات للأمان. هذا الاستخدام يعزز من فعالية أنظمة المراقبة في منع الجريمة والكشف عن النشاطات المشبوهة بشكل أكثر فعالية من الأساليب التقليدية [23].

3. **تحسين دقة الرصد:** يوفر التعلم العميق مستوى عالٍ من الدقة في تحديد الأفراد المطلوبين مقارنةً بالطرق التقليدية. بفضل استخدام CNNs و RNNs، يتمكن النظام من معالجة كميات كبيرة من البيانات وتحليلها بسرعة، مما يتيح له التعرف على الأفراد المطلوبين بدقة متناهية. بدلاً من الاعتماد على المراقبة اليدوية أو الأنظمة التقليدية التي قد تكون عرضة للأخطاء البشرية، تضمن أنظمة المراقبة الذكية المعتمدة على التعلم العميق مستوى عالٍ من الدقة والكفاءة، مما يساهم في تحقيق بيانات أكثر أمانًا [23].

4. **تحليل الفيديو في الوقت الحقيقي:** يُستخدم التعلم العميق أيضًا لتحليل تدفقات الفيديو الحية بشكل فوري. تُسهل الشبكات العصبية القدرة على التعرف على الأحداث والأنشطة أثناء حدوثها، مما يسمح بتنفيذ قرارات فورية مثل إرسال تنبيهات في حال اكتشاف سلوك غير عادي. هذه التطبيقات تساهم في تحسين مستوى الأمان في الأماكن العامة مثل المطارات ومحطات المترو [23].

5. **توقع الأحداث:** تعتمد بعض أنظمة المراقبة على التعلم العميق لتوقع الأحداث المستقبلية بناءً على البيانات التاريخية. باستخدام تقنيات مثل RNNs، يمكن للنظام توقع الحوادث المحتملة أو الأنشطة التي قد تثير القلق، مما يتيح للأجهزة الأمنية اتخاذ إجراءات استباقية قبل حدوث المشكلة [23].

4-4-2 تحديات التعلم العميق في أنظمة المراقبة

يواجه استخدام التعلم العميق في أنظمة المراقبة الذكية مجموعة من التحديات المعقدة التي تؤثر على أداء وكفاءة هذه الأنظمة في الكشف عن الأنشطة المشبوهة. فيما يلي أبرز هذه التحديات:

1. حجم البيانات الضخم: تزايد عدد كاميرات المراقبة بشكل متسارع يؤدي إلى إنتاج كميات هائلة من

البيانات المرئية. تتطلب هذه البيانات تقنيات متقدمة قادرة على تحليل المعلومات بفعالية، حيث تحتاج معظم خوارزميات التعلم العميق إلى كميات كبيرة من البيانات لتدريب النماذج بفعالية، مما يساهم في تعزيز دقتها وكفاءتها [24]. لذا، يصبح من الضروري تطوير أساليب لتحسين عملية معالجة وتحليل هذه البيانات الضخمة.

2. تنوع الأنشطة: يتطلب التعرف على الأنشطة البشرية المشبوهة مرونة عالية في تحديد الأنماط المختلفة،

مما يشكل تحديًا كبيرًا. تعتمد هذه الأنظمة على التعلم العميق لتفسير الأحداث المعقدة، ولكنها تواجه صعوبة في التكيف مع الأنشطة الجديدة أو غير العادية التي قد لا تتواجد في البيانات المستخدمة للتدريب، مما يؤثر سلبيًا على دقة الكشف وموثوقية الأنظمة [25]. يتطلب الأمر تطوير نماذج أكثر تعقيدًا قادرة على التعرف على أنماط متعددة في بيئات متغيرة.

3. تحديد الأنماط الشاذة: يتطلب اكتشاف الأنشطة غير العادية مستوى عالٍ من التعقيد في التعرف على

الأنماط. على الرغم من الاستفادة من خوارزميات التعلم العميق، لا تزال هناك حاجة ملحة لتحسين دقة الأنظمة في التعرف على الأنشطة المشبوهة في الوقت الحقيقي. تعتمد الأنظمة بشكل كبير على نماذج تدريبية تستطيع التمييز بين الأنشطة الطبيعية والشاذة، مما يتطلب وجود آليات فعالة لتقليل نسبة الخطأ في التنبؤات [24].

4. حجم البيانات التدريبية: قد تكون مجموعة البيانات المستخدمة لتدريب النماذج محدودة في بعض

الأحيان، مما يؤثر على قدرة الأنظمة على تحقيق أداء قوي. يعتبر هذا التحدي حيويًا، حيث إن زيادة

حجم البيانات التدريبية تعزز من جودة النموذج وتساعد على تحسين قدرته على التعرف على الأنشطة المختلفة. وبالتالي، يتطلب الأمر استثمارات أكبر في جمع وتحضير البيانات، مما يزيد من التعقيد والموارد المطلوبة [25].

5. التعقيد في معالجة الفيديو: يتطلب تحليل الفيديو المتصل بالنشاط البشري استخدام تقنيات معقدة ومتطورة، مما يؤثر بشكل مباشر على سرعة ودقة الأنظمة. تعد الحاجة إلى معالجة البيانات المكانية والزمنية في الوقت نفسه تحديًا إضافيًا. يتعين على الأنظمة التعامل مع تدفقات الفيديو الحية وتحديد الأنماط المتغيرة في الوقت الفعلي، مما يستدعي استخدام خوارزميات متطورة تتيح تحليل هذه المعلومات بكفاءة [24].

6. التفاعل مع المستخدم: يتطلب توفير واجهات مستخدم سهلة الاستخدام لضمان تفاعل فعال مع النظام، مما يمكن المستخدمين من تحميل الفيديوهات واستقبال التنبيهات بشكل سريع وموثوق. يعد تطوير واجهات الاستخدام عنصرًا أساسيًا في تحسين فعالية الأنظمة، حيث يجب أن تكون هذه الواجهات واضحة وسهلة التفاعل، مما يساهم في تعزيز تجربة المستخدم وفعالية النظام بشكل عام [24].

تتطلب معالجة هذه التحديات جهودًا مستمرة لفهم القيود الحالية على أنظمة التعلم العميق في المراقبة الذكية، فضلاً عن البحث عن طرق جديدة لتحسين الأداء والموثوقية.

5-2 العلاقة بين الذكاء الاصطناعي، التعلم الآلي، والتعلم العميق في أنظمة المراقبة الذكية

إن الذكاء الاصطناعي، والتعلم الآلي، والتعلم العميق تشكل ثلاث تقنيات مترابطة تلعب دورًا محوريًا في تطوير أنظمة المراقبة الذكية. حيث يعتمد الذكاء الاصطناعي بشكل أساسي على التعلم الآلي كأحد أدواته

الأساسية، والذي يتطلب بدوره التعلم العميق لتعزيز قدراته في تحليل البيانات واتخاذ القرارات. تتضح هذه العلاقة عندما ننظر إلى كيفية استخدام هذه التقنيات في تحسين كفاءة ودقة أنظمة المراقبة.

يعتبر الذكاء الاصطناعي المجال الأوسع الذي يشمل مجموعة من الخوارزميات والتقنيات التي تهدف إلى محاكاة الذكاء البشري. يعتمد الذكاء الاصطناعي على التعلم الآلي، الذي يمكن الأنظمة من تحسين أدائها من خلال التعلم من البيانات المتاحة، وتجاوز القواعد التقليدية المبرمجة مسبقاً. في المقابل، يعد التعلم العميق فرعاً متخصصاً من التعلم الآلي يستخدم الشبكات العصبية متعددة الطبقات لمعالجة كميات ضخمة من البيانات واستخراج الأنماط المعقدة منها. فعلى سبيل المثال، تعتمد أنظمة التعرف على الوجه في أنظمة المراقبة على الشبكات العصبية التلافيفية (CNN) التي تعد جزءاً من التعلم العميق، والذي يعزز القدرة على التعرف بدقة على الوجوه من بين آلاف الصور المتاحة [23].

تتعاون هذه التقنيات بشكل متكامل لتحسين فعالية أنظمة المراقبة الذكية. فعند استخدام التعلم الآلي في تحليل بيانات الفيديو، يتمكن النظام من اكتشاف الأنماط غير العادية أو الأنشطة المشبوهة. بينما يسهم التعلم العميق في تعزيز هذا التحليل عبر التعرف على التفاصيل الدقيقة التي قد يغفلها التعلم الآلي التقليدي. على سبيل المثال، في سياق أنظمة المراقبة الأمنية، يمكن للتعلم العميق معالجة وتحليل فيديوهات المراقبة بشكل آني، مما يتيح اكتشاف أي سلوك غير طبيعي بسرعة وكفاءة [24][25]. بالتالي، يصبح من الممكن تقليل الاعتماد على العنصر البشري في مراقبة الفيديوهات، مما يسهم في توفير الوقت والجهد.

تتعدد التطبيقات العملية التي تظهر كيف يمكن استخدام هذه التقنيات بشكل متكامل لتوفير نظام مراقبة شامل يغطي جميع جوانب الأمان. من خلال دمج الذكاء الاصطناعي مع التعلم الآلي والتعلم العميق، يتمكن المشغلون من تحليل السلوكيات المختلفة للمارة في الأماكن العامة، وتحديد ما إذا كانت هذه السلوكيات تمثل تهديداً محتملاً. على سبيل المثال، يمكن استخدام خوارزميات التعلم العميق لتحليل

سلوكيات الأفراد في المطارات، مما يسمح بالكشف المبكر عن الأنشطة المشبوهة مثل التجمعات الغير اعتيادية أو التصرفات غير العادية [24][25]. إن إنشاء أنظمة قادرة على رصد السلوكيات غير المعتادة وتحليلها بشكل آني يعزز من مستوى الأمان ويساهم في اتخاذ قرارات سريعة وفعالة في حال حدوث أي تهديد.

إن العلاقة الوثيقة بين الذكاء الاصطناعي، التعلم الآلي، والتعلم العميق تمثل إحدى اللبنات الأساسية لتطوير أنظمة المراقبة الذكية. مع تزايد الاعتماد على هذه التقنيات، يتزايد الأمل في تحسين معايير الأمان وتقديم حلول مبتكرة للتحديات التي تواجه المجتمعات اليوم.

الفصل الثالث: الرؤية

الحاسوبية

3-1 تمهيد

مع التزايد الكبير في الاعتماد على التكنولوجيا لتعزيز الأمن، وتتامي متطلبات السلامة في القطاعات العامة والخاصة، أصبحت أنظمة المراقبة الذكية ضرورة لا يمكن الاستغناء عنها. تشهد هذه الأنظمة تطورًا متسارعًا بفضل الذكاء الاصطناعي وتقنيات الرؤية الحاسوبية، التي تشكل أحد أهم أدوات التحليل والاستجابة في الوقت الفعلي. إن دور الرؤية الحاسوبية يتعدى مجرد تسجيل البيانات المرئية، حيث يمكن الأنظمة من فهم وتحليل المحتوى المرئي بشكل معمق، والتعرف على الأنماط والأشخاص في بيئات متعددة، مما يسهم في تعزيز القدرة على الاستجابة للأحداث فور حدوثها.

تمثل الرؤية الحاسوبية حجر الزاوية لأنظمة المراقبة الذكية، فهي تمكن الأنظمة من التعرف على الأشخاص عبر التعرف على الوجوه، واكتشاف أي حركات أو أحداث غير اعتيادية في المكان. وبما أن حجم البيانات التي يتم جمعها عبر هذه الأنظمة ضخم للغاية، فإن تحليل هذه البيانات دون دعم تقنيات متقدمة سيكون معقدًا وغير فعال. لذلك، تتيح تقنيات التعلم العميق والذكاء الاصطناعي تحليل البيانات بشكل سريع وفعال، مما يجعل أنظمة المراقبة قادرة على اتخاذ قرارات سريعة واستباقية.

في هذا السياق، يتناول هذا الفصل المكونات الأساسية التي تدعم عمل نظام المراقبة الذكي المقترح، ويتطرق إلى الأدوات والخوارزميات المستخدمة لتعزيز فعالية ودقة النظام. يشمل الفصل شرحًا عامًا للرؤية الحاسوبية، وكيفية استخدام خوارزميات اكتشاف الكائنات مثل نموذج YOLO لدعم عملية رصد الأشخاص وتحديد مواقعهم بدقة. كما يستعرض الفصل خوارزميات التعرف على الوجه، التي تسهم في تحديد الأفراد المطلوبين بسرعة وفعالية. إضافة إلى ذلك، يتم التركيز على الآليات المستخدمة لتحسين جودة الصور قبل معالجتها، مما يعزز من دقة النظام في مختلف الظروف البيئية.


3-2 مقدمة عن الرؤية الحاسوبية (Computer Vision)

الرؤية الحاسوبية هي مجال متخصص في تمكين الحواسيب من فهم المحتوى المرئي المتمثل في الصور والفيديوهات، حيث تسعى إلى محاكاة القدرات الإدراكية البشرية في تحليل البيانات المرئية واستخلاص المعلومات المفيدة منها (انظر الشكل 2-1). تعتمد هذه التقنية على معالجة الصور والفيديوهات باستخدام خوارزميات متقدمة تسمح بالتعرف على الأنماط والكائنات والأشخاص في البيئات المختلفة، مما يجعلها عنصراً أساسياً في أنظمة المراقبة الذكية. تتمثل أهمية الرؤية الحاسوبية في قدرتها على تحليل تدفقات الفيديو في الوقت الفعلي، مما يتيح الكشف السريع عن الأنشطة غير الاعتيادية والتنبؤ بالسلوكيات المشبوهة قبل حدوثها. بالإضافة إلى ذلك، تُستخدم تقنيات التعرف على الوجوه لتحديد هويات الأفراد المطلوبين أو المشبوهين في الأماكن العامة، مما يعزز من فعالية الأنظمة الأمنية في الاستجابة الفورية للتهديدات المحتملة. تعمل الرؤية الحاسوبية أيضاً على تقليل الاعتماد على المراقبة البشرية المستمرة، حيث يمكن للأنظمة الذكية تحليل كميات كبيرة من البيانات المرئية بشكل آلي، مما يقلل من الأخطاء البشرية ويوفر الوقت والجهد. كما تساهم في تحسين جودة الصور قبل معالجتها، مما يزيد من دقة النظام في ظروف إضاءة مختلفة أو صور ذات جودة منخفضة. بفضل هذه القدرات، أصبحت الرؤية الحاسوبية حجر الزاوية في تطوير أنظمة المراقبة الذكية، حيث تعمل على تعزيز الأمن والسلامة في الأماكن العامة من خلال تحليل السلوكيات غير الطبيعية وإصدار تنبيهات فورية للجهات المختصة. [26]

الرؤية الحاسوبية تعتمد على مجموعة من التقنيات والخوارزميات المتقدمة لتحليل الصور والفيديوهات لفهم المحتوى المرئي. تبدأ العملية بجمع البيانات المرئية من الكاميرات، حيث يتم تحويل الصور أو الفيديوهات إلى بيانات رقمية يمكن معالجتها بواسطة الحواسيب. بعد ذلك، تُستخدم خوارزميات التعلم العميق، مثل الشبكات العصبية التلافيفية (CNNs)، لاستخراج الميزات الأساسية من الصور، مثل الحواف والأشكال والأنماط. هذه الميزات تُستخدم لاحقاً للتعرف على الكائنات أو الأشخاص في المشهد.


في حالة الفيديوها، تعتمد الرؤية الحاسوبية على تقنيات معالجة البيانات المتسلسلة، مثل الشبكات العصبية المتكررة (RNNs)، لتحليل الإطارات المتتالية وفهم التغيرات الحركية أو السلوكيات. على سبيل المثال، يمكن للنظام اكتشاف حركات غير عادية أو أنشطة مشبوهة في الوقت الفعلي، مما يجعله أداة فعالة في أنظمة المراقبة الذكية. بالإضافة إلى ذلك، تُستخدم تقنيات التثليث (Triangulation) لإعادة بناء المشاهد ثلاثية الأبعاد من صور ثنائية الأبعاد (الشكل 3-2)، مما يسمح بفهم أعمق للبيئة المحيطة.

تساهم هذه التقنيات في تحسين دقة وكفاءة أنظمة الأمن، حيث يمكن للرؤية الحاسوبية تحليل كميات كبيرة من البيانات المرئية بشكل آلي، مما يقلل من الحاجة إلى التدخل البشري. كما تعمل على تحسين جودة الصور قبل معالجتها، مما يزيد من دقة النظام في ظروف إضاءة مختلفة أو صور ذات جودة منخفضة. بفضل هذه القدرات، أصبحت الرؤية الحاسوبية عنصراً أساسياً في تطوير أنظمة المراقبة الذكية، حيث تعمل على تعزيز الأمن والسلامة في الأماكن العامة من خلال تحليل السلوكيات غير الطبيعية وإصدار تنبيهات فورية للجهات المختصة.



الشكل [3-1]: تزايد عدد المنشورات الأكاديمية حول اكتشاف الأشياء (Object Detection) في مجال الرؤية الحاسوبية من عام 2010

إلى عام 2024.



الشكل [2-3]: عملية إعادة بناء نموذج ثلاثي الأبعاد باستخدام تقنية التثليث.

3-3 الخطوات الثلاث الرئيسية للتعرف على الكائنات

تعتمد عملية التعرف على الكائنات باستخدام الرؤية الحاسوبية على ثلاث خطوات رئيسية مترابطة، تهدف إلى تحويل البيانات المرئية إلى معلومات قابلة للفهم والتحليل. تبدأ هذه العملية بجمع الصور أو الفيديوها من الكاميرات، حيث يتم تحويل المشاهد المرئية إلى بيانات رقمية. تلي ذلك مرحلة كشف الكائنات، والتي يتم فيها تحديد مواقع الكائنات أو الأشخاص في الصور أو الفيديوها. أخيرًا، تأتي مرحلة تصنيف الكائنات، حيث يتم تحديد هوية الكائنات أو الأشخاص بناءً على الميزات المستخرجة. هذه الخطوات الثلاث تعمل بشكل متكامل لتمكين الأنظمة الذكية من فهم المحتوى المرئي والاستجابة له بشكل فعال.


3-3-1 إدخال الصور

تعتبر عملية جمع الصور أو الفيديوها من الكاميرات الخطوة الأولى والأساسية في أنظمة الرؤية الحاسوبية، حيث يتم تحويل البيانات المرئية إلى معلومات رقمية يمكن معالجتها بواسطة الحواسيب. تُستخدم الكاميرات بأنواعها المختلفة، بما في ذلك الكاميرات الثابتة والكاميرات المثبتة على المركبات الجوية غير المأهولة (UAVs)، لجمع البيانات المرئية من البيئات المختلفة. تعتمد جودة البيانات المجمعة على عوامل متعددة، مثل دقة الكاميرا، زاوية التصوير، والإضاءة المحيطة.

في حالة الكاميرات المثبتة على المركبات الجوية غير المأهولة (UAVs)، يتم جمع الصور من ارتفاعات مختلفة لتغطية مساحات واسعة، مما يوفر مرونة كبيرة في الحصول على صور عالية الدقة. ومع ذلك، فإن التحديات التي تواجه هذه العملية تشمل التغيرات في زوايا التصوير، الدقة، والإضاءة، والتي يمكن أن تؤثر على جودة البيانات المجمعة. على سبيل المثال، في دراسة أجريت باستخدام طائرة DJI air2s، تم جمع 48 صورة RGB من حقل زراعي لتحليل انتشار مرض الصدا الأصفر في القمح. تم تقسيم الصور إلى مجموعتين: مجموعة تدريبية ومجموعة اختبارية، حيث تم استخدام 24 صورة للتدريب و24 صورة للاختبار [27].


بعد جمع الصور، يتم تحميلها إلى برامج معالجة الصور مثل Ladder، الذي يوفر واجهة مستخدم رسومية (GUI) لتحميل الصور وتحديد المناطق ذات الاهتمام. يمكن للمستخدمين تحميل الصور عبر شريط القائمة العلوي وتحديد الحجم المناسب عن طريق التكبير أو التصغير. يتيح البرنامج أيضًا خيارين لتحديد المناطق ذات الاهتمام: الأول هو الرسم اليدوي للمستطيلات حول الكائنات، والثاني هو استخدام نموذج مدرب مسبقًا مثل YOLO للتنبؤ بالكائنات تلقائيًا. يوضح الشكل (3-3) واجهة المستخدم الرسومية لبرنامج Ladder، والتي تسمح بتحميل الصور وتحديد المناطق ذات الاهتمام يدويًا أو تلقائيًا باستخدام نموذج YOLO [27].

في حالة الفيديوها، يتم تحليل الإطارات المتتالية لفهم التغيرات الحركية أو السلوكيات. تُستخدم تقنيات مثل الشبكات العصبية المتكررة (RNNs) لتحليل البيانات المتسلسلة، مما يسمح بالكشف عن الأنشطة غير الاعتيادية في الوقت الفعلي. على سبيل المثال، في أنظمة المراقبة الذكية، يمكن للكاميرات تحليل تدفقات الفيديو لاكتشاف السلوكيات المشبوهة مثل التوقف المتكرر أو التحرك في مناطق غير مألوفة [28].



الشكل [3-3]: واجهة المستخدم الرسومية (GUI) لبرنامج Ladder والوظائف الرئيسية. تتكون واجهة المستخدم الرسومية من ثلاثة أجزاء (a). يمكنها تحقيق خطوات متتالية للتنبؤ، التعديل، والتحديث لتطوير نموذج كشف الأشياء (b).

بشكل عام، تعتبر عملية جمع الصور أو الفيديوها من الكاميرات خطوة حاسمة في أنظمة الرؤية الحاسوبية، حيث توفر البيانات الأولية اللازمة لتحليل المحتوى المرئي وفهمه. يتم تحسين هذه العملية باستخدام تقنيات متقدمة مثل الذكاء الاصطناعي والتعلم العميق لضمان دقة وكفاءة الأنظمة. يوضح الشكل (3-4) دقة نموذج YOLO v3 في تقييم مستويات مختلفة من انتشار مرض الصدف الأَصفر في القمح، مما يعكس فعالية هذه التقنيات في تحليل البيانات المرئية [27].



الشكل [3-4]: أداء نموذج YOLO v3 المدرب باستخدام نظام Ladder . يتم استخدام خريطة حرارية لمصفوفة الارتباك لعرض دقة نموذج YOLO v3 المدرب في تقييم مستويات مختلفة من شدة صدى الأوراق في القمح.

2-3-3 كشف الكائنات

يعد كشف الكائنات خطوة أساسية في مجال الرؤية الحاسوبية، حيث يلعب دوراً محورياً في تحليل الصور وفهم المحتوى المرئي. يتمثل الهدف الرئيسي من كشف الكائنات في تحديد مواقع الكائنات أو الأشخاص داخل الصور وتصنيفها إلى فئات محددة. هذه العملية تُعتبر حجر الأساس للعديد من التطبيقات المتقدمة مثل المركبات ذاتية القيادة، أنظمة المراقبة الأمنية، والروبوتات الذكية [29].

تتضمن عملية كشف الكائنات استخدام تقنيات متقدمة مثل الشبكات العصبية التلافيفية (CNNs) ونماذج التعلم العميق الأخرى. يتم تدريب هذه النماذج على مجموعات بيانات كبيرة تحتوي على صور مع تمييز الكائنات فيها بشكل يدوي. خلال التدريب، تتعلم النماذج كيفية تحديد الكائنات بدقة عن طريق تحليل السمات البصرية مثل الحواف، الألوان، والأنماط [30].

من بين النماذج الشهيرة المستخدمة في كشف الكائنات نجد YOLO (You Only Look Once) و Faster R-CNN و Mask R-CNN. تعتمد هذه النماذج على تقنيات مختلفة لتحقيق التوازن بين الدقة والسرعة.

على سبيل المثال، YOLO يعالج الصورة بأكملها في خطوة واحدة، مما يجعله سريعًا جدًا، بينما Faster R-CNN يستخدم شبكة اقتراح المناطق (RPN) لتحسين الدقة [29].

بعد إضافة الصور إلى النظام، يتم معالجتها باستخدام خوارزميات كشف الكائنات لتحديد المواقع المحتملة للكائنات. يتم ذلك عن طريق إنشاء مربعات محيطية (Bounding Boxes) حول الكائنات المكتشفة، والتي يتم تصنيفها بناءً على الفئة التي تنتمي إليها. يتم تقييم أداء هذه الخوارزميات باستخدام مقاييس مثل متوسط الدقة (mAP) ونسبة التداخل بين المربعات المحيطة المقترحة والمربعات المرجعية (IoU) [30].


3-3-3 تصنيف الكائنات

بعد إدراج الصور أو الفيديوها وكشف الكائنات، تأتي الخطوة الثالثة والأكثر تعقيدًا، وهي تصنيف الكائنات. هذه الخطوة تُعتبر جوهر عملية تحليل الصور، حيث يتم تحديد هوية الكائنات وتصنيفها إلى فئات محددة بناءً على سماتها البصرية. تصنيف الكائنات يتطلب استخدام تقنيات متقدمة مثل التعلم العميق والشبكات العصبية لتحقيق دقة عالية في التعرف على الكائنات [31].

تبدأ عملية التصنيف باستخراج السمات البصرية من الكائنات المكتشفة. تُستخدم خوارزميات مثل SIFT (Scale-Invariant Feature Transform) و SFTA (Segmentation-Based Fractal Texture Analysis) لاستخراج السمات التي تميز كل كائن. على سبيل المثال، يتم حساب الأبعاد، متوسط مستوى التدرج الرمادي، وعدد البكسلات لإنشاء متجهات السمات. هذه المتجهات تُستخدم لاحقًا في عملية التصنيف باستخدام خوارزميات التعلم الآلي مثل الشبكات العصبية (NN) [31].

بعد استخراج السمات، يتم تدريب النماذج على مجموعات بيانات كبيرة تحتوي على صور مع تمييز الكائنات بشكل يدوي. خلال التدريب، تتعلم النماذج كيفية تحديد الكائنات بدقة عن طريق تحليل السمات البصرية مثل الحواف، الألوان، والأنماط. يتم استخدام خوارزميات مثل KNN (K-Nearest Neighbors)

أو CNN (Convolutional Neural Networks) لتصنيف الكائنات بناءً على السمات المستخرجة. على سبيل المثال، في الشكل (3-5)، تم تصنيف الكائن بشكل صحيح كدائرة باستخدام خوارزمية SIFT [31].




الشكل [3-5]: التعرف على الشكل الدائري.


أحد التحديات الرئيسية في تصنيف الكائنات هو التباين في مظهر الكائنات بناءً على زاوية الرؤية أو الإضاءة. ومع ذلك، فإن استخدام خوارزميات متقدمة مثل الشبكات العصبية يساعد في تحسين الدقة. على سبيل المثال، حقق النظام المقترح دقة بنسبة 99.4% في تحديد الأشكال، مما يجعله مناسباً للتطبيقات العملية مثل التعرف على الوجوه والمركبات ذاتية القيادة [31].

بالإضافة إلى ذلك، تم اختبار النظام على أشكال أخرى مثل المربع والمثلث، حيث أظهر دقة عالية في التعرف على هذه الأشكال. على سبيل المثال، في الشكل (3-6)، تم التعرف على شكل مربع بشكل

صحيح، بينما في الشكل (3-7)، تم التعرف على شكل مثلث. هذه النتائج تُظهر فعالية النظام في التعامل مع أشكال مختلفة وظروف إضاءة متغيرة [31].



الشكل [3-6]: التعرف على الشكل المربع.



الشكل [3-7]: التعرف على الشكل المثلث.

3-4 خوارزميات الرؤية الحاسوبية

الرؤية الحاسوبية هي مجال واسع يعتمد على مجموعة متنوعة من الخوارزميات التي تهدف إلى تحليل الصور والفيديوهات لفهم المحتوى المرئي. تعمل هذه الخوارزميات على تمكين الحواسيب من تفسير البيانات المرئية بشكل مشابه للطريقة التي يعمل بها النظام البصري البشري. تُستخدم هذه التقنيات في العديد من التطبيقات العملية، بدءًا من أنظمة المراقبة الأمنية وحتى المركبات ذاتية القيادة، مما يجعلها جزءًا أساسيًا من التطور التكنولوجي الحديث.

من بين الخوارزميات الأكثر شيوعًا في الرؤية الحاسوبية هي تلك المتعلقة بالكشف عن الكائنات (Object Detection). هذه الخوارزميات تهدف إلى تحديد وجود كائنات معينة في الصور أو الفيديوهات وتحديد موقعها باستخدام صناديق محيطية (Bounding Boxes). من أبرز الأمثلة على هذه الخوارزميات هي Sliding Window، التي تعتمد على مسح الصورة بواسطة نافذة صغيرة تتحرك عبر الصورة للبحث عن

الكائنات. يتم تطبيق نموذج تصنيف على كل نافذة لتحديد ما إذا كانت تحتوي على كائن أم لا. ومع ذلك، تعاني هذه الخوارزمية من بعض العيوب، مثل البطء في المعالجة بسبب الحاجة لمسح الصورة بأكملها، وعدم الدقة في بعض الحالات بسبب الاعتماد على أحجام ثابتة للنوافذ [29]. على الرغم من ذلك، كانت Sliding Window واحدة من الخوارزميات الأساسية في بدايات تطوير أنظمة الكشف عن الكائنات.

بالإضافة إلى خوارزميات الكشف عن الكائنات، تُعتبر خوارزميات التصنيف (Classification) من الأدوات الأساسية في الرؤية الحاسوبية. هذه الخوارزميات تُستخدم لتصنيف الصور إلى فئات محددة مسبقاً، مثل التعرف على الحيوانات أو النباتات أو الأجسام الأخرى. من أشهر هذه الخوارزميات هي CNN (Convolutional Neural Networks)، التي تُعتبر من أكثر الخوارزميات فعالية في تصنيف الصور بسبب قدرتها على استخراج السمات (Features) من الصور بشكل تلقائي. تُستخدم CNN في تطبيقات متعددة، مثل التعرف على الوجوه وتصنيف الصور الطبية، حيث تعتمد على طبقات متعددة من المرشحات التلافيفية لتحقيق دقة عالية في التصنيف [29].

في مجال التعرف على الوجوه (Face Recognition)، تُستخدم خوارزميات متخصصة لتحديد هوية الأشخاص من خلال تحليل ملامح الوجه. من بين هذه الخوارزميات هي Eigenfaces، التي تعتمد على تحليل المكونات الرئيسية (PCA) لتحديد الوجوه. هذه الخوارزمية تقوم بتحويل الصور إلى مساحة ذات أبعاد أقل، مما يسهل عملية التعرف على الوجوه. بالإضافة إلى ذلك، تُستخدم خوارزميات أكثر تطوراً مثل DeepFace، التي تعتمد على شبكات عصبية عميقة لتحقيق دقة عالية في التعرف على الوجوه. تُستخدم هذه الخوارزميات في تطبيقات الأمن والمراقبة، حيث يتم التعرف على الأشخاص في الوقت الفعلي [29].

أما في مجال التتبع (Tracking)، فإن الخوارزميات تُستخدم لتتبع حركة الكائنات عبر الفيديوها. من بين هذه الخوارزميات هي KCF (Kernelized Correlation Filters)، التي تُستخدم لتتبع الكائنات في


الفيديوهات باستخدام المرشحات التلافيفية. تعتمد هذه الخوارزمية على تحليل العلاقة بين الإطارات المتتالية لتحديد موقع الكائنات المتحركة. بالإضافة إلى ذلك، تُستخدم خوارزميات مثل SORT (Simple Online and Realtime Tracking)، التي تُعتبر من الخوارزميات السريعة والفعالة في تتبع الكائنات في الوقت الفعلي. تُستخدم هذه الخوارزميات في تطبيقات مثل أنظمة المراقبة الأمنية والمركبات ذاتية القيادة [29].

على الرغم من تعدد الخوارزميات المستخدمة في الرؤية الحاسوبية، إلا أن الخوارزميات الأكثر تطوراً مثل YOLO (You Only Look Once) أصبحت الخيار الأول في العديد من التطبيقات الحديثة. تتميز YOLO بالسرعة الفائقة والدقة العالية، حيث تقوم بتحليل الصورة بأكملها مرة واحدة لتحديد مواقع الكائنات وتصنيفها. تُستخدم YOLO في تطبيقات متعددة، مثل أنظمة المراقبة الأمنية، المركبات ذاتية القيادة، وحتى في تطبيقات الطائرات بدون طيار (UAVs) للكشف عن الأجسام في الوقت الفعلي [32].

1-4-3 خوارزمية YOLO (You Only Look Once)

خوارزمية YOLO (You Only Look Once) تُعد من أبرز تقنيات الذكاء الاصطناعي في مجال كشف الكائنات داخل الصور والفيديوهات، حيث تعتمد على تحليل الصورة دفعة واحدة بدلاً من تقسيمها إلى خطوات متعددة كما في النماذج التقليدية. هذا النهج يُمكن YOLO من تحقيق سرعة عالية ودقة جيدة، مما يجعلها مثالية للتطبيقات التي تتطلب استجابة فورية في الزمن الحقيقي، مثل أنظمة القيادة الذاتية والمراقبة الأمنية. تقوم الخوارزمية بتقسيم الصورة إلى شبكة من الخلايا، وتعمل كل خلية على توقع مربعات إحاطة للكائنات وتصنيفها حسب الفئة، مما يتيح الكشف الدقيق والسريع حتى في الصور المعقدة أو التي تحتوي على عدد كبير من العناصر. وقد تطورت YOLO عبر عدة إصدارات، بدءاً من YOLOv1 الذي قَدّم مفهوم المعالجة الموحدة، وصولاً إلى YOLOv10 الذي ألغى بعض الخطوات لتحسين الكفاءة مثل إزالة عملية القمع غير الأقصى (NMS)، وهو ما ساهم في تقليل زمن التأخير. من أبرز التحسينات التي شهدتها الإصدارات المتقدمة مثل YOLOv8 هي القدرة على التعامل مع الصور عالية الدقة والتعرف على الكائنات

الصغيرة أو المتداخلة بدقة أعلى، مع المحافظة على سرعة التنفيذ. تُستخدم هذه الخوارزمية في العديد من المجالات العملية، مثل التعرف على الوجوه وتتبع الأشخاص في أنظمة الأمن، والتعرف على الإشارات والمشاة في السيارات ذاتية القيادة، وكذلك في تحليل الصور الطبية والتطبيقات الرياضية وتحليل السلوك البشري. بالمقارنة مع تقنيات أخرى مثل Faster R-CNN و SSD، تتفوق YOLO من حيث السرعة مع الحفاظ على دقة معقولة، إذ يمكنها معالجة ما يصل إلى 45 إطارًا في الثانية، مقابل 7 إطارات فقط لـ Faster R-CNN، مما يجعلها الخيار المفضل للتطبيقات التي تتطلب أداءً سريعًا وفعالًا في الوقت الحقيقي [33] [34] [35] [36].




الشكل [3-8]: عملية الكشف عن الكائنات باستخدام خوارزمية YOLO.

2-4-3 التعرف على الوجوه (Face Recognition)

التعرف على الوجوه هو أحد أكثر تطبيقات الذكاء الاصطناعي إثارة للإعجاب وانتشارًا في السنوات الأخيرة، وهو ببساطة القدرة على تحديد أو تأكيد هوية شخص من خلال صورة وجهه، لكن لفهم هذه التقنية علينا

أن نغوص قليلاً في كيفية رؤية الحاسوب للوجه البشري. بينما يرى الإنسان الوجوه بتلقائية شديدة ويميز بينها بسهولة حتى في ظروف صعبة كالظلام أو الزوايا الغريبة، فإن الحاسوب يتعامل مع الصورة كبيانات مكونة من ملايين البيكسلات، وهي نقاط صغيرة تمثل تدرجات مختلفة من الألوان والإضاءة، ومن خلال تحليل هذه النقاط بطرق معقدة يصبح بإمكان النظام استخراج معلومات مفيدة. عملية التعرف على الوجه تمر بعدة مراحل أساسية تبدأ بما يُعرف بالكشف عن الوجه، وهي عملية البحث داخل الصورة عن منطقة تحتوي على ملامح وجه، وتُستخدم في ذلك خوارزميات تعتمد على التحليل الهندسي للأنماط مثل حواف العينين، الأنف، الفم، وحجم الوجه، وعند تحديد الموقع يتم عزله لمزيد من التحليل.



الشكل [3-9]: النقاط المميزة للوجه.

بعد ذلك ينتقل النظام إلى مرحلة تحديد معالم الوجه، والتي تتضمن رسم نقاط دقيقة على أجزاء الوجه الأساسية، مثل زوايا العين، مركز الأنف، حدود الفم، والذقن، وهذه النقاط تُستخدم ليس فقط لفهم شكل الوجه ولكن لضبط اتجاهه وتصحيحه إذا كان مائلاً أو منحرفاً، مما يساعد على ضمان الدقة في المقارنة لاحقاً. المرحلة الأهم هي تحويل هذا الوجه إلى تمثيل رقمي رياضي يعرف باسم التشفير أو الـ encoding،

وهذا يعني أن النظام يحلل ملامح الوجه المحسوسة ويحولها إلى مجموعة من الأرقام الثابتة، غالبًا ما تكون عبارة عن 128 رقمًا تمثل البصمة الرقمية الفريدة لذلك الوجه، وهي بصمة تختلف عن أي وجه آخر حتى وإن تشابه شكله كثيرًا. بمجرد تحويل الوجوه إلى بصمات رقمية، يمكن للنظام إجراء المقارنة، فإذا أردنا التحقق من أن وجهًا جديدًا يخص شخصًا معروفًا لدينا مسبقًا، نقارن البصمة الرقمية الجديدة مع البصمات المخزنة، وإذا كانت المسافة الرياضية بين هذه الأرقام صغيرة فإن النظام يستنتج أن الوجهين ينتميان لنفس الشخص، أما إذا كانت الفروق أكبر من حد معين، فغالبًا يكون الشخص مختلفًا. وتستخدم هذه الطريقة في أنظمة مراقبة الدخول، والهواتف الذكية، والكاميرات الأمنية، وغيرها من التطبيقات. إحدى أشهر المكتبات البرمجية التي تسهل استخدام هذه التقنية في بايثون هي مكتبة face_recognition، وهي مكتبة مفتوحة المصدر تقوم بجميع المراحل السابقة بطريقة مبسطة للمستخدم، حيث تعتمد في الأساس على مكتبة dlib التي تحتوي على نموذج مدرب مسبقًا باستخدام شبكات عصبونية تلافيفية، هذا النموذج تم تدريبه على آلاف الصور لوجوه مختلفة بهدف تعلم التمثيل العددي الدقيق لها. ما يجعل مكتبة face_recognition مميزة هو أنها تخفي التعقيد الكامل خلف واجهة استخدام بسيطة، فالمستخدم لا يحتاج إلى معرفة كيفية بناء النموذج أو كيفية استخراج الخصائص، بل يمكنه فقط تحميل الصور وطلب استخراج البصمات ومقارنتها. وهذه المكتبة لا تعمل فقط على صورة واحدة، بل يمكنها التعامل مع صور تحتوي على عدة وجوه، وتميز كل وجه على حدة، ومطابقته مع البيانات السابقة. التقنية أثبتت فعاليتها في ظروف متعددة ولكنها ليست مثالية، إذ قد تواجه صعوبات في حالات الإضاءة السيئة، أو إذا تم تغطية جزء كبير من الوجه، أو في حال حدوث تغييرات كبيرة مثل اللحية الكثيفة أو ارتداء نظارات شمسية، ومع ذلك فهي دقيقة جدًا في الظروف الطبيعية. ومن المهم الإشارة إلى أن هذه التقنية رغم قوتها يجب استخدامها بحذر ومسؤولية، فهي تتعامل مع معلومات شخصية حساسة، والاعتماد عليها في أنظمة المراقبة أو تحديد الهوية يجب أن يكون ضمن إطار قانوني وأخلاقي يحترم الخصوصية الفردية. الوجه هو أحد أكثر السمات البشرية

تميزًا، وتحويله إلى مجموعة من الأرقام القابلة للمعالجة فتح آفاقًا جديدة في التكنولوجيا الحديثة، سواء في الأمن، أو الهواتف، أو حتى في التعليم والتفاعل الإنساني مع الآلة، وهذه القدرة التي طورها الإنسان لتقليد دماغه في تمييز الوجوه لا تزال في تطور مستمر، وقد تأخذنا مستقبلًا إلى تطبيقات أكثر تعقيدًا وتميزًا، ولكن سيظل المبدأ الأساسي فيها قائمًا على الفكرة البسيطة: كيف يمكن للحاسوب أن يرى ما نراه نحن، ويفهمه، ويقرّر بناءً عليه.

3-5 تحسين جودة الصور


تحسين جودة الصور قبل تطبيق خوارزميات الكشف والتصنيف يُعد خطوة أساسية لضمان دقة وكفاءة النماذج المستخدمة في التعلم الآلي. الصور ذات الجودة المنخفضة قد تحتوي على ضوضاء أو تشوهات أو إضاءة غير متساوية، مما يجعل من الصعب على الخوارزميات استخراج السمات المهمة بدقة. على سبيل المثال، في دراسة حول تأثير جودة البيانات على عدالة تصنيف الصور، وجد أن الضوضاء في البيانات تؤدي إلى انخفاض في دقة النماذج وزيادة في التحيز [38]. لذلك، تحسين جودة الصور قبل المعالجة يساعد في تحسين أداء النماذج وزيادة موثوقيتها.

إحدى التقنيات الرئيسية المستخدمة لتحسين جودة الصور هي تصحيح الإضاءة، حيث يتم تعديل الصور لتحسين توزيع الإضاءة فيها، مما يجعل التفاصيل أكثر وضوحًا. هذه التقنية مهمة خاصة في الصور التي يتم التقاطها في ظروف إضاءة غير مثالية. على سبيل المثال، في دراسة حول تحسين جودة الصور للكشف عن الوجوه، تم استخدام تقنيات تصحيح الإضاءة لتحسين أداء النموذج في ظروف إضاءة مختلفة [39]. كما يظهر في الشكل (3-10)، الصور التي تم تصحيح إضاءتها كانت أكثر وضوحًا وسهولة في التصنيف مقارنة بالصور الأصلية.




الشكل [3-10]: صورة ذات جودة عالية (على اليسار)، نسختها المضغوطة بجودة منخفضة باستخدام (JPEG) في المنتصف، ونسختها ذات الدقة المكانية المنخفضة (على اليمين).

تقنية أخرى مهمة هي إزالة الضوضاء، والتي تعمل على تقليل التشوهات في الصور الناتجة عن عوامل مثل الضوضاء الإلكترونية أو ضغط الصور. هذه التقنية تساعد في تحسين جودة الصور عن طريق إزالة العناصر غير المرغوب فيها التي قد تؤثر على دقة النماذج. في دراسة حول تأثير جودة البيانات على تصنيف الصور، تم استخدام تقنيات إزالة الضوضاء لتحسين دقة النماذج [38]. على سبيل المثال، في الشكل (3-11)، تمت مقارنة الصور قبل وبعد إزالة الضوضاء، حيث أظهرت النتائج تحسناً ملحوظاً في وضوح الصور ودقة التصنيف.



الشكل [3-11]: تحسين العدالة مع تحسين جودة بيانات التدريب (أي مستويات مختلفة من ضوضاء التسميات) على مجموعة بيانات (FMNIST).

أيضاً، تحسين الدقة يُعد من التقنيات الفعالة لزيادة وضوح الصور عن طريق زيادة عدد البكسلات أو تحسين التفاصيل. هذه التقنية مهمة خاصة في الصور ذات الدقة المنخفضة، حيث تساعد في جعل التفاصيل أكثر وضوحاً وبالتالي تحسين أداء النماذج. في دراسة حول تحسين جودة الصور للكشف عن الوجوه، تم استخدام تقنيات تحسين الدقة لزيادة دقة النموذج [39]. كما يظهر في الشكل (3-12)، الصور التي تم تحسين دقتها كانت أكثر تفصيلاً وسهولة في التصنيف. بالإضافة إلى ذلك، هناك تقنيات أخرى مثل التصنيف بناءً على الجودة، حيث يتم تصنيف الصور إلى فئات بناءً على جودتها قبل تطبيق خوارزميات الكشف. في دراسة حول تحليل الصور المصنفة بناءً على الجودة، تم استخدام شبكات عصبية عميقة لتصنيف الصور إلى فئات مثل "جودة عالية"، "جودة متوسطة"، و"جودة منخفضة"، ثم تطبيق خوارزميات كشف مناسبة لكل فئة [39]. هذا النهج ساعد في تحسين دقة النموذج بشكل كبير، خاصة عند التعامل مع صور ذات جودة مختلطة.



الشكل [3-12]: الإطار العام للتنبؤ بمستوى الجودة والكشف/التعرف على الوجوه المصنفة بناءً على الجودة.

تقنيات تحسين جودة الصور تساعد في زيادة دقة النظام عن طريق تحسين جودة البيانات المدخلة للنماذج. على سبيل المثال، تصحيح الإضاءة يساعد في جعل التفاصيل أكثر وضوحًا في الصور الملتقطة في ظروف إضاءة غير مثالية، مما يسهل على النموذج استخراج السمات المهمة. إزالة الضوضاء تساعد في تقليل التشوهات التي قد تؤثر على دقة النموذج، بينما تحسين الدقة يجعل التفاصيل أكثر وضوحًا ويسهل عملية التصنيف. في دراسة حول تأثير جودة البيانات على تصنيف الصور، وجد أن تحسين جودة الصور أدى إلى زيادة دقة النماذج بشكل ملحوظ [38].

علاوة على ذلك، فإن استخدام تقنيات مثل t-SNE لتحديد وإزالة الصور الشاذة من مجموعات البيانات يمكن أن يحسن بشكل كبير من دقة النماذج. في دراسة حول تحسين دقة الشبكات العصبية التلافيفية، تم استخدام t-SNE لتحديد الصور الشاذة في مجموعة بيانات تحتوي على صور لأعطال البناء. بعد إزالة هذه الصور، تم إعادة تدريب النموذج، مما أدى إلى زيادة دقة التصنيف من 81.25% إلى 87.5% [40]. هذا يوضح أهمية تنظيف البيانات قبل التدريب لضمان أفضل أداء للنموذج.

3-6 تطبيقات الرؤية الحاسوبية في أنظمة المراقبة الذكية

تعد الرؤية الحاسوبية أحد الركائز الأساسية في تطوير أنظمة المراقبة الذكية، حيث توفر تقنيات متقدمة تمكن من تحليل البيانات المرئية بشكل تلقائي وفعال. من بين التطبيقات العملية للرؤية الحاسوبية في هذا المجال هو التعرف على الوجوه، الذي يسمح بتحديد هوية الأفراد من خلال مقارنة السمات الفريدة لوجوههم مع قواعد بيانات مخزنة مسبقاً. هذه التقنية تُستخدم على نطاق واسع في المطارات والمؤسسات الأمنية لتعزيز الأمن من خلال الكشف عن الأشخاص المطلوبين أو غير المرغوب فيهم. بالإضافة إلى ذلك، تُستخدم تقنيات التعرف على الوجوه في أنظمة التحكم في الوصول إلى المنشآت الحساسة، مما يقلل من الاعتماد على الوسائل التقليدية مثل البطاقات أو الرموز السرية [2].

من التطبيقات الأخرى المهمة كشف الحركات المشبوهة، حيث يتم استخدام خوارزميات متقدمة لتحليل الفيديو في الوقت الفعلي لتحديد الأنشطة غير الطبيعية. على سبيل المثال، يمكن للنظام اكتشاف حركات مثل التسلل أو ترك الأشياء المشبوهة في الأماكن العامة. هذه التقنية تعتمد على مقارنة الإطارات المتتالية للفيديو لتحديد التغيرات في المشهد، مما يسمح بإصدار تنبيهات فورية في حالة اكتشاف أي نشاط مريب. هذا النوع من التطبيقات يُسهم بشكل كبير في تعزيز الأمن في الأماكن العامة مثل المولات والمحطات، حيث يمكن للأنظمة أن تتفاعل بسرعة مع التهديدات المحتملة [2].

أما تحليل تدفقات الفيديو في الوقت الفعلي، فهو أحد التطبيقات الحيوية التي تعتمد على الرؤية الحاسوبية لمراقبة المناطق الواسعة بشكل مستمر. هذه الأنظمة قادرة على معالجة كميات هائلة من البيانات المرئية في الوقت الفعلي، مما يسمح بمراقبة عدة مناطق في آن واحد دون الحاجة إلى تدخل بشري مكثف. على سبيل المثال، يمكن لهذه الأنظمة تتبع تحركات الأشخاص أو المركبات عبر كاميرات متعددة، مما يوفر

رؤية شاملة لحركة المرور أو الحشود في الأحداث الكبيرة. هذا النوع من التحليل يُسهم في تحسين إدارة الأزمات والاستجابة السريعة للحوادث [2].

تساهم هذه التطبيقات مجتمعة في تعزيز الأمن والسلامة في الأماكن العامة من خلال توفير مراقبة مستمرة وفعالة. التعرف على الوجوه يقلل من فرص التسلل أو الوصول غير المصرح به، بينما كشف الحركات المشبوهة يوفر طبقة إضافية من الحماية من خلال التنبيه الفوري عن أي نشاط غير طبيعي. تحليل تدفقات الفيديو في الوقت الفعلي يسمح بمراقبة شاملة وفورية، مما يسهل عملية اتخاذ القرارات السريعة في حالات الطوارئ. هذه التقنيات مجتمعة تُسهم في خلق بيئة أكثر أمانًا وتقلل من الاعتماد على العنصر البشري، مما يحد من الأخطاء ويزيد من كفاءة أنظمة المراقبة [2].

3-7 التحديات التي تواجهها تقنيات الرؤية الحاسوبية في أنظمة المراقبة الذكية

تواجه أنظمة الرؤية الحاسوبية في مجال المراقبة الذكية مجموعة من التحديات المعقدة التي يمكن أن تؤثر على أدائها وفعاليتها. أحد هذه التحديات يتمثل في التغيرات في الإضاءة والظروف البيئية، حيث تؤثر العوامل مثل الوهج والظلال والإضاءة المنخفضة على جودة الصورة، مما يؤدي إلى صعوبة في اكتشاف الأشياء والتعرف عليها بدقة. لمواجهة هذه المشكلة، يمكن استخدام تقنيات التعلم العميق التي يتم تدريبها على مجموعات بيانات متنوعة تشمل ظروف إضاءة مختلفة. بالإضافة إلى ذلك، يمكن لتقنيات مثل تحسين الصورة والتطبيع واستخدام الشبكات العنائية التوليدية (GAN) أن تعزز قدرة النماذج على العمل بشكل فعال في ظروف الإضاءة المتغيرة [41].

تعد الكثافة السكانية العالية تحديًا آخر، حيث يصعب تمييز الأفراد في الحشود الكثيفة بسبب التداخلات والانسدادات. هذا يمكن أن يؤدي إلى أخطاء في تتبع الأشخاص وإحصائهم. لحل هذه المشكلة، يمكن استخدام بنىات التعلم العميق متعددة النطاقات والهرمية، والتي تلتقط الميزات على مستويات مختلفة من

التفاصيل. كما يمكن لتقنيات الانتباه أن تساعد النماذج على التركيز على الأجزاء المهمة من الصورة، مما يحسن من دقة التعرف على الأفراد حتى في البيئات المزدحمة [41].

أيضاً، تُعد معالجة كميات كبيرة من البيانات في الوقت الفعلي تحدياً رئيسياً، حيث تتطلب أنظمة المراقبة تحليلاً سريعاً للفيديو دون تأخير. هذا يمكن أن يضع ضغطاً كبيراً على الموارد الحاسوبية. للتغلب على هذا التحدي، يمكن تطوير نماذج تعلم عميق خفيفة الوزن تقلل من الحمل الحسابي دون التضحية بالدقة. تقنيات مثل تقليل النماذج والتقسيم الكمي، بالإضافة إلى استخدام الحوسبة المتطورة، يمكن أن تسهل المعالجة السريعة للبيانات، مما يضمن استجابة فورية في أنظمة المراقبة [41].

بالإضافة إلى ذلك، تُشكل الانسدادات الشديدة وتشوه الأشياء عقبة كبيرة، حيث قد تظهر الأشياء بشكل جزئي أو مشوه في المشاهد المزدحمة. هذا يعقد عملية الكشف والتتبع. لمعالجة هذه المشكلة، يمكن استخدام خوارزميات اكتشاف الكائنات المتقدمة التي تدمج السياق والمعلومات الزمنية. تقنيات مثل الشبكات العصبية المتكررة (RNNs) وشبكات الذاكرة طويلة المدى (LSTM) يمكن أن تساعد في تتبع الأشياء بمرور الوقت، مما يحسن من قدرة النظام على التعرف عليها رغم الانسدادات [41].

يُعد اختلاف وجهة النظر تحدياً آخر، حيث تظهر الأشياء بشكل مختلف عند النظر إليها من زوايا متعددة. هذا يجعل من الصعب على النماذج المدربة على وجهات نظر محددة أن تعمم بشكل جيد. لتحسين الأداء في هذا الجانب، يمكن استخدام تقنيات زيادة البيانات التي تعرض النماذج لوجهات نظر مختلفة بشكل مصطنع. كما يمكن للنمذجة ثلاثية الأبعاد والتعلم متعدد العروض أن يعزز قدرة النموذج على التعرف على الأشياء من زوايا متعددة، مما يحسن من دقة النظام في ظروف العالم الحقيقي [41].

الفصل الرابع: التنفيذ

العملي والنتائج

4-1 تمهيد

في هذا الفصل، نقدم عرضًا تفصيليًا لمرحلة التنفيذ العملي للنظام، حيث يتم تحويل الأفكار والتصميمات النظرية إلى تطبيق عملي فعال. تُعد هذه المرحلة من أهم مراحل المشروع، حيث يتم فيها برمجة النظام واختباره وتنفيذه باستخدام الأدوات والمكتبات المناسبة. وتكمن أهمية اختيار الأدوات والمكتبات المناسبة في ضمان كفاءة الأداء، وسهولة التطوير، وسرعة المعالجة، بالإضافة إلى دقة النتائج المستخلصة، مما يساهم بشكل كبير في نجاح المشروع وتحقيق أهدافه بكفاءة.

4-2 أدوات وبيئات التطوير المستخدمة

4-2-1 اللغات البرمجية والأدوات

• **لغة Python:** تُعتبر لغة بايثون واحدة من أشهر لغات البرمجة في العالم، وذلك بسبب بساطتها وسهولة تعلمها حتى للمبتدئين. كما تحتوي على عدد كبير من المكتبات الجاهزة التي تساعد في تنفيذ مهام مختلفة مثل التعرف على الوجوه، الذكاء الاصطناعي، وتحليل البيانات. هذه المزايا جعلت بايثون اللغة المثالية لتطوير المشاريع التقنية بسرعة وكفاءة.



الشكل [4-1]: لغة البرمجة Python.

• **Jupyter Notebook:** هو بيئة برمجية تفاعلية تُسمح بكتابة الكود وتشغيله بشكل مباشر، إلى جانب عرض النتائج والرسوم البيانية في نفس الصفحة. يُستخدم بشكل واسع في تحليل البيانات والتعليم، ويُعد أداة مناسبة للتجريب السريع وعرض النتائج بطريقة مرئية واضحة.



الشكل [2-4]: Jupyter Notebook.

• **Anaconda:** هو أداة قوية تُستخدم لإدارة البيئات الافتراضية وتثبيت الحزم البرمجية (Packages) الخاصة بلغة بايثون. تساعدنا في العمل على مشاريع مختلفة باستخدام إصدارات مختلفة من بايثون والمكتبات دون التسبب في مشاكل بينها، مما يجعل عملية التطوير أكثر سهولة وتنظيمًا.



الشكل [3-4]: Anaconda.

• **SQLite3:** هي قاعدة بيانات خفيفة الوزن ولا تحتاج إلى خادم خارجي، وتُخزن البيانات في ملف بسيط. تُستخدم بشكل واسع في المشاريع الصغيرة والمتوسطة لتخزين المعلومات مثل بيانات المستخدمين أو في هذا المشروع لتخزين صور الوجوه المشبوهة وأوقات رصدها. فهي سهلة الاستخدام وسريعة بما يكفي للأداء الجيد في تطبيقات مثل هذه.



الشكل [4-4]: قاعدة البيانات SQLite.


2-2-4 المكتبات

- face-recognition: تُستخدم للكشف عن الوجوه في الصور أو الفيديو، وتحليل ميزاتها، ومن ثم مطابقتها مع صور موجودة. هي مكتبة قوية وفعالة، وتُعتبر سهلة الاستخدام مقارنة بغيرها، مما يجعلها مناسبة للمشاريع التي تعتمد على التعرف على الوجوه بدقة وسرعة.
- MediaPipe: توفر أدوات متطورة لمعالجة الفيديو وتحليل الحركات، مثل تتبع حركة الجسم والوجه. تساعد في استخراج نقاط الوجه أو وضعيات الجسد بشكل دقيق، مما يفيد في تطبيقات المراقبة والتفاعل مع النظام عبر الإيماءات أو الحركات.
- OpenCV: تُعتبر واحدة من أهم الأدوات في مجال معالجة الصور والفيديو. تُستخدم لقراءة الكاميرات، عرض الصور، تحسين جودتها، وتحويلها إلى صيغ مناسبة للتحليل. كما تدعم الكشف عن الوجوه باستخدام خوارزميات متقدمة، وتُعد أداة أساسية في أي مشروع يتعامل مع الرؤية الحاسوبية.
- NumPy & PIL: تُستخدم لتخزين ومعالجة البيانات الرقمية (مثل الصور) بطريقة فعالة، بينما تُستخدم مكتبة PIL (أو Pillow) لفتح وتعديل وتحويل الصور إلى صيغ مختلفة. تُسهّم هاتان المكتبتان في تحويل الصور إلى بيانات يمكن للنظام فهمها ومعالجتها بسهولة.

- Pandas / SQLite3 API: مكتبة Pandas تُستخدم لتنظيم البيانات وتحليلها بسهولة، بينما SQLite3 هي قاعدة بيانات خفيفة تُخزن المعلومات في ملف، وتُستخدم هنا لحفظ بيانات الوجوه المشبوهة، مثل الاسم، الوقت، وموقع الكاميرا. تسمح هذه الأدوات بتخزين البيانات واسترجاعها بسرعة داخل المشروع.

3-4 تصميم النظام وبنية العمل


1-3-4 مخطط خوارزمية العمل (Flowchart of Algorithm)



الشكل [4-5]: خوارزمية العمل.

المخطط المبين في الشكل (4-5) يوضح نظاماً آلياً لكشف الوجوه المشبوهة أو المطلوبة باستخدام تقنيات التعرف على الوجوه واستخراج ميزاتها، حيث يبدأ النظام من نقطة البداية بتحديد ميزات الوجوه الموجودة في قاعدة بيانات خارجية، ثم يبدأ باستقبال الإطارات من الكاميرا لتحليلها. يتم التحقق من وجود إطارات جديدة، وفي حال توفرها يعاد تعيين حجم الإطار ويتم تمريره إلى عملية استخراج ميزات الوجه، حيث تُقارن هذه الميزات مع تلك الموجودة في قاعدة البيانات. إذا تطابقت الميزات، يُعتبر الوجه مشبوهاً ويتم تشغيل الإنذار وإرسال تفاصيله مثل اسم المجرم ورقم السيارة إلى الجهات المختصة، أما في حال عدم التطابق فيتم تسجيل الوجه كوجه جديد ضمن القاعدة. يمكن للمستخدم في أي لحظة إنهاء البرنامج أو الاستمرار في المراقبة بشكل متكرر حتى النهاية، مما يمنح النظام مرونة في التشغيل ومتابعة العمل بكفاءة.

2-3-4 مخطط تدفق البيانات (Data Flow Diagram- DFD)




الشكل [4-6]: مخطط تدفق البيانات.

4-4 التنفيذ النهائي للنظام

الشكل (4-7) يوضح واجهة برنامج بعنوان "Combined Cameras" تم من خلالها التعرف على شخص مسجل مسبقاً باسم "issa"، حيث يظهر إطار أخضر يحدد موضع الوجه في منتصف الصورة. الشكل (4-8) يبين مخرجات النظام النصية بعد عملية التعرف، حيث تم تسجيل الاسم "issa" مرفقاً بطابع زمني بتاريخ 2025-08-14 والساعة 20:08:49، مع تكرار الاسم في السجل بما يعكس نجاح عملية التعرف.


الشكل (4-9) يوضح حالة النظام عند عدم التعرف على الشخص، إذ يظهر إطار أخضر يحدد الوجه مع عرض عبارة "Unknown (ID: 1)" باللون الأحمر في أعلى الإطار. الشكل (4-10) يبين المخرجات النصية للنظام في حالة عدم التعرف، حيث يتم تسجيل كلمة "Unknown" بشكل متكرر للدلالة على فشل عملية التعرف. الشكل (4-11) يعرض نموذج قاعدة بيانات فارغة مهيأة لتخزين بيانات التعرف المستقبلية. الشكل (4-12) يوضح قاعدة بيانات تحتوي على سجل يتضمن الاسم "issa" والمعرف 1 بالإضافة إلى الطابع الزمني لعملية التعرف، بينما يبقى حقل "camera_id" فارغاً.



الشكل [4-7]: التعرف على الشخص "issa" في واجهة البرنامج.

```
issa
Logged issa at 2025-08-14 20:08:49
#####
issa
issa
issa
issa
issa
issa
issa
issa
issa
```

الشكل [4-8]: مخرجات نصية بعد التعرف على "issa".



الشكل [4-9]: واجهة البرنامج عند عدم التعرف على الشخص.

```
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
Unknown
```

الشكل [4-10]: مخرجات نصية في حالة عدم التعرف.

A	B	C	D
id	name	timestamp	camera_id

الشكل [4-11]: قاعدة بيانات فارغة.

id	name	timestamp	camera_id
1	issa	2025-08-14 20:11:28	

الشكل [4-12]: قاعدة بيانات تحتوي على بيانات الشخص "Issa".

5-4 النتائج

أظهرت نتائج المشروع أن النظام المقترح قادر على تحقيق مستوى عالٍ من الكفاءة في التعرف على الأشخاص المصرح لهم، وإدراج بياناتهم في قاعدة المعلومات بشكل منظم ودقيق، مع القدرة على التمييز بين الأفراد المعروفين وغير المعروفين. وقد تمكّن النظام من التعامل مع الحالات غير المصرح لها عبر

وضعها تلقائياً في القائمة السوداء، ما يسهم في رفع مستوى الأمان ومنع الوصول غير المصرح به. اعتمد المشروع على مزيج من تقنيات الرؤية الحاسوبية وخوارزميات التعرف على الوجوه، إضافة إلى ربط النتائج مباشرة بقاعدة بيانات مركزية تتيح تحديث المعلومات بشكل مستمر. وخلال الاختبارات العملية، أثبت النظام دقة عالية وسرعة استجابة ملحوظة في بيئات عمل متنوعة، مما يعزز موثوقيته كأداة فعالة في التطبيقات الأمنية. كما ساعد توثيق العمليات بالطابع الزمني على تحسين قدرات التتبع والتحقق من الأحداث، بالرغم من بعض التحديات التي ظهرت في ظروف الإضاءة المتغيرة أو زوايا الالتقاط غير المثالية، والتي تشكل فرصاً لتطوير الأداء مستقبلاً.

الفصل الخامس:

الخاتمة

المشروع يمثل خطوة عملية متقدمة في مجال دمج تقنيات الذكاء الاصطناعي ضمن الأنظمة الأمنية الحديثة. فقد بيّنت النتائج الفعلية أن النظام ليس مجرد نموذج نظري أو تجربة مخبرية، بل هو حل يمكن تطبيقه في بيئات حقيقية، وقادر على التعامل مع معطيات واقعية متغيرة، مثل تنوع الأشخاص، تغير الظروف المحيطة، والحاجة إلى استجابة فورية في الحالات الطارئة. إن دمج خوارزميات التعرف على الوجوه مع قاعدة بيانات مركزية وواجهة برمجية تفاعلية مكن من توفير منظومة متكاملة لإدارة عمليات المراقبة والتحقق من الهوية. هذه المنظومة ليست فقط أداة لرصد الأشخاص، بل هي أيضاً منصة لتخزين وتحليل البيانات بما يتيح لمتخذي القرار الوصول إلى معلومات دقيقة ومحدثة بشكل مستمر. كما أتاح النظام درجة مرونة مهمة في إضافة وحذف بيانات المستخدمين، وتحديث القوائم البيضاء والسوداء بما يتماشى مع متطلبات الجهة المستفيدة. ومن خلال التجارب الميدانية، ثبت أن النظام يحقق توازناً جيداً بين الدقة في التعرف وسرعة الاستجابة، وهو ما يعد من العناصر الجوهرية لنجاح أي نظام أمني يعتمد على تقنيات الرؤية الحاسوبية.

إن هذا المشروع، في صورته الحالية، يشكل قاعدة صلبة يمكن البناء عليها لتطوير نسخ أكثر تقدماً من أنظمة التعرف على الهوية. وقد مكن التوثيق الدقيق للأحداث والطوابع الزمنية من تعزيز الشفافية وسهولة المراجعة لاحقاً، ما يمنح المؤسسات أداة قوية لإدارة أمنها الداخلي والخارجي بكفاءة. إضافة إلى ذلك، فإن تصميم النظام بشكل معياري يتيح دمج مع أنظمة أمنية أخرى أو مع أدوات تحليل البيانات، ما يوسع نطاق إمكانياته المستقبلية بشكل كبير. إن استثمار مثل هذه الأنظمة لا يقتصر على المنشآت الأمنية أو الحساسة فقط، بل يمكن أن يمتد إلى مجالات أخرى مثل إدارة الحضور والانصراف، تنظيم الدخول للمناطق المقيدة، وحتى تطبيقات في القطاع التجاري والخدمي.

وبالنظر إلى الأهمية المتزايدة لأمن المعلومات والأشخاص، فإن المشروع يفتح المجال أمام العديد من فرص التطوير والتحسين. ورغم النجاحات التي حققها، فإن التجربة كشفت عن جوانب قابلة للتحسين،

خاصة فيما يتعلق بالأداء في الظروف البيئية الصعبة مثل الإضاءة المنخفضة أو زوايا التصوير غير المباشرة. كما أن التحديات المتعلقة بتنوع ملامح الوجوه والاختلافات الفردية في المظهر تدعو إلى إدماج تقنيات تعلم أعمق وأوسع من أجل زيادة دقة النظام. إن مواصلة البحث والتطوير في هذا المجال ستتمكن من الوصول إلى أنظمة أكثر تكيفاً وذكاءً، قادرة على التعلم من البيانات الجديدة وتحسين أدائها مع مرور الوقت.

الآفاق المستقبلية للمشروع يمكن تلخيصها في النقاط التالية:

- تحسين خوارزميات التعرف لرفع الدقة في بيانات الإضاءة الضعيفة أو المتغيرة.
- دمج النظام مع تقنيات بيومترية أخرى مثل التعرف على الصوت أو بصمة العين لزيادة مستويات الأمان.
- تطوير واجهات استخدام أكثر تفاعلية وسهولة لتمكين المشغلين من إدارة النظام بكفاءة أعلى.
- ربط النظام بمنصات إنذار مبكر للتعامل مع الحالات الطارئة بشكل آني.
- إضافة خاصية التعلم المستمر لتمكين النظام من تحسين أدائه مع تزايد حجم البيانات.
- توسيع قابلية التكامل مع أنظمة إدارة أمنية وأدوات تحليل بيانات أخرى.
- تحسين إدارة وحفظ البيانات التاريخية لضمان سهولة الوصول إليها عند الحاجة.
- تطبيق النظام في مجالات أوسع مثل المؤسسات التعليمية، المرافق العامة، والفعاليات الكبرى لضمان الأمن وسلاسة الحركة.

جدول المصطلحات العلمية

الاختصار	الدلالة بالإنجليزية	الدلالة بالعربية
DL	Deep Learning	التعلم العميق
CNN	Convolutional Neural Networks	الشبكات العصبية التلافيفية
AI	Artificial Intelligence	الذكاء الاصطناعي
CV	Computer Vision	الرؤية الحاسوبية
SVM	Support Vector Machine	آلة المتجهات الداعمة
ROI	Region of Interest	منطقة الاهتمام
GPU	Graphic Processing Unit	وحدة معالجة الرسومات
ANN	Artificial Neural Networks	الشبكات العصبية الاصطناعية
OCR	Optical Character Recognition	التعرف الضوئي على الحروف

المراجع

- [1] Suman, S. (2023). Application of Smart Surveillance System in National Security. *Unity Journal*, 4, 317–330.
- [2] Saketh, M., Nandal, N., Tanwar, R., & Reddy, B. P. (2023). Intelligent surveillance support system. *Discover Internet of Things*, 3 (9).
- [3] Rahimi Ardabili, B., Danesh Pazho, A., Alinezhad Noghre, G., Neff, C., Bhaskararayuni, S. D., Ravindran, A., Reid, S., & Tabkhi, H. (2023, February 8). Understanding Policy and Technical Aspects of AI-Enabled Smart Video Surveillance to Address Public Safety. University of North Carolina at Charlotte.
- [4] Anagnostopoulos, T., Kostakos, P., Zaslavsky, A., Kantzavelou, I., Tsotsolas, N., Salmon, I., Morley, J., & Harle, R. (2021). Challenges and Solutions of Surveillance Systems in IoT-Enabled Smart Campus: A Survey. *IEEE Access*.
- [5] Mueller, B. (2020, January 24). London police to deploy facial recognition cameras across the city. *The New York Times*. Retrieved from <https://www.nytimes.com/2020/01/24/business/london-police-facial-recognition.html>
- [6] Al Jazeera. (2018, November 8). مراقبون في كل مكان: الصين تعرف مواطنيها. <https://www.aljazeera.net/tech/2018/11/8/مراقبون-في-كل-مكان-الصين-تعرف-مواطنيها>
- [7] Goswami, T. (2022). Human Intelligence and Machines. *Medicon Engineering Themes*, 2 (6), 63–65.
- [8] Rodionov, A. A., Fayziev, R. A., & Jakupov, G. A. (2022). The introduction of artificial intelligence in statistical and economic research. The 6th International Conference on Future Networks & Distributed Systems (ICFNDS '22), December 15, 2022, Tashkent, TAS, Uzbekistan. ACM, New York, NY, USA.
- [9] Oliveira, A. L., & Figueiredo, M. A. T. (2024). Artificial Intelligence: Historical Context and State of the Art. In H. Sousa Antunes et al. (Eds.), *Multidisciplinary Perspectives on Artificial Intelligence and the Law (Law, Governance and Technology Series, Vol. 58)*. Springer.
- [10] AL-Allaf, O. N. A., Tamimi, A. A., & Alia, M. A. (2013). Face Recognition System Based on Different Artificial Neural Networks Models and Training Algorithms.

International Journal of Advanced Computer Science and Applications (IJACSA), 4(6), 40–50.

[11] Gutierrez, C. I., Aguirre, A., Uuk, R., Boine, C. C., & Franklin, M. (2023). A Proposal for a Definition of General–Purpose Artificial Intelligence Systems. *Digital Society*, 2, 36.

[12] Damar, M., Özen, A., Çakmak, Ü.E., Özoğuz, E., Erenay, F. S. (2024). Super AI, Generative AI, Narrow AI and Chatbots: An Assessment of Artificial Intelligence Technologies for The Public Sector and Public Administration. *Journal of AI*. 8(1), 83–106. Doi: 10.61969/jai.1512906

[13] Abdel Galil, W. (2023). Applications of Artificial Intelligence in the Field of Diagnostic Medicine and Future Prospects. *International Journal of Artificial Intelligence and Emerging Technology*, 2 (2), 1–18.

[14] Li, X., & Xiao, C. (2023). The Application of Artificial Intelligence Technology in Games. *Proceedings of the 4th International Conference on Signal Processing and Machine Learning*.

[15] Saketh, M., Nandal, N., Tanwar, R., & Reddy, B. P. (2023). Intelligent surveillance support system. *Discover Internet of Things*.

[16] Shaveta. (2023). A review on machine learning. *International Journal of Science and Research Archive*, 9 (1), 281–285.

[17] Breiding, P., et al. (2024). Machine Learning. In *Metric Algebraic Geometry* (Oberwolfach Seminars 53, pp. 123–). Springer.

[18] Ambulgekar, S. M., & Mali, P. D. (2020). Technical review on machine learning. *International Journal of Engineering Applied Sciences and Technology*, 5 (6), 183–187. ISSN: 2455–2143.

[19] Sah, S. (2020, July 11). Machine Learning: A Review of Learning Types. Preprints.

- [20] Rao, B. S. P., Akhila, A., Sneha, G., & Charan, V. (2023). Smart Suspect Tracker Using Deep Learning Model. *Ciência & Engenharia – Science & Engineering Journal*, 11(1), 89–97. ISSN: 0103–944X
- [21] Bhutada, S., Srija, P., Sushanth, S., & Shireesha, A. (2023). Deep Learning Driven Instinctive Surveillance. *Asian Journal of Engineering and Applied Technology*, 12 (1), 40–44.
- [22] Tanveer, H., Adam, M. A., Khan, M. A., Ali, M. A., & Shakoor, A. (2023). Analyzing the Performance and Efficiency of Machine Learning Algorithms, such as Deep Learning, Decision Trees, or Support Vector Machines, on Various Datasets and Applications. *ASIAN BULLETIN OF BIG DATA MANAGEMENT*, 3 (2), 126–140.
- [23] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [24] Bhutada, S., Srija, P., Sushanth, S., & Shireesha, A. (2023). Deep Learning Driven Instinctive Surveillance. *Asian Journal of Engineering and Applied Technology*, 12 (1), 40–44.
- [25] Buttar, A. M., Bano, M., Akbar, M. A., Alabrah, A., & Gumaei, A. H. (2023). Toward trustworthy human suspicious activity detection from surveillance videos using deep learning. *Journal of Ambient Intelligence and Humanized Computing*.
- [26] Breiding, P., et al. (2024). Computer Vision. In *Metric Algebraic Geometry (Oberwolfach Seminars 53, pp. 163–)*. Springer.

- [27] Tang, Z., & Zhang, Z. (2023). Ladder: A software to label images, detect objects and deploy models recurrently for object detection. Department of Crop and Soil Sciences, Washington State University, Pullman, Washington, 99164 USA.
- [28] Yin, H. (2024). Object Detection Based on Deep Learning. Transactions on Computer Science and Intelligent Systems Research, 5. Warwick Evans Publishing. ISSN: 2960-1800, eISSN: 2960-2238.
- [29] Chavan, C., Hembade, S., Jadhav, G., Komalwad, P., & Rawat, P. (2023). Computer Vision Application Analysis based on Object Detection. International Journal of Scientific Research in Engineering and Management (IJSREM), 7 (4), 1-6.
- [30] Nandibewoor, A., Prateek, L. K., Sakaray, M., Hassan, A., Ravankar, A., & Hegde, A. (2023). Computer Vision Application in Object Detection and Tracking for Aerial Surveillance. Indian Journal of Science and Technology, 16 (31), 2374-2379. <https://doi.org/10.17485/IJST/v16i31.645>
- [31] V, U., M, D., Poojitha, D., & Sriya, G. S. (2023). Application access for chromatic color detection. Journal of Physics: Conference Series, 2484 (1), 012049. IOP Publishing.
- [32] Kumar, K. S., & Safwan, K. M. B. A. (2024). Accelerating Object Detection with YOLOv4 for Real-Time Applications.
- [33] Encord. (n.d.). YOLO Object Detection Explained: A Beginner's Guide. Retrieved from <https://encord.com/blog/yolo-object-detection-guide/>

- [34] Alkentar, S., Alsahwa, B., Assalem, A., & Karakolla, D. (2023). Practical Comparison of the Accuracy and Speed of YOLO, SSD, and Faster R-CNN for Drone Detection.
- [35] Sapkota, R., Qureshi, R., Flores-Calero, M., Badgujar, C., Nepal, U., Poullose, A., Zeno, P., Vaddevolu, U. B. P., Khan, S., Shoman, M., Yan, H., & Karkee, M. (2024). YOLOv10 to Its Genesis: A Decadal and Comprehensive Review of the You Only Look Once (YOLO) Series.
- [36] Du, Z. (2023). Review of Convolutional Neural Network. Dean & Francis.
- [37] Ibrahim, A. (2020, June 15). How YOLO algorithm work (part one) شرح عربي [Video]. YouTube. <https://www.youtube.com/watch?v=SmXQtCVHxzE>
- [38] Barry, A., Han, L., & Demartini, G. (2023). On the Impact of Data Quality on Image Classification Fairness. Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '23), July 23–27, 2023, Taipei, Taiwan. ACM, New York, NY, USA.
- [39] Yang, F., Zhang, Q., Wang, M., & Qiu, G. (2023). Quality Classified Image Analysis with Application to Face Detection and Recognition. International Doctoral Innovation Centre, University of Nottingham Ningbo China; School of Computer Science, University of Nottingham Ningbo China; College of Information Engineering, Shenzhen University, Shenzhen, China.
- [40] Perez, H., & Tah, J. H. M. (2020). Improving the Accuracy of Convolutional Neural Networks by Identifying and Removing Outlier Images in Datasets Using t–

SNE. Oxford Institute for Sustainable Development, School of the Built Environment, Oxford Brookes University, Oxford OX3 0BP, UK.

[41] Khan, M. A., Menouar, H., & Hamila, R. (2023). Visual Crowd Analysis: Open Research Problems. *AI Magazine*. Wiley Periodicals LLC on behalf of the Association for the Advancement of Artificial Intelligence.

