



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة العربية للعلوم والتكنولوجيا
كلية الهندسة المعلوماتية
قسم تقانة المعلومات

مشروع أعد لنيل درجة البكالوريوس في تقانة المعلومات بعنوان:

نظام الكشف عن الأسلحة باستخدام تقنيات الذكاء الاصطناعي

إعداد الطالب:

مصطفى الغالي

إشراف:

د. ميساء دياب

2025 - 2024

ملخص المشروع:

يهدف هذا المشروع إلى تطوير نظام ذكي قادر على اكتشاف الأسلحة باستخدام الكاميرا المدمجة في الهاتف المحمول أو الحاسوب المحمول، بالاعتماد على تقنيات الذكاء الاصطناعي، وتحديداً خوارزمية (YOLO (You Only Look Once التي تُعد من أقوى خوارزميات الكشف الفوري عن الأجسام في الصور والفيديو. تسهم هذه المنظومة في توفير وسيلة مرنة وفعّالة يمكن دمجها بسهولة في التطبيقات الأمنية اليومية دون الحاجة إلى معدات متقدمة أو باهظة الثمن، مما يجعلها مناسبة للاستخدام في المدارس، والمباني العامة، والمحلات التجارية. تم تدريب النموذج باستخدام مجموعة بيانات تحتوي على أنواع مختلفة من الأسلحة في ظروف إضاءة وزوايا متنوعة، وذلك لضمان دقة عالية في الكشف وتقليل معدل الإنذارات الخاطئة. وقد أظهرت النتائج أن النظام المقترح قادر على التعرف على الأسلحة بشكل لحظي وبدقة مقبولة، مع إمكانية توسيع قدراته في المستقبل لتشمل أنواعاً إضافية من التهديدات. تشير هذه النتائج إلى أن استخدام تقنيات الذكاء الاصطناعي في هذا السياق يمكن أن يحدث نقلة نوعية في أساليب الكشف الوقائي المبكر ويعزز من كفاءة أنظمة الأمان الذكية.

كلمات مفتاحية: YOLO، كشف الأسلحة، الذكاء الاصطناعي، الرؤية الحاسوبية، الكاميرا

المدمجة.

Project summary:

This project aims to develop an intelligent system capable of detecting weapons using the built-in camera of a smartphone or laptop, leveraging artificial intelligence techniques—specifically the YOLO (You Only Look Once) algorithm, which is one of the most powerful real-time object detection methods. The system provides a flexible and efficient solution that can be easily integrated into everyday security applications without the need for expensive or specialized hardware, making it suitable for use in schools, public buildings, and retail stores. The model was trained on a dataset containing various types of weapons captured under different lighting conditions and angles to ensure high accuracy and minimize false alarms. The results demonstrated that the proposed system can detect weapons in real-time with acceptable accuracy, and it has the potential to be extended to detect additional types of threats in the future. These findings suggest that the use of AI technologies in this context can significantly enhance early threat detection methods and improve the effectiveness of smart security systems.

Keywords: YOLO, weapon detection, artificial intelligence, computer vision, built-in camera.

المحتويات

1	الفصل الأول: مقدمة.....
2	1-1 مقدمة عامة.....
4	2-1 أهمية المشروع.....
4	3-1 الأهداف.....
5	4-1 الدراسات السابقة.....
7	5-1 المتطلبات الوظيفية.....
7	6-1 المتطلبات غير الوظيفية.....
8	2 الفصل الثاني: الخلفية النظرية.....
9	1-2 مقدمة في الذكاء الاصطناعي (AI).....
12	2-2 التعلم الآلي (Machine Learning - ML).....
14	3-2 التعلم العميق (Deep Learning – DL).....
16	4-2 الشبكات العصبية الاصطناعية (Artificial Neural Network).....
19	1-4-2 الشبكات العصبية العميقة (Deep Neural Networks).....
22	2-4-2 الشبكات العصبية الالتفافية (Convolutional Neural Networks).....

26	3 الفصل الثالث: خوارزمية YOLO
27	1-3 خوارزمية (YOLO (You Only Look Once)
27	1-1-3 ما هي خوارزمية YOLO؟
28	2-1-3 ما الذي يجعل YOLO شائعًا في مجال اكتشاف الأجسام؟
29	3-1-3 معمارية YOLO
30	4-1-3 كيف يعمل كشف الأجسام باستخدام YOLO؟
34	5-1-3 تطبيقات YOLO
35	6-1-3 تطور YOLO
38	4 الفصل الرابع: التنفيذ العملي
39	1-4 مقدمة الفصل
39	2-4 الأدوات والمكتبات البرمجية المستخدمة
41	3-4 مخطط خوارزمية العمل
43	4-4 لقطات من نتائج الكشف
44	5-4 النتائج
45	5 الخاتمة والآفاق المستقبلية
51	6 المراجع

الأشكال

- [الشكل 1-1]: معدلات القتل باستخدام الأسلحة النارية لكل 100,000 مواطن. 3
- [الشكل 1-2]: استخدام تقنية الذكاء الاصطناعي وكاميرات المراقبة للكشف عن الأسلحة النارية. 6
- [الشكل 2-1]: تطبيقات الذكاء الاصطناعي في الحياة اليومية. 10
- [الشكل 2-2]: الفرق بين الذكاء الاصطناعي الضيق والعام. 11
- [الشكل 2-3]: أنواع التعلم الآلي ومجالاتها. 13
- [الشكل 2-4]: الفرق بين التعلم الآلي والتعلم العميق. 15
- [الشكل 2-5]: آلية عمل الشبكة العصبية. 17
- [الشكل 2-6]: بنية الشبكة العصبية العميقة. 20
- [الشكل 2-7]: آلية عمل شبكة CNN. 23
- [الشكل 3-1]: سرعة YOLO مقارنةً بأحدث خوارزميات كشف الأجسام الأخرى. 28
- [الشكل 3-2]: معمارية YOLO من الورقة البحثية الأصلية. 30
- [الشكل 3-3]: التصنيف باستخدام YOLO. 30
- [الشكل 3-4]: تقسيم الصورة إلى شبكة من الخلايا. 31
- [الشكل 3-5]: تقدير مربعات الإحاطة. 32
- [الشكل 3-6]: إحداثيات مربع الإحاطة. 32
- [الشكل 3-7]: تقنية IoU. 34

35[الشكل 3-8]: تطور إصدارات YOLO.

42[الشكل 4-1]: مخطط خوارزمية العمل.

43[الشكل 4-2]: اكتشاف النظام للسكين.

44[الشكل 4-3]: اكتشاف النظام للمسدس.

الفصل الأول: مقدمة

1-1 مقدمة عامة


شهدت العقود الأخيرة تصاعدًا ملحوظًا في معدلات العنف المرتبط باستخدام الأسلحة النارية، مما دفع العديد من الدول إلى البحث عن حلول تقنية لمكافحة هذا التهديد المتنامي. وفقًا لدراسة نُشرت في مجلة PLOS Medicine، تجاوز عدد الوفيات الناتجة عن استخدام الأسلحة النارية عالميًا 251,000 وفاة في عام 2016، أكثر من نصفها جرائم قتل، وثلاثها تقريبًا حالات انتحار، في حين مثّلت الحوادث العرضية النسبة المتبقية [1]. ومن اللافت أن ست دول فقط، على رأسها الولايات المتحدة والبرازيل والمكسيك، تُمثل ما يزيد عن 50% من إجمالي هذه الوفيات، وهو ما يعكس وجود أزمة أمنية مركزة في مناطق معينة لكنها تحمل انعكاسات عالمية.

تعكس الولايات المتحدة الأمريكية نموذجًا صارخًا لهذه الأزمة؛ إذ تُسجل أعلى معدلات حيازة مدنية للأسلحة النارية عالميًا، بمعدل يُقدَّر بـ 120.5 قطعة سلاح لكل 100 شخص، وفقًا لتقرير Small Arms Survey [2]. هذا الانتشار الهائل للأسلحة يرتبط مباشرةً بارتفاع عدد الجرائم المسلحة.

يبين الشكل (1-1) الفجوة الكبيرة بين الولايات المتحدة الأمريكية والدول الأخرى فيما يتعلق بمعدلات القتل باستخدام الأسلحة النارية، حيث تظهر الولايات المتحدة بأعلى معدل بالمقارنة مع الدول التي تمتلك معدلات منخفضة جدًا أو تكاد تكون معدومة.

أمام هذه المؤشرات الخطيرة، بدأت المؤسسات الأمنية والأكاديمية بالبحث عن وسائل أكثر ذكاءً وكفاءة لاكتشاف الأسلحة ومنع وقوع الجرائم قبل حدوثها. أدى هذا الاتجاه إلى تطوير أنظمة تعتمد على الرؤية الحاسوبية (Computer Vision)، وعلى وجه الخصوص خوارزميات الذكاء الاصطناعي

القادرة على التعرف على الأجسام بدقة في الوقت الحقيقي. إحدى أبرز هذه الخوارزميات هي YOLO (You Only Look Once) بإصدارها الحديث YOLOv8، التي أثبتت قدرتها العالية في الكشف السريع عن الأسلحة النارية والبيضاء في الصور والفيديوهات، بدقة تصل إلى 93% في البيئات شبه الواقعية [3].



[الشكل 1-1]: معدلات القتل باستخدام الأسلحة النارية لكل 100,000 مواطن.

بناءً على هذه الحاجة الماسة، يهدف هذا المشروع إلى تطوير نظام ذكي منخفض التكلفة لاكتشاف الأسلحة باستخدام كاميرا الهاتف المحمول أو الكاميرا المدمجة في الحاسوب، مدمجًا مع نموذج YOLOv8. يوفر هذا النظام أداة قوية يمكن استخدامها في البيئات التعليمية، أو المؤسسات، أو الأماكن العامة، للكشف الفوري عن وجود سلاح ناري وتنبه الجهات المعنية دون الحاجة إلى مراقبة بشرية مستمرة. يعكس هذا التوجه مسعى عالميًا نحو اعتماد تقنيات الذكاء الاصطناعي كجزء أساسي من أنظمة الأمن الوقائي الذكية، خصوصًا في الأماكن ذات الموارد المحدودة.

2-1 أهمية المشروع

يمثل هذا المشروع أهمية كبيرة في ظل تزايد التهديدات الأمنية الناتجة عن انتشار استخدام الأسلحة في مختلف الأماكن العامة والخاصة، حيث يوفر حلاً ذكياً وفعالاً لاكتشاف وجود الأسلحة باستخدام تقنيات الذكاء الاصطناعي، مما يساهم في تعزيز السلامة العامة والوقاية من الجرائم قبل وقوعها. استخدام كاميرات الهاتف المحمول أو الحاسوب المدمجة يجعل النظام مرناً وقابلاً للتطبيق في بيئات متنوعة دون الحاجة إلى تجهيزات باهظة التكلفة أو بنى تحتية معقدة. إضافة إلى ذلك، يساهم المشروع في تقليل الاعتماد على المراقبة البشرية المستمرة، مما يقلل من احتمالات الخطأ ويزيد من سرعة الاستجابة للحوادث الأمنية. من خلال تقديم نظام ذكي قادر على التعرف السريع والدقيق على الأسلحة، يمكن للمؤسسات الأمنية والجهات المختصة اتخاذ إجراءات فورية، مما يعزز من كفاءة العمل الأمني ويوفر بيئة أكثر أماناً للمواطنين والمجتمعات. بهذا الشكل، يساهم المشروع في دعم الجهود العالمية للحد من العنف المرتبط بالأسلحة وتحقيق استخدام أكثر أماناً للتكنولوجيا في خدمة الأمن والسلامة.

3-1 الأهداف

- تطوير نظام ذكي للكشف الفوري والدقيق عن الأسلحة باستخدام تقنيات الذكاء الاصطناعي.
- توفير حل عملي وسهل الاستخدام يعتمد على كاميرات الأجهزة المحمولة أو الحواسيب المدمجة.

- ضمان قابلية تطبيق النظام في بيئات متعددة دون الحاجة إلى تجهيزات مكلفة أو بنى تحتية معقدة.
- تقليل الاعتماد على العنصر البشري في مراقبة الأنظمة الأمنية، مما يقلل من احتمالات الخطأ.
- زيادة سرعة وكفاءة الاستجابة للحوادث الأمنية المحتملة.
- تصميم نموذج مرن وقابل للتطوير لمواكبة التحديات الأمنية المستقبلية.
- الإسهام في بناء بيئات أكثر أمانًا وذكاءً باستخدام التكنولوجيا الحديثة.

4-1 الدراسات السابقة

شهد مجال كشف الأسلحة باستخدام تقنيات الذكاء الاصطناعي تطورات ملحوظة، حيث أظهرت الدراسات الحديثة فاعلية كبيرة للنماذج المعتمدة على الشبكات العصبية العميقة في تحقيق دقة عالية وسرعة في الكشف. ففي دراسة تناولت تحليل صور ومقاطع فيديو باستخدام تقنيات التعلم العميق، تم التوصل إلى دقة تفوق 85% في التعرف على الأسلحة، مع تقليل الإنذارات الكاذبة إلى أقل من 15%، مما يعزز من إمكانية التطبيق في أنظمة المراقبة الحضرية والصناعية [4]. وأظهرت النتائج أن استخدام تقنيات تحسين جودة الصور وأدوات تعزيز البيانات يساهمان بشكل كبير في تحسين أداء النماذج خصوصًا في ظروف الإضاءة المنخفضة والضوضاء البصرية.

كما أظهرت دراسات أخرى قدرة تقنيات التعلم العميق على الكشف الفوري عن الأسلحة في الفيديوها مع معدل استجابة منخفض ودقة تقارب 87%، مما يجعلها مناسبة للأنظمة الأمنية

التي تتطلب سرعة ودقة عالية في التعرف واتخاذ القرار [5]. وقد أثبتت هذه النماذج مرونتها في التعامل مع أنواع مختلفة من الأسلحة وبيئات تصوير متعددة.

وتؤكد الدراسة الحديثة التي تعتمد على تحليل الفيديو في الزمن الحقيقي قدرة أنظمة الذكاء الاصطناعي على التكيف مع الظروف البيئية المتغيرة مثل الإضاءة والحركة السريعة، مع تحقيق معدل دقة كشف يصل إلى 87% وتقليل الإنذارات الكاذبة بشكل كبير [6]. يبين الشكل (1-2) نظام إنذار ذكي للكشف عن الأسلحة النارية باستخدام تقنية الاستشعار والتحليل الرقمي، حيث يظهر الشخص الذي يحمل سلاحًا والنظام الذي يلتقط الصورة ويحللها عبر وحدة إلكترونية ترسل تنبيهًا فوريًا عند الكشف عن الخطر.



[الشكل 1-2]: استخدام تقنية الذكاء الاصطناعي وكاميرات المراقبة للكشف عن الأسلحة النارية.

5-1 المتطلبات الوظيفية

- قدرة النظام على الكشف الآني للأسلحة النارية باستخدام كاميرا الجوال أو اللابتوب المدمجة.
- معالجة وتحليل الصور والفيديوهات بدقة عالية لتحديد وجود الأسلحة.
- إصدار إنذار فوري عند اكتشاف سلاح ناري.
- تسجيل وتخزين بيانات الصور والفيديوهات للكشف مع طابع زمني.
- توفير واجهة مستخدم لعرض حالة النظام وتنبيهات الإنذار.
- إمكانية تحديث النموذج الذكي لتحسين الدقة مع مرور الوقت.

6-1 المتطلبات غير الوظيفية

- استجابة النظام يجب أن تكون في الزمن الحقيقي (زمن تأخير منخفض).
- يجب أن يكون النظام قادرًا على العمل في ظروف إضاءة مختلفة ومتغيرة.
- توفير حماية وأمان لبيانات المستخدمين والمعلومات المسجلة.
- قابلية التوسع لدعم المزيد من الأجهزة والكاميرات في المستقبل.
- تصميم النظام ليكون سهل الاستخدام مع واجهة واضحة وبسيطة.
- تحقيق كفاءة عالية في استهلاك الموارد مثل الطاقة والذاكرة.


الفصل الثاني: الخلفية

النظرية

1-2 مقدمة في الذكاء الاصطناعي (AI)

الذكاء الاصطناعي هو فرع من فروع علوم الحاسب يُعنى بتصميم أنظمة وبرمجيات تمتلك القدرة على محاكاة بعض جوانب التفكير البشري. يهدف هذا المجال إلى تمكين الآلات من أداء مهام تتطلب عادةً مستوى معينًا من الفهم أو التحليل، مثل التعرف على الصور، أو فهم اللغة، أو اتخاذ قرارات بناءً على البيانات المتاحة. لا يعني ذلك أن الحاسوب يُصبح ذكيًا كما الإنسان، بل إنه يتبع مجموعة من القواعد والخوارزميات التي تتيح له التعلّم من التجربة وتحسين أدائه مع مرور الوقت. وتعتمد هذه الأنظمة على تحليل كميات كبيرة من المعلومات، واستخلاص أنماط متكررة، ثم استخدامها للتنبؤ أو التصنيف أو التفاعل مع البيئة المحيطة بها. يُعد الذكاء الاصطناعي اليوم من أكثر المجالات تطورًا في عالم التقنية، ويُستخدم كأساس لبناء تطبيقات متقدمة يمكنها فهم المدخلات واتخاذ إجراءات شبه ذاتية دون تدخل مباشر من الإنسان [7].

تتجلى أهمية الذكاء الاصطناعي بشكل متزايد في مختلف جوانب الحياة اليومية (الشكل 1-2)، حيث أصبح جزءًا لا يتجزأ من العديد من الخدمات التي يستخدمها الناس دون أن يدركوا أحيانًا وجوده. فعند استخدام الهاتف المحمول للتحدث مع المساعد الصوتي، أو أثناء تصفح المواقع التي تقترح محتوى مناسبًا للاهتمامات، أو حتى في تطبيقات الترجمة الفورية، يكون الذكاء الاصطناعي هو المحرك الأساسي وراء هذه الوظائف الذكية. كما يُستخدم في تحليل الصور الطبية، وتحسين كفاءة شبكات النقل، وإدارة الطاقة، والخدمات البنكية، مما يساهم في تقليل الأخطاء وتوفير الوقت والجهد.




[الشكل 2-1]: تطبيقات الذكاء الاصطناعي في الحياة اليومية.

أما في الجانب الأمني، فقد أصبح الذكاء الاصطناعي أداة فعالة تسهم في تطوير أنظمة المراقبة والكشف المبكر عن التهديدات، حيث تُستخدم تقنياته في تحليل الصور من كاميرات المراقبة، والتعرف على الوجوه، ورصد السلوكيات غير الطبيعية، ومراقبة الحدود والمداخل الحساسة. كما يُستخدم في أنظمة الإنذار الذكية، وتحليل البيانات الأمنية لتوقع المخاطر المحتملة قبل وقوعها. كل ذلك يجعل الذكاء الاصطناعي ليس فقط وسيلة للراحة أو الترف، بل عنصرًا جوهريًا في تعزيز الكفاءة وتحقيق الأمان في مختلف المجالات.

رغم أن مصطلح الذكاء الاصطناعي يُستخدم بشكل عام للدلالة على قدرة الأنظمة الحاسوبية على محاكاة التفكير البشري، إلا أن هذا المجال لا يُعد متجانسًا، بل ينقسم إلى أنواع مختلفة وفقًا لقدرات الأنظمة ومستوى استقلاليتها في اتخاذ القرار. هذا التصنيف يساعد على فهم مدى تطور النظام، وما إذا كان مخصصًا لمهمة واحدة فقط، أم قادرًا على التعامل مع مهام متنوعة بطريقة شبيهة بالإنسان.

- **الذكاء الاصطناعي الضيق (Narrow AI):** هو النوع الأكثر شيوعًا واستخدامًا حاليًا، ويُقصد به الأنظمة المصممة لأداء مهمة محددة بفعالية عالية، مثل التعرف على الصور، أو الترجمة، أو قيادة المركبات ذاتيًا. هذه الأنظمة قد تتفوق على الإنسان في مجالها الضيق، لكنها غير قادرة على أداء مهام خارج نطاق تخصصها.
- **الذكاء الاصطناعي العام (General AI):** يُشير إلى الأنظمة التي تمتلك قدرة معرفية واسعة تُمكنها من أداء مختلف المهام الفكرية التي يستطيع الإنسان القيام بها، مثل الفهم والتفكير والتخطيط والتعلّم في سياقات متعددة. لا يزال هذا النوع في مرحلة البحث والتطوير، ولم يُحقق بعد على أرض الواقع، لكنه يمثل الهدف البعيد للباحثين في هذا المجال.




[الشكل 2-2]: الفرق بين الذكاء الاصطناعي الضيق والعام.

2-2 التعلم الآلي (Machine Learning - ML)

يُعد التعلم الآلي أحد الفروع الأساسية في مجال الذكاء الاصطناعي، ويُركز بشكل رئيسي على تطوير أنظمة قادرة على تحسين أدائها مع مرور الوقت من خلال التجربة. بخلاف البرمجة التقليدية التي تعتمد على كتابة تعليمات محددة لتنفيذ مهمة معينة، يسعى هذا النوع من الأنظمة إلى اكتساب المعرفة من خلال تحليل البيانات والتفاعل معها. يتم تدريب النموذج الحاسوبي على عدد كبير من الأمثلة، مما يُمكنه من التعرف على الأنماط والتصرف بطريقة ذكية عند مواجهة بيانات جديدة. ومع تكرار التجربة وزيادة كمية البيانات، يصبح النظام أكثر دقة وكفاءة في اتخاذ قراراته أو تقديم نتائج. هذا التوجه العلمي غيّر الكثير من المفاهيم في مجالات متعددة، وأصبح يستخدم في تطبيقات عملية تشمل التوصيات الذكية، وتحليل الصور، والتعرف على الأصوات، وغيرها من المهام التي كانت في السابق تتطلب تدخلًا بشريًا مباشرًا [7].

تعتمد آلية عمل التعلم الآلي على تمكين النظام من استخلاص المعرفة مباشرة من البيانات، دون الحاجة إلى تزويده بتعليمات تفصيلية مسبقة. فبدلاً من أن يُملَى عليه ما يجب فعله في كل موقف، يتعامل مع كمّ كبير من المعلومات ويتعلم من الأمثلة الموجودة فيها، ليستنتج بنفسه القواعد التي تربط بين المدخلات والمخرجات. هذا الأسلوب يمنح النموذج القدرة على التعميم، أي أنه يصبح قادراً على التعامل مع بيانات جديدة لم يسبق له رؤيتها من قبل، بناءً على ما تعلّمه من بيانات سابقة. كلما زادت جودة البيانات وتنوعها، زادت دقة النموذج وكفاءته في أداء المهمة المطلوبة [7].

تتعدد أساليب التعلم الآلي بحسب طبيعة البيانات المتوفرة والغرض من استخدامها، وقد أدى هذا التنوع إلى تطوير مناهج مختلفة تساعد النماذج على اكتساب المعرفة بطرق تناسب كل نوع من المشكلات أو التطبيقات. يعتمد اختيار نوع التعلم المناسب على ما إذا كانت البيانات تحتوي على نتائج معروفة مسبقًا، أو ما إذا كان الهدف هو اكتشاف الأنماط الخفية، أو تحسين الأداء من خلال التفاعل المباشر مع البيئة. ومن أبرز هذه الأنواع:



[الشكل 2-3]: أنواع التعلم الآلي ومجالاتها.

- **التعلم الخاضع للإشراف (Supervised Learning):** يتم فيه تدريب النموذج باستخدام بيانات تتضمن مدخلات ومخرجات معروفة، ليتمكن من التنبؤ بالنتائج عندما يواجه بيانات جديدة لاحقًا.
- **التعلم غير الخاضع للإشراف (Unsupervised Learning):** يُستخدم مع بيانات لا تحتوي على مخرجات محددة، ويهدف إلى اكتشاف البنى أو الأنماط الكامنة داخل هذه البيانات، مثل تصنيفها أو تجميعها حسب التشابه.


- **التعلم التعزيزي (Reinforcement Learning):** يعتمد على مبدأ التجربة والخطأ، حيث يتفاعل النظام مع بيئة معينة ويتعلم من خلال المكافآت أو العقوبات التي يتلقاها بناءً على أفعاله، مما يساعده على تحسين قراراته بمرور الوقت.

3-2 التعلم العميق (Deep Learning – DL)

يُعد التعلم العميق أحد الفروع المتقدمة من التعلم الآلي، ويتميز بقدرته على التعامل مع كميات كبيرة من البيانات من خلال بنية معقدة مستوحاة من طريقة عمل الدماغ البشري. يعتمد هذا النوع من التعلم على ما يُعرف بالشبكات العصبية، وهي نماذج حسابية مكوّنة من طبقات متعددة من الوحدات المرتبطة ببعضها البعض، تُشبه في بنائها الخلايا العصبية في الجهاز العصبي. كل طبقة في هذه الشبكة تقوم بتحويل البيانات المدخلة إلى تمثيل أكثر تجريداً، ما يساعد النظام على فهم العلاقات الدقيقة والمعقدة داخل البيانات. ومن خلال تعلّمه التدريجي عبر هذه الطبقات، يصبح النموذج قادراً على استخلاص خصائص عالية المستوى دون الحاجة إلى تدخل بشري مباشر في تحديد ما يجب البحث عنه داخل البيانات. هذا الأسلوب أتاح للتعلم العميق أداء مهام تتطلب مستويات عالية من الدقة، وجعله أساساً لتطورات كبيرة في مجالات الذكاء الاصطناعي الحديثة [7].

تبرز أهمية التعلم العميق بشكل خاص في المهام التي تتطلب قدرة على فهم التفاصيل الدقيقة داخل البيانات المعقدة، مثل الصور والمقاطع البصرية. فعند التعامل مع الصور، لا يقتصر الأمر على تمييز الألوان أو الأشكال الظاهرة فقط، بل يتطلب فهماً أعمق للبنى والأنماط الداخلية التي لا

يمكن ملاحظتها بالطرق التقليدية. يتيح التعلم العميق للنماذج أن تلتقط هذه السمات بشكل تدريجي، بدءًا من الملامح البسيطة وحتى العلاقات المعقدة بين العناصر داخل الصورة، مما يجعلها أكثر قدرة على التمييز والتصنيف بدقة عالية. كما أن قدرته على اكتشاف الأنماط المتكررة وغير الظاهرة بوضوح في البيانات تمنحه دورًا محوريًا في التطبيقات التي تعتمد على التحليل البصري الدقيق، وتجعله مناسبًا للتعامل مع بيانات يصعب معالجتها باستخدام خوارزميات أبسط.



[الشكل 4-2]: الفرق بين التعلم الآلي والتعلم العميق.

امتدت تطبيقات التعلم العميق لتشمل مجالات متعددة تستفيد من قدرته على تحليل البيانات المعقدة واستخلاص المعاني منها بدقة. في مجال التعرف على الصور، يُستخدم هذا الأسلوب لتمييز محتوى الصور تلقائيًا، سواء كانت لأشخاص، أشياء، أو مشاهد طبيعية، مما يساهم في تنظيم المحتوى البصري أو استخدامه في أنظمة الأمان والمراقبة. كما يلعب دورًا أساسيًا في معالجة الإشارات الصوتية، حيث يمكن الأنظمة من فهم الكلام البشري وتحويله إلى نصوص مفهومة، وهي


خاصية ضرورية في المساعدات الصوتية وتطبيقات الترجمة الفورية. إضافة إلى ذلك، يستخدم التعلم العميق في تحليل لوحات المركبات، إذ يمكنه التعرف على أرقامها بسرعة ودقة من خلال الصور الملتقطة، وهو ما يعزز من كفاءة أنظمة المرور والحماية في البيئات التي تتطلب معالجة فورية للبيانات [7].

4-2 الشبكات العصبية الاصطناعية (Artificial Neural Network)

الشبكات العصبية الاصطناعية (Artificial Neural Networks) هي أحد فروع الذكاء الاصطناعي وتقنية تعلم الآلة التي تستوحي تصميمها ووظيفتها من الشبكات العصبية البيولوجية الموجودة في أدمغة الكائنات الحية، وتهدف إلى محاكاة طريقة معالجة المعلومات واتخاذ القرارات بشكل يشبه عمل الدماغ البشري. هذه الشبكات تستخدم بشكل واسع في مجالات متعددة مثل التعرف على الصور، معالجة اللغة الطبيعية، التنبؤات، والتصنيف، وغيرها من التطبيقات التي تتطلب قدرة على التعلم واستخلاص الأنماط من البيانات المعقدة. أساس فكرة الشبكات العصبية الاصطناعية هو بناء نموذج رقمي يتكون من وحدات معالجة بسيطة تسمى "الخلايا العصبية الاصطناعية"، والتي ترتبط ببعضها بطريقة تسمح بتمرير المعلومات ومعالجتها بطريقة متسلسلة ومتعددة الطبقات [7].

مكونات الشبكة العصبية الاصطناعية تنقسم بشكل رئيسي إلى ثلاثة أجزاء: طبقة الإدخال، الطبقات الخفية، وطبقة الإخراج. طبقة الإدخال هي نقطة بداية الشبكة حيث يتم استقبال البيانات الخام أو المعلومات التي نريد تحليلها أو معالجتها، وهي تمثل المتغيرات أو الخصائص التي

نستخدمها كمدخلات للنموذج. بعد ذلك تأتي الطبقات الخفية، وهي عبارة عن طبقات متتالية من الخلايا العصبية التي تعمل على استخراج وتحويل الميزات والمعلومات من البيانات الأولية بشكل تدريجي، إذ تقوم كل طبقة منها بمعالجة المعلومات القادمة من الطبقة السابقة وتحويلها إلى شكل أكثر تجريداً أو تعقيداً. عدد هذه الطبقات وعدد الخلايا في كل طبقة يعتمد على تعقيد المشكلة المراد حلها. أخيراً، طبقة الإخراج، وهي التي تقوم بإعطاء النتيجة النهائية لمعالجة الشبكة، مثل تصنيف بيانات إلى فئات معينة، أو إعطاء تقدير رقمي، أو غير ذلك بناءً على نوع المهمة.



[الشكل 2-5]: آلية عمل الشبكة العصبية.

أما آلية عمل الشبكة العصبية (الشكل 2-5) فتبدأ بعملية التغذية الأمامية (Feedforward)، وهي الطريقة التي تنتقل بها البيانات من طبقة الإدخال عبر الطبقات الخفية وصولاً إلى طبقة الإخراج. في كل خلية عصبية داخل أي طبقة، يتم استقبال مجموعة من القيم (المدخلات) التي تمثل الإشارات القادمة من خلايا الطبقة السابقة، حيث يتم ضرب كل إشارة في وزن معين يعبر عن

أهمية هذه الإشارة، ثم يتم جمع كل النتائج للحصول على قيمة واحدة تسمى (القيمة المُجمعة). بعد ذلك، تمر هذه القيمة المُجمعة عبر دالة تنشيط (Activation Function) تقوم بتحويلها إلى إشارة مناسبة للمراحل التالية في الشبكة، بحيث تساعد هذه الدالة على إدخال اللاحطية للنموذج، مما يمكن الشبكة من تعلم أنماط معقدة غير خطية.

التدريب هو المرحلة التي يتم فيها تعديل أوزان الشبكة بحيث يمكنها أداء المهمة المطلوبة بدقة عالية. يتم ذلك عادة عن طريق تقديم مجموعة كبيرة من الأمثلة (بيانات التدريب) مع النتائج الصحيحة المعروفة، ثم تقوم الشبكة بحساب الفرق بين الناتج المتوقع والناتج الفعلي (الخطأ)، ومن خلال خوارزمية تسمى الانحدار العكسي (Backpropagation)، يتم تحديث الأوزان بطريقة تقلل هذا الخطأ تدريجيًا عبر عدة تكرارات. هذا التحديث يعتمد على حساب المشتقات لتحديد اتجاه وحجم تعديل الأوزان، مما يسمح للشبكة بالتعلم وتحسين دقتها بمرور الوقت.

وظيفة كل مكون داخل الشبكة تبرز من خلال دوره في معالجة المعلومات: طبقة الإدخال تعمل على استقبال البيانات وتحويلها إلى شكل مناسب لتغذية باقي الطبقات، الطبقات الخفية تقوم بتحليل وتحويل هذه البيانات إلى مستويات أكثر تجريدًا من المعلومات باستخدام الأوزان ودوال التنشيط، مما يمكن الشبكة من اكتشاف الأنماط والخصائص المهمة في البيانات، بينما طبقة الإخراج تقدم النتيجة النهائية أو التنبؤ بناءً على المعالجة التي تمت داخل الشبكة. الأوزان بين الخلايا العصبية تشكل جوهر التعلم داخل الشبكة، إذ يتم تعديلها باستمرار أثناء التدريب لتقليل الخطأ وتحسين الأداء. دوال التنشيط تلعب دورًا حيويًا في منح النموذج القدرة على التعامل مع


البيانات غير الخطية والمعقدة، كما تساعد في التحكم في إشارات الخلايا العصبية بحيث لا تكون قوية جدًا أو ضعيفة جدًا، مما يضمن استقرار عملية التعلم.

الشبكات العصبية الاصطناعية هي أداة قوية تعتمد على فكرة التكرار والتحسين التدريجي، حيث يبدأ النموذج بتخمينات عشوائية أو شبه عشوائية للأوزان، ثم يتعلم من خلال المعطيات ويعدل هذه التخمينات ليصل إلى نتائج دقيقة وموثوقة، وهذا ما يجعلها مناسبة جدًا لحل مشكلات معقدة لا يمكن للبرمجيات التقليدية التعامل معها بسهولة. نجاح الشبكات العصبية في التعلم واتخاذ القرارات يشبه إلى حد كبير طريقة دماغ الإنسان في التعامل مع المعلومات، لذا تعتبر من أهم التقنيات الحديثة في مجال الذكاء الاصطناعي [7].

1-4-2 الشبكات العصبية العميقة (Deep Neural Networks)

الشبكات العصبية العميقة (Deep Neural Networks) تمثل تطورًا طبيعيًا ومتقدمًا للشبكات العصبية الاصطناعية البسيطة، إذ تعتمد على نفس المبادئ الأساسية لكنها تتميز بوجود عدد كبير من الطبقات الخفية المتسلسلة، مما يمنحها القدرة على تحليل بيانات أكثر تعقيدًا واستخلاص ميزات أكثر تجريدًا. في الشبكات البسيطة، عادةً ما تحتوي البنية على طبقة إدخال واحدة، طبقة أو طبقتين خفيتين، وطبقة إخراج واحدة، وهذا كافٍ للتعامل مع مشاكل بسيطة أو ذات طبيعة خطية أو محدودة التعقيد. أما في الشبكات العميقة، فإن البنية تتكون من عدد كبير من الطبقات الخفية التي يمكن أن تتجاوز العشرات أو حتى المئات، وكل طبقة تقوم بمعالجة ناتج الطبقة السابقة بشكل تدريجي من خلال تحويله إلى تمثيل أكثر تعقيدًا وغنى بالمعاني، مما يسمح للنموذج بفهم

العلاقات الدقيقة والأنماط الخفية في البيانات. هذا العمق في الطبقات هو ما يميز الشبكات العميقة ويمنحها قدرات استثنائية، لكنه أيضًا يجعلها أكثر تطلبًا من حيث التدريب والموارد [7].



[الشكل 2-6: بنية الشبكة العصبية العميقة.]

أحد أهم الاستخدامات المتقدمة للشبكات العصبية العميقة هو في مجال معالجة الصور والفيديو، إذ أثبتت فعاليتها في فهم وتحليل محتوى الصور بدرجة تقترب من قدرات الإنسان. من أبرز تطبيقاتها تصنيف الصور، حيث يمكنها تحديد محتويات الصورة وتمييز الأجسام المختلفة بدقة عالية، واكتشاف الكائنات (Object Detection) مثل السيارات أو الأشخاص داخل مشهد معين، والتعرف على الوجوه، وتحسين جودة الصور، وحتى توليد صور جديدة من خلال الشبكات التوليدية. في مجال الفيديو، تستخدم الشبكات العميقة لتحليل المشاهد المتحركة والتعرف على الأنشطة والأحداث، مثل اكتشاف السلوك غير الطبيعي في كاميرات المراقبة، أو تحليل تعابير الوجه وتحديد المشاعر، أو تتبع الأجسام المتحركة عبر تسلسل من اللقطات. كذلك تُستخدم في


أنظمة الترجمة الفورية للغة الإشارة أو تحليل لقطات الأشعة الطبية في القطاع الصحي، مما يعزز دقة التشخيصات. كل هذه التطبيقات تتطلب قدرة على فهم المعلومات البصرية بمستويات متعددة من التجريد، وهذا ما تتيحه الشبكات العميقة من خلال قدرتها على التعلم من كميات ضخمة من البيانات واستخلاص ميزات تلقائيًا دون الحاجة إلى تدخل بشري مباشر في تصميم خصائص البيانات.

لكن رغم هذه القدرات العالية، تواجه الشبكات العصبية العميقة عدة تحديات كبيرة تحد من استخدامها بشكل واسع أو مباشر في كل التطبيقات. أول هذه التحديات هو حجم البيانات، إذ تحتاج الشبكات العميقة إلى كميات ضخمة من البيانات المتنوعة والممثلة بشكل جيد من أجل أن تتعلم بفعالية وتنتج نتائج دقيقة. قلة البيانات تؤدي إلى ضعف الأداء واحتمالية التعميم الخاطئ، لذلك يتطلب تدريب نموذج عميق توفير قواعد بيانات تحتوي على آلاف أو ملايين العينات، وهو أمر قد لا يكون متاحًا دائمًا، خاصة في المجالات المتخصصة أو الحساسة. التحدي الثاني هو الحاجة إلى قدرة معالجة عالية، حيث أن عملية التدريب تتطلب موارد حسابية ضخمة مثل وحدات معالجة الرسومات (GPUs) أو وحدات معالجة التنسور (TPUs) التي توفر سرعات عالية في تنفيذ العمليات الرياضية المعقدة. الزمن اللازم لتدريب شبكة عميقة على بيانات كبيرة قد يمتد إلى ساعات أو أيام أو حتى أسابيع، ويتطلب تخزينًا كبيرًا وذاكرة عشوائية عالية، وهذا ما يجعل استخدامها مكلفًا في البيئات العادية. إضافة إلى ذلك، فإن الضبط الدقيق للمعاملات (Hyperparameters) مثل معدلات التعلم، وعدد الطبقات، وعدد العقد في كل طبقة، ودوال

التنشيط، يتطلب خبرة تقنية كبيرة، ويمكن أن يؤثر بشكل كبير على أداء النموذج. كما تواجه هذه الشبكات تحديات في قابلية التفسير، إذ أن تعقيد بنيتها يجعل من الصعب على البشر فهم كيف ولماذا اتخذت قرارًا معينًا، مما يشكل عائقًا في التطبيقات التي تتطلب الشفافية مثل المجالات القانونية أو الطبية [7].

2-4-2 الشبكات العصبية الالتفافية (Convolutional Neural Networks)

الشبكات العصبية الترشيحية (Convolutional Neural Networks - CNN) تُعد واحدة من أبرز أنواع الشبكات العصبية العميقة وأكثرها فعالية في مجال معالجة الصور وتحليلها، إذ تم تطويرها خصيصًا للتعامل مع البيانات التي تتميز بالبنية الشبكية أو التوزيع المكاني مثل الصور. تختلف الشبكات العصبية الترشيحية عن الشبكات العصبية التقليدية في طريقة معالجتها للمدخلات، حيث تستفيد من خصائص الصور مثل التجاور المكاني والتكرار البنيوي لتقليل عدد المعاملات وتحسين القدرة على اكتشاف الأنماط المرئية، مثل الحواف، الزوايا، الأشكال، والأنسجة، وذلك بطريقة تحاكي عمل الخلايا البصرية في القشرة الدماغية. أهمية هذه الشبكات تنبع من قدرتها الكبيرة على استخلاص الميزات المفيدة من الصور بشكل تلقائي وفعال دون الحاجة إلى خطوات يدوية لتحديد الخصائص كما كان الحال في الطرق التقليدية، مما يجعلها العمود الفقري للعديد من التطبيقات في رؤية الحاسوب، مثل التعرف على الصور، واكتشاف الأشياء، وتقسيم الصور، والتعرف على الوجوه، والتصوير الطبي، وأنظمة القيادة الذاتية، والمراقبة الذكية، وغيرها من الاستخدامات التي تتطلب فهماً عميقاً للمحتوى البصري [7].



[الشكل 2-7]: آلية عمل شبكة CNN.

آلية عمل الشبكات العصبية الترشيحية تتضمن مجموعة من الطبقات المتسلسلة التي تعمل بتناغم لاستخلاص وتحويل تمثيلات الصور إلى نتائج مفهومة.

- **الطبقة الترشيحية (Convolutional Layer):** تُعد القلب النابض للشبكة، حيث تستخدم مجموعة من المرشحات (Filters) أو النوى (Kernels) الصغيرة الحجم والتي تنزلق على الصورة الأصلية وتقوم بعملية الترشيح لاستخلاص ميزات محددة من الصورة. كل مرشح يتم تدريبه ليتعرف على نمط معين، مثل الحواف الأفقية أو الرأسية أو الزوايا أو الانحناءات، ويتم إنتاج ما يسمى بخريطة المميزات (Feature Map) التي تحتوي على استجابات المرشح لمناطق مختلفة من الصورة. هذه الطبقة تمكن الشبكة من اكتشاف الأنماط الأساسية الموجودة في الصور، وهي الطبقة الأولى التي تبدأ منها عملية الفهم البصري. ما يميز الطبقة الترشيحية هو أن المعاملات فيها أقل بكثير من الشبكات الكاملة الاتصال،

لأن كل خلية عصبية في الخريطة تتصل بجزء صغير فقط من الصورة وليس بالصورة بأكملها، مما يقلل من التكلفة الحسابية ويزيد من كفاءة التعلم.

▪ **طبقة التجميع (Pooling Layer):** تأتي بعد الطبقات الترشيفية وتُستخدم لتقليل حجم خرائط الميزات الناتجة، مما يؤدي إلى تقليل عدد المعاملات وتسريع عملية التدريب، بالإضافة إلى زيادة قدرة النموذج على التعميم من خلال جعله أقل حساسية للانزياحات الصغيرة في الصورة. أكثر أنواع التجميع شيوعًا هو "التجميع الأقصى" (Max Pooling) حيث يتم اختيار أكبر قيمة في كل منطقة فرعية صغيرة من خريطة الميزات، أو "التجميع المتوسط" (Average Pooling) حيث يتم أخذ المتوسط. وظيفة هذه الطبقة هي تلخيص المعلومات الأهم من كل خريطة ميزات، ما يساعد على الاحتفاظ بالميزات المميزة وتقليل التفاصيل غير الضرورية أو الضوضاء، مع المحافظة على العلاقة المكانية العامة.

▪ **الطبقة الكاملة الاتصال (Fully Connected Layer):** تظهر عادةً في نهاية الشبكة العصبية الترشيفية، وتُشبه في عملها الشبكات العصبية التقليدية، حيث تتصل كل خلية عصبية بجميع الخلايا في الطبقة السابقة. بعد أن تمر البيانات عبر الطبقات الترشيفية والتجميع وتحولها إلى تمثيل منخفض الأبعاد ولكنه غني بالميزات، تقوم هذه الطبقة باستخدام هذا التمثيل لاتخاذ القرار النهائي، مثل تصنيف الصورة إلى فئة معينة أو تحديد احتمالية الانتماء لفئات متعددة. هذه الطبقة تعمل كمصنف يأخذ الميزات المستخرجة من الصور ويقوم بترجمتها إلى نتائج نهائية مفهومة مثل تسميات أو تقديرات رقمية.

الشبكات العصبية الترشيحية تتعامل مع الصور بطريقة ذكية ومنهجية لاستخراج المميزات، حيث تبدأ بالنظر إلى تفاصيل صغيرة محلية مثل الحواف والنقاط والزوايا، ثم تجمع هذه التفاصيل تدريجيًا عبر الطبقات المتتالية لتكوين فهم أعمق وأكثر تجريدًا للكيانات الأكبر مثل الأشكال أو الكائنات أو الأنماط المعقدة. بمرور البيانات عبر الشبكة، يتم تكوين خريطة غنية من الميزات التي تمثل الصورة الأصلية بدقة ولكن بطريقة عددية مبسطة تسمح للنموذج بفهم وتفسير محتوى الصورة. كل طبقة تضيف مستوى جديدًا من التحليل والتجريد، إلى أن تصل في النهاية إلى مرحلة يمكن فيها تصنيف الصورة أو فهم محتواها بشكل دقيق. وبفضل هذه الآلية، أصبحت الشبكات العصبية الترشيحية من أكثر الأدوات استخدامًا وموثوقية في تحليل الصور الرقمية، وأسهمت بشكل كبير في تطوير أنظمة الرؤية الحاسوبية في مختلف القطاعات التقنية والصناعية والطبية

[7]

3 الفصل الثالث:

خوارزمية YOLO

1-3 خوارزمية YOLO (You Only Look Once)


1-1-3 ما هي خوارزمية YOLO؟

"YOLO" وهي اختصار لعبارة "You Only Look Once" (تنظر مرة واحدة فقط)، هي خوارزمية متقدمة وحديثة لاكتشاف الأجسام في الصور والفيديوهات في الزمن الحقيقي، تم تقديمها لأول مرة في عام 2015 من قبل الباحثين جوزيف ريدمون، سانتوش ديفالا، روس جيرشيك، وعلي فرهادي، وذلك في ورقتهم البحثية الشهيرة بعنوان: "You Only Look Once: Unified, Real-Time Object Detection" (تنظر مرة واحدة فقط: كشف موحد للأجسام في الزمن الحقيقي).

في هذا البحث، صاغ المؤلفون مشكلة اكتشاف الأجسام بطريقة مختلفة، حيث اعتبروها مسألة انحدار (Regression) بدلاً من تصنيف (Classification). وتم ذلك من خلال تقسيم الصورة مكانياً إلى مربعات (شبكة) وتحديد الإحداثيات الخاصة بإطارات التحديد (Bounding Boxes) وتخصيص احتمالات لكل كائن يتم اكتشافه، وذلك باستخدام شبكة عصبية ترشيحية واحدة فقط (Convolutional Neural Network - CNN). هذه الطريقة جعلت عملية الكشف أكثر كفاءة وسرعة مقارنة بالأساليب التقليدية، حيث تتم المعالجة بأكملها في خطوة واحدة، بدلاً من خطوات متعددة كما هو الحال في أنظمة الكشف السابقة [8].

2-1-3 ما الذي يجعل YOLO شائعًا في مجال اكتشاف الأجسام؟

1. **السرعة:** يُعد YOLO سريعًا للغاية لأنه لا يعتمد على خطوات معالجة معقدة، بل يستخدم طريقة مباشرة وبسيطة. يمكنه معالجة الصور بسرعة تصل إلى 45 إطارًا في الثانية (FPS). بالإضافة إلى ذلك، يحقق YOLO أكثر من ضعف متوسط الدقة (mAP) مقارنةً بالأنظمة الأخرى التي تعمل في الوقت الحقيقي، مما يجعله خيارًا ممتازًا للمعالجة الفورية. ومن خلال الرسم البياني المبين في الشكل (3-1)، نلاحظ أن YOLO يتفوق بشكل كبير على أنظمة الكشف عن الأجسام الأخرى، حيث يصل إلى 91 إطارًا في الثانية [8].



[الشكل 3-1]: سرعة YOLO مقارنةً بأحدث خوارزميات كشف الأجسام الأخرى.

2. **دقة الكشف العالية:** يتفوق YOLO على النماذج الحديثة الأخرى من حيث الدقة، حيث يُظهر أداءً متميزًا مع عدد قليل جدًا من الأخطاء الناتجة عن الخلط بين الأجسام والخلفية.

3. **قدرة أفضل على التعميم:** يتميز YOLO، خاصة في نسخته الحديثة، بقدرة محسنة على التعميم عند استخدامه في مجالات جديدة. وهذا يعني أنه أصبح أكثر كفاءة في التعامل مع أنواع مختلفة من الصور والبيئات، مما يجعله خيارًا ممتازًا للتطبيقات التي تتطلب كشفًا سريعًا ودقيقًا للأجسام [8].


4. **مفتوح المصدر:** كون YOLO متاحًا كمشروع مفتوح المصدر أتاح للمجتمع التقني فرصة المشاركة المستمرة في تطويره وتحسينه. ويُعد هذا أحد الأسباب الرئيسية وراء التحسينات الكبيرة والسريعة التي شهدها YOLO خلال فترة زمنية قصيرة [8].

3-1-3 معمارية YOLO

معمارية YOLO تشبه إلى حد كبير معمارية GoogleNet. كما هو موضح في الشكل (3-2)، تتكوّن من 24 طبقة التلافية (Convolutional Layers)، وأربع طبقات تجميع أعظمي (Max-Pooling Layers)، بالإضافة إلى طبقتين كاملتي الاتصال (Fully Connected Layers) [8]. تعمل المعمارية على النحو التالي:


- يتم تغيير حجم الصورة المُدخلة إلى 448×448 بيكسل قبل تمريرها عبر الشبكة العصبية الترشيحية.
- يُطبّق أولاً ترشيح بحجم 1×1 لتقليل عدد القنوات (Channels)، ثم يتبعه ترشيح بحجم 3×3 لإنتاج مخرجات ثلاثية الأبعاد (Cuboidal Output).

- تُستخدم دالة تنشيط من نوع ReLU داخل الطبقات، ما عدا الطبقة النهائية التي تستخدم دالة تنشيط خطية (Linear Activation).
- تُستخدم تقنيات إضافية مثل "تطبيع الدفّعات" (Batch Normalization) و"الإسقاط" (Dropout) لتنظيم النموذج ومنع مشكلة الإفراط في التعلّم (Overfitting).




[الشكل 2-3]: معمارية YOLO من الورقة البحثية الأصلية.

4-1-3 كيف يعمل كشف الأجسام باستخدام YOLO؟



[الشكل 3-3]: التصنيف باستخدام YOLO.


1. **الكتل المتبقية (Residual blocks):** تبدأ هذه الخطوة بتقسيم الصورة الأصلية (A) إلى شبكة من الخلايا المتساوية الشكل بحجم $N \times N$ ، حيث في حالتنا هنا N يساوي 4، كما هو موضح في الشكل (3-4). كل خلية في هذه الشبكة تكون مسؤولة عن تحديد موقع الجسم الموجود داخلها وتوقع نوعه (الفئة)، بالإضافة إلى تقدير قيمة الاحتمالية أو الثقة بوجود هذا الجسم [8].



[الشكل 3-4]: تقسيم الصورة إلى شبكة من الخلايا.


2. **تقدير مربعات الإحاطة (Bounding Box Regression):** الخطوة التالية هي تحديد مربعات الإحاطة، وهي المستطيلات التي تُبرز كل الأجسام الموجودة في الصورة. يمكن أن يكون هناك عدد من مربعات الإحاطة يساوي عدد الأجسام داخل الصورة. يحدد YOLO خصائص هذه المربعات باستخدام وحدة تقدير واحدة (regression module) بالشكل التالي، حيث Y هو المتجه النهائي الذي يمثل كل مربع إحاطة: $Y = [pc, bx, by, bh, bw, c1, c2]$ ، وفي هذا المتجه، تشير القيمة pc إلى احتمال وجود جسم داخل الخلية في الشبكة. على سبيل المثال،

كل الخلايا الملونة باللون الأحمر لديها احتمال أعلى من الصفرة لاحتوائها على جسم، بينما الخلايا الصفراء في الصورة على اليمين تظهر احتمالاً صفرياً (أي لا تحتوي على جسم أو تأثير مهم).



[الشكل 3-5]: تقدير مربعات الإحاطة.

- bx, by : هما إحداثيات المركز (x و y) لمربع الإحاطة بالنسبة للخلية المحيطة في الشبكة.
- bh, bw : هما ارتفاع وعرض مربع الإحاطة بالنسبة لتلك الخلية.
- $c1, c2$: تمثلان الفتتين، اللاعب والكرة. ويمكن أن يكون هناك عدد أكبر من الفئات حسب ما يتطلبه التطبيق.



[الشكل 3-6]: إحداثيات مربع الإحاطة.

3. مقياس التداخل على الاتحاد (Intersection Over Union أو IOU): في كثير من الأحيان،

قد يكون هناك أكثر من مربع شبكة (Grid Box) مرشح لنفس الجسم في الصورة، رغم أن

ليس جميعها مناسب أو دقيق. هدف مقياس IOU، الذي يتراوح بين 0 و1، هو التخلص من

المربعات غير المهمة والاحتفاظ فقط بالمربعات الأكثر دقة وملائمة. إليك الفكرة ببساطة:

- يقوم المستخدم بتحديد عتبة IOU للاختيار، مثلاً 0.5.
- بعد ذلك، يقوم YOLO بحساب قيمة IOU لكل مربع شبكة، وهي نسبة مساحة التقاطع بين مربع التنبؤ ومربع الجسم الحقيقي إلى مساحة الاتحاد بينهما.
- في النهاية، يتجاهل YOLO التنبؤات التي تكون فيها قيمة IOU أقل أو تساوي العتبة، ويحتفظ فقط بالتنبؤات التي تتجاوز هذه العتبة.

في الشكل (3-6)، نرى مثالاً على تطبيق هذه العملية على الجسم الموجود في أسفل اليسار. يمكن

ملاحظة أن الجسم كان لديه في البداية مرشحين من مربعات الشبكة، ولكن في النهاية تم اختيار

“Grid 2” فقط [8].


4. طريقة الإخماد غير الأقصى (Non-Max Suppression أو NMS): تحديد عتبة IOU ليس

دائماً كافياً، لأن الجسم قد يحتوي على عدة مربعات تجاوزت العتبة، وترك كل هذه المربعات

قد يؤدي إلى وجود ضوضاء أو تكرار في التنبؤات. هنا يأتي دور تقنية NMS، التي تساعد في

الاحتفاظ فقط بالمربعات التي تحتوي على أعلى قيمة احتمال لكشف الجسم، مع إزالة

المربعات الأخرى الأقل دقة [8].




[الشكل 3-7]: تقنية IoU.

5-1-3 تطبيقات YOLO

تطبيقات نظام كشف الأجسام YOLO واسعة ومتنوعة، حيث يُستخدم في العديد من المجالات التي تتطلب التعرف السريع والدقيق على الأجسام في الصور والفيديوهات. من أهم هذه التطبيقات نجد الرعاية الصحية، حيث يساعد YOLO في تحديد مواقع الأعضاء أو الأورام أثناء العمليات الجراحية أو من خلال الصور الطبية مثل الأشعة المقطعية. كما يُستخدم في الزراعة لمراقبة النباتات والكشف المبكر عن الأمراض أو الآفات، مما يساهم في تحسين الإنتاجية. في مجال الأمن والمراقبة، يُساعد YOLO في التعرف على الأشخاص أو الأجسام المشبوهة بسرعة عالية، مما يعزز من فعالية أنظمة الحماية. بالإضافة إلى ذلك، يلعب دورًا مهمًا في تطوير السيارات ذاتية القيادة من خلال تحديد المركبات والمشاة والعوائق على الطريق لضمان قيادة آمنة وفعالة. تتميز تقنية YOLO بسرعة الأداء ودقتها، مما يجعلها خيارًا مثاليًا للعديد من التطبيقات العملية في الوقت الحقيقي [8].

6-1-3 تطور YOLO

تقنية YOLO تستخدم للتعرف على الأشياء داخل الصور أو الفيديو، مثلاً: التعرف على الأشخاص، السيارات، أو الحيوانات. هذه التقنية بدأت في 2015 ومنذ ذلك الوقت تم تطويرها عدة مرات لتصبح أسرع وأكثر دقة [8]:



[الشكل 3-8]: تطور إصدارات YOLO.

- **YOLOv1 (2015):** أول نسخة، كانت سريعة في اكتشاف الأشياء لكنها تواجه صعوبة في رؤية الأشياء الصغيرة أو التي تظهر بجانب بعضها.
- **YOLOv2 (2016):** تم تحسينها لتكون أسرع وأكثر دقة، وخاصة في اكتشاف الأشياء بأحجام مختلفة داخل الصورة، مثل رؤية السيارات الصغيرة والأشخاص معاً.
- **YOLOv3 (2018):** أصبحت أكثر دقة وأفضل في التعرف على الأشياء حتى لو كانت متداخلة أو تشبه بعضها، بفضل تحسين طريقة فهم الصورة.

- **YOLOv4 (2020):** جعلت الكشف أسرع وأدق، خاصة للأشياء في الصور الكبيرة والمعقدة، وهذا مفيد جداً للكاميرات الأمنية مثلاً.
- **YOLOv5 (2020):** نسخة أخف وأسهل للاستخدام على الهواتف أو الأجهزة الصغيرة، لكنها لا تزال دقيقة وسريعة.
- **YOLOX (2021):** نسخة مبسطة تستخدم طريقة جديدة لتحديد الأشياء بدون الحاجة لبعض الإعدادات المعقدة، مما يجعل التدريب أسهل.
- **YOLOv6 (2022):** ركزت على جعل الكشف سريع جداً في الوقت الحقيقي، مثل مراقبة حركة المرور بشكل مباشر.
- **YOLOv7 (2022):** زادت من دقة الكشف في الصور الصعبة والمعقدة مع تحسين سرعة الأداء.
- **YOLOv8 (2023):** أعادت تصميم النموذج ليصبح أكثر مرونة ودقة في اكتشاف الأشياء المختلفة بسهولة.
- **YOLOv9 (2024):** استخدمت تقنيات حديثة لفهم الصورة بشكل أعمق، مما يساعد في رؤية الأشياء من زوايا وأحجام مختلفة بدقة أكبر.
- **YOLOv10 (2024):** تم تطويره ليعمل بشكل أفضل على الأجهزة الصغيرة مثل الروبوتات أو الهواتف، مع الحفاظ على سرعة ودقة الكشف.

- **YOLOv11 (2024):** دمجت بين طريقتين في الذكاء الاصطناعي لجعل النموذج أقوى وأدق في التعرف على الأشياء مهما كانت الظروف.

4 الفصل الرابع: التنفيذ

العملي

1-4 مقدمة الفصل

يتناول هذا الفصل الجوانب التطبيقية لمشروع نظام الكشف عن الأسلحة النارية باستخدام تقنيات الذكاء الاصطناعي. حيث يتم استعراض الأدوات والبيئات البرمجية التي تم الاعتماد عليها في بناء النموذج، إلى جانب عرض المخطط الخوارزمي الذي يوضح سير عملية الكشف بدءًا من التقاط الصورة وحتى إصدار التنبيه. كما يتضمن الفصل لقطات حقيقية توضح أداء النظام أثناء التشغيل، ويُختتم بتحليل للنتائج المحققة، واستعراض لآفاق التطويرية الممكنة في المستقبل.

2-4 الأدوات والمكتبات البرمجية المستخدمة

- **لغة البرمجة Python:** تُعد لغة بايثون (Python) واحدة من أكثر لغات البرمجة استخدامًا في مجالات الذكاء الاصطناعي، التعلم العميق، والرؤية الحاسوبية. تتميز بتركيبها البسيطة وسهولة قراءة الكود، بالإضافة إلى دعمها الواسع لمكتبات متخصصة مثل OpenCV و TensorFlow و PyTorch. كما أنها تتمتع بمجتمع ضخم من المطورين والباحثين، مما يوفر كمية هائلة من الوثائق والأمثلة الجاهزة. وقد تم اختيار بايثون في هذا المشروع نظرًا لتكاملها السلس مع مكتبة YOLOv8 ومكتبة OpenCV، مما أتاح تنفيذ المهام بكفاءة وسرعة دون الحاجة إلى إعدادات معقدة.

- **مكتبة OpenCV:** هي مكتبة مفتوحة المصدر تُستخدم لمعالجة الصور والفيديوهات، وتحتوي على أكثر من 2500 خوارزمية مُعدة مسبقًا لمعالجة وتحليل البيانات البصرية. في هذا المشروع، تم استخدام OpenCV لقراءة الفيديو من الكاميرا، التعامل مع الإطارات في الزمن

الحقيقي، وإجراء بعض المعالجات الأولية مثل تحويل الصور إلى صيغ مناسبة للإدخال في نموذج YOLO. وتكمن قوة OpenCV في قدرتها على العمل بكفاءة عالية مع الصور من مصادر مختلفة، ودعمها الجيد لأنظمة التشغيل المتعددة مثل Windows وLinux.

- **مكتبة (YOLOv8) Ultralytics:** هي الجهة المطورة لأحدث إصدارات YOLO (You Only Look Once)، ويُعد YOLOv8 من أقوى النماذج في مجال الكشف الفوري عن الأجسام في الصور والفيديو. يتميز النموذج بسرعه العالية ودقته الكبيرة في تحديد مواضع الأسلحة في المشهد خلال أجزاء من الثانية. وقد تم اختيار YOLOv8 لأنه يوفر واجهات سهلة الاستخدام مع بايثون، ويحتوي على نماذج مدربة مسبقًا يمكن استخدامها مباشرة أو إعادة تدريبها لتناسب مجموعات بيانات جديدة. كما أن أداء YOLOv8 في الكشف عن الأسلحة يوفر الأساس العملي لإنشاء نظام إنذار ذكي يعتمد على تحليل بصري مباشر.
- **بيئة Anaconda:** هي منصة مفتوحة المصدر تُستخدم لإدارة حزم بايثون وإنشاء بيئات افتراضية مستقلة. تتيح هذه البيئة تنصيب مكتبات متعددة دون تعارض بينها، الأمر الذي يعد مهمًا جدًا في مشاريع الذكاء الاصطناعي التي تتطلب توافقًا دقيقًا بين الإصدارات. تم اعتماد Anaconda في المشروع لتسهيل إدارة مكتبات مثل OpenCV وUltralytics داخل بيئة معزولة، مما يُسهل في استقرار التشغيل وتقليل المشاكل المتعلقة بالتوافق البرمجي.
- **Jupyter Notebook:** هو محرر تفاعلي يُستخدم لتنفيذ أكواد بايثون على شكل خلايا، مع إمكانية عرض النتائج مباشرة داخل نفس الواجهة. ويُعد هذا النمط من التفاعل مثاليًا

لمشاريع الذكاء الاصطناعي لأنه يسمح بتنفيذ خطوة بخطوة، وتحليل المخرجات بصريًا في كل مرحلة. في هذا المشروع، تم الاعتماد على Jupyter لتجربة الكود بسرعة، عرض نتائج الكشف، وتسجيل مراحل التجريب والتحسين بشكل منظم وسهل التتبع.


- **محرر Visual Studio Code:** هو محرر شيفرة برمجية قوي وخفيف الوزن يدعم لغات برمجة متعددة من ضمنها Python. يتميز بواجهته البسيطة وقابلية تخصيصه العالية من خلال الإضافات، مما يجعله مثاليًا لكتابة مشاريع برمجية متوسطة وكبيرة. استخدم هذا المحرر في المراحل الأساسية من كتابة الشيفرة البرمجية للمشروع، وخاصة عند بناء الهياكل البرمجية وتنظيم الملفات والمجلدات. كما ساعدت الإضافات مثل Python extension على التحقق من الكود وتنسيقه وتحسين تجربة التطوير.

3-4 مخطط خوارزمية العمل

يبدأ النظام أولاً بتهيئة الكاميرا والتأكد من جاهزيتها للعمل. بعد ذلك، يتم تفعيل النموذج المدرب (YOLO) لتحليل الصور واكتشاف الأسلحة. يدخل البرنامج في حلقة تكرارية (while) تستمر ما دامت الكاميرا تعمل ولم يتم الضغط على زر الإنهاء.

في كل دورة من الحلقة، يتم التقاط الإطار الحالي من الفيديو، ثم يتم تمريره إلى النموذج لتحليله. بعد المعالجة، تُعرض النتائج على الشاشة مباشرة، حيث يُظهر النظام نوع الكائن المكتشف (مثل: مسدس أو بندقية) مع تحديد موضعه داخل الإطار.


تستمر هذه العملية تلقائيًا حتى يقوم المستخدم بالضغط على زر الإنهاء (غالبًا المفتاح "q")،
وعندها تُغلق الكاميرا ويتوقف البرنامج.



[الشكل 4-1]: مخطط خوارزمية العمل.


4-4 لقطات من نتائج الكشف

يظهر الشكل (2-4) نظام كشف السكاكين باستخدام نموذج YOLO مدرب (knife_model.pt). يظهر الشخص في بث مباشر عبر كاميرا الحاسوب وهو يحمل سكينًا، وقد تم التعرف عليه تلقائيًا وتحديده داخل إطار أصفر مع وسم "Target Zone"، مما يدل على نجاح النموذج في رصد السلاح الأبيض في الوقت الحقيقي.



[الشكل 4-2]: اكتشاف النظام للسكين.

كما يوضح الشكل نظام الكشف عن الأسلحة النارية (gun_model.pt). تم التعرف تلقائيًا على المسدس الذي يحمله الشخص، وإحاطته بإطار أصفر مع نفس الوسم "Target Zone"، مما يُظهر فعالية النموذج في التعرف على الأسلحة النارية ضمن بيئة حية.



[الشكل 3-4]: اكتشاف النظام للمسدس.

5-4 النتائج

أظهرت نتائج النظام أنه قادر على التعرف بشكل فوري على الأسلحة البيضاء والنارية عند ظهورها أمام الكاميرا، حيث تم الكشف عن السكين والمسدس بدقة جيدة وتحديد موقعهما داخل إطار واضح في الصورة. يعمل النظام في الزمن الحقيقي ويعتمد على نماذج YOLO المدربة مسبقًا، مما يجعله مناسبًا للتطبيقات الأمنية التي تتطلب استجابة سريعة. ومع ذلك، قد يحتاج النموذج إلى مزيد من التدريب لتحسين الدقة في بيئات مختلفة أو ظروف إضاءة متغيرة.

5 الخاتمة والآفاق

المستقبلية

جاء هذا المشروع استجابةً لحاجة أمنية متزايدة في العديد من المنشآت العامة والخاصة لمواجهة التهديدات الناتجة عن حمل الأسلحة النارية بشكل غير قانوني، وهو ما يمثل خطراً مباشراً على السلامة العامة والأمن المجتمعي. مع التطور السريع لتقنيات الذكاء الاصطناعي والرؤية الحاسوبية، تم تطوير نظام إنذار ذكي قادر على الكشف المبكر والدقيق للأسلحة النارية باستخدام كاميرات مراقبة متقدمة ووحدة معالجة ذكية لتحليل الصور والفيديوهات في الوقت الحقيقي. يعتمد النظام على خوارزميات متطورة لتحليل المشاهد واكتشاف وجود السلاح الناري، ومن ثم إصدار تنبيه فوري للجهات المختصة دون الحاجة لتدخل بشري مباشر، مما يعزز سرعة الاستجابة ويقلل من احتمالية وقوع حوادث أمنية.

يتميز النظام بقدرته على العمل في بيئات متعددة، سواء في ظروف الإضاءة الجيدة أو الضعيفة، وكذلك في أماكن مزدحمة أو ذات حركة معقدة، مما يزيد من موثوقيته وفعاليتها في مختلف السيناريوهات. وقد أظهرت التجارب الأولية للنموذج دقة عالية في التعرف على الأسلحة النارية والتمييز بينها وبين الأجسام الأخرى، وهو ما يعزز من مستوى الأمان ويقلل من الإنذارات الكاذبة. كما أن تصميم النظام مبسط وفعال من حيث التكلفة مقارنة بالأنظمة الأمنية التقليدية، ما يجعله خياراً عملياً لتطبيقه في المدارس، المرافق العامة، والمناطق الحساسة التي تتطلب مراقبة أمنية ذكية.

ولضمان استمرارية تطوير المشروع وتوسيعه ليواكب الاحتياجات الأمنية المستقبلية، يمكن اقتراح عدة آفاق تطويرية من بينها:

- تطوير خوارزميات أكثر تعقيدًا لتغطية أنواع متعددة من الأسلحة النارية بمختلف الأشكال والأحجام، مع تحسين دقة الكشف في ظروف الإضاءة المنخفضة أو الطقس السيء.
- دمج النظام مع كاميرات مراقبة قادرة على البث المباشر لتحليل فيديوهات الزمن الحقيقي دون الحاجة إلى تخزين بيانات ضخمة.
- تعزيز أمن النظام الإلكتروني عبر اعتماد تقنيات التشفير الحديثة وبروتوكولات الحماية ضد الهجمات السيبرانية.
- إضافة خاصية تتبع الحركة للهدف الذي تم الكشف عنه باستخدام تقنيات متعددة مثل GPS أو كاميرات متعددة الزوايا لضمان متابعة دقيقة.
- تحسين واجهات الاستخدام لتوفير تحكم مباشر وسهل للجهات الأمنية مع إمكانية تصفح سجلات الإنذارات وتحليلها.
- ربط النظام بقواعد بيانات أمنية وطنية أو محلية لمساعدة الجهات المختصة في اتخاذ القرارات بشكل متكامل وسريع.
- توسيع نطاق استخدام النظام ليشمل أنواعًا أخرى من التهديدات الأمنية كالكشف عن المواد الخطرة أو الأنشطة المشبوهة.

يُعد هذا المشروع خطوة متقدمة نحو بناء أنظمة أمنية ذكية تعتمد على الذكاء الاصطناعي لتحسين جودة وفعالية المراقبة الأمنية، وتقليل المخاطر المرتبطة بحمل الأسلحة النارية غير

المرخصة. كما يعكس المشروع قدرة البحث العلمي والتقني على تحويل التحديات الأمنية إلى حلول مبتكرة قابلة للتطبيق العملي، بما يدعم تحقيق بيئات أكثر أمانًا وسلامة للمجتمعات.

جدول المصطلحات

الاختصار	المعنى باللغة الانجليزية	الترجمة العربية
AI	Artificial Intelligence	الذكاء الاصطناعي
ML	Machine Learning	التعلم الآلي
DL	Deep Learning	التعلم العميق
ANN	Artificial Neural Network	الشبكات العصبية الاصطناعية

جدول المصطلحات

الشبكات العصبية العميقة	Deep Neural Network	DNN
الشبكات العصبية الالتفافية	Convolutional Neural Network	CNN
تنظر مرة واحدة فقط (خوارزمية لكشف الأجسام)	You Only Look Once	YOLO
التقاطع على الاتحاد (مقياس دقة مربعات الإحاطة)	Intersection over Union	IoU

6 المراجع

- [1] Ayala Quintanilla, D. M., et al. (2018). Global mortality from firearms, 1990–2016. PLOS Medicine.
- [2] Small Arms Survey (2018). Estimating Global Civilian-held Firearms Numbers.
- [3] Thakur, A., et al. (2024). Real-Time Weapon Detection Using YOLOv8 for Enhanced Safety. arXiv Preprint.
- [4] Yadav, A., & Singh, S. (2021). Deep learning-based weapon detection system using YOLO. International Journal of Computer Applications.
- [5] Zhang, Y., et al. (2022). Real-time object detection for security surveillance using deep learning techniques. Sensors, 22(15), 5863.
- [6] Sharma, R., & Patel, M. (2022). Video-based weapon detection in dynamic environments using deep learning. Journal of Imaging.
- [7] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- [8] DataCamp. (n.d.). YOLO object detection explained. Retrieved June 25, 2025, from <https://www.datacamp.com/blog/yolo-object-detection-explained>