تصنيف استفسارات الطلاب الجامعية العربية الهجينة بين الفصحى والعامية السورية: مجموعة بيانات جديدة ومقارنة منهجية لنماذج المحوّلات العربية مع خطوط أساس كلاسيكية

شفاء جميل قطّاع[1]، داليا نجيب الكيلاني[1]، روان مصطفى هبهاب[1]، مجد إدمون طنوس[1*]

[1] قسم هندسة الحاسوب، كلية الهندسة، الجامعة الوطنية الخاصة، الجمهورية العربية السورية

* المؤلف المراسل: [البريد الإلكتروني للمؤلف المراسل]

الملخّص

تتلقى الجامعات يومياً أعداداً متزايدة من استفسارات الطلاب عبر القنوات الرقمية، ويستهلك فرزها يدوياً وتوجيهها إلى المكتب الإداري المختص وقتاً وجهداً كبيرين. وتزداد صعوبة أتمتة هذه المهمة في السياق العربي لأن الاستفسارات قصيرة، وتمزج الفصحى بالعامية، وتتسم بتنوع إملائي كبير وتداخل دلالي بين الجهات الإدارية. يقدّم هذا البحث مجموعة بيانات عربية جديدة ومتوازنة تضم 2,000 استفسار طلابي جامعي من البيئة السورية، موزّعة بالتساوي على أربع جهات إدارية (الشؤون المالية، شؤون الطلاب، مكتب المعلوماتية، شؤون الامتحانات)، جُمعت من مصادر ميدانية ورقمية ثم نقارن منهجياً ثلاثة نماذج محوّلات عربية هي AraBERTv2 و MARBERTv2 وARBERTv2 بالضبط الدقيق الكامل ضمن بروتوكول تحقق متقاطع طبقي خماشي بفولدات موحّدة، وفق سيناريوهين: معاملات فائقة مثبّتة، ومعاملات مضبوطة لكل نموذج بإطار Optuna. وأضفنا ثلاثة خطوط أساس كلاسيكية قائمة على TF-IDF، وأرفقنا النتائج بفترات ثقة إحصائية. حقّق AraBERTv2 أعلى أداء بين نماذج المحوّلات في السيناريوهين (دقة 92.45 % ثم 92.70%، وF1-Macro يساوي 0.9243 ثم 0.9271). غير أن مصنّف SVM خطّياً على سمات n-gram للكلمات والحروف بلغ دقة 93.25%، وتتداخل فترات الثقة (95%) لجميع النماذج عدا Naive Bayes. ويكشف تحليل الأخطاء أن 73 استفساراً أخطأت فيها النماذج الثلاثة معاً، وأن فئة شؤون الطلاب هي مركز الالتباس الدلالي. تشير هذه النتائج إلى أن المهمة تحكمها إلى حدّ بعيد إشارات معجمية، وأن تفوق المحوّلات على هذا الحجم من البيانات غير محسوم إحصائياً. نتيح البيانات والشيفرة علناً لدعم قابلية الاستنساخ.

الكلمات المفتاحية: معالجة اللغة العربية؛ تصنيف النصوص القصيرة؛ العامية السورية؛ AraBERT؛ MARBERT؛ ARBERT؛ التحقق المتقاطع الطبقي؛ Optuna؛ أتمتة الخدمات الجامعية.

1. المقدّمة

انتقل التواصل بين الطلاب والجهات الإدارية في مؤسسات التعليم العالي خلال السنوات الأخيرة من المراجعة المباشرة إلى القنوات الرقمية، كالبريد الإلكتروني ومجموعات التواصل الاجتماعي وتطبيقات المراسلة. وقد سرّع هذا الانتقال تبادل المعلومات، لكنه رفع حجم الاستفسارات اليومية رفعاً كبيراً. وما زال قسم كبير من الجامعات يعتمد على موظف يقرأ كل استفسار ويحدد الجهة المختصة به، وهي عملية تتباطأ مع ازدياد أعداد الطلاب وتتعرض للخطأ البشري. وقد ركّزت الأدبيات التعليمية على المساعدات الحوارية وروبوتات المحادثة في التعليم [1]، غير أن الخطوة السابقة لأي نظام خدمي آلي هي **توجيه الاستفسار** إلى الجهة الصحيحة، وهي مهمة تصنيف نصي متعدد الفئات.

تواجه هذه المهمة في السياق العربي صعوبات تتجاوز التصنيف النصي المعتاد. فالعربية لغة غنية صرفياً وذات طبيعة التصاقية [2]، ويكتب الطلاب بمزيج من الفصحى المبسطة واللهجة المحلية، وهي ظاهرة لغوية معروفة تُضعف أداء الأدوات المصممة للفصحى [3], [4]. كما تتسم الاستفسارات بالقِصر الشديد أحياناً (كلمتان أو ثلاث)، وبتنوع إملائي واسع للكلمة الواحدة (مثل «متى» و«ايمت» و«ايمتا» و«امتى»)، وبتداخل مفردات الجهات الإدارية فيما بينها؛ فكلمة «الدفع» قد ترد في استفسار مالي أو في استفسار عن تسجيل المواد.

أحدثت نماذج المحوّلات [5] والتمثيلات ثنائية الاتجاه المدرّبة مسبقاً [6] تحولاً في معالجة اللغات الطبيعية، وظهرت لها نسخ عربية متخصصة مثل AraBERT [7] وARBERT وMARBERT [8]. وتُظهر المعايير القياسية أن تفوّق أيٍّ منها مشروط بطبيعة المهمة ومصدر بيانات التدريب المسبق [8], [9], [10], [11]. إلا أن هذه المعايير لا تتضمن نصوصاً إدارية جامعية هجينة، ولا تقدّم الدراسات التطبيقية القريبة مقارنة صارمة بفولدات

موحّدة وخطوط أساس كلاسيكية قوية. ومن هنا ينطلق السؤال البحثي: **أيّ النماذج العربية المدرّبة مسبقاً أنسب لتوجيه الاستفسارات الجامعية الهجينة، وهل تتفوّق فعلاً على الطرائق الكلاسيكية القوية عند حجم بيانات محدود؟**

تتلخص إسهامات هذا البحث فيما يأتي:

1. بناء مجموعة بيانات عربية جديدة ومتوازنة من 2,000 استفسار طلابي جامعي من البيئة السورية الخاصة، موزّعة على أربع جهات إدارية، مع توصيف كمّي ولغوي لخصائصها (الطول، والمؤشرات اللهجية، والتنوع الإملائي).
2. مقارنة منهجية بين AraBERTv2 وMARBERTv2 وARBERTv2 بالضبط الدقيق الكامل، ضمن تحقق متقاطع طبقي خماشي بفولدات ثابتة ومشتركة، وفق سيناريوهين: إعدادات موحّدة تعزل أثر النموذج، وإعدادات مضبوطة لكل نموذج بإطار Optuna.
3. مقارنة النماذج بثلاثة خطوط أساس كلاسيكية على البروتوكول ذاته، مع فترات ثقة إحصائية، وهو ما يكشف أن الفروق بين أفضل النماذج غير دالة إحصائياً على هذا الحجم من البيانات.
4. تحليل أخطاء معمّق يحدد الأخطاء البنيوية المشتركة بين النماذج، ويبيّن أن فئة شؤون الطلاب تمثل مركز الالتباس الدلالي، ويقدّر سقف الأداء الممكن بالتجميع.
5. إتاحة البيانات وشيفرة التجارب علناً لدعم قابلية الاستنساخ.

تُنظَّم بقية البحث كما يلي: يستعرض القسم 2 الدراسات السابقة، ويصف القسم 3 مجموعة البيانات، ويعرض القسم 4 المنهجية التجريبية، ويقدّم القسم 5 النتائج، ويناقشها القسم 6 مع مهددات الصلاحية، ويختم القسم 7 بالاستنتاجات والعمل المستقبلي.

2. الدراسات السابقة

2.1 نماذج اللغة العربية المدرّبة مسبقاً

قدّم AraBERT [7] أول نموذج BERT أحادي اللغة للعربية، وتميّز بمعالجة صرفية مسبقة تفصل السوابق واللواحق عبر مجزّئ Farasa [12] قبل تطبيق التجزئة الجزئية بأداة SentencePiece [13]، بهدف تقليل تضخم القاموس الناجم عن الطبيعة الالتصاقية للعربية. وتعتمد نسخته الثانية AraBERTv2 على نحو 77 غيغابايت من نصوص الفصحى (أخبار وويكيبيديا وOSCAR). في المقابل، قدّم Abdul-Mageed وزملاؤه [8] نموذجين: ARBERT المدرّب على نصوص فصحى متنوعة المصادر، وMARBERT المدرّب على نحو مليار تغريدة تمزج الفصحى بلهجات متعددة، مع حذف هدف التنبؤ بالجملة التالية لقِصر التغريدات. ثم قدّمت ورقة ORCA [9] الإصدارين ARBERTv2 وMARBERTv2 بقواعد تدريب أوسع. وأظهرت دراسة CAMeLBERT [10] أن مدى تطابق نوع اللغة في التدريب المسبق (فصحى أم لهجات) مع نوع لغة المهمة أهمّ من حجم بيانات التدريب المسبق وحده.

2.2 أداء النماذج على المعايير القياسية وتصنيف المواضيع

يبيّن معيار ARLUE [8] تبايناً واضحاً بحسب المهمة: يتصدر MARBERT مهام تحليل المشاعر وتمييز اللهجات والمعاني الاجتماعية، بينما يتصدر AraBERT مهمة تصنيف المواضيع (92.97 مقابل 92.65 لـ ARBERT و 91.54 لـ MARBERT)، وهي المهمة الأقرب بنيوياً لتوجيه الاستفسارات لأن الفئة تُحدِّد بالمضمون الموضوعي لا بالنبرة. ومع ذلك يتفوق ARBERT على مجموعتي Khaleej وOSAC بفوارق ضيقة [8]، ما يعني أن الأفضلية مشروطة بخصائص كل مجموعة بيانات. وتشير مراجعة منهجية لنماذج BERT العربية في تصنيف النصوص [11] إلى تفوق MARBERT في نسبة كبيرة من الدراسات المشمولة، لكنها تجمع نتائج من بيئات تجريبية غير متجانسة. ويلخّص الجدول 1 نتائج ARLUE ذات الصلة.

الجدول 1. أداء النماذج الثلاثة على تجمّعات مختارة من معيار ARLUE كما وردت في [8].

تجمّع المهام	AraBERT	ARBERT	MARBERT
تحليل المشاعر (F1)	78.26	87.96	93.30
تصنيف المواضيع	92.97	92.65	91.54
تمييز اللهجات	86.92	88.49	90.65

تجمّع المهام	AraBERT	ARBERT	MARBERT
الدرجة الكلية ARLUE	73.91	76.07	75.99

2.3 أثر التجزئة اللغوية

أظهرت دراسة مقارنة لمجزّئات النصوص العربية [14] أن التجزئة الصرفية تحسّن الأداء تحسناً طفيفاً في مهام التصنيف، لكن فاعلية مجزّئ Farasa تتراجع عندما يغلب الطابع العامي على النص، لأن أدوات التجزئة الصرفية صُمّمت أساساً للفصحى. وهذا يجعل أداء AraBERTv2 على الاستفسارات الهجينة سؤالاً تجريبياً مفتوحاً لا يمكن حسمه من المعايير القائمة.

2.4 تطبيقات في السياقات التعليمية والإدارية

طُبّقت نماذج BERT العربية في مهام قريبة من السياق الجامعي، منها تحليل مشاعر الطلاب تجاه تقييم أعضاء هيئة التدريس [15]. وفي مهام أخرى تباينت النتائج: سجّل AraBERTv2 وMARBERTv2 أداءً متقارباً في تحليل مشاعر تغريدات جائحة كوفيد-19 [16]، وأشارت دراسة لتصنيف نصوص الجرائم الإلكترونية [17] إلى تفوق AraBERT في بعض المسارات البحثية وMARBERT في مسارات أخرى. أما الطرائق الكلاسيكية، فقد أثبت SVM على سمات TF-IDF كفاءته في تصنيف النصوص [18]، وبيّن Wang وManning [19] أن خطوط الأساس القائمة على n-gram تبقى منافسة جداً في تصنيف المواضيع والنصوص القصيرة. وتُعدّ سمات الحروف مفيدة خصوصاً حين يكثر التنوع الإملائي [28].

2.5 الفجوة البحثية

يتضح من الأدبيات ثلاثة قيود: (أ) لا تتضمن المعايير القائمة نصوصاً إدارية جامعية تمزج المفردات المؤسسية الفصيحة بالصياغة العامية؛ (ب) تعتمد دراسات كثيرة على تقسيم وحيد للبيانات، ما يجعل نتائجها عرضة لتباين التقسيم؛ (ج) تُقارَن نماذج المحوّلات غالباً فيما بينها دون خطوط أساس كلاسيكية قوية ودون اختبار للدلالة الإحصائية. ويعالج هذا البحث هذه القيود الثلاثة على مهمة توجيه الاستفسارات الجامعية العربية، وهي مهمة لم تُدرس بهذا الشكل حسب اطلاعنا.

3. مجموعة البيانات

3.1 الجمع والتوسيم

بُنيت مجموعة البيانات على مرحلتين. في **المرحلة الميدانية**، زار فريق البحث المكاتب الإدارية الأربعة في الجامعة، وأجرى مقابلات مع الموظفين لتحديد أكثر أنماط الاستفسارات تكراراً، وفهم طبيعة المشكلات التي تصلهم، وتثبيت حدود كل فئة. وقد حدّدت هذه المرحلة الفئات الأربع ووفّرت دليلاً مرجعياً للتوسيم. وأضاف أعضاء الفريق استفسارات محاكية مبنية على خبرتهم الفعلية في البيئة الجامعية مع الحفاظ على الأسلوب الطبيعي للطلاب. وفي **المرحلة الرقمية**، جُمعت استفسارات من مجموعات طلابية على Facebook (منها مجموعة «سكوب الجامعات الخاصة») ومن مجموعات WhatsApp الخاصة بالدفعات، وهي مصادر تعكس لغة عفوية غير منقحة ومشكلات حقيقية. وُسم كل استفسار بالجهة الإدارية المسؤولة عن معالجته، وأُبقي على الأخطاء الإملائية والسمات العامية عمداً لأنها تمثل الواقع الذي سيعمل فيه النظام.

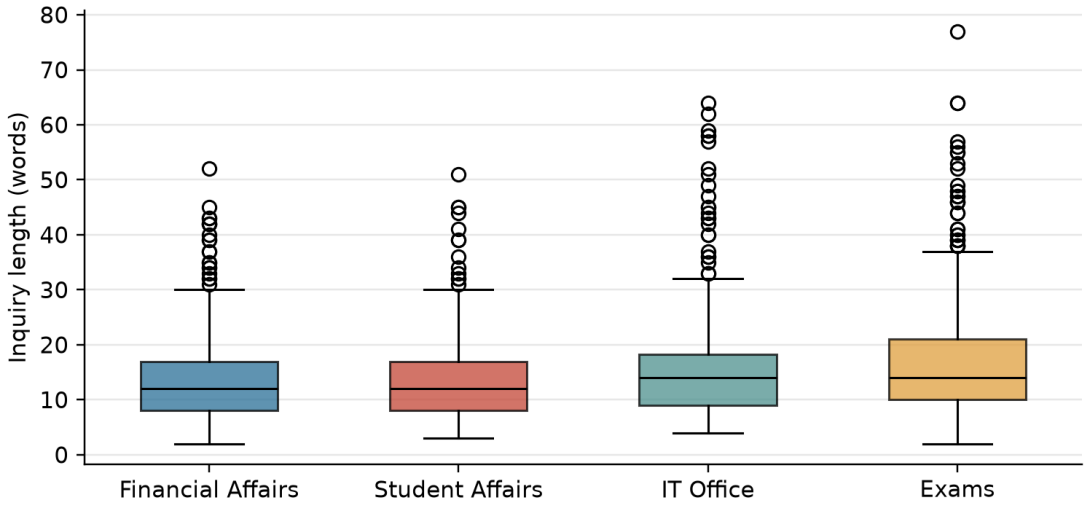
تعرّف الفئات الأربع كما يلي: **الشؤون المالية** (الأقساط، طرق الدفع، الرسوم، سعر الصرف، الغرامات، الحسومات، كشوف الحساب، الاسترداد)؛ **شؤون الطلاب** (تسجيل المقررات والحذف والإضافة، متطلبات التخرج، النقل والمفاضلات، التواصل مع الأساتذة، الأنشطة)؛ **مكتب المعلوماتية** (الحسابات وكلمات المرور، أعطال الموقع والتطبيق، الشبكة اللاسلكية، تعديل البيانات الشخصية، رسائل التصيّد)؛ **شؤون الامتحانات** (الإنذارات والفصل الاستدراكي، الاعتراض على العلامات، الجداول والتعارضات، الامتحانات التعويضية، أنظمة القاعة والمخالفات).

3.2 الخصائص الإحصائية

تضم المجموعة 2,000 استفسار بواقع 500 لكل فئة (25%)، دون أي تكرار حرفي بين النصوص. ويلخّص الجدول 2 الخصائص الكمية المحسوبة مباشرة من البيانات، ويوضح الشكل 1 توزيع الأطوال حسب الفئة.

الجدول 2. الخصائص الكمية لمجموعة البيانات (الطول مقيس بعدد الكلمات المفصولة بمسافات).

الخاصية	القيمة
عدد الاستفسارات	2,000 (500 لكل فئة)
متوسط الطول ± الانحراف المعياري	14.91 ± 9.02 كلمة
الوسيط (الأدنى – الأقصى)	13 (2 – 77)
متوسط الطول حسب الفئة	امتحانات 16.92، معلوماتية 15.45، مالية 13.84، شؤون طلاب 13.46
توزيع الأطوال	≤3 كلمات: 0.6%؛ 4–10: 35.7%؛ 11–25: 53.7%؛ >25: 10.1%
حجم المفردات (رموز فريدة)	6,677
استفسارات تحوي مؤشراً لهجياً سورياً واحداً على الأقل	54.4%
استفسارات تبدأ بتحية أو تتضمنها	28.8%
استفسارات تحوي أرقاماً	9.9%
استفسارات تحوي تكراراً متتالياً للحرف (مط)	3.4%
استفسارات تحوي حروفاً لاتينية	1.0%



الشكل 1. توزيع طول الاستفسارات (بالكلمات) حسب الفئة.

3.3 الخصائص اللغوية

قِسنا الطابع اللهجي بقائمة من المؤشرات العامية السورية الشائعة (مثل «شو، ايمت، اديش، قديش، هلق، فيني، بدي، ليش، هيك، كتير، يلي، لسا، مافي»). تحتوي 54.4% من الاستفسارات على مؤشر واحد على الأقل، وتتراوح النسبة بين 45.6% في الشؤون المالية و60.4% في مكتب المعلوماتية. وتُعدّ هذه النسبة حداً أدنى لأن القائمة لا تشمل كل الصيغ العامية. ومع ذلك تبقى المفردات المؤسسية الحاملة للمعنى فصيحة الجذر غالباً (التسجيل، الامتحان، الرسوم، الاعتراض)، ما يجعل النصوص هجينة: هيكل جملة عامي ومفردات موضوعية فصيحة. ويظهر التنوع الإملائي في حذف الهمزات، واستبدال الحروف المتقاربة، ومط الحروف، وتعدد صيغ الكلمة الواحدة.

ونتوقع ثلاثة مصادر للصعوبة: **التداخل المعجمي** (ترد «الدفع» و«المواد» و«الموقع» في أكثر من فئة)، و**الاختزال** (استفسارات من كلمتين إلى ثلاث تفتقر إلى السياق)، و**تعدد الإشارات** في الاستفسارات الطويلة التي قد تحمل مؤشرات تنتمي إلى أكثر من جهة.

4. المنهجية

4.1 صياغة المهمة

نصوغ المهمة تصنيفاً نصياً متعدد الفئات بفئة وحيدة: لكل استفسار x يتنبأ المصنف بفئة $\hat{y}$ من المجموعة {مالية، شؤون طلاب، معلوماتية، امتحانات}.

4.2 النماذج

اخترنا ثلاثة نماذج بحجم BERT-base تمثل ثلاث فلسفات في التدريب المسبق (الجدول 3): AraBERTv2 (فصحى مع تجزئة صرفية)، وARBERTv2 (فصحى واسعة المصادر بقاموس أكبر)، وMARBERTv2 (منصات تواصل تمزج الفصحى باللهجات). ويتيح هذا الاختيار اختبار أثر نوع لغة التدريب المسبق على نص هجين. أُضيفت فوق تمثيل الرمز [CLS] طبقة تصنيف خطية بأربعة مخارج، وطُبّق الضبط الدقيق الكامل لجميع الطبقات، وهو الأسلوب المعتاد في تصنيف النصوص بنماذج BERT [21].

الجدول 3. النماذج المستخدمة وخصائص تدريبها المسبق [7], [8], [9].

النموذج	المعرّف على Hugging Face	بيانات التدريب المسبق	التجزئة
AraBERTv2	aubmindlab/bert-base-arabertv02	فصحى، نحو 77 GB	Farasa + SentencePiece (60K)
ARBERTv2	UBC-NLP/ARBERTv2	فصحى متنوعة المصادر	WordPiece (100K)
MARBERTv2	UBC-NLP/MARBERTv2	تغريدات: فصحى ولهجات	WordPiece (100K)

4.3 خطوط الأساس الكلاسيكية

لتقدير القيمة المضافة الفعلية للمحوّلات، قارنّاها بثلاثة مصنّفات كلاسيكية: (1) Multinomial Naive Bayes على TF-IDF للكلمات المفردة والثنائية؛ (2) الانحدار اللوجستي ($C = 10$)، و(3) SVM خطي ($C = 1$) [18]، ويعتمد الأخيران على اتحاد سمات TF-IDF للكلمات ($n = 1–2$) والحروف ضمن حدود الكلمة ($n = 2–5$) مع تحجيم لوغاريتمي لتكرار المصطلح. لم تُضبط معاملات هذه المصنّفات، أي أنها خطوط أساس بإعدادات شائعة لا بأفضل إعداداتها. وتعالج سمات الحروف التنوع الإملائي بطبيعتها، لأن الصيغ المختلفة للكلمة الواحدة تشترك في معظم مقاطعها الحرفية.

4.4 المعالجة المسبقة والتجزئة

مُرّرت النصوص إلى المجزّئ الخاص بكل نموذج دون تنظيف إضافي، للحفاظ على الطابع الواقعي للبيانات. حُدّد طول التسلسل الأقصى بـ 128 رمزاً، وهو كافٍ لأن متوسط الاستفسار 15 كلمة تقريباً. واستُخدم الحشو الديناميكي على مستوى الدفعة لتقليل الكلفة الحسابية.

4.5 بروتوكول التقييم

اعتمدنا تحققاً متقاطعاً طبقياً خماسياً (StratifiedKFold، بذرة 42). في كل فولد تُخصص 400 عينة للاختبار (20%)، ويُقتطع من بيانات التدريب الباقية جزء طبقي بنسبة 10% (160 عينة) للتحقق ومراقبة التوقف المبكر، فيبقى 1,440 عينة للتدريب. ثُبّتت الفولدات قبل تدريب أي نموذج، فخضعت النماذج كلها، بما فيها خطوط الأساس، لتقسيمات متطابقة. وتُحسب المقاييس على فولد الاختبار ثم يؤخذ متوسطها عبر الفولدات الخمسة، وتُجمّع التنبؤات من الفولدات الخمسة لبناء مصفوفة ارتباك واحدة تغطي العينات الألفين.

4.6 السيناريو الأول: معاملات فائقة موحّدة

لعزل أثر النموذج عن أثر الإعدادات، دُرّبت النماذج الثلاثة بالإعدادات نفسها (الجدول 4)، مع توقف مبكر بصبر حقبتين على خسارة التحقق، واستعادة أوزان أفضل حقبة عند نهاية التدريب.

الجدول 4. المعاملات الفائقة الموحّدة في السيناريو الأول.

المعامل	القيمة
معدل التعلم	2×10^{-5}

المعامل	القيمة
حجم الدفعة	16
الحد الأقصى للحقب	10 (مع توقف مبكر، صبر = 2)
انحلال الأوزان	0.01
معيار اختيار أفضل نقطة	أدنى خسارة تحقق
الدقة العددية	FP16
البذرة	42 (random وNumPy وPyTorch وdata_seed)

4.7 السيناريو الثاني: ضبط المعاملات بإطار Optuna

لأن الإعدادات الموحّدة قد تظلم نموذجاً لا تناسبه، ضُبطت المعاملات لكل نموذج على حدة بإطار Optuna [23] بثلاثين تجربة لكل نموذج (90 تجربة إجمالاً). شمل فضاء البحث معدل التعلم بأخذ لوغاريتمي في المجال $[5\times10^{-6}, 5\times10^{-5}]$، وحجم الدفعة من {8، 16، 32}، ونسبة الإحماء في [0، 0.1]، وحُدد عدد الحقب بالتوقف المبكر كما في السيناريو الأول. أُجري البحث على مجموعة التحقق المقتطعة من تدريب الفولد الأول، وكان هدف التحسين F1-Macro على مجموعة التحقق، مع تقليم التجارب الضعيفة بالمقلّم الوسيطي (MedianPruner، خمس تجارب تأسيسية ثم أُعيد تقييم أفضل ثلاثة مرشحين لكل نموذج على الفولدات الخمسة، واعتُمد المرشح صاحب أفضل متوسط. وحُفظت الدراسات في قاعدة SQLite لاستئنافها عند انقطاع جلسات المعالجة.

4.8 مقاييس الأداء والاختبار الإحصائي

لأن الفئات متوازنة، نعتمد الدقة الكلية (Accuracy) ومتوسطات الماكرو للدقة الصنفية (Precision) والاستدعاء (Recall) وF1، وتُعرَّف لكل فئة c كما يلي ثم يؤخذ متوسطها الحسابي على الفئات الأربع:

$$Precision_c = TP_c / (TP_c + FP_c) \qquad Recall_c = TP_c / (TP_c + FN_c)$$

$$F1_c = 2 \cdot Precision_c \cdot Recall_c / (Precision_c + Recall_c) \qquad Macro\text{-}F1 = (1/4) \Sigma_c F1_c$$

ولتقدير عدم اليقين، نحسب فترة ثقة Wilson بمستوى 95% للدقة الكلية على العينات الألفين [26]. تعطي هذه الفترة تقديراً تقريبياً لعدم اليقين لكل نموذج على حدة، ولا تغني عن اختبار مزدوج مثل McNemar [27] الذي يتطلب تنبؤات كل عينة.

4.9 بيئة التنفيذ

نُفّذت تجارب المحوّلات على Google Colab بوحدة معالجة رسومية، باستخدام مكتبات Transformers [24] و PyTorch و[25] scikit-learn و[23] Optuna. ونُفّذت خطوط الأساس الكلاسيكية بمكتبة scikit-learn على المعالج المركزي، واستغرق تدريبها وتقييمها على الفولدات الخمسة أقل من دقيقة.

5. النتائج

5.1 السيناريو الأول: إعدادات موحّدة

يعرض الجدول 5 نتائج النماذج الثلاثة بإعدادات موحّدة. يتصدر AraBERTv2 بدقة 92.45% وF1-Macro يساوي 0.9243 و151 خطأً من 2,000 عينة، يليه MARBERTv2 (91.95%) ثم ARBERTv2 (91.05%). والفارق بين الأول والأخير 1.4 نقطة مئوية، أي 28 عينة.

الجدول 5. نتائج السيناريو الأول (متوسط الفولدات الخمسة).

النموذج	الدقة	Precision	Recall	F1-Macro	الأخطاء
AraBERTv2	92.45%	0.9255	0.9245	0.9243	151
MARBERTv2	91.95%	0.9217	0.9195	0.9195	161
ARBERTv2	91.05%	0.9122	0.9105	0.9100	179

ويوضح الجدول 6 حقبة أفضل نقطة لكل فولد. يتقارب ARBERTv2 أسرع (متوسط 1.6 حقبة)، بينما يحتاج AraBERTv2 إلى 3.0 حقب. ويدل التقارب المبكر جداً لـ ARBERTv2 على أن معدل التعلم الموحّد قد لا يناسبه، وهو ما يؤكده السيناريو الثاني.

الجدول 6. الحقبة التي سُجّلت فيها أدنى خسارة تحقق في كل فولد.

النموذج	F1	F2	F3	F4	F5	المتوسط
AraBERTv2	5	2	2	4	2	3.0
MARBERTv2	3	2	2	2	3	2.4
ARBERTv2	3	1	1	1	2	1.6

5.2 السيناريو الثاني: ضبط المعاملات بإطار Optuna

يعرض الجدول 7 أفضل المعاملات لكل نموذج، والجدول 8 نتائجها. فضّل MARBERTv2 معدل تعلم منخفضاً جداً (5.24×10^{-6}) مع دفعات صغيرة (8)، بينما فضّل AraBERTv2 وARBERTv2 معدلات أعلى بنحو ستة أضعاف مع دفعات أكبر (32). وأظهرت مخططات أهمية المعاملات أن معدل التعلم هو الأكثر تأثيراً، تليه نسبة الإحماء، بينما كان أثر حجم الدفعة محدوداً.

الجدول 7. أفضل المعاملات الفائقة لكل نموذج بعد الضبط.

النموذج	معدل التعلم	حجم الدفعة	نسبة الإحماء
AraBERTv2	3.44×10^{-5}	32	0.0366
ARBERTv2	2.92×10^{-5}	32	0.0008
MARBERTv2	5.24×10^{-6}	8	0.0182

الجدول 8. نتائج السيناريو الثاني والتحسن مقارنة بالسيناريو الأول.

النموذج	الدقة	Precision	Recall	F1-Macro	الأخطاء	ΔF1
AraBERTv2	92.70%	0.9303	0.9270	0.9271	146	0.0028+
ARBERTv2	92.45%	0.9266	0.9245	0.9246	151	0.0146+
MARBERTv2	92.40%	0.9247	0.9240	0.9240	152	0.0045+

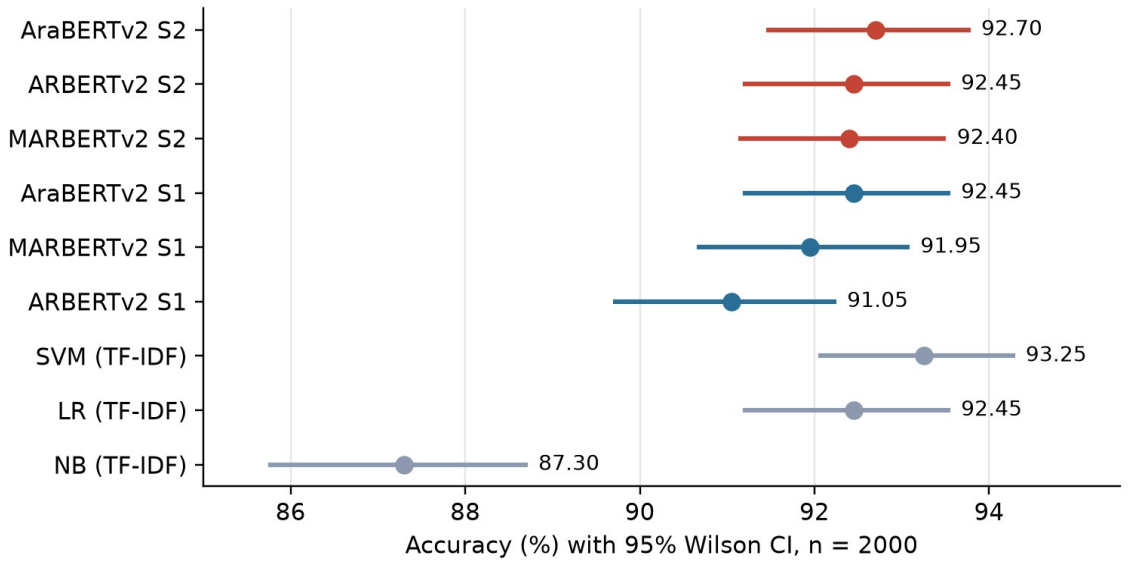
حسّن الضبط النماذج الثلاثة جميعاً، وكان أكبر تحسن لـ ARBERTv2 (+1.40 نقطة في الدقة) الذي انتقل من المرتبة الأخيرة إلى الثانية. وحافظ AraBERTv2 على الصدارة، لكن الفارق بين النماذج الثلاثة تقلص إلى 0.30 نقطة مئوية فقط (6 عينات). أي أن جزءاً كبيراً من الفروق في السيناريو الأول يعود إلى ملاءمة الإعدادات لا إلى النموذج نفسه.

5.3 المقارنة مع خطوط الأساس الكلاسيكية

يعرض الجدول 9 نتائج خطوط الأساس على الفولدات ذاتها، ويوضح الشكل 2 الدقة الكلية لجميع الأنظمة مع فترات ثقة 95%. حقّق SVM الخطي على سمات الكلمات والحروف دقة 93.25% (F1-Macro = 0.9325)، أي أعلى من أفضل نموذج محوّلات بـ 0.55 نقطة، وحقق الانحدار اللوجستي 92.45%، مساوياً لـ AraBERTv2 في السيناريو الأول. بينما تأخر Naive Bayes على سمات الكلمات فقط (87.30%).

الجدول 9. نتائج خطوط الأساس الكلاسيكية (متوسط الفولدات الخمسة، والانحراف المعياري بالنقاط المئوية).

النموذج	السمات	الدقة	الانحراف المعياري للدقة	F1-Macro	الأخطاء
Multinomial NB	كلمات (1–2)	87.30%	0.62	0.8727	254
Logistic Regression	كلمات (1–2) + حروف (2–5)	92.45%	0.91	0.9247	151
Linear SVM	كلمات (1–2) + حروف (2–5)	93.25%	0.57	0.9325	135

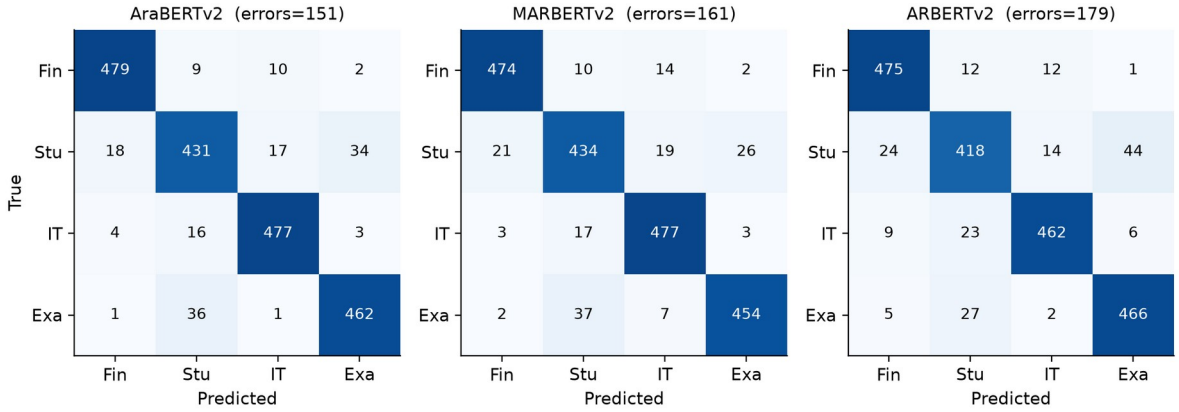


الشكل 2. الدقة الكلية مع فترة ثقة Wilson بمستوى 95% (n = 2000). S1: إعدادات موحّدة، S2: ضبط بإطار Optuna.

عرض فترة الثقة نحو ±1.1 نقطة مئوية، وتتداخل فترات جميع الأنظمة عدا Naive Bayes. فلا يمكن القول بوجود فرق دال إحصائياً بين أفضل نموذج محوّلات وSVM، ولا بين نماذج المحوّلات الثلاثة في السيناريو الثاني.

5.4 الأداء حسب الفئة ومصفوفات الارتباك

يوضح الشكل 3 مصفوفات الارتباك المجمّعة من الفولدات الخمسة في السيناريو الأول، ويعرض الجدول 10 قيم F1 لكل فئة المحسوبة منها. الفئة الأسهل هي الشؤون المالية (F1 بين 0.938 و0.956)، والأصعب بفارق واضح هي شؤون الطلاب (F1 بين 0.853 و0.870) في النماذج الثلاثة.



الشكل 3. مصفوفات الارتباك المجمّعة للسيناريو الأول (Fin: مالية، Stu: شؤون طلاب، IT: معلوماتية، Exa: امتحانات).

الجدول 10. قيم F1 لكل فئة في السيناريو الأول.

الفئة	AraBERTv2	MARBERTv2	ARBERTv2
الشؤون المالية	0.956	0.948	0.938
شؤون الطلاب	0.869	0.870	0.853
مكتب المعلوماتية	0.949	0.938	0.933
شؤون الامتحانات	0.923	0.922	0.916

5.5 تحليل الأخطاء

يبيّن الجدول 11 توزيع الأخطاء على أزواج الارتباك. يستحوذ الزوج (امتحانات ↔ شؤون طلاب) بالاتجاهين على 39.1% إلى 46.4% من أخطاء كل نموذج، وهو الزوج الأكثر تكراراً في النماذج الثلاثة، وتمثل الأخطاء الـتي

تكون شؤون الطلاب فيها الفئة الحقيقية بين 41.0% و45.8% من الأخطاء. وتتوزع أخطاء هـذه الفئـة على الفئات الثلاث الأخرى، لأن شؤون الطلاب واجهة عامة تتقاطع مفرداتها مع الجميع: «المواد» و«المعدل» مـع الامتحانات، و«الدفع» مع المالية، و«الموقع» و«النظام» مع المعلوماتية.

الجدول 11. توزيع الأخطاء حسب أزواج الارتباك (الحقيقي ← المتنبأ به) في السيناريو الأول.

الزوج	AraBERTv2	MARBERTv2	ARBERTv2
امتحانات ← شؤون طلاب	36	37	27
شؤون طلاب ← امتحانات	34	26	44
شؤون طلاب ← مالية	18	21	24
شؤون طلاب ← معلوماتية	17	19	14
معلوماتية ← شؤون طلاب	16	17	23
مالية ← معلوماتية	10	14	12
مالية ← شؤون طلاب	9	10	12
بقية الأزواج (5 أزواج)	11	17	23
المجموع	151	161	179

ويلخص الجدول 12 تقاطع الأخطاء بين النماذج. أخطأت النماذج الثلاثة معاً في 73 استفساراً، تمثل 40.8% إلى 48.3% من أخطاء كل نموذج، واختلفت النماذج في الفئة المتنبأ بها في 16 منها. أما الأخطاء الحصـرية فبلغت 29 لـ AraBERTv2 مقابل 64 لـ ARBERTv2. وإجمالاً أُخطئ في 279 عينة مختلفة على الأقل من نموذج واحد، بينما صنّف نموذج واحد على الأقل 1,927 عينة تصنيفاً صحيحاً؛ أي أن سقف الأداء الممكن نظرياً بالتجميع (Oracle) يبلغ 96.35%، ما يدل على تكامل جزئي بين النماذج يمكن استثماره.

الجدول 12. تقاطع الأخطاء بين النماذج الثلاثة (السيناريو الأول).

نطاق التقاطع	عدد العينات
مشتركة بين النماذج الثلاثة	73
AraBERTv2 وMARBERTv2 فقط	24
AraBERTv2 وARBERTv2 فقط	25
MARBERTv2 وARBERTv2 فقط	17
حصرية لـ AraBERTv2	29
حصرية لـ MARBERTv2	47
حصرية لـ ARBERTv2	64

وتوضح أمثلة من الأخطاء المشتركة طبيعة الغموض: استفسار «هلق انا دفعت فيني نزل المواد عالموقع مباشر؟» (شؤون طلاب) صنّفته النماذج الثلاثة مالياً لهيمنة كلمة «دفعت»، مع أن جوهر السـؤال هـو تسـجيل المـواد. واستفسار «بدي الكوود الخاص بجامعتنا» (معلوماتية) خالٍ من أي فعل تقني أو إشارة إلى منصة، فتوزعت تنبؤات النماذج بين شؤون الطلاب والمالية. أما استفسار «ممكن ينشال الحجب عني لأن نزلت علامتي ... وطبعا سددت يلي علي» (مالية) فيحمل ثلاث إشارات متنافسة: «علامتي» للامتحانات، و«الحجب» للمعلوماتية، و«سددت» للمالية.

6. المناقشة

6.1 لماذا تفوّق AraBERTv2 على MARBERTv2 رغم الطابع العامي؟

قد يُتوقع أن يتفوق MARBERTv2 لأن أكثر من نصف الاستفسارات يحمل مؤشرات عامية. لكن النتائج تتسق مع أفضلية AraBERT في تصنيف المواضيع على معيـار ARLUE [8]، ويمكن تفسـيرها بعـاملين: الأول أن المفردات الحاسمة للتصنيف مؤسسية فصيحة الجذر (التسجيل، الامتحان، الرسوم، الاعتراض) حتى في الجمـل العامية، وهي مفردات كثيفة في بيانات تدريب AraBERTv2؛ والثاني أن عامية الاستفسارات الجامعية مخففة وقريبة من الفصحى مقارنة بعامية التغريدات، ما يقلص الفجوة بين توزيع بيانات التـدريب المسـبق وبيانـات

المهمة [10]. ولا نعدّ الفارق بين النموذجين حاسماً، فهو 0.30 نقطة مئوية في السيناريو الثاني، ضمن هامش عدم اليقين.

6.2 هل تحتاج المهمة إلى المحوّلات؟

أهم نتيجة في هذا البحث أن SVM الخطي غير المضبوط على سمات الكلمات والحروف نافس أفضل نماذج المحوّلات، بل تجاوزها بفارق غير دال إحصائياً. وهذا يتسق مع ما وثقته الأدبيات من قوة خطوط الأساس القائمة على n-gram في تصنيف المواضيع [19]. ونفسر ذلك بثلاثة عوامل: (أ) تحكم المهمةَ إشاراتٌ معجمية قوية، فكلمات مثل «قسط» و«كلمة السر» و«اعتراض» تكفي غالباً لتحديد الجهة؛ (ب) تتعامل سمات الحروف مع التنوع الإملائي لأن «ايمت» و«ايمتا» تشتركان في معظم مقاطعهما الحرفية، وهي ميزة لا يضمنها مجزّئ مدرّب على الفصحى؛ (ج) حجم البيانات (1,440 عينة تدريب لكل فولد) صغير نسبياً مقارنة بنماذج يتجاوز عدد معاملاتها 110 ملايين، وهي بيئة يُعرف فيها عدم استقرار الضبط الدقيق وحساسيته للبذرة [22].

ولهذه النتيجة دلالة عملية: يُدرَّب SVM ويُقيَّم في ثوانٍ على المعالج المركزي، ويُستدعى بزمن وكلفة أقل بكثير من نموذج بحجم BERT-base، وهذا مهم لمؤسسات تعليمية ذات موارد محدودة. غير أن هذا لا يعني أن المحوّلات بلا قيمة؛ فقد تعمم أفضل على صياغات جديدة لم ترد في التدريب، أو على فئات أوسع، أو عند تجميعها مع المصنفات الكلاسيكية، إذ يدل سقف التجميع (96.35%) على أن النماذج تخطئ في عينات مختلفة جزئياً. وهذه فرضيات تحتاج إلى اختبار خارج التوزيع، ولا تثبتها نتائجنا الحالية.

6.3 حساسية الإعدادات

غيّر ضبط المعاملات ترتيب النماذج: انتقل ARBERTv2 من المرتبة الأخيرة إلى الثانية، وتقلص الفارق بين الأول والأخير من 1.40 إلى 0.30 نقطة. فالمقارنات المنشورة بإعدادات موحّدة قد تعكس ملاءمة الإعدادات أكثر مما تعكس جودة النموذج، ولذلك نوصي بإجراء السيناريوهين معاً في أي مقارنة بين النماذج المدرّبة مسبقاً.

6.4 مهددات الصلاحية

- **مصدر البيانات وتمثيلها:** جُمعت البيانات من جامعة خاصة واحدة وبيئة لهجية واحدة، ويتضمن جزء منها استفسارات محاكية كتبها فريق البحث، ما قد يُدخل أنماطاً أسلوبية تجعل المهمة أسهل من الواقع. ولم نفصل في هذه النسخة بين العينات الحقيقية والمحاكية لتقييم كل منها منفردة.
- **التوسيم:** لم نحسب معامل اتفاق بين موسّمين مستقلين، وبعض الاستفسارات الحدية قد تنتمي فعلياً إلى أكثر من جهة؛ ويُرجّح أن جزءاً من الأخطاء المشتركة (73 عينة) يعكس غموضاً في التوسيم لا قصوراً في النماذج.
- **انحياز اختيار الإعدادات:** اختير أفضل المرشحين الثلاثة في السيناريو الثاني بناءً على متوسط الأداء على فولدات الاختبار نفسها، وهذا قد يرفع نتائج هذا السيناريو قليلاً. والحل المنهجي هو التحقق المتقاطع المتداخل (Nested CV) [29]. ولم تُضبط خطوط الأساس الكلاسيكية إطلاقاً، فالمقارنة لا تحابيها.
- **التباين الإحصائي:** دُرّب كل نموذج ببذرة واحدة، ولم تُحفظ تنبؤات كل عينة لإجراء اختبار McNemar المزدوج، فاكتفينا بفترات ثقة لكل نموذج منفرداً.
- **الخصوصية:** تتضمن بعض الاستفسارات أسماء وأرقاماً جامعية كتبها الطلاب بأنفسهم، ونوصي بإخفاء هذه البيانات الشخصية في أي إصدار عام للمجموعة.

7. الخلاصة والعمل المستقبلي

قدّم هذا البحث مجموعة بيانات عربية جديدة ومتوازنة من 2,000 استفسار طلابي جامعي هجين بين الفصحى والعامية السورية، وقارن منهجياً ثلاثة نماذج محوّلات عربية وثلاثة خطوط أساس كلاسيكية على فولدات موحّدة. تصدر AraBERTv2 نماذج المحوّلات في السيناريوهين (F1-Macro = 0.9271 بعد الضبط)، ما يؤكد ملاءمة النماذج المدرّبة على الفصحى لمهام التصنيف الموضوعي حتى مع حضور العامية. لكن الفروق بين النماذج الثلاثة بعد الضبط ضئيلة، وقد نافسها مصنّف SVM على سمات الكلمات والحروف (93.25%) دون فرق دال إحصائياً. وتبيّن أن فئة شؤون الطلاب هي مركز الالتباس، وأن قرابة 40% من الأخطاء مشتركة بين النماذج وتعكس غموضاً متأصلاً في النصوص.

ونقترح للعمل المستقبلي: (1) توسيع المجموعة لتشمل جامعات ولهجات أخرى، مع التوسيم المستقل وحساب معامل الاتفاق؛ (2) اختبار التعميم خارج التوزيع على استفسارات حقيقية جُمعت بعد بناء النموذج؛ (3) تجميع المحوّلات مع المصنفات الكلاسيكية لاستثمار تكاملها؛ (4) دراسة التصنيف متعدد الوسوم أو الهرمي للاستفسارات الحدية؛ (5) مقارنة نماذج لغوية كبيرة عربية ومتعددة اللغات في وضع التعلم بالأمثلة القليلة؛ (6) إدماج آلية لتقدير عدم اليقين تحيل الاستفسارات منخفضة الثقة إلى مراجعة بشرية.

توافر البيانات والشيفرة

مجموعة البيانات متاحة على منصة Hugging Face بالمعرّف daliaalkelani/University_Student_Inquiries_Dataset_new3، وشيفرة تجارب المحوّلات وخطوط الأساس متاحة في المستودع: https://github.com/Daliaalkilani/Arabic-Nlp-University-Routing

شكر وتقدير

يشكر المؤلفون موظفي مكاتب الشؤون المالية وشؤون الطلاب والمعلوماتية والامتحانات في الجامعة الوطنية الخاصة على تعاونهم في مرحلة الجمع الميداني.

تضارب المصالح

يصرّح المؤلفون بعدم وجود أي تضارب في المصالح.

المراجع

[1] C. W. Okonkwo and A. Ade-Ibijola, "Chatbots applications in education: A systematic review," Computers and Education: Artificial Intelligence, vol. 2, p. 100033, 2021.

[2] N. Y. Habash, Introduction to Arabic Natural Language Processing. San Rafael, CA, USA: Morgan & Claypool, 2010.

[3] K. Darwish et al., "A panoramic survey of natural language processing in the Arab world," Communications of the ACM, vol. 64, no. 4, pp. 72–81, 2021.

[4] O. F. Zaidan and C. Callison-Burch, "Arabic dialect identification," Computational Linguistics, vol. 40, no. 1, pp. 171–202, 2014.

[5] A. Vaswani et al., "Attention is all you need," in Advances in Neural Information Processing Systems (NeurIPS), 2017, pp. 5998–6008.

[6] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in Proc. NAACL-HLT, 2019, pp. 4171–4186.

[7] W. Antoun, F. Baly, and H. Hajj, "AraBERT: Transformer-based model for Arabic language understanding," in Proc. 4th Workshop on Open-Source Arabic Corpora and Processing Tools (OSACT4), 2020, pp. 9–15.

[8] M. Abdul-Mageed, A. Elmadany, and E. M. B. Nagoudi, "ARBERT & MARBERT: Deep bidirectional transformers for Arabic," in Proc. ACL-IJCNLP, 2021, pp. 7088–7105.

[9] A. Elmadany, E. M. B. Nagoudi, and M. Abdul-Mageed, "ORCA: A challenging benchmark for Arabic language understanding," in Findings of the Association for Computational Linguistics: ACL 2023, 2023.

[10] G. Inoue, B. Alhafni, N. Baimukan, H. Bouamor, and N. Habash, "The interplay of variant, size, and task type in Arabic pre-trained language models," in Proc. 6th Arabic Natural Language Processing Workshop (WANLP), 2021, pp. 92–104.

[11] A. S. Alammary, "BERT models for Arabic text classification: A systematic review," Applied Sciences, vol. 12, no. 11, p. 5720, 2022.

[12] K. Darwish and H. Mubarak, "Farasa: A new fast and accurate Arabic word segmenter," in Proc. 10th Int. Conf. Language Resources and Evaluation (LREC), 2016, pp. 1070–1074.

[13] T. Kudo and J. Richardson, "SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing," in Proc. EMNLP: System Demonstrations, 2018, pp. 66–71.

[14] Z. Alyafeai, M. S. Al-shaibani, M. Ghaleb, and I. Ahmad, "Evaluating various tokenizers for Arabic text classification," Neural Processing Letters, vol. 55, 2023.

[15] H. Alamoudi, "Arabic sentiment analysis for student evaluation using machine learning and the AraBERT transformer," Engineering, Technology & Applied Science Research, vol. 13, no. 5, pp. 11945–11952, 2023.

[16] N. S. Alturayeif and H. Luqman, "Fine-grained sentiment analysis of Arabic COVID-19 tweets using BERT-based transformers and dynamically weighted loss function," Applied Sciences, vol. 11, no. 22, p. 10694, 2021.

[17] N. K. Al-Harbi and M. Alghieth, "Assessing BERT-based models for Arabic and low-resource languages in crime text classification," PeerJ Computer Science, vol. 11, p. e3017, 2025.

[18] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in Proc. European Conf. Machine Learning (ECML), 1998, pp. 137–142.

[19] S. Wang and C. D. Manning, "Baselines and bigrams: Simple, good sentiment and topic classification," in Proc. 50th Annual Meeting of the ACL, 2012, pp. 90–94.

[20] Y. Kim, "Convolutional neural networks for sentence classification," in Proc. EMNLP, 2014, pp. 1746–1751.

[21] C. Sun, X. Qiu, Y. Xu, and X. Huang, "How to fine-tune BERT for text classification?" in Proc. China National Conf. Chinese Computational Linguistics (CCL), 2019, pp. 194–206.

[22] M. Mosbach, M. Andriushchenko, and D. Klakow, "On the stability of fine-tuning BERT: Misconceptions, explanations, and strong baselines," in Proc. Int. Conf. Learning Representations (ICLR), 2021.

[23] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in Proc. 25th ACM SIGKDD, 2019, pp. 2623–2631.

[24] T. Wolf et al., "Transformers: State-of-the-art natural language processing," in Proc. EMNLP: System Demonstrations, 2020, pp. 38–45.

[25] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[26] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," Journal of the American Statistical Association, vol. 22, no. 158, pp. 209–212, 1927.

[27] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," Neural Computation, vol. 10, no. 7, pp. 1895–1923, 1998.

[28] X. Zhang, J. Zhao, and Y. LeCun, "Character-level convolutional networks for text classification," in Advances in Neural Information Processing Systems (NeurIPS), 2015, pp. 649–657.

[29] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," Journal of Machine Learning Research, vol. 11, pp. 2079–2107, 2010.